

个人 HomeBench: 个性化智能家居智能体评估

LG研究团队¹

摘要

Agentic AI系统正迅速发展以应用于实际场景, 但其在复杂且个性化环境中的准备程度仍缺乏充分刻画。为填补这一空白, 我们提出了**PersonalHomeBench**, 一个用于评估基础模型作为个性化智能家居环境中智能体助手的基准测试。该基准通过迭代过程构建, 逐步累积丰富的家庭状态, 并基于这些状态生成依赖上下文、个性化的任务。为了支持真实的智能体与环境交互, 我们提供了**PersonalHomeTools**, 一个包含家庭信息检索、设备控制和情境理解等功能的综合工具箱。PersonalHomeBench在单模态和多模态观察下评估了反应性与主动性的智能体能力。深入实验表明, 随着任务复杂度增加, 模型性能系统性下降, 尤其在反事实推理和部分可观测性条件下表现明显, 而后者要求有效的基于工具的信息收集。这些结果将PersonalHomeBench定位为一个严格的评估平台, 用于分析个性化智能体推理与规划的鲁棒性和局限性。

1. 引言

智能体AI系统旨在超越被动预测, 向日常环境中的自主辅助迈进, 在这些环境中, 稳健的性能取决于上下文推理、不确定性处理和个性化。尽管已经提出了越来越多的基准来评估智能体系统, 但大多数现有评估侧重于简化或模拟环境中的通用任务(张等人, 2024b; 博纳蒂等人, 2025; 席等人, 2025)。因此, 它们对模型行为在

¹多伦多和 Korea Labs。作者贡献列于附录。通讯作者: Nikhil Verma 和 InJung Yang<nikhil.verma@lge.com, kayla.yang@lge.com>。

预印本。2026年4月21日。




图1. PersonalHomeBench 数据生成流水线概览。首先根据角色、设备、记忆和背景描述组装详细的家庭环境, 并可选择视频 grounding。然后, 从这些环境中生成五类个性化任务, 涵盖反应性问题回答和主动辅助, 从而能够在个性化智能家居环境中评估智能体行为。

不断变化的个性化偏好、长期背景和部分可观测性下的洞察有限, 导致对个性化真实世界部署准备情况的不完整评估。

智能家居环境为揭示这些局限提供了自然且富有挑战性的测试平台。在该领域有效运作需要推理异构设备、维持持久且具有时间基础的上下文, 并适应不断演变的用户偏好, 同时兼顾安全性、效率和操作约束。先前的智能家居基准主要依赖简化的抽象, 例如设备覆盖有限且仅含原始动作的纯文本环境, 或是聚焦于孤立设备控制的窄范围任务(Li等人, 2025; Bartkowiak & Podstawski, 2025)。我们将智能家居视为个性化智能体智能的现实场景, 由此引入**PersonalHomeBench**, 这是一个在家庭环境中评估基础模型的框架, 其要求超越反应性任务执行的上下文推理、个性化和主动决策。

PersonalHomeBench 采用分阶段环境构建流程，它反映真实家庭演变，依次实例化居民角色设定、分配设备生态系统，并随时间积累上下文信号以合成连贯的家庭世界，同时可选多模态接地。如图1所示，从这些环境中衍生出五类个性化任务，以支持反应性推理和主动计划的统一评估，其流程借鉴了（Singh等人，2024）的方法。其中包括三项反应性问答任务：信息接地、反事实推理和多项选择，以及两项主动任务：特征推荐和计划生成，后者针对设备和例程层面的编排，实现及时的、偏好感知的家居辅助。

为了支持对智能体行为的忠实评估，我们引入了 **PersonalHomeTools**，这是一个智能家居工具箱，为智能体与真实家庭环境之间提供了基础交互层。它通过领域特定API，提供了结构化家庭信息检索、持久记忆和事件访问、环境感知以及真实设备控制等功能。这些能力共同支持了对融合感知、记忆和工具使用以实现个性化决策的智能体的系统性研究。

我们评估了广泛的基础模型，范围从适用于隐私保护边缘部署的紧凑型40亿参数模型，到基于云的大规模模型。除了任务特定指标外，我们采用角色扮演大语言模型（Wang等人，2024）作为评判者，以估算家庭中各个成员的预期满意度。在不同模型规模下，涉及工具使用、长期规划和高级推理的任务性能急剧下降，并且常伴随幻觉增加。这些发现揭示了当前系统的根本性局限，并凸显了在真实智能家居场景中实现稳健、个性化和主动行为的难度，从而将 *PersonalHomeBench* 确立为诊断故障和指导开发更可靠个性化智能体的实用资源。

我们的贡献有三方面：

- 我们介绍了 *PersonalHomeBench*，这是一个用于研究在情境化的智能家居环境中个性化和主动智能体行为的基准。
- 我们展示了 *PersonalHomeTools*，这是一个用于真实智能体评估的综合智能家居工具包。
- 我们跨模型规模和推理水平进行系统评估，并利用角色扮演大语言模型作为评判者来评估个性化满意度。

表1. 沿五个维度对基准进行对比：家庭类型、个性化、主动性、与工具的智能体交互以及多模态支持。SIM = 模拟家庭，REAL = 真实家庭数据，NONE = 非家庭设置。* 标记将多模态内容表示为文本用于推断的设置。

方法	家庭类型	个人	主动	代理	MM
具身基准	SIM	✗	✗	✓	✓
Toyota Smarthome	REAL	✗	✗	✗	✓
PersonalTravelPlanner	NONE	✓	✗	✓	✗
HomeBench	SIM	✗	✗	✓	✗
Edgewisepersona	SIM	✓	✓	✓	✗
Contextagent	NONE	✓	✓	✓	✓*
PersonalHomeBench (我们的)	SIM+REAL	✓	✓	✓	✓

2. 相关工作

如表1所述，现有的家庭领域基准（Puig 等人，2018; Shridhar 等人，2019; Li 等人，2024; Chang 等人，2024a; Yang 等人，2025c）侧重于模拟 3D 环境中的导航和原子动作执行，但并未建模真实的智能设备生态系统或个性化。Toyota Smarthome（Das 等人，2019）提供了真实家庭视频数据，但仅限于狭窄的人口统计和固定环境，并且侧重于活动识别，而非个性化、主动性或交互式智能体辅助。

最近的基准测试涵盖了工具使用和个性化方面的内容。PersonalTravelPlanner（Singh 等人，2024）研究了家庭领域之外使用简单工具的个性化规划。HomeBench（Li 等人，2025）评估了反应式智能家居命令验证，但电器覆盖范围有限且操作受限；而 Edgewisepersona（Bartkowiak & Podstawski，2025）则专注于在小型设备集上进行配置文件重建和轻量级例行推断，仅通过简短的角色描述实现最低限度的个性化。ContextAgentBench（Yang 等人，2025b）引入了具有上下文信息和工具的主动智能体，但依赖于以自我为中心的轨迹、通用 API 和仅语言推理，且个性化程度有限。

PersonalHomeBench 专注于在真实的家庭环境中智能体行为，其中个性化、长期上下文、感知和智能设备交互共同影响决策。通过与 *PersonaHomeTools* 集成，它评估智能体能否检索相关家庭信息、推理持久状态并协调设备操作，以提供主动的个性化辅助。如表2所示，现有基准测试均未同时涵盖真实家庭数据、个性化、主动性、领域特定工具和多模态，这使得 *PersonalHomeBench* 成为研究智能家居领域个性化智能体行为的统一平台。附录B中提供了对相关基准测试的额外讨论。

3. PersonalHomeBench

PersonalHomeBench 生成流程的概览如图1所示。各个组成部分将在后续章节中详细说明。

3.1. 家庭生成

如图家庭生成模块（图1）所示，生成过程从一个最小化框架开始，该框架指定了家庭类型、布局和粗略的人口统计信息，并利用来自 Nemotron Personas (Meyer& Corneil,2025) 的角色进行初始化，以实例化逼真的居住者。这些角色连同家庭元数据，被数据生成模型用于生成完整的居住者档案，这些档案符合预定义的模式（附录G）。随后，通过为环境分配合适的家电、综合历史记忆（涵盖设备使用和个人事件）以及更新居住者属性与家电状态以反映当前情况，家庭上下文得以逐步丰富。最后，构建一个紧凑的情境相关记忆缓存，提供家庭的一致快照，作为个性化任务生成的基础。

对于多模态设置，我们进一步利用放置在各个房间的摄像机拍摄的外心视频来锚定家庭上下文。我们生成结构化视频转录文本，包含实体引用、对象提及、时间戳事件以及对齐的音频字幕。为了在保持与视觉证据一致性的同时支持超越直接观察的推理，我们为视频基础信息和推断信息维护了独立的表示。详细的主题说明和视频转录模式分别见附录C.2和G。

所有生成的数据都经过人工审核，以确保真实性、内部一致性和模式合规性，从而产出高质量的家庭环境，用于下游的个性化任务生成。

3.2. 个性化任务生成

利用构建好的家庭环境以及相关的视频和转录（如果有），我们推导出五类个性化任务，这些任务探究智能家居环境中推理和规划的互补方面。任务生成假设完全可观测性，为模型提供整个家庭上下文。

反应式 任务被构建为封闭式问答问题，包括信息锚定 (IG)、反事实推理 (CF) 和多项选择 (MC)。这些任务评估智能体在不同难度级别下提取和整合家庭信息的能力，范围从直接事实查询到多-

跳推理涉及众多实体和属性。IG 衡量生成性事实接地，而 MC 则在受限答案选择下评估相同能力。CF 通过引入配对的反事实变体扩展了 IG，其中一个变体更改了真实答案，另一个则保持其未更改，从而实现对假设扰动的鲁棒性的针对性分析。例如，修改时间性背景可能会改变居民的年龄，而更改无关属性（如衣着）则不应改变。

主动型任务评估开放式的、主观的决策，用于个性化辅助，测试智能体是否能在没有明确提示的情况下预判用户需求并启动合适的动作。我们定义了两个这样的任务：特征推荐 (FR) 和计划生成 (PG)，侧重于家电和日常编排。

在FR中，智能体根据提供的API级清单按上下文相关性对家电特征进行排序，反映了现实世界中的特征发现与配置。在PG设置中，智能体生成结构化多步计划，协调异构设备以实现共同目标。例如，安全关键情况可以触发一个协调响应，启动急救援助、通知看护者并关闭危险家电（图2）。

3.3. 数据集统计

家庭数据。 *PersonalHomeBench* 包含 1,100 个家庭，采用第 3.1 节所述流程生成，每个家庭均遵循附录 G 中的模式，并包含超过 2,000 个独特的家庭成员档案。这些家庭展现出广泛的人口统计与结构多样性，年龄与性别分布均衡（图 3a）。大多数家庭不饲养宠物，而养宠物在家庭中最常见（图 3b）。每个家庭至少包含五件必备家电，大多数家庭拥有 9-10 件家电（附录图 7b）。家庭成员进一步标注了丰富的画像属性，包括爱好、生活方式和偏好，支持细粒度个性化；频繁出现的属性汇总于图 3d。此外，我们将 100 个家庭落地到真实家庭视频中，涵盖健康、安全和日常护理场景，视频时长分布如图 3c 所示。更多分析见附录 C。

个性化任务数据。 *PersonalHomeBench* 总共包含 9,168 个任务实例，其中包括 6,000 个纯文本示例和 3,168 个多模态示例。纯文本子集包含 IG、MC、FR 和 PG 各 1,000 个实例，以及 CF 的 2,000 个实例。对于多模态基础，数据集包含 IG 和 MC 各 742 个实例、CF 1,484 个实例，以及 FR 和 PG 各 100 个实例。反应式任务 (IG、CF、MC) 进一步标注了三个难度等级（简单、中等、困难）。与现有的个性化与主动式智能体系统基准相比，




图2. 智能体解读真实世界家庭场景与触发器，利用PersonalHomeTools生成主动计划（例如安全、急救、环境控制），并由Role Playing Judge进行评估，最终输出个性化推荐。

(Xie et al., 2024a; Singh et al., 2024; Yanget al., 2025b; Bartkowiak & Podstawski, 2025), PersonalHomeBench 在规模、任务多样性和支持的输入模态方面提供了更广泛的覆盖，从而能够在现实场景中对智能体行为进行更全面的评估。

4. PersonalHomeTools

如图2所示，PersonalHomeTools作为统一的交互层，使智能体能够感知、推理并作用于家庭环境，构成了我们框架的核心组件。该工具箱提供了家庭信息检索、设备控制以及上下文理解等能力。

家庭信息检索提供对居住者、宠物、家电及其他家庭实体的相对静态元数据的访问。由于此类信息变更频率较低，这些功能以非智能体工具的形式实现，返回确定性结构化输出。

设备控制工具使智能体能够影响家中智能设备的状态。我们基于主要智能家居供应商的公开文档，为超过40种智能家电实现了特征级接口，构建了一个全面的控制沙箱¹。设备交互可以是确定性的（如电源控制），或由家电专用智能体进行中介（如为冰箱配备的个性化菜谱推荐器）。

大多数智能体模块旨在通过自然语言查询结合可选的基于属性过滤实现混合推理，并复用缓存结果直到底层状态发生变更，从而支持深度上下文理解。

¹LG电子和三星。

核心智能体组件包括三个专门智能体：一个 *Transcriber*、一个 *Memory Retriever* 和一个 *Video Understanding Agent*。Transcriber 通过从观察结果中提取并更新记忆、事件和上下文属性，逐步构建和维护家庭状态。Memory Retriever 可根据需要检索与整体家庭及特定居住者相关的情境感知记忆。当多模态基础可用时，*Video Understanding Agent* 会检索相关片段、帧或音频线索，以便将视觉和听觉上下文纳入推断。

这些组件共同提供了一个连贯的接口，智能体通过该接口收集背景信息、基于持久记忆进行推理，并执行个性化操作，从而实现对工具中介推理和主动辅助的严格评估。支持的电器、功能、工具和智能体接口的完整列表见附录J。

5. 实验设置

本节介绍用于评估基础模型在 *PersonalHomeBench* 上的评估协议，涵盖评估的模型、实验设置和指标。

5.1. 模型与超参数

模型。我们对来自 QWEN3 (Yang 等人, 2025a)、GPT、NEMOTRON 和 GEMINI 模型系列的十一个基础模型进行了基准测试，这些模型涵盖多种规模层级、架构和推理配置。评估的模型分为三类：

- (1) 大型专有模型: GPT-4 (Achiam 等人, 2023), GPT-4o (Hurst 等人, 2024), 和 GEMINI 2.5 PRO (Co-




图3. PersonalHomeBench中生成的房屋与角色多样性统计。(a) 家庭成员的年龄和性别分布。(b) 按家庭类型划分的宠物数量分布。(c) 视频时长分布(秒)。(d) 常见角色属性词云, 展示兴趣、习惯和生活方式特征的多样性。

Manici 等人, 2025), (2) 中型开源模型: QWEN3-30B-INSTRUCT, QWEN3-30B-THINKING, NEMOTRON3- NANO-30B-A3B (Blakeman 等人, 2025), 和 GPT-OSS- 20B (Agarwal 等人, 2025). (3) 小型开源模型: QWEN3-4B 和 QWEN3-4B-THINKING.

对于支持显式推理模式的模型, 我们评估了多种推理配置。具体而言, GPT-OSS-20B在三个推理水平(低、中等、高)上进行了测试。为清晰起见, 我们在模型名称后附加一个单字母标签来表示推理模式, 例如QWEN3-4B [T], QWEN3-30B [T], 以及GPT-OSS-20B [L/M/H]。

我们使用GEMINI 2.5 PRO作为数据集生成的主要模型, 并作为所有LLM作为评判者协议(包括语义精确匹配和Role Playing Judge (*RPJ*))的评估主干。为减少潜在的评估偏差, 我们将GEMINI 2.5 PRO的性能与其他被评估模型的性能分开报告。

超参数。 我们使用温度0.6进行数据集生成以鼓励多样性, 并使用温度0.0以及 $\text{top-}p = 1.0$ 进行评估, 以获得确定性和可重复的输出。每个任务最多分配15个回合来完成。

除了智能体推理, 我们还在纯推理设置中评估模型, 其中完整的家庭上下文直接提供给模型, 无需任何工具调用。这种配置作为上界, 因为相关信息在提示中明确可用。

所有模型配置和推断设置的完整描述见附录E。

5.2. 评估指标

本小节描述了各任务中使用的评估指标, 然后详细介绍了用于主观评估的**角色扮演评判者**(*RPJ*)框架。

反应式任务。 对于这些确定性问答任务, 我们报告准确率(ACC)(附录公式3和6)。

对于IG和CF, 首先使用字符串级别的精确匹配来评估正确性。当精确匹配失败时, 我们采用

GEMINI 2.5 PRO 作为语义等价评判器, 判断预测答案是否与真实答案在意义上一致。这种混合方法之所以必要, 是因为有效答案的表面形式可能不同, 从短语到完整句子, 但表达相同的基本含义。对于CF, 表2报告了在 $CF_{\text{unchanged}}$ 和 CF_{changed} 上的宏平均。

对于多项选择题(MC), 准确率计算为选定选项(或其文本)与真实选项之间的精确匹配。由于所有有效答案都已明确列举, 我们不对该任务应用语义判断。

主动任务。 该F功能R推荐任务被表述为一个排序问题, 并使用排名一的平均精确率(MAP@1)进行评估(朱, 2004年)。对于P计划G生成, 我们报告两种角色扮演裁判分数, 用于评估偏好对齐的计划质量以及一个有效性指标, 定义为子程序步骤中可执行的、使用正确的工具或功能名称和格式良好的参数的比例(附录公式11)。

角色扮演裁判。 评估PG需要捕捉在个性化家庭偏好下的主观满意度。因此我们利用一个角色扮演LLM作为裁判框架, *RPJ*, 其中评判模型从单个家庭成员和家庭整体的角度评估计划。如算法1所示, *RPJ*以两种模式运行: 绝对模式和REL模式。

在绝对模式下, *RPJ*为计划中的每个子程序分配一个标量分数和文本反馈。由于计划可能同时包含强和弱的子程序, 这种模式能够进行细粒度分析, 并支持仅呈现高质量组件。我们使用 RPJ_{ABS} 进行多模态评估, 并报告整体平均分数。

在REL模式, *RPJ*根据家庭偏好对模型间的完整计划进行排名, 将评估构建为一种偏好比较, 这与RLHF式训练目标自然对齐(Comanici等人, 2025)。 RPJ_{REL} 在比较多个模型时特别高效。例如, 评估十一个模型需要 $11x$ 次调用在 RPJ_{ABS} 但仅需 x 次调用在 RPJ_{REL} 。

对于表 2 RPJ_{REL} 对每个实例的11个候选计划进行排名, 并报告胜率, 即模型排名第一的次数占比; 由于胜率总和为100%², 该指标反映的是偏好质量的分布, 而非绝对质量。关于指标定义和数学公式的详细信息, 请参见附录D.1。

算法1 角色扮演评判 (RPJ)

Require: 家庭角色 $\mathcal{H}$, 情境描述 S , 模型 $\{\mathcal{M}_i\}_{i=1}^N$
with 生成方案 $\{\mathcal{P}_i\}_{i=1}^N$, 评估模式 $mode \in \{ABS, REL\}$, 评判模型 $\mathcal{M}_\theta$
Ensure: 评估结果 R 包含整体和每角色结果
1: 初始化评判模型 $\mathcal{M}_\theta$ **with** RPJ 提示条件于 $\mathcal{H}, S$, 和 $mode$
2: 如果 $mode$ is ABS 则
3: 评分: 所有评分均为 $\{1, \dots, 5\}$ 范围内的整数, 其中5表示最高质量。
4: 对于每个方案 $\mathcal{P}_i$ **do**
5: 查询 $\mathcal{M}_\theta$ 为 $\mathcal{P}_i$ 分配一个整体 $score_o$
6: 对于每个家庭角色 $h \in \mathcal{H}$ **do**
7: 查询 $\mathcal{M}_\theta$ 为 $\mathcal{P}_i$ 分配一个每角色 $score_p$
8: 结束循环
9: 将整体和每角色评分存储到 R
10: 结束循环
11: 否则
12: 查询 $\mathcal{M}_\theta$ 根据方案的整体有用性对所有模型 $\{\mathcal{M}_i\}_{i=1}^N$ 进行排名
13: 对于每个家庭角色 $h \in \mathcal{H}$ **do**
14: 查询 $\mathcal{M}_\theta$ 从 h 的角度对所有模型 $\{\mathcal{M}_i\}_{i=1}^N$ 进行排名
15: 结束循环
16: 将整体和每角色排名存储到 R
17: 结束条件
18: 返回 R

6. 结果与讨论

在本节中, 我们总结了实验的关键发现, 并分析了各个因素的影响。

6.1. 总体结果

表2 揭示了跨模型和任务的一致模式: 从纯推理过渡到有工具的智能体执行时, 性能大幅下降。这种下降同时影响反应性和主动性任务, 表明有效的工具交互仍然是主要瓶颈。虽然更大的模型取得了更高的绝对性能, 但规模本身并不能弥合这一差距, 这表明主要失败源于交互层面的推理, 而非模型容量不足。在评估的模型中,

GPT-4 在大多数设置中取得了最强结果; 除此之外, 没有单一模型能在任务、模态和执行机制上持续占据主导地位。

反应式任务。在纯推理下, 模型在 IG 和 MC 上表现强劲, 许多模型超过85%的准确率。引入工具导致急剧下降, 频繁出现数十个百分点的降幅, 即使对于大型模型也是如此。最严重的退化发生在 IG 和 CF 上, 而 MC 的下降幅度略小但依然显著, 这可能是由于其受限的答案空间。这些趋势表明, 在智能体设置中, 检索和集成相关家庭信息的失败主导了错误模式。

主动任务。FR 在纯推理下表现出中等性能, 并且在引入工具时下降幅度最小, 这可能是因为被表述为预测排序问题而非自由形式生成。尽管如此, 即使是大型模型也难以在使用工具时维持良好的排序质量, 这表明将家庭上下文映射到相关家电特征方面存在持续的困难。

对于PG, RPJ_{REL} 评估表明, 尽管GPT-4占据了大部分胜场, 但许多其他模型也获得了不可忽视的胜率, 产生了分散的偏好分布。这种分散表明计划质量存在显著差异, 并指示模型常常生成仅部分符合家庭偏好的计划。

计划有效性描绘了更严峻的画面。在纯推理下, 大多数模型生成高度有效的结构化计划。在智能体设置中, 几乎所有基于文本的模型的有效性崩溃, 表明即使高层计划看似合理, 可靠地生成可运行的工具调用也是一个主要问题。少数模型仍保持较高的有效性, 但多模态输入并未改善可执行性, 反而略有降低。

推理模式。显式推理变体 (例如[T/L/M/H]) 在纯推理下持续提升性能, 特别是在反应式任务中, 但这些增益在智能体设置和主动任务中基本消失。在若干情况下, 更高的推理水平未能改善, 甚至可能降低工具中介性能, 表明额外的内部思考并未转化为更好的工具协调或状态跟踪。

多模态。多模态输入提升了在纯推理下的反应性能, 表明视觉基础有助于恢复情境细节。然而, 两种主动任务在多模态下均表现下降, 一旦引入工具, 仅文本与多模态之间的差异基本消失。这表明仅靠感知无法应对工具使用和长程规划中的主要挑战。

²对于前 k 名排名 (使用 $k > 1$), 胜率之和不为100%。

表2. 模型性能按大小排序。专有模型用灰色阴影标记。粗体和下划线 最佳和第二佳的非Gemini2.5 Pro结果。非百分比指标的置信区间见附录D.3。

模型	输入 模态	信息 接地 (ACC)		反事实 推理 (ACC)		多个 选择 (ACC)		特征推荐 (MAP@1)		计划生成 (R_{PJREL})		计划生成 (有效性)	
		No	With	No	With	No	With	No	With	No	With	No	With
		工具	工具	工具	工具	工具	工具	工具	工具	工具	工具	工具	工具
文本数据													
Qwen3-4B	Text	75.00	56.40	67.50	45.45	86.70	65.10	0.258	0.216	8.100	2.000	0.664	0.001
QWEN3-4B [T]	Text	75.70	32.60	71.00	36.35	<u>90.30</u>	57.00	0.257	0.229	6.900	5.500	0.773	0.006
gpt-oss-20b [L]	Text	<u>80.00</u>	67.80	72.80	63.10	88.70	79.60	0.242	0.211	9.700	<u>7.400</u>	0.753	<u>0.343</u>
gpt-oss-20b [M]	Text	79.94	68.90	72.81	63.65	88.70	77.20	0.242	0.217	<u>10.000</u>	5.500	0.725	0.415
GPT-OSS-20B [H]	Text	81.20	69.60	<u>74.00</u>	<u>63.25</u>	89.20	75.20	0.247	0.229	8.500	4.400	0.698	0.413
Qwen3-30B	Text	73.50	64.14	63.55	52.35	83.20	61.70	0.260	0.229	5.800	1.900	0.645	0.002
QWEN3-30B [T]	Text	78.82	67.50	74.53	58.75	91.60	77.60	0.254	<u>0.244</u>	6.900	4.800	0.665	0.010
NEMOTRON3-NANO-30B-A3B	Text	75.62	64.90	70.83	57.95	86.20	73.80	0.259	0.239	9.400	5.700	0.825	0.010
GPT-4o	Text	<u>80.00</u>	<u>71.03</u>	71.30	60.94	86.30	75.00	0.277	0.227	6.100	5.100	<u>0.836</u>	0.023
GPT-4	Text	77.90	73.80	73.45	62.90	86.30	<u>79.20</u>	<u>0.270</u>	0.247	19.300	22.300	0.869	0.022
GEMINI 2.5 PRO	Text	86.60	77.50	80.70	72.90	93.80	85.80	0.297	0.287	12.000	35.400	0.795	0.030
多模态数据													
GEMINI 2.5 PRO	Text	67.74	63.31	67.74	68.82	85.18	80.59	0.209	0.205	3.660	3.130	0.753	0.508
GEMINI 2.5 PRO	多模态	77.49	70.03	76.08	77.16	88.95	84.50	0.197	0.163	2.850	3.250	0.697	0.405

摘要。 整体而言，结果揭示了三个持续的弱点：脆弱的工具使用、在部分可观测性下对结构化家庭上下文进行推理的困难，以及生成连贯、可执行且偏好对齐的计划的能力有限。这些发现表明，在逼真的智能家居环境中，个性化智能体智能仍远未解决。

6.2. 额外讨论

反事实推理。 图 4 显示对于大多数模型，退化在 $CF_{unchanged}$ 中大于在 $CF_{changed}$ 中，表明在假设扰动下保持正确结论的困难；GPT-4o, GEM-INI 2.5 PRO, 和 QWEN3-30B（有推理和无推理）是部分正确例外。最严重的失败发生在 QWEN3-4B [T], 上，这表明较小模型，尤其是带有显式推理模式的，可能特别脆弱。有趣的是，QWEN3-4B [T] 也是唯一一个在 $CF_{changed}$ 上比原始问题准确率更高的模型，这反映了不稳定的反事实行为而非鲁棒的泛化。参见附录图8的纯推理。

个性化与PersonalHomeTools的影响。 表 3 分析了通过比较个性化设置与通用设置之间的性能差异来研究个性化的效果，其中用户特定属性被替换为匿名化标识符，从而减少了对个性化推理的需求。在纯推理下，个性化持续降低所有模型在IG和CF上的性能，大幅下降表明对个性化家庭细节进行推理引入了大量的额外复杂性。相比之下，当使用PersonalHome-




图4. 智能体反事实推理 (CF) 在不同模型上的性能。热力图报告了原始问题以及答案被更改和未更改的反事实案例上的准确率。

工具（即有工具）的情况下，这些下降幅度大幅减小，并且在多个案例中转为小幅增长。这一模式验证了我们PersonalHomeTools的核心设计，表明其结构化的、通过工具中介访问家庭信息的方式，使模型能够通过按需检索用户特定细节，而非依赖脆弱的隐式推断，从而有效适应个性化背景。更多结果见附录表8和9。

表3. 个性化的影响，以准确率差异 ($\Delta = \text{Personalized} - \text{Generic}$) 衡量

模型	IG		CF	
	无工具	有工具	无工具	有工具
gpt-oss-20b [H]	↓18.34	↑3.83	↓22.54	↑1.42
GPT-4	↓21.88	↓0.53	↓26.33	↓0.64
Gemini 2.5 Pro	↓13.20	↑0.60	↓19.10	↑1.10

工具使用模式。图5显示，主动性任务通常比反应式任务引发更多工具调用，这反映了其多步骤特性，而规模更大、具备推理能力的模型比小型模型更频繁地调用工具。然而，更高的工具使用并不总能转化为更好的性能，这凸显了有效协调和把握工具使用时机（而非单纯的使用频率）才是主要挑战。




图5. 各模型在响应型（上）和主动型（下）任务中的工具使用分布，按每任务实例调用次数低（< 5）、中（5–10）和高（> 10）分组。

反思的影响。我们将角色扮演评判者（RPJ）重新用作自我反思信号，使模型能够以Reflexion的精神迭代式批判和修改生成的计划（Shinn等人, 2023）。

RPJ反馈中突出显示了偏好不匹配和工具级错误，引导在多模态设置中有针对性地进行计划优化。如表4所示，反思一致地提升了 RPJ_{ABS} 评分和计划有效性，表明在仅文本和多模态设置中，计划更具可执行性且更贴合偏好。

表4. Agentic GEMINI 2.5 PRO的基于反思的消融实验。我们报告了计划生成的平均 RPJ_{ABS} 和有效性。

设置	仅文本		多模态	
	RPJ_{ABS}	有效性	RPJ_{ABS}	有效性
Base	3.380	0.030	3.250	0.405
带反思	3.520	0.428	4.240	0.496

人类分析。大语言模型作为评判者已知是不完美的（Dorner et al., 2025），且通常在主观任务中通过人类评估进行验证。因此，我们请了四位人类标注员评估RPJ输出，标注不一致、部分一致或完全一致，同时包括整体和角色层面分数。我们观察到高度一致，没有完全不一致的情况，标注者间一致性超过65%（附录图11）。这表明RPJ提供了可靠且有意

有意义的信号用于评估计划质量和个性化。

定性分析。图6展示了代表性的成功和失败模式，涵盖反应性和主动性场景。在图6a，较弱的模型会进行冗余或错误导向的工具调用，且无法从早期错误中恢复，导致答案不正确或部分正确，而较强的模型会针对记忆和成员信息发出定向查询，并在回答前收集连贯的证据。图6b表明，有效的主动行为始于获取情境背景，随后综合制定多步电器控制计划。即使计划看起来合理，模型也经常无法生成完全正确的工具调用，而这些例子（参见附录I）与定量结果相呼应，强调可靠的工具使用和状态感知协调仍然是主要局限。

Which members of the Simmons family celebrate their birthdays in the spring?		
Qwen3-4B Answer: No one Tool Chain: Member Info x 15 (id=Simmons) ... Analysis: Wrong arguments, and no recovery	GPT-OSS-20B [L] Answer: Maria Tool Chain: Memories (Simmons Birthday) ... Member Info(id=85_2) ... Analysis: Depth wise exploration, partially correct	Gemini 2.5 Pro Answer: Maria and Daniel ToolChain: Memories(Simmons Family Members) ... Member Info (id=[00085_1,...00085_4]) ... Life Events (id=[00085_1, ..00085_4]) ... Analysis: Thorough and correct

(a) 反应性任务（IG）示例

<Tool Calling>

Scene Summary

Get Household Profile

...

Extract Captions

Extract Frames (start: 36200, end: 36202)

✂

Plan Generation Response

- Offer to play the show on TV
- Turn on vent
- Dim lights
- Turn on air purifier (PG)

(b) 主动性任务（PG）示例

图6. 定性示例说明PersonalHomeBench中的个性化智能体行为，涵盖反应性问题回答（上）和多模态主动规划（下）。

请参阅附录 6.2 了解局限性和未来方向。

结论

我们提出了PersonalHomeBench，一个用于评估逼真智能家居环境中个性化智能体行为的基准，同时提供了PersonalHomeTools，一个用于与家庭上下文、记忆、感知和设备控制进行接地交互的特定领域工具箱。跨基础模型的广泛评估表明，在完全可观测性下的强性能并不能转化为可靠的工具使用或主动行为，并且反事实推理和个性化计划生成仍然具有挑战性。扩展规模、显式推理模式和多模态输入的改进有限且不一致。这些结果表明，关键挑战仍然存在

在于结合推理、工具使用和个性化，我们希望 PersonalHomeBench 将有助于更系统地研究这些问题，并支持未来在鲁棒个性化智能体系统方面的进展。

影响声明

本研究旨在推动个性化与主动式智能体系统的研究，重点关注智能家居环境，并兼具潜在益处与风险。积极方面，改进的个性化可提升可访问性、安全性、儿童监护效果以及整体生活质量，尤其对老年用户和有特殊需求的人群。与此同时，在个人空间中运行的智能体技术也引发了关于隐私、数据安全和滥用等重要问题。我们对紧凑型4B参数模型的纳入，也揭示了设备端保护隐私部署的可行性，有助于缓解安全与数据暴露担忧。通过发布一个专为系统评估设计的基准测试与工具箱，我们力求支持基于严谨分析的负责任开发。我们鼓励未来工作优先考虑安全措施、透明度和用户知情同意。总体而言，我们认为本研究的主要影响在于推动个性化与主动式智能体系统朝着更谨慎、更负责任、更有原则的方向发展。

局限性与未来工作

我们将多模态基准测试限制为GEMINI 2.5 PRO，因为目前大多数可用的多模态基础模型要么缺乏原生视频输入支持，要么表现出非常弱的推理与规划能力，使其不适合长期自主评估（Singh等人，2025；Tang等人，2025；Xu等人，2025）。目前，GEMINI 2.5 PRO是唯一在我们的设置中在感知、推理与规划方面表现出竞争性能的模型。随着多模态模型的不成熟，PersonalHomeBench的未来版本将纳入更广泛的具备视频能力的智能体，并实现更全面的多模态比较。PersonalHomeBench还专注于非具身智能家居辅助，而非物理导航或低级操作；将基准测试扩展到混合具身-设备设置是未来工作的重要方向。

此外，我们的Role Playing Judge实现了对主观计划质量和个性化满意度的可扩展评估，但它仍然是一个基于LLM的代理。尽管人类一致性分析表明高度对齐，但未来的工作将扩展直接人类评估，探索从人类反馈中学习偏好，并研究训练时集成RPJ式监督。综合来看，这些方向勾勒出一条路径，以加强范围与

个性化智能体评估的忠实度。

参考文献

- Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., Almeida, D., Altenschmidt, J., Altman, S., Anadkat, S., 等人. GPT-4技术报告. *arXiv预印本 arXiv:2303.08774*, 2023.
- Agarwal, S., Ahmad, L., Ai, J., Altman, S., Applebaum, A., Arbus, E., Arora, R. K., Bai, Y., Baker, B., Bao, H., 等. gpt-oss-120b 和 gpt-oss-20b 模型卡. *arXiv预印本 arXiv:2508.10925*, 2025.
- Bartkowiak, P. 与 Podstawski, M. Edgewisepersona: 一个用于从自然语言交互中进行设备端用户画像的数据集. *arXiv预印本 arXiv:2505.11417*, 2025.
- Blakeman, A., Grattafiori, A., Basant, A., Gupta, A., Khattar, A., Renduchintala, A., Vavre, A., Shukla, A., Bercovich, A., Ficek, A., 等. Nemotron 3 nano: 用于智能体推理的开放高效混合专家混合Mamba-Transformer模型. *arXiv预印本 arXiv:2512.20848*, 2025. Bonatti, R., Zhao, D., Bonacci, F., Dupont, D., Abdali, S., Li, Y., Lu, Y., Wagle, J., Koishida, K., Buckner, A., Jang, L. K., 与 Hui, Z. Windows智能体竞技场: 大规模评估多模态操作系统智能体. 第42届国际机器学习会议论文集, 267:4874–4910, 2025年7月13–19日.
- U
R
L
h
t
t
p
s://
proceedings.mlr.press/v267/bonatti25a.html.
Chang, M., Chhablani, G., Clegg, A., Cote, M. D., Desai, R., Hlavac, M., Karashchuk, V., Krantz, J., Mottaghi, R., Parashar, P., 等. Partnr: 一个用于具身多智能体任务规划与推理的基准. *arXiv预印本 arXiv:2411.00081*, 2024a.
Chang, M., Zhang, J., Zhu, Z., Yang, C., Yang, Y., Jin, Y., Lan, Z., Kong, L., 与 He, J. Agentboard: 一个多轮大语言模型智能体的分析评估平台. 神经信息处理系统进展, 37:74325–74362, 2024b. Comanici, G., Bieber, E., Schaekermann, M., Pasupat, I., Sachdeva, N., Dhillon, I., Blistein, M., Ram, O., Zhang, D., Rosen, E., 等. Gemini 2.5: 以高级推理、多模态、长上下文和下一代智能体能力推动前沿. *arXiv预印本 arXiv:2507.06261*, 2025.
- Das, S., Dai, R., Koperski, M., Minciullo, L., Garattoni, L., Bremond, F., and Francesca, G. Toyota SmartHome: 现实世界日常生活活动. In *The IEEE International Conference on Computer Vision (ICCV)*, 2019年10月.

Dorner, F. E., Nastl, V., and Hardt, M. 前沿可扩展评估的局限性: LLM 作为裁判无法击败两倍的数据。In Yue, Y., Garg, A., Peng, N., Sha, F., and Yu, R. (eds.), 国际学习表征会议, 卷2025, 第26467–26491页, 2025.

URL[https://proceedings.iclr.cc/paper_files/paper/2025/file/4264ee4376776907c0b87ed70b959585-Paper](https://proceedings.iclr.cc/paper_files/paper/2025/file/4264ee4376776907c0b87ed70b959585-Paper.pdf)

pdf.

Hurst, A., Lerer, A., Goucher, A. P., Perelman, A., Ramesh, A., Clark, A., Ostrow, A., Welihinda, A., Hayes, A., Radford, A., 等. GPT-4o系统卡。arXiv预印本 *arXiv:2410.21276*, 2024.

Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., Gonzalez, J., Zhang, H., and Stoica, I. 使用PagedAttention的大型语言模型服务的高效内存管理。在第29届操作系统原理研讨会论文集集中, 第611–626页, 2023.

Li, C., Zhang, R., Wong, J., Gokmen, C., Srivastava, S., Martín-Martín, R., Wang, C., Levine, G., Ai, W., Martinez, B., Yin, H., Lingelbach, M., Hwang, M., Hiranaka, A., Garlanka, S., Aydin, A., Lee, S., Sun, J., Anvari, M., Sharma, M., Bansal, D., Hunter, S., Kim, K.-Y., Lou, A., Matthews, C. R., Villa-Renteria, I., Tang, J. H., Tang, C., Xia, F., Li, Y., Savarese, S., Gweon, H., Liu, C. K., Wu, J., and Fei-Fei, L. Behavior-1k: 一个以人为中心、具身化的人工智能基准, 包含1000个日常活动和逼真模拟。arXiv预印本 *arXiv:2403.09227*, 2024.

Li, S., Guo, Y., Yao, J., Liu, Z., and Wang, H. HomeBench: 在智能家居中评估大语言模型, 包含单个和多个设备上的有效和无效指令。arXiv预印本 *arXiv:2505.19628*, 2025.

Lu, Y.-T., Yang, S., Qian, C., Chen, G.-F., Luo, Q., Wu, Y., Wang, H., Cong, X., Zhang, Z., Lin, Y., Liu, W., Wang, Y., Liu, Z., Liu, F., and Sun, M. 主动代理: 将大语言模型智能体从被动响应转变为主动协助。arXiv, abs/2410.12361, 2024.

URL <https://api.semanticscholar.org/CorpusID:273375463>.

Maharana, A., Lee, D.-H., Tulyakov, S., Bansal, M., Barbieri, F., and Fang, Y. 评估大型语言模型智能体的超长期对话记忆。收录于 Ku, L.-W., Martins, A., and Srikumar, V. (编)《计算语言学协会第62届年会论文集(第1卷: 长论文)》, 第13851–13870页, 泰国曼谷, 2024年8月。计算语言学协会。doi: 10.18653/v1/2024.acl-long.747.

URL <https://aclanthology.org/2024.acl-long.747/>.

Meyer, Y. and Corneil, D. Nemotron人物角色: 与真实世界分布对齐的合成人物角色。Hugging Face数据集, 2025年。Puig, X., Ra, K. K., Boben, M., Li, J., Wang, T., Fidler, S., and Torralba, A. 虚拟家庭: 通过程序模拟家庭活动。2018年IEEE/CVF计算机视觉与模式识别会议, 第8494–8502页, 2018年。

U
R

-会议。

<https://api.semanticscholar.org/CorpusID:49317780>。Qin, Y., Liang, S., Ye, Y., Zhu, K., Yan, L., Lu, Y., Lin, Y., Cong, X., Tang, X., Qian, B., Zhao, S., Hong, L., Tian, R., Xie, R., Zhou, J., Gerstein, M., dahai li, Liu, Z., and Sun, M. ToolLLM: 促进大型语言模型掌握 16000+真实世界API。收录于 第十二届国际学习表征会议, 2024年。

URL<https://openreview.net/forum?id=dHng200Jjr>.

Salemi, A., Mysore, S., Bendersky, M., and Zamani, H. LaMP: 当大语言模型遇到个性化。在 Ku, L.-W., Martins, A., and Srikumar, V. (编) 中, 第62届计算语言学协会年会论文集(第一卷: 长论文), pp. 7370–7392, 泰国曼谷, 2024年8月。计算语言学协会。doi: 10.18653/v1/2024.acl-long.399.

U
R

<https://aclanthology.org/2024.acl-long.399/>.

Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., and Yao, S. Reflexion: 语言智能体与口头强化学习。神经信息处理系统进展, 36:8634–8652, 2023.

Shridhar, M., Thomason, J., Gordon, D., Bisk, Y., Han, W., Mottaghi, R., Zettlemoyer, L., and Fox, D. ALFRED: 一个用于解释日常任务基于情境指令的基准。2020 IEEE/CVF 计算机视觉与模式识别大会 (CVPR), 第 10737–10746 页, 2019。URL

<https://api.semanticscholar.org/CorpusID:208617407>.

Singh, A., Fry, A., Perelman, A., Tart, A., Ganesh, A., El-Kishky, A., McLaughlin, A., Low, A., Ostrow, A., Ananthram, A., 等. OpenAI GPT-5 系统卡。arXiv预印本 *arXiv:2601.03267*, 2025.

Singh, H., Verma, N., Wang, Y., Bharadwaj, M., Fashandi, H., Ferreira, K., 和 Lee, C. 个人大语言模型智能体: 关于定制旅行计划的案例研究。在 Dernoncourt, F., Preostiuc-Pietro, D., 和 Shimorina, A. (编辑) 的 2024年自然语言处理实证方法会议: 行业赛道论文集, 第486–514页, 美国佛罗里达州迈阿密, 2024年11月。计算协会

语言学. doi: 10.18653/v1/2024.emnlp-industry.37.

URL<https://aclanthology.org/2024.emnlp-industry.37/>.

Tang, C., Li, Y., Yang, Y., Zhuang, J., Sun, G., Li, W., Ma, Z., and Zhang, C. video-salmonn 2: 字幕增强的视听大语言模型. *arXiv预印本 arXiv:2506.15220*, 2025.

Wang, N., Peng, Z., Que, H., Liu, J., Zhou, W., Wu, Y., Guo, H., Gan, R., Ni, Z., Yang, J., et al. Rolellm: 大语言模型角色扮演能力的基准测试、激发与增强. 见《计算语言学协会研究发现: *ACL 2024*》, 第14743–14777页, 2024.

Xi, Z., Ding, Y., Chen, W., Hong, B., Guo, H., Wang, J., Guo, X., Yang, D., Liao, C., He, W., et al. Agent-gym: 跨多样化环境评估与训练基于大语言模型的智能体. 见《第63届计算语言学协会年会论文集（第一卷: 长论文）》, 第27914–27961页, 2025.

Xie, J., Zhang, K., Chen, J., Zhu, T., Lou, R., Tian, Y., Xiao, Y., and Su, Y. Travelplanner: 一个面向语言智能体的真实世界规划基准. *arXiv预印本 arXiv:2402.01622*, 2024a. Xie, T., Zhang, D., Chen, J., Li, X., Zhao, S., Cao, R., Hua, T. J., Cheng, Z., Shin, D., Lei, F., Liu, Y., Xu, Y., Zhou, S., Savarese, S., Xiong, C., Zhong, V., and Yu, T. Osworld: 在真实计算机环境中为开放式任务评估多模态智能体. 在 Globerson, A., Mackey, L., Belgrave, D., Fan, A., Paquet, U., Tomczak, J., and Zhang, C. (编)中, 神经信息处理系统进展, 第37卷, 页码 52040–52094. Curran Associates, Inc., 2024b. doi: 10.52202/079017-1650. URL

[https://proceedings.neurips.cc/paper_](https://proceedings.neurips.cc/paper_files/paper/2024/file/5d413e48f84dc61244b6be550f1cd8f5-Paper-)
f
i
l
e
s/
p
a
p
e
r/
2024/file/5d413e48f84dc61244b6be550f1cd8f5-Paper-

和_基准测试_Track.pdf徐 J.、郭 Z.、何 J.、胡 H.、何 T.、白 S.、陈 K.、王 J.、范 Y.、党 K. 等人. Qwen2.5-omni 技术报告. *arXiv预印本 arXiv:2503.20215*, 2025. 杨 A.、李 A.、杨 B.、张 B.、惠 B.、郑 B.、于 B.、高 C.、黄 C.、吕 C. 等人. Qwen3 技术报告. *arXiv预印本 arXiv:2505.09388*, 2025a. 杨 B.、徐 L.、曾 L.、刘 K.、蒋 S.、卢 W.、陈 H.、蒋 X.、邢 G.、闫 Z.。Contextagent: 上下文感知的主动大语言模型智能体与开放世界感知. 载于第三十九届神经信息处理系统年会,

2025b. 网址<https://openreview.net/forum?id=tRXt10xKc5>.

Yang, R., Chen, H., Zhang, J., Zhao, M., Qian, C., Wang, K., Wang, Q., Koripella, T. V., Movahedi, M., Li, M., 等. Embodiedbench: Comprehensive benchmarking multi-modal large language models for vision-driven embodied agents. *arXiv预印本 arXiv:2502.09560*, 2025c.

Yao, S., Chen, H., Yang, J., and Narasimhan, K. Webshop: Towards scalable real-world web interaction with grounded language agents. In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A. (eds.), 神经信息处理系统进展, 卷35, pp. 20744–20757. Curran Associates, Inc., 2022.

URL[https://proceedings.neurips.cc/paper_](https://proceedings.neurips.cc/paper_files/paper/2022/file/82ad13ec01f9fe44c01cb91814fd7b8c-Paper-Conference)
f
i
l
e
s/
paper/2022/file/82ad13ec01f9fe44c01cb91814fd7b8c-Paper-Conference

pdf.

Zhang, X., Deng, Y., Ren, Z., Ng, S.-K., and Chua, T.-S. Ask-before-plan: 用于真实世界规划的主动性语言智能体. *ArXiv*, abs/2406.12639, 2024. URL <https://api.semanticscholar.org/CorpusID:270561990>.

Zhao, S., Zhu, A., Mozannar, H., Sontag, D. A., Talwalkar, A., and Chen, V. Codinggenie: 主动的大语言模型驱动的编程助手. *Pro-ceedings of the 33rd ACM International Conference on the Foundations of Software Engineering*, 2025. URL <https://api.semanticscholar.org/CorpusID:277112990>.

Zhu, M. 召回率、精确率和平均精确率. 滑铁卢大学统计与精算科学系, 滑铁卢, 2(30):6, 2004年.

数据集

A. 作者贡献

该工作展示 本文中介绍的研究由LG Research Team的成员在多个实验室进行

LG Toronto AI Lab:

- Nikhil Verma

LG Korea AI Lab:

- InJung Yang
- Sungil Kim
- KoKeun Kim
- YoungJoon Kim

前贡献者（在本工作期间隶属于LG Research）：

- Manasa Bharadwaj
- Yolanda Liu
- Kevin Ferreira

B. 额外相关工作

反应式智能体基准。大量研究工作已经建立了用于评估网络交互（Yao 等人, 2022）、UI 导航（Xie 等人, 2024b）、类游戏环境和模拟世界（Chang 等人, 2024b）中智能体行为的基准。这些基准标准化了对多步指令遵循和推理的评估，但通常侧重于在长期上下文有限且个性化程度极低的环境中完成反应性任务。近期以工具为中心的基准则评估基础模型能否选择并调用通用 API，从而深入了解基本的工具使用能力（Qin 等人, 2024）。然而，这些工具大多与领域无关，且任务很少需要持续的用户建模、家庭连续性或主动辅助。

具身家庭智能体基准。具身家庭基准测试如 VirtualHome（Puig 等人, 2018）、ALFRED（Shridhar 等人, 2019）、BEHAVIOR（Li 等人, 2024）和 PARTNR（Chang 等人, 2024a）在具有导航和原子动作执行的模拟家庭环境中评估智能体。相比之下，PersonalHomeBench 专注于非具身的真实家庭环境，使用在不同家庭中捕获的长时域视频来反映自然的日常活动、健康和场景。

主动式智能体基准。当前主动式大语言模型智能体涵盖了用于澄清（Zhang 等人, 2024）、多智能体预测（Lu 等人, 2024）和 UI 监控任务辅助（Lu 等人, 2024; Zhao 等人, 2025）的专业框架。ContextAgentBench（Yang 等人, 2025b）在评估带有背景信息和工具使用的主动智能体方面迈出了重要一步，但主要关注自我中心日常轨迹，依赖通用工具，并在仅语言推理设置中运行。相比之下，我们的基准针对共享家庭环境，使用领域特定智能家居工具，并基于持久个性化背景和可选多模态输入，评估反应性和主动性行为。

交互系统中的个性化。个性化已通过角色一致性基准、长期记忆数据集和用户特定问答任务进行了研究。这些基准主要评估模型能否在基于文本的交互中记住或保持与用户属性的一致（Salemi et al., 2024; Maharana et al., 2024）。并行工作探索了针对狭窄规划问题的个性化，例如具有有限工具支持的个性化旅行助手（Singh et al., 2024）。尽管有价值，但这些设置主要将个性化视为对话或检索的一个属性。PersonalHomeBench 将个性化视为交互式决策的核心驱动力，评估用户偏好如何影响动态环境中的推理、工具使用和长期规划，以及在评估生成方案时如何利用这些信息。

以家庭为中心的基准。

与诸如Toyota Smarthome (Das et al., 2019) 等数据集不同, 这些数据集是舞台化的、人口统计范围狭窄, 并且不是围绕智能设备交互设计的, 我们的数据涵盖了多样的家庭布局、年龄组、关系以及自发活动。视频时长从几秒到几十分钟不等, 可能涵盖多种活动 (例如烹饪、休闲、睡眠), 从而能够评估长时间范围内的持久上下文跟踪和主动辅助。

最近基于语言模型的家庭助手基准, 例如HomeBench (李等人, 2025) 和EdgeWisePersona (Bartkowiak & Podstawski, 2025), 更接近智能家居场景但仍有限。HomeBench专注于反应性验证和执行智能家居指令, 而不进行个性化建模, 而EdgeWisePersona则强调画像重建和轻量级主动例行推理, 使用少量设备和简单的状态转换。

C. 附加家庭统计

C.1. 文本数据统计

家庭规模。这些家庭涵盖了结构多样的居住环境, 分为: 单身住户、家庭和非亲属室友。家庭规模从单人居住到大家庭住宅 (图7a)。

拥有电器。该数据集包含近40种不同的电器类型, 其中包括所有家庭都拥有的五种核心电器: 冰箱、恒温器、微波炉、扬声器和电视。其他最常见的电器列于 (图7c) 中。

宠物分布。在409个家庭中, 该数据集共代表823只动物。宠物种类分为九种动物类型: 猫、狗、仓鼠、蜥蜴、豚鼠、兔子、鸟、鱼和龟——涵盖常见的家养哺乳动物、爬行动物和水生伴侣动物。

C.2. 多模态数据统计

表5展示了本研究构建的100个场景在三个核心领域中的分布: 安全护理、健康护理和日常护理。健康护理场景占比最大, 反映了家庭环境中涉及健康、用药和环境健康的情况普遍存在。日常护理场景涵盖回家和宠物护理等日常活动, 而安全护理场景则聚焦于风险敏感情况和事故预防。场景根据其标题中一致的语义线索进行分类, 从而在保持涵盖安全、健康和日常惯例等多样且逼真的家庭场景的同时, 实现清晰的领域划分。

表6总结了我们的基准测试中用于健康护理、安全护理和日常护理场景的真实家庭数据的参与者构成。数据集涵盖了家庭角色的显著多样性, 包括成人、看护者、儿童和宠物, 年龄范围从幼儿到70多岁的老年人。安全护理场景最为普遍, 反映了涉及风险监测和干预的真实世界常见情况, 特别是在同时有看护者和儿童的家庭中。日常护理场景进一步强调了日常的多人家庭动态, 而健康护理场景则关注涉及多个生命阶段成人的年龄敏感情境。整体而言, 这种分布突出了基准测试对现实家庭多样性和交互模式的重视, 为评估日常家庭环境中的个性化和主动辅助提供了代表性基础。所有数据均为自我中心视角, 并通过在受试者家中安全放置摄像头收集。

视频数据收集参与者说明。参与者获得了与表中所列领域相对应的场景特定指导5在家庭设置完成后 (包括摄像头放置、麦克风激活和传感器检查), 针对每个场景, 参与者收到了高层次指令, 描述了场景应如何展开以及要执行的动作类型, 同时允许执行中的自然变化。对于涉及安全或危险情况的场景, 参与者被指示模拟动作而非实际执行, 现场工作人员确保所有安全协议得到遵守。涉及多名参与者的场景通过指导所有相关被试来保持预期叙事的一致性。为了确保可用录制, 必要时重新拍摄场景以提高清晰度或覆盖范围。源数据是根据与外部供应商签订的服务合同收集的, 并在个人信息影响评估后, 按照适用的个人数据保护法规进行处理。参与者因参与而获得补偿。

表5. 基准中情景领域和分类依据的分布。

领域	视频数量	分类依据
安全护理	30	场景标题涉及安全、风险、危险或事故预防
健康护理	38	场景标题涉及健康、用药、通风或福祉
日常护理/常规	32	场景标题涉及日常惯例、回家、宠物护理或外出
总计	100	—

表6. 收集的家庭数据中跨场景的参与者人口统计。

场景	参与者类型	年龄组	性别	参与者数量
健康护理	成人	30s	Male	2
健康护理	成人	60-70岁	Male	3
健康护理	成人	60-70岁	女性	3
医疗保健 (总计)				8
安全护理	成人 (照护者)	30s	女性	5
安全护理	成人 (照护者)	40-50岁	女性	3
安全护理	成人 (照护者)	40-50岁	Male	2
安全护理	成人	30s	Male	1
安全护理	孩子	10岁以下	Male	3
安全护理	孩子	10岁以下	女性	5
安全护理	孩子	5岁及以上	女性	1
安全护理	孩子	10岁及以上	女性	2
安全护理 (总计)				22
日常护理	成人	60s	Male	1
日常护理	成人	70s	Male	1
日常护理	成人	70s	女性	1
日常护理	成人	30s	Male	1
日常护理	成人 (照护者)	30s	女性	2
日常护理	成人 (照护者)	40-50岁	女性	2
日常护理	孩子	10岁以下	女性	3
日常护理	孩子	10岁以下	Male	1
日常护理	孩子	5岁及以上	女性	1
日常护理	孩子	10岁及以上	女性	2
日常护理 (总计)				15
Pets	动物	—	Cat	1

D. 额外指标

D.1. 定义

对于IG和CF，首先使用字符串级精确匹配（等式1）。如果精确匹配失败，我们使用GEMINI 2.5 PRO 作为语义等价评判器（等式2）来确定预测答案是否与真实值在意义上一致。该混合决策规则在等式中正式定义3。

对于CF，性能报告为在所有答案保持不变的反事实实例和答案发生变化的反事实实例上的宏平均，如式4。

对于MC，准确率通过选定选项（或其文本形式）与真实选项之间的精确匹配来计算，如式6。由于所有有效答案均被明确枚举，因此本任务不应用语义判断。

对于FR，我们将任务构建为一个排序问题，并报告排名为 k (MAP@ k)，它衡量相关特征在推荐列表中的排名有多高。MAP@ k 的计算在式9。

我们还报告了平均相关排序和 (RRS)，这是一种排序误差度量，用于量化相关项目与其理想位置的偏离程度。对于每个实例，计算每个相关项目的预测排序与其理想排序（1-3）之间的绝对偏差之和，最终得分通过对所有实例求平均得到（式12-13）。数值越低表示排序质量越好，零对应完美排序。该指标通过捕捉相关选项之间的误排名程度，提供了超越




图7. PersonalHomeBench中生成家庭的附加统计信息。(a) 家庭规模和组成分布。(b) 家庭中拥有电器的分布。(c) 家庭拥有的常用家电。

top- k 准确率的补充性洞察。

对于PG，我们使用两个互补的指标。首先，主观计划质量通过角色扮演评判者（RPJ）框架进行评估。其次，我们测量计划有效性，定义为子程序步骤中可直接执行且包含正确工具或功能名称以及格式正确的参数的比例，如公式11所示。

总之，这些指标捕获了确定性响应任务的正确性，主动性推荐的排序质量，以及感知有用性用于计划生成的ss和实际可执行性。

表7. 每种任务使用的评估指标及其对应的公式定义摘要。

Task	指标	公式
信息锚定 (IG)	混合精确/语义准确率	公式3
反事实推理 (CF)	混合精确/语义准确率	公式3
反事实推理 (CF)	宏平均准确率	式4
多项选择 (MC)	精确匹配准确率	式6
特征推荐 (FR)	MAP@ k	公式9
特征推荐 (FR)	平均相关秩和	公式13
计划生成 (PG)	RPJ Score	算法1
计划生成 (PG)	计划有效性	公式11

$$\text{EM}(\hat{y}_i, y_i) = \mathbb{I}[\text{norm}(\hat{y}_i) = \text{norm}(y_i)], \quad (1)$$

$$\text{J}(\hat{y}_i, y_i) = \text{J}_{\text{GEMINI 2.5 PRO}}(\hat{y}_i, y_i) \in \{0, 1\}, \quad (2)$$

$$c_i^{(\text{IG/CF})} = \max(\text{EM}(\hat{y}_i, y_i), \text{J}(\hat{y}_i, y_i)), \quad \text{ACC}_{\text{IG/CF}} = \frac{1}{N} \sum_{i=1}^N c_i^{(\text{IG/CF})}. \quad (3)$$

$$\text{ACC}_{\text{CF}}^{\text{MACRO}} = \frac{1}{2} (\text{ACC}_{\text{CF}^{\text{CHANGED}}} + \text{ACC}_{\text{CF}^{\text{UNCHANGED}}}), \quad (4)$$

$$\text{ACC}_{\text{CF}_s} = \frac{1}{|S_s|} \sum_{i \in S_s} c_i^{(\text{CF})}, \quad s \in \{\text{CHANGED}, \text{UNCHANGED}\}. \quad (5)$$

$$c_i^{(\text{MC})} = \mathbb{I}[\text{norm}(\hat{z}_i) = \text{norm}(z_i)], \quad \text{ACC}_{\text{MC}} = \frac{1}{N} \sum_{i=1}^N c_i^{(\text{MC})}. \quad (6)$$

$$P_i(r) = \frac{1}{r} \sum_{t=1}^r \text{rel}_i(t), \quad (7)$$

$$\text{AP@}k_i = \frac{1}{\min(k, R_i)} \sum_{r=1}^k P_i(r) \text{rel}_i(r), \quad (8)$$

$$\text{MAP@}k = \frac{1}{N} \sum_{i=1}^N \text{AP@}k_i, \quad (9)$$

$$v_{i,j} = \mathbb{I}[\text{step}(i, j) \text{ uses a valid tool/feature name and well-formed arguments}], \quad (10)$$

$$\text{Validity}_i = \frac{1}{J_i} \sum_{j=1}^{J_i} v_{i,j}, \quad \text{Validity} = \frac{1}{N} \sum_{i=1}^N \text{Validity}_i. \quad (11)$$

每实例相关排名偏差。 令 N 表示评估实例的数量， $K = 3$ 表示每个实例的相关项目数量。对于实例 i ，令 $r_{i,j}$ 表示第 j 个相关项目的预测排名，其中理想排序为 $j \in \{1, 2, 3\}$ 。

$$D_i = \sum_{j=1}^K |r_{i,j} - j| \quad (12)$$

$$\text{RRS} = \frac{1}{N} \sum_{i=1}^N D_i \quad (13)$$

D.2. 反应式任务

反事实推理 图 8 比较了CF性能在 纯推理（右）和代理工具使用（左）。无工具时，大多数模型在原始问题上达到较高准确率，并且在答案改变和答案未改变的反事实上都保持了相当的性能，这表明当完整背景直接提供时，许多模型能够内部模拟假设性扰动。大型专有模型的性能始终最强，而中等和小型模型在各类反事实上的表现略低但稳定。相比之下，引入工具导致所有模型和反事实状态的性能均匀下降。这种下降不仅限于答案改变的情况，也影响了答案未改变的查询，表明失败主要源于不完美的检索和工具交互，而非反事实推理本身。几个模型在未更改条件下表现出更大的下降，表明一旦信息必须通过工具重新获取，即使保留已知事实也会变得脆弱。

整体来看，这一比较凸显了推理能力与交互能力之间的明显差距：模型在孤立情境下保留了一定的反事实推理能力，但在需要正确工具使用的智能体设置中却难以可靠地表达这一能力。这进一步印证了，在个性化家庭环境中，有效的“信息获取与状态基础”而非单纯的假设推理，才是实现反事实性能的主要瓶颈。

个性化与PersonalHomeTools的影响。 表 8 和 9 表明，个性化在纯推理与代理评估下具有显著不同的效果。当完整的家庭上下文直接可用时（表9），个性化通常能在IG、CF和MC上带来大幅准确率提升，表明当检索微不足道时，模型能有效利用用户特定信息。相反，在代理评估下（表8），个性化带来的变化更小且更混杂，某些情况有适度改进，另一些则略有退步。重要的是，代理场景中表现的相对稳定性反映了

PersonalHomeTools 的以个性化为中心的设计，它支持对用户特定背景进行结构化检索，并减轻直接对原始个性化信息进行推理的难度。

任务难度对反应性任务表现的影响。图 9 展示了所有三个反应式任务中跨任务难度的一致且可解释的缩放行为。准确率从简单到中等再到困难设置单调递减，证实了难度分层有意义地捕捉了不断增长的推理复杂度。IG和MC在所有难度等级中比CF保持相对更稳定，而CF表现出最陡的下降，强化了其作为最具挑战性的反应式任务的角色。更大和专有模型通常在各个难度上获得更高的准确率，但没有模型能免受困难实例上的性能下降，表明复杂的家庭级推理即使在规模化情况下仍然具有挑战性。标记大小进一步显示，较困难的实例往往需要更多交互轮次，表明模型尝试更深入的基于工具的探索或更长的推理链，而没有可靠地缩小性能差距。总体而言，该图强调了增加难度暴露了多跳和反事实推理中的系统性弱点，并且仅靠额外交互不足以克服这些挑战。




图8. 反事实推理 (CF) 在不同模型上的表现，分别在有工具和无工具访问的设置下。热力图报告了原始问题、正确答案改变的反事实查询以及答案保持不变的反事实查询的准确率。




图9. 三种反应式任务类别（信息锚定 (IG)、反事实推理 (CF) 和多项选择 (MCQ)）在简单、中等和困难难度级别下各模型的准确率。每个数据点对应一个模型-任务对；标记大小反映了完成任务的平均轮次。

表 8. 代理评估下个性化效果，报告通用和个性化设置在 IG、CF 和 MC 上的准确率

模型	IG (准确率 %)		CF (准确率 %)		MC (准确率 %)	
	通用	个性化	通用	个性化	通用	个性化
gpt-oss-20b [H]	65.77	69.60	61.83	63.25	71.00	75.20
GPT-4	74.33	73.80	63.54	62.90	77.40	79.20
GEMINI 2.5 PRO	76.90	77.50	71.80	72.90	87.90	85.80

表9. 在纯推理下个性化的影响，报告在IG、CF和MC上的通用和个性化设置的准确率。

模型	IG (ACC %)		CF (ACC %)		MC (准确率 %)	
	通用	个性化	通用	个性化	通用	个性化
gpt-oss-20b [H]	99.54	81.20	99.54	77.00	88.20	89.20
GPT-4	99.78	77.90	99.78	73.45	83.90	86.30
Gemini 2.5 Pro	99.80	86.60	99.80	80.70	94.10	80.70

D.3. 主动任务

特征推荐。图 10 展示了随着k的增加，所有模型的MAP@k持续改进，性能增益在超过中等k值后逐渐减弱。全方面来看，具有工具访问权限的智能体设置表现不如其纯推理对应项，进一步证实即使对于强大的基础模型，与工具有效交互仍然是一个关键挑战。更大且能力更强的模型实现了更高的绝对MAP@k，但有工具和无工具设置之间的相对差距仍然存在，表明仅靠规模并不能解决交互级错误。值得注意的是，GEMINI 2.5 PRO和GPT-4类模型定义了性能的上限包络，但在工具使用下仍表现出不可忽视的退化，凸显了在结构化环境中改进智能体推理和决策的巨大空间。

表10 报告了在基于文本的评估下，特征推荐的平均相关排序和 (RRS)。在纯推理条件下，前沿模型取得了最低的RRS值，其中GEMINI 2.5 PRO和GPT-4O表现最佳，表明相关特征被放置在更接近其理想排序的位置。中等规模开源模型的RRS略高，而较小模型的偏差最大，反映出更嘈杂的排名行为。当引入工具时，几乎所有模型的RRS都显著增加，表明工具介导交互会降低细粒度排序质量，即使Top-1准确率可能仍然合理。值得注意的是，各设置下模型的相对排序大体保持一致，这表明质量下降主要源于交互复杂性，而非底层排名能力的改变。总体而言，这些结果进一步证实了在智能体上下文中精确的偏好排序仍然具有挑战性，而有效使用工具对于维持排名保真度至关重要。




图10. 在有无工具访问的模型评估中, 排名 k 处的平均平均精确率($MAP@k$)。实线表示有工具时的性能, 虚线对应无工具时的设置。结果针对不同的 k 值报告, 展示了不同评估条件下的排序性能趋势。

表10. 相关排名总和

针对基于文本数据的特征推荐任务。数值越低表示排序质量越好。

模型	无工具	有工具
Qwen3-4B	3.4730	10.7620
QWEN3-4B [T]	3.3740	10.4270
gpt-oss-20b [L]	3.5740	17.3260
gpt-oss-20b [M]	3.5850	15.0270
gpt-oss-20b [H]	3.5930	19.5160
Qwen3-30B	3.4910	21.8080
QWEN3-30B [T]	3.4500	10.3440
Neutron3-Nano-30B	3.2580	9.0988
GPT-4o	3.1340	10.5030
GPT-4	3.2100	10.2050
Gemini 2.5 Pro	2.9780	9.0090

表11. 跨模型的特征推荐与计划生成有效性。

模型	特征推荐 (MAP@1)		计划生成 (有效性)	
	无工具	有工具	无工具	有工具
Qwen3-4B	0.258±0.139	0.216±0.159	0.664±0.341	0.001±0.015
QWEN3-4B [T]	0.257±0.140	0.229±0.154	0.773±0.324	0.006±0.072
gpt-oss-20b [L]	0.242±0.148	0.211±0.160	0.753±0.404	0.343±0.464
gpt-oss-20b [M]	0.242±0.149	0.217±0.159	0.725±0.412	0.415±0.481
GPT-OSS-20B [H]	0.247±0.146	0.229±0.155	0.699±0.428	0.414±0.483
Qwen3-30B	0.260±0.138	0.229±0.154	0.645±0.302	0.002±0.024
QWEN3-30B [T]	0.254±0.142	0.244±0.148	0.666±0.467	0.044±0.205
NemoTron3-30B	0.259±0.138	0.239±0.149	0.825±0.320	0.010±0.090
GPT-4O	0.277±0.125	0.227±0.155	0.836±0.215	0.023±0.117
GPT-4	0.270±0.131	0.247±0.146	0.869±0.208	0.022±0.123
Gemini 2.5 Pro	0.297±0.104	0.287±0.115	0.795±0.238	0.030±0.157
Gemini 2.5 Pro (Multimodal)	0.196±0.164	0.163±0.166	0.697±0.297	0.405±0.423

E. 模型与超参数

开源模型通过vLLM (Kwon等人, 2023) 托管在多GPU节点(4个GPU, 96GB显存)上, 采用固定的张量_并行_大小为4。为确保系统稳定性并容纳长上下文推理的开销, GPU内存利用率降低至0.85, 以防止在KV缓存分配期间出现内存溢出错误。

对于使用显式思考或推理模式的模型, 最大推理令牌预算根据模型规模进行明确约束。QWEN3-4B [T] 和 QWEN3-30B [T], 设置上限, 而GPT-OSS-20B与NEMOTRON3-NANO-30B-A3B则使用默认配置。QWEN3推理模型采用DEEPSEEK-R1作为推理解析器, 并在vLLM服务环境中使用其自身的Nano v3解析器。

表12. 按模型的推理令牌配置

模型名称	推理令牌	GPU内存利用率
Qwen3-4B	262,144	0.90
QWEN3-4B [T]	78,720	0.90
gpt-oss-20b [低,中,高]	131,072	0.90
QWEN3-30B	32,768	0.85
Qwen3-30B [T]	32,768	0.85
Nemotron3-Nano-30B-A3B	131,072	0.85

F. 提示词

F.1. 家庭成员角色生成

家庭成员角色生成提示模板

你是一位专家角色生成器。你的任务是根据家庭层面信息和示例角色创建逼真、连贯的个体角色。请精确遵循以下规则：

1. 以家庭角色为锚点

- 利用家庭层面描述推断：人口统计、居住状况、社会经济背景、生活方式偏好、环境和背景。

- 所有个体角色必须与这些家庭信息保持一致。

2. 尊重居住类型

- 如果居住_类型 =室友：

– 所有个体应无亲属关系。– 年龄应落在相近的年龄范围内，除非家庭角色另有说明。– 收入水平、职业和生活方式可以不同，但应仍然合理地共存于合租情况中。– 个性不应完全相同——让每个人各具特色，又能作为同居者和谐相处。

- 家庭规模 = 2

– 可以是情侣（恋人）。– 或者是一位父母 + 一个孩子。

- 家庭规模 = 3

– 可以是情侣 + 一个孩子。– 或者是一位单亲 + 两个孩子。

- 家庭规模 = 4或5

– 典型家庭构成包括: * 两个父母 + 儿童 * 单亲 + 多个儿童 * 多代家庭

3. 使用样本作为风格指导

- 将样本仅用作语气、结构和详细程度的示例。
- 不要复制内容。
- 保持相似的属性。

4. 为每个个体生成简洁、独立的角色

- 为每个人提供:
 - 成员_id: 必须为{household_id}_{n}, 其中n从1开始– 名称: 从角色描述中提取姓名– 角色: 父母、孩子、室友、伴侣等– 年龄 (若未明确说明则进行估算) – 性别 (男性或女性) – 职业– 个性: 1-2句话概括性格和特质– 爱好: 列出爱好和兴趣关键词– 生活方式: 习惯、日常惯例、能源使用倾向 (例如: 频繁烹饪、夜猫子、活跃、精通科技) – 偏好: 任何与模拟相关的偏好 (例如: 温度设置、电器使用模式、安静的早晨) – 重大_事件: 列出具有日期和描述的重要生活事件。若无已知重大事件, 此字段可留空。

5. 输出格式

返回结果作为人物列表, 每项对应一个人, 标明:

```
"成员": [{ "成员_id": "{household_id}_1", "
名称": "", "角色": "", "年龄": , "性别": "", "职业":
"", "角色": "", "爱好": [ "", "" ], "生活方式": "", "
偏好": "", "主要_事件": [{ "日期": "", "描述": "" }
}],
```

```
{ "成员_id": "{household_id}_2", "名称": "",
  "角色": "", "年龄": "", "性别": "", "职业": "",
  "角色": "", "爱好": ["", ""], "生活方式": "", "偏好": "",
  "主要_事件": [{ "日期": "", "描述": "" }
  ]}...
```

F.2. 任务生成

反应式任务

信息基础与多项选择题任务生成提示模板

提示：基于程序的字典驱动的问答生成

Role

您是一个数据问答生成引擎。您的任务是从给定的字典中生成准确、可验证的问答对，该字典包含许多键和值（包括嵌套对象、列表、ID、名称、属性、状态和记忆）。

所有输出必须是机器可评分的、基于程序的，并且严格从输入字典中派生。

输入

你将获得：

- 一个包含许多键和值的字典
- 可能映射到实体的ID（例如，人、设备、房间）
- 与ID关联的可选人类可读名称
- 结构化属性、列表、时间戳、状态和/或记忆

必需输出结构

对于每个生成的项目，包括以下所有部分。

- 1. 问题 - 对于每个项目，生成同一问题的两个版本：
 - A. 问题（基于ID） * 使用ID或原始字典键 * 示例：成员_id_001 和成员_id_002最喜欢的活动是什么？
 - B. 个性化问题（基于名称） * 在可用时用名称替换ID

* 语义上与基于ID的问题相同 * 示例: David和Susan最喜欢的活动是什么? – 两个问题必须得出完全相同的答案。

• 2. 答案

– 答案必须精确且具体– 无需完整句子– 以可接受变体的列表形式输出答案– 所有变体必须语义等价– 答案必须直接基于输入字典– 对于每个问答题, 你还必须生成一个“multiple_choices”字段。* 不正确的答案应为困难干扰项, 这些干扰项在字典中合理且语义上接近正确答案, 但在细微且可验证的方式上错误。* 有效的干扰项可以通过交换实体、使用来自错误背景、时间或地点的真实值, 或对正确值进行轻微修改来创建。* 明显虚假、通用或无根据的选项不被允许。* 所有不正确的答案必须互不相同, 不得与任何已接受的答案变体重叠, 并且必须与正确答案具有相同的语义类型。

• 3. 难度分类

– 每个问题必须标记为恰好一个难度级别:

* 简单: 最多3个推理步骤 * 中等:

3到5个推理步骤 * 困难: 5到10个

推理步骤

– 生成的集合必须包含以下混合类型:

* 简单问题 (直接查找, 单一实体)

* 中等问题 (比较、聚合或多个实体)

* 困难问题 (跨多个键、记忆或属性的多跳推理)

– 规则

* 所有答案必须直接由输入字典支撑 * 不要虚构或推断缺失的信息 * 个性化和基于ID的问题必须一一对应 * 答案必须是机器可检查的 * 如果提到多个实体, 答案必须对所有这些实体都正确 * 程序必须足以计算答案, 且不多不少

– 问题自然性约束 (强制)

* 问题必须听起来像人类在日常语言中会实际问出的内容。

· 问题不应透露答案的计算方式。

· 问题不应提及连接、查找、时间线或交叉引用。 * 不要问那些要求用不

同形式重复陈述同一事实的问题。

· 避免循环或自指问题 (例如, 询问与某个已经描述该事件的事件相同日期发生了什么)。

* 如果无法进行个性化, 那么个性化问题应为 "None"

输出格式 (严格)

仅返回JSON对象列表, 不附带任何额外文本。

```
[{"难度": "简单 | 中等 | 困难",
```

"问题": "基于ID的问题", "个性化_问题": "基于姓名的问题", "答案_变体": ["答案_变体_1", "答案_变体_2"], "多项_选择": {"正确": "最佳_答案_变体", "不正确": ["困难_干扰项_1", "困难_干扰项_2", "困难_干扰项_3", "困难_干扰项_4"] } # 你必须始终预测4个不正确的困难干扰项 } } }你必须为每个难度级别生成最多3个示例。
这是当前家庭信息: {household_information}

反事实任务生成提示模板

你是一名家庭知识反事实推理助手。

你的任务:

1. 获取一个情境化问答对。2. 对家庭/背景/记忆/电器数据生成一个反事实修改。
3. 提供: a) 反事实条件 b) 在此反事实世界下的新推导答案 c) 推理转变的简短解释

输入格式

您将获得一个 JSON 格式的单一问答项, 其结构如下:

```
{{ "难度": "简单 | 中等 | 困难", "问题": "<使用 ID 的通用问题>", "个性化_问题": "<使用名称代替 ID 的问题>", "答案_变体": ["<标准答案>", "<替代表面形式>"], "多个_选项": {"正确": "<正确选项>", "不正确": ["<干扰项1>", "<干扰项2>", "<干扰项3>", "<干扰项4>"] } } }
```

备注:

- 问题和个性化问题指的是同一个底层查询。
- 答案应为精确内容，而非完整句子。
- 可提供多个答案变体，以实现稳健的准确率检查。

反事实构建规则

- 单因子修改
 - 每个反事实必须仅修改一个主要因素。– 修改必须清晰可辨且独立。– 有效的修改维度包括：* 时间（例如，一个月前 → 六个月前）* 执行者（切换涉及的家庭成员）* 活动（例如，烹饪 → 学习）* 使用的电器或传感器 * 地点（例如，厨房 → 卧室）* 传感器可用性或故障 * 常规、习惯或动机变化 * 环境上下文（温度、季节、一天中的时间）
- 显式因果性
 - 反事实必须包含清晰的因果关系。– 如果答案发生变化，修改必须是导致变化的直接原因。– 如果答案没有变化，需明确说明为什么该修改不相关。– 避免推测性、隐含性或循环推理。
- 逻辑与物理一致性
 - 反事实必须保持内部一致。– 不得违反：* 物理约束（例如，不可能的电器行为）* 时间约束（例如，结果先于原因）* 家庭约束（例如，不存在的成员或电器）– 除非修改所必需，否则不得引入新实体。
- 答案精确性与有效性
 - 新答案必须是：– * 原始答案变体之一，或 * 逻辑上更新后的答案，且具有相同的精确性和粒度。– 答案必须是精确值，而非完整句子。– 不允许出现模糊或未指定的答案。
- 难度对齐
 - 反事实的推理复杂度必须与原始难度一致：– 简单：表面或无关变化；答案保持不变。– 中等：背景变化；答案可能改变。– 困难：涉及记忆、传感器和推断行为的多跳推理。

反事实下的回答规则：

- 重新计算答案，就好像反事实为真一样。 - 严格基于事实——除引入的变更
外，不得编造新内容。 - 如果反事实并未实质性地改变答案，则明确说明。

输出格式：

为每个输入的问答对返回一个JSON字典：

```
{{ "original_question_id": "...", "counterfactuals": [{{ "change": "<假设变更的描述>", "new_answer": "<确切答案>", "answer_changed": true | false, "reasoning": "<简洁的因果解释>", "outer_key": [{{ "<field_1>": "<值>", "<field_2>": "<值>", "...": "..." }} ] }}
```

约束条件： - 反事实列表必须包含1到3个项目。 - answer_changed必须
准确反映答案是否与原始答案不同。 - 推理必须简洁、明确且具有因果关系
(不得猜测)。

有效的反事实示例（仅用于说明）

- 时间性：“假设引用记忆发生在六个月前而不是一个月前。” - 行为性：“假设该家庭成员停止了深夜烹饪。” - 传感器相关：“假设微波功率计在那段时间处于离线状态。”
- 替代：“假设使用了电热板而不是微波炉。” - 无关变化：“假设室内温度为 30°C 而不是24°C。”

质量检查清单（所有项必须通过）在生成输出
之前，请验证： - 反事实是现实且合理的。 - 推理清晰地解释了因果关系。 - 答案是无歧义且机器可
检查的。 - 没有引入不必要的实体或假设。

你至少必须生成一个答案应发生变更的反事实，以及一个答案不应发生变更的反事实。

JSON严格遵守所需的模式。

以下是当前家庭信息： {
household_information}

这里是所有的问答对 {qa_pairs}

特征推荐

特征排序任务生成提示模板

你是一个家庭知识排序生成器。你的工作是严格依据提供的家庭数据，生成基于上下文的家电特征排名。将提供一个家电特征列表。从这个列表中，你必须选择恰好10个特征，并生成一个由家庭需求、行为、设备背景和长期模式支撑的排序顺序（1 → 10）。

你的任务是

1. 从输入列表中选择恰好10个特征。
2. 分配正确的排名，从1（最相关）到10（最不相关）。
3. 排名必须反映来自以下方面的明确证据：- 家庭结构（成员、年龄、爱好、角色、宠物）- 设备信息（电器类型、传感器、位置）- 上下文数据（当前时间、天气、日程、状态）- 长期记忆（习惯、重大事件、偏好）
4. 为每个特征提供简短说明，描述其被置于特定排名位置的原因。

排名要求：

- 排名必须反映从家庭行为和需求中推断出的实际优先级。
- 推理应展示：- 观察（例如，有人经常忘记关闭电器）- 推断（例如，高流量房间可能受益于自动化）- 多步推理（例如，宠物 + 机器人吸尘器 + 用户日程模式）
- 不要虚构提供列表中未包含的家电特征。
- 所有选择必须基于家庭记录中具体的显式字段。

API参考

冰箱内部摄像头远程查看 此功能会向您的APP发送冰箱/冷冻室内容的快照，并给出检测到的内容列表。

触屏家庭中心界面 更新家庭中心屏幕上显示的小部件（例如日历、备注、天气），也可向屏幕推送特定通知。

食材管理与过期跟踪 提供食材及其元数据信息（如数量和过期日期）的报告。若未指定具体食材，报告将涵盖所有食材。若传递了创建_购物_列表名称，则自动为库存不足或即将过期的食材生成购物清单。

食谱推荐 根据用户对食谱的自然语言请求，推荐个性化食谱并显示在冰箱屏幕上。

诊断警报（例如门未关）向用户发送问题警报。

双冰制冰机（冰块、碎冰/球形冰）切换制冰机模式或触发快速制冰循环。

烤箱远程预加热 烤箱预热至华氏350度或用户指定的温度。该系统还会执行诊断以确保预热安全。如果不安全，则会向用户APP发送警报。

内部AI摄像头监控

将烤箱内物品的快照发送至用户APP。如果请求视频模式，则发送实时视频流链接。如果传递了特定查询，则函数返回一个答案。未传递查询时，返回实时快照。烹饪控制兼容性 在对流、炙烤或烘焙模式之间切换烤箱模式。集成肉探针带数字读数 返回已连接肉探针的当前内部温度读数。可设置目标警报温度。... ————— 扬声器 收集用户响应 通常用于获取用户对扬声器请求的最后N个响应。返回指令列表。下一代AI助手集成 将复杂的对话查询卸载到大型语言模型（例如Gemini）以获得上下文感知答案。空间/房间感知音频 使用麦克风分析房间声学，并自动调整均衡器设置以实现空间音频。Matter/Thread/Wi-Fi 6E集线器支持 通过Matter或Thread协议扫描新设备以添加到家庭网状网络。高保真音频与Dolby Atmos支持 为支持的媒体切换高清编解码器和Dolby Atmos渲染。为用户生成通知 完成任务后为用户生成音频通知 ————— 电视 通用内容搜索 在所有已安装的流媒体应用和直播电视中搜索以找到特定电影、节目或演员。免提语音控制 无需遥控器即可执行“打开”、“音量调高”、“打开Netflix”或“播放爵士乐”等命令。智能家居仪表盘覆盖 显示交互式覆盖层，展示其他智能设备（例如门铃摄像头、恒温器）的状态，不影响播放。环境艺术模式 将电视切换至低功耗模式，在不活跃使用时显示艺术品、照片或天气信息。多视图/分屏 将屏幕一分为二，同时显示两个不同的内容源（例如游戏 + YouTube教程）。AI图像/声音校准 使用遥控器麦克风和电视光线传感器，根据房间当前条件优化音频和视频设置。为用户生成在电视上显示的通知 在电视上为用户生成视觉 + 音频通知。举例来说，可以是逐步食谱。下一代AI助手集成 将复杂的对话查询卸载到大型语言模型（例如Gemini）以获得上下文感知答案。————— 您必须生成三个高度相关特征、三个相关特征以及四个较低相关特征 输出模式

```
{{ "appliance": "设备名称", "feature": "功能名称", "rank": 1, "relevance": "高度_相关",
```

"reasoning": "解释为何此功能使用显式家庭数据排名 #1。" }, {"appliance": "设备名称", "feature": "功能名称", "rank": 2, "relevance": "高度_相关", "reasoning": "解释为何此功能使用显式家庭数据排名 #2。" }, ... {"appliance": "设备名称", "feature": "功能名称", "rank": 5, "relevance": "相关", "reasoning": "解释为何此功能使用显式家庭数据排名 #3。" }, ... {"appliance": "设备名称", "feature": "功能名称", "rank": 10, "relevance": "较低_相关", "reasoning": "解释为何此功能使用显式家庭数据排名 #10。" } }所有特征在rs在排名和多选题中应基于API参考。不要编造任何特征且

以下是家庭信息:

{家庭_信息}

计划生成

计划生成任务生成提示模板

系统角色

你是智能家居编排引擎。你生成包含不同步骤和可执行命令的程序，这些命令将控制智能家居中的各种家电。执行是**单线程**，但划分为由程序_id标识的**程序段**。程序_id代表一个连贯意图（例程、安全操作、娱乐流程、异常处理）。

执行模型

- 一次只有一个程序处于活跃状态
- 仅在意图变更时创建新的程序_id
- 同一意图下的所有步骤必须重用相同的程序_id
- 一些步骤可能包含多项动作**当且仅当**它们是兼容的，例如：✓关闭车库 +

开始时间 音乐

显示视觉通知 + 开始时间 观看电视

输出格式 (严格)

返回一个指令对象列表。

每个程序代表一组与当前上下文相关的步骤。

```
[{"程序_id": "字符串", "步骤": [{"步骤_id": "字符串", "电器": "<电器 | 工具箱>", "功能": "<功能>", "类别": [] # 一个或多个 事故 _ 响应, 例程, 异常, 良好 _ 存在 "参数": {"..."}, "理由": "为什么此功能对用户是相关的推荐"}]}]
```

规则:

- 所有返回的对象必须共享相同的程序_ID
- 仅在动作可以安全地同时发生时返回多个对象
- JSON列表外不得有文本

程序ID规则

- 使用描述性的、稳定的ID (例如"车库_安全_出口"、"晚上_放松_音乐"、"孩子_安全_警报")
 - 仅在以下情况下变更程序_ID: - 在类别之间切换 - 从一个用户意图切换到另一个

- 完成后切勿重复使用程序_id

兼容性规则 (关键)

仅当满足以下条件时, 动作才可被分组在同一回合中:

- 它们不争夺同一人类注意力模态
- 它们不依赖彼此的结果
- 它们不引入模糊状态排序

兼容共存:

- ✓ 机械动作 (车库门、灯具)
- ✓ 背景动作 (暖通空调、音乐启动)
- ✓ 被动上下文更新

不兼容:

视觉UI通知 + 媒体播放
电视播放 + 语音通知
安全警报 + 娱乐动作
如果不确定, → 拆分为单独的回合。

| **工具** | **输出类型** | **信息** |

|-----|-----|-----|

|更新_用户_信息(用户:家庭成员) |家庭成员 |函数可以更新匹配的用户元数据, 例如年龄、名称、职业等。
 |更新_记忆(家庭_id: str, memories: List[记忆]) |None |添加或更新关于该家庭的记忆。|更新_传感器_状态(传感器_名称, 传感器_地点, 状态) |传感器 |更新传感器的当前状态并返回更新后的传感器数据
 |更新_电器_状态(电器_名称, 电器_地点, 状态) |电器 |更新电器的当前状态并返回更新后的电器数据
 |更新_宠物_信息(宠物: 宠物, 家庭_id: str) |宠物 |更新后的宠物信息并返回更新后的对象。|创建_例程(List[函数]) |字符串 |通过链接一系列功能为用户创建例程, 并返回例程的名称 |

设备操作格式示例

```

[{"程序_id": "安全_退出_与_音乐", "电器": "车库门开闭器", "功能": "操作_门", "类别": ["福祉_健康", "异常"], "参数": {"动作": "关闭"}}, {"程序_id": "安全_退出_与_音乐", "电器": "扬声器", "功能": "复杂_查询", "类别": ["例程"], "参数": {"查询_文本": "晚间轻松低保真混音, 音量6", "背景_历史": True}}]
  
```

可用输入您必须生成最多3个对家庭成员有用的程序。每个程序必须包含1到5个步骤。程序可以是单步或多步, 但力求平衡混合。任何程序中的步骤数不得超过5步。

您应按重要性递减的顺序建议程序, 例如与事故相关的响应程序优先级高于例程。你应该非常谨慎地使用更新_用户_信息、更新_记忆和更新_宠物, 不要频繁使用。

以下是家庭拥有的电器及其可用智能功能。{appliances_and_features} 这是当前家庭信息: {household_information} 这是当前情况: {current_situation} 这是相关记忆: {memories}

F.3. 任务推理

IG和CF任务推理提示模板

基于反事实推理的推理问答 — 系统提示

你是一个仅用于推理的问答系统。

你获得：

- 一个原始问题

- 两个反事实版本，每个版本代表对原始条件的一个假设变化

- 相同的底层上下文/数据适用，除非被反事实显式修改

你的任务是独立回答所有三个问题，并为每个问题提供一个简洁、有依据的理由。

答案。

推理规则

- 将原始问题和每个反事实视为独立的推理任务。
- 对于每个反事实：
- 只应用所陈述的假设变化。
- 假设所有其他事实与原始上下文保持一致。
- 不要重复使用答案，除非在推理后它们在逻辑上相同。
- 答案必须满足：确定性、直接性、无推测、仅基于上下文
- 理由说明必须：简洁明了（1-3句话）
- 明确引用导致答案的关键事实或变化
- 清晰解释答案为何与原始答案存在差异（或不存在差异），如适用。
- 答案必须精确具体，无需完整句子，且不得在答案字段中提供任何额外信息在答案字段中。

输出格式（严格）

按以下格式返回单个JSON对象：

```
{
  "原始": {
    "答案": "<对原始问题的答案>",
    "理由": "<基于背景的简洁解释>"
  },
  "反事实_1": {
    "答案": "<反事实下的答案 1>"      ,
    "理由": "<涉及假设变化的简洁解释>"
  },
  "反事实_2": {
    "答案": "<反事实下的答案 2>"      ,
    "理由": "<涉及假设变化的简洁解释>"
  }
}
```

约束

- 不要在答案中重复问题。
 - 不要包含外部知识。
 - 不要超出所要求的理由来解释推理过程。
 - 不要在JSON对象之外添加额外字段或评论。
 - 答案需要非常具体、简洁，不要包含任何其他信息。
- 你的目标是展示精确的推断、可控的反事实推理以及清晰的论证。

以下是家庭信息：

{家庭_信息}

以下是问题列表：
{questions}

MC Task Inference Prompt Template

你是一个仅进行推理的问答模型。你将获得一个**完整上下文** JSON（家庭 + 成员 + 家电 + 传感器 + 日志/事件/记忆）以及一个**问题**。

你的任务

1. 使用**仅**提供的完整上下文来回答问题。2. 不得**虚构**事实。如果答案无法推导，则输出“unknown”。## 输出格式（严格JSON）{ "answer": "<从列表中选择一个作为答案的选项>", # 应返回字母 "evidence": [{ "rationale": "推理理由", "path": "<JSON路径指针, 例如 appliances.microwave.location>", }]}

规则

- 将**答案**保持简短精确（除非必要，否则不要写完整句子）。- 如果多个项目匹配，则在**答案**中返回列表（JSON 数组），并在有用时在答案_变体中包含字符串变体。- 如果问题询问时间，则保留背景中找到的格式。

输入完整背景:~

{household_
information}

问题:

{question}

多项 -选项:

{multiple_choices}

特征推荐

FR任务推断提示模板

家庭特征排序推理提示 你是一个**家庭特征排序推理引擎**。你得到: 1. 一个完整的家庭数据记录2. 一个**候选家电特征ID列表**, 所有这些都严格属于家庭记录中展示的电器。你的任务是**推断相关性** 和**对给定的功能ID进行排序**, 基于它们与家庭的需求、行为和背景的匹配程度。

所有推理必须**严格基于所提供的家庭数据**。

Do **不要发明**家电、特征、行为或事件。

—
允许的数据来源

您只能使用家庭记录中的以下信息：- 家庭结构（成员、年龄、角色、爱好、宠物）- 设备信息（电器类型、支持功能、传感器、位置）- 上下文数据（当前时间、天气、日程、状态）- 长期记忆（习惯、偏好、重大事件）

—
任务目标

给定一个**功能ID列表**，生成一个**排序顺序**，从最相关到最不相关，针对此家庭。

相关性应通过以下方式推断：- 直接观察来自显式

字段 - 简单推断来自家庭模式 - 结合多个家庭信号的多步推理

—
排序规则

1. **所有的输入功能ID必须恰好出现一次**在最终排序中。
2. 将特征从**最相关到最不相关**。
3. 排名必须反映**实际的家庭优先级**，而非通用推荐。
4. **不要引入**未提供的功能ID。
5. 仅使用家庭记录中存在的信息。

—
输出要求

返回**仅**以下JSON对象，不包含其他内容：

```
“ {“json”:{“排名_特征”: [“<特征_ID_1>”, “<特征_ID_2>”, “<特征_ID_3>”, “...” , “<特征_ID n>” _ ]}}
```

注意：

- 第一个元素是最相关的特征。
- 最后一个元素是最不相关的功能。
- 不要包含解释、推理文本或任何额外字段。
- 不要包含 JSON 对象之外的任何文本。

—— 以下是家庭信息：

{household_information} 以下
是特征列表： {feature_list}

PG Task Inference Prompt Template

系统角色

你是一个正在运行的智能家居编排引擎。

你生成包含不同步骤的可执行命令的程序，这些命令将控制智能家居中的各种家电。

执行是**单线程**的，但被分为由'program_id'标识的**程序段**。

一个'program_id'代表一个连贯意图（例程、安全操作、娱乐流程、异常处理）。

执行模型

- 一次仅有一个程序处于活跃状态
- 仅当意图发生变化时，才会创建新的'program_id'
- 同一意图下的所有步骤必须复用相同的'program_id'
- 某些步骤可包含多个动作，但前提是这些动作兼容

示例：

✓关闭车库 + 开始播放音乐

显示视觉通知 + 开始看电视

输出格式（严格）

返回一个指令对象列表。

每个程序代表一组与当前上下文相关的步骤。

```
[{"program_id": "字符串", "steps": [{"step_id": "字符串", "appliance": "<电器 | 工具箱>", "feature": "<功能>", "category": [] # 一个或多个 事故_响应, 例程, 异常, 福祉 "args": {" ... }, "rationale": "为什么这个功能是对用户的相关推荐? "}]}
```

规则：

- 所有返回的对象必须共享相同的程序_ID
- 仅当动作可以安全地同时发生时，才返回多个对象
- JSON列表之外不得有文本

程序ID规则

- 使用描述性的、稳定的ID（例如 "车库_安全_出口", "晚上_放松_音乐", "孩子_安全_警报")
 - 仅在以下情况下变更程序_id: -

在类别之间切换时

- 从一个用户意图切换到另一个时
- 永远不要在完成后重复使用程序_ID

兼容性规则（关键）

动作仅可在同一回合中分组，仅当：

- 它们不会竞争相同的人类注意力模态 ity
- 它们不依赖彼此的结果
- 它们不引入模糊状态排序

可同时兼容：✓ 机械动作（车库门、灯具）✓ 背景动作（暖通空调、音乐启动）
✓ 被动上下文更新

不兼容：

视觉UI通知 + 媒体播放 电视播放 +
语音通知 安全警报 + 娱乐动作

如果不确定，→ 拆分为单独的轮次。

生成计划工具箱

生成计划工具箱 工具 | 输出类型 | 信息

————— 更新_用户_信息(用户:家庭成员) | 家庭成员 | 能够更新匹配的用户元数据（如年龄、名称、职业等）的函数。更新_记忆(家庭_id: str, 记忆: 列表[记忆]) | None | 添加或更新关于家庭的记忆。更新_传感器_状态(传感器_名称, 传感器_地点, 状态) | 传感器 | 更新传感器的当前状态并返回更新后的传感器数据。更新_电器_状态(电器_名称, 电器_地点, 状态) | 电器 | 更新电器的当前状态并返回更新后的电器数据。更新_宠物_信息(宠物: 宠物, 家庭_id: str) | 宠物 | 更新后的宠物信息并返回更新后的对象。创建_例程(列表[函数]) | 字符串 | 通过链接一系列特征为用户创建例程，并返回例程的名称 —————

设备操作格式

示例

```
{{"program_id": "secure_exit_and_music", "appliance": "车库门开闭器", "feature": "操作_门", "category": ["健康_状态", "异常"]}args: {"action": "关闭"}}}, {"program_id": "secure_exit_and_music", "appliance": "扬声器", "feature": "复杂_查询", "category": ["例程"]}args: {"query_text": "晚上放松 lo-fi 混音, 音量 6", "context_history": True}}}
```

]

输入可用

您必须生成最多 3 个对家庭成员有用的程序。每个程序必须包含 1 到 5 个步骤。程序可以是单步或多步，但应力求平衡混合。任何程序中的步骤数不得超过 5 步。

您应按照重要性递减的顺序建议程序，例如与事故相关的响应程序优先级高于例程。您应极少且不频繁地使用更新_用户_信息、更新_记忆和更新_宠物。

以下是该家庭拥有的电器及其可用的智能功能。{电器_与_功能}

以下是当前家庭信息：{家庭_信息}

以下是当前情况：{情况_描述}

以下是相关记忆：
{memories}

PersonalHomeTools Prompt Template

每次工具调用后，您将收到TOOL_RESPONSE。然后您可以调用另一个工具，重复直到足够。

工具：

- `get_household_profile()` → Dict — 返回关于家庭的高级信息，包括家庭_规模、居住_类型、布局、宠物、成员_ID，这些ID可与其他工具一起使用。
- `get_household_member_info(member_ids: List[str])` → List[Dict] — 返回请求的成员_ID的个人资料（名称、角色、年龄等）。
- `get_household_member_major_events(member_id: str)` → Dict — 返回单个成员的重大人生事件（日期+描述）。
- `get_household_memories(search_string: str, num_memories: int)` → List[Dict] — 通过自然语言查询搜索家庭级记忆；返回最佳匹配。
- `get_member_memories(member_id: str, search_string: str, num_memories: int)` → List[Dict] — 通过自然语言查询搜索与一个成员_id绑定的记忆。
- `get_owned_appliances()` → List[Dict] — 列出家庭中的所有设备名称。
- `get_appliances(appliance_names: List[str])` → dict — 返回指定家电的详细状态（以设备名称为键）。
- `get_appliances_by_location(locations: List[str])` → List[Dict] — 列出筛选到特定位置（例如 ["厨房"]）的家电。
- `get_电器_特征(appliance_名称: List[str])` → str — 列出该设备对象可用的特征和参数。

- `run_电器_特征(电器_名称, 特征_方法, 特征_kwargs) → Any` — 使用特征kwargs为电器运行选定的特征方法。
- `update_appliance(appliance_name: str, state: dict) → None` — 用于更新按名称索引的电器状态。
- `get_contextual_event_descriptions(compact: bool = False, sort_by_time: bool = False, indent: str = " ") → str` — 返回当前上下文家庭事件的文本描述，可选择紧凑、按时间排序并带有缩进格式。
- `get_scene_summary() → str` — 返回源视频中指示的当前家庭场景的高级自然语言摘要。
- `get_layout_zones() → List` — 返回家庭布局中定义的空间区域列表。例如：厨房。
- `get_landmarks_in_house() → List` — 返回房屋内的显著地标或固定参考点列表（例如：厨房台面）。
- `get_members_appearance(member_ids: List[str]) → Dict[str, str]` — 返回指定家庭成员的外观描述，以成员ID为键。
- `get_appliance_descriptions(appliance_names: List[str]) → Dict[str, str]` — 返回指定设备的自然语言描述，以设备名称为键。
- `get_object_information() → str` — 返回包含环境中多个对象（例如马克杯等）信息的扁平化JSON（以文本形式）。
- `extract_captions(start: Optional[str], end: Optional[str], query: Optional[str], return_text: bool, join_with: str = "\n") → List[Dict[str, Any]] | str` — 在可选时间范围内提取片段，返回结构化字幕或合并文本。其中包含事件时间戳。片段可根据查询进行可选过滤。
- `extract_event_captions(num_events: int = 5, query: Optional[str]) → List[Dict]` — 返回最相关或最近事件的字幕，可选地根据查询进行过滤。这将只是文本，不包含时间戳。
- `检查_视频_片段(开始时间: float, 结束时间: float)` — 当提供开始和结束时间时生成一个剪辑视频；返回已上传视频文件的句柄。开始和结束输入时间戳必须以秒为单位。
- `获取_音频_事件(开始时间: Optional[str], 结束时间: Optional[str], 查询: Optional[str]) → 列表` — 在可选的时间范围内提取音频事件片段。其中包含事件的时戳。可通过查询对音频事件进行可选过滤。
- `提取_帧(自身, 开始时间: Optional[int], 结束时间: Optional[int], 帧率: str=2)` — 提取在开始和结束时间戳之间按指定帧率编码的帧。至少需要一个时间戳。您最多应使用300帧。

规划规则 (重要)

- 尽可能使用最少的工具调用。
- 优先使用针对性调用：
 - 如果你知道名称，直接使用 `→get_家电和其他信息`。
 - 如果你只知道地点，先使用 `→*_by_location`。
 - 如果你需要最新活动，使用 `→extract_字幕`。
 - 如果你需要行为性/历史信息，使用（成员/家庭）记忆，附带1-2条措辞良好的查询。

- 工具使用必须逐步进行（调用工具 → 读取响应 → 决定下一个工具）。
- 不要伪造工具输出。

F.4. 有工具推断

F对于此设置，我们采用与第F.3节相同的提示词，并进行以下修改：

- 家庭信息被省略，要求智能体通过工具获取。
- 添加了一个轨迹字段，包含工具调用动作及其对应观察结果的元组。

F.5. 评估

大语言模型作为评判者用于准确率严格的大语言模型评判者提示 你是一个评估评判者。对每个键评分，判断预测值是否匹配真实值。输入是一个JSON对象：

```
[{"task_id": "...", "pred": {"o": <答案>, "f1": <答案>, "f2": <答案>}, "gt": {"o": <答案>, "f1": <答案>, "f2": <答案>}}...]
```

规则：

- 独立评估每个键（o, f1, f2, ...）。
- 如果预测值与真实值语义等效，则返回1，否则返回0。
- 将大小写、冠词以及标点/空格细微差异视为等效。
- 不要给予部分得分。如果不确定，则返回-1。

输出必须是有效JSON：

```
{ "task_id": "<相同任务_id>", "per_key": { "o": 0|1|-1, "f1": 0|1|-1, "f2": 0|1|-1, ... }, }无额外文本。
```

Role Playing Judge - 绝对模式

你是一个多角色评估法官，负责智能家居辅助计划。你的工作是角色扮演以下视角：

- 每位家庭成员，
- 家庭环境本身，并共同生成详细的评估分数。

您的评估必须反映:

- 每位成员的个人舒适度和偏好,
- 安全考虑,
- 便利性,
- 与日常作息和习惯的一致性,
- 能源效率,
- 情感健康,
- 计划的清晰度和正确性,
- 通过智能家居设备执行计划的可行性。

您必须仅评估所提供的行动方案的质量和适当性。您不应发明新的动作或改进计划。

您必须角色扮演的角色

每个家庭成员角色设定都会提供给您。您必须扮演每一个角色, 并给出一个评分。最后, 您还必须扮演智能家居本身。

评分规则 (1-5)

给出一个从1到5的整数评分:

- 1- 非常差- 不安全、不清晰、不可行, 或与日常惯例矛盾- 导致家电的伤害、干扰或误用
- 2 - 差
 - 部分有用但有重大问题
 - 不个性化, 中等干扰, 缺少关键安全要素
- 3 - 合格- 可接受但通用- 小问题, 个性化不足或步骤不完整
- 4 - 良好
 - 个性化、安全、基本完整- 符合家庭习惯, 略有不足
- 5 - 优秀 (高级)
 - 高度个性化、安全、清晰、高效- 最大化舒适度, 与偏好和日常惯例一致- 电器/传感器使用正确, 过载最小- 在适用时提供情感支撑

评估格式

返回一个JSON字典:

```
[{"program_id": "<program_id>", "overall_score": <1 到 5>, "persona_feedback": { "household_member_id": {"feedback": "<反馈>", "score": score} }, "rationale": "<1对每个评分给出3句话的理由>" }]
```

ules:

- 简明扼要但富有意义。
- 保持角色特定语气差异。
- 切勿修改计划。
- 切勿添加新动作。
- 严格依据所提供计划进行评分。

你必须仅评判行动方案。
为每个生成方案生成评分。

以下是当前情境信息：
{household_information}

以下是家庭成员信息：
{家庭_成员_信息}

以下是生成的方案：
{generated_plans}

Role Playing Judge - RELATIVE Mode

你是一个家庭多视角排名引擎。

你将获得：1) 一组用字母标签的候选选项（例如，“A”、“B”、“C”……）。每个字母对应一个大语言模型生成的智能家居程序。2) 一个包含成员、偏好、日常惯例、约束条件和近期背景的家庭档案。你的任务是从以下视角对选项进行排名：- 整个家庭（智能_家居）的视角 - 每个家庭成员个人的视角
评估指南家庭（智能_家居）视角基于以下标准对选项进行排名：

- 安全与异常预防

- 能源效率与资源使用
- 系统一致性和长期收益
- 最小化非预期副作用

家庭成员视角 对于每位成员，选项排名基于：

- 与个人日常习惯和偏好保持一致
- 便利性与干扰
- 个人收益或舒适度影响
- 情境适切性（时间，近期事件）

排序规则

- 排名必须是相对的，并且在所有选项之间进行比较 s.
- 使用定性判断；不要平均评分。- 打破平局

的顺序：1) 安全与预防 2) 多成员收益 3) 低干扰

输出格式（严格）

仅返回一个JSON对象，完全遵循此模式：

```
{
  "整体_order": [ <字母\_1> , <字母\_2> , <字母\_3>... ] ,
  "角色_order": {
    "家庭\_member\_id_1": [ <字母\_1> , <字母\_2> , <字母\_3>... ] ,
    "家庭\_成员\_id_2": [ <字母\_1> , <字母\_2> , <字母\_3>... ]
  },
  "理由": "<1-3句话解释总结为什么整体排序被偏好以及成员偏好如何影响它>"
}
```

以下是家庭成员信息：

{家庭_成员}

以下是当前情况：

{当前_情况}

以下是生成方案：

{生成_方案}

G. Schemas

家庭模式。

家庭

```

家庭_id:字符串
家庭_size:整数
occupancy_类型: 字符串
布局: 字符串
宠物:  [{
    名称: 字符串
    动物: 字符串
    年龄: 整数
}]
成员:  [{
    成员_id: 字符串
    名称: 字符串
    角色: 字符串
    年龄: 整数
    性别: 字符串
    职业: 字符串
    角色: 字符串
    爱好: [字符串]
    生活方式: 字符串
    偏好: 字符串
    主要_事件:  [{
        名称: 字符串
        动物: 字符串
        年龄: 整数
    }]
}]
家电:  [{
    电器: ApplianceObject
    地点: 字符串
}]
传感器:  [{
    传感器: SensorObject
    地点: 字符串
}]
记忆:  [{
    记忆: 字符串
    被试: [字符串]
    附加_信息: 字符串
    时间: 字符串
}]
背景: {
    事件:  [{
        描述: 字符串
        传感器:  [{
            传感器: SensorObject
            地点: 字符串
        }]
        家电:  [{
            电器: ApplianceObject

```

```

        地点: 字符串
    }]
天气: {
    室外: {
        雨: 字符串
        雪: 字符串
        晴: 字符串
        温度: 字符串
        风: 字符串
    }
    室内: {
        灰尘: 字符串
        湿度: 字符串
        气味: 字符串
        温度: 字符串
    }
}
}

```

视频转录模式。

视频转录

```

数据点_标识符: 字符串
视频_路径: 字符串
视频_描述: {
    时间基准: {
        时间戳_格式: 日期时间
        开始时间_偏移_秒: 整数
    }
    场景: {
        摘要: 字符串
        环境_类型: String
        地点_标签: String
        光照: {
            整体: String
            来源_可见: [字符串]
        }
    }
    摄像机: {
        运动: 字符串
        视点: 字符串
        备注: 字符串
    }
    布局: {
        区域: [{
            区域_id: 字符串
            标签: 字符串
            相对_位置: 字符串
        }]
        地标: [{
            地标_ID: 字符串
            类型: 字符串
        }]
    }
}

```

```

        描述: 字符串
        区域_id: 字符串
    }}
}
}
实体: {
    成员: [{
        成员_id: 字符串
        外观: 字符串
        初始_地点: 字符串
    }]
    宠物: [{
        宠物_id: 字符串
        物种: 字符串
        初始_地点: 字符串
        描述: 字符串
    }]
    家电: [{
        电器_id: 字符串
        类型: 字符串
        地点: 字符串
        初始_状态: {}
        描述: 字符串
    }]
    对象: [{
        对象_id: 字符串
        标签: 字符串
        类别: 字符串
        初始_地点: 字符串
        初始_状态: 字符串
        描述: 字符串
    }]
    事件: [{
        事件_ID: 字符串
        时间戳_开始时间: 字符串
        时间戳_结束时间: 字符串
        事件_类型: 字符串
        参与者: [字符串]
        目标: [字符串]
        描述: 字符串
        音频: 字符串
    }]
    实体_状态_时间线: {
        成员: [{
            成员_ID: 字符串
            状态: [{
                时间戳: 字符串
                状态: 字符串
                触发器_事件_ID: [字符串]
            }]
        }]
    }
    宠物: [{

```

宠物_ID: 字符串 状态: 时间戳: 字符串 状态: 字符串 触发_事件_ID: 字符串 家电: 电器_ID: 字符串 状态: 时间戳: 字符串 状态: 字符串 触发_事件_ID: 字符串 对象: 对象_ID: 字符串 状态: 时间戳: 字符串 状态: 字符串 触发_事件_ID: 字符串 字幕: { 全局: 字符串 片段: 时间戳_开始时间: 字符串 时间戳_结束时间: 字符串 字幕: 字符串 } 事件: { 事件_ID: 字符串 字幕: 字符串 } 质量: { 备注: 字符串 一致性_检查: { 实体_ID_一致: 布尔 全部_状态_变化_有: 时间戳: 布尔 无不可验证推断: 布尔 } } }

H. Role Playing Judge 标注说明

为了评估Role Playing Judge的可靠性 (*RPJ*)，我们在一部分计划生成输出上进行了针对性的人工验证研究。四名独立的标注员各评估了100个计划³，在整体家庭层面和个体角色层面提供判断，以衡量 *RPJ* 捕捉个性化满意度。

对于每个数据项，标注员会看到：场景摘要、事件时间线、家庭成员档案、房屋摘要、布局摘要、推荐计划、输入模态，以及对应的 *RPJ* 评分和理由说明。基于这些信息，标注员评估 *RPJ* 评估是否准确。

标注员使用三级量表记录他们的评估：

(2) 正确 — 完全同意 *RPJ* 评分和理由说明；

(1) 部分正确 — 部分同意评分和/或理由说明；

(0) 不正确 — 不同意 *RPJ* 评估。

每位标注者针对每个示例提供两种判断：用于反映家庭层面评估的整体人类一致性分数，以及用于反映与个体成员视角一致性的用户画像人类一致性分数。该协议直接衡量 *RPJ* 是否能产生有意义且非随机的判断，以及它能否成功模拟用户画像特定视角。

如图11所示，在整体和角色层面评估中，所有标注者和两种模态下的大多数标注都属于“正确”或“部分正确”类别，几乎没有一致分歧的实例。这一模式表明，*RPJ* 判断与人类评估基本一致，并且被认为是有意義的而非随意的。整体家庭层面的一致性略高于角色层面，反映出细粒度角色特定满意度建模的难度增加。此外，我们观察到标注者严格程度存在明显差异，有些标注者比其他标注者更容易给出较高的一致性分数（例如，A1倾向于更严格，而A4更倾向于同意）。尽管如此，积极和部分一致的高度集中支持了*RPJ*作为个性化家庭设置中主观计划质量评估的实用替代指标的有效性。




图 11. Role Playing Judge 评估的人类一致性分数分布。分组水平条形图显示了在文本与视频设置下，四位标注者对整体家庭层面分数（左）和角色层面分数（右）做出的正确、部分正确和不正确判断的百分比。

³两位标注者（A1、A2）独立标注了同一组 50 个计划，另外两位标注者（A3、A4）独立标注了另一组 50 个计划，从而得到两组互不相交的 50 个计划，且每组均包含成对标注。

I. 定性分析

I.1. 任务示例

任务示例

IG, CF, MC

- 简单：女性左脚穿着什么来支撑？
 - 选项：石膏，拖鞋，厚袜子，绷带，踝关节支具– 反事实：假设受伤是轻微扭伤– 反事实：假设厨房台面上有碗
- 中等：女孩打电话时坐在哪里？
 - 选项：[在咖啡桌前面的地板上，在沙发上，在厨房桌旁，在厨房椅子上，在躺椅上]– 反事实：假设女孩决定留在沙发上– 反事实：假设她用的手机是黑色的
- 困难：朋友在女性烫伤手后执行的完整急救行动序列是什么？
 - 选项：[她冲过去，检查手，带她到厨房水槽，冲水，拿急救箱，并进行治疗。，她立即拿急救箱，涂药膏，然后冲水在手。，她跑到电话前求助，然后从冰箱冷冻室拿冰袋。，她告诉她坐着别动，拿湿毛巾，包住她的手。，她带她到厨房，给她一杯水，然后找急救箱。]– 反事实：假设急救箱就放在厨房水槽旁边，让朋友在冲水前先拿到它。– 反事实：假设烧伤发生在晚上，外面很黑。

FR

- 情况摘要：这是一个工作日的上午7:50，James刚刚离开家去上班，经过车库。Emily目前正在客厅里做瑜伽，播放着音乐，她最近覆盖了预设的恒温器设置，将其调高至更温暖的71°F。房屋现在正进入早晨惯例，Emily、Stephen和Denali在家。
- 功能：恒温器.远程室内传感器，恒温器.用于调度自动化的学习算法，咖啡机.定时冲泡

PG

- 场景摘要：一位老年女性在厨房的小桌子上用餐。吃完后，她收拾剩菜、清洗碗碟并擦拭桌子，清理完毕。她与画外某人简短交谈后，另一个人穿过场景，然后她重新出现，穿着外出服装并离开。
- 事件：00:00.000-00:11.500 lm1使用筷子从桌子上的几个碗中进食。
 00:11.500-00:33.000 lm1吃完，将碗叠放起来，并从椅子上站起来。
 00:33.000-00:41.000 lm1将叠放的碗拿到冰箱前，打开门，把它们放进去，然后关上门。
 00:41.000-00:51.500 lm1 从一个马克杯喝水，然后收拾桌子上剩余的物品，走向厨房水槽区域。
 00:51.500-01:08.000 lm1 在水槽处清洗碗碟。

01:17.500-01:50.000 lm1回到桌旁，用抹布将其表面擦拭干净。02:01.000-02:09.000 lm1坐下，看着桌上的一张纸。02:14.000-02:18.000 lm1问道：“我们该走了吗？”画外传来一个男性声音回答：“不，我们还需要更多的休息时间。”02:18.000-03:49.000 lm1离开画面。03:49.000-03:53.000 一个不知名的人从右向左穿过场景并离开。04:03.000-04:12.500 听到关门声，随后是电子门锁的蜂鸣声和上锁声。05:13.500-05:18.000 lm1从右侧进入，此时穿着一件冬季外套，走向笔记本电脑区域，然后离开画面。

I.2. 结果示例

计划生成示例1场景。一个女性走进一个明亮的客厅，展开瑜伽垫，打开电视播放瑜伽教学视频，并开始跟着拉伸动作做。

程序 1: 增强瑜伽练习

- 步骤1: 电视 → 校准音视频 理由: 优化画面和音频设置，以适应动作密集的教学内容 nt.
- 步骤2: 空气净化器 → 启用过敏原模式 理由: 改善运动期间的空气质量。

程序 2: 运动后恢复建议

- 步骤 1: 电视 → 显示通知动作详情: 显示一份奶昔配方（香蕉、蛋白粉、杏仁奶）。理由: 支撑运动后恢复。

程序 3: 放松氛围模式

- 步骤 1: 电视 → 设置环境模式理由: 在会话结束后过渡到平静的视觉显示。

表13. 不同长度轨迹的示例

#	工具调用序列
	获取_场景_摘要 提取_字幕 检查_视频_片段
	获取_场景_摘要 获取_家庭_资料 获取_家庭_成员_信息 提取_事件_字幕
	获取_场景_摘要 获取_家庭_资料 获取_拥有的_家电 获取_家电 获取_电器_特征
	获取_场景_摘要 获取_家庭_资料 获取_家电_按_地点 get_owned_家电 get_家电 extract_字幕
	get_场景_摘要 get_家庭_档案 get_家庭_成员_信息 提取_字幕 检查_视频_片段 根据_地点获取_家电_ 获取_电器_特征
	获取_场景_摘要 获取_家庭_简介 获取_家庭_成员_信息 提取_字幕 检查_视频_片段 获取_家电_按_地点 获取_家电 获取_拥有的_家电
	获取_场景_摘要 获取_家电_按_地点 获取_家电_按_地点 获取_拥有的_家电 获取_家电 获取_家电_功能 提取_事件_字幕 提取_字幕 检查_视频_片段
	获取_场景_摘要 获取_家庭_档案 获取_家庭_成员_信息 提取_字幕 检查_视频_片段 获取_家电_按_地点 获取_家电_按_地点 获取_拥有的_家电 获取_家电 51 提取_帧

规划生成示例2 情境。一个人在活跃的炉灶附近尖叫，暗示可能发生烧伤或厨房事故。

程序1: 厨房烧伤事故响应

- **步骤1: 炉灶** → **关闭燃烧器**理由: 消除即时危险, 防止进一步受伤或火灾。
- **步骤2: 智能显示屏** → **显示通知** 操作详情: 显示轻微烧伤急救指导, 并询问是否呼叫紧急服务。理由: 提供及时的医疗指导并支持升级处理。
- **步骤3: 灯具** → **调暗亮度** 理由: 在事故期间营造更平静的环境。
- **步骤4: 系统内存** → **事件记录**动作详情: 记录一位家庭成员被炉灶惊吓并立即获得帮助。理由: 启用未来安全感知的主动行为。

程序2: 提出烹饪安全例程

- **步骤1: 扬声器** → **播报**动作详情: 建议创建一个“烹饪安全”例程, 当炉灶打开时进行播报。理由: 通过主动安全自动化预防类似事件。

程序3: 增强烹饪环境

- **步骤1: 抽油烟机** → **开启电源**理由: 改善烹饪时的通风。
- **步骤2: 扬声器** → **播报**动作详情: 建议在烹饪恢复时播放舒缓音乐。理由: 减少压力, 恢复舒适氛围。

J. PersonalHomeTools

表14. Tool-Box中可用的家庭辅助功能

函数	助手/描述
获取_家庭_成员_信息	返回指定家庭的个人信息（例如：名称、角色、年龄）成员。
get_household_member_major_events	为指定家庭检索重大人生事件（日期和描述）成员。
获取_家庭_记忆	通过自然语言查询搜索家庭级记忆，并返回最佳匹配。
获取_家庭成员_记忆	搜索与特定家庭成员相关的记忆。
获取_拥有_家电	列出家庭中所有家电及其元数据，如类型和地点。
获取_拥有_传感器	列出家庭中所有传感器及其元数据，如类型和地点。
获取_天气	返回室内和/或室外天气读数。
获取_家电	返回指定家电的详细状态信息。
获取_传感器	返回指定传感器的详细状态或日志信息。
获取_电器_和_传感器_事件	返回一个组合的、按时间顺序排列的近期电器和传感器事件。
按_地点获取_家电_	按其物理位置列出家电。
获取_传感器_按_地点	按其物理位置列出传感器。
获取_家电_功能	列出指定家电的支持功能与可配置参数。
运行_家电_功能	使用提供的参数执行特定的设备功能。
更新_电器	用于更新以名称键控的电器状态。
获取_背景_事件_描述	返回当前上下文的家庭事件的文本描述，可选地压缩、按时间排序并以缩进格式呈现。
获取_场景_摘要	返回当前家庭的高级自然语言摘要场景，如源视频所示。
获取_布局_区域	返回在家庭布局中定义的空间区域或区域列表。例如，厨房
获取_地标_在_房屋	返回显著地标或固定参考点（例如厨房台面）的列表。在房屋内。
get_成员_外观	返回指定家庭成员的外观描述，以，成员ID为键。
get_电器_描述	返回指定电器的自然语言描述，按键为设备名称。
获取_对象_信息	返回扁平化JSON（以文本形式），包含关于多个环境中的对象（例如马克杯等）。
提取_字幕	提取可选时间范围内的片段，返回结构化字幕-或合并文本。此内容包含事件时间戳。这些片段是可选地按查询进行过滤
提取_事件_字幕	返回最相关或最近事件的字幕，可选地按查询进行过滤。这将只是文本，而非时间戳
检查_视频_片段	当提供了开始和结束时间时，生成一个剪辑视频
获取_音频_事件	提取可选的时间范围内的音频事件片段。这包含事件的时间戳。音频事件可选择地按查询进行过滤。
提取帧_	以指定的帧率提取开始时间戳和结束时间戳之间的编码帧。