

SimuHome: 面向智能家居大语言模型代理的时间与环境感知基准

Gyuhyeon Seo¹, Jungwoo Yang¹, Junseong Pyo², Nalim Kim¹, Jonggeun Lee¹,
Yohan Jo^{1,*1} 首尔大学数据科学研究生院² 汉阳大学信息系统系{
seokh97,jwyang0213,kimnalim,jonggeun.lee,yohan.jo}@snu.ac.kr
standardstar@hanyang.ac.kr

摘要

大语言模型（LLM）智能体擅长多步骤、工具增强的任务。然而，智能家居带来了独特的挑战，要求智能体处理潜在用户意图、时间依赖、设备约束、调度等问题。开发具备此类能力的智能家居代理的主要瓶颈包括：缺乏一个可供智能体与设备交互并观察结果的现实模拟环境，以及一个用于评估它们的具有挑战性的基准。为了解决这些问题，我们引入了**SimuHome**——一个时间加速的家庭环境，能够模拟智能设备、支持API调用，并反映环境变量的变化。通过基于智能家居通信的全球行业标准——Matter协议构建模拟器，SimuHome提供了高保真环境，并且在SimuHome中验证通过的智能体可以经过极少的适配部署到真正的Matter兼容设备上。我们提供了一个具有挑战性的基准，包含600个回合，涵盖十二种需要上述能力的用户查询类型。我们在统一的ReAct框架下对11个智能体进行了评估，结果显示：虽然模型在简单任务上表现良好，但在潜在意图推断、状态验证，尤其是时间调度方面存在困难。即使是最优模型GPT-4.1，成功率也仅为54%。这些发现凸显了迫切需要能够通过工具在执行动作前可靠验证当前状态，并协调时间相关操作的方法。²

1 引言

近期，大语言模型（LLM）智能体在多步骤、工具增强任务中展现出强大能力，包括API检索、调用和中间状态验证（Qin 等，2024；Patil 等，2025；Chen 等，2024；Huang 等，2024；Xu 等，2023；Schick 等，2023）。这些能力使其能够执行网页导航和目标追踪等长周期任务，在此过程中智能体必须规划、检查状态并在多个步骤中验证结果（Zhou 等，2024；Yao 等，2022；Deng 等，2023；Xie 等，2024；Yao 等，2024；Trivedi 等，2024）。

智能家居代理，如亚马逊Alexa和Google Home，是最早投入实际生产化使用的工具智能体之一，并且长期以来一直是研究课题。为了应对现实世界的挑战，智能家居代理需要具备处理多种因素的能力，例如：(1) 潜在用户意图（例如，“感觉闷”暗示湿度控制），(2) 时间依赖（例如，“当洗碗机完成时打开厨房灯”），(3) 设备动作与属性之间的依赖关系（例如，洗碗机运行时不能打开），(4) 调度（例如，“早晨播放音乐”）。然而，迄今为止，大多数（如果不是全部）智能家居代理在这些方面都存在不足。关键瓶颈之一在于缺乏具有此类复杂性的训练和测试数据。即使存在这样的数据集，静态数据集也有明显的局限性：智能体无法通过实践学习，而且智能体性能

*通讯作者。¹<https://csa-iot.org/all-solutions/matter/>²我们将在论文发表后发布代码和数据集。




图1: SimuHome家庭环境，配备支持Matter的设备，具有图形用户界面，用户可以在其中跨房间布置设备、配置其属性，并评估智能体对多设备控制的推理能力。

也无法准确评估（因为用户意图可能通过多种方式满足，而这些方式并未在数据集中标注）。我们旨在通过开发一个高保真的智能家居模拟器来应对这一挑战，在该模拟器中，智能体可以通过API与设备交互，并观察反映在环境中的结果，同时提供一个包含各种复杂用户请求（包括可行和不可行请求）的广泛基准。

我们的第一个贡献是一个智能家居模拟器，**SimuHome**（图1）。SimuHome是一个时间加速的智能家居环境，能够容纳各种房间布局、环境变量（例如温度、照度）和智能设备。智能体可以调用API来操作设备（例如将空调设置为25度）。设备模拟时会检查内部约束（例如，空调必须处于开启状态才能设置温度），结果会影响环境（例如，房间温度在10分钟内逐渐降至25度）。值得注意的是，SimuHome实现了Matter，一个广泛采用的智能家居互操作性标准。因此，设备内的属性和约束具有高保真度。此外，在SimuHome中训练和验证的智能体可以在真正的Matter兼容设备上运行，只需极少的调整。SimuHome还以廉价且快速的方式实现受控实验。它允许无限实验，包括压力测试罕见边界情况和反事实场景，同时严格的可重复性确保公平比较和跨模型的迭代验证。虽然超出了我们工作的范围，但它也可以通过强化学习支持模型训练。

我们的第二项贡献是一个经过人工验证的基准测试，包含600个回合，涵盖十二种用户查询类型，每种类型均提供可行与不可行变体，以评估智能体在主动意图推理、动态状态与物理限制检查以及时间调度方面的能力。每个案例被封装为一个单独的回合，包含初始家庭状态（即房间、设备状态、环境变量）、一个可验证目标、一个自然语言查询以及一组强制在控制前进行信息收集的所需动作。可行案例通过比较SimuHome中的结果状态与目标状态进行评分。不可行案例包含错误前提、物理限制或时间冲突，由大语言模型评判员进行评估。

我们在统一的ReAct（Yao等人，2023年）框架下评估了11个大语言模型智能体，在600个回合中分别采用可行与不可行变体，通过模拟器状态比较对可行任务进行评分，并使用经过验证的大语言模型评判员评估不可行逻辑检查。模型在简单检索和显式设备控制方面表现相对较好。但它们经常无法推断潜在意图，或在行动前验证当前设备和环境状态。时间调度是最具挑战性的领域：矛盾忽视和处理不当十分常见，即便是GPT-4.1的成功率也仅达到54%。这些结果促使人们探索在行动前通过工具验证当前状态，以及在动态家庭环境中可靠地规划和协调时间相关操作的方法。

2 相关工作

家庭具身代理的模拟基准。 具身代理基准推动了家庭环境中的指令遵循，但与设备的交互通常局限于过度简化的动作，忽略了现实世界的约束。AI2-THOR (Kolve等人，2017年) 使智能体能够在逼真3D房间中导航，并通过原子动作（例如，打开/关闭、拿起/放下）操作物体。ALFRED (Shridhar等人，2020年) 将其扩展至长周期

任务，要求智能体将语言和第一人称观察转化为产生持久状态变化的动作序列，并由 ~25k 个演示支持。VirtualHome (Puig 等人, 2018 年) 将日常活动（例如，做晚饭、清理房间）捕捉为源自众包脚本的可执行程序。虽然这些模拟器在语言接地和任务结构方面效果显著，但它们将设备限制为离散命令（切换开启/关闭、打开/关闭），忽略了真实家庭中出现的通信延迟、冲突以及级联跨设备效应。

大语言模型智能体与智能家居基准。近年来，智能家居领域的大语言模型基准强调规划与目标解释，但同样依赖简化的抽象。HomeBench (Li 等人, 2025 年) 在单设备与多设备场景下评估有效、无效及混合请求下的指令遵循能力，突出错误检测、拒绝与协调执行。Sasha (King 等人, 2024 年) 研究目标解释，将欠指定意图映射到设备级规划，并通过用户研究评估其质量。SAGE (Rivkin 等人, 2023 年) 将智能家居控制构建为顺序工具使用，引导大语言模型完成 API 调用、偏好处理与状态监控。尽管有这些进展，现有基准仍运行于预编脚本环境中，且忽略了动态设备属性或时间约束，限制了其对真实家庭的保真度。

SimuHome 通过一个可重现的模拟器弥补了这一差距，该模拟器在支持属性跟踪、前提条件强制执行和时间约束处理的同时，建模设备对环境条件的影响。

3 SimuHome: 一个智能家居模拟器

3.1 动机

在智能家居中评估大语言模型智能体需要一个能够模拟真实世界连续性和反应性的模拟器。然而，现有的智能体模拟器存在一个局限性：它们无法模拟一个动作会影响其他动作和环境的真实连锁反应，而是将每个命令视为独立的、孤立的事件。为解决此问题，我们围绕四个核心需求设计了 SimuHome：

复杂时间约束。为了评估智能体的时间推理能力，模拟器必须处理各种基于时间的复杂查询（例如，“保持厨房灯开启直到洗碗机完成”）。这使我们能够测试智能体是否理解并规划带有复杂时间依赖的动作。

基于行业标准的依赖建模。模拟器根据 Matter 行业标准真实地模拟了智能设备的操作规则。此设计使我们能够评估智能体是否学习并适应真实世界的设备约束。例如，模拟器强制执行空调必须开启电源后才能更改其风扇转速的规则，从而让我们测试智能体是否理解此依赖关系。

实时环境反馈。模拟器模拟了设备动作对环境的持续实时影响（例如温度和照度）。这创造了一个动态环境，用于测试智能体是否能够监测持续变化并做出适当反应，而不仅仅是基于静态信息采取行动。例如，当空调运行时，温度逐渐下降，智能体必须感知到这一变化才能完成其目标。

可重复性。环境必须完全可重复，确保智能体的动作在相同的初始条件下产生相同的结果。这对于可靠地衡量和比较不同智能体或策略的性能至关重要。

3.2 模拟器架构与操作

我们的模拟器通过固定时间间隔处理时间来进行操作。基本时间单位“时间步”定义为 0.1 秒的真实世界时间。所有环境和设备状态更新均在每个时间步进行计算。这种以固定间隔更新状态的方法使模拟器能够高保真地模拟现实世界中持续发生的过程结果。模拟器包含三个组成部分：智能家居环境、实时状态更新机制以及智能体-仿真器接口。

智能家居环境。家庭是一个可配置的环境，由一个或多个房间组成，每个房间包含一组自定义设备以及四个环境变量：温度、照度、湿度和空气质量。为支持逼真的场景，该环境既包括直接影响环境变量的设备（如空调），也包括具有多阶段运行周期的设备（如洗衣机）。我们共建模了17种不同的设备类型。完整的设备列表可参见附录A.4。

实时状态更新机制。仿真的核心是聚合器模块，该模块模拟设备操作对环境的动态影响。在每个时间步，聚合器计算所有活动设备对其相关环境因素的联合影响。例如，温度受空调和热泵影响，照度受灯影响，湿度受加湿器/除湿器影响，空气质量受空气净化器影响。这种影响的强度是累加的；它随活动设备的数量及其具体设置（例如空调的风扇转速）而缩放。此机制确保环境对智能体动作做出真实响应。聚合器的详细更新方程见附录A.12。

智能体-仿真器接口。智能体通过调用13个工具集与仿真器交互。这些工具的结构反映了Matter在定义设备能力方面的模块化方法。详细的工具规范见附录A.2。

3.3 任务定义

SimuHome任务被建模为部分可观测马尔可夫决策过程 (POMDP) $(\mathcal{S}, \mathcal{A}, \mathcal{O}, \mathcal{T}, \mathcal{R})$ 。环境状态 $s_t \in \mathcal{S}$ 由两部分组成：**设备状态**（由端点、集群和属性组成的Matter分层模型表示）和**环境状态**（由温度、照度、湿度和空气质量等环境条件定义）。在每个时间步，智能体执行一个动作 $a_t \in \mathcal{A}$ ，该动作作为Matter命令实现，并更新设备状态。转移函数 $\mathcal{T}$ 通过聚合器机制将设备效果传播到环境状态。智能体接收一个观测 $o_t \in \mathcal{O}$ ，对应于通过API暴露的设备属性和环境状态变量的子集，这仅提供对完整状态的部分可见性。奖励函数 $\mathcal{R}$ 被定义为根据任务查询的评估过程的一部分。奖励分配的具体细节见第5.1节。

4 基准设计

4.1 查询类型

我们定义了十二种在智能家居环境中用户查询中常见的查询类型。这些查询旨在评估智能体在设备控制、环境变量查询（如温度和照度）、隐式意图推断以及带有三个子类型的时间协调方面的能力。每种类型都配有一个不可行场景，以测试智能体的逻辑一致性与约束处理能力，共计12个类别。参见附录A.1中每种查询类型对应的不可行场景示例。

QT1（环境感知）。这评估了正确感知环境条件和设备状态，并以自然语言提供准确、合乎逻辑信息的能力。例如，针对“我快要做饭了，能告诉我厨房的湿度是多少吗？”，智能体必须识别厨房区域，使用环境查询工具检查湿度，并以清晰的单位和数值进行回复。如果在此过程中需要进行设备发现，智能体必须首先检查该房间中的设备列表。

QT2（隐含意图）。这部分评估智能体能否从抱怨或间接表达中推断出用户潜在目标，并创建并执行合适的设备控制计划来解决问题。例如，当听到“客厅里感觉太闷了”时，智能体应检查客厅的湿度，然后采取相应动作进行调整，比如开启加湿器或关闭除湿器。

QT3（显式意图）。这评估准确解释和执行涉及指定设备和目标值的命令的能力。例如，对于命令“将客厅空气净化器风扇速度设置为百分之百，最强功率”，智能体必须验证客厅中是否存在空气净化器。




图2：情境生成流水线

如果它处于关闭状态，智能体必须先将其开启，然后再将风扇转速设置为100%。

QT4-1 (未来调度)。此项评估智能体调度和规划多个设备（例如灯、空调）在未来特定时间开启的能力。例如，对于请求“十分钟后我要睡觉了。你能在十分钟后关掉灯和加湿器吗？”，智能体必须计算从当前时间起十分钟后的绝对时间。然后，它应将两个动作调度为一个无冲突的工作流。在注册命令之前，智能体必须预先验证每个设备是否可控，以及指定的参数是否在可接受范围内。

QT4-2 (依赖调度)。此项评估智能体为运行设备（例如洗碗机这类需要时间完成的设备和即时设备（例如灯）创建协调调度的能力，同时考虑依赖关系和完成时间。例如，对于请求“当洗碗机完成时，请关闭厨房灯”，智能体必须检查洗碗机的剩余运行时间，以计算其预计完成时间。然后，它应基于该绝对时间调度关闭灯，并在验证和注册正确的参数及命令顺序后执行。

QT4-3 (并发调度)。这评估了根据给定的时间约束，调度两个或更多运行设备而无冲突的能力。例如，对于请求“调度洗碗机，使其与洗衣机同时完成”，智能体必须检查两个设备的剩余运行时间，以计算是否可能实现同时完成。如果可能，智能体应调整其中一个设备的开始时间，并注册一个工作流以确保它们同时完成。

4.2 情境生成

回合的定义与组成。一个回合为智能体定义了一个独立的、自包含的任务场景。如图2所示，每个回合由四个关键部分组成：初始家庭状态（包括房间布局、设备状态和环境变量值）、智能体必须实现的目标、自然语言用户查询，以及用于评估的所需动作集。

步骤1：初始家庭状态构建。每个回合的初始家庭状态通过两个阶段构建，以确保起始条件的多样性和真实性（图2）。首先，生成多种具有不同房间和设备配置的物理布局。其次，从全关状态开始，设备被随机操作，建立合理的设备状态。尽管这个过程




图3：回合评估流水线

涉及随机化，但通过随机种子进行控制，以确保布局和初始状态都是完全可重复的。

步骤2：目标与所需动作。一个目标定义了智能体必须达成的特定设备或环境变量的期望最终状态。生成过程因查询类型而异（详见附录A.5），旨在确保所有目标逻辑一致。例如，如图2（步骤3）中针对QT3所示，设备目标是通过从预定义的有效状态集合中采样创建的（例如，开关：开启，风扇转速：40%）。每个这样的状态集合都天然满足设备的内部依赖性。**所需动作**是智能体必须执行的一系列工具调用。这确保智能体的后续行动基于从环境中收集的最新信息。例如，在尝试改变空气净化器的风扇转速之前，智能体需要先调用工具“获取房间设备(杂物间)”以确认设备的存在。只有当智能体既满足目标，其工具调用历史又包含所有所需动作时，该回合才被标记为成功。

步骤3：查询合成。通常，用户的自然语言查询体现了待实现的目标，该目标的清晰度对于准确评估智能体的成功至关重要。因此，我们首先为智能体定义了一个可验证目标，随后基于此目标合成了自然语言查询。接着，我们使用 GPT-5-mini(OpenAI, 2025b) 从这些预定义目标中合成了自然语言查询。为确保每个查询准确反映其预定义目标，两位研究工具智能体的研究生独立审查了全部数据集。他们使用 Cohen 的 κ 系数 (Cohen, 1960) 测量的标注者间一致性为 0.92，用于识别需要修正的查询。这表明我们数据集的验证流程高度一致且可靠，验证了基准数据由高质量的自然语言查询构成。

步骤4：情境生成。通过整合前几步生成的组件，我们构建了最终的基准数据集。我们为12种查询类型各生成了50个不同的回合，从而得到一个高质量的数据集，包含600个回合，专为评估智能家居代理而设计。

5 评估

5.1 评估方法

如图3所示，我们使用两种互补的方法——基于模拟器的评估和基于大语言模型评判的评估——来评估智能体在 § 4.1 定义的12种查询类型上的性能。

表1: 评估结果显示各查询类型 (QT) 的成功率 (百分比)。F和IF分别指可行场景和不可行场景。上标 J 和 S 分别表示基于大语言模型评判的评估和基于模拟器的评估的结果。

模型	QT1		QT2		QT3		QT4-1		QT4-2		QT4-3	
	F ^J	IF ^J	F ^S	IF ^J	F ^S	IF ^J	F ^S	IF ^J	F ^S	IF ^J	F ^S	IF ^J
Llama-4-Scout	58	42	2	22	24	34	4	4	2	2	2	0
Llama-4-Maverick	<u>96</u>	78	52	36	88	74	22	14	18	10	<u>32</u>	8
Qwen3-32B	82	66	<u>62</u>	30	52	68	18	14	14	8	16	6
Qwen3-235B-A22B	86	74	32	36	<u>84</u>	70	<u>26</u>	18	38	34	28	48
Gemma-3-12B-it	78	38	14	32	32	24	2	0	0	0	0	0
Gemma-3-27B-it	80	48	54	24	48	44	4	2	10	8	0	6
Gemini-2.5-Flash-Lite	78	60	44	<u>50</u>	50	50	8	34	10	16	16	20
Gemini-2.5-Flash	92	86	66	54	82	74	22	44	<u>40</u>	<u>32</u>	12	<u>32</u>
GPT-4.1-nano	58	42	6	12	30	16	2	6	6	0	0	0
GPT-4.1-mini	<u>96</u>	76	<u>62</u>	28	64	<u>76</u>	<u>26</u>	<u>40</u>	<u>40</u>	20	10	28
GPT-4.1	98	<u>82</u>	44	44	<u>84</u>	88	50	12	46	34	34	<u>32</u>

基于模拟器的评估。基于模拟器的评估对于针对物理状态变化的回合至关重要，因为结果必须客观且可靠地评估。在每个回合结束时，模拟器会自动验证所有相关设备和环境变量的最终状态，并将其与该回合定义的目标进行比较。在图3所示的QT4可行情节中，智能体完成所有动作后，模拟器将时间加速至19:00，此时洗衣周期结束。随后，将目标状态——洗衣机关闭且厨房灯开启——与模拟器的最终状态进行比较，以确定是否成功。这种直接的状态比较产生了清晰且完全自动化的成功标准，并能在相同条件下实现公平的模型间比较。

基于大语言模型评判的评估。我们采用基于大语言模型的评判器来处理那些成功不依赖于物理状态变化，而是依赖于智能体最终自然语言回答的回合。这为基于模拟器的评估提供了客观且有效的补充。在我们的流程中，评判器会收到回合目标和用户查询，以及任何必须验证的不可行条件的简要描述。我们还提供智能体的完整ReAct轨迹，以便评判器可以验证最终答案是否由连贯且充分的推理链所支持。例如，在图3所示的QT4不可行情景中，基于大语言模型的评判器评估了智能体对调度冲突的解释。评判器仅评分最终面向用户的答案，同时利用轨迹来确认一致性。对于每个案例，我们询问评判器三次，并采用一致的结果以确保可靠性 (Taubenfeld等, 2025)。详细的提示模板和评分标准见附录A.9。为了验证我们的基于大语言模型的评判器，我们确认它们的评估结果与人类评估达到了高度一致性 (科恩的 $\kappa = 0.826$)，而人类评估本身也显示出非常高的评分者间信度 (完整分析见附录A.6)。

5.2 实验


实验设置。我们定量比较了各模型在 § 4.1 定义的12种查询类型上的推理、规划和工具调用性能。评估涵盖11个模型，包括开源模型 (Llama、Qwen、Gemma) 和闭源模型 (Gemini、GPT)，可复现性细节见附录A.7。所有实验均采用ReAct框架 (Yao等人, 2023)，使模型能够在我们的智能家居模拟环境中逐步生成推理轨迹和动作。ReAct框架使用的具体智能体提示见附录A.8。

5.3 主要结果

表1报告了所有查询类型 (QT1-QT4) 在可行 (F) 和不可行 (IF) 条件下的性能。出现了一些一致的模式。

表2: 错误分类。详细描述和示例见附录A.10。

类别	错误类型	定义
可行	环境感知(EP)	未能正确感知环境变量。
	意图推断 (II)	误解用户潜在目标。
	设备控制 (DC)	操作错误的设备或命令。
	行动规划 (AP)	动作规划不完整或不正确。
	时间推理 (TR)	时间计算或序列对齐错误。
不可行	矛盾处理不当 (CM)	检测到矛盾但未能遵循指令。
	矛盾盲视 (CB)	未能检测到矛盾。
	LLM-Judge (LJ)	LLM-Judge 的分类错误。



Fig图4: GPT-4.1 在 QT2 和 QT4 上的错误类型分布。(a) 和 (b) 显示了可行场景的分布，而 (c) 和 (d) 展示了不可行场景的分布。

环境感知 (QT1)。QT1-F回合大部分已解决：大多数前沿模型超过85%。在QT1-IF中，我们观察到各模型的成功率下降，反映了在检测基于错误前提的请求（例如引用不存在的设备）时存在一致的挑战。

显式与隐式设备控制 (QT2 与 QT3)。在可行和不可行两种场景中，大多数模型处理显式命令 (QT3) 的能力远优于隐式请求 (QT2)。在可行场景中，领先模型在 QT3 上超过 84%，而 QT2 停留在 62-66%。在可行情况下，当用户发出显式命令 (QT3) 时，模型的表现始终优于隐式请求 (QT2)。然而，在不可行场景中，对比更加明显：模型在 QT3-IF 中能较成功地检测到不存在的设备，但当设备存在但因操作约束无法达成目标时，模型则困难得多。例如，空调已以最大风扇转速运行，无法进一步降低温度。这表明，针对这种约束驱动的不可行性进行推理，对当前模型构成了更大的挑战。

时间推理 (QT4)。QT4查询要求智能体处理调度、协调和时间一致性，在可行和不可行场景中均最具挑战性。GPT-4.1在QT4-1上达到50%，QT4-2为46%，QT4-3为34%，虽然优于同类模型，但远未达到稳健水平。在包含矛盾或不可能时间的不可行案例中，性能急剧下降：即使GPT-4.1和 Gemini-2.5-Flash也仅分别在QT4-1-IF上达到44%、QT4-2-IF上达到34%，而 Qwen3-235B-A22B在QT4-3-IF上以48%的显著性能脱颖而出。这些结果表明，矛盾检测和时间验证仍是未解决的挑战。

模型级别比较。闭源模型 (GPT-4.1、Gemini-2.5-Flash) 始终处于领先地位，但没有任何模型在可行和不可行任务中均表现稳定。中等规模开源模型 (如Qwen3-235B-A22B和 Gemini-2.5-Flash-Lite) 在某些查询类型上取得了显著成果——例如Qwen3-235B-A22B在 QT4-3-IF上达到48%——但其性能在不同查询类型间分布不均。较小模型 (Gemini-3-12B-it、GPT-4.1-nano) 整体能力有限，尤其是在时间密集型任务上。

6 分析

6.1 错误分析

我们定义了八种错误类型来分析智能体故障：五种针对可行场景 (EP、II、DC、AP、TR)，三种针对不可行场景 (CM、CB、LJ)。错误分类在表2中给出。我们的分析聚焦于表现最佳的模型 GPT-4.1。




图5：四个模型在QT3-F上的工具调用错误模式。左图显示了成功案例中错误数量相对于工具调用平均数量的情况。右图展示了通过首次尝试成功实现的任务比例与需要错误恢复的任务比例。

图4总结了GPT-4.1在可行与不可行场景中的错误类型分布。对于可行场景，图(a)和(b)展示了QT2和QT4中的错误分布。在QT2（间接请求）中，故障主要由设备控制（DC，71%）主导，模型发出启发式猜测而非使用正确的API。意图推断（II）错误（11%）也出现，反映出将模糊抱怨如“房间太热”映射到适当设备动作的困难。QT4（时间调度）则表现出更多样的混合：DC（40%）、时间推理（TR，25%）和动作规划（AP，19%）均贡献显著，此外还有较小的II错误（11%）。这些分布表明，多步时间推理需要同时协调多种技能，使其比直接执行任务困难得多。

对于不可行查询，图（c）和（d）突出了两种主要模式。在QT1-QT3中，GPT-4.1经常检测到矛盾，但未能遵循指定的协议，导致矛盾处理不当（CM）。例如，当要求使用不存在的热泵来升高厨房温度时，它反而作用于客厅的热泵。在QT4中，主要问题是矛盾盲视（CB）：模型未能识别时间不可行性（例如矛盾截止时间），并继续执行请求，仿佛请求是有效的。即使识别出矛盾，响应也经常处理不当（CM）。

6.2 工具反馈的作用

为了更好地理解智能体动态，我们研究了QT3，大多数模型在该场景中表现相对较强。图5显示，超过40%的成功QT3回合涉及在初始无效工具调用后的恢复。换句话说，智能体不需要事先完美了解Matter协议，而是从错误信息中主动学习。这种恢复能力解释了它们在显式设备控制查询上的鲁棒性。相比之下，QT4上的弱点部分源于其延迟反馈：智能体通常调用工具调度 workflow，该 workflow 仅返回调度确认（即成功/失败消息），而不验证可执行性。因此，模拟器提供很少的纠正信号，使智能体无法修改其计划。

7 结论

我们提出了SimuHome——一个与Matter对齐的模拟器和基准测试，能够在可重复的条件下评估智能家居大语言模型智能体在现实、动态变化环境中的表现。我们模拟了4个环境变量（即温度、照度、湿度、空气质量）以及17种设备类型，包含基于时间的效果和严格可重复性，能够近乎无缝地迁移到真正的Matter兼容设备上。我们提供了跨越12种查询类型的600个回合，包含可行与不可行变体，每个回合包含初始状态、可验证目标、自然语言查询以及用于过程感知的客观评分所需动作。我们通过模拟器中最终状态与目标比较对可行任务进行评分，并使用与人类评估高度一致的大语言模型评判器评估不可行逻辑检查。在ReAct设置下评估了11个智能体。当前的开源和闭源大语言模型在处理显式控制和简单检索方面表现良好，但在潜在意图推断、实时状态验证和时间调度方面常常失败；GPT-4.1在所有查询类型上的总体成功率达到54%。

参考文献

- 陈泽辉, 杜伟华, 张文伟, 刘奎坤, 刘江宁, 郑淼, 卓景明, 张松阳, 林达华, 陈凯, 赵峰。T-eval: 逐步评估大语言模型工具利用能力。载于第62届计算语言学协会年度会议论文集 (第一卷: 长论文), 第9510–9529页, 泰国曼谷, 2024年8月。计算语言学协会。doi: 10.18653/v1/2024.acl-long.515。URL <https://aclanthology.org/2024.acl-long.515/>。
- Jacob Cohen. 名义量表的一致性系数。教育与心理测量, 20(1):37–46, 1960年4月。doi: 10.1177/001316446002000104。URL <https://doi.org/10.1177/001316446002000104>。
- Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, 等。Gemini 2.5: 以高级推理、多模态、长上下文和下一代智能体能力推动前沿。arXiv预印本 arXiv:2507.06261, 2025年。
- Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Samuel Stevens, Boshi Wang, Huan Sun, and Yu Su. Mind2web: 面向网络的通用智能体。在 NeurIPS 2023数据集与基准测试赛道, 2023年。URL <https://openreview.net/forum?id=kiYqbO3wqw>。亮点。
- 黄悦, 史佳文, 李媛, 范晨锐, 吴思源, 张启辉, 刘益新, 周攀, 万瑶, Neil Zhenqiang Gong, 以及孙立超。大语言模型的Metatool基准: 决定是否使用工具及使用何种工具。载于第十二届国际学习表征会议 (ICLR) 论文集。OpenReview.net, 2024年。网址: <https://openreview.net/forum?id=R0c2qtagG>。
- Evan King, 于浩翔, Sangsu Lee, 以及Christine Julien。Sasha: 基于大语言模型智能家居创意目标导向推理。ACM交互、移动、可穿戴与泛在技术汇刊, 8(1), 2024年3月。doi: 10.1145/3643505。网址: <https://dl.acm.org/doi/10.1145/3643505>。
- Eric Kolve, Roozbeh Mottaghi, Winson Han, Eli VanderBilt, Luca Weihs, Alvaro Herrasti, Matt Deitke, Kiana Ehsani, Daniel Gordon, 朱玉科, Aniruddha Kembhavi, Abhinav Gupta 和 Ali Farhadi。AI2-THOR: 面向视觉人工智能的交互式三维环境。arXiv, 2017年。doi: 10.48550/arXiv.1712.05474。URL <https://arxiv.org/abs/1712.05474>。arXiv:1712.05474[cs.CV], version 4 (2022-08-26)。
- Silin Li, Yuhang Guo, Jiashu Yao, Zeming Liu 和 Haifeng Wang。HomeBench: 在智能家居中评估大语言模型, 涵盖单设备和多设备上的有效和无效指令。载于《计算语言学协会第63届年会论文集 (第一卷: 长论文)》, 第12230–12250页, 维也纳, 奥地利, 2025年7月。计算语言学协会。doi: 10.18653/v1/2025.acl-long.597。URL <https://aclanthology.org/2025.acl-long.597/>。
- Meta AI。介绍LLaMA 4: 推进多模态智能。技术报告, Meta AI, 2024年。URL <https://ai.meta.com/blog/llama-4-multimodal-intelligence/>。
- OpenAI。介绍GPT-4.1 in the api。技术报告, OpenAI, 2025a。URL <https://openai.com/index/gpt-4-1/>。
- OpenAI。Gpt-5 mini。技术报告, OpenAI, 2025b。URL <https://openai.com/gpt-5> /。
- OpenRouter。Openrouter, 2025年。URL <https://openrouter.ai/>。
- Shishir G. Patil, Huanzhi Mao, Fanjia Yan, Charlie Cheng-Jie Ji, Vishnu Suresh, Ion Stoica, 和 Joseph E. Gonzalez。伯克利函数调用排行榜 (BFCL): 从工具使用到大语言模型的智能体评估。收录于《第42届国际机器学习会议 (ICML) 论文集》, 第267卷, PMLR, 2025年。URL <https://icml.cc/virtual/2025/poster/46593>。海报。

Xavier Puig, Kevin Ra, Marko Boben, Jiaman Li, Tingwu Wang, Sanja Fidler, 和 Antonio Torralba. VirtualHome: 通过程序模拟家庭活动。收录于《IEEE/CVF计算机视觉与模式识别会议 (CVPR) 论文集》, 第8494–8502页。IEEE, 2018年6月。URL https://openaccess.thecvf.com/content_cvpr_2018/html/Puig_VirtualHome_Simulating_Household_CVPR_2018_paper.html。

Yujia Qin, Shihao Liang, Yining Ye, Kunlun Zhu, Lan Yan, Yaxi Lu, Yankai Lin, Xin Cong, Xiangru Tang, Bill Qian, Sihan Zhao, Lauren Hong, Runchu Tian, Ruobing Xie, Jie Zhou, Mark Gerstein, Dahai Li, Zhiyuan Liu, and Maosong Sun. Toolllm: 帮助大语言模型掌握 16000+ 真实世界API。载于第十二届国际学习表征会议 (ICLR) 论文集。OpenReview.net, 2024年。URL <https://openreview.net/forum?id=dHng2O0Jjr>。亮点论文。

Dmitriy Rivkin, Francois Hogan, Amal Feriani, Abhisek Konar, Adam Sigal, Steve Liu, and Greg Dudek. Sage: 具有基础执行能力的智能家居代理。arXiv, 2023年。doi: 10.48550/arXiv.2311.00772。URL <https://arxiv.org/abs/2311.00772>。

Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Eric Hambro, Luke Zettlemoyer, Nicola Cancedda 和 Thomas Scialom. Toolformer: 语言模型可以自己学习使用工具。《神经信息处理系统进展》第36期 (NeurIPS 2023), 2023年。URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/02120bee420311dce5a9bdb228f4118f-Abstract-Conference.html。口头报告。

Mohit Shridhar, Jesse Thomason, Daniel Gordon, Yonatan Bisk, Winson Han, Roozbeh Mottaghi, Luke Zettlemoyer, 和 Dieter Fox. Alfred: 日常任务基础指令解读基准。见《IEEE/CVF计算机视觉与模式识别会议论文集 (CVPR)》。IEEE, 2020年6月。URL https://openaccess.thecvf.com/content_CVPR_2020/html/Shridhar_ALFRED_A_Benchmark_for_Interpreting_Grounded_Instructions_for_Everyday_Tasks_CVPR_2020_paper.html。Amir Taubenfeld, Tom Sheffer, Eran Ofek, Amir Feder, Ariel Goldstein, Zorik Gekhtman, 和 Gal Yona. 置信度提升大语言模型中的自一致性。见 Wanxiang Che, Joyce Nabende, Ekaterina Shutova, 和 Mohammad Taher Pilehvar (编), 《计算语言学协会 ACL 2025 年会发现卷》, 第 20090–20111 页, 奥地利维也纳, 2025 年 7 月。计算语言学协会。ISBN 979-8-89176-256-5。doi: 10.18653/v1/2025.findings-acl.1030。URL <https://aclanthology.org/2025.findings-acl.1030/>。Gemma Team, Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, Ramona Merhej, Sarah Perrin, Tatiana Matejovicova, Alexandre Ramé, Morgane Rivière, 等。Gemma 3 技术报告。arXiv预印本 arXiv:2503.19786, 2025。Harsh Trivedi, Tushar Khot, Mareike Hartmann, Ruskun Manku, Vinty Dong, Edward Li, Shashank Gupta, Ashish Sabharwal, 和 Niranjana Balasubramanian. Appworld: 一个用于基准测试交互式编码代理的可控应用与人世界。见《第62届计算语言学协会年度会议论文集 (第一卷: 长文)》, 第16022–16076页, 泰国曼谷, 2024年8月。计算语言学协会。doi: 10.18653/v1/2024.acl-long.850。URL <https://aclanthology.org/2024.acl-long.850/>。Jian Xie, Kai Zhang, Jiangjie Chen, Tinghui Zhu, Renze Lou, Yuandong Tian, Yanghua Xiao, 和 Yu Su. Travelplanner: 语言代理现实世界规划基准。见《第41届国际机器学习大会 (ICML)》。PMLR, 2024。Spotlight. Qiantong Xu, Fenglu Hong, Bo Li, Changran Hu, Zhengyu Chen, 和 Jian Zhang. 开源大语言模型的工具操作能力。arXiv, 2023。doi: 10.48550/arXiv.2305.16504。URL <https://arxiv.org/abs/2305.16504>。An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, 等。Qwen3 技术报告。arXiv预印本 arXiv:2505.09388, 2025。

Shunyu Yao, Howard Chen, John Yang, 和 Karthik Narasimhan. Webshop: 迈向基于真实环境语言代理的可扩展真实世界网页交互. 见《神经信息处理系统进展 (NeurIPS)》, 2022.

Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: 在语言模型中协同推理与行动. 第十一届国际学习表征会议 (ICLR) 论文集. OpenReview.net, 2023年. URL https://openreview.net/forum?id=WE_vluYUL-X.

Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik Narasimhan. τ -bench: 真实世界领域中工具-代理-用户交互的基准, 2024年. URL <https://arxiv.org/abs/2406.12045>.

Shuyan Zhou, Frank F. Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, Uri Alon, and Graham Neubig. Webarena: 一个用于构建自主代理的逼真网页环境. 收录于第十二届国际学习表征会议 (ICLR) 论文集, 2024年. 海报.

A 附录

A.1 不可行查询类型

QT1 不可行。 这评估了基于错误前提识别请求的能力，例如询问关于不存在的设备或不支持的属性的信息。例如，对于请求“你能告诉我客厅里空气净化器的厂商ID吗？”，智能体必须检查客厅中的设备列表，确认没有空气净化器，并解释该请求的前提无效。

QT2 不可行。 这评估了识别以下情况的能力：即使用户意图被正确推断，目标也因环境限制或设备限制而无法实现。例如，针对“客厅感觉像桑拿房”，智能体必须验证客厅的冷却系统已在最大容量下运行，并给出支持理由，解释为何无法进一步降温。

QT3 不可行。 这评估了识别并拒绝控制不存在设备的命令的能力。例如，对于请求“打开客厅的加湿器”，智能体必须检查客厅的设备列表，确认没有加湿器。然后应解释该请求无法完成，并在不改变任何设备状态的情况下终止任务。

QT4-1 不可行。 这评估了识别并解释调度请求无效情况的能力，原因是用户指定的相对时间和绝对时间存在矛盾，或者用户对当前时间存在误解。例如，如果用户询问“现在下午6点对吧？五分钟后的下午6:05打开厨房灯”，但实际时间不是下午6点，智能体必须检查当前时间，检测相对表达式“五分钟之后”与绝对时间“下午6:05”之间的差异，并清楚地解释这一矛盾。

QT4-2 不可行。 这评估了识别并解释（并附上证据）用户错误假设设备完成时间或通过同时提供相对时间和绝对时间造成矛盾的请求的能力。例如，假设洗衣机设定在下午6:30完成，但用户请求，“我认为洗衣机在下午6点完成，所以在下午5:50启动除湿器，这比它完成早10分钟”。智能体必须检查洗衣机实际预计完成时间。然后需要指出用户的假设（下午6点）、相对表达（“早10分钟”）和绝对时间（“下午5:50”）都不一致。智能体不得登记调度，直到矛盾解决，并应要求用户重新确认正确的时间。

QT4-3 不可行。 这评估了识别并解释用户请求的截止时间在当前两台正在运行的设备的进度下无法实现的能力。例如，如果用户请求，“客人下午6点到达，所以确保洗衣机和洗碗机在下午5:30前完成”，智能体必须检查当前时间和每台设备完成所需的最短时间。基于此，它应通过清晰的推理解释为什么下午5:30完成是不可行的，并建议最早可能的完成时间或替代的顺序计划。

A.2 工具列表

表3：智能体工具列表

Name	描述	Args
完成	完成任务并返回最终的自然语言答案。	答案 (str, 必填): 最终回复文本。
执行命令	在设备上执行命令（例如，开启灯，设置级别，设置设定点）。	设备ID (str, 必填); 端点ID (int, 必填); 集群ID (字符串, 必需); 命令ID (字符串, 必需); 参数 (字典, 必需)。
写属性	直接设置设备属性值。	设备ID (字符串, 必需); 端点ID (整数, 必需); 集群ID (字符串, 必需); 属性ID (字符串, 必需); 值 (任意, 必需)。
获取所有属性	获取设备的所有属性。	设备ID (字符串, 必需)。
获取属性	获取设备的特定属性。	设备ID (str, req); 端点ID (int, req); 集群ID (str, req); 属性ID (str, req).
获取设备结构	获取设备结构（端点、集群、属性、和命令）。	设备ID (str, req).
获取房间	获取家庭中所有房间及其显示名称。	(无)
获取房间设备	获取房间中的所有设备。	房间ID (str, req).
获取房间状态	获取房间的环境状态（温度、湿度、照度、PM10）。	房间ID (str, req).
获取集群文档	在 Matter 集群文上执行语义搜索档化（覆盖集群、命和规范令和属性）。	查询 (str, req); top k (int, req).
调度工作流	在虚拟 ab- 上调度一个步骤的顺序工作流绝对时间。计划时间必须在未来相对于当前时间。	开始时间 (str, req; "YYYY-MM-DD HH:MM:SS"); 步骤 (list, req; 例如, {"tool": "...", "参数": {...}}).
获取当前时间	获取当前虚拟时间作为人类可读字符串“YYYY-MM-DD HH:MM:SS”	(无)
获取工作流列表	获取工作流程列表，支持可选过滤。	(无)

A.3 Matter集群列表

表4：已实现的Matter集群。

集群	属性	命令
基本信息	供应商名称, 供应商ID, 产品名称, 产品ID	None
描述符	设备类型列表, 服务器列表, 客户端列表, 部件列表, 标签列表	None
开关	全局场景控制, 开启时间, 关闭等待时间, 启动开关	关, 开启, 切换
级别控制	当前级别, 剩余时间, 最小级别, 最大级别, 当前频率, 最小频率, 最大频率, 开关过渡时间, 开启级别, 开启过渡时间, 关闭过渡时间, 默认移动速率, 选项, 启动电流级别	移动到级别, 移动, 步长, 停止, 移动到最近频率
风扇控制	风扇模式, 风扇模式序列, 百分比设置, 电流百分比	Step
媒体播放	当前状态	播放、暂停、停止、重新开始。上一个, Next, 快退, 快进
频道	频道列表、节目单、当前频道	切换频道, 按数字切换频道, 跳过频道
键盘输入	支持的按键	发送按键
识别	识别时间, 识别类型	识别, 触发效果
运行状态	阶段列表, 当前阶段, 倒计时时间, 操作状态列表, 运行状态, 操作错误	暂停、恢复、停止、开始, 操作命令响应
电源	集群修订版、特性映射、状态、顺序、描述, 端点列表、有线评估输入电压、电池电压, 电池剩余百分比、电池充电状态、活动电池故障	None
电源拓扑	集群修订版, 特性映射, 可用端点, 活动端点	None

集群	属性	命令
电力 测量	功率模式, 测量类型数量, 精度, 无功电流, 视在电流, 无功功率, 视在功率, RMS电压, RMS电流, RMS功率, 频率, 功率因数	开始测量, 停止测量, 重置测量, 获取测量快照
电能 测量	精度, 累计导入电能, 累计导出电能, 周期导入电能, 周期导出电能, 累计电能重置	开始电能测量, 停止电能测量, 重置累计电能, 获取电能快照
设备能量管理 ESA类型, ESA可生成, ESA状态, 绝对最小功率, 绝对最大功率, 功率调节能力, 预测, 选择退出状态		None
洗碗机模式	支持的模式, 当前模式	切换至模式, 获取支持的模式
洗碗机警报	掩码, 锁存, 状态, 支持的	重置, 修改已启用的警报, 获取警报状态·获取活动警报
冰箱和 温度控制 柜模式	支持的模式, 当前模式	切换至模式
RVC清洁模式	支持的模式, 当前模式	切换至模式
RVC运行状态	阶段列表, 当前阶段, 倒计时时间, 运行状态列表, 运行状态, 运行错误	暂停, 恢复, 归位
RVC运行模式	支持的模式, 当前模式	开始, 停止, 地图, 停止地图
温度控制	温度设定值, 最低温度, 最高温度, 步长, 选定的温度等级, 支持的温度等级	设定温度
温度测量	测量值, 最小测量值, 最大测量值	None
恒温器	本地温度, OccupiedCoolingSetpoint, OccupiedHeatingSetpoint, 操作控制顺序, 系统模式	设定点升降
窗户遮盖物	类型, 配置状态, 运行状态, 最终产品类型, 模式, 安全状态, 当前提升位置百分比百分之一, 目标位置升降百分比百分之一, 升降执行次数, 等。	上升或打开, 下降或关闭, 停止动作, 跳转到升降百分比
干衣机控制	支持的干燥等级, 选定的干燥等级	None
干衣机模式	支持的模式, 当前模式	切换至模式
洗衣机控制	转速, 当前转速, 漂洗次数, 支持的漂洗	None
洗衣机模式	支持的模式	切换至模式
相对湿度 测量	测量值, 最小测量值, 最大测量值, 容差	None

A.4 设备类型列表

表5: 已实现的设备类型列表及其对应的簇。

设备类型	集群
空调	基本信息, 风扇控制, 开关, 恒温器
空气净化器	基本信息, 描述符, 风扇控制, 识别, 开关
除湿器	基本信息, 风扇控制, 开关, 相对湿度测量
可调光灯	基本信息, 级别控制, 开关
洗碗机	基本信息, 开关, 运行状态
电气传感器	基本信息, 电能测量, 电力测量, 电源拓扑
Fan	基本信息, 风扇控制, 开关
冰柜	基本信息, 描述符, 冰箱和温控柜模式, 温度控制, 温度测量
热泵	基本信息, 描述符, 设备能源管理, 电能测量, 电力测量, 电源, 电源拓扑, 恒温器
加湿器	基本信息, 风扇控制, 开关, 相对湿度测量
干衣机	基本信息, 干衣机控制, 干衣机模式, 开关, 运行状态
洗衣机	基本信息, 洗衣机控制, 洗衣机模式, 开关, 运行状态, 温度控制
开关灯	基本信息, 开关
冰箱	基本信息, 描述符, 冰箱和温控柜模式, 温度控制, 温度测量
RVC	基本信息, RVCCleanMode, RVCOperational状态, RVCRunMode
TV	基本信息, 频道, 键盘输入, 级别控制, 媒体播放, 开关
窗帘控制器	基本信息, 窗帘

A.5 目标示例

表6：各查询类型的示例目标

查询类型	查询	所需动作	Goal
QT1 Feasible	杂物间有多亮 照明现在？我正在整理一些箱子，想知道是否有足够的光线。另外，客厅湿度怎么样？我正在想着那里的植物和想知道他们是否舒适。	获取房间状态(杂物间) 获取房间状态(客厅) -	杂物间的照度是1000勒克斯。客厅湿度是50%。
QT1 不可行	我正准备淋浴，想知道风扇模式有哪些可供浴室中的风扇1使用？	获取房间设备(浴室)	浴室风扇1未找到；模式不可用。
QT2 Feasible	呃，厨房感觉很干燥，我的手很紧，我把面包在那里发酵，所以我已经有点担心这件事。客厅感觉有灰尘，我的眼睛发痒，而且我的喉咙有点刺痛，像是空气中有什么粗砂粒。	获取房间设备（厨房） 获取房间设备（客厅） -	增加厨房湿度；降低客厅PM10。
QT2 不可行	唉，办公室太冷了，我一想到等会儿要去那里工作，手就冻得发麻	获取房间设备（办公室）	办公室热泵1缺失；无法提高温度。
QT3可行性	在客厅设置较柔和的灯光用于晚间阅读，打开客厅房间调光灯1 开启并设置它到级别50。为书房稍微降温以工作舒适，打开书房房间空调1 开启，将其切换为制冷模式并将风扇设置为50%。	获取房间设备（客厅） - 获取房间设备（书房） -	客厅可调光灯1开启于级别50；书房空调1开启，制冷模式，风扇50%。
QT3 不可行	今天早上有点闷，请开启卧室空气净化器1 并将风扇设置为百分之八十。	获取房间设备（卧室）	不可行：卧室空气净化器1 缺失；无法将风扇设置为80%。
QT4-1	当我在这里整理衣物并试图清除潮湿空气，让浴室变得舒适这样当我走到那里时感觉清新过去。开启浴室中的风扇1 浴室，从此刻起9分钟后在30%，并将其提升到40 % 在之前的动作之后7分钟动作。开启调光灯1在浴室，从此刻起28分钟后在级别10，并将其提升到级别40 在先前的动作之后17分钟。	获取房间设备（浴室）	在9分钟时：浴室风扇1开启，30%。在16分钟时：浴室风扇1开启，40%。在28分钟时：浴室可调光灯1开启，级别10。在45分钟时：浴室可调光灯1 开启，级别40。
QT4-1 时间冲突	你能从厨房日程调光灯1 在客厅开启并设置为百分之八十在八分钟后，具体将是上午11:25，我需要像这样来预热房间，迎接客人以及电影的开始	None	在8分钟时：客厅可调光灯1开启，级别80。
QT4-2	我正在叠衣服并准备东西准备好。20分钟之后杂物间的洗衣机1完成，开启空气净化器1在客厅并将风扇设置为40%并切换热泵1在杂物间为加热模式	获取房间设备(客厅) - 获取房间设备(杂物间)-	在79分钟：客厅空气净化器1开启，风扇40%；杂物间热泵1处于加热模式。
QT4-2 时间冲突	洗衣离开杂物间潮湿且凉爽，所以我希望空气被净化，空间变暖在它稳定后立即进行。正好20分钟之后，当杂物间的洗衣机1完成，并且在下午12:36，打开客厅的空气净化器1 将房间调至轻柔风速，并开启杂物间的热泵1，设置为供暖模式。	None	在79分钟时：客厅空气净化器1开启，风扇40%；杂物间热泵1处于加热模式。
QT4-3	等待厨房蒸汽消散，以免衣物变得发霉。当洗碗机1在厨房完成等待11分钟。然后开始烘干机1在杂物间房间。将其设置为运行和干燥程度等级1。	获取房间设备(杂物间) -	在第99分钟：杂物间烘干机1 停止。在第100分钟：杂物房间烘干机1正在运行，带有干燥级别1。

查询类型	查询	所需动作	Goal
QT4-3 时间冲突	在浴室开始烘干机1于下午12点36分。暂停烘干机1在浴室立即, 当杂物间中的烘干机1完成以避免跳闸断路器并保持洗衣批次按顺序。	None	在43分钟时: 浴室干手器1以干燥等级1运行; 在44分钟时: 浴室干手器1暂停。

A.6 大语言模型评判器验证

为验证基于LLM的评判，我们将其评估结果与人类标签在随机抽取的70个回合子集（涵盖所有评判器评分的任务）中进行了对比。人类标注者表现出非常高的评分者间信度（科恩's $\kappa = 0.913$ ）。LLM-Judge与共识人类标签达到了较高的一致性（科恩's $\kappa = 0.826$ ）。这些结果支持在我们的基准中使用LLM-Judge作为人类评估的可靠替代方案。

在手动审查LLM-Judge评估为错误的155个案例后，我们发现仅有5个属于误分类，这进一步印证了评估的可靠性。详细的错误分布可参见表A.11。

A.7 实验设置

我们评估了11个近期发布的闭源与开源模型：Llama-4-Scout (Meta AI, 2024年)、Llama-4-Maverick (Meta AI, 2024年)、Qwen3-32B (Yang 等人, 2025年)、Qwen3-235B-A22B (Yang 等人, 2025年)、Gemma-3-12B-it (Team 等人, 2025年)、Gemma-3-27B-it (Team 等人, 2025年)、Gemini-2.5-Flash (Comanici 等人, 2025年)、Gemini-2.5-Flash-Lite (Comanici 等人, 2025年)、GPT-4.1、GPT-4.1-mini (OpenAI, 2025a) 以及 GPT-4.1-nano (OpenAI, 2025a)。所有模型均通过 OpenRouter API (OpenRouter, 2025) 访问，以确保标准化的访问方式和可比性。

A.8 REACT提示

ReAct提示

你是一个使用工具控制设备、基于Matter协议提供信息的智能家居助手，目标是满足基于Matter协议的信息，以实现用户的目标。
查询。
你在ReAct框架下运行，采用结构化JSON响应。

[ReAct框架]
- 循环: (‘思考’ -> ‘动作’ -> ‘动作_输入’) -> ‘观测’ -> 重复直到完成。
- 每个响应必须恰好包含一个步长，包含推理、工具名称和JSON-格式化的参数。
- ‘动作_输入’ 必须始终以JSON格式字符串提供。
- 在生成下一个步长之前，彻底分析每个 ‘观测’ 。
- 当查询完全满足时，以 ‘完成’ 工具结束: {"动作": "完成", "动作_输入": "\答案\":"你的最终答案\"}"

[关键要求] -
- 仅使用可用工具列表中的精确工具名称。
- 切勿捏造、假设或猜测信息。始终通过工具进行验证。
- 仔细分析用户查询意图: 区分信息请求和设备控制操作。
- 如果房间或设备不存在，请在最终答案中明确说明。
- 始终在回复中包含正确的设备ID、房间ID和房间状态。
- 如果用户的请求包含相对时间和绝对时间之间的矛盾，或者如果时间不一致性导致情况模糊不清，停止执行并清晰地地向用户告知冲突。
- 在向用户解释结果时，使用简单、日常的对话语言而不是技术术语。

[设备] -
支持的设备类型: 开启_关_灯(灯), 可调光_灯(调光灯), 空气_调节器, 空气_净化器, 电视, 热_泵, 加湿器, 除湿器, 窗口_遮盖物_控制器(百叶窗), 洗碗机, 衣物_洗衣机(洗衣机), 衣物_干衣机(干衣机), 风扇, RVC, 冰柜, 冰箱
- 不要混淆 “灯” 和 “调光灯” 。

[Matter协议] -
层级: 设备 -> 端点 -> 集群 -> 属性/命令 - 使用来自API响应的精确ID (设备_id、端点_id、集群_id、属性_id、命令_id) 。 - 当不确定设备能力或集群操作时: • 使用get_device_structure探索设备端点和集群。• 使用get_cluster_doc理解集群属性、命令及依赖关系。• 通过这些发现工具动态学习Matter协议。 - F

or devices with 歌剧 tional state cluster:

- 使用get_device_structure探索模式特性并估算操作持续时间。
- 使用倒计时时间属性预测设备运行时的操作结束时间。

[数据处理与单位] -

房间状态以 $\frac{1}{100}$ ts (比例转换):

温度: 百分之一摄氏度 (1850 = 18.50°C) • 湿度: 百分之一百分比 (7250 = 72.50%)

- 照度: 直接勒克斯 (1000 = 1000 勒克斯)
- PM10 (空气质量): 直接 $\mu\text{克}/\text{立方米}^3$ (125 = 125 $\mu\text{克}/\text{立方米}^3$)

[工作流调度] -

警告: 成功响应表示调度成功, 但并不保证所有步骤都能成功执行。- 确保执行命令和写入属性参数在工作流步骤中完全准确。- 调度前必须准备: • 验证设备能力和集群 (参见 [MATTER PROTOCOL] 部分) 。• 仅使用完全验证的参数进行调度。

[验证与准确性] -

用户可能混淆控制不准确的设备, 或发出包含逻辑或时间不一致性的请求。

- 在行动前务必核实用户的陈述:
 - 使用get_rooms来确认房间存在并获取正确的房间ID。• 使用get_current_time来确认时间信息。• 使用get_room_states来验证房间状态。
 - 使用get_room_devices来验证设备存在并获取准确的设备ID
- 最终答案严格基于工具观测, 而非用户的宣称。- 如果操作失败或资源缺失, 请清楚解释原因。- 未经确认, 切勿声称操作成功。

[可用工具]<工具列表>

A.9 LLM JUDGEPROMPT

本节展示了用于评估智能家居大语言模型智能体的大语言模型评判器提示的示例。每个查询类型 (QT) 都有专门的评估提示具有特定标准。a

A.9.1 QT1 Feasible JUDGEPROMPT

QT1 可行性判断提示 (标准)

系统

你是一个严格的智能家居大语言模型智能体评估者, 负责评估对用户查询的响应。仅返回一个字符: 'A' (通过) 或 'B' (失败)。不要包含其他文本。

评估目标: -

用户可能会询问设备属性的值 - 用户可能会询问房间状态的值 - 智能体使用工具检索信息并提供最终答案 - 你必须评估智能体的最终答案是否准确且合理基于上下文

Matter协议上下文: -

设备属性遵循格式: '端点.集群.属性' - 示例: '1.OnOff.OnOff' 表示端点1, OnOff集群, OnOff属性 - 端点: 设备内的功能单元 (例如, 主控制的端点1) - 集群: 相关属性和命令的组 (例如, 电源控制的OnOff集群) - 属性: 特定属性或值 (例如, 当前电源状态的OnOff属性)

- 智能体必须从工具中检索准确的属性值

房间状态单位: -

温度: 乘以100 (例如, 2300 = 23.0°C, 2550 = 25.5°C) - 湿度: 乘以100 (例如, 5500 = 55.0%, 4200 = 42.0%) - 照度: 直接勒克斯值 (例如, 250 = 250勒克斯) - PM10: 直接 $\mu\text{g}/\text{m}^3$ 值 (例如, 15 = 15 $\mu\text{g}/\text{m}^3$) 以上所有房间状态值在原始形式和转换形式下均有效。

通过(A) 仅当智能体最终答案满足所有条件: 1) 目标达成: 智能体处理评估中指定的所有目标 2) 房间状态准确性: 对于房间状态目标, 值与工具观测一致

3) 房间名称准确性：智能体对设备属性和房间状态均提及正确房间名称

否则，输出'B'。

用户

用户查询：<用户查询>
>

- 目标（应评估的内容）：<目标>

- 智能体的ReAct步骤（工具调用和观察结果）：
<ReAct步骤>

- 智能体最终答案：
<最终答案>

评估步骤：

1. 对于每个目标，检查智能体是否调用了正确的动作（获取_房间_设备用于设备_属性，获取_房间_状态用于房间_状态）2. 对于设备_属性目标：检查智能体是否调用了获取_设备_结构并使用了正确的设备_id，并提取了正确的属性值3. 对于房间_状态目标：检查智能体是否从获取_房间_状态的观测中提取了正确的房间状态值4. 验证智能体最终答案是否正确地反映了实际的观测值（考虑单位转换规则）5. 确保智能体在最终答案中正确提及房间名称（对于设备和房间状态）

您的决策：A或B

A.9.2 QT1 INFEASIBLEJUDGE PROMPT

QT1 不可行判断提示

系统

你是一个严格的评估者，负责评估响应用户查询的智能家居大语言模型代理。请仅返回一个字符：'A'（通过）或'B'（失败）。不要包含任何其他文本。

评估目标：-

用户可能会询问设备属性的问题，但目标设备在指定房间中不存在 - 用户可能会询问房间状态，应准确回答 - 智能体应识别设备缺失并适当告知用户 - 你必须评估智能体是否妥善处理了缺失设备，并准确回答了房间状态问题

房间状态单位：-

温度：按100倍缩放（例如，2300 = 23.0°C，2550 = 25.5°C）
湿度：按100倍缩放（例如，5500 = 55.0%，4200 = 42.0%）
- 照度：直接勒克斯值（e.g., 250 = 250 勒克斯）
- PM10：直接 $\mu\text{g}/\text{m}^3$ 值（e.g., 15 = 15 $\mu\text{g}/\text{m}^3$ ）
上述所有房间状态值在原始形式和转换形式下均为有效。

仅当智能体最终答案符合所有条件时，才返回'A'。当智能体最终答案不符合所有条件时，返回'B'。
1) 目标达成：智能体解决了评估中指定的所有目标 2) 房间状态准确性：对于房间_状态目标，值与工具观测结果匹配 3) 房间名称准确性：智能体提及设备属性和房间状态时使用正确的房间名称 4) 设备不存在识别：对于设备_属性目标，智能体明确说明该设备不存在 5) 无捏造设备数据：智能体不得为不存在的设备提供虚构的属性值

否则，输出'B'。

用户

用户查询：<用户查询>
>

- 目标（应评估的内容）：
<目标>

- 智能体的ReAct步骤（工具调用和观察结果）：
<ReAct步骤>

<ReAct步骤>

- 智能体最终答案: <最终答案>

评估步骤: 1.

- 对于设备^{ice}属性目标: 检查智能体是否调用了获取房间设备并发现目标设备在房间中不存在
2. 对于设备属性目标: 验证智能体的最终答案明确声明该设备不存在 (不仅仅是缺少数据)
3. 对于房间状态目标: 检查智能体是否调用了 get_房间状态并提取了正确的观察结果中的值
4. 对于房间状态目标: 验证最终答案反映了实际的观察结果值 (考虑单位转换规则)
5. 确保智能体在最终答案中提及两个设备的正确房间名称和房间状态
6. 确保智能体不虚构或编造不存在设备的属性值

你的决策: A 或 B

A.9.3 QT2 INFEASIBLEJUDGE PROMPT

QT2 不可行判断提示

系统

你是一个严格评估智能家居大语言模型智能体对房间状态变更响应的评估者

请求。

仅返回一个字符: 'A' (通过) 或 'B' (失败)。无其他文本。

评估目标 - 不可行情况:

- 用户要求更改房间状态 (温度、湿度、光照度、PM10) 在特定方向上
- 在不可行情况下, 存在可控设备, 但请求的更改在上下文中不可能
- 常见原因包括:
 - * 照度降低: 所有灯已关, 或所有可调光灯处于其最低水平 (级别 = 1, 基于1-254刻度), 因此照度无法降低进一步。
 - * 温度降低: 在目标房间内, 所有空调机组均已开启, 风扇 = 100 百分比和CoolingSetpoint < 当前室温。而且加热器没有主动供暖 (系统模式不是4或加热设定点 < 当前室温温度)。因为空调已经处于满负荷, 进一步降低是不可能。
 - * 温度升高: 空调处于关状态, 或风扇 = 0, 或CoolingSetpoint ≥ 当前室温温度。而且热泵处于加热模式 (系统模式 = 4) 和加热设定点 > 当前室温。
 - * 湿度控制: 加湿器/除湿器以最大容量在相反方向
- 智能体应识别此上下文不可行性并解释具体的限制
- 您必须评估智能体是否正确识别并解释了不可行性

通过(A) 仅当智能体最终答案满足所有条件:

- 1) 目标达成: 智能体解决评估中指定的所有目标
 - 2) 不可行性识别: 智能体明确声明无法满足请求由于上下文限制
 - 3) 具体原因: 智能体提供关于请求为何的具体解释
 - 4) 房间名称准确性: 智能体提及正确房间名称
 - 5) 无虚假声明: 智能体未声称进行过更改或提供虚假信息
 - 6) 工具一致性: 所有事实陈述与工具观测结果匹配
- 否则, 输出 'B'。

用户

用户查询:<用户查询>

- 目标 (应该评估什么):<目标>

- 智能体的ReAct步骤 (工具调用和观测结果): <ReAct步骤>

- 智能体最终答案: <最终答案>评估步骤 - 不可行情况: 1. 检查智能体是否探索了房间并识别出可控设备 2. 验证智能体是否发现了导致请求不可行的上下文限制: - 对于照度降低: 确认所有灯已关闭或所有可调光灯处于最低水平 (1/254) - 对于温度降低: 确认所有空调: OnOff.OnOff=为真, FanControl.CurrentPercent=100, OccupiedCoolingSetpoint < 当前_房间_温度, 且加热器未激活 (SystemMode不是4或 OccupiedHeatingSetpoint <当前_房间_温度) - 对于温度升高: 确认空调关闭或FanControl.CurrentPercent =0 或CoolingSetpoint ≥ 当前_房间_温度, 且热泵供暖 (SystemMode=4) 且OccupiedHeatingSetpoint >当前_房间_温度 - 对于湿度: 发现设备已处于相反方向的最大容量 3. 确保智能体的最终答案明确说明无法满足请求 4. 确认智能体提供了不可行的具体原因 (而非通用解释) 5. 验证智能体在最终答案中提到了正确的房间名称 6. 确认智能体没有虚构成功操作或虚假设备控制 7. 验证任何事实陈述与工具观测结果一致 您的决策: A 或 B

A.9.4 QT2 INFEASIBLE-NONEXISTENCEJUDGE PROMPT

QT2 不可行判断提示

系统_Y

你是一个严格的评估者, 用于评估响应房间状态变更的智能家居大语言模型代理请求。
返回恰好一个字符: ' A' (通过) 或 ' B' (失败)。无其他文本。

评估目标 - 不存在情况:

- 用户要求更改房间状态 (温度、湿度、照度、PM10) 在具体指示
- 在不存在案例中, 目标房间内没有可控设备/执行器可以做出请求的更改
- 房间可能有设备, 但没有任何设备能控制特定请求状态
- 智能体应识别此限制并适当告知用户
- 您必须评估智能体是否妥善处理了不可能请求

通过(A) 仅当智能体最终答案满足所有条件: 1) 目标达成: 智能体解决了评估中指定的所有目标 2) 不可行性识别: 智能体明确声明由于上下文限制无法完成请求 3) 设备分析: 智能体展示了对现有设备与所需设备的理解 4) 房间名称准确性: 智能体提到了正确的房间名称 5) 无虚假声明: 智能体未声称已进行更改或提供虚假确认 6) 工具一致性: 任何事实陈述均与工具观测结果相符 否则, 输出'B'。

用户₋

用户查询:<用户查询>

- 目标 (应评估的内容): <目标>

- 智能体的ReAct步骤 (工具调用和观察结果):
<ReAct步骤>

- 智能体最终答案:<最终答案>

评估步骤 - 不存在案例: 1. 检查智能体是否探索了房间, 并发现没有可控设备可用于请求的房间状态变更。2. 验证智能体最终答案明确声明无法满足请求。3. 确保智能体展示了对现有设备与所需能力的理解。4. 验证智能体在最终答案中提及正确的房间名称。5. 确认智能体未虚构成功操作或虚假设备控制。6. 验证所有事实陈述与工具观测一致。

您的决策: A 或 B

A.9.5 QT3不可行判断提示

QT3不可行判断提示

系统

你是一位严格的评估者，负责评估响应设备操作请求的智能家居代理。仅返回一个字符：‘A’（通过）或‘B’（失败）。不得有其他文本。

评估目标: -

用户请求在指定房间内操作设备或读取属性 - 在异常情况下，目标设备不存在于指定房间 - 智能体应识别设备缺失并适当地告知用户 - 您必须评估智能体是否妥善处理了设备缺失情况

只有当智能体的最终答案满足所有条件时才给予通过(A): 1) 目标达成: 智能体响应了评估中指定的所有目标 2) 设备不存在识别: 智能体明确声明指定设备不存在于目标房间中 3) 房间名称准确性: 智能体提到了正确的房间名称 4) 无虚假操作: 智能体未声称操作了该设备或读取其属性 5) 无捏造设备数据: 智能体未提供捏造的设备信息或属性值 否则，输出'B'。

用户-

用户查询:
<用户查询>

- 目标（应评估的内容）:
<目标>

- 智能体的ReAct步骤（工具调用和观察结果）:
<ReAct步骤>

- 智能体最终答案: <最终答案>

评估步骤:

1. 对于每个目标，检查智能体是否探索了房间并发现目标设备不存在 2. 验证智能体最终答案明确说明设备在指定房间中不可用 3. 确保智能体在最终答案中提到了正确的房间名称 4. 确认智能体没有声称操作了设备或访问了其属性 5. 验证智能体没有捏造设备信息或属性值

您的决策: A 或 B

A.9.6 QT4-1 JUDGE PROMPT

QT4-1 评判提示

系统 您是一个严格的评估者，负责评估处理设备调度场景中时间冲突的智能家居代理。仅返回一个字符: 'A' (通过) 或 'B' (失败)。不要有其他文本。严格规则: 所有时间比较必须允许最多 ± 1 分钟的容差。此窗口内的任何差异均应视为相等。通过(A)需满足以下所有条件: 1) 冲突识别: 代理明确识别到由于时间不匹配而导致请求无法实现。2) 解决策略: 代理要么(a)明确拒绝执行给定的请求，要么(b)停止执行并向用户请求澄清。失败(B)仅在代理出现以下情况时:

- 忽略时间冲突并继续执行，或 - 在其最终回复中声称任务已成功完成，尽管实际上不可能。

用户-

原始查询:
<原始查询>

- 冲突上下文:
<冲突上下文>

- 智能体推理过程:
<ReAct推理摘要>

- 智能体最终答案:
<最终答案>

您的决策: A 或 B

A.9.7 QT4-2 JUDGE PROMPT

QT4-2 判断提示

系统

你是一位严格的评估者，负责评估智能家居代理处理时间冲突在智能设备协调场景。
返回恰好一个字符: 'A' (通过) 或 'B' (失败)。无其他文本。

严格规则: 所有时间比较必须允许最多 ± 1 分钟的容差。任何差异在此窗口内应被视为相等。

通过(A) 如果满足所有以下条件:

- 1) 完成识别: 智能体必须通过引用参考设备中的正确识别实际完成时间倒计时时间属性，从而在运行状态族。
- 2) 冲突识别: 智能体识别出计算出的相对时间与指定的绝对时钟时间发生冲突。
- 3) 解决策略: 智能体要么 (a) 拒绝按原样执行，因为两者时序约束无法同时满足，要么 (b) 停止并请求用户选择一种时序选项来澄清; 无论哪种情况，它不继续执行。

失败 (B) 仅当智能体:

- 忽略时序冲突并继续执行，或
- 在最终回复中声称已成功完成任务，尽管执行不可能
- 在最终回复之前的ReAct步骤中未获取倒计时时间。

用户-

原始查询:<原始查询>- 冲突上下文:<冲突上下文>- 智能体推理过程:<ReAct推理摘要>- 智能体最终答案:<最终答案>你的决策: A 或 B

A.9.8 QT4-3 评判提示

QT4-3 评判提示

系统

你是一位严格的评估者，负责评估处理家电协调场景中时间冲突的智能家居代理。只返回一个字符: 'A' (通过) 或 'B' (失败)。不得有其他文本。

严格规则：所有时间比较必须允许最多 ± 1 分钟的容差。任何差异在此窗口内应被视为相等。

通过(A) 如果满足以下所有条件：

完成识别：智能体必须正确识别实际完成时间的 $\langle \text{锚点_id} \rangle$ ，通过引用倒计时时间属性或操作状态运行状态簇中的属性。

冲突识别：智能体明确识别出该请求是不可能的
因为锚点已经在 $\langle \text{锚点_结束_时间} \rangle$ ，所以 $\langle \text{目标_ID} \rangle$ 无法在锚点的完成时间开始然后暂停。

解决策略：智能体要么(a)说明 $\langle \text{目标_ID} \rangle$ 无法开始并然后在 $\langle \text{冲突_时间} \rangle$ 暂停，或者(b)解释由于 $\langle \text{锚点_ID} \rangle$ 将在 $\langle \text{targets_ids} \rangle$ 开始之前完成，无需暂停 $\langle \text{targets_ids} \rangle$ 。

仅当智能体出现以下情况之一时，判定为失败 (B)：

完全忽略时间冲突，或

在最终回复中声明它成功完成了任务，尽管执行是不可能的，或

在ReAct步骤期间未检查 $\langle \text{锚点_id} \rangle$ 的运行状态属性在最终回复之前。

User

- 原始查询：
 $\langle \text{原始查询} \rangle$

- 冲突上下文：
 $\langle \text{冲突上下文} \rangle$

- 智能体推理过程：
 $\langle \text{ReAct推理摘要} \rangle$

- 智能体最终答案：
 $\langle \text{最终答案} \rangle$

你的决策：A 或 B

A.10 错误分类细节

表 7: 可行场景中的错误类型

错误类型	定义	示例
环境感知错误 (EP)	未能正确感知或检索一个环境的值变量。	查询错误的传感器, 错误识别设备状态, 猜测而非感知。
意图推断错误 (II)	误解用户潜在目标。	未执行实际命令 即使用户意图明确。
设备控制错误 (DC)	执行错误的设备、错误的命令或缺少控制步骤。	设置错误频道、调整风扇 不先开启就调节转速。
动作规划错误 (AP)	控制工作流的不正确或不完整构建。	仅破坏逻辑依赖关系 执行多目标查询的一部分 不加考虑。
时序推理错误 (TR)	相对/绝对时间计算错误或序列对齐。	调度“在10分钟内”在 错误时间, 计算失误 洗碗机完成时间。

表8: 不可行场景中的错误类型

错误类型	定义	示例
矛盾处理不当错误(CM)	智能体检测到矛盾, 但没有遵循正确的指令遵循规则。	例如, 不是告知用户 请求的动作是不可能的, 它随意操作其他 设备, 或忽略指令。
矛盾盲视错误(CB)	智能体完全未能识别矛盾并执行请求, 仿佛其有效。	例如, 调暗一个开关灯, 调度冲突的时序 动作而未注意到 不一致。
LLM评判错误 (LJ)	错误并非由智能体引起, 而是由评估系统引起对行为进行错误分类或忽略。	例如, 将一次有信息价值的 拒绝视为失败, 或者错误地 将幻觉控制接受为 有效。

A.11 错误类型分布

错误类型	QT2	QT3	QT4-1	QT4-2	QT4-3
环境感知(EP)	3	0	4	1	0
意图推断 (II)	3	1	0	4	5
设备控制 (DC)	20	7	13	13	8
行动规划 (AP)	2	0	6	3	7
时间推理 (TR)	0	0	2	6	13
总计	28	8	25	27	33

表9: GPT-4.1在可行场景中的错误类型分布。

错误类型	QT1	QT2	QT3	QT4-1	QT4-2	QT4-3
矛盾处理不当 (CM)	8	24	6	5	6	1
矛盾盲视 (CB)	0	5	0	40	25	30
LLM-Judge (LJ)	1	0	0	0	1	2
总计	9	29	6	45	32	33

表10: GPT-4.1在不可行场景中的错误类型分布。

A.12 聚合器方程

$$S_{r,t+1} = S_{r,t} + \sum_{d \in D_{S,r}} \Delta S_{d,r}(t), \quad (1)$$

其中 $D_{S,r}$ 表示在房间 r 中被定义为影响状态 S 的设备集合, 而 $\Delta S_{d,r}(t)$ 表示设备 d 在时间步 t 对房间 r 中 S 的贡献。

A.13 QT3错误类型分布




图6：四种模型的成功QT3可行案例中工具执行错误类型的分布。

A.14 大语言模型使用

我们声明，大语言模型（OpenAI GPT-5）被用作通用辅助工具进行语言编辑，包括润色措辞、提升清晰度以及保持一致性。大语言模型未参与研究设计、实施、实验或分析。本文中的所有科学贡献和论断均由作者全权负责。