

基于多视图表示学习的触发-动作编程规则用户意图预测

吴刚, 胡亮, 胡宇潇, 邢永恒, 王峰*

吉林大学计算机科学与技术学院及网络技术与应用软件工程研究中心, 教育部, 长春 130012, 中国

文章信息

关键词: 物联网 触发-动作编程 用
户意图预测 多视图表示学习

摘要

触发-动作编程 (TAP) 允许用户为自动化智能设备和互联网服务创建规则, 例如“如果有人离开, 则关闭空调”。用户意图作为规则创建的内在驱动力, 在理解用户需求方面起着至关重要的作用。虽然现有研究可以轻松识别用户的显性需求, 例如关闭空调, 但往往无法识别隐性意图, 例如节能。预测用户意图面临若干挑战, 包括: (1) 触发器与动作之间的上下文依赖性, 导致用户组合不同功能时产生不同的意图; (2) 在简短的功能描述文本中识别用户意图; (3) 功能相似的实体由于缺乏领域特定知识而无法反映用户意图。为应对这些挑战, 我们提出了一个基于多视图表示学习的框架MvTAP, 该框架联合了 (1) 用户视图、(2) 开发者视图和 (3) 知识视图。在MvTAP中, 我们首先设计不同的方法来分别学习这三个视图的表示。然后, 我们提出了一种基于Transformer的方法来融合这些视图的表示。用户意图预测被表述为一个多标签分类任务。MvTAP的有效性通过一个真实的IFTTT数据集得到了验证。实验结果表明, 所提出的框架能够有效预测TAP规则中的用户意图。

1. 引言

在当今快速扩张的物联网 (IoT) 格局中, 互联传感器、执行器和智能设备的数量显著增加。预计到2030年, 物联网生态系统将涵盖约290亿台连接设备。¹随着连接设备的爆炸式增长, 管理和协调这些设备以执行自动化任务的需求变得日益紧迫。为满足这一需求, 触发-动作编程 (TAP) 已成为一种关键的物联网范式。TAP使用户能够在各种实体 (即互联网服务和智能设备) 之间定制自动化。用户可以通过从这些实体提供的功能集中选择一个触发器和动作, 以“如果触发器, 则动作”的形式创建TAP规则。这种范式不仅促进了重复性任务的自动化, 还确保实体能响应用户指定的触发器, 从而提升用户体验并促进智能环境的创建 (Desolda, Ardito, & Matera, 2017)。随着触发器和动作数量的不断增长, 出现了大量

可能的组合, 使得手动创建规则对用户而言既繁琐又低效。

已有许多方法 (Corno, De Russis, & Monge Roffarello, 2019, 2020, 2021年; 刘等人, 2021年; 姚、李、高、Sadler、孙, 2019年; Yusuf、江、Lo, 2022年; 张等人, 2020年) 被提出来以提高规则创建的效率。这些方法从三个研究视角进行分类: (1) 规则语义解析 (Yao等人, 2019年; Yusuf等人, 2022年) 利用自然语言处理技术, 将用户的自然语言描述转化为规则组件, 如触发器和动作; (2) 规则合成 (刘等人, 2021年; 张等人, 2020年) 基于用户的活动轨迹合成规则; 以及 (3) TAP规则推荐系统 (Corno等人, 2019, 2020, 2021年) 基于先前创建的用户规则进行推荐, 为高效规则创建提供了一种有前景的方法。

动机。然而, 上述方法在生成或推荐规则时, 主要关注用户的显性需求, 而非其隐性意图。如图1所示, 给定规则“如果你离开家, 则关闭空调”, 现有方法

* 通讯作者。电子邮件地址: wugang17@mails.jlu.edu.cn (吴刚), hul@jlu.edu.cn (胡亮), huyx22@mails.jlu.edu.cn (胡永新), xingyh18@mails.jlu.edu.cn (邢宇航), wangfeng12@mails.jlu.edu.cn (王峰)。¹
<https://www.statista.com/statistics/1183457/iot-connected-devices-worldwide/>.




图1. 给定一条用户创建的TAP规则, 现有方法只能推荐功能相似的规则 (蓝色箭头), 而用户意图 (绿色箭头) 则在跨功能规则 (橙色箭头) 之间架起了桥梁。① 表示一条规则包含多个用户意图; ② ③ 表明不同功能的规则可以基于用户意图建立联系; ②和 ③ 则强调功能相似的规则可能包含不同的意图。

可以轻易识别用户的显性需求, 即关闭空调, 并可以推荐具有类似功能的其他规则, 例如“如果温度低于26°C, 则关闭空调”。然而, 在物联网场景中, 用户期望的自动化往往是意图驱动的。一方面, 用户意图可以在不同功能的规则之间建立关联。例如, 在图1的 ③ 中, 基于“节能”这一用户意图, 在功能独立的规则 R_4 、 R_7 和 R_8 之间建立了链接。另一方面, 一条规则可以包含多种意图, 这些意图的组合可以产生更有效的规则推荐。例如, 图1中的 R_1 可能同时涉及亮度和氛围意图。如果一个物联网系统能够理解并整合这些多重意图, 它就能提供更全面的自动化。

本文聚焦于TAP中的用户意图预测问题, 旨在建立TAP规则与用户意图之间的映射关系, 这对于包括TAP规则推荐在内的许多物联网应用至关重要。解决此问题面临三个关键挑战。首先, 触发器与动作功能之间的上下文依赖关系导致用户在组合不同功能时会产生多种意图。例如, 用户创建了两条规则: “当人离开时关灯”和“当日出时关灯”, 它们分别反映了节能和照明的意图。其次, 在简短的功能描述中识别用户意图具有挑战性。当触发器和动作被开发时, 每个都附带一段描述其功能的文本。这些文本描述非常简短, 使得模型难以界定每个触发器和动作的功能边界。第三, 缺乏关于实体的常识知识, 阻碍了实体间关联性的发现, 导致跨功能自动化能力有限。例如, 空调和风扇是功能 (如制冷) 和应用场景 (如卧室) 相似但互不相关的设备。

创新点。为应对这些挑战, 我们提出了一种基于多视图表示学习的框架, 用于TAP中的用户意图预测, 命名为MvTAP。在MvTAP中, 我们构建了三个不同的视图: 用户视图、开发者视图和知识视图, 并采用多视图表示学习技术来预测用户意图。具体而言, 为解决第一个挑战, 我们使用图来表示用户视图中触发器与动作之间的关系, 并采用基于注意力的消息传递神经网络 (MPNN) (Gilmer, Schoenholz, Riley, Vinyals, & Dahl, 2017) 模块来捕获触发器-动作对之间的上下文依赖关系。为了学习触发器和动作功能描述的语义信息, BERT (Devlin, Chang, Lee, & Toutanova, 2019) 预训练语言

模型与TextCNN (Kim, 2014) 相结合, 以生成开发者视图中每个触发器和动作的表示, 这已被证明在学习短文语义方面是有效的 (Zhou, Li, Chi, Tang, & Zheng, 2022)。为解决第三个挑战, 我们首先构建了一个知识图谱来建立实体之间的关联。我们设计了一种新颖的方法, 从ConceptNet (Speer, Chin, & Havasi, 2017) 中提取与实体相关的常识知识。接着, 受KGCL (Yang, Huang, Xia, & Li, 2022) 的启发, 我们在功能与其连接的实体之间采用注意力机制, 以生成功能的知识感知表示。为了整合来自不同视图的信息, 我们开发了一种基于Transformer的融合方法, 该方法聚合各视图的规则表示以生成融合表示, 同时为每个视图保留局部和全局信息。融合后的规则表示随后被用于预测用户创建该规则时的意图。

贡献。总而言之, 本文的贡献如下所列。

1. 我们提出了一种基于多视图表示学习的框架, 通过从用户视图、开发者视图和知识视图学习规则表示来预测用户意图。
2. 我们分别应用MPNN、TextCNN和RKE来学习用户视图、开发者视图和知识视图的表示。提出了一种基于Transformer的方法来融合这些表示, 同时保留每个视图的全局和局部信息。
3. 我们将用户意图预测表述为一个多标签分类任务。在真实的IFTTT数据集上进行了大量实验来评估MvTAP, 结果表明MvTAP能有效预测TAP规则中的用户意图。

章节安排。本文其余部分的组织结构如下: 第2节回顾相关工作。问题陈述在第3节中描述。我们在第4节提供了所设计框架的技术细节。第5节描述了我们的实验。第6节讨论了MvTAP的实验结果和局限性。此外, 第7节总结了本文并提出了未来的研究方向。

2. 相关工作地点

本节首先回顾了高效创建TAP规则的主要进展与方法。随后, 我们简要回顾了多视角表示学习技术及其在TAP中的应用。

表 1 先前 工作地点 与 本文 的对比。

方法	参考文献	数据 类型	Typical technology	Use ^r 意图	Use ^r 意图
规则 生成	Yusuf 等人 (2022)	Textual	NLP	定义	建模
规则 合成	Zhang 等人 (2020年)	Time 系列	基于规则 匹配	No	No
	Liu 等人 (2021年)	Time 序列	基于规则 匹配	No	No
	刘 等人 (2023年)	Time series	Rule-基于 匹配	No	No
	李, 黄, 高, 和 董 (2023年)	Time 系列	Large L语言 模型	No	No
规则 推荐 mmendatio n	Corno et al. (2020年)	文本 与知识 图谱	基于规则 matchin g	目标导向	本体
	Corno et al. (2021)	文本	基于规则 m匹配 g	活动 T提取 行为 描述	在线 匹配 atc 匹配 中
	黄, Li, Zhang, Zhang, 和 Yu (2023年)	Graph 和 文本	Graph 神经 网络	No	Web No
	Yao 等人 (2023年)	Graph	Graph 神经 网络	No	No
	King, Yu, Lee, 和 Julien (2024)	Textual 与 空间	Large L语言 模型	特定 目标	Manual labeling
	本文 文章	Graph 文本、 与知 识 图	多视角 表示 学习	Specifi c 目标	Model 预测 n

2.1. 基于 机器学习 的 TAP 规则创建

TAP规则创建依赖于用户在网站上手动导航和创建规则，这既昂贵又耗时。已有许多方法被提出来高效创建TAP规则，主要分为三个研究视角：规则生成、规则合成和规则推荐。表1总结了现有工作，并从多个指标上与本文进行了比较。Yusuf et al. (2022)使用自然语言处理技术将用户的自然语言描述翻译成规则组件，例如通道、触发器和动作。Chakraborty, Pandey, Verma, and Dhanda (2023年)设计了一个语音助手，引入了BumbleBee API，使用户能够使用自然语言与Windows操作系统交互。然而，当用户的描述不完整且模糊时，这些方法表现不佳。Wang, Dong, Gu, Ling, and Yang (2023年)提出了一种基于手势的规则生成方法，通过摄像头识别用户的指向射线和手部动作来生成TAP规则。然而，该方法并未对用户的意图进行建模。

许多模型 (Li 等人，2023年; Liu 等人，2021年, 2023年; Zhang 等人，2019年, 2020年) 被设计用于基于用户轨迹生成规则。Zhang 等人 (2019年) 设计了一套安全属性来约束错误和冲突规则的创建。这些属性有助于新规则的合成。后来，他们提出了Trace2TAP (Zhang 等人，2020年)，它可以通过分析传感器读数的时间戳日志和设备手动驱动的轨迹来自动合成规则。遗憾的是，这些模型是在小规模平台和简单场景下测试的，限制了可推断规则的可能性。

近年来，TAP规则推荐系统 (Corno等人，2020年, 2021年, 2023年, 2024年, 2024年; Huang等人; King等人; Wu, Wang和Wang; Yao等人, 2023年) 已被提出，旨在基于用户先前创建的规则进行推荐，为高效创建规则提供了一个有前景的趋势。AutoTAR (Zhao, Wu, Ma, Shen和Chen, 2021年) 是一种上下文感知的对话式推荐技术，它利用TAP知识图谱来编码规则的语义特征和抽象功能，然后进行规则推荐，以解决规则冲突和可扩展性等问题。Corno等人 (2020年) 和Huang等人 (2023年) 分别设计了TAPrec和TAP-AHGNN，它们都是支持基于用户指定的触发器自动补全动作的TAP规则推荐系统。具体而言，TAPrec尝试将用户意图图定义为目标导向的活动，例如个性化用户房间的照明，并通过从EUPont

本体 (Corno 等人，2019年) 中提取的OWL类来建模用户意图。后来，他们进一步提出了一种基于对话代理的推荐系统HeyTAP，该系统首先从用户对话中提取抽象文本描述作为用户意图，然后将它们映射到OWL类，以匹配具有相似功能的规则。然而，这些系统成本高昂，因为构建EUPont本体是基于规则的，并且需要手动标注和专家知识。King 等人 (2024年) 开发了一个名为Sasha的智能家居助手，它将模糊的用户指令和家居布局作为输入提供给大语言模型，以推荐所需的规则。然而，在设计Sasha时，他们不得不为每条规则手动标注一个具体目标 (即本文定义的用户意图)，这非常耗时。

虽然上述方法提高了用户创建TAP规则的效率，但它们并未显式建模用户意图，导致推荐的规则仅限于相似功能和设备。与Sasha不同，我们将用户意图标注视为一个模型预测问题，而非手动标注每条规则。

2.2. 多视图 表示 学习

多视图表示学习 (Li, Yang, & Zhang, 2018) 旨在整合来自不同视图的多个数据源，以提升模型预测性能，其方法可分为多视图表示对齐 (Yang等人, 2021) 和多视图融合 (Shao等人, 2022; Wen等人, 2023; Zhong等人, 2023)。Yang等人 (2021) 提出了一种噪声鲁棒对比损失方法，该方法同时学习表示并对齐数据，以解决部分视图对齐问题，在无需标注数据的情况下实现了跨视图对应关系并带来了显著的性能提升。Zhong等人 (2023) 提出了KGAN，这是一个知识图谱增强网络，它通过多视图表示学习融合外部知识和文本信息以进行情感分析。MetaN-aBP (Shoombuatong, Homdee, Schaduengrat, & Chumnannpuen, 2024) 是一种创新的基于元学习的方法，旨在高准确率地预测Nav阻断肽。它通过采用一系列多样化的基于序列的特征描述符来生成新的特征表示，这些描述符捕捉了多个视角。随后，这些表示与强大的机器学习算法相结合，以增强预测性能。

图表示学习作为多视角表示学习的一个子集，被用于学习TAP组件 (例如实体、功能和规则) 的表示，以捕捉其结构和属性。这些学习到的表示被用于各种与TAP相关的

表 2 常用 符号 说明。

符号	含义
TAP	触发器-动作 编程
MPNN	消息传递 神经 网络
RKE	关系感知 知识 嵌入
MLP	多层 感知器
AC	空调
$\mathcal{R}, \mathcal{T}, \mathcal{A}$	TAP rule 集合, 触发器集合, 动作 开启 设置
$\mathcal{G}$	User 意图 集
$u, v, N(v)$	触发器 n 节点 u , 动作 n 节点 v , 和 该 邻域
$\mathcal{D}_v$	描述 o 的 n 节点 v 的 邻域
$G^{uv}, \mathbb{V}, \mathbb{E}$	用户 意图 u, v 节点集合, 及其 边 集合
G^{dv}	开发者 v 视图, 其 头部 实体 集合, 其 关系 n 集合, 以及 其 尾 实体 集合
G^{kv}, h, r, t	知识 v 视图, 其 头部 实体 集合, 其 关系 n 集合, 以及 其 尾 实体 集合
$e_v^{uv}, e_v^{dv}, e_v^{kv}$	节点 v 的 表征 n 的 节点 v 获得 $from$ user v 视图, 开发者 v 视图, 以及 知识 v 视图
$e_v^d, e_v^u, e_{v,u}^i$	节点 v 的 表征 n 的 节点 v 获得 $from$ user v 视图, 开发者 v 视图, 以及 知识 v 视图
ϕ, Θ	线性 变换 $formation$ 和 聚合 n function 在 该 用户 视图下
$D_v, \tilde{D}, F$	该 节点 v 的 n 节点 v , 平均 节点 度, 以及 向量 场的 该 用户 r 视图 graph
x_v	节点 v 来自 BERT 的 表示
$\mathfrak{R}^d$	该 d 维 向量 表示
W, σ	可训练 权重 矩阵, 以及 LeakyReLU 激活 n 函数
$\pi(h, r, t)$	A 注意力 w 关系 下的 权重 n 函数
Q^i, K^i, V^i	查询 向量, key 向量 和 v 值 向量 关联 n 函数
$e^i, \tilde{e}^i, \bar{e}^i$	The 局部、全局、与 both 局部 和 全局 l 向量 r 表示 n 函数
$\bar{e}$	在 三种 视图 下 触发器 与 动作 的 融合 表示 n 函数
e_R	规则 的 向量 表示 n 函数
β	The w 用于 调整 位置 的 权重 n 函数
θ	The parameter n 函数
$\hat{y}_{ij}$	该 概率 n 函数
$\mathcal{L}$	总 损失

应用中, 例如实体间或触发器与动作之间的链接预测 (Huang等人, 2023; Xing, Hu, Zhang, Wu, & Wang, 2021)、规则分类 (Hu, Wu, Xing, & Wang, 2019; Wu, Hu等人, 2024) 以及TAP安全 (Wang, Guo, Li, Liu & and Yan, 2023; Wang, Ivanov等人, 2023)。一些研究 (Hu等人, 2019; Wu, Hu等人, 2024; Xing等人, 2021) 使用异质信息网络来建模TAP规则及其组件之间的关系。随后利用图表示学习来捕捉TAP规则中的语义, 这已被证明在分类任务中是有效的。最近, 几项研究 (Wang, Guo等人, 2023; Wang, Ivanov等人, 2023) 提出使用图表示学习方法来解决TAP规则中的安全问题。在 Wang, Guo等人 (2023) 中, 设计了一个基于图神经网络的系统 FexIoT, 用于进行物联网交互漏洞分析。他们基于规则描述和实时事件日志构建了一个表示TAP规则之间关系的交互图。该交互图被作为图神经网络的输入, 以检测TAP规则的漏洞。同时, 他们进一步提出了 Glint (Wang, Ivanov等人, 2023), 这是一个基于图表示学习的系统, 能够检测智能家居中的交互式威胁。

在本文中, 我们设计了一个用于预测TAP中用户意图的自动化框架。受图表示学习在TAP中成功应用的启发, 我们提出了一个端到端多视图表示学习框架来编码TAP数据, 以预测用户意图。与现有的仅考虑相似功能内规则推荐的用户意图建模方法不同, 我们的框架能够实现跨功能规则推荐。

3. 问题 陈述

在本节中, 我们将介绍相关定义并阐述用户意图预测问题。此外, 我们提供表2来总结常用的符号。

TAP是一种物联网范式, 它允许用户通过创建“如果这样, 那么就那样”形式的条件规则, 来自动化智能设备或在线服务的操作。每条规则由四个主要组件构成: 一个触发器通道、一个动作通道、一个触发器和一个动作。例如, 如图2所示, 规则“如果日出, 那么就关闭加热器”



图 2. 一个 TAP 规则的 示例: “如果 日出 则 关闭 加热器”。

是通过组合触发器日出监测功能 (由天气服务提供) 和动作关闭加热器 (由加热器设备实现) 而形成的。值得注意的是, 用户也可以用自然语言来指定规则, 例如“我想在黎明时关闭加热器”, 这使得非技术用户能更直观地设置自动化。

定义 1 $\mathcal{R}_i = \langle \mathcal{T}_i, \mathcal{A}_i \rangle$ (TAP 规则). 一条TAP规则表示为, 即触发器与动作的组合, 其中和分别是可由实体触发和执行的功能。每条TAP规则 $\mathcal{R}_i$ 都有一段用户编辑的自然语言, 记为 $D_{\mathcal{R}_i}$ 。此外, 每个触发器 $\mathcal{T}_i$ 和动作 $\mathcal{A}_i$ 都有一个开发者提供的功能描述, 分别记为 $D_{\mathcal{T}_i}$ 和 $D_{\mathcal{A}_i}$ 。

定义2 (TAP 用户意图). TAP中的用户意图被定义为用户希望通过设置特定触发器 $\mathcal{T}$ 和相应动作 $\mathcal{A}$ 来实现的具体目标 $\mathcal{G} = \{g_1, g_2, \dots, g_o\}$, 其中 o 是用户意图类型的数量。

定义 3 (用户视图). 我们使用用户自定义的触发器-动作对来构建图 $G_{uv} = (\mathbb{V}, \mathbb{E})$, 其中 $\mathbb{V} \subseteq \{\mathcal{T}, \mathcal{A}\}$ 表示节点集合, 每个节点代表一个触发器或一个动作。每条边 $e = (u, v) \in \mathbb{E}$ 表示从一个节点到另一个节点的链接。此外, 每个链接都附带有用户编辑的自然语言。

定义 4 (开发者视图). 我们将开发者视图表示为一个集合 $G_{dv} = \{v_1, v_2, \dots, v_{m+n}\}$, 其中 $v_i \in \{\mathcal{T}, \mathcal{A}\}$ 代表一个触发器或一个动作。每个节点 v_i 都附有开发者提供的描述文本, 记作 D_{v_i} 。




图 3. MvTAP 框架 概述。

定义 5 (知识视图)。知识视图表示为一组三元组

$G_{kv} = \{(h, r, t) \mid h, t \in \mathbb{V}_{kv}, r \in R\}$, 其中 $\mathbb{V}_{kv}$ 代表触发器、动作和实体的集合, 而 R 表示关系的集合。每个三元组表示从头实体 h 到尾实体 t 的关系 r (例如, 空调, *CapableOf*, 冷却房间)。

基于以上定义, 我们提出用户意图预测的问题定义。我们的目标是根据用户创建的规则推断其最可能的意图。形式化地, TAP的用户意图预测问题被表述为一个多标签任务, 其中节点是TAP规则, 标签是用户意图。

问题定义。 令 $R = \{R_1, R_2, \dots, R_c\}$ 表示规则集合,

$\mathcal{T} = \{\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_m\}$ 表示触发器集合, $\mathcal{A} = \{\mathcal{A}_1, \mathcal{A}_2, \dots, \mathcal{A}_n\}$ 表示动作集合, 其中 c, m, n 分别表示规则 R 、触发器 $\mathcal{T}$ 和动作 $\mathcal{A}$ 的数量。

给定一个TAP规则的组件, 包括 R_i 、 $\mathcal{T}_i$ 和 $\mathcal{A}_i$, 以及关联的用户意图 G_i , MvTAP的目标是学习一个函数 $f_\theta: R_i \rightarrow G_i$, 将该TAP规则映射到一组用户意图, 使得 f_θ 能够预测其他规则的用户意图。目标函数可表述为:

$$\min_{\theta} \mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^J y_{ij} \log(\hat{y}_{ij}) + (1 - y_{ij}) \log(1 - \hat{y}_{ij}) \quad (1)$$

其中 N 是训练规则的数量, J 是用户意图的数量, y_{ij} 是真实的用户意图。 $\hat{y}_{ij}$ 是预测的用户意图的概率分布, 可通过下式计算:

$$\hat{y}_{ij} = f_{\theta}(\mathcal{T}_i, \mathcal{A}_i, R_i) \quad (2)$$

其中 θ 代表 f_{θ} 的参数。 $f_{\theta}(\cdot)$ 是一个预测函数, 通过输入触发器 $\mathcal{T}_i$ 、动作 $\mathcal{A}_i$ 和规则 R_i 来生成用户意图的概率。

4. MvTAP 的设计

在本节中, 我们介绍一个概述关于我们提出的 MvTAP框架, 如图 3 所示。MvTAP 包含以下五个主要模块:

1. 用户视图表示学习 (另见第4.1节): 该模块基于用户创建的触发器-动作对构建用户视图图。为了编码用户语义, 使用MPNN来学习用户视图图, 并将触发器和动作转换为向量表示。

2. 开发者视图表示学习 (另见第4.2节): 该模块以开发者生成的触发器和动作的描述文本作为输入, 使用自然语言处理技术来学习有效的触发器与动作的句子级表示。

3. 知识视图表示学习 (另见第4.3节): 该模块将与触发器和动作相关的实体映射到外部知识库 (即 ConceptNet (Speer 等人, 2017)), 建立从实体到知识图谱概念的链接。然后, 采用关系感知知识嵌入 (RKE), 通过聚合基于知识图谱 (KG) 的语义邻居表示, 来学习知识增强的触发器和动作表示。

4. 多视图表示融合 (另见第4.4节): 本模块引入一种基于 Transformer的融合方法, 用于融合从上述三个视图学习到的触发器和动作表示, 并在用户视图约束下将它们结合起来, 以生成TAP规则表示。

5. 用户意图预测 (另见第4.5节): 本模块以TAP规则表示作为输入, 预测每条规则对应的用户意图。

4.1. 用户视图 表示 学习

该模块通过对触发器和动作之间的依赖关系进行建模, 来推断用户的潜在意图。每条TAP规则都可以表示为用户在触发器与动作之间创建的一个链接。这个链接是显式的, 而触发器与动作之间的依赖关系 (如位置和上下文) 则是隐式的。例如, 在规则“当我接近时解锁门”中, 触发器“监测接近门的人”与动作“解锁门”之间存在位置依赖关系。具体来说, 解锁门的动作取决于用户的位置。理解这种依赖关系对于推断用户意图和创建更具创新性的自动化系统至关重要。

为了对触发器和动作之间的依赖关系进行建模, 我们构建了一个用户视图图来表示触发器和动作之间的关系, 如定义 3所示。我们应用 MPNN (Gilmer 等人, 2017) 来学习用户视图图的结构, 并通过消息传递将触发器和动作转换为可学习的低维向量表示, 具体如下。

$$\mathbf{e}_v^{uv} = MLP(\mathbf{e}_v^l, \mathcal{O}_{u \in \mathcal{N}(v)}(\phi(\mathbf{e}_v^l, \mathbf{e}_u^l, \mathbf{e}_{v,u}^l))) \quad (3)$$

其中 $MPLP(\cdot)$ 是一个多层感知机 (MLP)，它以节点 v 在第 l 层的表示 $\mathbf{e}_v^l$ 及其邻居 $u \in \mathcal{N}(v)$ 的表示 $\mathbf{e}_u^l$ 作为输入，以得到新的表示 $\mathbf{e}_v^{\phi}$ 。 ϕ 是一个线性变换， $\mathcal{O}$ 是一个聚合函数。特别地，当一个动作被不同的触发器链接时，它们可能具有不同的上下文依赖关系，这意味着链接背后不同的用户意图。例如，规则“当人们离开时关灯”和规则“日出时关灯”由不同的触发器触发以关灯，分别反映了用户节能和照明的意图。为了对这种上下文依赖关系进行建模，我们在公式(3)中同时聚合了邻居节点特征 $\mathbf{e}_u$ 和边特征 $\mathbf{e}_{v,u}$ 。这里的边特征来源于用户对规则的自然语言描述。受PNA (Corso, Cavalleri, Beaini, Liò, & Veličković, 2020年) 的启发，我们进一步利用多个聚合器和缩放器来提升模型聚合邻居信息的能力，表达如下：

$$\mathcal{O} = \underbrace{\begin{bmatrix} 1 \\ \log(D_v + 1) / \bar{D} \end{bmatrix}}_{\text{scalers}} \otimes \underbrace{\begin{bmatrix} \text{sum} \\ op_1 \\ op_2 \end{bmatrix}}_{\text{aggregators}} \quad (4)$$

其中 D_v 是 v 的度， $\bar{D}$ 是训练中的平均节点度。PNA 提供了多种聚合器，例如求和、最大值和最小值， op_i 表示待选的聚合器。这些聚合器使模型能够有效捕捉各种上下文依赖关系。此外，我们在公式(4)中引入了方向性聚合器，以捕捉触发器与动作之间的顺序关系。受 DGN (Beaini 等人, 2021年) 的启发，我们基于用户视图图的拉普拉斯特征向量定义了一个方向感知向量场 $\mathbf{F}$ 。节点特征向量之间的差异反映了消息传递过程中触发器与动作信息的传播方向。此外，我们利用该向量场 $\mathbf{F}$ 定义了方向平滑 op_1 和方向导数 op_2 聚合器，其计算方式如下：

$$op_1 = |\hat{\mathbf{F}}|, op_2 = \hat{\mathbf{F}} - \text{diag}\left(\sum_j \hat{\mathbf{F}}_{:,j}\right) \quad (5)$$

其中 $\hat{\mathbf{F}}$ 表示向量场 $\mathbf{F}$ 在按行以其 L_1 范数归一化后的结果， $|\cdot|$ 表示绝对值。

4.2. 开发者视图 表示 学习

每个触发器和动作都有一个由开发者编辑的描述。该描述由一句话组成，用于解释触发器或动作的主要功能。本模块的目的是从触发器和动作的描述文本中捕获语义信息。直观上，用户创建的具有功能相似动作的规则往往具有相同的意图。然而，每个触发器和动作的描述都很简短，这使得用户难以理解其确切角色。为了解决这个问题，我们必须对描述文本中的语义信息进行编码。受TextCNN (Kim, 2014) 的启发，我们采用了一种基于句子的嵌入方法，该方法已被证明在学习短文本语义方面是有效的 (Zhou et al., 2022)。

给定触发器或动作 D_v 的描述文本，我们采用BERT (Devlin 等人, 2019) 作为文本编码器来获取每个词的向量表示。作为一种双向Transformer编码器，BERT在各种自然语言处理任务中表现优异，为捕捉触发器和动作描述文本中的语义信息提供了坚实基础。由于描述文本的长度不一，直接将其输入TextCNN模型可能导致问题。为解决此问题，我们需要标准化每个描述文本的长度。通过分析数据集确定描述文本的最大长度 M 。我们使用零填充来处理长度不足的句子，确保每个句子具有统一长度。经过

此处理后，每个描述文本可通过公式 (6) $\mathbf{x}_{v_i} \in \mathbb{R}^{M \times d'}$ 表示为一个预训练矩阵。

$$\mathbf{x}_v = f_{BERT}(D_v) \quad (6)$$

其中 $\mathbb{R}^{M \times d'}$ 表示一个 d' 维度的单词向量表示。 $f_{BERT}(\cdot)$ 是一个基于BERT的函数。我们将每个描述文本的预训练矩阵作为输入，使用公式 (7) 来学习其句子级表示。

$$\mathbf{e}_v^{dv} = f_{TextCNN}(\mathbf{x}_v) \quad (7)$$

其中 $f_{TextCNN}(\cdot)$ 是一个TextCNN层，其配置与 (Kim, 2014) 相同。通过使用BERT模型捕捉句子中的局部特征，并使用TextCNN层获取全局信息，我们的开发者视图表示学习能够有效地编码触发器和动作的句子级语义。

4.3. 知识视图 表示 学习

知识视图表示学习的主要任务是从外部知识库中提取实体之间的关联关系。其核心思想是：实体之间的关联性越高，组合这些实体功能的规则具有相同用户意图的概率就越高。例如，空调和风扇具有高度关联性（即它们都能为房间降温），因此组合它们的两条规则共享一个共同的用户意图，例如环境温度。然而，在真实的物联网场景中，缺乏关于实体（例如位置、能力）的常识知识，这阻碍了实体间关联性的发现，并导致跨设备自动化能力有限。尽管开发者视图表示学习模块可以为触发器和动作生成语义一致的词级和句子级表示，但NLP模型中缺乏常识和领域特定知识仍然会限制性能。为了解决这个问题，我们首先引入一个外部知识库ConceptNet (Speer等人, 2017)，为TAP构建一个知识图谱，以丰富实体的常识知识。然后，使用RKE来学习实体、触发器和动作的表示。知识视图表示学习模块如图4所示。

4.3.1. 构建 知识 图谱

ConceptNet 是一个提供常识和常识性信息的知识图谱，它通过带标签的边将自然语言的单词和短语连接起来 (Speer et al., 2017)。其知识来源于多种渠道，例如专家标注的资源 and 众包。它包含 36 种关系类型和超过 800 万个节点，以三元组形式表示，例如 (加热器, TypeOf, 设备)。

本文设计了一种方法，用于从 ConceptNet 中提取与实体相关的常识知识，以建立它们之间的关联。具体而言，我们基于三种关系从 ConceptNet 中提取知识图谱概念：UsedFor、CapableOf 和 AtLocation，以丰富实体的上下文信息。其理念是，操作具有相似上下文信息的实体的用户通常具有相同的意图。例如，在智能家居中，恒温器和窗户传感器可能共享关于温度控制的上下文信息。我们从触发器和动作的描述文本中提取实体，以建立从实体到知识图谱概念的映射。首先，我们通过执行一个包括停用词移除、词形还原和词性标注的工作流程来预处理这些描述文本。在触发器或动作与提取的实体之间建立 Has 关系。例如，在图 4(a) 中，存在从 a_5 到空调和从 a_4 到风扇的 Has 关系。然后，使用提取的实体来匹配知识图谱概念，基于三种关系获取关于它们的上下文信息。例如，空调和风扇都能为房间降温。此外，还利用了 a_5 和 风扇 之间的高阶关系（即连通性），这可以

被定义为一个多跳关系路径 $a_5 \xrightarrow{r_1} AC \xrightarrow{r_2} \text{cool a room} \xrightarrow{r} fan$ 。在不失一般性的前提下， r_2 关系可以在 a_5 和 风扇 之间建立。完成此步骤后，一个包含三种类型节点和四种类型边的知识图谱即构建完成。




图 4. 知识 视图表示学习模块。红色虚线表示通过知识图构建的一条新链接。

4.3.2. 关系感知知识 嵌入

为了将实体的上下文信息整合到触发器和动作的表示中，我们受 KGCL (Yang et al., 2022) 的启发，采用RKE来聚合具有不同关系的邻居表示，如图4(b)所示。由于递归传播节点的表示会带来额外开销，我们通过使用关系路径将高阶关系（例如）转化为一阶关系，从而简化了我们构建的知识图谱。

使用 $\xrightarrow{2} f_{an} \xrightarrow{r_1} AC \xrightarrow{r_2} cool_a_room$ 而非 $a_5 \xrightarrow{r_1} AC \xrightarrow{r_2} cool_a_room$ 。对于每个触发器或动作 r_h ，我们记 $r = \text{cool_a_room}$ 。 $\mathcal{N}_h = \{(h, r, t) \mid (h, r, t) \in G_{kv}\}$ 为基于不同类型关系 r 的 h 的相邻实体。采用 h 与其在 G_{kv} 中的相邻实体之间的**关系感知知识聚合机制**来生成触发器和动作的表示，公式如下：

$$\mathbf{e}_v^{kv} = \mathbf{e}_h + \sum_{(h, r, t) \in \mathcal{N}_h} \pi(h, r, t) \mathbf{e}_t \quad (8)$$

其中 $\mathbf{e}_h \in \mathbb{R}^d$ 和 $\mathbf{e}_t \in \mathbb{R}^d$ 分别表示触发器或动作以及实体的初始向量表示。 $\mathbf{e}_v^{kv} \in \mathbb{R}^d$ 代表在开发者视图下触发器和动作的最终嵌入。 $\pi(h, r, t)$ 是一个注意力权重，表示在通过关系 r 进行知识聚合时，有多少信息从 h 传播到 t 。在此，我们使用关系感知注意力机制来实现 $\pi(h, r, t)$ ，如下所示：

$$\pi(h, r, t) = \frac{\exp(\sigma(\mathbf{r}^T \mathbf{W} [\mathbf{e}_h || \mathbf{e}_t]))}{\sum_{(h, r', t') \in \mathcal{N}(h)} \exp(\sigma(\mathbf{r}'^T \mathbf{W} [\mathbf{e}_h || \mathbf{e}_{t'}]))} \quad (9)$$

其中 $\mathbf{r} \in \mathbb{R}^d$ 表示关系 r 的初始表示， $||$ 是拼接操作。 $\mathbf{W} \in \mathbb{R}^{d \times 2d}$ 是一个可训练的权重矩阵。这里， σ 是LeakyReLU激活函数。直观上，公式(9)编码了在不同关系 r 下，实体 t 对于触发器或动作 h 的重要性。

4.4. 多视角表示融合

该模块旨在融合来自三个视角的触发器和动作的表示，并将其组合以生成TAP规则的表示。每个视角提供了各种触发器和动作的一个特定方面，包含了跨越这些不同视角的更复杂的意图。由于各视角之间存在较大的异质性，简单地组合所有视角（例如通过拼接和平均操作）无法充分利用信息，从而导致意图预测结果不理想。

本文设计了一种基于Transformer的融合方法，将多种表示精炼为单一的综合性表示，该方法利用了用户视图、开发者视图和知识视图中所包含的互补性意图信息。如图5所示，由用户视图模块、开发者视图模块和知识视图模块学习到的三种不同表示被输入到一个Transformer模型中，生成一个单一的表示，该表示保留了每个视图的全局与局部意图信息。给定视图列表 $G = \{G^{uv}, G^{dv}, G^{kv}\}$ 以及来自不同视图的每个触发器和动作的表示 $\{\mathbf{e}^{uv}, \mathbf{e}^{dv}, \mathbf{e}^{kv}\}$ ，我们利用一个Transformer模型来建立每对视图之间的关联。对于第 i 个视图的表示

$\mathbf{e}^i$ ，它由第 i 个视图表示学习模块获得，我们为其关联一个查询向量 $\mathbf{Q}^i$ 、一个键向量 $\mathbf{K}^i$ 和一个值向量 $\mathbf{V}^i$ ，具体如下：

$$\mathbf{Q}^i = \mathbf{e}^i \mathbf{W}_Q, \mathbf{K}^i = \mathbf{e}^i \mathbf{W}_K, \mathbf{V}^i = \mathbf{e}^i \mathbf{W}_V, i \in G \quad (10)$$

其中 $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 和 $\mathbf{W}_V$ 是可学习参数。注意力机制是我们提出的Transformer模型的基本组件，它可以衡量不同视图彼此之间的相对重要性。对于一对视图，这意味着Transformer可以决定一个视图所隐含的哪个意图在其他视图的上下文中最为相关，从而捕获全局意图信息。例如，在对用户视图的全局信息进行编码时，开发者视图和知识视图提供的意图信息应根据用户视图的意图信息进行调整。基于这一考虑，我们在Transformer模型中设计了一个注意力机制来捕获每个视图的全局信息。对于每个视图 i ，我们按如下方式聚合来自其他视图的信息：

$$\alpha_{(i,j)} = \frac{\exp(\mathbf{Q}^i \cdot \mathbf{K}^j)^T)}{\sum_{t \in G} \exp(\mathbf{Q}^i \cdot \mathbf{K}^t)^T)}, \quad \hat{\mathbf{e}}^i = \sum_{j \in G} \alpha_{(i,j)} \mathbf{V}^j \quad (11)$$

直观地说，查询向量 $\mathbf{Q}^i$ 与键向量 $\mathbf{K}^j$ 的点积衡量了第 i 个视图与第 j 个视图之间的相关性。 $\alpha_{(i,j)}$ 是一个相关性注意力权重，它表示来自其他视图的信息对当前视图的重要性。 $\hat{\mathbf{e}}^i$ 被视为包含全局信息的第 i 个视图的表示。为了在学习过程中将全局信息和局部信息同时整合到单个视图中，我们计算：

$$\tilde{\mathbf{e}}^i = \beta \hat{\mathbf{e}}^i + (1 - \beta) \mathbf{e}^i \quad (12)$$

其中 β 是一个可学习参数，用于平衡当前视图中的全局信息和局部信息。与(杨, 严, 潘, 叶, 和范, 2023年)仅考虑视图的全局信息不同，我们通过一个可学习权重来平衡视图的全局和局部信息。每个触发器和动作的最终表示是通过拼接学习到的三个视图的表示获得的，

$$\tilde{\mathbf{e}} = \text{concat}(\tilde{\mathbf{e}}^{uv}, \tilde{\mathbf{e}}^{dv}, \tilde{\mathbf{e}}^{kv}) \quad (13)$$

遵循上述流程，每个触发器和动作的融合表示可用于在用户视图约束下，通过组合机制生成TAP规则的表示 $\mathbf{e}_R$ 。

$$\mathbf{e}_R = \tilde{\mathbf{e}}_u \odot \tilde{\mathbf{e}}_v, u \in \mathcal{T}, v \in \mathcal{A}, (u, v) \in \mathbb{E} \quad (14)$$

其中 $\odot$ 表示对触发器和动作表示进行乘法运算， (u, v) 表示用户自定义的触发器与动作之间的链接。




图 5. 基于Transformer的多视角表示融合。此处，我们以用户视图为例，展示如何通过Transformer模型从用户视图中提取全局与局部意图信息的过程。

4.5. 用户意图预测

本文旨在根据用户创建的TAP规则预测用户意图。用户创建一条TAP规则时，可能存在多种意图。例如，规则“使用Alexa打开你的窗帘”包含了用户对环境温度和環境照明的意图。为此，我们将用户意图预测表述为一个多标签分类问题，以基于已创建的TAP规则作为标签，生成概率最高的那些用户意图。具体来说，给定一个TAP规则表示 $\mathbf{e}_{R_i}$ ，我们使用一个具有两层结构的多层感知机，后接一个 *sigmoid* 激活函数，来计算每个标签 j 的概率 $\hat{y}_{ij}$ ：

$$\hat{y}_{ij} = \text{sigmoid}(\mathbf{W}_2^T \cdot \sigma(\mathbf{W}_1^T \cdot \mathbf{e}_{R_i} + b)) \quad (15)$$

其中 $\mathbf{W}_1^T$ 和 b 是MLP的可学习参数， σ 是ReLU激活函数。为了优化MvTAP的模型参数 $\theta = \{\mathbf{W}_i, \mathbf{r}_i\}$ ，我们最小化由公式(16)计算的二元交叉熵损失。

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^J y_{ij} \log(\hat{y}_{ij}) + (1 - y_{ij}) \log(1 - \hat{y}_{ij}) \quad (16)$$

其中 N 是训练样本的数量， J 表示标签的数量， y_{ij} 是真实标签。

算法1描述了MvTAP的训练过程，以优化模型参数 θ 并获取每个TAP规则的表示。首先，将三个部分作为输入来学习触发器和动作的单视图表示：用户视图、开发者视图和知识视图。然后，基于每个视图的表示，通过Transformer模型生成每个触发器和动作的融合表示。最后，我们通过乘法运算得到每个TAP规则的表示。BCE计算损失函数，模型参数可以通过Adam优化器有效更新 (Kingma & Ba, 2015)。迭代重复进行，直到损失函数收敛，我们便能在学习到的参数下获得TAP规则的表示。

4.6. 时间复杂度分析

用户视图的时间复杂度为 $O(|\mathbb{E}| \cdot a \cdot d')$ ，其中 $|\mathbb{E}|$ 是用户视图图中边的数量， a 是聚合器的数量。 d' 表示单视图表示的维度。开发者视图的时间复杂度为 $O(M \cdot K \cdot w \cdot d')$ ，其中 M 是描述文本的最大长度， K 和 w 分别是卷积滤波器的数量和窗口大小。知识视图的时间复杂度为 $O(|R| \cdot d')$ ，其中 $|R|$ 表示知识视图中关系的数量。多视图融合包含两部分：Transformer模型和一个乘法

算法1 MvTAP的训练过程

输入： 用户视图 G^{uv} 、开发者视图 G^{dv} 、知识视图 G^{kv} 。

输出： 优化后的模型参数 $\theta = \{\mathbf{W}_i, \mathbf{r}_i\}$ 、TAP规则的表示。

TAP规则。

1: 初始化参数 θ 。

2: 当训练轮次数 ≤ 1000 时执行

3: 从三个视图计算触发器和动作的表示

使用公式(3)、公式(7)、以及公式(9)。

4: 生成每个触发器和动作的融合表示

使用公式(10)-公式(13)。

5: 通过公式(14)获取每条TAP规则的表示。

6: 使用公式(16)计算损失。

7: 使用Adam优化器更新参数 θ 。

8: 结束循环

运算符，因此其成本为 $O(|V|^2 \cdot d' + c \cdot d')$ ，其中 $|V|$ 是触发器和动作的总数， c 是规则的数量。对于用户意图预测，其复杂度为 $O(d' \cdot d)$ ，其中 d 表示最终表示的维度。总体而言，MvTAP的时间复杂度为 $O(|\mathbb{E}| \cdot a + M \cdot K \cdot w + |R| + |V|^2 + c + d) \cdot d'$ 。

5. 实验

为评估我们提出的MvTAP框架的有效性，我们在真实世界的IFTTT数据集上进行了多标签分类实验。首先，介绍数据集、对比方法和评估指标。然后，我们定量分析MvTAP的性能，并将其与其他方法进行比较。最后，我们讨论从实验结果中获得的见解。

5.1. 实验设置

5.1.1. 数据集

IFTTT是一个支持TAP模式的第三方平台，覆盖了从物联网设备到网络应用等数百种服务。我们的IFTTT数据集源自Yu, Hua, and Julien (2021)的研究，于2021年8月从IFTTT平台收集。它包含50,067条规则，其中2,648条与物联网应用相关。表3展示了一条示例IFTTT规则的详细组件。每条规则由一个触发器和一个动作组成，每个都附有一段简短的文本描述。此外，这些规则根据用户目标被手动标注为12个类别。在我们的实验中，我们选择了与物联网相关的规则并去除了重复项，最终得到1,923条规则、302个触发器、523个动作和12个目标。我们数据集的统计信息如表4所示。

表 3 一个示例IFTTT 规则 的组件。

组件	内容
ID	PVkgiLYy
Name	自动 tu rn your lights 于 在 日落时
触发器 c hannel	Weather Underground (该 设备 或 se rvice)
触发器	此 触发器 gger fires 在 1分钟内 of the 日落 in your location.
动作 频道	Philips 色调 (该 设备 或 se rvice)
动作	此 动作 将 开启 n on your hue lights.
描述	从 n o be left in the 黑暗. 每当 太阳 开始 落山 时, 您的 Philips Hue bulbs 将 自动 开启 。
Goal	环境 亮 度

表 4IFTTT 数据集的统计信息。

View	节点 类型	Link type	特征
用户视图	#触发器: 302 # 动作: 523	#触发器-动作: 1,923	D_T, D_A, D_R
开发者视图	#触发器: 302 # 动作: 523	–	D_T, D_A
知识视图	#触发器: 302 #动作: 523 #概念: 60 1	#触发器-概念: 1,982 # 动作-概念: 2 ,681 #概念-概念: 226	D_T, D_A

这些选定的规则被用于构建三个视图。每条规则代表一个触发器-动作对，在触发器和动作之间形成了1,923条边，这些边被用来构建一个包含825个节点和1,923条边的用户视图图。触发器和动作的功能描述被用来构建开发者视图。对于知识视图，我们将触发器和动作中的关键词映射到ConceptNet (Speer 等人, 2017)，得到了601个概念，并生成了1,982条触发器-概念边和2,681条动作-概念边。此外，我们基于UsedFor、CapableOf和AtLocation关系提取概念之间的链接，生成了226条概念间的边。

触发器、动作和规则的描述文本特征使用一个Sentence-BERT模型 (Reimers & Gurevych, 2019) 转换为固定长度的向量。对于节点分类，我们随机选择50%、20%和30%的TAP规则分别用于训练、验证和测试集。三个视图作为输入，12个目标用作分类标签，包括安全、环境氛围、节能节省、机器人控制、插座控制、园艺、其他电器、环境温度、环境照明、控制中枢、提醒用户和其他。如第4.5节所述，一条TAP规则可能具有多个用户意图，因此部分规则被分配了多个标签。

5.1.2. 对比 方法

我们将MvTAP与四组方法进行比较。第一组使用基于NLP的方法，包括TF-IDF、Sentence-BERT和TextCNN，来学习开发者视角信息。第二组使用基于图神经网络的方法，如GAT、EGAT、PNA、DGN、FastGTNs和SeHGNN，来学习用户视角信息。第三组包括知识图谱方法，即DistMult、ComplEx和RKE，用于学习知识视角信息。第四组包括多视图表示学习方法，如TMC、RCML和KGAN，用于从三个视图学习综合表示。此外，我们进一步将MvTAP框架与其变体方法进行比较，包括基于拼接和均值算子的多视图融合。TF-IDF+多层感知机 (Ramos 等 人, 2003)：TF-IDF以向量权重的形式评估单词在文档中的重要性。我们可以将此向量权重视为每条TAP规则描述的向量表示，并将其输入多层感知机以预测用户意图。

Sentence-BERT+多层感知机 (Reimers & Gurevych, 2019): 使用一个基于BERT的预训练模型来生成句子表示。我们用它来学习每条TAP规则的表示，并通过多层感知机提升分类任务的性能。

TextCNN (Kim, 2014): TextCNN是一种专门为文本分类任务设计的卷积神经网络模型，它利用卷积层来捕捉文本数据中的局部特征。

GAT (Velićković 等人, 2018)：这是一种图神经网络模型，通过带有注意力层的邻居特征聚合方法来获取节点的表示。

EGAT：它扩展了GAT，以同时聚合节点和边的特征。

PNA (Corso 等人, 2020年)：它同时使用多个任意聚合算子来聚合邻居特征。

DGN (Beaini 等人, 2021年)：这是一种在节点处具有定向流的图神经网络。节点特征向量之间的差异反映了信息传播的方向。

FastGTNs (Yun 等人, 2022)：这是一种异构图神经网络，可以在学习节点表示的过程中自动识别有用的元路径。

SeHGNN (Yang 等人, 2023年)：它使用一种基于Transformer的方法来融合从预定义元路径聚合的节点特征。

DistMult (Yang, Yih, He, Gao, & Deng, 2014)：这是一种知识图谱嵌入方法，它将实体和关系表示为共享空间中的向量，并使用双线性模型来捕捉它们的对称关系。

ComplEx (Trouillon, Welbl, Riedel, Gaussier, & Bouchard, 2016)：它将DistMult推广到包含反对称关系的知识图谱，通过在复向量空间中表示实体和关系来实现。

RKE：这是一种源自KGCL (Yang et al., 2022)的关系感知知识嵌入方法。其目标是基于异构注意力聚合器生成知识感知的实体表示。

TMC (Han, Zhang, Fu, & Zhou, 2022)：这是一种多视图学习方法，它动态整合来自不同视图的证据，以增强分类的可靠性和鲁棒性，特别是在存在噪声或分布外数据的情况下。

RCML (Xu et al., 2024)：它通过生成视图特定的证据和意见，并使用冲突意见聚合策略来建模多视图可靠性，从而解决在具有冲突信息的多视图数据上做出决策的问题。

KGAN (Zhong et al., 2023年): 这是一种基于方面的情感分析方法，它有效地将外部知识与句法及上下文信息相结合，从基于上下文、句法和基于知识的视图中捕捉情感特征表示，并利用分层融合模块将多视图表示融合在一起。

MvTAP-mean, MvTAP-concat: 它们是MvTAP框架的变体, 使用均值与拼接操作而非Transformer来融合多视图表示。

5.1.3. 评估指标

为了评估微调框架并衡量我们提出的框架以及对比方法在多标签分类任务上的性能, 我们计算了模型的灵敏度、特异性、准确率和F1分数。推荐多样性则通过列表间相似度 ($InterLS@K$) 和列表内相似度 ($IntraLS@K$) 分数进行评估。

准确率是所有样本中被正确分类的样本比例, 使用scikit-learn API的 $sklearn.metrics$ 模块中的 $accuracy_score$ 函数计算。准确率的计算公式如下:

$$Accuracy(S) = \frac{\sum_{s \in S} (TP(s) + TN(s))}{\sum_{s \in S} (TP(s) + TN(s) + FP(s) + FN(s))} \quad (17)$$

其中 TP 、 FP 、 TN 和 FN 分别代表真阳性、假阳性、真阴性和假阴性的数量。灵敏度和特异性分别是分类器正确检测出的正例和负例的比例。它们可以表示为:

$$Sensitivity(S) = \frac{\sum_{s \in S} TP(s)}{\sum_{s \in S} (TP(s) + FN(s))} \quad (18)$$

$$Specificity(S) = \frac{\sum_{s \in S} TN(s)}{\sum_{s \in S} (TN(s) + FP(s))} \quad (19)$$

对于F1分数的测量, 给定整体标签集 S , Micro-F1和Macro-F1的计算方式如下:

$$Precision(S) = \frac{\sum_{s \in S} TP(s)}{\sum_{s \in S} (TP(s) + FP(s))}, \quad (20)$$

$$Recall(S) = Sensitivity(S),$$

$$Micro-F1(S) = \frac{2 \cdot Precision(S) \cdot Recall(S)}{Precision(S) + Recall(S)},$$

$$Macro-F1(S) = \frac{\sum_{s \in S} F1(s)}{|S|}$$

其中 $Precision$ 表示检索结果中相关实例的比例, 而 $Recall$ 与 $Sensitivity$ 相同。Micro-F1通过计算总的 TP 、 FN 和 FP 来全局计算F1, 对每个实例赋予相等的权重。Macro-F1则定义为在整个标签集 S 上的平均F1。

采用 $InterLS@K$ 和 $IntraLS@K$ 指标来量化推荐的多样性。

$InterLS@K$ 衡量用户创建的规则与推荐列表中其他规则之间的多样性, 而 $IntraLS@K$ 衡量推荐列表中所有可能规则对之间的多样性。给定一个TAP规则 R_u 和一个由模型生成的包含 k 条规则的推荐列表 R , $InterLS@K$ 和 $IntraLS@K$ 可按如下方式计算:

$$InterLS(R) = \frac{1}{k} \sum_{j \in R} Sim(R_u, j) \quad (21)$$

$$IntraLS(R) = \frac{2}{k(k-1)} \sum_{i \in R, j \in R, i \neq j} Sim(i, j) \quad (22)$$

其中 $sim(i, j)$ 被定义为任意两条规则 i 和 j 之间的相似度。在本文中, 如果 i 和 j 具有相同的意图标签但设备或功能不同, 我们为 $sim(i, j)$ 赋值为 0.1; 如果它们共享相同的意图标签以及设备或功能, 则赋值为 0.5; 否则赋值为 1。例如, 给定规则 R_1 : 如果你离开家则关闭灯。 , R_2 : 如果日出则关闭加热器。 , 以及 R_3 : 如果日出则关闭灯。 , R_1 和 R_2 之间的相似度得分为 0.1, 因为这两条规则不包含相同的设备但具有相同的用户意图, 即节能。 R_1 和 R_3 都拥有相同的设备 (即灯) 和用户意图, 因此它们的相似度得分为 0.5。直观上, 更低的 $InterLS@K$ 和 $IntraLS@K$ 得分表明推荐列表具有更好的多样性。

5.1.4. 实现 细节

所有实验均在 Python 3.10 环境 (Ubuntu 22.04.4 LTS) 下进行, 使用 Tesla V100 PCIe 32 GB 显卡和英特尔至强金牌 6248 处理器 @ 2.50 GHz。MvTAP 使用开源机器学习框架 PyTorch² 和图学习框架 DGL³ 2.1.0 实现。每个触发器、动作和规则的原始特征维度 d' 为 768。单视图输出的表示维度 d 设置为 128。在用户视图表示模块中, 我们将 MPNN 的隐藏层数量设为一层。对于开发者视图模块, 卷积滤波器的窗口大小设置为 {2, 3, 4}, 不同宽度的卷积滤波器数量为 256。在知识视图模块中, 触发器、动作和概念的初始表示维度与 d 相同。对于模型优化, 学习率设置为 0.001, 训练轮次数设置为 1000。

为确保公平比较, 所有对比方法均使用与MvTAP相同的维度、学习率和训练轮次。对于基于NLP的方法, 我们将TAP规则的描述文本作为输入以获取其表示。由于基于GNN的方法和知识图谱方法仅学习触发器和动作的表示, 我们通过MvTAP的融合阶段 (不含Transformer模型) 来获取TAP规则的表示。所有方法均运行5次, 取平均值作为最终结果。

5.2. 实验 结果

我们从灵敏度、特异性、Micro-F1、Macro-F1和准确率方面比较了所有方法的整体性能。表 5 列出了实验结果。最佳结果以粗体标出。根据结果, 我们总结出以下观察:

1. 我们提出的MvTAP框架在准确率、Micro-F1和Macro-F1方面表现良好。
2. MvTAP在准确率、灵敏度、Micro-F1和Macro-F1方面优于单视图方法。具体而言, 在准确率方面, MvTAP相较于开发者视图、用户视图和知识视图中最强的方法, 分别实现了34.65%、1.8%和11.33%的提升。
3. 与最强的多视图方法相比, MvTAP在准确率方面实现了19.28%的提升, 在Micro-F1方面实现了8.55%的提升, 在Macro-F1方面实现了5%的提升, 在特异性方面实现了0.35%的提升。同时, MvTAP在准确率、Micro-F1和Macro-F1方面的性能优于其变体方法。

5.3. 消融 实验

为了研究MvTAP中每个模块的有效性, 我们对MvTAP的三个变体进行了消融实验: **w/o UV**, 即移除了用户视图表示模块, 仅保留开发者视图和知识视图的MvTAP; **w/o DV**, 即移除了开发者视图表示模块, 仅保留用户视图和知识视图; 以及**w/o KV**, 即仅利用用户视图和开发者视图的信息。图 6 展示了它们在Micro-F1、Macro-F1和准确率方面的结果。从结果中, 我们可以得出以下结论:

1. 当移除任一视图时, MvTAP的性能都会下降, 这证明了通过多视角表示学习方法, 同时建模来自不同视图的信息对于用户意图预测是必要的。

² <https://pytorch.org/>.

³ <https://www.dgl.ai/>.

表 5 不同方法在用户意图预测上的实验结果。其中，“DV”、“UV”、“KV”和“MV”分别表示开发者视图、用户视图、知识视图和多视角的缩写。每列的最佳性能已用粗体标出。

特征	方法	灵敏度	特异性	Micro-F1	Macro-F1	准确率
DV	TF-IDF	37.25 ± 0.72	42.91 ± 1.20	39.88 ± 0.85	33.98 ± 0.87	28.89 ± 0.93
	Sentence-BERT	50.45 ± 1.45	96.36 ± 0.28	54.22 ± 1.44	50.61 ± 1.57	40.41 ± 1.97
	TextCNN	57.42 ± 0.34	99.34 ± 0.03	70.17 ± 0.26	62.04 ± 0.60	57.03 ± 0.40
UV	GAT	34.71 ± 3.69	98.59 ± 0.15	46.65 ± 3.49	36.32 ± 3.18	33.14 ± 2.85
	EGAT	39.37 ± 4.85	98.01 ± 0.12	49.44 ± 4.25	40.09 ± 6.06	37.31 ± 4.64
	PNA	71.60 ± 0.92	97.99 ± 0.10	74.74 ± 0.37	71.14 ± 0.74	69.72 ± 0.49
	DGN	67.40 ± 1.23	97.92 ± 0.19	71.72 ± 1.05	64.83 ± 0.63	65.48 ± 1.09
	FastGTNs	46.69 ± 1.29	98.76 ± 2.30	58.95 ± 0.84	36.12 ± 2.10	45.82 ± 1.12
	SeHGNN	75.43 ± 0.67	97.68 ± 0.06	75.43 ± 0.67	71.46 ± 1.26	75.43 ± 0.67
KV	DistMult	37.72 ± 1.24	99.27 ± 0.08	52.17 ± 1.48	33.08 ± 1.80	37.24 ± 1.32
	ComplEx	44.50 ± 2.06	99.07 ± 0.04	57.94 ± 1.99	41.77 ± 1.90	43.34 ± 2.10
	RKE	69.69 ± 2.02	98.84 ± 0.09	76.99 ± 1.05	64.10 ± 4.04	68.97 ± 1.73
MV	TMC	97.16 ± 0.06	93.33 ± 0.86	73.89 ± 2.52	71.13 ± 4.50	49.65 ± 5.42
	RCML	93.32 ± 0.14	90.95 ± 0.68	65.58 ± 1.71	58.86 ± 1.64	34.26 ± 3.22
	KGAN	70.98 ± 0.87	97.88 ± 0.28	74.02 ± 0.79	62.39 ± 1.15	64.38 ± 0.90
	MvTAP-mean	78.35 ± 1.77	98.28 ± 0.13	80.22 ± 0.56	72.19 ± 3.40	75.24 ± 1.37
	MvTAP-concat	78.25 ± 2.09	98.33 ± 0.19	80.34 ± 0.56	72.91 ± 5.18	75.97 ± 1.52
	MvTAP	79.04 ± 1.27	98.22 ± 0.13	80.35 ± 0.50	74.69 ± 1.70	76.79 ± 0.88




图 6. 不同视图组合在 MvTAP 中的影响。




图 7. 任意单个视图在 MvTAP 中的影响。

2. 尽管用户视图对 Micro-F1 和准确率的影响最小，但当它被移除时，性能也会下降，这表明建模触发器与动作之间的依赖关系对预测用户意图是有益的。3. 知识视图比用户视图的影响更大。主要原因是知识图谱提供了关于实体的上下文信息，并帮助模型更好地理解和推断用户的意图。

4. 与其他两种变体相比，无开发者视图在三个指标上的表现最差。这表明理解触发器和动作的功能描述对于预测用户意图是不可或缺的。

我们进一步报告了 MvTAP 在单一视图下的性能，包括用户视图表示 (**w UV**)、开发者视图表示 (**w DV**) 和知识视图表示 (**w KV**)。结果如图 7 所示。可以观察到，MvTAP 在任何单一视图下的性能都逊于其多视图版本。此外，**w KV** 在 Micro-F1 和 Macro-F1 指标上优于 **w UV**。原因是用户视图图的稀疏性阻碍了基于 GNN 的方法学习到充分的表示。从图 7 中明显可见，采用开发者视图的 **w DV** 在所有三个指标上的表现均超过了其他两种视图表示。相反，如图 6 所示，**w/o DV** (即不含开发者视图) 表现出最低的性能，这凸显了开发者视图在准确预测用户意图中不可或缺的作用。这一观察也证实了使用 TextCNN 从

与触发器和动作相关的描述文本中提取语义信息的有效性。

5.4. 参数灵敏度

在本节中，我们分析了 MvTAP 框架中参数的灵敏度。具体来说，我们评估了 MvTAP 在多标签分类任务上关于维度和训练比例的性能。然后，我们评估了训练轮次和学习率对 MvTAP 的影响。

5.4.1. 嵌入维度的影响

我们研究了表示维度 d 对 MvTAP 性能的影响。维度大小从 16 到 256 按 2 的倍数设置。如图 8(a) 所示，我们可以看到随着维度的增加，所有指标都趋于上升，表明性能更好。这是因为更多的表示维度可以编码更多信息。然而，在 $d = 256$ 处 Micro-F1 值的轻微下降可能是由过拟合引起的。维度太高可能导致模型向数据中引入噪声，从而降低性能。我们的实验中使用了 $d = 128$ 的最佳值。

5.4.2. 数据集比例的影响

我们研究了训练比例对 MvTAP 性能的影响。如图 8(b) 所示，随着训练比例的增加，整体呈现上升趋势。这表明 MvTAP 的性能，




图 8. 影响的维度，训练比例，训练轮次，和学习率对多标签分类性能。

就Micro-F1分数而言，随着训练数据的增加而提升。与Micro-F1类似，Macro-F1分数也随着训练比例的增加而上升，这表明更多数据提升了模型在不同类别间的泛化能力。准确率趋势同样是向上的，表明随着更多数据用于训练，模型做出正确预测的整体比例也随之增加。

5.4.3. 训练轮次的影响

我们探究了MvTAP的损失在训练阶段如何下降。如图8(c)所示，损失通常随着训练轮次的增加而减少，这表明模型正在学习并随时间改进。在最初的几个训练轮次中，损失出现了明显的急剧下降。这表明模型能够从初始数据中学习并快速取得显著改进。在最初的急剧下降之后，损失出现了一些波动。在后续的训练轮次中，损失似乎趋于平稳，这表明模型在当前参数下从给定数据集中学习的能力已接近极限。

5.4.4. 学习率的影响

我们对MvTAP的学习率进行了详细分析，这是一个影响收敛质量的超参数。我们使用一系列从0.0001到0.1的预设学习率，来测量MvTAP在每个设置下的Micro-F1和Macro-F1分数。如图8(d)所示，我们观察到在较高的学习率（即0.1和0.05）下，Micro-F1和Macro-F1分数都相对较低。随着学习率从0.01降低到0.001，MvTAP的性能显著提升，并在学习率设置为0.001时达到最佳性能，这表明较低的学习率更有利于在IFTTT数据集和我们的框架配置中进行细致的权重调整。

5.5. 案例研究

我们提出的框架旨在根据用户创建的规则预测用户意图，为TAP规则推荐带来显著益处。为了说明本文描述的框架，我们使用IFTTT数据集进行了一个案例研究。我们随机选择了三条规则，并应用MvTAP将这些规则转换为向量表示。然后，这些表示被用于计算与其他规则的余弦相似度，排名前 K 的规则作为候选规则。由于IFTTT平台最多推荐六条规则， K 被设置为6。我们将MvTAP的推荐结果与IFTTT平台进行了比较，结果呈现在表6中。我们观察到，当用户创建规则“当我接近家时，打开空调”时，IFTTT平台推荐的候选规则全部与位置相关。这很可能是因为该规则的组件中包含位置传感器。然而，用户可能会对这些推荐感到沮丧，因为它们偏离了用户的真实意图。相比之下，MvTAP推荐的规则，如“恒温器风扇开启”和“告诉Alexa打开你的空调”，则与温度相关，这更符合用户控制温度的意图。

为评估MvTAP在TAP规则推荐中的有效性，我们进行了一项聚焦于推荐多样性的定量分析实验。TAP规则推荐的多样性定义为：在推荐规则中，具有相同用户意图的规则不共享相似设备或功能的程度。给定一条用户创建的规则及其由MvTAP生成的表示，我们计算该规则与其他规则之间的余弦相似度，并将前 K 条规则用作推荐列表。为评估MvTAP在推荐多样性方面的性能，我们使用两个指标 $InterLS@K$ 和 $IntraLS@K$ 来量化推荐的多样性，其定义见公式 (21) 和 (22)。 $InterLS@K$ 主要衡量已创建规则与推荐规则之间的多样性，而 $IntraLS@K$ 则衡量推荐列表中规则之间的多样性。图9展示了性能对比

表 6MvTAP 与 IFTTT 平台 推荐结果前 6 名。

		IFTTT	我们的 框架
给定 规则	le	自动 氮 nm 执行 你的 r 安卓 当 你 获取 back 家	将 你的 Ecobee 设置为 房间 m 温度 通过 Alexa
推荐	rules	在 Google 日历中 追踪 你的 工作地点 工时	恒温器 风扇 开启
		Log 如何 多 uch tim e 您 花费 在 特定 地点 例如 在 办公室 或 家 中 a 电子表格	设置 你 r Honeywell therm 个 特定 温 m 度 如果 外部 温度 下降
		静音 你 r Android 手机 当 你 到达 工 时 , 告诉 作地点	Alexa 打开 你的 空 rn on 调 。 ir
		打开 你的 r ligh 空调 在 自动 icall y 当 你 到达 家	空调 当 到 家时 打开 空调 oom 温度 升高 a bove 25 °C
		追踪 你 r 工作地点 氮 ours in i 操作系统 日历	Wiser Away M ode O N - Geofencing - leave locatio n
给定 rule		If 你 到达 ive cl 关闭 你的 设备 h 家 , 则 hen 禁用 你的 Myf 氧 系统 m	Open 车库 门 使用 亚马逊 Alexa
推荐	rules	自动 执行 nm 为你 计算 r Android 当 你 收到 back 家	Wh e n 我 离开 家 y h , lose m y 车库 door
		追踪 你 r 工作地点 氮 ours in 谷歌 日历	A 自动解锁 door 当 我 到达 我的 氢 屋 , 打 n my 车库 门 r
		Log 你 在 uch tim e 特定 地点 花费 多少时间 例如 在 办公室 里 r 家 中 a 电子表格	我 马上到 了 ! 打开 门 !
		静音 你 r Android 手机 当 你 在 时到达 工作地点	When you leave h 到家时 , 启动 安全 mode
		打开 你的 r ligh ts 开启 自动模式 icall y 当 你 到达 家	
给定 rule		追踪 你 r 工作地点 氮 ours in i 操作系统 日历 r	
推荐 规则		更换 您的 H 灯泡 为 智能 tch purple when 你 获得 一个 新 w 关注者	Tell Google Assi 时 将 设置 温 e 场景 能 描述 在 特定 l 件时 .
		自动 调 rn your lights on 在 日落时	你 曲目/艺术家 x 被 播放 在 n Spotify上, 根据色调 改变 颜色 。 选择 颜色
		打开/关 ff your lights with on n 你的 智 hone	Match your light's col 或 向 你 r Instagram when 你 使用 一个 规格 ific hashtag
		打开 你的 r lights on 自动 icall y 当 你 的 抵达 家	改变 颜色 wh 当 有人 发送 me a 消息
		Tell Alex rt th e 派对 使用 一个 氮 ue light color show	
		„Alexa, 触发 r self 销毁 ”	
		打开 氧 ff your Hue 灯光 当 you leave home	

在 *InterLS@5*、*InterLS@10*、*InterLS@20* 和 *InterLS@30* 和方面的推荐结果。我们可以观察到，MvTAP框架在所有指标上都优于对比方法，表明其在已创建规则与推荐规则之间具有更优的多样性。推荐列表中规则间推荐多样性的结果如图 10所示，MvTAP在*InterLS@10*、*InterLS@20*和 *InterLS@30*方面取得了最低的分

数，这证明了其相比其他方法能够提供更多样化推荐的能力。更高的推荐多样性意味着MvTAP可以向用户推荐使用不同设备或功能的规则来实现指定意图。

为了进一步验证MvTAP的性能，我们使用t-SNE（范德马滕与辛顿，2008）进行了一项可视化实验，将TAP规则的高维表示投影到二维空间中。这种可视化有助于我们理解不同规则在嵌入空间中的分布情况，并突显了MvTAP所捕捉到的多样性。如图 11所示，我们观察到，尽管规则 R_1 和 R_2 由不同功能的不同设备提供，但它们具有相同的用户意图（即安全），并且在嵌入空间中彼此接近。这表明MvTAP能够识别并对齐满足相似用户意图的功能与服务。这种能力对于增强推荐的多样性至关重要，因为它使得该框架能够捕捉规则之间更深层次的、由意图驱动的联系。



6. 讨论

在本节中，我们首先分析第5.2节中观察到的实验结果。然后，我们讨论MvTAP与类似工作地点相比的优势与局限性。

6.1. 实验 结果 分析

根据第5.2节观察到的结果，我们得出以下见解：

1. 从第一个结果中，我们发现MvTAP在多标签分类任务上表现良好，这证明了使用多视图表示学习来预测TAP中用户意图的有效性。
2. 第二个结果表明，在灵敏度、准确率、Micro-F1和Macro-F1方面，多视图方法优于单视图方法。这是合理的，因为单一视图包含的语义信息有限。同时，多视图方法整合了数据的多个视图，其中包含的语义信息在不同视图之间可能形成互补。此外，MvTAP在开发者、用户和知识视图方面均显著优于最强的基线方法。MvTAP的主要优势在于其学习TAP规则表示以及规则与用户意图之间关联的能力。

图 9. TAP 规则 推荐 在 $InterLS@K$ 度量 中的 多样性 结果。图 10. TAP 规则 推荐 在 $IntraLS@K$ 度量 中的 多样性 结果。




图11. TAP规则表示的TSNE可视化。 R_1 和 R_2 分别表示规则“如果发生Nest Protect烟雾紧急事件则录制视频”和“如果我的安卓手机连接到我的个人WiFi网络，则禁用Myfox系统”。

3. 从第三个结果来看，MvTAP在四个指标上优于其他多视图方法，这表明我们提出的框架能更好地整合每个视图提供的独特方面，从而更准确地从不同视图预测用户意图。具体来说，我们观察到MvTAP在灵敏度指标上的性能比TMC差。主要原因是TMC在证据层面动态整合意见，侧重于不确定性和可信度，这可能使其对检测正确的意图标签特别敏感。

4. MvTAP的性能优于MvTAP-concat和MvTAP-mean，这表明Transformer模型在整合来自不同视图的触发器和动作表示方面，优于拼接和均值方法。主要原因是MvTAP-concat和MvTAP-mean无法捕捉跨视图的关联，而MvTAP可以通过Transformer模型在三个视图的触发器或动作之间建立相互关系。

6.2. MvTAP 的 适用性

MvTAP旨在整合来自TAP规则的多个数据视图，以预测用户意图，从而增强如IFTTT和Zapier等支持TAP的平台的能力。通过准确理解和预测用户意图，这些平台可以推荐与用户需求和偏好紧密契合的规则。例如，当用户创建一条规则“如果检测到我离开家，则关闭空调”时，MvTAP能够识别出用户意在节能。它可以帮助TAP平台推荐相关规则，例如“太阳升起时关闭加热器”。与现有平台仅基于相似的触发器或动作（例如“当室温降至26 °C时关闭空调”或“当你到家时自动打开灯”）来推荐规则不同，这些推荐往往无法匹配用户的真实意图，从而降低了用户体验。相比之下，MvTAP提高了用户在TAP平台上找到满意规则的效率。

将多个触发器和动作组合起来的规则，可以简化原本需要多个独立规则才能完成的流程。这种整合减少了管理众多独立自动化系统的开销，并提高了整体效率。MvTAP能够识别

众多规则背后的用户意图，并将具有相似意图的规则聚类，从而帮助开发者设计出包含多个触发器和动作、满足特定用户意图的复杂规则。例如，规则“如果是晚上7点，则打开供暖系统”和“如果室外温度低于5 °摄氏度，则将供暖温度提高2度”具有相同的用户意图，即调节室内温度，因此可以合并为一条规则：“如果是晚上7点且室外温度低于5 °摄氏度，则将供暖温度提高2度”。

6.3. MvTAP 的 优势 与 局限

TAP规则的创建主要依赖于用户手动创建，这非常耗时。尽管规则生成、规则合成和规则推荐方法提高了规则创建效率，但它们只能识别用户创建规则的显性需求，例如关闭空调，而忽略了用户创建规则行为背后隐藏的意图，即节能。因此，这些传统方法推荐的规则具有相同的设备和功能。MvTAP旨在根据用户创建的规则预测用户意图，这可以帮助TAP规则推荐系统实现跨设备和跨功能的规则推荐。此外，MvTAP能够整合多视图（用户、开发者、知识）以更全面地理解用户意图。这与许多现有的TAP规则创建方法形成对比，后者通常只关注一两个视图的信息，例如开发者视图提供的描述文本，而没有考虑三个视图的协作。通过整合多视图，MvTAP实现了用户需求、设备能力和领域知识的综合，从而提高了用户意图预测的准确率。

本文提出的用户意图预测框架存在两方面局限性。在数据方面，MvTAP 要有效学习并做出准确预测，需要所有视图的高质量数据。若数据稀疏或质量较低，尤其是在开发者和知识视图方面，MvTAP 的性能可能会受到影响。在计算效率方面，由于其复杂的多视角和基于Transformer的架构，与更简单、更直接的TAP系统相比，MvTAP 的实现和维护可能更具挑战性。

7. 结论

本文提出了一种用于TAP用户意图预测的端到端基于多视图表示学习的框架——MvTAP。MvTAP 通过构建三个视图：用户视图、开发者视图和知识视图，克服了TAP中国有的复杂性，例如触发器与动作之间的上下文依赖关系、有限的功能描述以及实体相关常识知识的缺乏。我们开发了一种基于Transformer的多视图表示学习方法来获取TAP规则的表示。最后，将用户意图预测表述为一个多标签分类任务。我们在IFTTT数据集上进行了全面的实验，实验结果证明了我们框架的有效性。

8. 未来 方向

本文的一项进一步改进是增强数据隐私和安全。由于TAP涉及敏感用户数据，未来的工作应侧重于实施强大的隐私保护机制。可以探索差分隐私和安全多方计算等技术，以确保在训练和推理过程中用户数据的机密性。一个可靠且值得信赖的TAP系统可以吸引更多用户，从而增加收入。此外，一个关键的重点领域应是对MvTAP增强的经济影响进行实证验证。

TAP规则推荐。当必要的数据和资源可用时，我们可以衡量在各种行业（如智能家居自动化和工业物联网）中使用MvTAP的经济效益，旨在量化效率的提升和运营成本的降低。在未来几年，人形机器人预计将在各个领域扮演越来越重要的角色。它们感知环境并与之交互的能力，为推进人机交互环境中的自动化和协作开辟了重大机遇。虽然此主题超出了当前研究的范围，但它是一个值得关注的领域，因为本文讨论的技术未来可能被用于人形机器人应用。

CRedit 作者 贡献 声明

吴刚： 概念化，方法论，验证，可视化，撰写 – 初稿。**胡亮：** 监督，资源。**胡宇潇：** 软件，验证。**邢永恒：** 撰写 – 初稿，调查。**王峰：** 调查，方法论，概念化，数据管理。

利益冲突 声明

作者声明，他们不存在任何已知的可能影响本论文所报告工作的竞争性经济利益或个人关系。

致谢

本工作由吉林省科技发展计划（项目20220101115JC）资助。

数据 可用性

数据将根据请求提供。

参考文献

- Beaini, D., Passaro, S., Létourneau, V., Hamilton, W., Corso, G., & Liò, P. (2021年). 方向图网络. 载于国际机器学习大会 (pp. 748–758). PMLR. Chakraborty, D., Pandey, D., Verma, R., & Dhanda, N. (2023年). BumbleBee: 多功能语音助手. 载于智能系统国际会议: 计算创新 (pp. 185–197). 施普林格. Corno, F., De Russis, L., & Monge Roffarello, A. (2019年). RecRules: 为最终用户开发推荐IF-THEN规则. AC M智能系统与技术汇刊, 10(5), 1–27. Corno, F., De Russis, L., & Monge Roffarello, A. (2020年). TAPrec: 通过动态推荐支持触发-动作规则的组合. 载于第25届智能用户界面国际会议论文集 (pp. 579–588). Corno, F., De Russis, L., & Monge Roffarello, A. (2021年). 从用户意图到物联网中的if-then规则. ACM信息系统汇刊, 39(4), 1–33. Corso, G., Cavalleri, L., Beaini, D., Liò, P., & Veličković, P. (2020年). 图网络的主邻域聚合. 神经信息处理系统进展, 33, 13260–13271. Desolda, G., Ardito, C., & Matera, M. (2017年). 赋能最终用户定制其智能环境: 模型、组合范式与领域特定工具. ACM Transactions on Computer-Human Interaction, 24(2), 1–52. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019年). BERT: 用于语言理解的深度双向Transformer预训练. 载于计算语言学协会北美分会. Gilmer, J., Schoenholz, S. S., Riley, P. F., Vinyals, O., & Dahl, G. E. (2017年). 用于量子化学的神经消息传递. 载于国际机器学习大会 (pp. 1263–1272). PMLR. Han, Z., Zhang, C., Fu, H., & Zhou, J. T. (2022年). 基于动态证据融合的可信多视图分类. IEEE模式分析与机器智能汇刊, 45(2), 2551–2566. Hu, L., Wu, G., Xing, Y., & Wang, F. (2019年). Things2Vec: 物联网中基于图表示学习的语义建模. IEEE物联网期刊, 7(3), 1939–1948.

- Huang, Z., Li, J., Zhang, H., Zhang, C., & Yu, G. (2023). TAP-AHGNN: 一种基于注意力的异构图神经网络, 用于触发-动作编程平台上的服务推荐. 载于国际智能计算会议 (第141–152页). 施普林格. Kim, Y. (2014). 用于句子分类的卷积神经网络. 载于2014年自然语言处理经验方法会议论文集 (第1746–1751页). 计算语言学协会. King, E., Yu, H., Lee, S., & Julien, C. (2024). Sasha: 智能家居中基于大语言模型的创造性目标导向推理. ACM交互式、移动、可穿戴和普适技术论文集, 8(1), 12:1–12:38. <http://dx.doi.org/10.1145/3643505>. Kingma, D. P., & Ba, J. (2015). Adam: 一种随机优化方法. 载于第三届国际学习表征会议, ICLR 2015, 美国加州圣地亚哥, 2015年5月7–9日, 会议论文集. Li, F., Huang, J., Gao, Y., & Dong, W. (2023). ChatIoT: 使用ChatGPT零代码生成基于触发-动作的物联网程序. 载于第七届亚太网络研讨会论文集 (第219–220页). Li, Y., Yang, M., & Zhang, Z. (2018). 多视图表示学习综述. IEEE知识与数据工程汇刊, 31(10), 1863–1883. Liu, L., Chen, W., Liu, L., Zhang, K., Wei, J., & Yang, Y. (2021). TAGen: 通过挖掘事件轨迹为智能家居生成触发-动作规则. 载于面向服务的计算: 第19届国际会议, ICSOC 2021, 线上会议, 2021年11月22–25日, 论文集 (第652–662页). 施普林格. Liu, L., Chen, W., Wang, T., Wang, W., Wu, G., & Wei, J. (2023). 通过挖掘历史事件日志为智能家居生成以场景为中心的TAP规则. 载于2023年IEEE国际网络服务会议 (第21–27页). IEEE. Van der Maaten, L., & Hinton, G. (2008). 使用t-SNE进行数据可视化. 机器学习研究杂志, 9(11). Ramos, J., et al. (2003). 使用tf-idf确定文档查询中的词相关性. 载于第一届机器学习教学会议论文集: 第242卷, (第1期), (第29–48页). Citeseer. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: 使用孪生BERT网络的句子嵌入. 载于K. Inui, J. Jiang, V. Ng, & X. Wan (编), 2019年自然语言处理经验方法会议暨第九届自然语言处理国际联合会议论文集 (第3980–3990页). 计算语言学协会, <http://dx.doi.org/10.18653/v1/D19-1410>. Shao, Z., Xu, Y., Wei, W., Wang, F., Zhang, Z., & Zhu, F. (2022). 具有多视图表示学习的异构图神经网络. IEEE知识与数据工程汇刊, 35(11), 11476–11488. Shoombuatong, W., Homdee, N., Schaduagratt, N., & Chumnanpuen, P. (2024). 利用元学习方法提升Nav阻断肽预测的准确率. 科学报告, 14(1), 4463. Speer, R., Chin, J., & Havasi, C. (2017). Conceptnet 5.5: 一个开放多语言常识知识图谱. 载于AAAI人工智能会议论文集: 第31卷, (第1期). Trouillon, T., Welbl, J., Riedel, S., Gaussier, É., & Bouchard, G. (2016). 用于简单链接预测的复数嵌入. 载于国际机器学习大会 (第2071–2080页). PMLR. Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., & Bengio, Y. (2018). 图注意力网络. 载于国际学习表征会议. Wang, L., Dong, K., Gu, X., Ling, Z., & Yang, M. (2023). 面向家庭物联网的基于轻量级手势的触发-动作编程. 载于2023年第26届计算机支持的协同设计国际会议 (第959–964页). IEEE. Wang, G., Guo, H., Li, A., Liu, X., & Yan, Q. (2023). 联邦物联网交互漏洞分析. 载于2023年第39届IEEE国际数据工程会议. IEEE. Wang, G., Ivanov, N., Chen, B., Wang, Q., Nguyen, T., & Yan, Q. (2023). 面向异构智能家居规则数据的交互式威胁检测的图学习. ACM数据管理汇刊, 1(1), 1–27. Wen, J., Liu, C., Deng, S., Liu, Y., Fei, L., Yan, K., et al. (2023). 具有不完整标签和缺失视图的深度双重不完整多视图多标签学习. IEEE神经网络与学习系统汇刊, 1–13. <http://dx.doi.org/10.1109/TNNLS.2023.3260349>. Wu, G., Hu, L., Mao, X., Xing, Y., & Wang, F. (2024). 一种基于异构信息网络嵌入的数据融合框架, 用于物联网中的触发-动作编程. Expert Systems with Applications, 235, 文章121065. Wu, G., Wang, M., & Wang, F. (2024). TAP with ease: 一种基于多模态表示学习的触发-动作编程通用推荐系统. 应用软计算, 166, 文章112163. Xing, Y., Hu, L., Zhang, X., Wu, G., & Wang, F. (2021). 基于非负矩阵分解的异构图嵌入方法, 用于物联网中的触发-动作编程. IEEE工业信息学汇刊, 18(2), 1231–1239. Xu, C., Si, J., Guan, Z., Zhao, W., Wu, Y., & Gao, X. (2024). 可靠的对立多视图学习. 载于AAAI人工智能会议论文集: 第38卷, (第14期), (第16129–16137页). Yang, Y., Huang, C., Xia, L., & Li, C. (2022). 用于推荐的知识图谱对比学习. 载于第45届国际ACM SIGIR信息检索研究与发展会议论文集 (第1434–1443页). Yang, M., Li, Y., Huang, Z., Liu, Z., Hu, P., & Peng, X. (2021). 具有噪声鲁棒对比损失的部分视图对齐表示学习. 载于IEEE/CVF计算机视觉与模式识别会议论文集 (第1134–1143页)。

- Yang, X., Yan, M., Pan, S., Ye, X., & Fan, D. (2023). 简单高效的异构图神经网络。载于 AAAI 人工智能会议论文集: 第37卷, (第9期), (第10816–10824页)。Yang, B., Yih, W., He, X., Gao, J., & Deng, L. (2014). 知识库中用于学习和推理的实体与关系嵌入。载于国际学习表征会议。Yao, Y., Kamani, M. M., Cheng, Z., Chen, L., Joe-Wong, C., & Liu, T. (2023). FedRule: 基于图神经网络的联邦规则推荐系统。载于第八届 ACM/IEEE 物联网设计与实现会议论文集 (第197–208页)。Yao, Z., Li, X., Gao, J., Sadler, B., & Sun, H. (2019). 通过分层强化学习对 if-then 配方进行交互式语义解析。载于 AAAI 人工智能会议论文集: 第33卷, (第01期), (第2547–2554页)。Yu, H., Hua, J., & Julien, C. (2021). 分析 IFTTT 配方以研究人类如何使用物联网设备。载于第19届 ACM 嵌入式网络传感器系统会议论文集 (第537–541页)。
- Yun, S., Jeong, M., Yoo, S., Lee, S., Sean, S. Y., Kim, R., et al. (2022). 图变换器网络: 学习元路径图以改进图神经网络。神经网络, 153, 104–119。Yusuf, I. N. B., Jiang, L., & Lo, D. (2022). 通过领域自适应序列到序列学习准确生成触发-动作程序。载于第30届 IEEE/ACM 国际程序理解会议论文集 (第99–110页)。Zhang, L., He, W., Martinez, J., Brackenbury, N., Lu, S., & Ur, B. (2019). AutoTap: 使用 LTL 属性合成与修复触发-动作程序。载于2019年第41届 IEEE/ACM 国际软件工程会议 (第281–291页)。IEEE。Zhang, L., He, W., Morkved, O., Zhao, V., Littman, M. L., Lu, S., et al. (2020). Trace2tap: 从行为轨迹合成触发-动作程序。ACM 交互式、移动、可穿戴和普适技术论文集, 4(3), 1–26。Zhao, M., Wu, Q., Ma, E., Shen, B., & Chen, Y. (2021). 物联网编程中上下文感知的对话式触发-动作规则推荐。国际软件工程与知识工程杂志, 31(10), 1517–1538。Zhong, Q., Ding, L., Liu, J., Du, B., Jin, H., & Tao, D. (2023). 面向基于方面的情感分析的多视图表示学习的知识图谱增强网络。IEEE 知识与数据工程汇刊, 35(10), 10098–10111。Zhou, Y., Li, J., Chi, J., Tang, W., & Zheng, Y. (2022). Set-CNN: 一种基于语义扩展的短文本分类文本卷积神经网络。基于知识的系统, 257, 文章编号109948。