



边缘大语言模型：一项全面调研

江山¹ · 薛晨 · g 周¹ · 张明金² · 徐长福³ · 廖国成¹ · 陈建国¹ · 曹建农

2

收稿日期：2025年10月1日 / 接受日期：2025年12月17日 / 网络首发日期：2026年1月29日 ©
中国计算机学会 (CCF) 2026

摘要

大语言模型的范式正在经历从集中式云端到网络边缘的根本性转变，其驱动力是对数据隐私、低延迟交互和离线可靠性的迫切需求。然而，在资源受限的边缘设备（如智能手机和车辆）上部署资源密集型大语言模型，是一项重大的技术挑战。本调研从整体、端到端的工程视角审视边缘大语言模型，系统性地规划了从设备端适配到高效推理的路径。我们从新兴的微调技术开始，例如参数高效微调和联邦学习，这些技术对于个性化至关重要。本工作的核心是深入探讨高效推理的三大支柱：模型压缩（量化、剪枝和蒸馏）、优化的架构设计（例如注意力机制变体）以及关键的运行时和系统级优化（例如键值缓存管理、推测解码和内存分页）。我们进一步建立了一个整体评估框架，并调研了跨不同领域蓬勃发展的应用。与现有可能侧重于更狭窄主题（如安全、特定设备类别或高层未来概念）的综述不同，本调研为研究者和从业者提供了一份实用、统一的路线图。它弥合了算法理论与系统级实现之间的差距，为构建下一代私密、响应迅速且智能的边缘大语言模型应用提供了全面指南。

关键词 大语言模型 · 边缘大语言模型 · 设备端人工智能

1 引言

大语言模型 (LLMs) (Naveed等人, 2025) 的出现, 包括GPT (Brown等人, 2020) 和Llama (Touvron等人, 2023), 标志着人工智能 (AI) 领域的一个变革性时刻, 在理解和生成类人文本方面展现出前所未有的能力。传统上, 这些庞大的模型被局限于功能强大的集中式数据中心, 用户通过云端 (Hu等人, 2024) 访问它们。然而, 一场重大的范式转变正在进行中: 将大语言模型推理甚至适配从云端转移到网络边缘 (Lin等人, 2025), 例如智能手机、个人电脑、物联网 (IoT) 设备和车辆。

向边缘大语言模型的转型, 是由一系列关键用户和应用需求汇聚驱动的, 这些需求是云端中心化模型无法完全满足的。首要的是数据隐私, 因为设备端处理确保了敏感的个人或专有数据始终处于用户控制之下 (Das et al. 2025)。其次是低延迟, 这对于增强现实和车载助手等实时交互式应用至关重要, 因为网络往返

陈建国 chenjk33@mail.sysu.edu.cn 江山
jiangsh73@mail.sysu.edu.cn 周学成
zhouxch33@mail2.sysu.edu.cn 张明金
cs-mingjin.zhang@polyu.edu.hk 徐长福
xuchangfu@jxufe.edu.cn 廖国成
liaogch6@mail.sysu.edu.cn 曹建农
jiannong.cao@polyu.edu.hk¹ 中山大学软件工程学院,
中国珠海² 香港理工大学计算学系, 中国香港特别行政区
³ 江西财经大学软件与物联网工程学院, 中国南昌

成本高昂且速度极慢 (Fu 等人, 2024)。此外, 边缘大语言模型提供了更高的可靠性和离线功能-性, 使其能够在网络连接不稳定或完全中断的环境中持续运行 (Shen 等人, 2024)。最后, 它们实现了深度个性化, 允许模型安全地从用户的本地上下文和《数据》中学习, 提供真正定制化的体验 (Chen 等人, 2024)。

该主题日益增长的重要性在近期涌现的大量文献中显而易见。已有数篇优秀的调研开始描绘这一新领域, 每篇都有其宝贵且独特的侧重点 (Friha 等人, 2024; Qu 等人, 2025; Luo 等人, 2025; Chen 等人, 2025; Zheng 等人, 2025)。例如, Friha 等人 (2024) 提供了一个全面的概述, 并着重强调了安全与可信度这一关键方面。Qu 等人 (2025) 则将焦点缩小至移动边缘, 深入探讨了智能手机及类似设备所面临的挑战与解决方案。其他工作则采用了更具前瞻性的概念性方法, 探索了多个大语言模型的协同编排以及实现边缘通用智能 (EGI) 的长期愿景 (Luo 等人, 2025; Chen 等人, 2025)。尽管像 Zheng 等人 (2025) 的论文也对设计、执行和应用进行了广泛的回顾, 但本调研通过其深度融合、端到端的工程视角而独树一帜。

尽管上述调研很重要, 但它们要么关注的主题过于狭窄, 例如安全 (Friha 等人, 2024) 和特定设备类别 (Qu 等人, 2025), 要么仅介绍高层次的未来概念 (Luo 等人, 2025; Chen 等人, 2025)。在本文中, 我们提供了一个整体视角, 系统-性地将模型中心的优化与系统级部署的现实情况联系起来。本调研旨在为工程师和应用研究人员提供一份实用指南, 弥合高层次算法概念 (例如, 量化、高效架构) 与使其实际工作所面临的细-粒度、实现层面的挑战 (例如, 键值缓存管理、异构计算调度和按需内存分页) 之间的差距。我们提供了一个统一的流程, 详细阐述了一个大语言模型从在设备上的初始适配到最终高效执行的完整历程。通过涵盖整个生命周期, 我们为构建稳健高效的边缘大语言模型-系统提供了一份当代路线图。系统。

图 1 描绘了本调研的纲要。第 2 节介绍了边缘计算和大语言模型的基本概念, 概述了定义边缘大语言模型领域的核心动机与挑战。第 3 节深入探讨了在资源受限的硬件上适配和个性化大语言模型的方法, 涵盖参数高效微调、联邦学习、协同边缘-云范式, 以及将边缘大语言模型与用户偏好对齐。第 4 节详述了模型压缩、高效架构设计以及运行时/系统级优化的关键技术

这些技术使得设备端推理成为可能。第 5 节建立了一个评估边缘大语言模型的框架, 涵盖了针对特定任务模型性能的指标以及关键的系统效率指标, 如延迟、内存使用和能耗。第 6 节展示了该技术在多个领域的变革性影响, 包括消费电子、智能交通、智慧医疗和工业 4.0。第 7 节总结了本调研, 讨论了激动人心的未来可能性, 如超个性化和多模态推理, 同时也强调了将塑造下一波研究浪潮的关键未解难题。

本调研的主要贡献如下:

- 提供边缘大语言模型的端到端工程路线图。我们为边缘大语言模型提供了一个全面、统一的流程, 系统性地覆盖了从微调、适配到高效推理的整个生命周期。
- 在边缘大语言模型领域, 连接算法理论与系统级实现。本调研将高层次的算法概念 (如量化、高效架构) 与在边缘设备上部署的细粒度、实际挑战 (如KV缓存优化、内存分页和热管理) 联系起来。
- 深入探讨高效的边缘大语言模型推理。我们详细阐述了在边缘实现可行推理的三大核心支柱: 模型压缩 (量化、剪枝、蒸馏)、高效架构设计 (注意力变体, 如MQA和GQA) 以及运行时/系统优化 (推测解码、算子融合)。
- 建立边缘大语言模型的评估与应用框架。我们提出了一个用于评估边缘大语言模型的结构化框架, 涵盖模型性能基准测试 (如MMLU) 和关键系统效率指标 (延迟、内存和能耗), 同时调研了跨消费电子和医疗保健等不同领域的关键应用。

2 预备知识

大语言模型与边缘计算的融合标志着人工智能领域一次重大的范式转变, 将强大的能力从集中式数据中心转移到生成《数据》的设备和传感器所在之处。本节提供了理解这一融合所需的基础背景。我们首先分别定义边缘计算和大语言模型的核心概念。随后, 我们将探讨




图 1 调研大纲

在网络边缘部署大语言模型的动机，并概述边缘大语言模型所带来的重大挑战。

2.1 边缘计算基础

边缘计算是一种分布式计算范式，它将计算和数据存储带到更靠近数据源的地方 (Tu et al. 2025)。其主要目标是将部分工作负载从遥远的、集中式的云端服务器转移到网络边缘，更靠近生成数据的用户和设备。这种邻近性减少了数据必须传输的距离，从而解决了传统云计算架构中固有的高延迟和网络带宽限制等问题。

2.1.1 关键概念

边缘生态系统由三个关键组件构成，它们形成了一个分层架构：终端设备、边缘服务器和

从下到上依次是微云。首先，终端设备是位于网络最边缘的数据源，包括智能手机、可穿戴设备、智能车辆和工业机器人。终端设备通常在处理能力、内存和电池续航方面资源受限。其次，边缘服务器（也称为边缘节点）是比云端更靠近终端设备的中间计算资源。边缘服务器可以以多种形式部署，例如车载网络中的路边单元、工厂中的本地服务器、智能建筑中的网关或蜂窝网络的基站。它们聚合并预处理来自多个终端设备的数据，然后可能将关键结果转发到云端。微云，被称作“盒子里的数据中心”，是一个位于互联网边缘的小型、本地化的云数据中心。其目的是为附近的移动设备提供强大、低延迟的云计算资源，从而在设备和核心云之间有效地创建一个中间层。

2.1.2 边缘计算范式

虽然经常互换使用,但有两个不同的术语描述了边缘概念的具体实现:多接入边缘计算(MEC)和雾计算。一方面,MEC最初名为移动边缘计算,是由欧洲电信标准协会(ETSI)定义的标准(Zhang等人,2022)。MEC是一种网络架构,能够在蜂窝网络的边缘提供云计算能力。通过在诸如4G/5G基站等位置部署服务器,MEC为移动应用提供超低延迟和高带宽接入,使其成为联网车辆和增强现实应用的理想选择(Chen等人,2024)。另一方面,雾计算是一个更广泛的概念,它通过更分布式和层次化的架构扩展了云到物连续体(Mouradian等人,2017)。它不仅涵盖网络边缘,还包括设备本身,在终端设备和云端之间创建了一个多层网状的计算、存储和网络资源。虽然MEC通常由运营商管理且距离用户仅一跳,但雾计算可以更灵活地部署在更广泛的地理区域,例如智慧城市,并且可以涉及节点之间的点对点通信。

2.2 大语言模型基础

大语言模型是一类先进的深度学习模型,专门为理解、生成和处理人类语言而设计(Thirunavukarasu等人,2023)。诸如GPT(生成式预训练变换器)系列(Brown等人,2020)、Llama(Touvron等人,2023)和BERT(Liu等人,2019)等模型已在广泛的自然语言处理任务中展现出卓越的能力。

2.2.1 Transformer和注意力机制

大多数现代大语言模型背后的基础创新是Transformer架构(Vaswani等人,2017)。与依赖顺序处理的先前架构(如循环神经网络(Yu等人,2019)或长短期记忆网络(Greff等人,2016))不同,Transformer并行处理整个数据序列。其强大能力归功于自注意力机制。

自注意力机制使模型能够评估输入序列中不同词语(或标记)的相对重要性(Wang et al. 2020)。对于每个标记,模型会计算注意力分数,以决定对序列中其他标记施加多少关注,从而使其能够捕捉复杂的上下文关系,即使跨越长距离也能实现。这种动态创建上下文感知表征的能力,正是大语言模型如此强大的原因。

2.2.2 预训练与微调

大语言模型的开发通常涉及两个主要阶段:预训练和微调。一方面,预训练是初始的、计算量巨大的阶段,模型在此阶段学习通用的语言模式、语法、事实和推理能力(Guo等人,2020)。预训练是在大量未标记的文本和代码数据集上使用自监督目标完成的,例如预测序列中的下一个词(因果语言建模)或填充被遮蔽的词(掩码语言建模)。其结果是产生一个多功能的基础模型,该模型对语言有广泛的理解。另一方面,在预训练之后,基础模型会针对特定的下游任务或领域进行调整,这被称为微调,这是一个监督学习过程,使用一个更小、带标签的数据集来优化模型的权重(Chen等人,2023)。例如,一个通用模型可以在客户服务对话记录的数据集上进行微调,从而成为一个专门的聊天机器人。

2.3 边缘大语言模型的动机

传统以云端为中心的部署大语言模型方法,即设备向远程服务器发送查询并等待响应,存在若干严重缺陷。直接在边缘设备上运行大语言模型(这种做法称为设备端人工智能)的动机在于需要克服这些局限(Yu等人,2024)。关键驱动因素包括:

- **数据隐私与安全:** 这是一个主要动机。通过在用户设备上本地处理数据,敏感信息(如个人消息、健康数据或机密商业文档)永远不会传输到云端。这从根本上降低了外部服务器数据泄露的风险,并有助于组织遵守数据隐私法规。
- **低延迟:** 对于许多应用而言,实时交互至关重要。将数据发送到云端进行推理会因往返时间而引入网络延迟,这对于实时翻译、车载语音助手或交互式增强现实体验等用例来说可能是个问题。设备端处理消除了网络延迟,实现了近乎实时的响应。
- **网络带宽减少:** 持续向云端流式传输数据,例如用于远程监控的视频或用于分析的传感器读数,会消耗大量网络带宽且成本高昂。边缘大语言模型在本地处理数据,仅需传输少量最终结果或元数据,从而大幅减轻网络基础设施的负载。

● 提升的可靠性与离线功能：依赖云端的应用在无互联网连接时会失效。边缘大语言模型可以在连接不稳定或无连接的区域可靠运行。此特性对于偏远工业现场、车辆、飞机及其他类似环境中的应用至关重要。

● 个性化：设备端人工智能允许模型使用用户的本地数据（例如电子邮件、笔记、习惯）进行安全、持续的定制。它能够创建一个真正个性化的助手，在不损害隐私的前提下理解用户的上下文和偏好。

2.4 边缘大语言模型的核心挑战

尽管动机充分，但由于大语言模型巨大的资源需求与边缘硬件有限能力之间存在明显的不匹配，在边缘设备上部署大语言模型面临着巨大的技术挑战，具体如下：

● 内存：现代大语言模型拥有数十亿参数，加载和运行可能需要数百千兆字节的内存。边缘设备通常只有几千兆字节的可用随机存取内存，使得直接部署大模型变得不可行。

● 计算：Transformer架构内部的矩阵乘法在每秒浮点运算次数方面计算成本高昂。边缘设备配备低功耗中央处理器、图形处理器或专用加速器，其计算吞吐量仅为数据中心图形处理器的一小部分，导致推理速度较慢。

● 能耗：高计算负载直接转化为高功耗。运行一个大语言模型

在电池供电设备上推理会迅速耗尽电池电量，严重限制其实际可用性和运行时长。研究表明，设备端推理消耗的能量可能远高于从远程服务器获取结果，这凸显了优化的必要性。

● 硬件与软件异构性：边缘生态系统极其多样化，包含大量具有不同处理器（例如高通、苹果和ARM）、操作系统（例如安卓、macOS和嵌入式Linux）以及可用软件库的设备。这种碎片化使得开发、优化和部署一个能在所有平台上高效运行的单一解决方案变得困难。

2.5 用于大语言模型部署的典型边缘设备

边缘设备这一术语涵盖了广泛且异构的硬件谱系。部署大语言模型的可行性及优化技术的选择，从根本上与目标硬件的具体能力紧密相关。例如，在英伟达Jetson上有效的策略，对于资源受限的微控制器来说可能完全不切实际。

为了在本调研中提供更具结构性和意义的分析，我们根据计算能力、内存和能耗限制，将边缘领域划分为三个不同的层级。该分类法详见表1，使我们能够将特定的硬件配置映射到可行的大语言模型规模。虽然高性能的一级设备在重度优化下可能运行700亿参数模型，而像树莓派这样的高端三级设备可能处理接近30亿参数的模型，但典型的用例反映了每个层级的核心限制。该分类法将作为参考点，用于在后续章节中关联方-法与挑战，阐明哪些技术适用于哪一类设备。

表 1 用于大语言模型部署的边缘设备三个层级

类别	示例硬件	典型限制	可行性LLMs
第一层级： 高性能 性能 edge	英伟达Jetson系列（例如，AGX Orin）； 高端笔记本-TOPS（例如，配备RTX GPU）	内存：16–64GB； 算力：专用GPU/神经网络处理器（>50 TOPS）； 功耗：20–100瓦	7–30B（例如，DeepSeek-R1 8B, Llama3.1 8B/70B, Mistral 7B)
第二层级： 移动/ 消费级 edge	高端智能手机； 现代平板电脑	内存：8–16 GB； 计算：集成GPU/神经网络处理器（10–50 TOPS）； 功耗：5–15瓦	3–7B（例如，Qwen3 4B, Phi-3-mini 3.8B, Llama3.2 3B, Gemma3 4B)
第三层级： 资源- con- 受限 edge	微控制器（例如，ESP32、ARM Cortex-M）； 树莓派	内存：<2 GB； 计算：可选微型神经网络处理器（<1 TOPS）； 功耗：< 5瓦	<3B（例如，TinyLlama 1.1B)

3 边缘大语言模型的微调与适配

为边缘环境适配和定制大语言模型是一个关键过程，涉及两个相辅相成的目标：任务适应和偏好对齐。任务适应通常通过微调实现，使通用模型专门用于特定的下游应用（例如摘要和代码生成）。另一方面，偏好对齐则确保模型的行为是有益的、无害的，并与用户意图保持一致，防止生成不安全或不期望的内容。虽然两者在计算上都很密集，但近期的进展已为在显著约束条件下执行这些过程铺平了道路。

的边缘硬件。本节涵盖了在边缘大语言模型背景下，用于任务适应和偏好对齐的关键技术。

3.1 边缘参数高效微调

虽然预训练基础模型拥有广泛的一般性知识，但其在专业应用中的真正潜力需要通过微调来释放。然而，标准的全量微调方法需要更新模型所有的数十亿参数，这对于边缘设备而言成本过高。这个过程需要大量的内存，不仅要存储模型权重，还要存储梯度、优化器状态和中间激活值。例如，微调一个70亿参数模型可能轻易需要超过100GB的GPU内存，这远远超出了任何消费级或边缘硬件的容量。

为弥合这一差距，研究界已开发出参数高效微调（PEFT）技术（Lin等人，2024）。PEFT的核心原理是冻结预训练模型绝大部分参数，仅训练少量、易于管理的新增或现有参数。PEFT极大地减少了微调过程的内存占用和计算负载，使得在资源有限的设备上适配大语言模型成为可能。此外，通过将任务特定的调整与核心模型隔离，PEFT有助于缓解灾难性遗忘（即模型在学习新任务后遗忘其通用能力）。

表 2 参数高效微调方法对比

方法	核心思想	微调	核心优势
基于适配器	在模型层间注入小型、可训练的瓶颈模块在冻结的基础模型	参数 ~ 0.1%–1%	强大的任务隔离性；单个基础模型可以服务通过切换小型、独立的适配器模块这些已调优
LoRA	来表示权重更新矩阵作为一个低秩乘积由两个较小矩阵构成。仅这些较小矩阵被	~ 0.01%–0.1%	矩阵可以合并回原始的大语言模型中，从而实现无架构变更或额外
基于提示	保持整个大语言模型冻结且学习一组小型连续序列 f con- 向量，这些向量被预先添加到输入中，以引导大语言模型的行为	< 0.01%	计算极其参数-高效且 non-invasive，如基础模型被视为一个黑盒，其权重永远不会被修改

一项新任务）并简化了模型管理，因为一个单一的基础模型可以通过简单地更换小型、任务特定的模块来适应众多任务。

参数高效微调方法已成为高效大语言模型适配的基石。它们提供了一种实用的权衡，在仅调整总参数一小部分的同时，实现了与全量微调相当的性能。表 2将参数高效微调方法分类为基于适配器的方法、低秩适应和基于提示的方法。

3.1.1 基于适配器的方法

基于适配器的微调是参数高效微调中的开创性概念之一。其核心思想是在预训练模型的架构中注入小型、可训练的神经网络模块，即适配器（Houlsby 等人，2019）。

标准的实现方式是在每个Transformer块中插入两个适配器模块：一个位于多头注意力层之后，另一个位于前馈网络之后。每个适配器模块通常采用瓶颈架构：一个用于降低特征维度的下投影线性层、一个非线性激活函数（如ReLU或GeLU），以及一个用于恢复原始维度的上投影层。适配器周围会添加一个残差连接，这使得模型可以通过学习将其权重驱动为零，从而在需要时完全绕过该适配器。

在微调过程中，原始大语言模型的权重保持冻结，仅更新这些新引入的适配器模块的参数。由于瓶颈维度远小于模型的隐藏维度，可训练参数的数量非常少（例如，约占总参数的0.1%–1%）。在部署时，一个共享的大型预训练模型副本可以通过动态加载和交换小型、任务特定的适配器权重来服务于多个任务，从而在存储和内存方面实现显著节省。

3.1.2 低秩适应

低秩适应（LoRA）因其简单性和高效性，已成为最流行和有效的参数高效微调技术之一（Hu et al. -2022）。LoRA基于一个经验观察：模型权重在适配过程中的变化（即更新矩阵， ΔW ）具有较低的内在秩。这意味着更新可以通过两个更小矩阵的乘积来精确近-似。

具体来说，对于一个预训练的权重矩阵 W （大小为 $d \times k$ ），LoRA 将其更新 ΔW 表示为低秩分解： $\Delta W = BA$ ，其中 B 是一个 $d \times r$ 矩阵，而 A 是一个 $r \times k$ 矩阵。秩 r 是一个超参数，它远小于 d 和 k （例如， r 通常为 4、8 或 16）。

在微调期间, W 是冻结的, 仅训练矩阵 A 和 B 的参数。该过程将该层的可训练参数数量从 $d \times k$ 减少到 $r \times (d + k)$ 。

LoRA 在推理阶段提供了一个关键优势: 训练好的矩阵 A 和 B 可以相乘, 并将它们的乘积 BA 直接加到原始权重矩阵 W 上, 从而得到一个新的合并矩阵 $W' = W + BA$ 。这意味着适配后的模型与原始模型具有完全相同的架构和大小, 不会引入任何额外的推理延迟, 这与基于适配器的方法不同, 后者会增加额外的层和计算。

LoRA 的一个重要演进是 QLoRA (量化低秩自适应) (Dettmers 等人, 2023)。QLoRA 通过引入以下关键创新, 进一步普及了大规模模型的微调: (1) 4 位标准浮点数 (NF4): 一种新的、信息论上最优的数据类型, 用于将模型权重量化到 4 位精度, 同时最大限度地减少信息损失; (2) 双重量化: 一种进一步压缩量化常数本身的技术, 可节省额外的内存; (3) 分页优化器: 当 GPU 内存已满时, 通过将优化器状态卸载到 CPU 内存, 利用英伟达的统一内存特性, 防止微调期间出现内存溢出错误。通过结合这些技术, QLoRA 允许梯度通过一个冻结的、4 位量化的大语言模型反向传播到 LoRA 适配器中。它极大地减少了内存占用, 使得在单个仅配备 24GB 显存的消费级 GPU 上微调参数高达 650 亿的模型成为可能, 而这在以前是大型工业数据中心之外难以想象的任务。这种资源高效特性使得 QLoRA 成为设备端微调场景中一个特别有前景的技术。

3.1.3 基于提示的调优

与修改模型权重或架构的方法不同, 基于提示的调优将整个大语言模型冻结, 转而专注于优化模型的输入。基于提示的调优受提示工程启发, 但它是在连续嵌入空间中学习最优提示, 而非依赖离散的人工生成文本。前缀微调和 P 调优是两个代表性工作。

前缀微调在每个 trans-former 层的输入序列前添加一系列可训练的连续向量 (即前缀) (Li 和 Liang 2021)。预训练大语言模型的注意力机制可以关注这些前缀向量, 它们充当任务特定指令, 在不改变其底层参数的情况下引导模型的行为。在微调过程中, 只有前缀参数会被更新。

P 调优是一种相关技术, 它在不同位置插入可训练的连续嵌入, 或称虚拟标记,

置于输入提示中 (Liu 等人, 2021)。这些虚拟标记通过梯度下降进行优化, 以引导模型针对特定任务产生期望的输出。与前缀微调相比, P 调优已被证明在更广泛的模型规模和任务范围内更加稳定和有效。

基于提示的调优的主要优势在于其极致的参数效率, 因为它仅需优化连续提示的几千个参数, 而与大规模模型的规模无关。整个模型被视为一个黑盒, 使得这种方法侵入性最小且易于实现。通过学习任务特定指令, 基于提示的调优提供了一种强大而轻量级的机制, 用于控制在边缘设备上冻结的大语言模型的行为。

3.2 面向大语言模型的联邦边缘学习

虽然参数高效微调使得在单个边缘设备上适配大语言模型成为可能, 但许多现实场景受益于整个用户群体的集体知识。例如, 改进虚拟键盘的下一词预测需要从数百万用户的输入模式中学习。然而, 将用户《数据》收集到中央存储库会带来巨大的隐私风险和后勤障碍。

联邦学习为此问题提供了一个优雅解决方案。它是一种去中心化的机器学习范式, 能够在分布于大量客户端 (例如, 智能手机、车辆) 的《数据》上进行协作模型训练, 而《数据》无需离开设备。联邦学习本质上维护了用户隐私, 使其成为在敏感的、用户生成的《数据》上微调大语言模型的理想框架。

针对大语言模型的标准联邦学习流程, 通常由中央服务器协调, 遵循一种迭代协议, 最常见的是联邦平均 (FedAvg)。首先, 分发: 服务器将当前的全局模型状态发送给一组选定的客户端设备。对于大语言模型, 全局模型不会是完整的数十亿参数模型, 而是一组较小的可训练参数, 例如 LoRA 适配器或提示嵌入。其次, 本地微调: 每个选定的客户端在其本地数据上进行微调。关键的是, 此步骤可能利用像 LoRA 这样的参数高效微调技术, 以便在资源受限的客户端硬件上可行。设备仅训练一小部分参数几个轮次。第三, 更新通信: 每个客户端仅将更新后的参数 (模型增量) 上传回服务器。原始的私有数据永远不会离开设备。第四, 聚合: 服务器聚合来自所有客户端的更新, 通常通过计算参数增量的加权平均来实现。然后将聚合后的更新应用于全局模型。第五, 重复: 循环重复, 改进后的全局模型在下一轮通信中被发送给一组新的客户端。通过

在此过程中，全局大语言模型通过从整个设备群的集体经验中学习而逐步改进，同时始终保护每个用户个人《数据》的隐私。

联邦学习与参数高效微调之间的协同作用对于联邦大语言模型的实际应用至关重要。社区并未尝试进行不可能的联邦全模型微调，而是专注于联邦参数高效微调。在该范-式中，庞大的基础大语言模型保留在服务器上（或预加载到设备上），仅对微小的参数高效微调模块进行协同训练。例如，在联邦LoRA设置中，服务器初始化并分发LoRA适配器（Wu等人，2024）。客户端在其本地数据上微调这些适配器，并将更新后的适配器权重发回。服务器随后聚合这些适配器，以创建一个改进的全局LoRA适配器。这种方法显著降低了每轮中的本地计算成本和通信开销。

3.2.1 应对统计异质性

联邦学习的一个核心挑战在于，每个设备上的《数据》并非独立同分布（非独立同分布）。在大语言模型的背景下，统计异质性极为显著：一位用户的文本数据可能由专业电子邮件构成，另一位用户的可能是随意的短信，而第三位用户的则可能是源代码。

当拥有如此多样化数据分布的客户端对模型进行微调时，其本地更新可能会将模型拉向相互冲突的方向。简单地平均这些不同的更新（如标准FedAvg中那样）可能导致收敛缓慢、不稳定性，或产生一个对所有用户都表现不佳的最终全局模型，这种现象被称为客户端漂移。为缓解此问题，已提出了几种先进的联邦学习算法。例如，FedProx在每个客户端的本地损失函数中添加了一个近端项（Li等人，2020）。该项会惩罚那些偏离初始全局模型过远的本地模型更新，有效地充当一种正则-化器，使本地微调过程受控，并确保更新不会过于发散。SCAFFOLD通过估计服务器和每个客户端的更新方向来校正客户端漂移（Karimireddy等人，2020）。它使用控制变量来调整本地更新，确保即使在数据异构的情况下，聚合后的更新也能更准确地反映真实的全局梯度。个性化联邦学习（pFL）认识到单一的全局模型可能并非对所有用户都是最优的，旨在创建定制化的模型（Arivazhagan等人，2019）。具体而言，一种混合方法可能会训练一个全局模型以捕获通用知识，同时也在每个设备上训练一个专门针对用户特定数据的本地组件。

3.2.2 降低通信开销

通信是联邦学习中的一个主要瓶颈，对于大语言模型而言尤其如此。虽然参数高效微调显著减少了更新的大小，但即使是从数百万台设备传输这些较小的模块，也可能使网络资源紧张并消耗宝贵的电池续航。因此，提高通信过程的效率至关重要。关键策略包括：

- 更新量化（Gao等人 2025）：从客户端发送到服务器的模型更新（例如LoRA适配器权重）可以量化为较低精度，例如8位整数甚至4位浮点数。这可以将上传负载减少4-8倍，而对最终模型性能的影响微乎其微。
- 更新稀疏化（Qiu等人 2025）：客户端无需发送整个更新向量，而只需发送最重要的值，其余部分设为零。这可以通过仅传输超过特定幅度阈值（top-k选择）的值来实现。
- 降低通信频率（Wu等人 2025）：可以设计算法，允许在每次通信前进行更多的本地计算。这可以将通信成本分摊到更多的本地调优步骤中，从而提高整体效率。

通过结合联邦学习的隐私优势与参数高效微调的效率，并采用先进算法应对数据异构性和通信成本的挑战，我们得以构建在边缘运行的强大、个性化且持续改进的大语言模型。

3.3 协同边缘-云端微调

虽然设备端微调和联邦学习专注于在边缘端适配模型，但它们是在边缘硬件的显著限制下运行的。第三种强大的方法是在资源丰富的云端服务器与数据丰富的边缘设备之间建立共生关系。协同边缘-云端微调范式旨在兼取两者之长：云端巨大的计算能力，与边缘的隐私、低延迟和数据局部性相结合。这些范式承认，最强大的大语言模型很可能始终驻留在云端，而更小、更高效的模型将在边缘运行。其核心目标是利用强大的云端模型，以持续高效的方式增强边缘模型的能力。

3.3.1 大-小模型协作

大-小模型协作是最有前景且有效的边缘-云端协作策略之一。它将云端与边缘的关系框定为教师与学生，其中云端一个庞大的高性能大语言模型充当教师，而为边缘设计的一个小型轻量级大语言模型则充当学生。其目标是将知识从教师转移到学生，使学生模型能够实现远超仅靠数据集微调所能达到的性能。这种知识转移过程被称为知识蒸馏（Acharya等人，2024年）。

图2描述了边云知识蒸馏的一般工作流程，解释如下。首先，一个大规模、专有的教师模型（例如，一个100B+参数的模型）托管在云端。其次，使用教师模型生成一个大规模、高质量的合成数据集。该数据集可以涉及为多样化的提示词生成回复，或为未标注数据打标签。第三，使用响应、软标签或特征蒸馏技术来捕获教师的知识。最后，紧凑的学生模型基于蒸馏出的知识进行微调。微调过程可以在学生模型部署到边缘设备之前在云端进行。通常，有三种知识蒸馏技术（Gou et al. 2021），如下：

- 响应蒸馏：学生模型被训练以直接模仿教师模型生成的最终文本输出。教师模型连贯、详尽且风格丰富的响应可作为高质量的训练目标。

- 软标签蒸馏：教师并非仅使用单个词（硬标签）作为下一个标记，而是训练学生去匹配教师在整个词汇表上的完整输出概率分布（软标签）。该分布包含更多信息，因为它

通过展示教师模型认为哪些其他词语是合适的，揭示了教师模型的思考方式。

- 特征蒸馏：学生模型也可以被训练来模仿教师模型的中间隐藏状态或注意力图。这迫使学生模型学习与教师模型相似的内部表征。

大-小模型协作允许开发者在无需直接访问云端庞大、专有的教师模型的情况下，创建能力强大的边缘模型。云端的大型教师模型将知识预先消化成较小的学生模型易于学习的格式。

3.3.2 面向大语言模型的分割学习

分割学习是另一种用于协作微调的范式，它将大语言模型分割在边缘设备与云端服务器之间（Lin等人，2024）。一个典型的大语言模型微调分割学习设置如下。首先，模型被分割为两个部分：一组初始层在边缘设备上运行，而模型的其余部分（通常更大）在云端服务器上运行。其次，在前向传播过程中，边缘设备通过其负责的模型部分处理输入数据，生成一个中间表征，通常称为粉碎数据。第三，这些并非原始输入的粉碎数据被发送到云端服务器。这提供了一定程度的隐私保护，因为服务器从未看到原始用户数据。第四，服务器使用其负责的模型部分完成前向传播，计算损失，并通过计算梯度开始反向传播。第五，与服务器层对应的梯度用于更新其权重。初始层的梯度被发送回边缘设备。最后，边缘设备接收梯度并完成反向传播步骤，以更新其本地模型权重。

虽然分割学习提供了强大的隐私保证（Zhang et al. 2024），并允许对更大的模型进行微调，但其主要缺点是高昂的通信成本。每个训练步骤中激活值和梯度的持续来回传输，使其对网络延迟和带宽高度敏感，与联邦学习相比，可能会显著拖慢整体微调过程。在实践中，分割学习常与参数高效微调结合，用于高效的大语言模型微调（Gu et al. 2025）。

3.4 将边缘大语言模型与用户偏好对齐

虽然第3.1节讨论的参数高效微调方法非常适合将大语言模型的能力适配到新任务或新领域，但它们本身并不能保证模型的输出




图2 知识蒸馏的流程

将是有益的、无害的，并与微妙的人类价值观保持一致。这个过程被称为偏好对齐，对于创建值得信赖和可靠的AI助手至关重要。为大规模云基础设施开发的传统对齐技术，对于边缘部署来说通常过于复杂。然而，一波新的更高效的方法，正使得设备端或边缘辅助的对齐变得越来越可行。

3.4.1 基于人类反馈的强化学习

基于人类反馈的强化学习（RLHF）已成为现代大语言模型对齐的基石，其著名应用是塑造了如ChatGPT等模型的行为（Chaudhari等人，2025）。这是一个复杂、多阶段的过程，利用人类偏好来引导模型的输出。该过程通常包含三个步骤。首先，监督微调（SFT）：一个预训练基础模型首先在一个小型、高质量的精选提示-回复数据集上进行微调。这教会模型期望的输出格式和风格（例如，如何像一个有用的助手那样回应）。其次，奖励模型（RM）训练：训练一个独立的奖励模型，用于预测人类会更偏好两个回复中的哪一个。为了创建其训练数据，人类对同一提示下模型生成的多个回复进行排序。这些偏好对（被选中的回复与被拒绝的回复）被用来训练RM，使其为更受偏好的输出分配更高的分数。第三，强化学习微调：随后，使用如近端策略优化（PPO）这样的强化学习算法对监督微调模型进行微调。在此阶段，大语言模型（即策略）生成对提示的回复，训练好的奖励模型（即奖励函数）对这些回复进行评分。强化学习算法更新大语言模型的权重，以最大化其从奖励模型获得的奖励，从而有效地优化模型，使其生成符合人类偏好的输出。

完整的RLHF流程在边缘侧的计算成本过高。它需要训练多个模型（监督微调模型、奖励模型以及最终的RL调优模型），并涉及一个复杂且内存密集的强化学习循环，这不适合资源受限设备。因此，RLHF几乎完全是一种基于云端的预部署技术，用于准备一个通用对齐模型，该模型随后可以进一步为边缘侧进行专门优化。

3.4.2 直接偏好优化

认识到基于人类反馈的强化学习的复杂性，研究人员开发了直接偏好优化，这是一种更简单但功能强大的替代方案（Rafailov等人，2023）。直接偏好优化的核心洞见在于，奖励建模和强化学习微调步骤可以合并为一个单一的、直接的优化阶段。它

巧妙地将问题从最大化奖励重新定义为直接在偏好《数据》本身上优化大语言模型。

与RLHF一样，DPO也从一个监督微调模型开始。它使用相同的人类偏好数据集，其中包含被选中的（ y_w ）和被拒绝的（ y_l ）回答。DPO没有训练一个单独的奖励模型，而是使用一个损失函数，直接鼓励大语言模型提高偏好回答相对于被拒绝回答的相对概率。该损失函数的构建旨在解析地解决与RLHF相同的优化问题，但无需显式的奖励模型或不稳定的强化学习训练循环。

DPO因其简单性、高效性和可行性优势，代表了边缘对齐领域的一项重大突破：(1) 简单性：它将复杂的三阶段RLHF流程简化为一个单一、稳定的微调阶段；(2) 高效性：通过消除训练和存储单独奖励模型的需求，它极大地减少了计算和内存开销；(3) 可行性：DPO更简单、更稳定的特性，使其成为在资源受限硬件（例如高端边缘服务器，甚至结合LoRA等PEFT方法直接在设备端）执行偏好对齐的一个更可行的候选方案。

4 边缘大语言模型的高效推理

将大语言模型部署到边缘的最终目标，是直接设备上执行推理（即根据用户输入生成响应、分类或嵌入表示的过程）。然而，正如前言所述，此过程对计算和内存的需求是巨大的。对拥有数十亿参数的模型进行一次前向传播，就涉及数十亿次计算，并且仅存储模型权重就需要数千兆字节的内存。这样的要求从根本上与边缘设备资源受限的特性不相容。

为了实现设备端推理，必须对庞大的预训练大语言模型进行显著压缩和优化。本节深入探讨那些能减少模型占用空间和计算复杂度的关键技术，使其能够在边缘硬件严格的功耗和内存预算内高效运行。我们首先探讨模型压缩技术，这些技术能缩小模型本身；然后讨论运行时与内存优化，这些优化能使推理过程更加高效。

4.1 模型压缩

模型压缩旨在创建一个更小、计算成本更低的大语言模型版本，并尽可能接近地保留原始模型的性能。这些技术

对于减少模型的存储大小、降低其在运行时的内存（RAM）使用量以及通过减少所需计算量来加速推理速度至关重要。最突出且有效的压缩策略是量化、剪枝、知识蒸馏和低秩分解。

4.1.1 量化

量化是最有效且应用最广泛的模型压缩技术之一。它涉及降低模型参数（权重）的数值精度，有时也包括推理过程中计算的中间激活值。大多数深度学习模型使用32位浮点数（FP32）进行训练，这提供了宽广的动态范围和高精度。量化将这些数字转换为低位表示形式，例如8位整数（INT8）、4位整数（INT4）或其他低位格式。

量化的好处是双重的。一方面，它减少了内存占用。从FP32转换到INT8，模型大小减少为原来的四分之一。转换到INT4则减少为原来的八分之一。这极大地降低了磁盘所需的存储空间以及加载模型所需的内存。另一方面，它实现了更快的计算。许多边缘处理器，包括中央处理器、图形处理器，尤其是专门的神经网络处理器，都拥有专用的硬件指令，可以比浮点运算更快、更节能地执行整数运算。

量化主要有两种方法：训练后量化（PTQ）（Lin等人 2024）和量化-感知训练（QAT）（Liu等人 2023）。首先，PTQ是一种更简单的方法，即在训练完成后，将完全训练好的FP32模型转换为低比特格式。该过程通常包含一个校准步骤，使用一个小的、有代表性的数据集来确定浮点数范围到整数范围的最佳映射，以最小化信息损失。PTQ速度快且无需重新训练，这使其成为快速部署的热门选择。其次，QAT在模型微调过程中模拟量化的影响。它在模型图中插入伪量化节点，这些节点模拟低比特推理期间将发生的舍入和截断误差。通过让模型在训练期间感知这些影响，模型可以学会对精度损失更具鲁棒性。QAT通常比PTQ产生更高的精度，尤其是在极低的比特宽度（例如4比特或更低）下，但它更复杂，因为它需要一个带标签的数据集和一个完整的重新训练周期。

近期的进展已将边界推至极端量化，使用4位、3位甚至二进制/

三元格式。像QLoRA这样的技术引入了4位标准浮点数数据类型，这是一种信息论上最优的4位量化格式，已被证明在训练和推理方面都非常有效。

4.1.2 剪枝

剪枝是一种受人类大脑启发的技术，涉及从训练好的神经网络中移除冗余或不重要的连接（参数）。许多大模型都存在严重的过参数化问题，其大部分权重可以被移除，而对性能几乎没有影响，尤其是在经过一段时间的再训练以补偿移除操作之后。大语言模型剪枝可分为非结构化剪枝和结构化剪枝。

非结构化剪枝根据特定标准（通常是权重的大小，即绝对值较小的权重被认为较不重要）从模型中移除单个权重。它可以实现很高的压缩率。然而，这会导致稀疏的权重矩阵，在没有能够高效处理稀疏计算的专用库的情况下，很难在中央处理器和图形处理器等标准硬件上加速（Blalock等人，-2020）。由此带来的加速效果往往与稀疏性水平不匹配。

结构化剪枝是一种对硬件更友好的方法，它移除模型的整个结构组件。它不是移除单个权重，而是移除完整的神经元、注意力头或权重矩阵中的整行/整列。结构化剪枝保留了模型的密集、规则结构，使其能够在标准硬件上高效执行，并直接、可预测地降低延迟和内存使用。虽然其理论压缩极限低于非结构化剪枝，但其在推理速度方面的实际效益通常更大。

4.1.3 知识蒸馏

如微调章节（第3.3.1节）所述，知识蒸馏也是一种强大的压缩技术，用于创建高效的推理模型（Hinton等人，2015）。其核心思想是训练一个紧凑的小型学生模型，使其模仿一个更大、高性能的教师模型的行为。

从推理的角度来看，知识蒸馏的目标是生成一个架构上更小的学生模型（例如，具有更少的层、更小的隐藏维度或更少的注意力头），但其表现却如同更大的教师模型。通过让学生在教师模型丰富的输出（如其软概率分布）上进行训练，学生模型学习到的表征比仅使用原始数据集训练时更为精细和泛化。

最终压缩后的学生模型将被部署到边缘设备上。知识蒸馏之所以极其有效，是因为它将庞大模型的复杂推理能力转移到了一个足够小、适合边缘部署的模型中。这种技术通常被用作第一步，得到的学生模型随后会通过量化和剪枝进行进一步压缩。

4.1.4 低秩分解

低秩分解基于这样一个观察：神经网络中的大型权重矩阵通常具有低内在秩，这意味着它们包含冗余信息。低秩分解旨在用两个或多个更小、更薄的矩阵的乘积来近似这些大型矩阵（Hu 等人，2022 年）。

例如，一个大小为 $d \times k$ 的大型权重矩阵 W 可以被两个较小矩阵替换，即大小为 $d \times r$ 的 B 和大小为 $r \times k$ 的 A ，其中秩 r 远小于 d 或 k 。原始的矩阵-向量乘法被替换为与这两个较小矩阵的连续两次乘法。这直接将参数总数从 $d \times k$ 减少到 $r \times (d + k)$ ，并降低了计算所需的浮点运算次数。该技术对Transformer架构的注意力机制和前馈层中存在的大型投影矩阵尤其有效。

4.2 高效模型架构设计

虽然模型压缩技术能缩小一个预先存在的大型模型，但一种互补且可以说是更根本的方法是设计从一开始就高效的模型架构。标准的Transformer架构虽然强大，但包含固有的计算瓶颈，使其难以缩小规模。其中最重要的是自注意力机制，其计算和内存需求随输入序列长度 $O(n^2)$ 呈二次方增长，其中 n 是词元数量。对于长上下文，这种二次方复杂度成为高效推理的主要障碍。

因此，面向边缘大语言模型的架构创新，主要聚焦于重新设计自注意力机制，或完全用更高效的替代方案来取代它。其目标是创建能够处理长序列并实现高性能的模型，同时避免标准Transformer所面临的过高计算成本。

4.2.1 高效注意力机制

与让每个词元都关注所有其他词元（全自注意力）不同，各种近似注意力机制

机制已被开发出来，以将复杂度从 $O(n^2)$ 降低至线性或近线性时间。

- **稀疏注意力**：这种方法限制了注意力模式，使得每个标记仅关注其他标记的一个子集。这是一种高效且对硬件友好的折中方案（Beltagy 等人，2020）。稀疏注意力技术可进一步分为滑动窗口（或局部）注意力、扩张（或跨步）注意力以及全局注意力。首先，在局部注意力中，例如 Longformer（Beltagy 等人，2020），每个标记仅关注一个固定大小的邻近标记窗口（例如，前 512 个标记）。其基于大多数语言信息是局部的这一直觉。其次，扩张注意力（Child 等人，2019）通过使一个标记关注更大范围内每隔 k 个标记来使窗口扩张。它能在不关注每个标记的情况下捕获更广的感受野。第三，为防止长距离依赖的丢失，稀疏注意力方法通常会指定少数标记作为全局汇总点。这些特殊标记被允许关注整个序列，而所有其他标记也被允许关注它们。这种混合方法，同样被用于 Longformer（Beltagy 等人，2020），将局部效率与全局上下文结合起来。

- **线性注意力**：这些方法旨在通过重新表述注意力计算（Katharopoulos 等人，2020 年）将复杂度降低至 $O(n)$ 。标准的注意力机制计算 $\text{Softmax}()$ 。其二次瓶颈在于查询（Q）矩阵与键（K）矩阵的乘法运算，两者的维度均与序列长度 n 成正比。线性注意力方法，例如 Performers（Choromanski 等人，2020 年）和 Linformers（Wang 等人，2020 年），使用数学近似（如核方法）来改变运算顺序为 $(K^T V)$ 。通过先计算 $K^T V$ ，可以避免对 n 的二次依赖。尽管理论上很强大，但用这些方法达到与标准注意力机制相同的质量可能具有挑战性。

4.2.2 专家混合模型

专家混合模型（MoE）已成为一种强大的架构，能够将大语言模型扩展到数千亿甚至数万亿参数，而计算成本不会成比例增加（Jiang et al. 2024）。在混合专家模型中，密集的前馈网络层被一组称为专家的小型神经网络所取代。对于每个输入令牌，一个轻量级的路由器或门控网络会动态地选择一小部分专家（通常只有两个）来处理该令牌。MoE 设计巧妙地解耦了模型的总参数数量与其推理成本

(浮点运算次数)，因为对于任何给定的令牌，只使用了模型权重的一小部分。

MoE似乎是边缘计算的理想选择。一个拥有180B参数模型知识容量、但推理浮点运算次数仅相当于小得多的13B参数稠密模型的模型，看起来是资源受限设备的完美解决方案。然而，在边缘部署混合专家模型引入了一系列独特且艰巨的系统级挑战，这些挑战与传统稠密模型截然不同。

- 巨大的内存占用：虽然在任何时刻只有少数专家处于激活状态，但所有专家都必须可访问。这意味着整个模型及其庞大的参数数量必须存储在内存中。一个100B+ 参数的MoE模型可能需要超过200GB的内存，这远远超出了当前任何移动或边缘设备的RAM容量。
- 不规则内存访问与缓存低效：动态的、逐令牌的专家选择导致了高度不规则且不可预测的内存访问模式。与权重被顺序访问的稠密模型不同，MoE推理需要为每个令牌获取分散的、非连续的内存块（即专家）。这种行为破坏了内存局部性，严重降低了CPU/GPU缓存的有效性，并导致系统因等待权重加载到计算单元而产生高延迟。
- 高昂的卸载延迟：处理大模型的一种标准技术是将非活跃参数卸载到速度较慢的二级存储（如闪存）中，并按需将其拉入内存。然而，这种策略对于边缘MoE推理并不可行。从闪存加载整个专家来处理单个令牌的延迟将高得惊人，使得交互式、实时的生成变得不可能。

- 微调复杂性：在设备上微调混合专家模型会带来进一步的困难。决定是更新所有专家、一部分专家还是仅更新门控网络需要仔细考量，并且存储数十亿参数的梯度和优化器状态所需的内存是难以承受的。

解决这些挑战是当前一个活跃的研究领域（Kong等人，2025；Li等人，2025）。潜在的解决方案包括从头设计更小型的原生边缘MoE模型，开发能够通过预测路由器的决策来推测性预加载专家的复杂软件，以及协同设计更适合稀疏、动态工作负载的软硬件系统。在这些挑战得到解决之前，大规模MoE模型的部署将

很可能仍局限于强大的服务器或分布式设备集群，而非单个边缘设备。

4.2.3 状态空间模型

近期一个极具前景的架构趋势完全脱离了注意力机制，转而从经典的状态空间模型（SSMs）中汲取灵感。像Mamba（Gu和Dao，2024）这样的模型代表了一类新的序列模型，它们能够以线性时间复杂度处理信息，同时有效地捕捉长距离依赖。

状态空间模型的核心思想是通过在每一步更新一个隐藏状态 h 来递归地处理序列。该过程的简化视图是： $h_t = A * h_{t-1} + B * x_t$ ，其中 x_t 是当前的输入标记。Mamba的关键创新在于使矩阵 A 和 B 依赖于输入，允许模型根据当前标记选择性地记住上下文信息或将其遗忘。这种方法赋予了Mamba类似注意力机制的上下文感知推理能力，却没有二次成本。状态空间模型为边缘推理提供了几个主要优势。首先，训练和推理的复杂度都随序列长度线性增长（ $O(n)$ ）。其次，不需要键值缓存。与Transformer模型在自回归生成过程中必须为所有先前令牌存储庞大的键值缓存不同，状态空间模型只需要维护一个小的、固定大小的隐藏状态。这极大地减少了文本生成过程中的内存占用，而这正是边缘设备上大语言模型常见的瓶颈。第三，逐步递归计算对于一次生成一个标记的文本生成来说非常高效。由于其线性扩展性和生成时极低的内存需求，像Mamba这样的状态空间模型架构特别适合设备端部署，并且是下一代边缘大语言模型的有力竞争者。

4.3 推理加速与运行时优化

拥有一个采用高效架构的压缩模型只是成功了一半。要在边缘设备上实现实时性能，执行模型的过程（即推理运行时）也必须高度优化。这些优化侧重于最小化内存移动、减少计算冗余，并尽可能充分利用底层硬件。这是弥合理论模型与响应迅速的设备端应用之间差距的最后关键一步。

4.3.1 键值缓存优化

在逐词元生成文本的自回归生成中，Transformer架构存在一个主要的性能瓶颈：键值（KV）缓存。模型在为某个词元计算完键矩阵和值矩阵后，会将其存储起来，以避免在后续步骤中重新计算。随着生成序列变长，缓存会线性增长，消耗大量内存。对于一个70亿参数模型，仅处理几千个词元的上下文，其KV缓存就可能轻易消耗数千兆字节的内存，这常常超出了边缘设备的承载能力。

为管理海量KV缓存，采用了多种策略：

- 键值缓存量化：正如模型权重可以被量化一样，存储在KV缓存中的值也可以转换为较低的精度，例如8位整数（INT8）（Hooper等人，2024）。由于这些值仅用于注意力计算，而不用于反向传播，因此精度降低对输出质量影响极小，但可以将缓存的内存占用减少2到4倍，这通常决定了模型能否在边缘设备上运行。
- 多查询注意力（MQA）（Shazeer 2019）与分组查询注意力（GQA）（Ainslie 等人，2023）：这些是直接影响并显著减小KV缓存大小的架构修改，如图3所示。在标准的多头注意力（MHA）中，每个注意力头都有其独立的键和值投影矩阵，导致缓存占用巨大。MQA提出了一种简单而有效的改变：所有注意力头共享一个键值头。这极大地减小了键和值矩阵的大小，从而显著减少了KV缓存，而模型质量仅有轻微下降。GQA是MHA和MQA之间的折中方案。它将多个注意力头分组，每个组共享一个键值头。GQA在减小缓存大小和保持模型性能之间提供了更好的平衡。

包括Llama2和Mistral在内的现代高效模型都使用了GQA。

- 缓存淘汰策略：对于非常长的序列，即使超过优化后缓存的容量，也可以使用淘汰策略。类似于滑动窗口，这些策略会从缓存中移除最旧的令牌，为新令牌腾出空间（Kwon等人，2023）。更先进的方法可能会尝试预测并淘汰那些注意力分数最低的令牌，假设它们与正在进行的生成过程相关性较低。

4.3.2 推测解码

自回归生成本质上是顺序执行且速度缓慢。模型必须执行一次完整的前向传播才能生成单个词元，这一过程通常受限于内存带宽而非计算能力。推测解码是一项巧妙的技术，它通过一次生成多个词元来加速该过程（Chen et al. 2023）。其工作原理是使用两个模型：一个庞大而精确的验证模型（用于云端部署的主大语言模型）和一个更小、更快的草稿模型（主大语言模型的微型版本，甚至是用于边缘部署的简单n元语法模型）。生成过程如图4所示，具体步骤如下。首先，使用小型草稿模型快速生成包含数个候选词元（例如4-5个词元）的草稿序列。其次，大型验证模型随后接收整个草稿序列，并通过一次并行的前向传播进行处理，以检查其自身会生成哪些词元。第三，将草稿词元与验证模型的输出进行比较。匹配的最长前缀会被立即接受。例如，如果前3个词元匹配，则所有3个词元都会在通常生成一个词元所需的时间内被接受。最后，如果出现不匹配，则仅保留已验证正确的部分前缀，添加验证模型预测的第一个“正确”词元，并重复该过程。推测解码能带来显著的加速效果（通常为2-3倍），因为验证模型一次高效的前向传播即可验证多个词元，从而打破了逐词元顺序处理的性能瓶颈。

图3 不同注意力机制在KV缓存大小方面的比较




图4 推测解码流程





图5 算子融合减少内存I/O

- 硬件专用内核：一个高级运行时将包含一个手工优化的内核库，这些内核利用目标硬件的特定指令集。它包括在移动CPU上使用ARM NEON指令集、在英伟达GPU上使用张量核心，或利用现代片上系统中神经网络处理器的专-有指令集（Chen 等人，2018；Zheng 等人，2020）。使用这些专用指令集可以为量化矩阵乘法等关键操作带来数量级的加速。

- 内存布局优化：内存访问的性能在很大程度上取决于《数据》（张量）在内存中的排列方式。编译器可以自动重-排张量的维度（例如，从NCHW格式转为NHWC格式），以匹配硬件能最高效处理的布局，从而确保更快的数据访问和更好的缓存利用率（Chetlur等人，2014；Abadi等人，2016）。

4.3.3 编译器与内核优化

优化的最后一层来自专门的深度学习编译器和运行时（例如，ONNX Runtime、TVM、基于MLIR的框架），它们将高级模型图转换为针对目标硬件的极其高效的低级机器码。相关技术包括：

- 算子融合：如图5所示，这是最重要的编译器优化之一。它涉及将多个连续操作合并为单个计算内核（Chen等人，2018）。例如，矩阵乘法、偏置加法和GELU激活函数可以融合为一个操作。算子融合对性能至关重要，因为它通过防止中间结果写入主存并再次读取，极大地减少了内存流量。它最大限度地缓解了内存带宽瓶颈，并减少了内核启动开销。

通过结合这些运行时策略，可以在边缘设备上大幅提升压缩后大语言模型的执行效率，从而实现更低的延迟和更低的功耗，这对于流畅、响应迅速的用户体验至关重要。

4.4 系统级部署策略

在大语言模型经过压缩、架构精炼并为运行时执行优化后，最终的挑战是在现代边缘设备复杂、多任务的环境中有效地部署它。设备的操作系统必须管理有限的资源，例如内存、处理核心和电池，这些资源由众多应用程序和后台进程共享。系统级策略确保大语言模型不是作为一个孤立的程序运行，而是作为设备生态系统中一个行为良好的成员，在提供持续性能的同时不损害整体用户体验。这些策略应对部署的实际现实，侧重于资源管理，

热约束，并创建一个能够智能利用边缘和云端资源的稳健服务。

4.4.1 模型分片

对于运行远超单个边缘设备能力的大语言模型，一种极具前景的策略是将模型本身分布到多个协作的边缘设备上。这种方法被称为模型分片或分布式推理，它将一组邻近的设备视为一个更强大的单一计算资源。其核心思想是将由顺序层构成的大语言模型进行分区，并将这些“分片”部署到本地网络中的不同设备上。

推理过程随之变成一个分布式流水线，类似于装配线。当一个请求发起时，链中的第一个设备通过其负责的模型部分（第一组层）处理输入，并将中间结果（激活值）传递给下一个设备。这个过程沿着流水线持续进行，直到最后一个设备生成输出。然而，这种流水线的一种简单实现会导致显著的空闲时间，因为每个设备必须等待前一个设备完成后才能开始工作。为了克服这个问题，需要使用诸如流水线并行之类的优化技术。通过同时向系统中输入多个请求（或单个大请求的微批次），流水线中的所有设备可以并行操作，从而显著提高整体吞吐量并减少每个设备的空闲时间。

该方法的主要优势在于能够运行庞大的最先进模型，这些模型原本无法部署，并且相比仅依赖云端，它能实现更低的延迟和更高的吞吐量。然而，这种策略也带来了一系列必须解决的重要系统级挑战，才能实现实际部署。首先，在设备间传递的中间激活张量可能非常庞大，有可能压垮本地Wi-Fi网络的带宽，成为主要瓶颈。其次，参与的边缘设备不可避免地具有不同的计算能力。整个流水线的速度受限于最慢的设备（即“掉队者”），这使得负载均衡和调度变得至关重要。第三，决定如何将模型“切割”成分片是一个复杂的优化问题。目标是在设备间均衡计算负载，同时最小化需要在它们之间通信的激活数据大小。第四，系统必须管理设备发现、连接建立以及分布式计算的编排。它还需要对故障具有鲁棒性，例如设备离开网络或在推理过程中失去连接，这需要复杂的容错机制。像EdgeShard（Zhang等人，2025）这样的研究框架正开始

为解决这些复杂的编排挑战提供了蓝图。

4.4.2 混合运行时

现代边缘设备构建在异构片上系统之上，这些系统集成成了多种专用处理器：高能效的CPU核心、高性能的CPU核心、图形处理器，以及通常一个专用的神经网络处理器或数字信号处理器。最高效的部署策略并非将整个大语言模型运行在单一类型的处理器上，而是将工作负载在它们之间进行划分。混合运行时系统可以很好地管理这种划分。一方面，NPU/GPU可以承担繁重的计算任务。模型中绝大部分计算是稠密矩阵乘法。这些操作，尤其是在量化到INT8或INT4时，非常适合NPU或GPU的大规模并行架构。将这些核心计算卸载到专用加速器，是提升速度和能效最有效的方法。另一方面，CPU可以处理控制流和不支持的操作。并非大语言模型中的所有操作都能被NPU的编译器支持。涉及控制流、特定激活函数或自定义逻辑的操作通常会回退到CPU执行。CPU充当协调者，管理整体执行流程，并处理加速器无法处理的那部分模型。一个智能的运行时调度器协调这一过程，管理不同处理器之间的数据流（例如，将张量从CPU内存移动到NPU内存），以最小化延迟。这种异构方法确保模型的每个部分都在最适合该任务的硬件上执行，从而最大化性能并最小化功耗。

4.4.3 按需内存分页

即使经过深度压缩的大语言模型，其权重也可能需要数百兆字节甚至数吉字节的内存来存储。在应用程序启动时将整个模型加载到内存中，速度会很慢，并且可能消耗过多内存，导致操作系统被迫关闭其他后台应用程序，从而带来糟糕的用户体验。一种更复杂的系统级方法是按需权重加载，通常通过内存映射文件（mmap）实现（Kwon等人，2023）。最初，模型的权重存储在设备的持久闪存（例如SSD）中。当模型初始化时，系统并非将整个文件加载到内存中，而是将该文件映射到应用程序的虚拟地址空间。操作系统仅在推理引擎首次访问模型的特定部分（一页）时，才将其从存储加载到内存中。如果设备遇到

当面临来自其他应用的内存压力时，操作系统可以透明地将模型中未使用的部分从内存换出，因为它知道后续如果需要，可以从闪存存储中重新加载它们。

按需内存分页策略带来了显著优势。首先，它支持更快的应用启动。应用几乎可以立即进入交互状态，因为它无需等待整个模型加载完成。其次，它可以降低峰值内存使用量。只有模型中被当前推理任务主动使用的部分需要驻留在物理内存中。第三，它支持更好的多任务处理。它允许大语言模型在可用内存较少的设备上运行，并提升整个系统流畅处理多任务的能力。

4.4.4 热管理与功耗管理

运行大语言模型推理是边缘设备所能执行的计算最密集的任务之一，会导致显著的功耗和发热。如果管理不当，这种高强度工作负载会迅速导致设备过热。作为响应，操作系统将启动热节流，大幅降低处理器的时钟频率以降温，这会严重降低推理性能。

一个稳健的部署必须具备热感知能力并积极主动 (Tan 和 Cao 2024)。首先，系统应持续监测设备的温度和电池电量。其次，基于热状态，系统应进行动态调整。例如，它可能从使用高性能核心切换到更多高能效核心，或者在令牌生成之间引入轻微延迟以降低持续的计算负载。第三，推理策略应与设备的电源模式挂钩。在低功耗模式下，系统可能使用更小更快的模型或更多地依赖云端卸载，以牺牲部分性能为代价来保持电池续航。这确保了大语言模型提供的是可持续服务，而非短暂的高性能爆发后伴随长时间的节流。

4.4.5 智能卸载

最具韧性和强大的系统认识到，边缘并非总是运行每个查询的最佳位置。混合边缘-云策略提供了一种优雅的回退机制，创造了一种无缝体验，让系统智能地决定每个推理请求的执行位置。智能卸载让用户享受到高质量的大语言模型服务：边缘的隐私、低延迟和离线可用性，与云端的原始算力和深层知识相结合。

此决策的设备端逻辑可基于多种因素，包括查询复杂度、设备状态、

和网络条件。首先，简单的请求非常适合在边缘处理，而复杂的推理问题（例如，解释这部电影的情节并将其与书籍改编版进行比较）可能更适合由更强大的基于云的模型来处理。设备端模型甚至可以先用于对查询的复杂性进行分类。其次，如果设备过热、电池电量低，或者已经因其他应用而处于高负载状态，将推理卸载到云端可能是更好的选择，以节省电池并维持系统响应能力。第三，当连接到快速的Wi-Fi网络时，使用云端的成本可能较低。当处于缓慢或计费的蜂窝网络连接下，或完全离线时，边缘推理是更优或唯一的选择。

5 评估指标与基准测试

5.1 模型性能指标

在评估一个大语言模型在边缘设备上的效率之前，必须严格评估其执行指定任务的基本能力。先前讨论的压缩与优化技术的主要目标，是在最小化对模型性能负面影响的同时，降低其资源需求。因此，性能评估是评估流程中首要且最关键的步骤。以下指标评估模型的核心语言能力，包括其对语法、句法和语义的理解。

- 困惑度 (Bengio et al. 2003): 这是评估自回归语言模型最基本的指标。困惑度衡量一个概率模型预测文本样本的能力，其计算方式为序列平均负对数似然的指数化。简单来说，它量化了模型在遇到一段文本时的“惊讶”程度。较低的困惑度分数表明模型为真实文本分配了更高的概率，意味着模型对语言模式的掌握更好。虽然它是衡量通用语言流畅性的良好指标，但并不直接衡量模型遵循指令或执行特定任务的能力。
- 任务特定准确率: 对于为分类任务微调过的模型，准确率仍是最直接的性能衡量标准。不同的用例会考虑不同的任务特定准确率变体。例如，在情感分析中，模型是否能正确将文本分类为积极、消极或中性？在聊天机器人或语音助手的意图识别中，模型是否能正确识别用户意图（例如，设置计时器、播放音乐、获取路线）？在文本分类中，模型是否能正确-

将文档分配到一个预定义的类别（例如，体育、金融、技术）？

- F1分数、精确率和召回率：对于模型必须在较大文本中识别特定文本片段的任务，简单的准确率是不够的。这些指标对于评估命名实体识别等任务的性能至关重要。更具体地说，精确率衡量的是准确性：在模型识别的所有实体中，有多少是正确的？召回率衡量的是完整性：在文本中所有真实存在的实体中，模型成功识别了多少？F1分数是精确率和召回率的调和平均数，它提供了一个单一、平衡的分数，被广泛用于比较模型性能。

- 生成式任务的评估指标：对于文本摘要或翻译这类可能存在多个正确输出的任务，评估更为复杂。BLEU（双语评估替补）和ROUGE（面向召回率的摘要评估替补）是用于将模型生成的文本与一个或多个人工撰写的参考文本进行比较的标准指标。BLEU主要用于机器翻译，它衡量生成文本中n元语法（连续n个词的序列）相对于参考文本的精确率（Papineni等人，2002）。它奖励那些与人工参考文本共享许多短短语的输出。ROUGE更常用于摘要任务，它衡量n元语法的召回率（Lin，2004）。它检查人工参考文本中的n元语法有多少出现在模型生成的摘要中。

5.2 知识与安全基准测试

现代大语言模型被期望不仅能生成连贯的句子，还应具备推理、获取事实知识以及安全交互的能力。为此，人们开发了一套标准化的基准测试来评估这些高级能力。对于边缘大语言模型而言，在这些基准测试中取得高分，表明该模型在压缩后仍保留了其智能。

- MMLU（大规模多任务语言理解）（Hendrycks等人，2020）：这是一个全面的基准测试，旨在衡量模型的一般知识和问题解决能力。它包含涵盖57个不同学科的多项选择题，包括基础数学、病史、计算机科学、法律等。在MMLU上获得高分表明该模型保留了广泛的世界知识。
- 常识推理基准测试：这些基准测试评估模型对日常情境做出合理判断的能力，这项任务对人类而言轻而易举，

对人类而言容易但对人工智能来说历来困难。例如，在HellaSwag（Zellers等人，2019）中，模型会看到一个上下文，并必须从四个选项中选择最合乎逻辑且听起来最自然的补全；Com-monsenseQA（Talmor等人，2019）提供了一个多项选择题格式，要求模型运用常识知识（例如，“你会去哪里理发？A) 农场, B) 沙龙, C) 图书馆”）。

- TruthfulQA (Lin等人 2022)：该基准测试专门用于衡量一个模型是否真实，即能否避免生成错误信息或大语言模型中常见的幻觉。它测试模型在一些可能倾向于重复其训练数据中常见误解的问题上的表现。高分对于构建值得信赖的设备端助手至关重要。

- GSM8K (小学数学8K) (Cobbe等人 2021)：该基准测试评估模型执行多步骤数学推理的能力。它由一系列需要基本算术运算序列才能解决的文字问题组成。在GSM8K上的成功是模型推理能力提升的有力信号。

在评估一个新的边缘大语言模型时，标准做法是报告其在选定基准测试上的得分。这允许将其推理和知识能力与其更大的父模型以及该领域的其他高效模型进行直接比较。

5.3 系统效率指标

模型性能指标决定了人工智能是否能给出正确答案，而系统效率指标则决定了它能否在资源受限的设备上以实用的方式给出答案。对于一个边缘大语言模型而言，低延迟、小内存占用和最低的能耗不仅仅是理想特性，更是部署的基本要求。这些指标量化了推理的计算成本，并且通常是针对实际应用选择和优化策略时的决定性因素。

5.3.1 延迟

延迟是最能被用户感知的效率指标。它衡量执行一项推理任务所需的时间，并直接影响应用程序的响应速度和流畅度。对于逐词生成文本的生成式大语言模型而言，延迟并非单一数值，而是分解为两个关键组成部分：

- **首词元时间**：这是指从用户提交提示词到模型生成并显示出其响应的第一个标记所经过的时长。首词元时间包含了处理输入提示词（预填充阶段）所花费的时间，这一阶段计算密集，因为必须并行计算所有输入词元的注意力机制。从用户体验的角度来看，首词元时间是模型被感知的“思考”时间。较低的首词元时间对于让应用感觉即时响应至关重要。

- **单输出词元时间或词元间延迟**：这是生成第一个词元后，产生每个后续词元所需的平均时间。这个阶段被称为自回归解码，涉及模型的一次前向传播以产生单个词元。此步骤的速度决定了响应的其余部分被流式传输到屏幕的速度。低单输出词元时间会带来流畅、连续的本流，而高单输出词元时间则会导致输出断断续续、卡顿，感觉缓慢。

这两个指标共同定义了整体生成速度。一个相关且常被报告的指标是吞吐量，以每秒令牌数衡量。它是 TPOT 的倒数，代表模型在解码阶段的原始生成速率。

5.3.2 内存使用

内存可以说是在边缘设备上运行大模型最显著的瓶颈。手机和其他边缘硬件的内存容量有限，必须在操作系统、前台应用和各种后台进程之间共享。如果一个大语言模型的内存需求超过了可用资源，它根本无法运行。内存使用通过两种方式评估：

- **静态内存（磁盘上的模型大小）**：指存储模型参数所需的持久存储（闪存或 SSD）量。通常以千兆字节（GB）为单位衡量。该指标直接影响应用的安装大小，并可能影响将模型从存储加载到内存所需的初始时间。

- **动态内存（峰值 RAM 使用量）**：这是最关键的内存指标。它衡量的是应用程序在执行推理任务期间消耗的最大内存量。该数值总是大于静态模型大小，因为它包括：1) 模型权重：模型的参数，必须加载到内存中进行计算；2) KV 缓存：一个庞大且动态增长的缓存，用于存储序列中先前令牌的键值状态（对于长上下文，

KV 缓存可能占用数千兆字节的内存，常常成为内存使用中最大的单一组成部分），3) 中间激活值：前向传播过程中产生的临时张量，以及 4) 运行时开销：推理引擎及其他应用逻辑所使用的内存。

超出可用动态内存将导致应用程序崩溃，或迫使操作系统终止其他后台应用程序，从而导致整体用户体验不佳。

5.3.3 能耗

对于任何电池供电设备，从智能手机到笔记本电脑，能耗都是一个至关重要的考量因素。运行大语言模型是一个计算密集型过程，如果未经优化，可能会迅速耗尽电池电量。此外，高功耗会产生热量，这可能导致热节流，进而导致性能下降。能源效率通过两个关键指标来衡量：

- **功耗（瓦特）**：这是设备片上系统（SoC），或具体使用的中央处理器、GPU 或神经网络处理器在大语言模型运行时消耗的瞬时电功率。通常使用专门的硬件功耗监测器进行精确测量，但芯片供应商提供的基于软件的估算方法也常被使用。

- **单次推理能耗（焦耳）**：这是衡量能效最全面的指标。它量化了完成一项定义任务（例如，处理一个提示并生成一个 100 个词元的响应）所消耗的总能量。其计算方式为平均功耗乘以任务所用时间。在比较模型时，该指标优于瞬时功耗，因为它考虑了速度。例如，一个高度优化的模型可能具有更高的峰值功耗，但完成推理任务的速度非常快，以至于其消耗的总能量比一个速度较慢、功耗较低的模型更少。该指标直接关系到模型对设备电池续航的影响。

6 边缘大语言模型应用

尽管第 3 节和第 4 节已经概述了边缘大语言模型训练、微调和推理的优化技术，但这些技术的应用与实际应用部署之间仍存在差距。在下文中，我们为旨在

部署这些系统，然后介绍最流行的边缘大语言模型应用。

成功的部署始于对目标硬件约束的严格评估，即如表1所示，评估可用内存、计算能力和功耗预算。此硬件配置直接指导合适基础模型的选择，因为在资源受限的设备上部署大型模型是不可行的。对于高性能边缘设备（第一层级），7–30B 参数范围的模型是一个强有力的起点；而移动设备（第二层级）更适合高度高效的 3–7B 模型；资源受限的微控制器（第三层级）则可能需要参数少于 3B 的模型。

一旦选定模型，主要瓶颈便决定了优化策略。对于常见的内存受限环境，结合多种技术至关重要。量化，特别是像GPTQ或AWQ这样的4位方法，是减少模型存储占用不可或缺的第一步。这辅以通过GQA等架构选择来优化KV缓存的运行内存使用。为了解决延迟并为应用实现交互速度，实践者应利用专门的推理引擎，如MLC-LLM或TensorRT-LLM，它们通过内核融合等技术最大化硬件利用率。此外，推测解码能显著提升感知吞吐量，使实时交互成为可能。最后，对于需要设备端个性化的应用，像LoRA这样的PEFT方法是无需昂贵完全重新训练即可适配模型的标准方案。

最终，最有效的部署采用一种整体的多层策略。例如，一个典型的移动应用可能涉及采用一个3–8B参数模型，应用4位量化，使用硬件感知引擎进行编译，并可能通过推测解码进一步加速。这种分层方法是本次调研得出的关键实践教训；它使实践者能够系统地在模型能力与边缘硬件的严苛要求之间取得平衡，将本节讨论的理论应用转化为实际现实。

6.1 消费电子与智能设备

边缘大语言模型最直接、最广泛的影响正体现在消费电子领域。我们口袋里的智能-手机、家中的智能音箱、手腕上的智能手表以及我们工作用的笔记本电脑，正成为设备端人工智能的主要平台（Yi等人，2023）。通过将智能从遥远的云端转移到本地设备，制造商们正在创造出更快、更可靠、更私密且深度个性化的产品。这些应用将用户交互范式从

从明确的指令之一转变为智能、情境感知和主动的协助之一。

6.1.1 智能手机：个人人工智能中心

智能手机是边缘大语言模型革命的中心（Liu 等人，2024；Qin 等人，2024）。凭借配备专用神经网络处理器的强大片上系统，它们完全有能力承载复杂的模型，从而彻底改变用户体验。

- 真正智能的助手：当前的语音助手通常依赖云端，导致离线时延迟高且功能有限。设备端大语言模型能极大增强这些助手，使其能够处理复杂的多轮对话，并理解用户屏幕上的内容上下文。用户可以命令助手总结项目管理相关的最近三封邮件，并起草回复说文件将在下午审阅，而手机可以在不泄露任何个人《数据》的情况下执行整个任务。
- 主动的《操作系统》级集成：除了被动的助手，边缘大语言模型可以集成到移动《操作系统》的底层架构中。这使得能够提供预测用户需求的主动协助。示例包括：1) 智能回复与摘要：为任何消息应用自动生成基于上下文的回复建议；2) 通知管理：智能分类、优先级排序和摘要通知，以应对信息过载；3) 自然语言搜索：允许用户使用对话式语言查找文件、照片或设置。
- 设备端创意与编辑：用于照片和视频编辑的生成式人工智能功能变得即时且私密。用户可以通过简单的文本指令执行复杂编辑，例如移除图片背景中的人物或让天空看起来更具戏剧性，所有处理均在本地进行。同样，写作辅助（起草、改写、总结和改变文本语气）可以在用户能够输入的任何应用程序中实现。

6.1.2 智能家居与物联网设备

在智能家居中，隐私和响应能力至关重要。边缘大语言模型解决了当前依赖云端的智能音箱和中枢的核心限制（King 等人，2024）。

- 自然且对话式的控制：用户无需使用刻板、需要记忆的指令（例如“嘿助手，将客厅恒温器设置为72度”），而是可以进行自然交互。用户可能会说：“这里感觉有点闷”，

而运行在中央智能家居中枢或扬声器上的设备端大语言模型，可以推断意图并打开风扇或调节空调。

- **增强的隐私与安全：**在智能家居领域最显著的优势是隐私。本地处理语音指令意味着关于家庭、健康或财务的敏感对话不会被持续传输到公司的服务器。这对于配备摄像头和麦克风的设备（如安防系统和婴儿监视器）尤为关键。
- **智能自动化：**一个边缘大语言模型可以作为整个家庭的推理引擎，学习用户模式并自动化日常任务，无需复杂的手动编程。它可能会注意到用户总是在晨间闹钟后打开咖啡机和百叶窗，并主动建议创建一个自动化的晨间场景。

6.1.3 个人电脑

随着个人电脑和笔记本电脑越来越多地配备神经网络处理器，设备端大语言模型将重新定义生产力（Wang et al. 2024）。

- **系统级副驾：**集成到操作系统中的AI助手（如微软Copilot）可以执行跨多个应用的任务。由于它们在本地运行，因此可以安全地访问并推理用户的本地文件、电子邮件、日历和应用。用户可以询问：“总结我刚收到的PDF提案中的要点，并将其与我上周二会议中的笔记进行比较”，而助手可以在这些敏感业务数据永不离开设备的情况下完成任务。
- **离线生产力：**对于经常出差或网络不稳定的专业人士而言，能够离线使用强大的人工智能工具将改变游戏规则。起草文档、生成代码、总结研究论文以及分析《数据》都可以无缝衔接，确保生产力永不中断。

6.2 智能交通系统

汽车工业正在经历一场翻天覆地的变革，车辆正从机械机器演变为精密的、软件定义的轮上计算机（Liu et al. 2025）。在这一新范式中，人工智能的角色至关重要，而边缘大语言模型正成为创造更安全、更直观、更高效的交通系统的关键技术（Yan and Li 2025）。**车辆独特的运行环境**（其中网络连接可能时断时续，延迟可能关乎生死，数据隐私至关重要）

日益增长的担忧）使得设备端处理成为绝对的必要。

6.2.1 对话式座舱

边缘大语言模型在车辆中最直接的应用是彻底改变座舱体验（Xu等人，2025）。当前的语音控制系统通常僵化，仅限于狭窄的指令集，并且依赖于稳定的云端连接。设备端大语言模型创造了一个真正智能的车载助手，它具备对话能力、情境感知能力，且私密。

- **自然且复杂的车辆控制：**驾驶员和乘客可以使用自然、对话式的语言与车辆交互，助手将智能地调节气候控制。它还能处理复杂、复合的请求，例如导航到回家路上最近的咖啡店。
- **情境感知辅助：**设备端大语言模型可以融合来自各种来源的信息，包括车辆传感器、导航路线、驾驶员日历，甚至屏幕内容，以提供主动且相关的帮助。它可以警告驾驶员燃油不足并自动将加油站添加到路线中，或者阅读并总结收到的短信并建议一个符合情境的回复，同时始终理解首要任务是尽量减少驾驶员分心。
- **无与伦比的隐私：**汽车内部是一个私人空间（Jiang et al. 2023）。通过在车辆自身硬件内完全处理语音指令和对话，边缘大语言模型确保个人或商业讨论不会被传输到第三方服务器。这对消费者而言是一个强大的卖点，也是确保《数据》安全的关键特性。

6.2.2 高级驾驶辅助系统

虽然用于ADAS（高级驾驶辅助系统）和自动驾驶的传统控制系统依赖于确定性的、基于视觉的模型，但大语言模型正开始通过提供更高层次的推理和解释能力，在增强这些系统中扮演关键角色（Shao et al. 2024）。

- **场景理解与意图预测：**大语言模型可以为来自摄像头和激光雷达的原始《数据》添加一层常识推理。通过在海量描述人类行为和交通状况的数据集上进行训练，它可以帮助系统从简单地识别物体（例如，有一个行人）提升到预测其意图（例如，该行人正在看手机，可能

可能没有注意到人行横道)。意图预测对于在复杂的城市环境中导航至关重要。

- 处理长尾场景：自动驾驶系统经过数百万英里驾驶数据的训练，但它们仍然可能遇到罕见的、意料之外的长尾事件（例如，不寻常的道路碎片、穿着戏服的人指挥交通、复杂的交通事故场景）。大语言模型凭借其广泛的世界知识，可以作为一个推理引擎，帮助车辆在面对从未明确训练过的情况时做出更安全的决策。

- 用于提升驾驶员信任的可解释人工智能（XAI）：自动驾驶技术普及的一个关键障碍是驾驶员信任。当自动驾驶汽车做出决策时，例如突然刹车或变道，驾驶员可能会感到困惑或惊慌。设备端大语言模型可以将复杂的传感器数据和系统逻辑实时转化为简单、自然的语言解释，例如：车辆减速是因为检测到前方两辆车处有车辆意外汇入。这个反馈循环对于建立信心和确保安全的人机协作至关重要。

6.2.3 车联网通信

边缘大语言模型可以作为智能过滤器和解释器，处理车联网（V2X）通信中涉及的海量数据流，在这种通信中，车辆彼此之间以及与周围基础设施进行对话（Chiu et al. 2025）。

- 智能车联网数据处理：一辆车可能从附近的汽车和交通信号接收数百个原始数据包。设备端大语言模型可以实时处理这股信息洪流，过滤掉噪声，并将最关键的信息总结成可供驾驶员或ADAS采取行动的可执行警报。例如，它可以将来自交通管理中心的数据流转化为一个简单的警报：前方2英里处报告有事故，将导致15分钟延误，并已找到一条更快的路线。

- 增强型车队物流：对于商业车队（例如卡车运输、配送服务），设备端大语言模型能显著提升效率。驾驶员可以使用语音指令记录交付、报告路况并完成文书工作，全程无需双手离开方向盘。该系统能基于大语言模型解读的实时交通数据动态优化路线，并通过本地分析车辆传感器数据提供预测性维护警报，从而减少对中央调度的依赖，提高运营正常运行时间。

6.3 智慧医疗

医疗保健行业在数据隐私、可靠性和安全方面遵循着全球最严格的要求之一（Jiang 2025）。监管环境，加上在网络连接可能不可靠的环境（例如医-院、救护车、乡村诊所）中对实时决策支持的需求，使得医疗保健成为采用边缘大语言模型的主要领域。通过在本地处理《数据》，这些模型能够提供强大的人工智能能力，同时从根本上尊重患者隐私并确保运营连续性。医疗保健领域的主要限制并非性能，而是数据隐私。因此，能够在边缘大语言模型微调和设备端大语言模型推理（第4节）过程中保护患者保密性的联邦学习（第3.2节）和分割学习（第3.3.2节）策略，以及防止《数据》离开诊所的技术，都成为了关键的使能技术。

6.3.1 临床医生赋能

现代医学最重大的挑战之一是临床医生面临的巨大行政负担，这常常导致职业倦怠，并减少了直接患者互动的机会。边缘大语言模型可以直接解决这一问题，充当医生和护士的设备端助手（Wan 等人2024）。

- 环境临床记录：临床医生可以与患者进行自然对话，同时平板电脑或智能设备上的专用应用程序进行监听。设备端大语言模型实时转录对话，识别医学相关信息（症状、病史、药物），并自动将其构建成临床记录。整个过程在离线状态下完成，这意味着敏感的患者对话永远不会离开诊所的安全环境。这极大地减少了文书工作时间，让临床医生能够完全专注于患者。

- 离线医学参考与决策支持：在医院或Wi-Fi信号不稳定的偏远诊所，医生可能需要快速查询药物相互作用、诊断标准或治疗指南。运行在本地设备上的边缘大语言模型可以即时访问海量预加载的医学知识库。例如，医生可以询问，对于估算肾小球滤过率为40的患者，开具二甲双胍的禁忌症有哪些，并在无需互联网连接的情况下，立即获得一份基于循证摘要的答复。

6.3.2 慢性病管理

对于患者，尤其是那些管理慢性病或老年人，边缘大语言模型可以驱动运行于其智能手机或专用家庭设备上的健康伴侣，以私密且易于访问的方式提供指导和支持 (Wang et al. 2024)。

- **智能用药与健康提醒：**一个设备端助手可以管理复杂的用药计划，但其功能不止于简单的闹钟提醒。它可以与用户进行对话（例如，“现在是晚间服药时间；您吃过晚饭了吗？”），根据预加载的信息回答关于副作用的疑问，并记录用药依从性。
- **解读个人健康数据：**使用连续血糖监测仪、智能血压袖带或心电图手表等设备的患者会持续产生健康数据流。边缘大语言模型可以将原始数据转化为简单易懂的语言。例如，应用程序不仅可以显示血糖图表，还可以说明血糖水平在夜间保持稳定，处于您的目标范围内。这种数据解读能力使患者能够更好地了解自身状况并做出明智的生活方式选择，同时其个人健康数据仍安全地保留在自己的设备上。

6.3.3 辅助技术

边缘大语言模型能够为更直观、响应更快的辅助技术提供动力，从而显著改善残障人士的生活质量 (Zhuang等人, 2025)。

- **增强型沟通辅助工具：**对于有言语障碍的人士，设备端大语言模型可以根据其独特的语音模式进行微调，从而准确解读通用云端模型无法理解的指令。这使得对智能家居设备、轮椅和通信软件进行可靠、低延迟的控制成为可能。
- **感官障碍的实时辅助工具：**连接到智能手机摄像头的边缘大语言模型可以充当视障人士的实时导盲眼，描述周围环境、阅读文档或标志上的文字、并识别杂货店中的商品。其设备端的特性确保了这种辅助始终可用、即时且私密。

6.4 工业4.0与机器人技术

工业4.0代表了制造技术中持续的自动化和《数据》交换，从而创造出智能

工厂中，信息物理系统监控并控制物理过程。在此环境中，可靠性、速度和数据安全不仅是商业目标，更是运营上的硬性要求。生产线不能因互联网连接中断而停止，专有的制造-工艺是必须保护的商业机密。这使得工厂车间成为边缘大语言模型理想且在许多情况下是强制性的应用环境。通过在机器人、机械和控制系统中本地运行人工智能，制造商可以构建更灵活、智能和具有韧性的运营体系 (Colabianchi等人, 2024)。

6.4.1 自然人机交互

历史上，编程和操作工业机器人需要专业知识和复杂的编码界面。边缘大语言模型正在通过使自然语言成为一种新颖、直观的人机交互界面，来推动机器人技术的普及 (Fan et al. 2025)。

- **对话式机器人编程：**工厂技术人员或产线工人，即使没有任何机器人技术背景，也可以通过简单的语音或键入指令来指挥机器人。他们无需使用带有复杂菜单的示教器，而是可以通过自然对话来指示机器人从传送带上每隔一个拾取零件，并将其放入质量控制箱中。设备端大语言模型将操作意图转化为精确的机器人动作序列。这极大地减少了设置时间，提高了灵活性，并使现有员工能够管理自动化系统。

- **更安全、更直观的协作机器人：**对于设计用于与人类并肩工作的协作机器人 (cobots) 而言，沟通是安全与效率的关键。边缘大语言模型使协作机器人能够理解其环境并与人类伙伴互动。它可以理解口头警告，例如“小心”，并立即暂停其运动。它还可以解释自身的行动，减少不可预测性，并在共享工作空间中建立信任。

6.4.2 智能诊断

停机时间是制造业的大敌。边缘大语言模型可以充当智能诊断引擎，持续监控设备健康状况，以在故障发生之前进行预测 (Palma 等人, 2025)。

- **实时异常解释：**工业设备配备有传感器，可产生关于振动、温度、压力和功耗的海量数据流。边缘大语言模型能够本地实时分析这些数据流。关键在于，它超越了简单的

异常检测（一个危险信号）以提供解释。机器的界面可以报告：主轴的振动频率已发生偏移，这是轴承磨损的早期迹象；我建议在未来48小时内安排维护，以避免发生严重故障。而不是一个晦涩的错误代码。

- **交互式故障排查与维修：**当设备发生故障时，设备端大语言模型可以指导技术人员完成维修流程。技术人员能以对话方式向设备提问：更换这个液压泵的步骤是什么？边缘大语言模型能即时调取技术手册的正确章节，显示图表或视频，甚至提供分步检查清单。这一切都在本地完成，确保敏感的机器原理图和运行数据安全地保留在工厂内部。

6.5 增强现实与虚拟现实

增强现实与虚拟现实若要实现其无缝融合数字与物理世界的终极愿景，必须克服一个根本性的技术障碍：延迟（Zhao等人，-2024）。在沉浸式体验中，用户动作与系统响应之间的延迟必须难以察觉（通常低于20毫秒），以避免破坏临场感并引发晕动症。这一不容妥协的单一要求使得基于云的人工智能无法满足实时交互需求。往返远程服务器的传输时间实在太长。因此，直接在头戴式设备、眼镜或连接的本地设备上运行的边缘大语言模型，不仅是增强现实/虚拟现实的改进方案，更是创造真正交互式且可信的合成世界所必需的关键使能技术（Hong等人，-2024）。该应用领域对单输出词元时间与首词元时间特别敏感，因为任何可感知的延迟都会破坏用户沉浸感。因此，推测解码（第4.3.2节）和硬件-专用内核优化（第4.3.3节）等技术至关重要。

6.5.1 AR中的情境感知

AR将数字信息叠加到用户对现实世界的视野中。为了使这些叠加信息有用，它们必须是智能的、相关的，并且与现实完美同步。设备端大语言模型作为实时推理引擎，使这一切成为可能（Behravan等人，2025）。

- **实时世界理解：**增强现实眼镜配备有摄像头和麦克风，能持续感知用户周围环境。一个边缘大语言模型在本地处理数据流，使其能够理解

用户正在看什么、他们正在与谁交谈，以及他们正在做什么。这种理解会在设备上即时且私密地发生。

- **情境信息与引导：**基于实时理解，大语言模型可以提供即时信息，例如现实世界搜索、即时翻译和分步指导。
- **隐私需求：**增强现实眼镜捕捉用户生活的第一人称视角。将这种高度个人化的视频流持续传输到云端服务器的想法是一个重大的隐私顾虑。通过在设备端处理数据，边缘大语言模型确保用户的世界仍属于他们自己。

6.5.2 VR中的交互式虚拟世界

在VR中，用户完全沉浸于计算机生成的环境中。边缘大语言模型有望将这些世界从静态、脚本化的空间转变为动态、有生命力的环境（Afzal等人 2025）。

- **真正交互式的非玩家角色：**几十年来，游戏和模拟中的角色一直局限于预定义的对话树。由设备端大语言模型驱动的NPC可以进行开放式、非脚本化的对话。它们可以记住过去的互动，理解用户的意图，并以真正的自发性做出反应。这将训练模拟、教育体验和游戏提升到了一个新的真实感和沉浸感水平。
- **动态世界生成与控制：**用户成为创造者。边缘大语言模型允许用户通过自然语言指令操控虚拟世界。在一个创意应用中，用户可以指令在某个山顶上建造一座带有护城河的中世纪城堡，环境将被实时生成。这将交互方式从按键操作提升为更直观、更强大的表达形式。
- **社交VR与虚拟化身：**在社交VR平台中，边缘大语言模型可以实现更逼真的互动。它们可以驱动虚拟化身的面部表情和肢体语言以匹配用户的语音，或在来自世界不同地区的用户之间进行实时语言翻译，从而促进更自然、更具包容性的交流。设备端处理的低延迟确保了这些互动感觉即时且真实。

7 未来方向与开放挑战

尽管当前边缘大语言模型的应用已经具有变革性，但这项技术仍处于起步阶段。通往无处不在、功能强大且真正智能的设备端人工智能的旅程，既充满了令人兴奋的可能性，也面临着巨大的技术障碍。该领域正在进行的研究和开发不仅专注于完善现有能力，还致力于解锁全新的人机交互范式。然而，要实现这一未来，需要研究人员、硬件制造商和软件开发者共同努力，以克服在效率、可扩展性和安全方面的根本性挑战。

7.1 未来方向

边缘大语言模型的发展轨迹指向一个未来，在那里智能不仅是本地化的，更是深度个性化、协作化且无缝融入我们环境的。

超个性化与终身学习：下一代边缘大语言模型将超越静态的预训练模型，发展为能够持续进行设备端学习的系统。想象一下，一个智能手机助手不仅知道你的联系人，还能学习你的沟通风格，理解你人际关系的细微差别，并在多年的互动中不断调整其建议。终身学习将使模型能够为每位用户构建独特的、深度个性化的上下文，而无需将底层个人数据发送到云端。这将创造出终极的个性化人工智能，在一个仅包含单一个体的数据集上进行微调。

设备间协作：边缘智能的未来可能不局限于单一设备，而是分布在由个人设备组成的生态系统中。这一被称为群体智能的概念，将允许你的智能手机、智能手表、笔记本电脑和汽车进行协作。例如，你汽车上的边缘大语言模型可以通知家中的智能中枢你还有10分钟到家，从而提示你的笔记本电脑从睡眠中唤醒，并让智能音箱开始播放欢迎回家的播放列表。这种去中心化的协作将在你的设备之间直接发生，从而创建一个具有弹性且私密的个人网络。

边缘多模态推理：未来的边缘大语言模型将天生具备多模态能力，不仅能理解和推理文本与语音，还能处理视频、传感器数据，甚至生物特征信号。一个增强现实眼镜应用可以同时聆听对话、分析参与者的面部表情，并交叉参考网络信息，以提供一个丰富的实时社交教练。在医疗保健领域，一个可穿戴设备可以关联用户对症状的口头描述

并结合其实时心电图数据，以提供更准确、更具情境性的健康警报。

面向边缘大语言模型的Web3 DePIN：未来的边缘大语言模型可以利用Web3的去中心化物理基础设施网络（DePIN）来创建点对点的计算市场（Jiang等人，2026）。在此模型中，设备可以将密集的人工智能任务卸载到附近更强大的硬件上，以换取基于代币的微支付。这利用加密经济激励来构建一个用于人工智能处理的、有韧性的、用户拥有的网络，培育一种去中心化的、替代传统云服务的方案，并允许用户将其闲置的计算资源货币化（Wang等人，2024）。

生成式物理人工智能：先进的机器人技术与边缘大语言模型的结合，将催生出能够理解并执行物理世界中抽象的、目标导向指令的机器人（Liang等人，2024）。这将超越简单的编程，实现真正的任务理解。用户可以告诉一个家用机器人去清理杂物，而机器人将利用其设备端推理能力来识别物体、确定合适的工具（抹布处理泼洒物，簸箕处理碎屑），并执行一个多步骤计划来完成该任务。

7.2 开放挑战

尽管进展迅速，但要让强大的边缘大语言模型成为广泛现实，仍需解决重大挑战。下文我们将列出几个关键的开放挑战。

模型优化与效率：这是最关键的挑战。模型向更大、能力更强的趋势发展，这与边缘设备有限的功耗和散热预算直接冲突。一方面，虽然量化和剪枝等技术是有效的，但将其推向极致（例如2位或1位模型）通常会导致准确性显著下降。在模型大小与性能之间找到最佳权衡点，仍然是一个主要的研究领域。另一方面，需要专门为效率而非单纯追求原始能力而设计的新模型架构。在专家混合模型（MoE）和状态空间模型等领域的创新显示出前景，但需要进一步改进才能实现设备端部署。

软硬件协同设计：要实现性能最大化，需要一种整体性方法，即软件模型的设计与运行它们的硬件同步进行。未来可能会出现更复杂、更专用的加速器。下一代神经网络处理器的设计必须参考未来大语言模型的计算模式。这包括增加片上存储器（静态随机存取存储器）以减少数据移动，以及对新型数据类型和稀疏性的硬件支持。此外，由于缺乏访问不同神经网络处理器的通用软件层（类似于CUDA之于图形处理器的角色），开发者生态系统呈现碎片化。一个标准化堆栈

这将使得在广泛的设备上部署模型变得更加容易。

设备端数据管理与学习：在不影响设备性能或稳定性的前提下，实现设备上的终身学习是一个复杂的问题。一方面，灾难性遗忘在边缘大语言模型中仍然是一个严重问题。神经网络在接受新数据训练时，往往会遗忘之前学到的知识。开发能够持续增量学习且避免灾难性遗忘的方法，对于需要随时间适应的模型至关重要。另一方面，功耗与性能成本是核心关切。训练或微调过程在计算上成本高昂。在后台执行这些更新而不耗尽电池电量或导致设备无响应，是一项重大的工程挑战。

隐私、安全与伦理：虽然边缘人工智能通过将数据保留在本地，本质上增强了隐私，但它也引入了新的风险。首先，在模型安全方面，如果模型本身是个人信息的存储库，它就会成为高价值目标。保护模型权重不被提取或逆向工程至关重要。其次，对抗性攻击尚未得到充分处理。设备端模型与云端模型一样容易受到对抗性攻击（导致错误分类的巧妙操纵输入）的影响。确保其鲁棒性至关重要，尤其是在汽车领域和医疗保健等安全关键型应用中。第三，伦理偏见问题严重。在大型公共数据集上训练的模型可能会继承并延续社会偏见。如果这些带有偏见的模型随后大规模部署在数十亿台设备上，它们可能会强化有害刻板印象。为面向边缘的模型开发审计和减轻偏见的技术，是一项关键的伦理责任。

可靠性感知压缩与幻觉缓解：尽管当前研究高度优先考虑最小化内存占用和延迟，但一个关键且未被充分探索的前沿领域是激进的模型压缩与幻觉生成之间的关联。随着边缘大语言模型被推向极端量化（例如，低于4位）和高稀疏性以适应三级设备，它们面临着显著的知识遗忘和推理崩溃风险。未来的研究必须超越标准的性能指标（如困惑度或BLEU），这些指标通常无法捕捉压缩模型中事实可靠性的微妙损失。关键的开放挑战如下。首先，量化压缩引发的幻觉是困难的。开发严格的基准测试来绘制量化的安全悬崖，并识别推理能力相对于模型大小非线性下降的精确阈值至关重要。其次，研究大语言模型的哪些组件对事实回忆最为负责，从而允许采用混合精度策略，在积极压缩的同时保留知识密集权重，这既具有挑战性又意义重大。

压缩其他部分。第三，可靠性感知的模型压缩对于边缘设备而言至关重要。压缩后的模型常常存在校准错误，对错误答案变得过于自信。开发专门针对量化模型的轻量级训练后校准方法，对于部署在医疗保健或自动驾驶等安全关键边缘应用中至关重要。

8 结论

本调研描绘了大语言模型从集中式云端基础设施向网络边缘的根本性范式转变，这一转变是由对数据隐私、低延迟交互和离线可靠性的关键需求所驱动的。为应对在资源受限的硬件上部署这些资源密集型模型的重大技术挑战，本工作提供了一个全面的、端到端的工程路线图。它系统地详述了设备端适配的关键技术，例如参数高效微调和联邦学习，并深入探讨了高效推理的支柱：模型压缩、优化架构和运行时系统优化。通过弥合算法理论与系统级实现之间的鸿沟，本调研为构建下一代私密、响应迅速且智能的边缘应用提供了实用指南。

致谢 本工作由香港研资局主题研究计划（编号：T43-513/23-N）及香港理工大学人工智能物联网研究院支持。

数据可用性不适用

声明

利益冲突 通讯作者代表所有作者声明，不存在利益冲突。

参考文献

- Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., 等: Tensorflow: 一个用于大规模机器学习的系统。见: 第12届USENIX操作系统设计与实现研讨会 (OSDI 16), 第265–283页 (2016) Acharya, K., Velasquez, A., Song, H.H.: 关于大语言模型符号知识蒸馏的调研。IEEE Trans. Artif. Intell. (2024) Afzal, M.Z., Ali, S.A., Stricker, D., Eisert, P., Hilsmann, A., Perez-Marcos, D., Bianchi, M., Crottaz-Herbette, S., De Ioris, R., Mangina, E., 等: 下一代XR系统——大语言模型与增强现实和虚拟现实相遇。IEEE Comput. Gr. Appl. (2025)

- Ainslie, J., Lee-Thorp, J., De Jong, M., Zemlyanskiy, Y., Lebrón, F., Sanghai, S.: GQA: 从多头检查点训练广义多查询Transformer模型。arXiv预印本arXiv:2305.13245 (2023)
- Arivazhagan, M.G., Aggarwal, V., Singh, A.K., Choudhary, S.: 带个性化层的联邦学习。arXiv预印本arXiv:1912.00818 (2019)
- Behravan, M., Matković, K., Gračanin, D.: 利用增强现实中视觉语言模型的生成式人工智能进行情境感知3D对象创建。见: 2025 IEEE人工智能与扩展及虚拟现实国际会议 (AIXVR), 第73–81页 (2025). IEEE
- Beltagy, I., Peters, M.E., Cohan, A.: Longformer: 长文档Transformer。arXiv预印本arXiv:2004.05150 (2020)
- Bengio, Y., Ducharme, R., Vincent, P., Jauvin, C.: 一种神经概率语言模型。《机器学习研究杂志》3(2月), 1137–1155 (2003)
- Blalock, D., Gonzalez Ortiz, J.J., Frankle, J., Gutttag, J.: 神经网络剪枝的现状如何? 《机器学习与系统会议论文集》2, 129–146 (2020)
- Brown, T.B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D.M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D.: 语言模型是少样本学习器。见: 神经信息处理系统年会 (NeurIPS 20) (2020)
- Chaudhari, S., Aggarwal, P., Murahari, V., Rajpurohit, T., Kalyan, A., Narasimhan, K., Deshpande, A., Silva, B.: RLHF解密: 针对大语言模型的基于人类反馈的强化学习批判性分析。《ACM计算概览》58(2), 1–37 (2025)
- Chen, X., Cao, J., Sahni, Y., Jiang, S., Liang, Z.: 基于依赖感知强化学习的边缘计算动态任务卸载。《IEEE云计算汇刊》12(2), 594–608 (2024)
- Chen, H., Deng, W., Yang, S., Xu, J., Jiang, Z., Ngai, E.C., Liu, J., Liu, X.: 通过大语言模型迈向边缘通用智能: 机遇与挑战。《IEEE网络》39(5), 263–271 (2025)
- Chen, J., Liu, Z., Huang, X., Wu, C., Liu, Q., Jiang, G., Pu, Y., Lei, Y., Chen, X., Wang, X., 等: 当大语言模型遇见个性化: 挑战与机遇的视角。《万维网》27(4), 42 (2024)
- Chen, Y., Qian, S., Tang, H., Lai, X., Liu, Z., Han, S., Jia, J.: LongLoRA: 长上下文大语言模型的高效微调。arXiv预印本arXiv:2309.12307 (2023)
- Chen, C., Borgeaud, S., Irving, G., Lespiau, J.-B., Sifre, L., Jumper, J.: 利用推测采样加速大语言模型解码。arXiv预印本arXiv:2302.01318 (2023)
- Chen, T., Moreau, T., Jiang, Z., Zheng, L., Yan, E., Shen, H., Cowan, M., Wang, L., Hu, Y., Ceze, L., 等: TVM: 一个用于深度学习的自动化端到端优化编译器。见: 第13届USENIX操作系统设计与实现研讨会 (OSDI 18), 第578–594页 (2018)
- Chetlur, S., Woolley, C., Vandermersch, P., Cohen, J., Tran, J., Catanzaro, B., Shelhamer, E.: cuDNN: 深度学习的高效原语。arXiv预印本arXiv:1410.0759 (2014)
- Child, R., Gray, S., Radford, A., Sutskever, I.: 使用稀疏Transformer生成序列。arXiv预印本arXiv:1904.10509 (2019)
- Chiu, H.-k., Hachiuma, R., Wang, C.-Y., Smith, S.F., Wang, Y.-C.F., Chen, M.-H.: V2V-LLM: 基于多模态大语言模型的车对车协同自动驾驶。arXiv预印本arXiv:2502.09980 (2025)
- Choromanski, K., Likhoshesterov, V., Dohan, D., Song, X., Gane, A., Sarlos, T., Hawkins, P., Davis, J., Mohiuddin, A., Kaiser, L., et al.: 重新思考注意力机制与Performers。arXiv预印本arXiv:2009.14794 (2020)
- Cobbe, K., Kosaraju, V., Bavarian, M., Chen, M., Jun, H., Kaiser, L., Plappert, M., Tworek, J., Hilton, J., Nakano, R., et al.: 训练验证器解决数学文字问题。arXiv预印本arXiv:2110.14168 (2021)
- Colabianchi, S., Costantino, F., Sabetta, N.: 评估基于大语言模型的数字智能助手在装配制造中的应用。计算机工业 162, 104129 (2024)
- Das, B.C., Amini, M.H., Wu, Y.: 大语言模型的安全与隐私挑战: 一项调研。《ACM计算概览》57(6), 1–39 (2025)
- Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L.: QLoRA: 量化大语言模型的高效微调。神经信息处理系统进展 36, 10088–10115 (2023)
- Fan, H., Liu, X., Fuh, J.Y.H., Lu, W.F., Li, B.: 制造业中的具身智能: 利用大语言模型实现自主工业机器人。智能制造杂志 36(2), 1141–1157 (2025)
- Friha, O., Ferrag, M.A., Kantarci, B., Cakmak, B., Ozgun, A., Ghoualmi-Zine, N.: 基于大语言模型的边缘智能: 关于架构、应用、安全与可信度的全面调研。IEEE通信学会开放期刊 5, 5799–5856 (2024)
- Fu, Y., Xue, L., Huang, Y., Brabete, A.-O., Ustiugov, D., Patel, Y., Mai, L.: ServerlessLLM: 大语言模型的低延迟无服务器推理。见: 第18届USENIX操作系统设计与实现研讨会 (OSDI 24), pp. 135–153 (2024)
- Gao, Z., Zhang, Z., Guo, Y., Gong, Y.: 大语言模型的联邦自适应微调: 异构量化与LoRA。见: IEEE INFOCOM 2025-IEEE计算机通信会议, pp. 1–10 (2025). IEEE
- Gou, J., Yu, B., Maybank, S.J., Tao, D.: 知识蒸馏: 一项调研。国际计算机视觉杂志 129(6), 1789–1819 (2021)
- Greff, K., Srivastava, R.K., Koutník, J., Steunebrink, B.R., Schmidhuber, J.: LSTM: 一次搜索空间奥德赛。IEEE神经网络与学习系统汇刊 28(10), 2222–2232 (2016)
- Gu, Z., Fan, Q., Sun, L., Liu, Y., Ye, X.: VFlair-LLM: 大语言模型分割学习的综合框架与基准。见: 第31届ACM SIGKDD知识发现与数据挖掘会议论文集 V. 2, pp. 5470–5481 (2025)
- Gu, A., Dao, T.: Mamba: 具有选择性状态空间的线性时间序列建模。见: 首届语言建模会议, pp. 1–32 (2024)
- Guu, K., Lee, K., Tung, Z., Pasupat, P., Chang, M.: 检索增强的语言模型预训练。见: 国际机器学习会议, pp. 3929–3938 (2020). PMLR
- Hendrycks, D., Burns, C., Basart, S., Zou, A., Mazeika, M., Song, D., Steinhardt, J.: 测量大规模多任务语言理解。arXiv预印本arXiv:2009.03300 (2020)
- Hinton, G., Vinyals, O., Dean, J.: 蒸馏神经网络中的知识。arXiv预印本arXiv:1503.02531 (2015)
- Hong, J., Lee, Y., Kim, D.H., Choi, D., Yoon, Y.-J., Lee, G.-c., Lee, Z., Kim, J.: 一个由大语言模型驱动元宇宙情境感知入门代理。见: 2024年ACM交互系统设计会议论文集, pp. 1857–1874 (2024)
- Hooper, C., Kim, S., Mohammadzadeh, H., Mahoney, M.W., Shao, Y.S., Keutzer, K., Gholami, A.: KVQuant: 通过键值缓存量化实现千万级上下文长度的大语言模型推理。神经信息处理系统进展 37, 1270–1303 (2024)
- Houlsby, N., Giurgiu, A., Jastrzebski, S., Morrone, B., De Laroussilhe, Q., Gesmundo, A., Attariyan, M., Gelly, S.: 参数高效

- 自然语言处理的迁移学习。见：国际机器学习会议，第2790–2799页（2019年）。PMLR Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W., et al.: LoRA: 大语言模型的低秩适应。ICLR 1(2), 3 (2022) Hu, Q., Ye, Z., Wang, Z., Wang, G., Zhang, M., Chen, Q., Sun, P., Lin, D., Wang, X., Luo, Y., et al.: 数据中心内大语言模型开发的特征分析。见：第21届USENIX网络系统设计与实现研讨会 (NSDI 24)，第709–729页（2024年） Jiang, S.: 大数据共享：一项全面调研。《数据》10(11), 182 (2025) Jiang, S., Cao, J., Wu, H., Chen, K., Liu, X.: 基于区块链的智能交通系统中隐私保护与高效的数据共享。《信息科学》635, 72–85 (2023) Jiang, S., Chai, W., Zhang, M., Cao, J., Xuan, S., Shen, J.: 通过边缘大语言模型验证基于Web3的去中心化清洁能源网络的发电量。《信息融合》127, 103752 (2026) Jiang, A.Q., Sablayrolles, A., Roux, A., Mensch, A., Savary, B., Bamford, C., Chaplot, D.S., Casas, D.d.l., Hanna, E.B., Bressand, F., et al.: Mixtral of experts. arXiv预印本 arXiv:2401.04088 (2024) Karimireddy, S.P., Kale, S., Mohri, M., Reddi, S., Stich, S., Suresh, A.T.: Scaffold: 用于联邦学习的随机控制平均。见：国际机器学习会议，第5132–5143页（2020年）。PMLR Katharopoulos, A., Vyas, A., Pappas, N., Fleuret, F.: Transformer模型是循环神经网络：具有线性注意力机制的自回归Transformer模型。见：国际机器学习会议，第5156–5165页（2020年）。PMLR King, E., Yu, H., Lee, S., Julien, C.: Sasha: 智能家居中基于大语言模型的创造性目标导向推理。《ACM交互式、移动、可穿戴和普适技术汇刊》8(1), 1–38 (2024) Kong, R., Li, Y., Wang, W., Kong, L., Liu, Y.: 通过动态专家交换在资源受限边缘设备上服务混合专家模型。《IEEE计算机汇刊》（2025） Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C.H., Gonzalez, J., Zhang, H., Stoica, I.: 利用分页注意力机制实现大语言模型服务的高效内存管理。见：第29届操作系统原理研讨会论文集，第611–626页（2023） Li, T., Sahu, A.K., Zaheer, M., Sanjabi, M., Talwalkar, A., Smith, V.: 异构网络中的联邦优化。《机器学习与系统会议论文集》2, 429–450 (2020) Li, X.L., Liang, P.: 前缀微调：优化用于生成的连续提示词。arXiv预印本 arXiv:2101.00190 (2021) Li, N., Guo, S., Zhang, T., Li, M., Hong, Z., Zhou, Q., Yuan, X., Zhang, H.: MoE赋能的边缘大语言模型部署：架构、挑战与机遇。arXiv预印本 arXiv:2502.08381 (2025) Liang, Z., Cao, J., Jiang, S., Xu, H.: 用于分布式多智能体协作的带伙伴建模的分层强化学习。《IEEE并行与分布式系统汇刊》，1–13 (2024) Lin, Z., Qu, G., Chen, Q., Chen, X., Chen, Z., Huang, K.: 将大语言模型推向6G边缘：愿景、挑战与机遇。《IEEE通信杂志》63(9), 52–59 (2025) Lin, J., Tang, J., Tang, H., Yang, S., Chen, W.-M., Wang, W.-C., Xiao, G., Dang, X., Gan, C., Han, S.: AWQ: 用于设备端大语言模型压缩与加速的激活感知权重量化。《机器学习与系统会议论文集》6, 87–100 (2024) Lin, X., Wang, W., Li, Y., Yang, S., Feng, F., Wei, Y., Chua, T.-S.: 基于大语言模型的推荐系统的数据高效微调。见：第47届国际ACM SIGIR信息检索研究与发展会议论文集，第365–374页（2024） Lin, Z., Hu, X., Zhang, Y., Chen, Z., Fang, Z., Chen, X., Li, A., Vepakomma, P., Gao, Y.: SplitLoRA: 一种用于大语言模型的分割参数高效微调框架。arXiv预印本 arXiv:2407.00952 (2024) Lin, C.-Y.: Rouge: 一个用于摘要自动评估的软件包。见：文本摘要分支，第74–81页（2004） Lin, S., Hilton, J., Evans, O.: TruthfulQA: 衡量模型如何模仿人类谬误。见：第60届计算语言学协会年会论文集，第3214–3252页（2022） Liu, P., He, Q., Chen, Y., Jiang, S.: 面向云边协同智能交通系统的高效多关键词可搜索可验证数据共享。《IEEE物联网期刊》12(11), 15869–15882 (2025) Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., Stoyanov, V.: Roberta: 一种鲁棒优化的BERT预训练方法。arXiv预印本 arXiv:1907.11692 (2019) Liu, X., Ji, K., Fu, Y., Tam, W.L., Du, Z., Yang, Z., Tang, J.: P-tuning v2: 提示调优可在规模和任务上普遍媲美微调。arXiv预印本 arXiv:2110.07602 (2021) Liu, Z., Oguz, B., Zhao, C., Chang, E., Stock, P., Mehdad, Y., Shi, Y., Krishnamoorthi, R., Chandra, V.: LLM-QAT: 大语言模型的无数据量化感知训练。arXiv预印本 arXiv:2305.17888 (2023) Liu, Z., Zhao, C., Iandola, F., Lai, C., Tian, Y., Fedorov, I., Xiong, Y., Chang, E., Shi, Y., Krishnamoorthi, R., 等: MobileLLM: 为设备端用例优化十亿参数以下语言模型。见：第四十一届国际机器学习会议 (2024) Luo, H., Liu, Y., Zhang, R., Wang, J., Sun, G., Niyato, D., Yu, H., Xiong, Z., Wang, X., Shen, X.: 迈向基于多大型语言模型 (Multi-LLM) 的边缘通用智能：架构、信任与编排。《IEEE认知通信网络汇刊》（2025） Mouradian, C., Naboulsi, D., Yangui, S., Glitho, R.H., Morrow, M.J., Polakos, P.A.: 雾计算全面调研：最新进展与研究挑战。《IEEE通信调查与教程》20(1), 416–464 (2017) Naveed, H., Khan, A.U., Qiu, S., Saqib, M., Anwar, S., Usman, M., Akhtar, N., Barnes, N., Mian, A.: 大语言模型全面概述。ACM智能系统与技术汇刊 16(5), 1–72 (2025) Palma, G., Cecchi, G., Rizzo, A.: 用于皮革鞣制行业预测性维护的大语言模型：压缩机中的多模态异常检测。《电子学》14(10), 2061 (2025) Papineni, K., Roukos, S., Ward, T., Zhu, W.-J.: Bleu: 一种机器翻译自动评估方法。见：第40届计算语言学协会年会论文集，第311–318页（2002） Qin, R., Xia, J., Jia, Z., Jiang, M., Abbasi, A., Zhou, P., Hu, J., Shi, Y.: 通过自监督数据选择与合成实现设备端大语言模型个性化。见：第61届ACM/IEEE设计自动化会议论文集，第1–6页（2024） Qiu, W., Zhou, Y., Wang, J., Sheng, Q.Z., Cui, L.: FLM-TOPK: 通过稀疏化区间化梯度加速联邦大语言模型调优。见：IEEE INFOCOM 2025 - IEEE计算机通信会议，第1–10页（2025） Qu, G., Chen, Q., Wei, W., Lin, Z., Chen, X., Huang, K.: 面向大语言模型的移动边缘智能：当代调研。《IEEE通信调查与教程》（2025） Rafailov, R., Sharma, A., Mitchell, E., Manning, C.D., Ermon, S., Finn, C.: 直接偏好优化：你的语言模型秘密地是一个奖励模型。《神经信息处理系统进展》36, 53728–53741 (2023)

- Shao, H., Hu, Y., Wang, L., Song, G., Waslander, S.L., Liu, Y., Li, H.: LMDrive: 基于大语言模型的闭环端到端驾驶。载于: IEEE/CVF计算机视觉与模式识别会议论文集, 第15120–15130页 (2024) Shazeer, N.: 快速Transformer解码: 一个写头足矣。arXiv预印本 arXiv:1911.02150 (2019) Shen, Y., Shao, J., Zhang, X., Lin, Z., Pan, H., Li, D., Zhang, J., Letaief, K.B.: 大语言模型赋能的自主边缘人工智能, 助力互联智能。《IEEE通信杂志》第62卷, 第10期, 第140–146页 (2024)
- Talmor, A., Herzig, J., Lourie, N., Berant, J.: CommonsenseQA: 一个针对常识知识的问答挑战。载于: 计算语言学协会北美分会2019年会议: 人类语言技术, 第4149–4158页 (2019) Tan, T., Cao, G.: 面向移动设备上基于神经网络处理器的深度学习的感知调度。《IEEE移动计算汇刊》第23卷, 第12期, 第10706–10719页 (2024) Thirunavukarasu, A.J., Ting, D.S.J., Elangovan, K., Gutierrez, L., Tan, T.F., Ting, D.S.W.: 大语言模型在医学中的应用。《自然·医学》第29卷, 第8期, 第1930–1940页 (2023) Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., 等: Llama: 开放且高效的基础语言模型。arXiv预印本 arXiv:2302.13971 (2023) Tu, J., Yang, L., Cao, J.: 边缘计算中的分布式机器学习: 挑战、解决方案与未来方向。《ACM计算概览》第57卷, 第5期, 第1–37页 (2025) Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: 注意力机制就是一切。载于: 神经信息处理系统进展, 第30卷 (2017) Wan, P., Huang, Z., Tang, W., Nie, Y., Pei, D., Deng, S., Chen, J., Zhou, Y., Duan, H., Chen, Q., 等: 护士与大语言模型协作的门诊接待: 一项随机对照试验。《自然·医学》第30卷, 第10期, 第2878–2885页 (2024)
- Wang, Y., Cao, J., Jiang, S., Wang, S., Liu, H., Liang, Z.: 面向去中心化Web3应用的高效原子化跨区块链交易处理。载于: 2024年IEEE智能世界大会, 第155–162页 (2024). IEEE
- Wang, S., Li, B.Z., Khabsa, M., Fang, H., Ma, H.: Linformer: 具有线性复杂度的自注意力机制。arXiv预印本 arXiv:2006.04768 (2020) Wang, C., Pan, D., Kumari, S., Wu, M.-E., Jiang, H.: 大语言模型驱动的消费电子健康文本信息分析。《IEEE消费电子汇刊》(2024) Wang, S., Deng, J., Li, Q., Wu, J., Zhao, Z.: 大语言模型应用性能分析: 以老年人护理为例。载于: 2024年IEEE高性能计算与通信国际会议, 第145–151页 (2024). IEEE Wu, X., Liu, X., Niu, J., Wang, H., Tang, S., Zhu, G.: FedLoRA: 当个性化联邦学习遇上低秩适应 (2024) Wu, T., Li, M., Qu, Y., Wang, H., Wei, Z., Cao, J.: 面向高效联邦学习的无人机部署与边缘关联联合优化。《IEEE认知通信网络汇刊》(2025) Xu, Z., Chen, T., Huang, Z., Xing, Y., Chen, S.: 利用大语言模型个性化驾驶员智能体以提升驾驶安全与更智能的人机交互。《IEEE智能交通系统杂志》(2025)
- Yan, H., Li, Y.: 面向智能交通系统的生成式人工智能: 道路交视角。《ACM计算概览》(2025) Yi, R., Guo, L., Wei, S., Zhou, A., Wang, S., Xu, M.: EdgeMoE: 基于MoE的大语言模型的快速设备端推理。arXiv预印本 arXiv:2308.14352 (2023)
- Yu, Y., Si, X., Hu, C., Zhang, J.: 循环神经网络综述: LSTM单元与网络架构。《神经计算》31(7), 1235–1270 (2019) Yu, Z., Wang, Z., Li, Y., Gao, R., Zhou, X., Bommur, S.R., Zhao, Y., Lin, Y.: Edge-LLM: 通过统一压缩与自适应层投票在边缘设备上实现高效大语言模型适配。见: 第61届ACM/IEEE设计自动化会议论文集, 第1–6页 (2024) Zellers, R., Holtzman, A., Bisk, Y., Farhadi, A., Choi, Y.: HellaSwag: 机器真的能完成你的句子吗? 见: 第57届计算语言学协会年会论文集, 第4791–4800页 (2019) Zhang, M., Shen, X., Cao, J., Cui, Z., Jiang, S.: EdgeShard: 通过协同边缘计算实现高效大语言模型推理。IEEE物联网期刊 12(10), 13119–13131 (2025) Zhang, Y., Wang, W., Ren, J., Huang, J., He, S., Zhang, Y.: 移动边缘-云计算中基于收益的高效移动边缘计算服务器部署与管理。《IEEE/ACM网络汇刊》31(4), 1449–1462 (2022) Zhang, M., Cao, J., Sahni, Y., Chen, X., Jiang, S.: 异构边缘计算中资源高效的并行分割学习。见: 2024年计算、网络与通信国际会议, 第794–798页 (2024) Zhao, L., Yang, Q., Huang, H., Guo, L., Jiang, S.: 智能无线感知驱动的元宇宙: 一项调研。《计算机通信》214, 46–56 (2024) Zheng, Y., Chen, Y., Qian, B., Shi, X., Shu, Y., Chen, J.: 边缘大语言模型综述: 设计、执行与应用。《ACM计算概览》57(8), 1–35 (2025) Zheng, L., Jia, C., Sun, M., Wu, Z., Yu, C.H., Haj-Ali, A., Wang, Y., Yang, J., Zhuo, D., Sen, K., et al.: Ansor: 为深度学习生成高性能张量程序。见: 第14届USENIX操作系统设计与实现研讨会 (OSDI 20), 第863–879页 (2020) Zhuang, W., Pan, X., Wen, S., Yu, W., Li, X., Bao, J.: 大语言模型赋能的个性化康复辅助设备设计多智能体自组织方法。《国际生产研究杂志》1–30 (2025)
- 施普林格·自然或其许可方 (例如学会或其他合作伙伴) 根据与作者或其他权利持有人签订的出版协议, 拥有本文的独家权利; 作者对本文录用稿版本的自存档完全受该出版协议条款及适用法律的约束。

江山 江山于2015年在中国广州中山大学获得计算机科学与技术理学学士学位, 并于2021年在香港特别行政区香港理工大学获得计算机科学博士学位。他目前是中国珠海中山大学软件工程学院的一名副教授。他曾于2021年至2025年在香港特别行政区香港理工大学计算学系担任研究助理教授, 并于2018年至2019年访问伦敦帝国理工学院。他获得了TCC 2024和BlockSys 2021的最佳论文奖。他的研究兴趣包括分布式系统、区块链和边缘计算。

周学成 周学成于2022年在中国北京化工大学获得计算机科学与技术理学学士学位。他目前是中山大学软件工程学院软件工程专业的研究生, 就读于中国珠海。他的研究兴趣包括多模态智能体协作、大语言模型和边缘计算。

张明金 张明金现任香港理工大学计算学系研究助理教授。他于2024年在香港理工大学获得计算机科学博士学位，并于2019年在中国武汉的武汉理工大学获得通信工程工学学士学位。他于2023年访问了英国剑桥大学。他的研究兴趣包括边缘计算、协同边缘人工智能以及边缘大语言模型。

徐长福 徐长福于2015年和2018年分别获得江西财经大学通信工程理学学士学位和软件工程理学硕士学位，并于2025年获得香港特别行政区香港浸会大学计算机科学与技术博士学位。目前，他是中国南昌江西财经大学软件与物联网工程学院的助理教授。他的主要研究方向包括边缘计算和生成式人工智能。

廖国成 廖国成于2021年获得香港特别行政区香港中文大学博士学位，并于2016年获得中国广州中山大学工学学士学位。他现在是珠海中山大学软件工程学院的助理教授。他曾获得2017年IEEE全球通信大会通信学会青年专业人士最佳论文奖。他的研究方向包括分布式计算和边缘智能。

陈建国 陈建国于2018年在中国湖南大学获得计算机科学与技术博士学位。他目前是中国中山大学软件工程学院的副教授。他的研究兴趣包括移动计算、分布式计算、联邦学习和无人集群智能协同。

曹建农 曹建农现任香港理工大学计算学系副校长（教育）、数据科学欧亚慈善基金讲座教授及分布式与移动计算讲座教授。他是欧洲科学院院士、香港工程科学院院士、IEEE会士、中国计算机学会会士以及ACM杰出会员。他曾获得CCF海外杰出贡献奖、IEEE TCCLD研究创新奖，以及TCC 2024、Blocksys 2021、TII 2018、DSAA 2017、SMARTCOMP 2016、EUC 2016、ISPA 2013、WCNC 2011等会议的最佳论文奖。他的研究兴趣包括分布式系统与区块链、无线传感与网络、大数据与机器学习，以及移动云与边缘计算。