

DevPiolt: 小米智能家居中的物联网设备操作推荐

王宇翔[†] 王思文[§] 韩浩威[†] 王傲[†] 刘博雅[§] 赵勇[§] 吴承博[§] 朱斌[§] 秦斌[§] 周晓凯[†] 严晓[†] 蒋佳伟[†] 杜博[†]

[†] 武汉大学计算机学院 [§] 小米

[†] {nai.yxwang, haowei.han, aowang2024, xiaokaizhou, yanxiaosunny, jiawei.jiang, dubo}@whu.edu.cn
[§] {wangsiwen, liuboya, zhaoyong6, wuchengbo1, zhubin, qinbin}@xiaomi.com

摘要

物联网设备操作推荐是指根据用户的上下文（如历史操作、环境信息和设备状态）为其生成个性化的设备操作。这项任务对于提升用户满意度和公司利润至关重要。现有的推荐模型在处理复杂操作逻辑和多样化用户偏好方面存在困难，并且对次优建议敏感，这限制了它们在物联网设备操作上的适用性。为了解决这些问题，我们提出了DevPiolt，一个基于大语言模型的物联网设备操作推荐模型。具体来说，我们首先通过在精心构建的设备操作数据集上进行预训练和微调，使大语言模型具备物联网操作的基础领域知识。然后，我们采用直接偏好优化方法，将微调后的大语言模型与特定用户偏好对齐。最后，我们设计了一个基于置信度的曝光控制机制，以避免低质量推荐带来的负面用户体验。大量实验表明，DevPiolt在所有数据集上均显著优于基线模型，在所有指标上平均提升了69.5%。

DevPiolt已在小米家庭应用中实际部署一个季度，每日为255,000名用户提供操作推荐。在线实验结果表明，独立访客设备覆盖率提升了21.6%，页面浏览量接受率提升了29.1%。

关键词

推荐，大语言模型，物联网设备管理

1 引言

小米智能家居是小米旗下的智慧生活生态系统，主要负责公司的智能家居业务。小米智能家居已发展出一个涵盖家庭控制、健康监测和安全防护的智能服务领域，利用物联网技术连接并协调终端设备。小米智能家居的产品线涵盖三大主要类别：智能家居、可穿戴设备和智能出行设备，进一步细分为超过260个子类别，包括智能空调、开关和窗帘。2024年，其全球设备出货量达到6000万台，较上年增长20.1%，累计总销量达9.44亿台。为便于管理这些智能设备，小米智能家居开发了一款配套的移动应用（即小米家庭应用），致力于推动物联网设备在日常生活场景中的深度管理。截至2025年6月，小米家庭应用的月活跃用户基数达到1.13亿，其中超过2050万用户拥有五台或更多智能设备。



图1：小米家庭应用中设备操作推荐的工作流程。

操作推荐是小米智能家居的一项核心服务，旨在为用户提供个性化的设备操作建议。这项服务对用户和企业双方都有益处。对用户而言，物联网设备种类和功能的日益增多，使得根据当前环境实现精确控制变得越来越不便。操作推荐可以减少手动操作的频率，从而提升用户效率和交互体验。对企业而言，它可以通过用户对这些推荐的反馈来优化产品设计并增加相关设备的销量。如图1所示，推荐引擎首先收集用户的历史操作序列（例如开灯、设置空调温度）、设备列表（例如灯、空调）和环境数据（例如时间、温度）。这些数据随后被输入一个推荐模型，以预测用户潜在的设备操作需求。最后，它以文本形式向用户提供操作建议。例如，如果智能设备检测到夜间有人在卧室，操作推荐会预测用户可能需要“关闭卧室窗帘”。如果用户接受此建议，小米家庭应用将通过统一设备控制接口执行相关操作。

推荐模型是操作推荐的核心组件，在学术界和工业界都得到了广泛研究 [5, 17, 23, 34, 36]。这些模型通常可分为两种类型 [26]：基于特征的推荐模型（FRM） [16, 24] 和基于大语言模型的推荐模型（LRM） [28, 30]。FRMs使用精心设计的特征作为输入，构建用户与物品之间的映射关系 [36]。

表1: CGC、DeepSeek和DevPiolt在整体数据集上的准确率对比结果（参见第4.1节）。

方法	整体		
	EM-Acc	LM-F1	Rule
CGC [23]	19.95	17.72	23.48
DeepSeek [4]	32.97	44.68	41.45
DevPiolt	44.33	57.49	53.03

例如，定制化门控模型 [23]（CGC）通过可学习门控参数动态控制不同交叉特征的激活，有效过滤出与用户最相关的交互。LRM方法，如CALRec [13]和MLLM-MSR [29]，将历史行为序列和物品特征转化为自然语言，依靠大语言模型的语义理解能力来揭示用户与物品之间的联系。鉴于大语言模型强大的文本生成能力，能够为多个设备和操作生成建议及相应的文本描述，我们开发了基于大语言模型的操作推荐。

挑战。然而，当应用于操作推荐任务时，表1显示当前模型表现出较低的准确性。我们识别出使用现有推荐模型实现设备操作推荐的三个关键挑战：

❶ **复杂操作逻辑。**操作推荐必须召回多个物品组合（例如，设备和动作）。然而，现有的推荐模型通常只处理单一类型的物品。此外，操作之间存在顺序逻辑，例如需要先开启电源插座，再打开空调，而不是相反的顺序。

❷ **多样化用户偏好。**用户偏好显著影响操作推荐，既包括长期稳定偏好（例如，每天在特定时间打开窗帘的习惯），也包括短期行为模式（例如，避免频繁开关空调）。然而，现有方法通常难以处理多样化的用户偏好，从而阻碍了对这些特定倾向的有效捕捉。

❸ **对不当建议敏感。**庞大的候选操作池中不可避免地包含许多次优或不恰当的操作，这些操作不合逻辑且会严重降低用户体验。因此，一个关键挑战是前瞻性地识别并过滤这些不恰当的候选操作，以确保仅向用户呈现高质量的推荐。

为应对这些挑战，我们提出了DevPiolt，一个基于大语言模型的操作推荐框架，包含四个核心组件：预训练、微调、推荐精炼和曝光控制。具体而言，针对挑战❶，我们首先在大规模用户历史操作上对大语言模型进行预训练，使其学习可行操作组合。接着，我们使用细粒度操作语料库（包含历史操作、当前环境数据和可操作设备）对大语言模型进行微调。微调使大语言模型能够基于上下文理解操作间的逻辑关系。此外，我们在语料库中为每个操作动作配对一个文本描述，并提示大语言模型输出

操作动作及其对应的描述。针对挑战❷，我们构建了一个包含正负样本对的操作数据集，用于直接偏好优化（DPO）。该方法最大化正负样本之间的相对似然差异，使大语言模型能够从大量历史操作中学习特定用户偏好。最后，针对挑战❸，我们引入了一种曝光控制技术，该技术根据置信度分数决定是否向用户展示操作建议，从而避免可能导致负面用户体验的次优推荐。

为了训练操作推荐模型，我们每三个月从用户日志中采样45,000条操作记录进行预训练。微调语料库包含15,000个人工标注的样本。测试集包含4,882条标注操作，涵盖21种物联网设备。我们根据设备数量和设备类别进一步细分了测试集，分别得到7个和17个子数据集。DevPiolt已在小米家庭应用中实际部署一个季度，每日服务255,000名用户，并每天生成326,000条操作建议。

我们在来自小米智能家居的多个数据集上评估了DevPiolt及其设计方案与基线模型的对比。我们还引入了三个用于定性评估的指标：精确匹配准确率、宽松匹配F1分数和规则分数。主要结果表明，DevPiolt在所有数据集上都优于基线模型。与最佳性能基线相比，三项指标的平均提升分别为95.5%、58.5%和54.0%。消融研究验证了所提出的每项技术在添加到基础大语言模型时都能逐步提升准确率。此外，参数敏感性实验发现，模型准确率随LLM规模提升而提高，并且将上下文和历史序列设置为适中长度能产生最佳结果。在线实验表明，DevPiolt实现了独立访客设备覆盖率21.6%的提升和页面浏览量接受率29.1%的提升。

本文中，我们的贡献总结如下：

- 我们发现现有方法无法很好地处理操作推荐任务，并识别出三大主要挑战：复杂的操作逻辑、多样化用户偏好以及对次优建议敏感。
- 我们提出了DevPiolt，并设计了预训练和微调来学习操作数据集1中的操作知识，一种基于DPO的方法来强化特定用户偏好，以及一种曝光控制技术来过滤不满意的推荐。
- 我们进行了广泛的实验来评估DevPiolt。结果表明，DevPiolt显著优于基线模型，并且我们的设计能有效提升准确性。

2 预备知识

操作记录数据。为了让大语言模型能够学习用户的操作偏好，我们构建了一个高质量的设备操作数据集。如图2（a）和（b）所示，我们从小米家庭应用的原始环境日志和操作日志中聚合了历史操作。环境日志是来自物联网传感器的环境检测数据，例如室温和

¹我们将开源操作数据集，以促进社区内的进一步探索。




图2: 构建操作数据集的过程。




图3: DevPiolt 概览。

湿度。操作日志是用户通过语音或直接控制对智能设备的操作记录。我们记录操作动作的设备、房间和时间戳，并分别使用字段和值来表示操作的类型和内容。

为了将复杂的设备操作转化为大语言模型易于理解的文本内容，我们设计了图2(c)中的操作模板来过滤日志数据。我们将一个设备操作数据集表示为 $D = \{H_1, H_2, \dots, H_N\}$ ，其中 H 表示用户的历史操作序列， N 是用户数量。此外，每个序列 $H_i = \{O_1, O_2, \dots, O_l\}$ 包含多个操作 O ，其中 l 是一个用户的操作次数。如图2(d)所示，每个操作由以下四个部分组成：

- 时间 O_i^{time} 。我们将动作的执行时间戳转换为日期格式（即 $yy-mm-dd$ ）以及星期几。
- 环境 O_i^{env} 。我们构建一个三元组 $O_i^{env} = \{[room][indicator], [value]\}$ 来描述当前环境。
- 描述 O_i^{desc} 。这是用户通过语音或小米家庭应用向设备给出的操作描述。
- 动作 O_i^{act} 。我们提取用户执行的操作动作，并使用四元组 $\{[room], [device], [field], [value]\}$ 精确表示动作内容。

操作推荐任务。其目标是根据历史操作、当前环境以及用户的设备，生成一个动作四元组 O_i^{act} 和一个描述 O_i^{desc} 。值得注意的是， O_i^{act} 和 O_i^{act} 在操作含义上是语义等价的。

3 DevPiolt 框架

概述。为应对操作推荐面临的四个挑战，我们提出了 DevPiolt，它包含四个模块：预训练、微调、推荐精炼和曝光控制。如图3所示，针对挑战1，我们首先拼接用户的历史操作序列来预训练一个大语言模型，并




图4: 一个操作数据集样本。黑色文本代表操作推荐提示 $\mathcal{P}$ ，斜体部分表示用于损失计算的目标。预训练仅包含操作历史，而微调则额外包含环境与设备数据。

然后使用细粒度操作语料库对预训练大语言模型进行微调，使模型能够理解操作逻辑并生成合理的建议。针对挑战2，我们进一步利用直接偏好优化来精炼微调后的大语言模型。该技术使模型能够学习特定的用户偏好。最后，针对挑战3，我们通过计算置信度分数来实现曝光控制，该分数决定了是否向用户展示推荐结果。

3.1 预训练与微调

如挑战1中所强调的，尽管大语言模型可以利用其广泛的世界知识来推理操作中复杂的关联关系，但由于缺乏物联网设备操作领域的专业知识，其表现并不理想。此外，直接使用一个未经专门训练的大语言模型进行推荐任务，并不能保证其输出会符合合法的操作结构。

预训练。为确保大语言模型能够理解设备操作，我们在用户历史序列上对基础大语言模型进行预训练

$H = \{O_1, O_2, \dots, O_B\}$ 。如图4的“用户操作历史”部分所示, 每个操作实例 O_i 被序列化为一个单一的文本序列, 其中包含时间 O_i^{time} 和环境 O_i^{env} , 然后是相应的 a_i 动作 $O_i^{act} = \{O_{i1}^{act}, \dots, O_{iL}^{act}, a_i\}$ 。例如, 在 O_1 中, 用户执行了逻辑动作: 当卧室温度达到32度时, 开启空调并将其温度设置为24度。我们的训练方法将任务重新定义为下一动作预测, 这非常适合大语言模型。我们将用户的历史动作 $O_{<i}$ 与当前时间 O_i^{time} 和环境信息 O_i^{env} 拼接起来, 作为模型预测用户下一动作的条件输入。这通过最小化负对数似然损失 (训练大语言模型的标准目标) 来正式实现:

$$\mathcal{L}_{pt} = - \sum_{O_i \in H} \log P(O_i^{act} | O_{<i}, O_i^{time}, O_i^{env}) \quad (1)$$

通过学习从上下文预测动作, 模型内化了设备操作的逻辑。例如, 它学会了设备特定功能 (例如, 灯只能开启或关闭, 不能设置为25度) 和有效值空间 (例如, 空调的温度必须是合理范围内的数字)。最后, 为确保模型保留其通用知识并避免灾难性遗忘, 我们通过将我们的操作预训练语料库与通用领域语料库 (如ShareGPT [3] 和悟道 [32],) 以1:1的比例混合, 创建了一个平衡的训练数据集。

预训练之后, 模型已具备理解物联网操作领域的的能力。然而, 仍存在两个关键差距。1) 模型难以应用其操作知识来提供推荐, 例如无法为用户可用的设备建议动作。2) 它无法生成用户友好的自然语言描述 (例如, “打开空调”) 来呈现给用户, 而不是原始的结构化操作 (例如, [空调][开关][开启])。

微调。为了弥合这两个差距, 我们在一个包含15,000个手动标注操作实例的专门训练语料库上对大语言模型进行微调。每个训练实例由一个操作推荐提示、真实动作和相应的文本描述组成。如图4所示, 我们通过用户的操作历史 (排除最终操作) $O_{<i}$ 、当前时间 O_i^{time} 和环境信息 O_i^{env} 以及候选设备列表 C 来构建操作推荐提示 P , 其中包含候选设备列表是为了训练模型根据可用设备推荐有效操作。我们使用低秩适应 [8] 对大语言模型进行微调。它引入了低秩矩阵用于在预训练大语言模型中进行增量参数更新, 从而仅训练少量可学习参数。

我们使用一个多任务目标来微调模型, 以同时预测最终动作 O_i^{act} 和相应的描述 O_i^{desc} 。我们的初始方法是同时生成这两个输出, 通过最小化以下联合概率目标来实现:

$$\mathcal{L}_{ft} = -\log P(O_i^{act}, O_i^{desc} | P) \quad (2)$$

然而, 我们发现此方法产生的准确度欠佳, 因为模型难以同时掌握两项任务。因此, 模型先预测动作, 再生成描述。这将动作-描述目标 $\mathcal{L}_{ad}$ 分解如下:

$$\mathcal{L}_{ad} = -(\log P(O_i^{act} | P) + \log P(O_i^{desc} | P, O_i^{act})) \quad (3)$$




图5: 一天中不同时段用户对窗帘操作推荐的接受率。

洞察。我们采用动作优先策略, 在描述之前生成动作, 以建立更符合逻辑、从具体到抽象的学习流程。预测结构化且精确的动作是核心任务, 为后续文本生成提供了清晰明确的“锚点”。一旦动作确定, 生成描述就变成了一个更简单、更基于事实的总结任务。相比之下, 文本优先策略会先生成自由形式的描述, 这要求模型从可能模糊或不完整的文本中推断出精确的动作。此过程更具挑战性且容易出错。因此, 我们的方法确保模型优先掌握推荐的核心逻辑, 从而提升整体准确性和可靠性。对比结果见第4.3节。

3.2 推荐精炼

尽管模型通过训练海量的用户历史数据捕捉到了物联网操作的一般分布规律, 但其性能仍可能受到超出此分布的特殊场景的阻碍。我们观察到, 此类场景通常由特定的用户偏好引起, 这些偏好大致可分为两类:

- **时间敏感型操作:** 对某些操作的偏好可能具有强烈的时间依赖性。如图5所示, 智能窗帘是这种模式的典型例子: 对其操作的推荐通常在早晨和夜晚被接受, 但在白天则被拒绝。我们的分析表明, 当推荐的操作与用户在特定时间窗口内的历史行为不一致时, 此类推荐往往会失败。

- **冲突操作:** 用户不太可能在短时间内连续执行相互矛盾的动作, 这会导致冲突推荐被拒绝。例如, 在用户手动关闭空调后不久, 又建议开启空调, 这会被认为是侵扰性的, 通常会被拒绝。

为了让我们的推荐模型能在这些特殊场景下学习用户偏好, 我们使用直接偏好优化 (DPO) [19] 对其进行精炼。DPO 的核心原理是直接对偏好数据上优化模型。它使用偏好 (正样本) 与非偏好 (负样本) 的输出对, 以增加正样本的可能性, 同时降低负样本的可能性。与传统的强化学习方法相比, DPO 绕过了对显式奖励模型的需求, 从而实现了更简单、更稳定的训练过程。

DPO样本构建。对于DPO训练, 我们从为期两周的用户数据样本中构建了一个数据集, 包含大约9,000次交互。基于这些数据, 我们构建用户偏好




图6：一个DPO样本的示例。请注意，红色文本代表冲突操作，绿色文本表示相似的时间戳。

配对，每个配对包含一个正样本 S^{pos} 和一个负样本 S^{neg} 。如图6所示，正样本 S^{pos} 由操作推荐提示 $P = \{O_{<l}, O_l^{time}, O_l^{env}\}$ 以及用户实际执行的动作 O_l^{act} 组成。负样本 S^{neg} 使用相同的提示 P ，但配对一个非偏好动作 $O_l^{act'}$ 。这些配对正式定义为：

$$S^{pos} = \{P, O_l^{act}\}, \quad S^{neg} = \{P, O_l^{act'}\} \quad (4)$$

此处，非偏好动作的识别基于上述两种场景：

- **时间敏感拒绝。**如果一个动作在推荐时间的 ± 1 小时时间窗口内，用户没有执行它的历史记录，则将其标记为非偏好动作 ($O_{<l}^{act}$)，从而标识其为时间上不合适的。
- **冲突拒绝。**如果一个动作是用户在过去10分钟内对同一设备执行动作的相反操作，则被视为非偏好动作 ($O_{<l}^{act}$)。为避免误分类常见的高频交互（例如，开关灯），此类操作的时间窗口缩短至两分钟。

DPO训练。我们通过优化这些样本对的概率对数来训练模型。DPO目标函数形式化如下：

$$\mathcal{L}_{DPO} = -\log \sigma \left(\beta \log \frac{P_{\theta}(O_l^{act} | P)}{P_{ref}(O_l^{act} | P)} - \beta \log \frac{P_{\theta}(O_l^{act'} | P)}{P_{ref}(O_l^{act'} | P)} \right) \quad (5)$$

其中 P_{θ} 表示当前模型计算出的概率， P_{ref} 是参考模型（即微调阶段）的概率，而 β 是控制优化强度的超参数。与参考模型相比，此目标函数鼓励模型为偏好动作分配更高的概率，为非偏好动作分配更低的概率。

3.3 基于置信度的曝光控制

在操作推荐任务中，用户对次优建议非常敏感，这会严重降低用户体验。这促使我们提出一个根本性问题：我们如何评估推荐质量并相应地控制曝光？为了回答这个问题，我们分析了被拒绝的推荐，发现用户明显更可能拒绝那些

模型以低置信度预测的操作。为了提高操作建议的质量，我们采用了基于置信度的曝光控制机制。具体来说，只有当模型对预测的置信度超过某个阈值时，我们才会曝光该建议。此置信度是模型对该建议关键属性的输出概率的加权平均值。

置信度分数。我们为每个推荐的操作计算置信度分数 $Conf(O_i)$ 。由于一个操作由 a_i 个动作组成，最终分数是它们的平均值。对于每个动作 $O_{i,j}^{act}$ ，我们关注模型对其关键属性（这些属性来自词汇表 $V = \{\text{设备, 字段, 值}\}$ ，例如图4中标注动作内的[空调][温度][24]）的预测概率。为了反映它们的相对重要性，每种属性类型 k 的概率（表示为 $P(\text{attr}_k(O_{i,j}^{act}) | P)$ ）会乘以一个预定义的权重 α_k 。然后，通过将所有动作中所有属性的这些加权概率相加，并将该值除以动作总数归一化到 $[0,1]$ ，来计算总的置信度值。该过程可以定义为：

$$Conf(O_i) = \frac{1}{a_i} \sum_{\text{attr}_k \in \mathcal{V}} \sum_{j=1}^{a_i} \alpha_k P(\text{attr}_k(O_{i,j}^{act}) | P). \quad (6)$$

自适应计算策略。鉴于操作推荐中的复杂场景，依赖静态公式计算置信度分数是不可靠的。因此，我们引入了几种自适应策略来优化此过程：1) 置信度阈值根据任务复杂度动态调整。对于候选池较大或来自连续范围的数值属性（例如温度）的预测，阈值会降低10%，以考虑这些任务固有的难度。2) 为了提高效率，我们采用了级联剪枝机制。如果高级别属性（例如设备）的置信度低于其阈值，则整个推荐将被丢弃。这种分层检查防止了在低置信度候选者上浪费计算资源。3) 为了创建一个更稳健可靠的指标，最终的置信度分数是所有动作的平均置信度与首先生成的令牌的置信度的融合。这防止了高平均分数可能掩盖基础第一个令牌（这通常对整个推荐的有效性至关重要）置信度较低的情况。

4 实验评估

4.1 实验设置

数据集。我们从小米家庭应用中提取环境特征、设备列表和历史操作，以构建一个用于设备操作推荐的数据集。我们每月采样45,000个操作实例，此采样过程持续进行了三个月以用于预训练。此外，我们手动标注原始用户日志，生成了一个包含4,882个实例的高质量测试集。值得注意的是，训练集和测试集在时间上互不重叠，以防止知识泄露到模型训练阶段。为了增强数据集的多样性，我们根据设备数量和类别将其划分为多个子数据集。评估共使用了9个数据集，包括上述两个类别中实例数量最高的4个子数据集，

表2：操作推荐的准确率结果。最佳结果以粗体标出。“1-5”表示此子数据集中每位用户的设备数量范围为1至5。“灯”表示此子数据集中所有可操作的设备均为灯。其余子数据集同理。增益是DevPiolt相对于最佳性能基线的平均提升。

指标	方法	设备数量				设备类别				整体	增益 (%)
		1-5	6-10	11-20	20+	电灯开关	摄像头	取暖器	AC		
EM-Acc	CGC	43.13	20.86	13.97	7.83	19.14	18.26	33.02	27.23	19.95	95.53
	DeepSeek	47.53	27.50	17.26	12.44	21.67	20.90	43.71	18.32	32.97	
	GPT-4o	48.03	29.99	18.33	15.57	20.02	21.47	47.03	19.51	33.43	
	DevPiolt	68.66	51.69	36.48	27.62	38.56	44.72	77.67	53.00	44.33	
LM-F1	CGC	49.48	22.70	16.10	7.29	13.90	15.05	33.85	32.13	17.72	58.49
	DeepSeek	56.38	38.19	38.10	33.23	41.66	37.46	45.27	26.42	44.68	
	GPT-4o	56.66	38.69	39.04	33.38	40.80	36.87	46.34	27.32	45.19	
	DevPiolt	74.31	61.91	54.81	54.34	55.76	63.78	76.61	58.85	57.49	
Rule	CGC	48.26	24.09	17.37	10.18	23.37	21.29	33.81	30.64	23.48	54.04
	DeepSeek	55.20	40.64	33.37	23.85	35.67	35.29	54.00	31.31	41.45	
	GPT-4o	55.61	39.14	34.26	24.04	34.96	33.94	55.19	33.26	42.32	
	DevPiolt	74.44	59.32	46.23	38.38	55.76	63.78	79.72	60.3	53.03	

以及整体测试集。详细的数据集统计信息见附录A。

基线模型。我们将DevPiolt与三种基线模型进行比较：1) **CGC模型。**我们将定制门控控制（CGC）模型 [23] 适配到操作推荐任务，并进行了详细调整。具体而言，我们使用多层感知机层来编码用户和设备特征，并利用Transformer来捕捉历史序列中的操作依赖关系。编码后的特征随后被拼接起来，并与目标操作一同输入到CGC中。CGC通过可学习的门控参数动态控制不同交叉特征的激活，从而有效地为用户过滤出最相关的目标操作。2) **DeepSeek。**我们将用户的历史操作序列、当前环境以及可操作设备列表拼接起来，然后提示 DeepSeek-V3 [14] 模型直接输出操作推荐。3) **GPT-4o** [14]。与DeepSeek基线类似，我们使用GPT-4o模型来提供操作建议。请注意，当前的FRMs和LRMs并非为设备操作推荐而设计，因此无法作为合适的基线模型。

实现。我们使用 Qwen2.5-14B [27] 作为默认模型进行训练和推理。在预训练阶段，我们将多个历史操作序列连接起来以填充上下文窗口，并将最大长度设置为2048。该模型以3e-5的学习率预训练了1个轮次。在微调阶段，我们将LoRA秩设置为16，LoRA alpha设置为32，LoRA dropout设置为0.05。LoRA [8] 更新矩阵应用于所有投影层。该模型以4e-4的学习率微调了2个轮次。实验在一台配备8个NVIDIA H20 GPU（每个96GB内存）的服务器上进行。

操作评估标准。一个合理的评估标准对于操作推荐的质量分析至关重要。我们将用户的实际动作作为真实标签Y。

预测的结果表示为 y 。接下来，我们将详细介绍我们提出的三个指标：

- **精确匹配准确率。**精确匹配意味着预测中的动作四元组 O^{act} 的四个项目与实际操作完全相同。
- **宽松匹配F1分数。**一个动作即使不完全匹配标签，也可能被视为正确，因为用户可以使用各种表达来实现相同的操作意图。宽松匹配的定义是：预测动作值与实际动作值之间的差异低于20%，或者预测动作与实际动作在功能上等效。例如，预测动作“将卧室空调设置为舒适模式”被认为等同于实际动作“开启卧室空调”。我们在附录B中提供了详细解释。我们基于此宽松匹配标准计算宽松匹配F1分数：

$$LM-F1 = 2 \cdot \frac{lm_precision \cdot lm_recall}{lm_precision + lm_recall}.$$

- **规则分数。**规则分数评估模型在多设备、多操作场景中推荐结果的准确性和全面性。我们考虑单动作四元组设置，其中包含四个指标：相同、相交、包含和相反：

$$\varsigma = \begin{cases} 1, & \mathcal{Y} = y \\ 1/|E|, & E = \mathcal{Y} \cap y \\ 0.9, & \mathcal{Y} \subset y \\ -0.1, & y = -\mathcal{Y} \end{cases},$$

其中 $-Y$ 表示相反的操作。总规则分数是每个动作四元组实例得分的总和，除以预测的四元组数量 N_{quad} ：规则 = $(\sum_{i=1}^{N_{quad}} \varsigma_i) / N_{quad}$ 。该指标是合理的，因为它同时考虑了

表3: DevPiolt的微调、预训练和推荐优化的消融研究。基础是朴素的Qwen2.5-14B模型。

方法	整体		
	EM-Acc	LM-F1	Rule
Base	32.04	44.05	41.92
+ 微调	42.36	56.12	51.23
+ 预训练	43.57	56.99	52.74
+ 推荐精炼	44.33	57.49	53.03

单个操作的准确性以及跨多个操作的整体准确性。

4.2 主要结果

我们将DevPiolt与CGC模型、DeepSeek和GPT-4o进行比较, 以评估推荐结果的准确性。表2报告了在9个子数据集和整体数据集上的实验结果。我们有以下三点观察: 1) DevPiolt在所有数据集上的三个准确性指标均优于基线模型, 相比最佳性能基线, 平均最高提升了95.53%、58.49%和54.04%。DevPiolt通过利用大语言模型的上文理解能力来生成逻辑连贯的操作组合, 从而超越了CGC模型。此外, DevPiolt优于GPT-4o, 因为大语言模型通过预训练、微调和DPO学习了特定的操作模式和用户偏好。2) 随着设备数量增加, 所有方法的准确性都会下降, 这是因为做出准确预测的复杂性增加了。3) 我们的方法在Camera数据集上取得了最高的准确性, 但在Light数据集上的准确性相对较低。这是因为摄像头只有两种可能的操作(即开启和关闭), 而灯可能具有更复杂的操作, 包括照明模式和亮度控制。

4.3 微观实验

消融研究。为了研究De-vPiolt中每个组件的影响, 我们逐步在基础大语言模型(即Qwen2.5-14B)上激活微调、预训练和推荐精炼, 并在Whole数据集上进行评估。如表3所示, 每个模块都显著提升了模型的准确率, 证明了我们技术的有效性。微调使大语言模型能够学习细粒度的物联网设备操作模式, 预训练通过利用大量历史操作序列注入领域特定知识, 而推荐精炼则确保大语言模型学习特定的用户偏好。

曝光控制评估。为了研究曝光控制的作用, 我们逐步将置信度从0调整到1, 并观察曝光率和接受率的变化。接受率是指用户接受的操作建议数量占操作建议总数的比例。曝光率则表示展示给用户的建议数量占生成建议总数的比例。如图7(a)所示, 随着置信度增加, 曝光率起初缓慢下降, 随后下降更快, 而接受率




图7: 不同参数下模型准确率的对比结果。

则呈现相反趋势。更高的置信度意味着更保守的推荐策略, 从而降低了向用户展示预测结果的可能性。然而, 更高的置信度也意味着模型对其预测更有把握, 从而带来更高的接受率。为了平衡曝光率与接受率之间的权衡, 我们将置信度阈值设定为0.7。

动作优先 vs. 文本优先。我们在整个测试集上评估了两种操作生成策略对准确率的影响: 动作优先和文本优先。对比结果如表4所示。我们观察到, 动作优先策略在所有三个指标上都优于文本优先策略。这是因为与文本描述相比, 动作四元组提供了更细粒度的操作表示。详细的动作四元组可以帮助模型提高设备召回率。相反, 如果先生成粗略的操作描述, 由于大语言模型的下一个词生成机制, 动作四元组可能会向该描述收敛, 从而损害准确率。

不同模型规模的影响。我们评估了不同规模的Qwen2.5模型在整个测试集上的准确率影响。“微调”指对原始Qwen模型进行微调, 而“+预训练”表示在预训练的Qwen模型上进行微调。如图7(b)所示, 我们观察到准确率随模型规模增大而提升, 因为更大的模型展现出更强的表达能力以及对长历史操作序列更好的建模能力。此外, 为较小模型引入预训练阶段, 可以达到与较大模型相当的准确率。这表明预训练能学习领域特定知识, 从而提升模型准确率。

上下文长度与历史序列长度的影响。我们研究了训练期间上下文长度以及测试期间历史序列长度的影响。对比结果如图7(c)、(d)所示。我们发现, 过短的上下文

表4: 动作优先与文本优先策略的模型准确率对比。"动作优先"表示在微调过程中先于文本生成动作, 而"文本优先"则遵循相反的顺序。

方法	整体		
	EM-Acc	LM-F1	Rule
动作优先	44.33	57.49	53.03
文本优先	42.43	56.66	51.75

长度会限制模型所能学习的操作知识, 而过长的上下文长度则会导致模型失去焦点。在历史序列长度方面也观察到了类似现象。因此, 适中的上下文长度和历史序列长度对于获得最佳模型准确率至关重要。

失败分析。我们随机抽取一周内的50条用户不喜欢的操作建议进行失败分析。我们将失败原因分为六类:

- 不完整的操作。生成的建议未能涵盖用户的所有实际操作。
- 描述不清晰。生成的操作描述让用户难以理解（例如, 建议“关闭灯”但没有指定房间）。
- 不可感知的环境。环境数据不足导致操作建议不准确（例如, 在夜间房间有人时建议关灯）。
- 不恰当的时机。建议的操作时机常常不当（例如, 在白天打开所有灯）。
- 缺乏历史操作。由于历史操作有限, 模型的推荐不准确。（用户直接控制设备导致操作记录缺失。）
- 不合理的推荐。操作建议可能无法满足用户需求（例如, 在室温较高时关闭空调）。

图8显示, 超过45%的失败案例是由于不合理的推荐和缺乏历史操作。这凸显了丰富历史操作数据并利用其更好地理解用户意图的重要性, 这对推荐模型的准确性至关重要。因不恰当的时机导致的失败案例最少, 这表明我们的推荐优化技术能有效缓解此类问题。其余三个类别的案例数量大致相同, 表明模型在涉及多个设备和操作的复杂环境中仍面临重大挑战。

5 相关工作

推荐模型。现有的推荐模型可分为两类: 基于特征的推荐模型 (FRMs) [5, 10, 17, 25, 34] 和基于大语言模型的推荐模型 (LRMs) [7, 9, 12, 15, 35]。具体来说, 对于FRMs, DIN [36] 利用注意力机制和深度神经网络捕捉用户的兴趣特征, 并采用MLP来建模特征间的高阶交互。DirectPred [24] 通过对比学习区分短期




图 8: 用户不喜欢的操作建议案例研究

行为偏好和长期兴趣特征。HRNN [16] 使用时序卷积网络中的因果卷积和空洞卷积, 对用户实时行为和上下文特征的时间依赖性进行建模。对于LRMs, CALRec [13]基于大语言模型, 通过微调和多任务学习, 在潜在空间中动态对齐用户行为序列与目标物品特征。Recformer [11] 利用预训练语言模型提取物品文本特征, 并使用Transformer对用户动作序列进行建模, 仅通过文本模态实现用户意图与物品语义的映射。LRURec [33] 通过简化的线性循环结构和参数共享, 实现了快速训练和动态兴趣建模, 从而在保持计算效率的同时增强了序列预测能力。然而, 这些方法均无法应用于操作推荐, 因为它们无法捕捉复杂的操作逻辑和模式。

物联网设备管理。物联网设备管理 [1, 2, 6,18, 31] 包括对物联网设备的配置和调度, 以确保其高效可靠地运行。AutoIoT [20]通过使用大语言模型驱动的自然语言编程来实现自动化的AIoT应用管理, 该方法通过语义解析为设备生成可执行配置指令。qToggle [21] 设计了一种低功耗通信协议和一个嵌入式传感器网络, 以实现物联网设备间的互联互通和自主决策。Cristina等人 [22]采用了一种经济高效的Wi-Fi模块作为核心控制器, 并集成了物理开关, 以统一智能家居中的本地和远程控制。然而, 这些方法仅限于基本的设备控制, 无法基于当前环境提供细粒度的操作建议。

6 结论

我们介绍 DevPiolt, 一种基于大语言模型的物联网设备操作推荐系统。具体而言, 我们通过预训练和微调大语言模型来理解设备操作的基本逻辑。接着, 我们使用直接偏好优化技术, 使建议能够贴合个体用户的偏好。最后, 我们实施了一种基于置信度的曝光控制技术, 以防止展示次优建议。大量实验表明, 我们的方法超越了所有基线模型, 为操作推荐领域的社区研究铺平了道路。

参考文献

[1] Pragma Bajpayi, Smita Sharma, and Madhu Sharma Gaur. 2024. AI驱动的物联网医疗设备安全漏洞管理。收录于 2024年第二届颠覆性技术国际会议。IEEE, 366–373. [2] Anders Eivind Braten, Frank Alexander Kraemer, and David Palma. 2020. 自主物联网设备管理系统：结构化综述与通用认知模型。IEEE物联网期刊 8, 6 (2020), 4275–4290. [3] 陈林, 李金松, 董晓艺, 张攀, 何聪慧, 王佳琪, 赵峰, and 林达华. 2024. ShareGPT4V: 通过更好的字幕改进大型多模态模型。收录于 欧洲计算机视觉会议。Springer, 370–387. [4] 郭达雅, 杨德建, 张浩伟, 宋俊骁, 张若愚, 徐润欣, 朱启昊, 马世荣, 王培毅, 毕骁, 等. 2025. DeepSeek-R1: 通过强化学习激励大语言模型的推理能力。arXiv预印本 arXiv:2501.12948 (2025). [5] 郭会锋, 唐瑞明, 叶云明, 李振国, and 何秀强. 2017. DeepFM: 一种基于因子分解机的神经网络用于点击率预测。arXiv预印本 arXiv:1703.04247 (2017). [6] Ehtisham Ul Haque, Adil Shah, Jawaid Iqbal, Syed Sajid Ullah, Roobaea Alroobaea, and Saddam Hussain. 2024. 一种基于区块链的可扩展框架, 用于使用轻量级共识进行高效的物联网数据管理。科学报告 14, 1 (2024), 7841. [7] Jesse Harte, Wouter Zorgdrager, Panos Louridas, Asterios Katsifodimos, Dietmar Jannach, and Marios Fragkoulis. 2023. 利用大语言模型进行序列推荐。收录于 第17届ACM推荐系统会议论文集。1096–1102. [8] 胡爱德华, 沈业龙, Phillip Wallis, Zeyuan Allen-Zhu, 李远志, 王申, 王璐, 陈伟柱, 等. 2022. LoRA: 大语言模型的低秩适应。ICLR 1, 2 (2022), 3. [9] 胡俊, 夏雯雯, 张晓璐, 付赤林, 吴伟昌, 邹兆鑫, 李昂, 唐作立, and 周军. 2024. 通过基于大语言模型的语义嵌入学习增强序列推荐。收录于 2024年ACM网络大会附属论文集。103–111. [10] 康旺成 and Julian McAuley. 2018. 自注意力序列推荐。收录于 2018年 IEEE 国际数据挖掘会议。IEEE, 197–206. [11] 李佳成, 王明, 李进, 傅金森, 沈鑫, 尚靖波, and Julian McAuley. 2023. 文本即所需: 为序列推荐学习语言表征。收录于 第29届ACM SIGKDD知识发现与数据挖掘会议论文集。1258–1267. [12] 李磊, 张永锋, and 陈立. 2023. 用于高效基于大语言模型推荐的提示蒸馏。收录于 第32届ACM信息与知识管理国际会议论文集。1348–1357. [13] 李耀然, 翟翔, Moustafa Alzantot, 于可一, Ivan Vulić, Anna Korhonen, and Mohamed Hammad. 2024. CALRec: 用于序列推荐的生成式大语言模型对比对齐。收录于 第18届ACM推荐系统会议论文集。422–432. [14] 刘爱珍, 冯蓓, 薛冰, 王炳轩, 吴博超, 陆成达, 赵成刚, 邓承启, 张晨宇, 阮冲, 等. 2024. DeepSeek-V3技术报告。arXiv预印本 arXiv:2412.19437 (2024). [15] 刘启东, 吴贤, 王叶菁, 张子健, 田丰, 郑冶枫, and 赵祥宇. 2024. LLM-ESR: 用于长尾序列推荐的大语言模型增强。神经信息处理系统进展 37 (2024), 26701–26727. [16] 马一飞, Balakrishnan Narayanaswamy, 林海斌, and 丁浩. 2020. 实时时序上下文推荐。收录于 第 26 届 ACM SIGKDD 知识发现与数据挖掘国际会议论文集。2291–2299. [17] Maxim Naumov, Dheevatsa Mudigere, 石昊俊, 黄建宇, Narayanan Sundaraman, 朴钟秀, 王晓东, Udit Gupta, Carole-Jean Wu, Alisson G Azzolini, 等. 2019. 用于个性化和推荐系统的深度学习推荐模型。arXiv预印本 arXiv:1906.00091 (2019). [18] Thinagaran Perumal, Soumya Kanti Datta, and Christian Bonnet. 2015. 面向智能家居场景的物联网设备管理框架。收录于 2015年第四届IEEE全球消费电子大会。IEEE, 54–55. [19] Rafael Rafailov, Archit Sharma, Eric Mitchell, 克里斯托弗·D·曼宁, Stefano Ermon, and 切尔西·芬恩. 2023. 直接偏好优化: 你的语言模型其实是一个奖励模型。神经信息处理系统进展 36 (2023), 53728–53741. [20] 沈乐明, 杨强, 郑元庆, and 李墨. 2025. AutoIoT: 面向AIoT应用的大语言模型驱动的自动化自然语言编程。arXiv预印本 arXiv:2503.05346 (2025). [21] K Srinivasrao, S Ramana Kumar Joga, Athava Praveen Kumar, Orupula Puja Hemanth, Kanumareddy Leela Varaha Lavanya, and Dasari Yaswanth. 2024. 物联网驱动的智能家居自动化界面的用户体验设计。收录于 2024年第三届人工智能赋能物联网国际会议。IEEE, 1

[22] Cristina Stolojescu-Crisan, Calin Crisan, and Bogdan-Petru Butunoi. 2021. 基于物联网的智能家居自动化系统。Sensors 21, 11 (2021), 3784. [23] Hongyan Tang, Junning Liu, Ming Zhao, and Xudong Gong. 2020. 渐进式分层提取 (PLE): 一种用于个性化推荐的新型多任务学习模型。In *Proceedings of the 14th ACM Conference on Recommender Systems*. 269–278. [24] Yuandong Tian, Xinlei Chen, and Surya Ganguli. 2021. 理解无需对比的自监督学习动态。In *International Conference on Machine Learning*. PMLR, 10268–10278. [25] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang. 2017. 用于广告点击预测的深度与交叉网络。In *Proceedings of the ADKDD*. 1–7. [26] Le Wu, Xiangnan He, Xiang Wang, Kun Zhang, and Meng Wang. 2022. 面向准确性的神经推荐综述: 从协同过滤到信息丰富的推荐。IEEE Transactions on Knowledge and Data Engineering 35, 5 (2022), 4425–4445. [27] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. 2025. Qwen3技术报告。arXiv preprint arXiv:2505.09388 (2025). [28] Shenghao Yang, Weizhi Ma, Peijie Sun, Qingyao Ai, Yiqun Liu, Mingchen Cai, and Min Zhang. 2024. 基于大语言模型的潜在关系序列推荐。In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 335–344. [29] Yuyang Ye, Zhi Zheng, Yishan Shen, Tianshu Wang, Hengruo Zhang, Peijun Zhu, Runlong Yu, Kai Zhang, and Hui Xiong. 2025. 利用多模态大语言模型进行多模态序列推荐。In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39. 13069–13077. [30] Mingjia Yin, Hao Wang, Wei Guo, Yong Liu, Suojuan Zhang, Sirui Zhao, Defu Lian, and Enhong Chen. 2024. 序列推荐的数据集再生。In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3954–3965. [31] Liang Yu, Weiwei Xie, Di Xie, Yulong Zou, Dengyin Zhang, Zhixin Sun, Linghua Zhang, Yue Zhang, and Tao Jiang. 2019. 用于智能家居能源管理的深度强化学习。IEEE Internet of Things Journal 7, 4 (2019), 2751–2762. [32] Sha Yuan, Hanyu Zhao, Zhengxiao Du, Ming Ding, Xiao Liu, Yukuo Cen, Xu Zou, Zhilin Yang, and Jie Tang. 2021. Wudaocorpora: 用于预训练语言模型的超大规模中文语料库。AI Open 2 (2021), 65–68. [33] Zhenrui Yue, Yueqi Wang, Zhankui He, Huimin Zeng, Julian McAuley, and Dong Wang. 2024. 用于序列推荐的线性循环单元。In *Proceedings of the 17th ACM International Conference on Web Search and Data Mining*. 930–938. [34] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Jiayuan He, et al. 2024. 行动胜于雄辩: 用于生成式推荐的万亿参数序列转换器。In *Proceedings of the 41st International Conference on Machine Learning*. 58484–58509. [35] Junjie Zhang, Ruobing Xie, Yupeng Hou, Xin Zhao, Leyu Lin, and Ji-Rong Wen. 2025. 指令跟随式推荐: 一种大语言模型赋能的推荐方法。ACM Transactions on Information Systems 43, 5 (2025), 1–37. [36] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. 用于点击率预测的深度兴趣网络。In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1059–1068.

A 数据集

我们在表5中提供了测试集的统计数据。“DC 1-5”表示孩子数据集中的用户设备数量在1到5台之间, “Light”表示孩子数据集中所有被操作的对象都是灯。其余数据集遵循类似的模式。整体代表完整数据集。表中的数字表示每个子数据集包含的样本数量。

B LooseMatch准则的详细信息

宽松匹配标准包含两个必要条件。首先, 预测的与实际连续参数值之间的差异必须在20%以内。具体来说, 如果操作值是数值(例如, 温度设置或设备功率水平),

表5：测试集统计。样本数量表示样本的数量。

数据集	DC 1-5	DC 6-10	DC 11-20	DC 20+	电灯开关	摄像头	取暖器	AC	整体	
样本数量	970	1,037	1,650	1,225	1,211	1,599	318	200	390	4,882

我们使用以下公式计算相对误差：

$$\epsilon = \frac{|y_p - y_a|}{y_a},$$

其中 y_p 是预测的值， y_a 是实际值。当满足条件 $\epsilon \leq 0.2$ 时，即达到宽松匹配。其次，

操作意图必须在功能上等效。例如，如果实际操作为“开启卧室空调”，那么模型预测“将卧室空调设为26度”也被认为是正确的。同样，“激活客厅灯”与“将客厅吸顶灯亮度调至50%”都被视为能达到等效的照明效果。