

迈向基于定制化小语言模型的隐私保护与个性化智能家居

Xinyu Huang, *IEEE*学生会员, Leming Shen, *IEEE*学生会员, Zijing Ma, *IEEE*学生会员, Yuanqing Zheng, *IEEE*高级会员,

摘要—大语言模型在语言理解方面展现出卓越的泛化能力,并具有革新智能家居中人机交互的巨大潜力。现有基于大语言模型的智能家居助手通常将用户指令、用户配置文件及家庭配置传输至远程服务器,以获取个性化服务。然而,用户日益担忧数据可能泄露给远程服务器带来的隐私风险。为解决此问题,我们开发了*HomeLLaMA*,一个基于定制化小语言模型的设备端助手,旨在提供隐私保护与个性化的智能家居服务。

HomeLLaMA 通过学习云端大语言模型来提供令人满意的响应并实现用户友好的交互。一旦部署, *HomeLLaMA*通过持续更新本地小语言模型和用户配置文件来促进主动交互。为了在保护用户隐私的同时进一步提升用户体验,我们开发了*PrivShield*,为那些对本地响应不满意且愿意向远程服务器发送低敏感度查询的用户,提供一种可选的、基于大语言模型的隐私保护智能家居服务。为进行评估,我们构建了一个全面的基准测试工具*DevFinder*来评估服务质量。大量的实验和用户研究($M = 100$)表明, *HomeLLaMA*能够在显著增强用户隐私的同时,提供个性化服务。

索引术语—智能家居, 大语言模型, 用户隐私, 个性化

随^{HE}

I. 引言

智能家居的普及极大地促进了智能生活空间 [1],

[2]的发展。通常,智能家居是一个配备了各种互联设备与系统 [3], [1] 的住所,这些设备与系统可以远程或自主控制,通过物联网和基于人工智能的聊天机器人 [4]等技术来提高效率和便利性。智能家居的长期目标是实现无缝的用户-助手交互,使系统能够深入理解用户意图并提供令人满意的个性化响应 [5]。

现有的商用现成品智能家居助手,如Amazon Alexa [6] 和Apple Siri [7],是在各种指令数据集上预训练的任务特定模型,这可能导致其在未见任务上性能下降。例如,当用户给出一个未明确指定的指令(例如,“让客人进来”)而未提及具体设备时,由于缺乏预定义的指令-动作对,系统可能难以生成一个涉及智能设备的合理行动计划。

X. Huang, L. Shen, Z. Ma, Y. Zheng 隶属于中国香港特别行政区香港理工大学计算学系。电子邮件: unixy-xinyu.huang@connect.polyu.hk, leming.shen@connect.polyu.hk, zijing.ma@connect.polyu.hk, csyqzheng@comp.polyu.edu.hk。通讯作者: Yuanqing Zheng。

因此,用户和开发者必须手动添加新的指令-动作对来自定义助手。配置过程 [8]主要涉及设置触发器(例如,特定时间和条件)以及定义相应的动作(例如,启动电器和预定义的日常程序),这对应用程序开发者而言复杂且耗时,更不用说新手用户了。

为克服这些限制,近期研究整合大语言模型[9], [10]以革新智能家居服务,使助手能够理解超越预定义指令的用户意图。其中,Sasha利用ChatGPT [11]来生成行动计划以响应未明确指定的用户指令。SAGE通过存储对话历史以进行个性化计划生成,进一步提升了用户体验。然而,这些基于云端大语言模型的助手引入了重大的隐私风险。实践中,用户通常需要注册API密钥以访问云服务,并提供可识别的详细信息,如用户ID和电子邮件地址。在运行期间,家庭内的指令、用户配置文件和家庭设备状态(例如,温度设置、照明条件)会被传输到云端进行处理。在诚实但好奇的威胁模型下 [12], [13], [14], [8], 此工作流程可能将用户隐私 [15], [16],——包括日常程序(例如,烹饪、锻炼)、个人偏好和详细家庭配置——暴露给第三方。

为了保护用户隐私不被泄露,一种替代方案是利用开源模型在本地为智能家居提供服务。尽管前景广阔,但由于资源限制,本地设备只能支持小规模语言模型(SLMs)。

[17], [18], [19] 我们的初步研究 (§ III-B) 表明, SLMs在充分理解用户意图方面常常存在不足 [20]。因此,用户正面临一个性能-隐私困境:云端大语言模型擅长提供高质量服务,但可能引发隐私担忧;反之,本地小语言模型能保障用户隐私,却因模型能力有限而无法生成令人满意的响应。

为解决这一困境,我们提出 *HomeLLaMA*, 一个隐私保护的本地家庭助手,它通过持续学习提供个性化且令人满意的服务。*HomeLLaMA* 的核心洞见在于,赋能本地小语言模型,使其具备云端大语言模型的能力,从而将大多数对隐私敏感的查询处理任务从云端转移到本地,进而在模型性能和用户隐私之间取得平衡。只有在必要时(例如,本地小语言模型的响应不令人满意),并且获得用户明确批准的情况下,才会咨询强大的云服务。虽然基本思路很简单,但必须解决几个技术挑战。

- 与大语言模型相比, 小型语言模型性能较差, 并且缺乏用于有效增强的高质量数据集。

初步实验 (§ III-B) 表明, 与云端大语言模型相比, 小语言模型在提供高质量智能家居计划方面的关键瓶颈在于其准确关联相关设备与用户指令的能力有限。然而, 进一步的实验表明, 直接在现有的指令-动作对上微调小语言模型, 由于在异构家庭配置间泛化能力不足, 仅能带来轻微的性能提升。为解决此问题, 我们提出了一种新颖的免人工数据增强方法, 并配以定制化推理范式。具体而言, 我们指导强大的云端大语言模型, 基于可用的众包数据合成一个可泛化的指令-设备数据集。我们在此合成数据集上微调本地小语言模型, 并使用精心设计的提示词, 通过一致的推理流水线来引导它们。最终, 经过微调的本地小语言模型能够有效地生成更高质量的行动计划, 这些计划适用于设备配置各不相同的多样化家庭。

- 即使是一个经过良好增强的小语言模型, 也可能无法持续为用户提供云端大语言模型级别的服务。

如初步结果 (图2(b)) 所示, 即使使用我们精心构建的数据集进行微调后, 本地小语言模型与云端大语言模型之间仍然存在显著的性能差距。这种在服务智能家居方面的差距, 可能会因本地小语言模型的限制而损害用户体验。为解决此问题, 我们设计了一种隐私保护的本地-云端协作范式, 为用户提供咨询云端辅助以获得更高质量响应的选项。在此协作过程中, *HomeLLaMA* 将用户偏好和家庭配置数据保留在本地, 并进一步混淆发送给辅助服务的指令以保护用户隐私。该过程完全由用户驱动, 这意味着只有在获得用户明确批准后, 涉及隐私的敏感指令才会被处理并传输到远程服务器以进行性能增强。

- 本地存储空间有限, 难以保证长期个性化服务。

先前的工作 [21] 将整个历史用户-助手对话嵌入提示词以实现个性化。然而, 开源小型语言模型的上下文长度 (例如, LLaMA3为8K个标记) 比商业模型短, 无法将长对话历史纳入提示词。虽然流行的检索增强生成 (RAG) [22] 通过从数据库中获取相关信息来减少上下文长度, 前景广阔, 但仅仅将所有历史对话存储在数据库中会导致偏好相关数据持续累积, 造成冗余并阻碍高效检索高度相关的信息。为缓解此问题, 在每次对话结束时, 我们指示本地SLM将当前聊天内容提炼成一个简洁的用户画像, 包含主题、偏好、当前指令及其最终批准的计划。在对历史数据进行摘要处理后, 我们设计了一种基于相似性的动态画像更新机制以减少冗余。

我们针对特定的智能家居布局, 在本地服务器上实现并部署了 *HomeLLaMA*, 并评估了其性-

能在多个常用场景 (例如, 氛围调节和能源管理) 中的表现。定量实验和充分的用户研究 ($M = 100$) 均表明, *HomeLLaMA* 在保持可接受的性能水平的同时, 显著增强了以用户为中心的隐私, 缓解了智能家居用户面临的性能-隐私困境。简而言之, 贡献如下:

- 据我们所知, *HomeLLaMA*¹ 是首个支持通过用户参与循环提供隐私保护和个性化服务的设备端智能家居助手。
- *HomeLLaMA* 包含三个关键的新型技术模块: 本地SLM增强, 通过定制化推理范式有效提升本地助手的性能; 本地-云端协同, 通过一个以用户为中心、考虑隐私的本地-云端协同工作流来最大化用户体验; 以及用户偏好学习, 用于实现高效的本地托管长期个性化服务。
- 我们构建了一个全面的智能家居基准测试 *De-vFinder*², 以定量评估智能家居助手的计划质量。大量的实验和研究表明, *HomeLLaMA* 能够有效提供令人满意且隐私增强的服务, 同时提升面向用户的隐私信心。

二、相关工作

A. 智能家居

近年来, 智能家居已成为更广泛的物联网领域内一个重要的关注点 [25]。这些系统集成各种联网设备, 以实现家庭生活的自动化和提升, 提供诸如能源管理 [1] 和个性化服务 [27] 等功能 [26]。一个典型的场景包含若干智能设备、一个用户界面组件以及一个将智能家居与云端服务器连接起来的中央处理单元 [28]。在智能设备方面, 近期的研究重点是通过机器学习算法增强设备能力。例如, [29] 通过开发一种基于设备收集的加速度计数据识别用户活动的深度学习算法, 探索了用于家庭自动化的活动识别。在用户界面方面, 语音助手因其能够促进自然语言交互和免提控制而日益受到青睐。像 Google Assistant [30], 和 Alexa [6] 这样的商业产品体现了这一趋势, 它们提供了直观的接口, 能够管理各种指令 (如购物和设置提醒), 以简化自动化设备控制。然而, 正如我们的初步研究所展示的, 这些现代家庭助手通常难以处理隐式和复杂指令 [31]。另一方面, 大语言模型的最新进展在开放词汇问答方面表现出色, 能够更好地理解用户对未充分指定的指令的意图。*HomeLLaMA* 通过将大语言模型与智能家居设备集成, 以克服上述挑战, 从而以改进的系统性能提升了用户体验。

¹训练好的模型可通过匿名账户在Huggingface获取:
<https://huggingface.co/USER9724/HomeLlama-8B>。

²该数据集可在Huggingface上通过匿名账户获取:
<https://huggingface.co/datasets/USER9724/SmartHome-Device-QA>。

表I 与其他基于大语言模型的助手的全面比较。

系统	基础模型	计划质量	个性化	隐私保护	用户参与度
HomeGPT [23]	GPT-3.5 (云端)	中等	有限	Low	有限
Sasha [5]	GPT-4 (云端)	High	有限	Low	有限
SAGE [21]	GPT-4 (云端)	High	High	Low	有限
TT-Gemma [24]	Gemma (本地)	Low	有限	High	有限
TT-Phi-2 [24]	Phi-2 (本地)	Low	有限	High	有限
HomeLLaMA	LLaMA3 (本地)	中等	High	高 ↑	主动式

B. 将大语言模型与智能家居集成

认识到大语言模型强大的泛化能力和语言处理能力, [32], [33], [34], [35], 研究人员正尝试将其与智能家居集成, 以提升用户体验。一项开创性工作HomeGPT [23], 直接提示大语言模型, 通过提供包含详细设备状态的用户指令, 为智能设备生成一系列日常程序。这些程序将进一步被解析以相应地调整智能设备的状态。Sasha [5] 通过将整个过程分为五个步骤: 澄清、过滤、计划、执行和反馈, 进一步优化了推理和控制流程。然而, 它无法适应用户习惯来生成个性化行动计划, 从而降低了长期用户满意度。为解决此问题, SAGE [21] 和Jordan 等人。[36]使大语言模型能够结合用户配置文件来生成个性化计划。然而, 这些系统将用户数据和智能家居配置传输到云端大语言模型进行处理, 由于数据离开本地环境, 引发了用户隐私担忧。为了在增强隐私的同时提供令人满意且个性化的计划, HomeLLaMA通过微调定制了一个本地部署的小语言模型, 专注于提供令人满意且个性化的智能家居计划, 同时通过我们设计的PrivShield增强用户隐私。

总而言之, 表I从质量上全面比较了HomeLLaMA 与其他基于大语言模型的智能家居助手在多个维度上的表现。每个维度都对应评估章节 (§ VI) 中讨论的具体量化指标, 例如, 计划质量 是使用定义的设备相关性分数来衡量的。与云端助手相比, HomeLLaMA在提供个性化服务的同时, 以最小的性能权衡显著增强了用户隐私。另一方面, 与本地解决方案相比, HomeLLaMA 在提供卓越的个性化和更高质量的计划方面表现出色。此外, 它支持一种创新的交互范式, 通过用户驱动的用户-助手交互链促进主动的用户参与, 使用户能够主动个性化响应, 从而获得更具适应性的体验。

三、动机与挑战

A. 现有智能家居助手的局限性

现有的智能助手解决方案可分为基于任务的助手和基于大语言模型的助手。基于任务的助手在预定义的指令-动作对上进行训练, 而




图 1. 现有工作的图示, 包括任务特定模型的典型示例以及现有基于大语言模型的工作流程。

基于大语言模型的助手则利用大语言模型的强大能力, 来理解用户在各类智能家居场景中的意图。

现有基于任务的助手的局限性。作为一个在大量人工标注数据集上训练出的著名任务型助手, Siri [37]能够对预定义任务提供出色的响应[7]。然而, 当遇到未见过的复杂指令时, 其性能会下降。图 1(a) 展示了Apple Siri与智能家居用户之间对话的一个典型失败场景。当用户输入诸如“派对开始, 让所有客人进来!”这样的指令时, Siri 无法提供适当的响应, 而是直接返回互联网的搜索结果, 导致糟糕的用户体验。

基于大语言模型的助手存在的隐私问题。近期, 基于大语言模型的智能家居助手(如Sasha和SAGE)取得了进展, 允许用户更自由地发出指令, 并接收超越预定义任务的响应。具体而言, Sasha通过一个包含澄清、过滤和规划等步骤的流水线来提示大语言模型, 以生成满足用户指令的行动计划。Sasha未能提供个性化服务。另一方面, SAGE通过存储对话历史并将其总结为用户配置文件, 进一步增强了个性化。

尽管有所改进, 但如图1(b)所示, 此工作流程可能对用户隐私构成重大风险。在实践中, 用户需要将指令连同构建的用户配置文件及详细的设备状态(例如, 一个指示空调状态的JSON文件)传输到云端服务器进行处理。假设存在一个诚实但好奇的云端对手 [12], 此工作流程可能导致以下信息的暴露:

- 敏感个人信息, 包括个人可识别信息 (PII) 和用户偏好 [38];




Fig. 2. (a) GPT-4和LLaMA3的响应以及(b)将GPT-4设为参考后的DRS 初步结果。

- 家庭配置, 例如., 实时家庭设备状态 [39];
- 用户的日常居家活动/日常程序, 例如, 锻炼 [40]。这些隐私风险阻碍了现有的基于大语言模型的助手。

B. 挑战

作为缓解现有基于大语言模型的助手隐私顾虑的直接解决方案, 我们通过在本地服务器上部署开源模型LLaMA3-8B [41]进行了初步实验。从初步研究中, 我们报告了几个技术挑战, 这些挑战进一步启发了HomeLLaMA的设计。

挑战一: 原始小型语言模型在识别相关设备方面表现不佳, 且缺乏用于有效微调的高质量数据集。为了首先定性揭示小型语言模型在智能家居场景中表现不如大语言模型的根本原因, 我们向GPT-4和LLaMA3输入了一条欠明确指令以及一组可用设备以生成响应。如图2(a)所示, GPT-4涉及了全面的相关设备列表, 而LLaMA3则生成了一个更简单的响应, 仅提到了灯光和音乐播放器。结果表明, 小型语言模型主要缺乏识别用户指令与相关设备之间潜在语义关联的内在能力和领域知识。

基于此观察, 随后从智能家居平台 [42] 收集用户配置的数据集用于微调SLM。一旦完成微调, 我们以相同的提示格式将准备好的测试指令输入到原始SLM和微调后的SLM中, 生成两组相关设备作为响应。为公平比较, 相同的测试指令也使用GPT-4进行处理, 以生成参考设备输出。所有响应均基于预定义的设备集生成, 从而限制模型以自由风格生成输出。为量化每个模型将相关设备与输入指令关联的能力, 我们采用 [43], 中定义的设备相关性分数

(DRS), 其详细指标定义见 § VI。如图2(b)所示, 比较结果表明, 在数据集上微调后, DRS 值在各种场景下仅表现出轻微改善 (低于10%)。现有众包数据集带来的性能提升微乎其微, 这促使我们构建一个专为智能家居中微调SLM量身定制的高质量数据集。

挑战二: 即使是一个经过良好增强的小语言模型, 也可能无法持续生成云端大语言模型级别的响应。我们探索了应对挑战一的潜在策略, 并最终构建了一个适用于在智能家居场景中有效增强小语言模型的专用数据集 (§ IV-B)。然而, 如图2(b)所示, 尽管使用我们定制的数据集对小语言模型进行微调能显著提升其性能, 但本地小语言模型与云端大语言模型之间仍然存在差距。

在实践中, 这意味着即使经过增强, 小语言模型在智能家居环境中可能仍无法持续为用户提供高质量的服务。这种不一致性会降低用户体验, 尤其是在与强大的云端助手相比时。这一差距凸显了对一种用户驱动的云端辅助机制的需求——该机制需包含隐私保护措施——使用户在本地输出未达预期时能获得更高质量的响应。**挑战三: 仅为实现个性化而简单存储所有交互历史, 需要过长的上下文。**现有方法 [21] 直接将原始对话历史或累积的用户配置文件纳入云端大语言模型的提示词中以增强个性化。然而, 将此方法应用于本地小语言模型面临一个独特的挑战: 本地小语言模型的上下文长度要短得多 (例如, LLaMA3仅支持8K个词元), 使得在提示词中包含冗长的用户配置文件变得不可行。虽然广泛采用的检索增强生成 (RAG) 方法 [22] 通过从本地数据库中检索相关信息, 为节省上下文长度提供了一个有前景的解决方案, 但其在智能家居中长期使用可能导致偏好相关文件持续累积。这种累积会随着时间的推移导致数据冗余增加, 从而阻碍对高度相关信息的有效检索。这一实际限制呼唤创新的解决方案来优化历史数据的使用。

IV. HOMELLAMA 设计

A. 系统概述

为应对上述挑战, 我们提出了HomeLLaMA, 其概述如图3所示。在部署前, 它始于离线本地SLM增强模块 (§ IV-B); 借助增强后的模型, 用户指令会进一步通过在线阶段进行处理, 该阶段包含多方交互模块 (§ IV-C) 和用户偏好学习模块 (§ IV-D)。

- **本地SLM增强**使本地SLM能够为各种用户指令生成计划。在部署本地助手之前, 有必要增强SLM, 使其能够根据用户指令识别相关设备。我们首先从一个开源命令-动作数据集集中选择种子指令, 涵盖照明、环境控制和安全 [42]等多种场景。然后, 我们提出一种定制化的数据增强方法, 将种子指令输入云端大语言模型 (GPT-4) 以生成新指令, 融入不同的表达风格 (用户多样性) 和场景 (应用多样性)。此过程




图3. HomeLLaMA的系统概览。该系统始于一个离线阶段，旨在提升智能家居内的服务质量。一旦部署，便进入在线阶段，在此阶段中，系统持续学习并实时更新用户配置文件，并可根根据用户请求选择性地获得云端辅助。

合成了大量用户指令。随后，教师大语言模型为这些指令标注全面的相关设备，并将其编译成一个增强数据集，该数据集进一步用于微调本地SLM。

• **多方交互**进一步增强了用户-助手-云端交互循环中的用户体验。用户可以通过自由表达需求 (①) 与 HomeLLaMA 交互。如果HomeLLaMA生成的响应未达预期，用户可以给出反馈，或允许本地助手向云端大语言模型寻求建议 (②)。为增强用户隐私，PrivShield 在将指令混合物发送给云端大语言模型处理前，会通过将用户指令与SLM生成的对抗性指令混合来混淆用户指令 (③)。云端大语言模型在收到这些混合查询后，会生成一组响应并将其返回给本地PrivShield (④)。随后，与原始用户指令对应的真实响应被识别并恢复为建议，SLM整合此建议，为用户提供一个精炼的行动计划 (⑤)。

• **用户偏好学习**确保助手持续学习并适应用户偏好。具体来说，HomeLLaMA 记录每一次用户-助手交互，随后将其摘要为具有预定义格式的结构化用户配置文件 (⑥)。并且，维护中的用户配置文件将基于配置文件相似性动态更新。该模块允许助手检索用户配置文件，以便为未来的类似指令生成个性化计划 (⑦)。随着时间的推移，随着积累的用户配置文件，HomeLLaMA会越来越贴合用户偏好。

备注。HomeLLaMA 专注于生成令人满意的个性化行动计划。在实践中，这些行动计划可以自动转换为可执行文件（例如，JSON格式），以通过应用程序接口（例如，苹果应用程序接口 [44]）控制智能设备，本文省略了自动转换部分。

B. 本地SLM增强

为提升智能家居中的小型语言模型，一个可行的方法是在定制的“用户指令-相关设备”数据集上应用监督式微调。受近期数据增强方法（例如，WizardLM[45]）进展的启发，我们探索了利用强大的云端大语言模型（例如，GPT-4）自动合成更高质量定制数据集的潜力。此方法有效地将

云端大语言模型（教师）中蕴含的知识，通过微调过程迁移到本地SLM（学生）中。

1) **理解数据集：**为拥有不同用户群体的多样化智能家居提供服务，并非一个简单的单一输入到单一输出的映射问题，需要考虑两种类型的多样性：1) **指令多样性**。它源于两个主要方面：用户多样性和场景多样性。用户多样性指的是不同用户可能以各种方式表达他们的请求，而场景多样性指的是不同类型的家居场景。2) **设备多样性**。它指的是不同的智能家居可能拥有不同的可用设备集合，导致同一指令可能有多种可能的响应。

2) **指令增强：**针对**指令多样性**问题，构建一个包含跨不同用户群体和各类场景的广泛高质量指令的数据集至关重要。我们通过手动从众包平台（例如，IFTTT）[42] 根据其流行度（即，用户中的总体采用频率）选择一组未充分指定的指令作为种子来启动此过程。所选指令涵盖了几种常用的智能家居场景，例如气候控制和照明控制。每个场景包含10条指令，我们总共获得了90条种子指令。

新指令合成。利用云端大语言模型强大的生成能力，我们可以在无需手动数据收集的情况下扩展数据集。在每次合成迭代中，我们从指令池中随机抽取五条指令作为起点。受指令多样性两个方面的启发，我们沿着以下两个方向对原始指令进行增强：

• **垂直合成**为不同的智能家居场景生成新指令。利用抽样的种子指令，我们首先指示GPT-4，通过我们精心设计的提示词（图4(a)），考虑一个不同的场景来生成一条新的相关指令。对于新获得的指令，我们将其反馈给GPT-4，以验证该指令是否确实与智能家居上下文相关。如果不相关，则丢弃该指令并进入下一次迭代。

• **水平合成**旨在生成具有多样化表达风格的新指令。类似于垂直合成过程，我们指导（图4(b)）GPT-4在保持




Fig. 4. 用于(a)垂直合成、(b)水平合成、(c)指令标注和(d)计划生成的提示模板

on.

其原始含义的同时, 改变原始指令的表达风格。一旦生成, 我们便将新指令添加到候选指令池中, 以供进一步验证。**相似性检查器。**为确保增强指令的质量, 需要从候选池中移除语义相似的多余指令。具体而言, 给定任何新生成的指令 s_{new} , 令指令池中现有指令的集合为 $S = \{s_1, s_2, \dots, s_n\}$ 。ROUGE-L评分函数 [46], 表示为 $R(s, s')$, 用于衡量指令间的相似性。那么新指令的保留条件为

$$\text{Retain } s_{new} \iff \max_{i \in \{1, 2, \dots, n\}} R(s_{new}, s_i) < \alpha \quad (1)$$

其中 α 是一个预定义的阈值, 用于控制新指令与现有指令之间语义相似性的重叠部分。这意味着, 只有当新指令与任何现有指令的相似性低于预定义阈值时, 该新指令才会被保留。

3) 指令标注: 在获得增强指令池后, 下一个关键步骤是准确标注这些指令, 以构建一个综合的指令-设备数据集。我们利用云端大语言模型, 使用综合的设备集来标注指令, 该设备集涵盖了所有潜在的相关设备。具体来说, 我们首先模拟一个虚拟的大规模智能家居, 其中部署了一个智能家居平台 [42] 收集的综合商用现货设备集 (共 39 个设备)。通过图 4(c) 中设计的提示, 我们指示云端大语言模型从综合设备集中为增强数据集中的每条用户指令识别出一个相关设备子集。该标注过程可表示为:

$$\mathcal{D}_a = \{s_i \rightarrow G(s_i, \mathcal{D})\}, \forall s_i \in \mathcal{S}_a \quad (2)$$

其中 $\mathcal{D}_a$ 是增强数据集, s_i 是来自增强指令池 $\mathcal{S}_a$ 的一条用户指令, $\mathcal{D}$ 是我们构建的综合设备集, 而 $G(\cdot)$ 代表黑盒大语言模型。**备注。**对于智能家居中包含的设备不在综合设备集内的罕见情况, 用户可以明确建议遗漏的设备, 并指定她希望如何调整该设备的偏好。此类明确的用户反馈将被记录并检索, 以供未来参考 (§ IV-C)。请注意, 标注过程与具体的设备配置无关, 且无需向云端大语言模型传输特定的用户数据。

4) 训练适配器作为设备识别器: 在获得定制的指令-设备数据集后, 我们开始对本地SLM进行微调, 以增强其能力。具体而言, 我们采用QLoRA技术 [47], 这是一种被广泛采用的

参数高效微调 (PEFT) [48] 方法。与微调所有模型参数 (既耗费资源又耗时) 不同, QLoRA训练一个轻量级适配器并将其集成到目标模型中。在智能家居上下文中, 此过程涉及训练一个LoRA适配器, 使其充当本地SLM的设备识别器。通过将此适配器与保留了广泛世界知识的原始SLM相结合, *HomeLLaMA* 变得更擅长准确识别并与各种智能设备交互。

5) 推理范式: 在获得增强的小语言模型后, 我们针对每个家庭的**设备多样性**, 提出了一种基于思维链 (CoTs) [49]的定制化推理范式。图 4(d) 展示了我们设计的提示, 它指导小语言模型以逐步方式生成相应的计划。该推理范式可分为图 5 所示的两个步骤:

- 首先, 我们考虑一个如前所述配备了几乎所有商用现货设备的大型家庭。然后, 我们提示小语言模型根据给定的指令生成一份全面的相关设备列表。我们将此全面相关设备集表示为 $\mathcal{D}_l$, 如图 5 红色方框所示。
- 接着, 通过执行匹配过程, 将生成的结果适配到特定的家庭。具体而言, 将家庭 i 中可用的设备集表示为 $\mathcal{D}_i$, 我们使用图 4(d) 中的指令提示小语言模型执行任务, 将 $\mathcal{D}_l$ 与 $\mathcal{D}_i$ 的共有设备进行匹配, 从而为家庭 i 获得匹配集 $\mathcal{D}_f^i$ (如图 5 蓝色方框所示)。通过小语言模型进行的匹配操作是:

$$\mathcal{D}_f^i = \mathcal{D}_l \cap \mathcal{D}_i. \quad (3)$$

备注: 在初始步骤中, 虽然可以直接输入目标家庭的设备集来生成行动计划, 但这种方法可能导致性能下降。主要原因是本地SLM是在我们定制的数据集上使用预定义的输入格式进行微调的。因此, 只有当提示符合预期格式时, 相关设备识别的增强能力才可能被激活。

C. 多方交互

如 § III-B 所述, 增强后的SLM在实践中可能仍无法持续提供高质量服务。为了进一步提升用户体验, 我们提出了一个多方交互模块, 该模块便于收集用户反馈, 并在必要时咨询云端大语言模型。此模块支持两种类型的交互: 1) 用户-助手交互, 允许用户明确指定其请求和偏好, 以及




图5. 本地SLM设计的推理范式。

2) 用户驱动的本地-云端协作，即由用户触发本地SLM，以在隐私保护的前提下咨询云端大语言模型，从而获得更佳服务。

1) 用户-助手交互：作为HomeLLaMA的核心组件，用户-助手交互充当了用户表达其意图的接口。在图6所示的流程图中，助手在接收到用户指令后，将生成行动计划并响应用户以进行确认。对于生成的每一个响应，用户可以选择接受、拒绝或提供一条建议进行跟进。

• **接受**：如果用户对生成的行为计划感到满意，该行动计划将被转换为控制相关智能设备的指令。

• **建议**：用户可以提供自然语言反馈，以进一步细化用户意图。例如，假设用户输入一个如“调亮卧室”的指令，而助手响应“打开卧室里所有的灯”。如果用户只想打开床头灯，她可以跟进一个详细的说明（例如，“请只开床头灯。”）。随后，助手将通过把用户的建议纳入提示中，重新生成行动计划。

• **拒绝**：如果用户对本地响应不满意，她可以拒绝该行动计划。例如，如果用户想举办家庭聚会并输入“让派对开始吧”，但助手仅响应一个简单的动作如“打开灯并调节室温”，用户可能会拒绝此响应。在这种情况下，助手将利用云端大语言模型，通过用户驱动的本地-云端协作模块（§ IV-C2）生成一个改进的行动计划。

备注。请注意，在每次生成的响应（包括因“建议”或“拒绝”而产生的修订计划）之后，用户都可以继续与助手交互。只有当用户明确“接受”一个提议的行动计划时，该计划才会被翻译成相应的智能设备控制指令（图6）。随后，该用户指令及最终批准的计划将作为一条交互记录保存，并供偏好学习模块进一步使用（§ IV-D）。

2) 本地-云端协同：当用户拒绝一个计划时，HomeLLaMA会请求用户许可可以咨询云端模型（例如.. GPT-4）。如果获得批准，助手将进行此过程以生成改进的响应 [50]。

潜在的隐私风险。然而，直接通过注册的API调用，使用原始用户指令和家庭详细信息查询云端大语言模型，可能会引发隐私担忧 [51]，因为用户活动和个人信息可能被好奇的云端服务器间接推断和监控 [52]（例如，通过差分攻击 [53]）。例如，假设用户首先

请求：“晚上9点，让我的客厅变冷并打开电视。”随后又请求：“晚上10点，检查门窗是否锁好，并让我的卧室变得舒适。”从这些指令中，可以轻易推断出用户可能在晚上9点到10点之间看电视，然后去睡觉。

协同期间HomeLLaMA 的角色。虽然本地-云端协同的目标是提升用户体验，但这绝不能以不可接受的隐私妥协为代价。为此，HomeLLaMA 既充当处理中心，也扮演隐私守护者的角色：它在本地保留所有智能家居配置和用户配置文件，仅将当前用户指令传输至云端以获取协助。为了进一步减轻原始指令中潜在的隐私风险，我们引入了PrivShield，这是一个轻量级的混淆模块，旨在云端交互前对用户查询进行匿名化处理，如图7所示。

PrivShield。本质上，PrivShield 在一个SLM-在中间的框架内运行。在实践中，PrivShield 通过包括用户指令重写、对抗性指令生成和计划恢复在内的流程来保护用户隐私。

• **用户指令重写**。原始用户指令可能包含个人信息（例如，如姓名、位置）和许多口语化表达（例如，如语气词）。这些成分不仅引入了信息冗余，也为第三方在后续过程中通过持续的模式识别来推断用户的真实指令提供了机会。为了解决这个问题，我们引导本地SLM首先过滤敏感个人信息 [54]，然后使用图8(a)所示的定制化提示词对原始用户指令进行转述。

• **对抗性指令生成**。给定一个转述后的指令，PrivShield 使用图8(b)中设计的指令提示本地SLM，以生成其他 N 跨越各种不相关场景的对抗性指令，从而混淆原始指令。每条指令都被分配一个唯一的指令ID并进行随机排序，只有原始指令的ID t 在本地被记录。这些指令随后会与它们各自的指令ID一起组合成一个单一的查询，如图8(c)所示。这个组合查询将被传输到云端大语言模型，以为所有指令生成行动计划。

• **行动计划恢复**。在收到来自云端大语言模型的响应后，PrivShield 会提取出与正确顺序相关联的综合行动计划。这个提取出的行动计划随后会作为建议输入到本地助手手中，以便为用户生成一个定制化计划。该定制化计划随后会作为更新后的计划交付给用户。

备注。PrivShield 使用户能够访问云服务




图6. 用户-助手交互流程。




图7. PrivShield的工作流程。

并以易于理解的方式提供隐私保护。然而，该助手主要在可能的情况下于本地运行。原因有二：1) 用户配置文件和家庭配置存储在本地，出于隐私考虑，不会传输到云端进行处理。2) 持续查询云端的成本可能过高。在部署前，允许用户自定义对抗性指令的数量，即， N ，以实现以用户为导向的隐私-成本平衡。

D. 用户偏好学习

由于上下文长度受限且信息存在冗余，本地小语言模型无法简单地存储所有聊天记录来生成个性化响应。为应对这一挑战，我们开发了一种轻量级的用户画像方法，使助手能够高效地检索动态更新的用户配置文件数据库以供参考。在实践中，用户偏好学习模块在三个关键阶段运行：用户配置文件生成、配置文件更新和个性化计划生成。

1) 用户配置文件生成：用户与助手之间的交互记录在本地被记录。一个结构化提示（如图9(a)所示）引导本地SLM摘要并生成一个组织良好的用户配置文件，对应每次对话。这些配置文件以简洁的方式包含以下详细信息：

① **主题**（即，由SLM总结的对话关键词）、② **偏好**、③ **指令**以及④ **最终行动计划**。这些配置文件随后被转换为向量表示，并存储在一个文本嵌入数据库 $\mathcal{E}$ 中。

2) 配置文件更新：用户配置文件数据库遵循精心设计的更新机制，以长期保持其有效性。当生成新的用户配置文件时，会通过余弦相似度将其与所有现有配置文件进行比较。如果新配置文件与所有现有配置文件的相似性低于预定义阈值，则该新配置文件将作为独立条目保存到数据库中。否则，它将与最相似的现有配置文件进行建设性合并。具体来说，给定新生成的用户配置文件的嵌入（表示为 p_n ），将此配置文件插入嵌入数据库的条件由以下公式决定：

$$\text{Insert } p_n \text{ into } \mathcal{E} \iff \max_{p_i \in \mathcal{E}} C(p_n, p_i) < \beta \quad (4)$$

其中 $C(\cdot)$ 是余弦相似度函数， β 是一个预定义的相似度阈值。如果最大余弦相似度

低于 β ，则新配置文件将作为独立条目插入。否则，这两个相似的配置文件将被合并成一个新的、统一的配置文件，并通过使用图9(b)中所示的设计提示词来提示小语言模型，以替换原始配置文件。这一过程提升了用户配置文件数据库的存储效率。

3) 个性化计划生成：在推理阶段，给定一个新的用户查询 q_i ，助手会检索出与该查询余弦相似度最高的前3个用户配置文件（以文本嵌入形式表示，记为 p_m 、 p_n 和 p_p ）。然后，我们通过解码将选定的嵌入转换为文本（记为 u_m 、 u_n 和 u_p ）：

$$(p_m, p_n, p_p) \xrightarrow{\text{Decode}} (u_m, u_n, u_p) \quad (5)$$

通过将解码结果与用户查询 q_i 拼接，基于这些配置文件和当前家庭配置 H_i 生成个性化输出计划：

$$\text{Plan} \leftarrow \mathcal{L}(u_m, u_n, u_p, H_i, q_i) \quad (6)$$

其中 $\mathcal{L}$ 代表本地SLM的行动计划生成函数。生成的行动计划随后被用于控制相应的智能设备。

备注：用户偏好学习模块旨在维护一个动态更新的用户配置文件数据库，以实现个性化。此外，我们设计的用户档案学习范式可以通过为每个用户构建独立的数据库，扩展到多用户智能家居场景。在提供服务时，助手将首先进行语音识别 [39] 以确定用户身份，然后再进行处理。

V. 实现

我们使用PyTorch框架 [55]，在本地服务器上实现了所设计的 *HomeLLaMA*，其整个工作流程由LangChain [56] 提供支持。各关键组件的实现细节如下：

数据增强：我们从IFTTT准备种子指令，并通过OpenAI API访问OpenAI的服务。在增强过程中，我们选择GPT-4-Turbo作为默认大语言模型，并适当地提示它以生成所需数据。默认情况下，我们将公式1中的 α 设置为0.7。增强数据集总共包含14K个行动-指令对，涵盖了




图8. 所设计的PrivShield的提示模板。




图9. 用于用户画像生成与合并的提示模板。

9个常见的智能家居场景(例如, 氛围调节、电源管理、等)。

微调: 我们选择从 Hugging Face³下载的 Meta-LLaMA3-8B [57] 作为我们的基础模型。为了使用我们的增强数据集对基础模型进行微调, 我们采用了结合8位量化的 QLoRA [47]技术。秩 r 设置为64, $lora\ alpha$ 设置为128。学习率初始化为 3×10^{-5} , 并应用了0.1的丢弃率以缓解过拟合问题。微调轮次为3, 训练-测试分割比例为80-20。模型在安装有 Ubuntu 22.04 LTS 和单块 NVIDIA RTX 4090 GPU 的服务器上进行调整, 耗时约8小时。

用户配置文件数据库: 我们通过 FAISS [58],部署和维护用户配置文件数据库, 这是一个用于高效稠密向量相似性搜索和聚类的库。从交互中收集的对话历史以文本格式保存, 并汇总为用户画像。这些经过良好汇总的用户配置文件存储在文本嵌入数据库中, 准备好在推理阶段被检索以生成个性化计划。默认情况下, 方程4中的 β 设置为0.6。

六、性能评估

在本节中, 我们进行了全面的量化实验, 以评估 HomeLLaMA 在解决性能-隐私困境方面的有效性。具体而言, 我们旨在回答以下问题:

- **Q1 -性能:** HomeLLaMA 能否在本地提供高质量的服务?
- **Q2 - 隐私:** HomeLLaMA 是否在量化层面提升了用户隐私?

- **Q3 - 系统开销:** HomeLLaMA 是否具备本地部署的经济可行性?
- **Q4 -敏感性:** 系统配置(即, 基础模型)如何影响性能?

A. 模型能力 (Q1)

1) DevFinder基准测试: 考虑到 § IV-B中描述的配备常用智能设备的综合家庭设置, 我们从IFTTT数据集中选取了100条带有人工标注设备标签的测试指令[42], 更多细节详见开源数据集。这些带标签的指令涵盖了广泛场景, 包括环境控制、氛围调节、电源管理、等。将指令输入智能家居助手以生成响应, 随后与标注标签进行比较, 以量化生成行动计划的质量。


为量化HomeLLaMA识别相关设备的能力, 我们采用设备相关性分数(DRS)作为评估指标 [5]。假设真实设备集合为 G_l , 本地SLM生成的设备集合为 G_r , 则相关性分数计算如下:

$$DRS = \frac{|G_l \cap G_r| - |G_r - G_l|}{|G_r|} \quad (7)$$

其中 $|G_l \cap G_r|$ 表示重叠设备的数量, $|G_r - G_l|$ 指响应中未包含在真实设备集合内的设备数量。随后, 相关性分数被归一化至 $[-1, 1]$ 。相关性分数越高, 识别相关设备的性能越好。

2) 基线模型: 为了将HomeLLaMA的模型性能置于具体情境中, 我们将我们的系统与其他几个基于LLM的智能家居基线进行比较:

³<https://huggingface.co>



(a) 小型语言模型的FP16精度。

(b) 小型语言模型的INT8精度。

图 10. 设置 (a) FP16 和 (b) INT8 精度后的平均值 DRS 。

• **HomeGPT** [23] 直接提示大语言模型，以响应用户指令生成智能家居计划。

• **Sasha** [5] 通过引入一个由五个步骤组成的修订流水线（包括过滤、规划、等）来修改HomeGPT，以提升计划的质量。

• **SAGE** [21] 通过将所有对话历史插入提示词来生成个性化计划。

• **Thoughtful Things (TT)** [24] 利用设备端小语言模型（Google Gemma-7B [59] 和 Microsoft Phi-2-3B [60]）来生成日常程序并控制智能设备。


请注意，为了公平比较，在评估设备相关性时，云端辅助模块被禁用，所有结果均完全基于本地操作计算得出。

3) 结果：我们在提出的 $DevFinder$ 上测试了 $HomeLLaMA$ 和基线模型，并报告了每个系统的平均得分。此外，我们将这些模型的温度 t 分别设置为0.1和0.7进行评估。如图10所示，所设计的 $HomeLLaMA$ 显著优于其他两个设备端助手，但仍落后于基于云端的大语言模型助手。为了探究其背后的原因，我们检查并分析了生成的行动计划，并揭示了以下见解：

- 尽管由大型模型驱动的云端助手具有卓越的性能，但 $HomeLLaMA$ 在通过 $PrivShield$ 和本地处理确保用户隐私的同时，实现了与GPT-3.5相当的 DRS ，展示了在不损害用户隐私情况下的高性能。
- 在设备端助手中， $HomeLLaMA$ 提供了最佳的本地服务，在设备相关性方面优于TT-Gemma和TT-Phi-2。这得益于其在智能家居特定数据上的微调及其混合设计，该设计能够在需要时启用选择性云端辅助以进一步提升 DRS 。
- 提高模型温度可增强创造性并可能提升相关性（例如， $HomeLLaMA$ 在FP16下从0.51提升至0.55 $t=0.7$ ），但也可能导致幻觉 [66]。尽管存在缓解措施，但像 TT-Phi-2-3B这样的小型模型在温度升高时，由于推理能力较弱，仍会遭受性能下降。

B. 隐私保护 (Q2)

1) 定性风险分析：在对 $HomeLLaMA$ 的隐私保护进行量化之前，首先定性审视潜在的隐私风险至关重要。在典型的基于云端的智能家居系统中，用户必须注册API密钥并



(a) 响应延迟。

(b) GPU内存使用量。

图 11. (a) 延迟和 (b) 内存使用量的结果。




图12. 用于启动活动监控攻击的提示模板。

将指令和设备状态传输到远程服务器，使其在数据存储、网络传输和推理过程中面临风险，详见表II。这些风险包括未经授权的访问、拦截以及推理攻击，例如个人身份信息提取、属性推断和活动监控。与此类系统不同， $HomeLLaMA$ 在本地运行，无需共享用户配置文件或家庭配置，从而降低了存储和传输风险。此外，其 $PrivShield$ 模块在将提示词发送到云端之前会过滤敏感内容，防止个人可识别信息暴露。然而，经过混淆处理的提示词仍可能通过API可追溯性面临活动监控的风险。下一节将通过定量实验来评估系统对此残余威胁的抵御能力。


2) 定量分析：我们重点考察 $HomeLLaMA$ 中的家庭内活动监控威胁。在使用 $PrivShield$ 期间，真实的指令会与 N 其他SLM生成的对抗性指令混合混淆，然后才发送到云端大语言模型进行处理。

威胁模型。我们假设云端大语言模型运行在诚实但好奇的远程服务器上 [31]，攻击者在此提供正确的推理结果，但同时会探查所有传输的用户查询。其目标是通过预训练分类器从混合指令中识别出真实查询，从而实现对用户家庭内活动的实时监控。遵循 [67]中的流程，我们通过使用图12所示精心设计的提示词指示云端GPT-4，基于持续接收的指令来推断用户的家庭内活动，从而启动活动监控攻击。随后，我们使用攻击成功率 [40] 来评估系统的隐私保护水平，更高的成功率意味着对用户隐私的威胁更大，系统的保护能力则相应降低。


结果。我们使用构建的 $DevFinder$ 作为测试用户查询，将对抗性指令的数量 N 设置为2、4、9和19。我们还改变 $HomeLLaMA$ 中的基础小型语言模型，以考察它们对对抗性指令生成质量的影响。通过大量实验获得的各查询轮次的平均攻击准确率结果如图13所示，我们报告以下关键发现：

表II 基于大语言模型的助手（包括基于云的系统、本地TT和HomeLLaMA）的定性风险分析。此处“■”表示该威胁会危及隐私，而“□”则表示需要定量评估（§ VI-B2）。


威胁类型	基于云的系统	TT (本地)	HomeLLaMA (混合)
数据存储 [61]	●	○	○
网络传输 [62]	●	○	○
个人身份信息提取 [64]	●	○	○
推理 [63]	●	○	○
属性推断 [65]	●	○	○
活动监控 [40]	●	○	●



(a) Phi3-3B.



(b) LLaMA3-8B.



(c) LLaMA3-13B.

图13. 不同 N 值和基础模型下，各查询轮次的平均攻击成功率。

• *PrivShield* 通过保持显著低于无其保护时直接查询的攻击成功率，有效保障了用户隐私。如图13所示，利用 *PrivShield* 配合不同的 N 值和各种基础模型，导致攻击准确率大幅降低，远低于直接查询100%的成功率。此外，虽然增加查询轮次允许攻击者积累更多信息（如所有子图所示），但这并未增强他们准确推断用户提示词的能力。实际上，记 *PrivShield* 的平均攻击成功率为 SR_p ，而 *HomeLLaMA* 的总体攻击成功率 SR_h 应为

$$SR_h = \epsilon \cdot SR_p \quad (8)$$

其中 ϵ 代表 *PrivShield* 的使用频率。在实际日常使用中，随着用户配置文件逐步构建完成，频率 ϵ 会逐渐降低，如 § VII-B所述。因此，*HomeLLaMA* 的整体隐私保护能力将随时间增强，因为用户将越来越多地依赖本地操作，而无需云端大语言模型协助。

• 随着对抗性指令数量的增加，隐私保护得到加强。这些对抗性指令可以在文本空间中引入噪声，使得恶意攻击者更难识别真实查询。此外，生成更多对抗性指令会导致更高的延迟和成本，因此应允许用户根据自身需求，在隐私与性能之间决定其偏好的权衡。

• 隐私保护也受益于使用更强大的小型语言模型。如表II所示，用更大、更强大的模型替换基础小型语言模型，能显著降低攻击准确率。这是因为识别真实用户查询变得等同于从混合文本中区分AI生成的内容。更强大的小型语言模型更擅长生成高质量的对抗性指令，从而进一步掩盖真实查询，使其难以被识别。然而，

由于资源限制，部署更大的模型可能不切实际，这将在 § VI-D中进一步讨论。

备注：尽管攻击者可能部署先进的预训练分类器来区分用户指令与混淆后的混合指令。在此类情况下，可通过加强查询混淆（例如，选择更大的 N ）来增强 *PrivShield*，从而根据用户需求提供 stronger 的隐私保护。

C. 系统成本 (Q3)

1) 指标：我们从以下几个方面评估系统成本：1) **响应延迟**：我们测量从用户输入指令到生成最终行动计划所花费的时间，作为每个系统的响应延迟。2) **内存使用量**：我们通过一个名为 memory-profiler [68] 的 Python 包在系统使用过程中跟踪 GPU 内存使用量（以 GB 为单位）来衡量系统开销。

2) 基线模型：我们保持与 § VI-A2中相同的基线模型。请注意，前三个系统（即.., HomeGPT、Sasha和SAGE）基于无法直接访问的云端大语言模型，而只有TT探索了将小型语言模型集成到智能家居助手中。因此，我们仅测量 TT-Gemma、TT-Phi-2以及我们提出的 *HomeLLaMA* 的内存使用量。

3) 结果：为了衡量 *HomeLLaMA* 与基线模型的系统开销，我们将 *DevFinder* 基准中的每条测试指令输入其中，并报告平均响应延迟及其方差。如图11(a)所示，云端助手表现出相对更快的平均响应时间（约4.97秒），这主要得益于OpenAI服务的性能优化 [11]。然而，基于云端 LLM 的系统极易受网络条件和服务器稳定性影响，导致响应延迟方差显著，这可能会对用户体验产生负面影响 [69]。相比之下，*HomeLLaMA* 在响应延迟上表现出更小的方差，




图 14. 不同基础模型的影响。


尽管响应时间稍长。我们还跟踪了两种基于本地SLM的系统（即，TT和HomeLLaMA）在推理时采用不同量化精度（即，FP16、int8和INT4）时的最大GPU内存使用量。如图11(b)所示，这些系统的最大GPU内存需求保持在16 GB以下，这对于典型家庭来说是负担得起且易于管理的⁴。

D. 敏感性分析 (Q4)

1) 不同基础模型：我们通过部署 Qwen2-1.5B [70]、Phi3-3B [71]、LLaMA2-7B/13B [72]、LLaMA3-8B [57] 和 LLaMA3-70B [72] 到 HomeLLaMA 中来评估基础模型的影响。给定来自 DevFinder 的测试输入，我们记录其平均 DRS 和 GPU 内存使用量。如图 14 所示，模型可分为三组：(1) 轻量级模型（白色），如 Qwen2-1.5B 和 Phi3-3B，提供最低的内存使用量（~8GB），但性能较差；(2) 高端模型（红色），如 LLaMA2-13B、LLaMA3-70B 和 GPT-4o，能产生最佳的 DRS，但需要 ≥ 24 GB 的 GPU 内存；(3) 中端模型（蓝色），如 LLaMA2-7B 和 LLaMA3-8B，在性能和成本之间取得了平衡。因此，我们选择 LLaMA3-8B 作为默认的基础模型。

2) 不同的 α 在增强过程中：为了研究增强阈值 α （公式 1）的影响，我们将其从 0.1 变化到 0.9，并在相应的增强数据集上对 LLaMA3-8B、Phi3-3B 和 LLaMA2-7B 进行微调。如图 15(a) 所示，增加 α 通过促进数据多样性提高了平均 DRS。然而，增益在较高值时趋于饱和，同时由于数据集扩展导致训练成本上升。因此，我们默认设置 $\alpha = 0.7$ 。

3) 配置文件更新期间的不同 β ：配置文件更新阈值 β （公式 4）决定了何时保存新的用户画像。我们使用 10 位参与者，评估了在 β 从 0.1 到 0.9 变化下的个性化评分（1-5）。如图 15(b) 所示，较高的 β 最初通过防止过早的配置文件合并来提高满意度，但过高的值会导致冗余条目，损害检索效果。满意度在 $\beta = 0.6$ 左右达到峰值，我们将其采纳为默认值。

(a) 检查器使用的不同 α 。(b) 合并配置文件使用的不同 β 。图 15. 选择不同阈值 α 和 β 的影响。

VII. 用户研究

我们开展用户研究以收集用户反馈。该研究可分为两部分：一项在线调查和一次现场访谈，旨在回答以下问题：

- **Q5** - 用户隐私信心：HomeLLaMA 是否提升了用户感知的隐私信心？
- **Q6** - 用户满意度：用户对 HomeLLaMA 的整体服务质量感受如何？
- **Q7** - 长期个性化：HomeLLaMA 能否持续适应用户的偏好？

A. 在线调查：冷启动评估 (Q5 与 Q6)

1) 准备工作：我们选择了两个代表性的基线：云端助手 SAGE 和本地助手 TT-Gemma。针对每个场景，我们从 DevFinder 中选择一条测试指令，并将其输入到各个系统中以生成初始行动计划。随后，我们手动选择“建议”选项（§ IV-C1），并将反馈提供给所有系统。这些系统接着会进行偏好学习（如果适用），并重新生成行动计划，这些计划将被记录下来以供进一步分析。为确保公平性，系统呈现给参与者的顺序是随机化的。

2) 参与者：我们使用 Microsoft Forms⁵ 创建了一份在线调查，并通过电子邮件和社交媒体分发以招募参与者。在参与之前，所有受访者都收到了一份知情同意书，其中概述了研究目的、数据处理程序以及他们作为参与者的权利。该研究方案已由我们机构的伦理审查委员会（IRB）审查并批准。参与者被告知，他们的响应将被匿名化，并仅用于学术研究目的。参与完全是自愿的，且不提供任何金钱补偿。12天后，我们总共收到了100份响应，参与者数据显示，在性别、年龄、教育背景、英语熟练程度以及对智能家居助手的熟悉程度方面，参与者分布相对均衡。

3) 综述设计：该综述从以下四个指标评估智能家居系统：① **总体计划满意度**，评估对初始行动计划质量的满意度，不考虑个性化因素；② **用户档案准确性**，衡量生成的用户画像在本次交互中反映个人偏好和行为的准确程度；③ **个性化匹配度得分**，评估响应和推荐与

⁴一个 NVI DIA RTX 4070 Ti SUPER GPU (16 GB) 成本约为 84 美元 0。

⁵ <https://forms.office.com/>




图16. 用户研究结果, 包括 (a) 在线调查评分, 以及 (b)–(d) 显示的平均访谈结果。

交互轮次内的历史反馈的契合程度; 以及 ④ **隐私保障得分**, 衡量参与者对系统保护个人数据和维护隐私能力的信心。参与者被要求使用李克特量表 [73] 从1 (例如.g., 完全不) 到5 (例如.g., 完全) 对这些指标进行评分。

4) 总体结果: 图16(a) 可视化了总体评分结果, 各维度的关键观察包括: 1) 参与者对 *HomeLLaMA* 提供的服务质量表达了高度满意 (接近基于云端的助手 SAGE), 这反映了其能够根据用户需求提供有效且可靠行动计划的能力。这可能归功于本文提出的针对小型语言模型的定制化增强方法。2) 与其他基线模型相比, *HomeLLaMA* 在提供个性化响应和生成精确用户配置文件方面表现出色, 获得了约4.35分的最高平均分。这可能归功于用户偏好学习模块, 它能准确刻画结构良好的用户配置文件, 从而有效地调整计划。3) *HomeLLaMA* 因其隐私保护特性获得了高分, 超越了基于云端的解决方案, 并接近完全本地系统 TT-Gemma 的水平。这表明其通过在本机运行并最小化向云端的数据传输, 能够增强用户感知的隐私。此外, 由设计的 *PrivShield* 支持的本地-云端协作范式, 增强了用户对隐私的信心, 从而提升了系统的整体可用性。

B. 现场访谈: 长期评估 (Q7)

为了评估*HomeLLaMA*的长期性能, 我们本地部署了该系统以进行现场访谈。访谈持续25天, 包含50个对话轮次, 志愿者的实际平均使用时间约为45.6分钟。每个轮次代表一次完整的用户-助手-云端交互 (图6), 从用户指令开始, 到最终的行动计划结束。

1) 流程: 我们按照 § V 中的配置, 在一台实验室PC 上部署了*HomeLLaMA*。从 § VII-A1 描述的100名调查受访者中, 邀请了10名参与者, 并根据他们对智能家居的熟悉程度分为两组: 5名专家和5名非专家。访谈开始前, 所有参与者均提供了知情同意, 并获得了价值约10美元的超市优惠券作为报酬。参与者首先被介绍了交互工作流——包括接受、建议和拒绝选项——以确保熟悉。此外, 在开始交互前, 向他们解释了两个评估指标: ① **长期个性化** 评估系统如何

有效地推断并长期保留用户偏好。② **易用性** 评估系统如何随着使用持续, 高效地最小化用户为获得满意响应所需付出的努力。随后, 参与者被邀请自由地与*HomeLLaMA*交互, 通过用户界面以自然语言无约束地发出智能家居指令。每经过五个对话轮次, 他们使用这两个预定义指标在5分制上对系统进行评分。在整个会话期间, 我们记录了所有评估分数, 并且每五个轮次, 还追踪了*PrivShield* 为获取云端辅助而被激活的次数。最后, 分别计算并分析了每组的平均结果。

2) 结果: 如图16所示, 随着对话轮次的增加, 专家和非专家参与者对*HomeLLaMA*在个性化和易用性方面的评分均呈现稳步上升趋势, 这反映了系统通过动态维护用户配置文件进行适应的能力。专家倾向于更早给出更高分数, 这可能是由于他们能更清晰地表达偏好, 从而加速了配置文件质量的提升和系统适应。在易用性评分方面, 专家始终保持约0.35分的优势, 尽管两组评分在50轮后均收敛至4.2分以上, 表明系统具有很强的可用性。此外, 两组参与者激活*PrivShield* 的频率均有所下降, 到第50轮时接近为零, 这突显了*HomeLLaMA*随着对用户偏好的更好内化, 减少了对云端支持的依赖, 从而增强了隐私保护。

八、结论

本文提出了一种设备端智能家居助手, 旨在为用户平衡隐私与性能。所设计的*HomeLLaMA* 包含三个技术模块: 本地SLM增强、多奇偶性交互和用户偏好学习, 支持涉及用户参与循环的无缝且隐私增强的交互。我们构建了*DevFinder*基准来评估生成响应的质量。全面的用户研究表明, *HomeLLaMA*能提供令人满意的、增强个性化的计划, 同时减轻隐私顾虑。此外, 广泛的定量实验验证了*HomeLLaMA* 在增强用户于数据存储、网络传输和推理相关 (例如, 个人身份信息提取) 攻击中的隐私方面的有效性。

参考文献

- [1] B. L. R. Stojkoska and K. V. Trivodaliev, 《智能家居物联网综述: 挑战与解决方案》, 清洁生产杂志, 第140卷, 第1454–1464页, 2017年。

- [2] S. Solaimani, W. Keijzer-Broers 和 H. Bouwman, 《我们对智能家居的已知与未知: 智能家居文献分析》, 室内与建筑环境, 第24卷, 第3期, 第370–383页, 2015年。[3] X. Yu, Z. Zhou, L. Zhang 和 X.-Y. Li, 《Thumbup: 使用简单手势的智能家居安全智能手表控制器》, IEEE移动计算汇刊, 第23卷, 第1期, 第865–878页, 2022年。[4] J. Cui, J. Xiao, H. Zhong, J. Zhang, L. Wei, I. Bolodurina 和 D. He, 《Lh-ids: 基于差分隐私的车载自组织网络轻量级混合入侵检测系统》, IEEE移动计算汇刊, 第23卷, 第12期, 第12195–12210页, 2024年。[5] E. King, H. Yu, S. Lee 和 C. Julien, 《Sasha: 智能家居中基于大语言模型的创造性目标导向推理》, ACM普适计算交互、移动、可穿戴和普适技术汇刊, 第8卷, 第1期, 第1–38页, 2024年。[6] Z. Ramadan, M. F Farah 和 L. El Essrawi, 《从亚马逊网站到亚马逊之爱: Alexa如何为有特殊需求的人群重新定义陪伴与相互依存》, 心理学与市场营销, 第38卷, 第4期, 第596–609页, 2021年。[7] J. R. Bellegarda, 《用于自然交互的口语理解: Siri的经验》, 与机器人、知识机器人和智能手机的自然交互: 将口语对话系统付诸实践, 第3–14页, 2013年。[8] D. Xu, W. Yin, H. Zhang, X. Jin, Y. Zhang, S. Wei, M. Xu 和 X. Liu, 《Edgellm: 基于推测解码的快速设备端大语言模型推理》, IEEE移动计算汇刊, 第24卷, 第4期, 第3256–3273页, 2025年。[9] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong 等, 《大语言模型综述》, arXiv预印本 arXiv:2303.18223, 2023年。[10] C. Liu 和 J. Zhao, 《增强边缘辅助移动系统中大语言模型训练的稳定性与资源效率》, IEEE移动计算汇刊, 第1–18页, 2025年。[11] Openai, 《GPT-4》。[在线]。访问地址: <https://chat.openai.com/chat/> [12] Q. Chai 和 G. Gong, 《面向半诚实但好奇的云服务器的可验证对称可搜索加密》, 发表于IEEE国际通信大会, 2012年, 第917–922页。[13] P. Sun, Z. Wang, L. Wu, Y. Feng, X. Pang, H. Qi 和 Z. Wang, 《面向移动群智感知系统中真值发现的个性化隐私保护激励机制》, IEEE移动计算汇刊, 第21卷, 第1期, 第352–365页, 2020年。[14] T. Li, H. Wang, Q. Li, Y. Jiang 和 Z. Yuan, 《Cl-shield: 保护用户隐私的持续学习系统》, IEEE移动计算汇刊, 第24卷, 第4期, 第3148–3162页, 2025年。[15] W. Wang, Y. Wang, P. Duan, T. Liu, X. Tong 和 Z. Cai, 《移动众包中基于边缘计算和区块链的三重实时轨迹隐私保护机制》, IEEE移动计算汇刊, 第22卷, 第10期, 第5625–5642页, 2022年。[16] H. Chi, Q. Zeng, X. Du 和 J. Yu, 《智能家居中的跨应用干扰威胁: 分类、检测与处理》, 发表于2020年第50届IEEE/IFIP可靠系统与网络国际会议。IEEE, 2020年, 第411–423页。[17] L. Shen, Q. Yang, K. Cui, Y. Zheng, X.-Y. Wei, J. Liu 和 J. Han, 《Fedconv: 面向异构联邦客户端的基于模型的学习范式》, 发表于ACM移动系统、应用与服务国际会议, 2024年, 第398–411页。[18] L. Shen 和 Y. Zheng, 《Feddm: 通过动态权重共享实现数据和模型异构感知的联邦学习》, 发表于2023年IEEE分布式计算系统国际会议。IEEE, 2023年, 第975–976页。[19] L. Shen, Q. Yang, K. Cui, Y. Zheng, X.-Y. Wei, J. Liu 和 J. Han, 《通过基于模型的学习范式实现分层异构联邦学习》, IEEE移动计算汇刊, 第1–16页, 2025年。[20] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu 和 D. Amodei, 《神经语言模型的缩放定律》, arXiv预印本 arXiv:2001.08361, 2020年。[21] D. Rivkin, F. Hogan, A. Feriani, A. Konar, A. Sigal, S. Liu 和 G. Dudek, 《Sage: 具有接地执行的智能家居代理》, arXiv预印本 arXiv:2311.00772, 2023年。[22] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Kuttler, M. Lewis, W.-t. Yih, T. Rocktaschel 等, 《面向知识密集型自然语言处理任务的检索增强生成》, 神经信息处理系统进展, 第33卷, 第9459–9474页, 2020年。[23] E. King, H. Yu, S. Lee 和 C. Julien, 《“准备派对吧”: 借助大语言模型探索更智能的智能空间》, arXiv预印本 arXiv:2303.14143, 2023年。[24] E. King, H. Yu, S. Vartak, J. Jacob, S. Lee 和 C. Julien, 《Thoughtful Things: 利用小语言模型构建以人为本的智能设备》, arXiv预印本 arXiv:2405.03821, 2024年。[25] S. Aheleroff, X. Xu, Y. Lu, M. Aristizabal, J. P. Velásquez, B. Joa, and Y. Valencia, “工业4.0下的物联网智能家电: 案例研究,” 《先进工程信息学》, 卷 43, 页 101043, 2020。[26] R. H. Jensen, Y. Strengers, J. Kjeldskov, L. Nicholls, and M. B. Skov, “设计理想的智能家居: 家庭体验与能耗影响研究,” 发表于 ACM 人机交互大会, 2018, 页 1–14。[27] M. Li, W. Gu, W. Chen, Y. He, Y. Wu, and Y. Zhang, “智能家居: 架构、技术与系统,” 《Procedia 计算机科学》, 卷 131, 页 393–400, 2018。[28] D. Marikyan, S. Papagiannidis, and E. Alamanos, “智能家居文献系统综述: 用户视角,” 《技术预测与社会变革》, 卷 138, 页 139–154, 2019。[29] R. D. Manu, S. Kumar, S. Snehashish, and K. Rekha, “使用物联网和深度学习的智能家居自动化,” 《国际工程技术研究杂志》, 卷 6, 期 4, 页 1–4, 2019。[30] A. S. Tulshan and S. N. Dhage, “虚拟助手综述: Google Assistant, Siri, Cortana, Alexa,” 发表于《信号处理与智能识别系统进展: 第四届国际研讨会 SIRS 2018, 印度班加罗尔, 2018年9月19–22日, 修订版论文集 4》。施普林格, 2019, 页 190–201。[31] J. Li, Z. Li, G. Tyson, and G. Xie, “家庭安防摄像头服务的使用模式与隐私风险特征分析,” IEEE移动计算汇刊, 卷 21, 期 7, 页 2344–2357, 2020。[32] K. Han, A. Xiao, E. Wu, J. Guo, C. Xu, and Y. Wang, “Transformer中的Transformer,” 神经信息处理系统大会, 卷 34, 页 15 908–15 919, 2021。[33] L. Shen, Q. Yang, Y. Zheng, and M. Li, “AutoIoT: 面向人工智能物联网应用的LLM驱动自动化自然语言编程,” 发表于 ACM 移动计算与网络大会, 2025。[34] L. Shen, Q. Yang, X. Huang, Z. Ma, and Y. Zheng, “GPIoT: 为物联网程序合成与开发定制小语言模型,” 发表于 ACM 嵌入式网络系统大会, 2025。[35] L. Shen and Y. Zheng, “IoTcoder: 物联网应用开发的副驾驶,” 发表于 ACM 移动计算与网络大会, 2024, 页 1647–1649。[36] J. Rey-Jouanchicot, A. Bottaro, E. Campo, J.-L. Bouraoui, N. Vigouroux, and F. Vella, “利用大语言模型增强智能家居的个性化用户体验,” 2024。[37] A. K. Newendorp, M. Sanaei, A. J. Perron, H. Sabouni, N. Javadvpour, M. Sells, K. Nelson, M. Dorneich, and S. B. Gilbert, “苹果的知识导航器: 为何该对话代理尚未出现?” 发表于 ACM 人机交互大会, 2024, 页 1–14。[38] P. M. Schwartz and D. J. Solove, “个人可识别信息问题: 隐私与个人可识别信息的新概念,” 《纽约大学法律评论》, 卷 86, 页 1814, 2011。[39] Z. Wang, Y. Sun, D. Liu, J. Hu, X. Pang, Y. Hu, and K. Ren, “移动边缘计算中的位置隐私感知任务卸载,” IEEE移动计算汇刊, 卷 23, 期 3, 页 2269–2283, 2023。[40] V. Srinivasan, J. Stankovic, and K. Whitehouse, “保护您的日常家庭活动信息免受无线窃听攻击,” 发表于 ACM 普适计算大会。[41] B. Gunel, J. Du, A. Conneau, and V. Stoyanov, “用于预训练语言模型微调的监督对比学习,” arXiv预印本 arXiv:2011.01403, 2020。[42] H. Yu, J. Hua, and C. Julien, “分析 IFTTT 配方以研究人类如何使用物联网设备,” 发表于 ACM 嵌入式网络系统大会, 2021, 页 537–541。[43] C.-Y. Lin and F. Och, “寻找几个好的指标: ROUGE 及其评估,” 发表于 NTCIR 研讨会, 2004。[44] D. Blazakis, “苹果沙盒,” 弗吉尼亚州阿灵顿, 2011年1月。[45] C. Xu, Q. Sun, K. Zheng, X. Geng, P. Zhao, J. Feng, C. Tao, and D. Jiang, “WizardLM: 赋能大语言模型遵循复杂指令,” arXiv预印本 arXiv:2304.12244, 2023。[46] C.-Y. Lin, “ROUGE: 自动摘要评估包,” 发表于《文本摘要分支》, 2004, 页 74–81。[47] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, “QLoRA: 量化大语言模型的高效微调,” 神经信息处理系统大会, 卷 36, 2024。[48] Z. Han, C. Gao, J. Liu, S. Q. Zhang 等, “大模型的参数高效微调: 全面综述,” arXiv预印本 arXiv:2403.14608, 2024。[49] J. Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, Q. V. Le, D. Zhou 等, “思维链提示激发大语言模型的推理能力,” 神经信息处理系统大会, 卷 35, 页 24 824–24 837, 2022。[50] Y. Zhao, Z. Yang, X. He, X. Cai, X. Miao, and Q. Ma, “Trine: 面向家庭应用的云端协同实时视频分析,” IEEE移动计算汇刊, 卷 22, 期 8, 页 4973–4985, 2022。[51] T. W. Li, A. Arya, and H. Jin, “基于用户反馈重新设计隐私: 以Zoom参会者注意力追踪为例,” 发表于 ACM 人机交互大会, 2024, 页 1–14。

- [52] E. Al Qahtani, P. Story, and M. Shehab, “风险诉求方法对用户分享机密信息的影响,” 发表于ACM人机交互大会, 2024, 页1–21. [53] U. Scherhag, C. Rathgeb, J. Merkle, and C. Busch, “用于差分变形攻击检测的深度人脸表示,” IEEE信息取证与安全汇刊, 卷15, 页3625–3639, 2020. [54] Q. Li, J. Wen, and H. Jin, “通过示例编程利用边缘大语言模型治理开放词汇数据泄露,” ACM普适计算交互、移动、可穿戴和普适技术汇刊, 卷8, 期4, 页1–31, 2024. [55] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimeshein, L. Antiga 等, “PyTorch: 一种命令式、高性能的深度学习库,” 《神经信息处理系统进展》, 卷32, 2019. [56] H. Chase, “LangChain,” 2022年10月。[在线]。可访问: <https://github.com/langchain-ai/langchain> [57] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar 等, “Llama: 开放高效的基础语言模型,” arXiv预印本 arXiv:2302.13971, 2023. [58] M. Douze, A. Guzhva, C. Deng, J. Johnson, G. Szilvasy, P.-E. Mazaré, M. Lomeli, L. Hosseini, and H. Jégou, “faiss库,” arXiv预印本 arXiv:2401.08281, 2024. [59] G. Team, T. Mesnard, C. Hardin, R. Dadashi, S. Bhupatiraju, S. Pathak, L. Sifre, M. Riviére, M. S. Kale, J. Love 等, “Gemma: 基于Gemini研究与技术的开放模型,” arXiv预印本 arXiv:2403.08295, 2024. [60] M. Abdin, S. A. Jacobs, A. A. Awan, J. Aneja, A. Awadallah, H. Awadalla, N. Bach, A. Bahree, A. Bakhtiari, H. Behl 等, “Phi-3技术报告: 手机上本地运行的高性能语言模型,” arXiv预印本 arXiv:2404.14219, 2024. [61] P. Sun, “云计算中的安全与隐私保护: 讨论与挑战,” 《网络与计算机应用期刊》, 卷160, 页102642, 2020. [62] Z. Yang, M. Yang, Y. Zhang, G. Gu, P. Ning, and X. S. Wang, “Appintent: 分析安卓中的敏感数据传输以进行隐私泄露检测,” 发表于ACM计算机与通信安全会议, 2013, 页1043–1054. [63] C. Marcolla, V. Sucasas, M. Manzano, R. Bassoli, F. H. Fitzek, and N. Aaraj, “全同态加密综述: 理论与应用,” 《IEEE会刊》, 卷110, 1609, 2022 10, 1572 期 pp. –。 [64] S. Kim, S. Yun, H. Lee, M. Gubri, S. Yoon, and S. J. Oh, “Propile: 探测大语言模型中的隐私泄露,” 神经信息处理系统大会, 卷36, 2024. [65] A. Frikha, N. Walha, K. K. Nakka, R. Mendes, X. Jiang, and X. Zhou, “Incognitext: 通过基于LLM的私有属性随机化实现隐私增强的条件文本匿名化,” arXiv预印本 arXiv:2407.02956, 2024. [66] Z. Xu, S. Jain, and M. Kankanhalli, “幻觉不可避免: 大语言模型的内在局限,” arXiv预印本 arXiv:2401.11817, 2024. [67] Q. Li, J. Hong, C. Xie, J. Tan, R. Xin, J. Hou, X. Yin, Z. Wang, D. Hendrycks, Z. Wang 等, “LLM-PBE: 评估大语言模型中的数据隐私,” arXiv预印本 arXiv:2408.12787, 2024. [68] o. Fabian Pedregosa, “Memory-Profiler: 监控Python代码的内存使用量。” [在线]。可访问: https://github.com/pythonprofilers/memory_profiler [69] F. Bang, “Gptcache: 面向大语言模型应用的开源语义缓存, 实现更快回答与成本节约,” 发表于自然语言处理开源软件研讨会, 2023, 页212–218. [70] A. Yang, B. Yang, B. Hui, B. Zheng, B. Yu, C. Zhou, C. Li, C. Li, D. Liu, F. Huang 等, “Qwen2技术报告,” arXiv预印本 arXiv:2407.10671, 2024. [71] M. Abdin, S. A. Jacobs, A. A. Awan, J. Aneja, A. Awadallah, H. Awadalla, N. Bach, A. Bahree, A. Bakhtiari, H. Behl 等, “Phi-3技术报告: 手机上本地运行的高性能语言模型,” arXiv预印本 arXiv:2404.14219, 2024. [72] A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Yang, A. Fan 等, “Llama 3模型群,” arXiv预印本 arXiv:2407.21783, 2024. [73] A. Joshi, S. Kale, S. Chandel, and D. K. Pal, “李克特量表: 探索与解释,” 《英国应用科学与技术杂志》, 卷7, 期4, 页396–403, 2015.