

Sasha：大语言模型在智能家居中的创造性目标导向推理

EVAN KING, 德克萨斯大学奥斯汀分校, 美国

HAOXIANG YU, 德克萨斯大学奥斯汀分校, 美国

SANGSU LEE, 德克萨斯大学奥斯汀分校, 美国

CHRISTINE JULIEN, 德克萨斯大学奥斯汀分校, 美国

当用户指令直接且明确指定时——例如“打开厨房灯”——或者当硬编码的例程指定了响应时，智能家居助手的功能发挥最佳。然而，在更自然的交流中，人类语言是无约束的，通常描述的是目标（例如“让这里变得舒适”或“帮我节能”），而不是指明具体目标设备以及要在这些设备上执行的动作。当前的系统无法理解这些欠明确指令，因为它们无法根据与人类情境的关联来推理设备和设置。我们将大语言模型引入这一问题领域，探索其在智能家居中用于控制设备以及创建自动化例程以响应未充分明确的用户指令的用途。我们通过对不同年龄段的用户的调查，实证研究了大语言模型创建的行动计划的质量基线质量和故障模式。我们发现，大语言模型可以进行创造性推理以实现具有挑战性的目标，但它们存在一些故障模式，降低了其实用性。我们通过Sasha——一个更智能的智能家居助手——来弥补这些不足。Sasha通过执行计划来实现用户目标，从而响应“让这里变得舒适”或“帮我睡得更好”等宽松约束指令——例如，利用可用设备设置氛围，或设计自动化例程。我们通过实践用户研究实现并评估了Sasha，展示了大语言模型驱动的智能家居在面对无约束用户生成场景时的能力和局限性。

CCS概念：• 以人为中心的计算 → 普适与移动计算；普适与移动计算系统及工具；普适与移动计算实证研究。

其他关键词和短语：智能环境，普适计算，环境智能，大语言模型

ACM参考文献格式：

Evan King, Haoxiang Yu, Sangsu Lee, 以及 Christine Julien. 2024. Sasha：智能家居中基于大语言模型的创造性目标导向推理。《ACM交互式、移动、可穿戴和普适技术汇刊》8卷，第1期，文章12（2024年3月），38页。<https://doi.org/10.1145/3643505>

1 介绍

普适计算领域一个长期存在的挑战是开发能够创造性地推断并响应用户目标的智能空间。当一个人像与Alexa这样的智能家居界面进行对话式交流时——例如，要求它“让客厅变得舒适”——很快就会发现，这些系统难以将日常的人类情境与恰当的智能家居动作联系起来[17, 27, 32, 42]。当人们彼此互动时，不受约束的自然语言则不那么成问题。如果有人要求我们“让客厅变得舒适”，我们会将“舒适”这个概念与环境特质联系起来：温度、照明、音乐等。正确的响应会因空间、空间提供的参数以及个人偏好而异[25, 47]。总的来说，人类擅长

作者地址：Evan King, 德克萨斯大学奥斯汀分校, 德克萨斯州奥斯汀市, 美国, e.king@utexas.edu; Haoxiang Yu, 德克萨斯大学奥斯汀分校, 德克萨斯州奥斯汀市, 美国, hxyu@utexas.edu; Sangsu Lee, 德克萨斯大学奥斯汀分校, 德克萨斯州奥斯汀市, 美国, sethlee@utexas.edu; Christine Julien, 德克萨斯大学奥斯汀分校, 德克萨斯州奥斯汀市, 美国, c.julien@utexas.edu。

本作品的部分或全部内容可以免费制作数字或纸质副本，供个人或课堂使用，前提是这些副本不得用于盈利或商业目的，且每份副本首页须保留本声明及完整引用信息。对于本作品中第三方组件的版权须予以尊重。其他所有用途，请联系所有者/作者。© 2024 版权归所有者/作者所有。2474-9567/2024/3-ART12<https://doi.org/10.1145/3643505>

从“舒适”这样的抽象概念快速进行语义跳跃，联想到对可用设备采取的具体动作。遗憾的是，驱动现代智能家居的系统缺乏这种能力。

当用户发现家庭助手推理能力的局限时，他们必须手动安装智能家居例程。这些工具（例如“If This Then That”（IFTTT）[4]）提供了一种为现代智能家居注入智能假象的方法，尽管在这种情况下，真正的智能来源仍然是用户，是他们创造了它。如果有人想告诉Alexa“派对时间到了”以触发灯光方案和音响配置，他们必须使用IFTTT来硬编码该动作。根据最近的统计，IFTTT上大约有3000个智能家居例程已被安装了近200万次[63]，这意味着用户有许多目标无法通过当前系统实现，而无需手动干预。用户必须调整自己的心智模型以适应系统的限制，而不是系统直观地支持用户[14, 54]。

我们利用大语言模型（LLMs）来应对在智能家居中灵活支持用户目标的挑战。大语言模型是在涵盖互联网上大部分可用书面文本和代码的多样化语料库上训练的通用的语言模型[22, 45]。这些模型在许多下游任务上表现出极高的性能，而无需针对特定用例进行重大的模型更新[11, 57]。例如，同一个GPT-3模型已被用于通过自然语言控制机器人技术[30, 61]，以及模拟小社区中的人类社会动力学[41]。这种通用性部分归因于大语言模型训练数据的多样性和规模：由于这些数据跨越学科和上下文，它以一种特定任务模型输入数据所不具备的方式，体现了跨领域的语义关系[22, 52]。正如Dey在一篇关于情境感知系统的基础性论文中所写，正是“[人类]语言的丰富性……[对世界运作方式的共同理解，以及对日常情境的隐含理解]使得人类能够以高层次概念而非具体动作进行交流[19]。鉴于大语言模型在涉及无约束语言和人类情境上下文的许多任务中的性能，我们将其引入智能环境。我们研究其潜力，以弥合隐含的智能家居用户目标与实现这些目标所需的具体动作之间的概念鸿沟，并围绕以下研究问题构建我们的探究：

- 研究问题一：当大语言模型用于智能家居控制时，会解锁哪些独特能力？我们试图揭示大语言模型是否以及如何为智能家居中更宽松的交互提供支持。
- 研究问题二：基于大语言模型的系统会带来哪些实际挑战？大语言模型可能产生不正确或“幻觉生成”的响应，并且运行计算成本高昂。我们旨在建立对这些在智能家居中存在的实际问题的基线理解。
- 研究问题3：哪些系统设计选择可以应对这些实际挑战？我们试图应用来自其他领域的大语言模型系统设计，并评估它们在应对智能家居特定应用挑战方面的有效性和适用性。
- 研究问题四：这种新型智能家居在无约束场景下支持用户目标的效果如何？在现实世界实现中，我们试图了解用户如何与一个约束更少的系统交互，它提供了哪些新能力，以及仍然存在哪些限制。

我们在本文中研究将大语言模型引入智能空间，其包含以模型驱动智能环境交互领域，先前工作很少。我们通过一个原型系统将大语言模型引入该问题领域，该系统能响应智能家居中的用户指令，生成具体、可执行的行动计划，并利用可用的设备和传感器。

实证动机。我们研究原型系统的输出，以建立对大语言模型在智能环境中使用时出现挑战的实证理解。我们定性分析了来自 $N = 20$ 人工标注员的600条标签和自由形式理由，这些内容涉及大语言模型生成的行动计划，并辅以定量分析。我们发现，大语言模型能够灵活地生成创造性的行动计划，以响应未充分明确的用户指令。然而，大语言模型也容易在任务中出现故障；我们揭示了导致用户满意度低的7种常见故障类型，并提出了测量它们的方法。我们表明，大语言模型能够实现




图 1. Ov本文四个关键组成部分、其内部结构及驱动研究问题的概述

即时用户目标，例如“让这里变得舒适”，以及更复杂的持续性目标，例如“有阳光时使用自然光”，这需要自动化例程。

设计Sasha。为了应对我们识别出的挑战，我们提出了Sasha：一个更智能的智能家居助手。Sasha的创新之处在于一个迭代推理过程，使其能够创造性地工作以实现用户目标，同时调节大语言模型产生无意义或幻觉生成计划的倾向。我们的设计解决了我们通过实证研究提出的锁定相关设备和纳入用户偏好的挑战。我们的评估表明，Sasha减少了误报和对无关设备的错误目标锁定。

实现Sasha。我们在一个测试家庭中实现了Sasha。我们邀请了 $N = 7$ 名参与者在用户生成场景中给出不受限制的指令，使我们能够在现实环境中收集用户观点并测量系统的性能。

总之，我们的贡献如下：

- 一个将大语言模型引入智能空间中响应用户指令进行推理问题的系统。
- 一项实证研究，展示了大语言模型支持面向目标的交互的潜力，同时也揭示了降低大语言模型实用性的特定故障模式。
- Sasha，一个更智能的智能家居助手，它利用新颖的迭代推理过程，针对不同智能家居中未充分明确的用户指令，生成高质量的行动计划。
- 对Sasha进行的一系列评估，从定性和定量角度验证了该系统用于生成行动计划的迭代推理过程的每一步。
- 在测试家庭中对Sasha进行的现实世界实现和用户研究，展示了该系统在面对无约束的用户生成场景时的实际能力。

我们在第2节提供背景。我们在第3节通过一个原型系统将大语言模型引入智能环境。我们在第4节进行了一项实证研究，揭示了进一步研究的具体方向。第5节介绍了Sasha，这是一个解决了一些已识别的关键挑战的系统。我们在第6节评估Sasha，并在第7节描述了一项现实世界用户研究的结果。第8节讨论了影响和未来工作，而第9节为结论。

2 背景与相关工作

在下文中，我们将本文置于智能环境和大型语言模型的相关研究背景中进行定位。

1s.

2.1 智能环境与用户目标

“智能环境”与Weiser对普适计算的愿景相一致，即嵌入日常设备中的计算能力被用于不引人注目地满足人们的需求 [59]。一个智能环境依赖于嵌入灯泡、电器、可穿戴设备和建筑环境中的联网设备和传感器来




图2. 用户指令具有不同程度的明确性。左：明确指定的指令定义了具体动作、具体目标设备和具体触发器。中：中度未明确指定的指令可能提及目标、动作和触发器，但未具体说明。右：完全未明确指定的指令没有明确的目标、期望动作或触发器。我们重点关注中度和完全未明确指定的指令。

感知并响应这些需求 [20]。在建筑环境中使用某种形式的“智能”来协调设备和传感器，在楼宇管理 [26]，基础设施 [10]，医疗保健 [6] 和家庭 [7] 领域有着广泛的应用。我们专注于智能家居，Lutolf 将其描述为“家庭内不同服务的整合”，并且“包含高度的...灵活性” [33]。我们从社会技术视角（即它们如何支持人）而非纯粹的技术视角（即它们能做什么）来考虑智能家居，因为这最终会影响人们是否选择将其融入日常生活 [60]。在最近一项关于智能家居的社会技术分析中，Reisinger 等人将可定制性、自动化、可访问性、可靠性和低延迟确定为主要关切点 [47]。这些因素中的每一个都影响着我们的方法。

我们的工作核心在于应对以下挑战：推理家庭环境中可用设备和传感器，与用户以其自身表达方式所暗示的目标之间的关系 [14, 37, 40]。我们将问题定义为创建可执行的“行动计划”，利用空间的能力来满足用户的即时（即立即做某事）和持久性（即自动化某事）目标。我们将交互分为这两类，这与 Clark 等人的分类相呼应，他们将交互模式分为即时或“条件性” [14]。该研究发现，用户“期望智能体理解基本目标。如果系统能够支持这一点，将为智能体实现指定目标提供极大的灵活性。”在这些设想的面向目标的交互中，系统应被设计为能够根据用户对期望最终状态或环境变化的描述（例如，“我想看电影”）来推断并设计行动方案，而不是根据对具体动作的描述 [24]。

我们关注那些在某个方面欠明确的用户指令，即它们没有定义具体的目标设备、在设备上要执行的特定动作，以及对于持续性目标而言，具体的触发器。指令的“明确性”是一个连续谱系，从明确指定（例如，“早上8点打开厨房灯”）到中度未明确指定（例如，“早上让厨房亮堂起来”）再到完全未明确指定（例如，“帮我起床”）（图2）。对于中度未明确指定的指令，其目标对人类而言通常是清晰的，但对系统来说则不那么明显，这也是一个常见的挫败感来源：现有系统在僵化、高度特定的命令结构之外表现不佳 [17, 27, 32]，并且通常无法处理复杂的指令 [42, 54]。因此，我们的研究范围既包括中度未明确指定的指令（例如，“外面冷的时候关掉空调”），也包括完全未明确指定的指令（例如，“让这里变得舒适”）。

先前工作已提出用于推断用户目标的任务特定系统。Noura 等人提出了用于建模面向目标的智能家居话语的VISH语法和生成式数据集，并利用它来训练任务特定自然语言模型并改进理解 [36, 37]。该方法通过引入面向目标的语法来拓宽助手支持的命令结构，例如，用户可以说“百叶窗太低了”来升起百叶窗。该系统不支持像“让这里变得舒适”这样可能根据环境需要不同响应的完全未明确指定的指令，也不支持像“帮我节能”这样需要对家庭环境和传感器进行推理的持续性目标。Palanca 等人则通过

一个任务特定系统来实现用户目标的问题，提出了一种多智能体方法 [40]。智能体（例如，照明智能体、电视智能体等）根据描述智能体能力和关系的本体进行协调，以形成实现用户目标的合适计划。我们对输出“行动计划”的关注与此有相似之处——然而，对刚性本体的依赖最终会强加关于人们如何在家中设备以及他们想要实现什么目标的假设。我们的目标是比现有系统具有更大的灵活性。

2.2 大语言模型的应用

大语言模型（LLMs）源于20世纪50年代和60年代开始的自然语言处理（NLP）研究 [12]。NLP研究旨在使计算机能够以有用的方式理解、解释和生成人类语言。近期NLP研究活动的激增，归因于Vaswani等人引入的Transformer模型 [55]。基于Transformer的模型，如双向编码器表示转换器（BERT） [18]、生成式预训练转换器（GPT） [11, 44, 45]、文本到文本传输转换器（T5） [46]，以及大型语言模型Meta AI（Llama） [52, 53]，均在大量多样的数据集上进行训练 [22]，使它们能够在许多涉及自然语言的任务上实现高性能，而无需针对特定任务进行训练 [11, 57]。在我们的实证研究中，我们重点关注几种流行的Transformer模型：商业化的GPT-3.5和GPT-4模型，以及Llama 2模型。这些模型最近已被应用于机器人技术 [50, 61]和社会科学 [41]中的各种问题。

在智能家居中，大语言模型可能比任务特定系统实现用户与空间之间更灵活的交互。这源于其多样化的训练数据中蕴含的对日常情境的更深入接触。例如，Fast等人表明，一个仅接受虚构文学作品训练的语言模型，可以通过利用物体与其常用活动之间的语义关系，来识别日常生活活动 [21]。语言模型对人类行为的这种体现，本质上是其基于海量包含非结构化行为描述的文本进行训练的副产品。然而，除了我们先前的研究 [28]，外，我们尚未了解到大语言模型与智能空间交叉领域的研究。该研究表明，GPT-3.5能够针对智能家居中未充分明确的用户指令制定创造性的计划。但该研究并未实证性地确立开放挑战，也未探究实现持久性用户目标的可能性、提出系统改进方案或包含用户研究。我们则考虑了所有这四个方面。

将大语言模型集成到系统中仍然具有高度主观性 [43, 48]。目前存在两种相互重叠的实践，以使通用模型适应特定任务：微调 [64] 和提示工程 [31]。前者涉及使用反映期望输出结构的（输入，输出）对来部分重新训练模型，而后者则依赖于精心构建的自然语言提示词来引出期望的输出。在某些情况下，经过设计的提示词可能包含暗示期望输出结构的“少样本”训练示例，而包含无训练示例的提示词则被称为“零样本”。微调和提示工程并非互斥：通常，提示工程在已经为指令遵循 [57]，进行过微调的模型上表现更好，这使得它们能够遵循提示词中的指令。在我们的工作中，我们采用提示工程。关于思维链提示的研究表明，将问题分解为多个推理步骤（而非单一提示）可以提高性能 [58, 62]。我们基于零样本提示设计了一个原型系统，用于我们的初始实证研究，这使我们能够在大语言模型执行此项新任务的基础案例中描述其性能。随后，我们提出了一个改进的系统——Sasha，它将思维链提示应用于智能空间应用。

3 将大型语言模型引入智能空间

我们构建了一个原型，利用大语言模型来生成响应智能家居中用户指令的行动计划。我们的原型通过向大语言模型发送零样本提示词来工作，提示词中包含用户的自然语言指令以及一个描述智能家居中房间、设备和传感器的JSON格式“家庭模板”。




图3。我们 首先使用此实验设置，对智能家居应用中的大语言模型行为进行初步研究。

p.




图4。即时目标提示词与持久目标提示词的文本（分别为左和右）。即时提示词产生可立即执行的动作计划，而持久提示词则产生自动化例程。

提示词引导大语言模型输出机器可解析的动作计划——即，针对即时指令的设备设置更改，以及针对自动化例程的（触发器，动作）对，两者均以JSON格式表达——或者，如果目标看起来无法通过可用设备实现，则拒绝用户的请求。随后，解析并执行由模型生成的JSON动作计划。由于大语言模型尚未在智能环境上下文中得到严格研究，我们的原型设计避免涉足其他领域的最先进方法（例如，微调或思维链提示）。这提供了对基础案例中性能的理解，并为未来的改进建立了基线。我们将在第5节中提出此类改进。我们在图3中展示了我们的设置，并在下文提供详细信息。

提示。我们的提示词包含：(1) 关于任务的说明，(2) 一个包含家庭环境中房间、设备、传感器和设置信息的JSON“家庭模板”，以及(3) 用户的指令。即时指令的提示词指示模型输出一个立即执行的行动计划，而持久指令的提示词则指示模型以（触发器，动作）对的形式输出一个自动化例程。触发器是一个传感器或一组传感器及其触发例程的对应值，而动作则是一组设备及其待分配的设置。在这两种提示类型中，我们都指示模型，如果目标看起来无法通过可用设备实现，则应拒绝用户的指令。我们在图4中展示了这些提示词。

规划。给定提示后，大语言模型会构建一个JSON行动计划，该计划将用户指令中推断出的目标映射到可实现该目标的具体设备设置。由于这种“推理”最终源于不同词语之间的语义关系，因此行动计划是基于家庭模板JSON中房间、设备和设置的命名来构建的。模板中名为台灯的设备既表达了台灯的功能能力（例如，亮度），也表达了台灯的语义内容（例如，台灯用于阅读，台灯提供氛围照明）。这促使我们采用描述性命名并




图5. GPT-3.5对智能家居指令的响应。我们向模型提供用户指令以及家庭环境中可用设备和传感器的信息。其响应通常极具创造性, 但也常常错得离谱。

构建家庭模板的结构, 因为这是将家庭的具体 (例如, 设置) 和抽象 (例如, “氛围”) 能力提供给模型的主要方式。

解析。在大语言模型生成行动计划后, 我们对其进行后处理以提取JSON。我们的提示词中包含说明, 要求JSON中包含对所做更改的“解释”, 以便于检查。有了这个系统, 大语言模型就能响应智能家居指令——图5展示了一些示例。

4 实证动机

为了回答**研究问题1-2**, 我们使用前述原型系统进行了一项实证研究。我们 (1) 构建了一个具有代表性的用户指令和智能家居配置数据集, 作为系统的输入; (2) 设计了一项调查, 以获取用户对系统行动计划的质量和故障模式的看法; (3) 为行动计划本身建立了量化指标; (4) 报告了我们在调查和定量分析两方面的发现。

4.1 家庭模板与用户指令

我们构建了一个具有代表性的数据集作为系统的输入, 以便生成大量用于分析的行动计划。我们首先描述构建“家庭模板”作为系统输入的方法, 然后描述创建能代表我们任务的用户指令的流程。

家庭模板。我们通过改编两个来源的数据构建了三个家庭模板: 一个IFTTT智能家居例程数据集 [63], 以及来自CASAs数据集中一个家庭 [15] 的布局和传感器套件。IFTTT数据包包含用户创建和安装的最受欢迎的“配方”, 用于控制设备和自动化例程。它揭示了人们正在使用哪些设备以及他们如何使用这些设备, 同时也揭示了当前系统在无需手动配置的情况下无法满足的目标类型。

我们模拟了三个家庭, h_1 、 h_2 和 h_3 , 它们拥有不同数量和多样性的设备。我们根据设备类型在IFTTT数据集中的受欢迎程度来选择每个家庭包含的设备类型。智能灯是最受欢迎的, 因此 h_1 模拟了仅包含灯光的最基础的智能家居。 h_2 增加了次受欢迎的类型 (气候控制和娱乐), 而 h_3 则再次增加了接下来最受欢迎的类型 (安防、扫地机器人和杂项电器)。每个家庭都拥有相同的传感器套件, 这是通过选取CASAs数据集中HH101家庭的传感器子集构建的。每个家庭都与HH101具有相同的布局——我们在图6中展示了家庭和设备, 并在图7中展示了传感器套件。

我们使用两种数据结构将每个家庭环境编码为一个JSON“家庭模板”: 一种用于家庭的可控设备, 另一种用于其传感器。家庭中的每个顶层元素是一个房间, 其名称具有描述性 (例如, livingroom), 作为关于该处所发生活动的语义提示。房间包含设备, 其名称同样具有描述性 (例如, overheadlight)。每个设备有若干设置, 以键值对形式表示, 其中




图6. 我们为三个家庭环境（从左到右分别为 h_1 、 h_2 和 h_3 ）建模，其设备种类逐渐增多。这三个家庭都拥有相同的传感器套件。模型的推理基于给定的指令以及可用的设备和传感器。




图7. 我们家庭环境集合中的每个家庭模板 h_1 、 h_2 和 h_3 都拥有相同的传感器套件，如图所示 wn .

键是设置的名称（例如，灯的亮度），值是它的数据类型（例如，浮点数）。第二个数据结构包含家庭中的传感器——例如，运动、光照度——同样按房间组织。我们在传感器结构中包含一个全局字段，用于存储诸如本地时间和天气等值。我们选择JSON，因为它在大语言模型训练语料库中很常见 [22, 52]。此外，它也是智能设备API事实上的标准格式 [1—3, 5]，这有助于从研究到实际应用的过渡。

用户指令。我们创建了40条对应智能家居常见用户目标的自然语言指令。我们的指令（1）反映了当前系统无法满足的用户目标，并且（2）具有挑战性的、欠指定的措辞。我们再次挖掘了IFTTT数据集，考察人们如何使用其设备。数据集中的例程被分为12个目标类别，这些类别描述了它们所涵盖的动作和设备类型。例如，“环境亮度”类别包含表达用户改变照明目标的例程。我们为每个类别创建了指令，其依据是：存在对应的IFTTT例程意味着在现有系统中需要手动干预才能实现该目标。我们省略了几个与我们家庭环境中的设备无关的目标类别——园艺、设备中枢、插座和警报——最终为我们的指令确定了7个类别：环境温度、环境亮度、安防、节能、环境氛围、机器人控制和其他电器。我们为每个类别创建了6条指令，但节能类别除外。对于此类别，我们只创建了4条指令，因为数据集中的许多节能

例程实现了类似的目标，但只是针对了相似设备类型的不同制造商。我们编写了声明式指令，即表达期望的最终状态而不指定所需动作的指令 [24]。此外，我们的每条指令在以下至少一个方面是中度或完全未指定的：预期的目标设备、期望的动作，以及对于持续性目标而言，合适的触发器（图2）。指令“日落后保持照明”是中度未指定命令的一个例子，因为它既未指定目标（灯光、百叶窗等），也未指定触发器（检测日落的特定时间和/或传感器）。“帮我降低电费账单”是完全未指定命令的一个例子，因为它没有暗示任何能实现该目标的目标设备、触发器或动作。

每个类别中的一半指令反映即时目标，另一半是持续性目标。即时目标通过一个即时动作或一组动作实现，例如“让这里变得舒适”或“让这里不那么闷”。持续性目标则需要自动化例程。示例包括“帮我节能”或“如果天气不好请通知我”。我们在附录A中列出了所有指令，并附有它们所基于的IFTTT例程示例。

4.2 用户调查流程与指标

我们通过在线调查来收集用户对行动计划质量的看法。我们使用每条指令与每个家庭模板的组合作为输入，输入到前文所述的实验设置中，以生成行动计划。下文将描述调查设计、参与者招募和分析流程。

4.2.1 调查设计。对于给定的行动计划，我们会展示一张家庭环境的图片（如图6所示）以及下达给家庭环境的用户指令（例如“让这里变得舒适”）。我们要求参与者对用户指令的目标、动作以及（对于持续性目标指令）触发器是否被明确指定进行标注。我们在调查说明中包含了“明确指定”的定义（附录B），类似于图2。这些标注使我们能够验证关于用户认为指令有多不明确的假设。接下来，我们提供从JSON中提取的LLM行动计划的文本描述。我们要求参与者在从“非常不满意”到“非常满意”的5点量表上，标注他们对智能家居所采取行动的“满意程度”。为了回答研究问题1-2，满意度标注使我们能够分析导致LLM生成的行动计划用户感知质量高或低的可能因素。最后，我们要求参与者用自己的话简要描述响应的哪些方面令人满意或不满意。标注者提供的自由形式原理为LLM的能力和潜在故障模式提供了重要信息。每份调查包含30个此类问题，大约需要45分钟完成。每个行动计划会收到来自5位参与者的标注，使我们能够比较不同用户对同一行动计划的看法。完整调查问卷见附录B。

4.2.2 参与者。我们在机构审查委员会的监督下进行了调查。我们通过电子邮件、滚雪球和口碑方式招募了 $N = 20$ 名参与者。我们的目标是让参与者在各年龄段的分布相对均匀，因为年龄是影响智能家居认知和满意度 [49] 的关键因素。我们最终获得的参与者池呈半均匀分布，在6个年龄组中，除55-64岁组仅占5%代表性不足外，其余每组均占 $20\% \pm 5\%$ 。我们向参与者提供了20美元的礼品卡作为补偿。

4.2.3 分析：用户感知质量。我们根据用户调查中给出的满意度评分，对行动计划的用户感知质量进行评分。我们将从“非常不满意”到“非常满意”的五点量表上的每个分类评级，映射为 $[0.2, 1.0]$ 的数值评分。为了进行进一步的定性分析，我们研究了那些评分高于或低于平均水平，或其五位标注员评分存在高变异性的行动计划的自由形式理由。

4.2.4 分析：故障模式。我们通过一个系统性的两阶段编码过程，从用户调查中的自由形式理由中推导出故障模式：

ID	性别	Age	教育程度	智能家居熟悉度	英语水平
SP1	F	45-54岁	学士学位	中等程度	母语/双语
SP2	M	65+	研究生	Very	母语/双语
SP3	F	55-64岁	学士学位	轻微	母语/双语
SP4	F	25-34岁	学士学位	轻微	母语/双语
SP5	M	25-34岁	研究生	中等程度	母语/双语
SP6	F	18-24岁	高中或同等学历	中等程度	母语/双语
SP7	M	18-24岁	高中或同等学历	中等程度	母语/双语
SP8	M	25-34岁	研究生	轻微	母语/双语
SP9	F	65+	部分大学	中等程度	中等
SP10	M	65+	副学士或技术学位	中等程度	母语/双语
SP11	F	25-34岁	研究生	中等程度	母语/双语
SP12	M	65+	部分大学学历	中等程度	母语/双语
SP13	F	18-24岁	副学士或技术学位	Very	母语/双语
SP14	F	25-34岁	研究生	中等程度	母语/双语
SP15	F	35-44	研究生	中等程度	母语/双语
SP16	F	18-24岁	高中或同等学历	Very	母语/双语
SP17	F	45-54岁	研究生	轻微	母语/双语
SP18	M	35-44	大学毕业	轻微	基础
SP19	M	45-54岁	学士学位	中等程度	母语/双语
SP20	F	35-44	学士学位	Very	母语/双语

表1. 基于LLM的智能家居控制实证研究中调查参与者（SP）的人口统计学特征。

(1) 一名研究人员审阅了所有响应，以确定几个高层级的故障类别。随后，三名研究人员独立地将这些高层级类别的标签分配给325个质量低于“非常满意”的响应。

(2) 同三位研究人员讨论了他们在高层级分类任务中观察到的更具体的故障模式。在定义了一组细粒度故障模式后，每位研究人员独立地将这些标签分配给他们各自的原始标注。

此过程共产生了975个标注，其克里彭多夫阿尔法系数为0.75，配对科恩卡帕系数分别为0.75,0.76, 和 0.74，表明标注者间一致性处于可接受水平。

4.3 行动计划分析流程与指标

4.3.1 分析：相关性指标。我们通过检查目标设备与指令的目标类别的相关性来分析行动计划。这些指标大致基于信息检索中的文档相关性 [16]。针对7个目标类别中的每一个，我们识别出相关设备类型（基于该目标类别下IFTTT例程所针对的设备类型 [63]），以此作为一种真实情况。给定我们的用户指令集 C 、指令的目标类别 g_c 、LLM的行动计划为响应指令 $c \in C$ 而针对的设备的目标类别集 G_c ，以及家庭环境中设备所支持的目标类别集 G_h ，我们测量以下指标：

误报 (FP): 当系统创建了一个针对一个或多个设备的计划，但家庭环境中实际上没有任何与该指令相关的设备时，就会发生误报。我们将其计为：

$$FP = \frac{1}{|C|} \sum_{c \in C} fp(G_c, G_h, g_c)$$

$$fp(G_c, G_h, g_c) = \begin{cases} 1 & \text{if } |G_c| > 0 \text{ and } g_c \notin G_h \\ 0 & \text{otherwise} \end{cases}$$

漏报 (FN): 相反, 当系统未创建计划, 但家庭环境中存在相关设备时, 则发生漏报:

$$FN = \frac{1}{|C|} \sum_{c \in C} fn(G_c, G_h, g_c) \quad fn(G_c, G_h, g_c) = \begin{cases} 1 & \text{if } |G_c| = 0 \text{ and } g_c \in G_h \\ 0 & \text{otherwise} \end{cases}$$

准确率 (Acc): 准确率衡量的是, 当相关设备存在时, 行动计划仅针对相关设备的比例:

$$Acc = 1 - (FP + FN)$$

相关性分数 (Rel): 最后, 我们通过为 C 中的每条指令计算一个分数 $r \in [-1, 1]$ 来衡量系统输出的相关性, 该分数根据每条指令生成的行动计划中包含的相关设备与不相关设备的相对数量来分配。数值越低表示目标设备中不相关的部分越多, 数值越高则表示相关的部分越多。我们将 Rel 定义为一个系统所有 r 输出的平均值, 具体如下:

$$Rel = \frac{1}{|C|} \sum_{c \in C} r(G_c, G_h) \quad r(G_c, G_h) = \frac{|G_c \cap G_h| - |G_c - G_h|}{|G_c|}$$

在比较不同大语言模型的性能时, 我们根据未拒绝指令的行动计划比例来调整 Rel , 因为如果大语言模型拒绝了更多指令, 其 Rel 会被虚高。

4.3.2 分析: 成本与延迟。 输入或输出大语言模型的令牌数量是成本的一个指标 [56]。我们根据给定模型使用的编码方案来测量令牌数 [29, 39]。我们还通过计时代码中调用相关远程API的函数来测量响应延迟 (以秒为单位)。对于GPT模型, 我们使用OpenAI API; 对于Llama模型, 我们使用Hugging Face “推理端点” 上的专用部署。在这两种情况下, 我们都通过1Gbps光纤互联网连接访问API。延迟包括网络延迟、分布式计算资源上的负载变化等, 并提供了面向用户的性能估计。

4.3.3 分析: JSON有效性。 我们记录强制提取JSON是否必要且可行。首先, 我们尝试逐字解码响应——在这种情况下, 无需提取。如果失败, 我们尝试提取并解码响应中被顶级花括号包围的部分。这使我们能够识别那些包含额外说明 (例如, “当然, 这是JSON行动计划: { ... }”) 的响应中的有效JSON部分。最后, 如果这也失败了, 我们尝试将提取的字符串解释为抽象语法树, 即使响应包含例如用Python语法而非JSON表达的部分, 也能解码响应。如果所有步骤都失败, 我们认为该响应无效。

4.3.4 相关性检验。 我们使用肯德尔 τ_b 系数 (τ_b) 来检验用户调查中的质量标签与行动计划特征之间的相关性。 τ_b 检验两个可能不服从正态分布的变量之间的相关性, 其中 -1 和 1 分别表示强负相关和强正相关, 0 表示无相关性。考虑到我们任务的主观性程度 (特别是关于用户感知质量评分), 我们将 $\tau_b \geq 0.2$ 或 $\tau_b \leq -0.2$ 的阈值设为 $p \leq 0.05$ 。我们对于 τ_b 的阈值遵循了建立至少 “中等” 相关性的通用准则 [9]。

4.4 发现

4.4.1 发现一: 行动计划从极其有用到完全无意义不等。为了回答**研究问题1-2**, 我们根据其用户感知质量评分中的指标, 重点分析了几项行动计划。表2展示了来自我们调查中具有 (1) 持续高、 (2) 持续低以及 (3) 高度变动的质量评分的行动计划。持续高或低质量的计划, 其平均质量评分分别高于或低于总体平均水平, 且方差低于平均水平。高度变动的计划在其质量评分中具有高于平均水平的方差。

高满意度 (47% 的计划)	
h_1 帮我降低我的电费账单 为了降低您的电费账单，我会在15分钟内未检测到运动的任何房间关闭灯光。 这将确保灯光不会被不必要地开着。	
非常满意	SP1: 不错的选择。
非常满意	SP7: 非常好的回答，同时也理解并找出了完成任务所需的动作。
非常满意	由于只有灯光，家庭环境完全理解了如何节能。
	SP16: 是的，这很棒
h_2 帮助我放松 我已将客厅和卧室的灯光调暗为暖色调，并关闭了其他 房间的灯光，将恒温器设置为舒适的68度，并调低了智能音箱的音量。 电视已关闭，以帮助您放松。	
非常满意	SP10: 很好的策略，充分利用了可用设备。
非常满意	SP16: 这很可靠。人工智能比我更懂得如何放松。
满意	SP17: 这听起来很适合放松。
低满意度 (13% 的计划)	
h_2 日落后停止清洁 当本地时间传感器检测到日落时，客厅的智能音箱将被指令 停止清洁过程。	
非常不满意	SP1: 智能音箱不进行清洁。
不满意	SP8: 智能音箱似乎不相关。
非常不满意	SP18: 智能音箱不会清洁。
h_1 有人时不清洁 当入口检测到运动时，清洁机器人将被关闭。	
非常不满意	SP7: 这栋房屋里没有清洁机器人。另外，检查入口处的运动 不会告诉你房屋里是否有人。
中立	SP12: 没有机器人。
非常不满意	SP18: 房屋内没有清洁机器人。
变量满意度 (40% 的计划)	
h_1 让客人进来 入口顶灯已以60%的亮度打开，以便让客人进来。	
满意	SP6: 使用了最可用的有用设备，所以看起来是一个不错的响应。
非常不满意	SP7: 没有控制入口门的设备，因此家庭环境应该直接说 由于没有可用的设备，它无法完成此任务。
中立	SP19: 打开灯有助于客人进入，但这与让他们进来是两回事。
h_2 在我不需要时关闭恒温器 当客厅的温度传感器显示 温度处于舒适范围内时，恒温器将被关闭，这表明不需要使用恒温器。	
不满意	SP1: 我可能不需要它，因为我不在家庭环境中。
中立	SP4: 我也希望当我离开时，家庭环境能停止供暖或制冷。
非常满意	SP18: 家庭环境理解了“需要它”这个概念

表2. GPT-4生成的行动计划，在标注员间具有持续高、持续低和变量用户满意度。持续高或低满意度分别意味着该计划要么有帮助，要么表现出明显的故障，且主观性低。变量满意度意味着计划的某些方面受个人偏好影响。

高质量计划为完全未明确指定的指令提供复杂的解决方案。以“帮助我降低电费账单”为例，GPT-4 将家庭环境 h_1 中唯一可用的设备（灯光）与降低电费账单这一欠明确目标关联起来。它还提出了一个能实现此目标的传感器触发器及条件（15分钟无运动）。以“帮助我放松”为例，GPT-4 将“放松”活动与一系列广泛的设备和设置关联起来以实现目标。用户对这些计划的评价是高质量。

低质量计划表现出会降低用户满意度并限制实用性的故障。以家庭环境 h_2 （不具备清洁能力）中的“日落后停止清洁”为例，GPT-4 针对智能音箱制定了一个无意义的计划；以 h_2 中的“有人时不清洁”为例，GPT-4 选择了一个次优的触发器，并计划针对一个家庭中不存在的清洁机器人。用户对这些计划的评价是低质量。

质量参差不齐的计划涉及“创造性”、主观性的选择。这在家庭环境 h_1 中“让客人进来”的计划中得到了例证。一位用户认为GPT-4决定打开入口灯是考虑到家庭环境限制的合理响应，而另一位用户则认为这毫无意义，更希望系统拒绝该请求。在“我不需要时关闭恒温器”的案例中，用户对“不需要”的定义各不相同，导致了满意度的差异。这些计划是被视为足智多谋（因而高质量）还是毫无意义（因而低质量），取决于用户的偏好。

4.4.2 发现2：行动计划表现出特定的故障模式，这些模式会降低用户满意度。我们在大语言模型生成的行动计划中识别出7种常见的故障模式，如下所示：

- (1) **设备 → 无选项存在：**行动计划针对一个不相关的设备，并且似乎不存在更好的选项（除了拒绝请求），例如，当房屋中没有清洁机器人时，响应“停止清洁”而关闭智能音箱。
- (2) **设备 → 选项存在：**行动计划未针对相关设备，即使存在选项，可能是因为请求被拒绝或计划未能包含额外的相关目标，例如，为了“节能”而调整灯光但不调整恒温器。
- (3) **设备 → 额外操作：**行动计划除了针对相关设备外，还针对一个或多个额外的、不相关或相关的设备，例如，同时打开电视和智能音箱。
- (4) **设备 → 幻觉生成：**行动计划针对一个家庭环境中不存在的设备，即大语言模型“幻觉生成”了一个设备并将其添加到行动计划中，例如，当家中没有清洁机器人时打开清洁机器人。
- (5) **设备 → 设置：**行动计划分配了一个可能不正确或依赖于额外上下文的设置，例如，无论一天中的什么时间都将灯光设置为全亮度。
- (6) **传感器 → 次优选择：**对于持续性目标，行动计划为自动化选择了一个次优的传感器，例如，使用入口通道的运动来确定占用状态。
- (7) **传感器 → 触发值：**对于持续性目标，行动计划为自动化选择了一个不合逻辑或未充分指定的触发值，例如，使用“日落”的时间值作为关闭灯光的触发器。

我们在附录C中，针对每种故障模式，分别展示了一个示例性的行动计划及其相应原理。

用户对误报的评判最为严苛。图8描绘了呈现每种故障模式的行动计划的平均用户感知质量。“无选项存在”的平均质量最低，其次是“幻觉生成”。这意味着误报——无论是由于针对了存在但不相关的设备，还是由于试图针对一个不存在的设备——都会受到用户的严厉评判。我们测试了行动计划平均质量与其误报评级 f_p 之间的相关性，使用 $\tau_b = -0.42$ 和 $p = 0.00000004$ ，结果表明存在强烈的负相关性且具有高度显著性。

故障模式受家庭环境能力的影响。图9展示了每种故障模式的频率，按家庭环境分组。考虑到所有指令，当从家庭环境 h_1 移动到 h_3 时，“无选项”和“幻觉生成”故障的频率会下降，因为越来越多的设备可用于实现目标。相反，“选项存在”故障的频率会增加：当有更多设备可用时，用户期望它们




图8. 用户对GPT-4生成的行动计划按故障模式（跨所有家庭）评定的质量。(D) 表示设备定位失败；(S) 表示传感器选择失败。误差线表示95%置信区间。 n 表示每个故障模式的样本量（即分配给行动计划的标签数）。用户对误报的评分比其他故障模式更为严苛：“无选项存在”和“幻觉生成”的平均质量最低。




图9. GPT-4生成的行动计划中故障模式的频率，按家庭组织（ h_1 , h_2 和 h_3 ，每个家庭的设备数量和多样性递增）。左图：所有指令对应的行动计划。右图：针对家庭支持的目标所对应的指令的行动计划（例如，家庭 h_1 中“帮我凉快一下”的计划被省略，因为 h_1 没有恒温器）。(D) 表示设备定位失败；(S) 表示传感器选择失败。

成为目标。仅考虑目标受家庭环境支持的指令时，主要的故障模式是“额外操作”——在目标可实现的情况下，行动计划往往会针对额外的设备。

4.4.3 发现3：即使对于性能最高的模型，可靠地定位相关设备也是一项挑战。我们报告了4种不同模型的准确率、误报、漏报和相关性分数，每种模型使用2种不同的温度 t 参数，见表3。 t 温度参数设置了大语言模型在输出序列中预测较低可能性令牌的概率（即输出的“创造性”）。

GPT-4在所有指标上都优于其他模型。所有模型的相关性分数都远低于1.0。GPT-4 $t = 0.7$ 达到了最高值，为0.63，这表明GPT-4最有可能针对相关设备，而不针对无关设备。0.63 尽管如此，仍有很大的改进空间。随着家庭环境提供更多能力，所有模型都倾向于在最小相关集合之外，额外针对无关设备。我们在图10中通过按家庭和指令的目标类别对行动计划相关性分数进行分组来描绘这一点。在能力较少的家庭中（例如， h_1 ），行动计划往往针对设备的最小相关集合（在几个目标类别中达到1.0），但当目标

配置		相关性				延迟 (秒)			JSON	
模型		t	Acc	FP	FN	Rel	Min	Max	Mean	强制无效
GPT-4		0.00	0.84	0.16	0.00	0.63	0.82	35.83	9.54	0.01
GPT-4		0.70	0.82	0.16	0.02	0.67	0.71	46.69	12.59	0.01
GPT-3.5	text-davinci-003	0.00	0.68	0.32	0.00	0.30	0.47	20.58	6.91	0.43
GPT-3.5	text-davinci-003	0.70	0.68	0.33	0.00	0.26	0.51	23.75	7.46	0.37
Llama 2	7B-chat-hf	0.10	0.65	0.28	0.07	0.09	1.23	26.12	12.79	0.61
Llama 2	7B-chat-hf	0.70	0.62	0.28	0.10	0.11	1.17	16.61	9.94	0.59
Llama 2	13B-chat-hf	0.10	0.62	0.28	0.09	0.18	3.17	49.87	30.05	0.79
Llama 2	13B-chat-hf	0.70	0.62	0.29	0.09	0.21	2.97	58.05	29.93	0.77

表3. 我们实证研究的定量结果总结。我们报告了相关性指标，这些指标反映了大语言模型在行动计划中包含与目标无关的设备的倾向（准确率 Acc 、误报 FP 、漏报 FN 以及相关性分数 Rel ）。我们还报告了响应延迟和JSON有效性。温度 t 设置了大语言模型在输出序列中预测较低概率令牌的概率（即输出的“创造性”）。阴影行表示参与者在我们的用户调查中评分的行动计划集合。




图10. 按家庭环境（ h_1 , h_2 和 h_3 ，其设备数量和多样性递增）和指令的目标类别（决定了相关设备的类型）分组的大语言模型生成行动计划的相关性分数。-1.0 表示该类别所有指令的所有行动计划中的设备均不相关；0.0 表示要么没有目标，要么相关与不相关设备数量相等；1.0 表示所有设备均相关。设备较少的家庭环境（ h_1 ）中的行动计划更可能针对最小相关集合（1.0），但当目标不被支持时，也会针对完全不相关的设备（-1.0）。在能力更强的家庭环境（ h_3 ）中，行动计划同时包含相关和不相关的设备，从而稀释了相关性分数。

不受支持时（在这些类别中达到-1.0），也会通过无意义计划针对完全无关的设备集合。随着家庭获得更多能力，创建无意义计划的风险会降低（表现为 h_2 和 h_3 中-1.0 分数减少）。然而，这种改进受到一个事实的制约，即行动计划除了最小相关集合外，开始包含额外的无关设备。

4.4.4 发现4：成本和延迟构成实际挑战。复杂的家庭环境和目标会带来更高的成本。对于即时目标（无需在模板中包含传感器），输入令牌数分别为469、529和607，对应 h_1 , h_2 和 h_3 ；对于持续性目标，这些值分别增至670、730和808。总体而言，输出标记数根据目标不同，在8到566之间变化。在最小情况下，输出仅为拒绝该目标。在

最大情况下，输出是一个冗长的行动计划。基于这些令牌测量结果并结合API定价，单条智能家居指令的成本约为：GPT-3.5需0.02美元，GPT-4需0.03美元。¹考虑到关于用户与家庭助手互动频率的纵向数据 [8]，GPT-3.5的每日成本将在0.10至0.60美元之间，GPT-4则在0.30至1.00美元之间。

高性能模型和复杂目标会导致更长的响应时间。延迟统计数据见表3。响应延迟差异很大，取决于外部因素（例如，云基础设施的负载）以及所需响应的复杂性。在最佳情况下，所有模型的延迟大约为一秒；这发生在请求被拒绝时。然而，生成更复杂行动计划的延迟极不稳定，对于最强大的模型，延迟常常接近30到45秒。

4.4.5 发现5：JSON响应有效性构成了一项实际挑战。表3 描绘了需要强制提取或完全无效的行动计划所占比例。几乎所有模型的输出偶尔都需要强制提取。这在为聊天应用微调过的Llama 2模型中很常见。响应通常包含一个有效的行动计划，前面带有说明性文字：例如，“当然，这是行动计划...”在GPT模型中，没有无效的JSON；然而，Llama 2偶尔会响应不带JSON，而是对计划的描述，或者JSON被分割成多个部分。这是一个工程挑战：微调增加了模型输出具有所需结构的置信度 [57]。

4.4.6 总结。我们从实证研究中得出以下结论：

- 大语言模型能够针对未充分明确的用户指令，生成具有创造性和复杂性的行动计划。（研究问题一）
- 大语言模型容易在目标设备的相关性、其分配设置，以及对于持续性目标而言的传感器触发器和触发值方面出现故障。误报（即在没有可用设备时，针对不相关或不存在的设备）与用户满意度呈负相关。（研究问题二）
- 性能从模型行动计划的准确率、误报、漏报和相关性评分等方面进行比较。即使是性能最高的模型也难以可靠地定位相关设备：它们要么（1）在家庭环境中没有设备支持目标时，定位到不相关的设备；要么（2）在家庭环境中更多可用设备时，除了最小相关集合外，还定位到额外的不相关设备。（研究问题二）
- 生成行动计划的成本和延迟，以及输出有效性的不稳定性，是开放的工程挑战。（研究问题二）

5 设计Sasha

图3 中展示并在我们上述实证研究中使用的基于LLM的智能家居原型，在解决研究问题3方面取得了显著进展。然而，正如我们的实证研究所表明的，这种简单方法存在必须解决的缺陷。在本节中，我们提出Sasha，一个更智能的智能家居助手，旨在提升大语言模型在智能环境中的性能。我们的动机源于需要通过以下方式改善响应质量：(1) 减少误报，(2) 提高行动计划的相关性，以及(3) 为用户反馈提供输入以减少主观性。我们的实证研究揭示了这些因素都是影响用户满意度的关键。

Sasha 将响应用户指令的过程解构为迭代推理组件(图 11)。它并非在单次推理中直接生成行动计划，而是通过多个步骤来推理响应。我们假设使用一个经过指令微调的模型，该模型已通过微调以遵循提示词中提供的书面说明 [57]，但并未针对智能家居任务进行微调。此外，我们假设该模型在使用思维链提示 [58]时表现出高性能。这两点对于众多模型都成立 [11, 13, 38, 51]。Sasha 的两个输入与第3节相同：一条用户指令和一个描述可用传感器与设备的模板。下文将描述 Sasha 迭代推理的每个组件。

¹OpenAI API定价 2023年11月：GPT-3.5为每1K令牌0.02美元，GPT为每1K输入令牌0.03美元 / 每1K输出标记0.06美元




图 11. Sasha 利用迭代推理，生成持续高质量的动作计划，以利用特定智能家居中任何可用的相关设备。

5.1 澄清：该目标是否可利用现有设备实现？

误报与用户满意度呈负相关，正如我们的实证研究所显示。我们的首要目标是开发一个能直接降低误报率的组件。因此，澄清步骤会提示模型，结合家庭模板中可用的设备来考虑用户指令的目标。如果家庭环境中存在与指令语义相关的设备，Sasha 将判定目标可实现，并无需用户介入即可超越澄清步骤。如果 Sasha 未能识别出足够的相关设备集合，它会通知用户无法继续。我们允许用户提供澄清信息进行后续跟进，此时提示词会附带添加上下文后重复执行。该组件的输出是一个状态码：如果存在相关设备则为成功，否则为故障。

我们用一个例子来说明。当用户告诉Sasha“我累了”时，我们会向模型提供该指令、家庭环境中的设备以及考虑是否有任何设备与该指令相关的说明。如果该指令是在我们实证研究中的家庭 h_3 （配备咖啡壶）发出的，Sasha会将“累了”与咖啡壶联系起来，并确定家中确实存在相关设备。反之，如果同样的指令在只有灯光设备（ h_1 ）的家庭环境中发给同一系统，Sasha则不太可能找到看似相关的设备。输出结果是“故障”，并附带给用户口头回应：“抱歉，我在家里没有找到任何看起来与您的指令相关的东西。您能提供更多信息吗？”为了举例，我们假设用户累了，而灯光能帮助他们起床。用户可以（再次用自己的话）提供澄清信息：“我需要帮助来起床”。我们利用新增的上下文重复提示，要求系统再次考虑是否有任何设备相关。在只有灯光的 h_1 中，模型很可能发现“累了”、“起床”与灯光的颜色和亮度之间的语义关联，因此现在会返回“成功”。

同样重要的是，需要考虑家庭环境根本无法支持该目标的情况，我们的实证研究揭示，这可能导致产生无意义的输出。假设用户在“我累了”之后进一步澄清：“我真的很想来点咖啡”。此时已有足够信息推断目标，但在 h_1 和 h_2 的情况下，仍然没有相关设备来支持它。此时，Sasha将返回“故障”作为相关性检查结果，并避免生成无意义的行动计划。若没有Sasha的相关性检查，模型会打开 h_1 的灯，并为其推理辩护：“打开入口顶灯，以提供明亮、提神的氛围，帮助你为享用咖啡做好准备。”

与任务特定组件相比，利用大语言模型执行推理的澄清步骤具有若干优势，因为任务特定方法存在两个关键局限：(1) 其设计编码了一套关于哪些设备与哪些目标相关的受限假设，这阻碍了创造性行动

计划的发明，以及 (2) 存在通用设备类型（例如，智能插座），几乎无法预测其与用户目标的关系。使用大语言模型在这两种情况下都提供了优势：(1) 它可以利用其训练语料库中编码的、通常不可预测的情境知识来发明创造性的行动计划，以及 (2) 它能对设备进行语义推理。这意味着，只需在家庭模板中命名一个智能插座，例如 `humidifier_plug` 或 `guitar_amp_plug`，就能使模型利用同一设备类型执行比任务特定系统所假设的更广泛的动作集。作为一项实施说明，我们可以选择在完整设备模板（即语义完整且正确的JSON片段）上执行此推理，或者，在一个缩短的可用设备列表（即仅列出家庭环境提供的设备名称列表）上执行。后一种选择有利于性能，我们在评估中强调了这一点。

5.2 过滤：哪些是相关设备？

相关性：目标设备在动作计划中的相关性在不同家庭环境中往往不稳定，正如我们的实证研究所示。我们的下一个目标是开发一个组件，能在不同环境中提供一致的相关性 (*Rel*)。为此，我们提示模型从JSON家庭模板中选择最小的相关设备集合。此步骤输出家庭模板中设备的一个JSON子集。

对于“我累了，需要帮助醒来”这一指令，我们使用设备过滤提示来提示模型。作为响应，模型在 h_3 中将返回厨房中咖啡机的JSON。在 h_1 或 h_2 中，它将返回各自房间中灯光的JSON。与澄清步骤类似，我们可以过滤完整的设备集，或者过滤一个设备列表（排除其设置）。使用大语言模型而非任务特定系统来执行此步骤，其理由与上述类似。基于指令与家庭中命名设备之间的语义关系进行过滤，比依赖严格定义的本体的系统具有更大的灵活性。

5.3 规划：如何使用这些设备和传感器来实现目标？

在模型选择了相关设备后，我们提示它生成一个行动计划。规划提示包含用户指令、过滤后的设备（对于持续性目标，还包括传感器）。对于即时目标，我们引导模型生成一个行动计划，该计划本质上是对家庭模板中过滤出的设备子集进行修改，并为设备分配设置。对于持续性目标，我们引导模型以自动化例程的形式生成行动计划，其定义为（触发器，动作）对。触发器是一个传感器或一组传感器及其对应的值，用于触发该例程；而动作则是家庭模板中过滤出的设备子集，并已分配了设置。此步骤输出一个JSON格式的行动计划。

5.4 执行：将计划映射到API调用

我们通过将JSON中设备状态的更改映射到相应的智能家居API调用来执行行动计划。这是一个实现层面的问题，无需模型的协助。

5.5 反馈：该行动计划是否实现了用户目标？

如我们的实证研究所示，行动计划的用户感知质量有时是主观的。我们的最后一个目标是提供输入，让用户偶尔能对生成的行动计划的某些方面进行优化。执行后，模型生成的行动计划会被描述给用户，以供其评判。如果用户对行动计划中的选择感到满意，则无需进一步输入。然而，如果计划的某些方面需要调整，用户则有机会提供反馈。他们可以用无约束语言提供此反馈（与初始指令类似）。例如，如果用户对Sasha说 h_3 “我很无聊”，而系统通过打开电视和智能音箱来响应，用户可能会提供一些反馈：“我不需要电视和音箱都开着”。一旦用户提供了此反馈，我们会提示模型修改计划，或者如果

配置		相关性					延迟 (秒)			JSON	
模型		List	ΔAcc	ΔFP	ΔFN	ΔRel	Min	Max	Mean	强制无效	
澄清 + 过滤											
GPT-4	gpt-4		+0.10	-0.12	+0.03		0.72	44.54	11.90	0.00	0.00
GPT-4	GPT-4	✓	+0.07	-0.08	+0.02		0.71	14.43	4.84	0.00	0.00
GPT-3.5	text-davinci-003		+0.01	-0.01	0.0		0.40	19.45	6.26	0.00	0.00
GPT-3.5	text-davinci-003	✓	+0.02	-0.02	0.0		0.40	6.06	2.80	0.01	0.00
澄清											
GPT-4	gpt-4		+0.08	-0.15	+0.07		0.59	2.26	1.32	0.00	0.00
GPT-4	gpt-4	✓	+0.11	-0.15	+0.04		0.61	2.45	1.26	0.00	0.00
GPT-3.5	text-davinci-003		+0.06	-0.12	+0.06		0.43	2.77	1.04	0.00	0.00
GPT-3.5	text-davinci-003	✓	+0.13	-0.16	+0.03		0.36	1.52	0.76	0.00	0.00
过滤 + 规划											
GPT-4	gpt-4					-0.03	2.97	50.01	18.19	0.00	0.00
GPT-3.5	text-davinci-003					-0.16	1.02	15.05	7.42	0.00	0.00
过滤											
GPT-4	gpt-4					+0.01	2.23	36.66	11.87	0.00	0.00
GPT-4	GPT-4	✓				+0.00	2.14	38.39	12.71	0.01	0.00
GPT-3.5	text-davinci-003					+0.02	1.59	19.74	7.61	0.01	0.00
GPT-3.5	text-davinci-003	✓				+0.00	1.72	15.84	6.49	0.00	0.00
完整推理链 (澄清、过滤、规划)											
GPT-4	gpt-4	✓, -	+0.11	-0.15	+0.04	+0.01	0.61	66.98	14.84	0.00	0.00
GPT-3.5	text-davinci-003	✓, -	+0.13	-0.16	+0.03	+0.02	0.40	33.61	11.73	0.01	0.00

表4. Sasha定量结果总结。结果以我们实证研究中零样本方法与Sasha推理链迭代组件所达到的测量值之间的差异呈现。在我们的消融研究中，我们测试了在完整家庭模板（包含所有设备及其设置）上进行推理与在简化的设备列表（在“列表”列中以 ✓表示）上进行推理的效果。

Sasha发现无法改进它，则道歉并采取任何行动。此步骤会向用户输出口头回应，描述随着计划逐步修改的过程，以及最终的行动计划JSON。

6 评估

我们使用第3节中的家庭与指令数据集，通过消融研究，评估Sasha在两种不同大语言模型下的性能。为确保可复现性，我们将温度 $t = 0.0$ 。为了回答研究问题3，我们的目标是理解推理链的不同组件如何影响系统性能，衡量指标包括准确率、误报、漏报和相关性（定义见第4.3.1节），所有这些指标均可通过简单检查Sasha返回的响应来计算。

结果1：将目标澄清与设备过滤分开进行，降低了误报率。我们比较了将澄清 + 与过滤合并为单一步骤，与将澄清作为独立步骤时的性能。在第一种情况下，我们使用单一提示要求大语言模型选择任何相关设备，或在没有设备相关时拒绝（澄清 + 与过滤）。在后一种情况下，我们提示模型考虑是否存在任何相关设备（即Sasha的澄清组件）。在两种情况下，我们都测量了在完整家庭模板上进行推理与在简化的可用设备列表上进行推理的影响。我们在表4中报告了结果。




图12. Sasha用户研究的测试家庭环境。我们邀请 $N = 7$ 参与者在该测试家庭环境中模拟日常生活活动时，向 Sasha发出无约束指令。这项用户研究使我们能够发现基于LLM的智能家居在面对用户生成场景时的能力和局限性。

对于两种模型，合并的澄清 + 与过滤都通过减少误报提高了准确率。对于GPT-3.5，在设备列表上进行推理提供了轻微优势；GPT-4则不然。对于GPT-4，漏报率略有增加。独立的澄清步骤在两种情况下都比合并的澄清 + 与过滤带来了更大的性能提升。当澄清在设备列表上进行时，这种优势进一步增加。误报的减少被漏报的轻微增加略微抵消——本质上，澄清步骤使输出更加保守。

结果2：将设备过滤与动作规划分开进行能提升相关性。我们评估了将过滤 + 与规划相结合（即模型基于完整设备集创建行动计划）相对于分开进行过滤和规划步骤（即模型基于过滤后的设备集创建行动计划）的效果（表4）。对于两种模型，将过滤 + 与规划相结合会降低其相对于零样本方法的相关性。当将过滤步骤分开并对完整设备集进行推理时，两种模型的相关性均略有提升；当基于设备列表进行过滤时，其性能与零样本方法相同。

总结。我们对Sasha的定量评估中得出以下结论：

- 澄清功能减少了多个模型的误报，可能对用户满意度有益。[\(研究问题3\)](#)
- 过滤功能对多个模型的目标设备相关性提供了适度的改进。[\(研究问题3\)](#)

7 用户研究

为了回答[研究问题四](#)，我们在一项实践研究中，通过不可预测的用户生成场景来评估Sasha的实现。我们在一个大型实验室中构建了一个测试家庭环境（图12），其中包含智能灯、智能窗帘、咖啡壶、电水壶、风扇、一个可选择5种音乐流派智能音箱、一台智能电视和一个“清洁机器人”²。我们扩展了Sasha的Python实现，通过多个智能设备API来控制这些设备。然后，我们邀请了 $N = 7$ 参与者，在几个开放式的日常生活场景中与Sasha互动。由于我们的会话时间有限，我们只研究了Sasha对即时目标的响应。

7.1 用户研究流程与分析

7.1.1 参与者与环节结构。我们的用户研究在机构审查委员会监督下进行。我们通过电子邮件、滚雪球和口碑方式招募了 $N = 7$ 名参与者（表5）。环节全程录音，持续30-45分钟。在每个环节中，单名参与者（1）接受5分钟的Sasha能力概览与演示；（2）执行3个日常生活预设场景，同时向系统发出无约束、用户生成的指令；（3）执行与参与者个人习惯相关的自定义场景；以及（4）参与结束访谈。我们定义了3个预设场景（“回家”、“晨间例程”和“举办派对”），每个

²我们的清洁机器人不具备清洁能力，但当系统将其开启时，会由一盏指示灯照亮。

ID	性别	Age	教育程度	智能家居熟悉度	英语水平
RWP1	F	25-34岁	学士学位	中等程度	母语/双语
RWP2	F	55-64岁	学士学位	轻微	母语/双语
RWP3	F	18-24岁	高中或同等学历	Very	母语/双语
RWP4	M	18-24岁	学士学位	中等程度	母语/双语
RWP5	M	18-24岁	学士学位	轻微	母语/双语
RWP6	M	18-24岁	研究生	轻微	母语/双语
RWP7	M	25-34岁	学士学位	Very	中级

表5. 我们Sasha用户研究中真实世界参与者（RWP）的人口统计学特征。RWP在我们的测试家庭环境中，于日常生活场景期间发出无约束指令，并对系统性能提供了看法。

场景包含数个高层目标（“回家”：吃晚餐、放松、就寝时间；“晨间例程”：起床、离家；“举办派对”：准备家庭环境、结束派对）。完成3个预设场景后，参与者构思了与其个人习惯相关的自定义场景，并相应发出指令。我们指导参与者持续向Sasha发出指令和反馈，直到他们认为房间内的设备已充分支持该场景的每个目标。我们指导参与者在指令中使用无约束语言，并请他们口头分享对系统动作的看法。虽然Sasha能够解读语音指令，但在此受控研究中，由研究人员手动输入参与者的指令。由于响应延迟不在本研究范围内，我们指导参与者分享对系统动作的看法，而非系统延迟。环节脚本见附录D.1。

7.1.2 定性分析。我们从会话中收集了大约5小时30分钟的音频，并对其进行分析，以识别用户与Sasha交互的常见主题。我们引出了Sasha能够支持无约束用户目标的实例，以及系统局限性明显的案例。我们根据交互发生的高层场景以及交互目标来标记交互。

7.1.3 定量分析。在每个会话期间，我们记录了用户与系统交互时Sasha推理链的状态。我们测量了Sasha拒绝指令的频率、参与者提供反馈的程度，以及完成每个场景众多目标所使用的指令数量。

7.2 观察结果

我们在下文呈现用户交互中的常见主题。标题表示交互发生的高层场景，其后是具体的交互目标。

观察1：宽松的指令结构可以支持复杂的多部分目标。参与者利用Sasha宽松的指令结构，发出了包含多个步骤的指令：

晨间例程 → 起床

RWP4：我洗完澡后感觉太热了，还想做些清洁。Sasha：我已打开风扇帮你降温，并启动了清洁机器人协助打扫。

用户生成 → 杂项

RWP7: 我想在餐厅桌边喝咖啡，同时看看窗外。**Sasha:** 我已打开厨房的咖啡机为你准备咖啡。我还为你打开了餐厅窗帘，方便你看窗外，并将顶灯调整到了舒适的亮度。

用户生成 → 杂项

RWP5: 我看完比赛了，打算喝点咖啡然后吃晚饭。**Sasha:** 由于您已看完比赛，客厅的电视已关闭。厨房的咖啡机已为您打开，准备制作咖啡。厨房和餐厅的顶灯已打开，亮度设为70，颜色为白色，以便您用餐。**RWP5:** 嗯，这样安排很合理。

观察2: 用户利用反馈迭代优化行动计划。参与者通常以一个欠指定命令开始交互，然后通过迭代反馈来优化行动计划。他们的反馈往往同样欠指定，但Sasha仍能将其纳入考量：

举办派对 → 结束派对

RWP4: 客人们要离开了，我们让派对慢慢收尾吧。**Sasha:** 我已调暗客厅、厨房和餐厅的灯光，以营造更轻松的氛围。入口灯稍亮一些，以便引导人们离开。客厅的音乐播放器现在正在播放氛围音乐，以帮助派对平缓结束。电视已关闭。**RWP4:** **(反馈)** 音乐切换得有点突兀。**Sasha:** 根据您的反馈，已将音乐切换为不那么突兀的流派（民谣）。**RWP4:** 好的，这样好多了。我喜欢这个...我可能想不到这一点。

在某些情况下，参与者以一个完全未指定的指令开始互动，然后通过反馈增加更多明确性：

回家 → 就寝时间

RWP1: 我要睡觉了。**Sasha:** 客厅和入口的所有灯光及电视已为您就寝而关闭。**RWP1:** **(反馈)** 你还得把厨房的灯关掉。**Sasha:** 我已根据您的反馈更新行动计划，同时关闭厨房的灯光。

回家 → 放松休息

RWP3: 我现在要放松一下。**Sasha:** 我已关闭客厅的阅读灯和电视，以营造一个放松的环境。我还打开了音乐播放器，并将其设置为播放氛围音乐。**RWP3:** **(反馈)** 我本来想打开电视。**Sasha:** 我已根据您的反馈更新了行动计划，将打开电视。

在另一个案例中，Sasha对反馈的响应就不那么优雅了。当一位参与者试图通过反馈来选择他们偏好的阅读灯颜色时，他们与Sasha陷入了一场来回拉锯：

回家 → 放松休息

RWP2：你能把阅读灯调成冷色调吗？Sasha：客厅的阅读灯已调整为冷色调（深蓝色）。
RWP2：[笑]（反馈）这太冷了。Sasha：根据用户反馈原色调过冷，已将阅读灯颜色调整为更暖的色调（深红色）。RWP2：啊，哇。（反馈）这有点太红了。Sasha：我已降低红色强度，并在颜色中添加了一些绿色和蓝色，以减少红色感。RWP2：好的，呃。嗯。有点粉了。

观察3：需要对个人偏好和上下文有更高的敏感度。一些互动突显出Sasha有必要随着时间学习个人偏好：

晨间例程 → 离家

RWP2：Sasha，我要出门了，请确保所有东西都关掉了。Sasha：您要出门，所有设备均已关闭。（清洁机器人仍保持开启）RWP2：我不在的时候会不会有什么东西出故障？我希望把它也关掉。

另一位参与者在同一场景中表达了相反的偏好：

晨间例程 → 离家

RWP5：我要去上班了。Sasha：所有灯光、电视和音乐播放器都已关闭。厨房的清洁机器人已启动，将在您外出时进行打扫。RWP5：是的，在理想情况下，这正是我所期望的。在我出门后处理日常家务。

一位参与 者提出了一个有趣的观点，关于Sasha对上下文缺乏敏感性所带来的风险 t:

举办派对 →结束派对

RWP1：我的朋友在厨房吐了。Sasha：我已将厨房顶灯调至最大亮度以改善视野，并启动了清洁机器人来清理污物。RWP1：我的第一反应是，[这主意不错] ……它确实建立了这种联系… …但是，其局限性在于，这并非该设备能做的事……该设备无法清理呕吐物。所以，在实际操作中，这只会搞得一团糟。我觉得它需要了解设备的局限是什么。

观察4：计划可以引入用户自己可能想不到的创造性动作。在多个案例中，参与者依赖Sasha为他们做决定，或发现系统能够制定出参与者原本不会考虑的计划：

晨间例程 → 起床

RWP6: 我不确定要咖啡还是茶。帮我选一个吧。**Sasha:** 我为您选择了咖啡。咖啡机现已启动。

用户生成 → 改善情绪

RWP6: 帮我让我的女朋友开心。**Sasha:** 我已将客厅的音乐播放器设置为播放环境音乐播放列表，启动了厨房的咖啡机，并打开了餐厅的窗帘，以营造一个愉快的氛围。**RWP6:** 我觉得这真的会让她很开心。她喜欢咖啡。

用户生成 → 接待访客

RWP4: 我的父母要来拜访。
Sasha: 我已将客厅、入口、厨房和餐厅的灯光设置为温暖的亮度。电视已关闭以鼓励交谈。客厅的音乐播放器设置为播放爵士乐播放列表，以营造轻松氛围。厨房的咖啡机已开启，供您的父母享用咖啡。清洁机器人已启动，以确保房屋清洁。窗帘已打开，以便引入自然光。**RWP4:** 这一点最让我惊讶。音乐选择、咖啡机和灯光。感觉它在一个指令里就考虑到了所有事情……但无需我逐一说明所有步骤。

观察5: 复杂目标仅需少量无约束交互即可完成。我们在附录D.1中总结了所有会话的定量结果。参与者报告目标平均通过约3条指令完成；然而，此数字因目标复杂性而异。在所有会话的198条指令中，参与者调用反馈以完善行动计划的比率为0.27。反馈用于纳入用户偏好，并纠正因系统缺乏状态知识而导致的疏忽（例如，未能针对先前交互已设置状态的设备）。我们将任何被拒绝的指令视为假阴性。这种情况很少见，比率为0.06——通常发生在指令完全未指定时，例如“再见，Sasha”或“外面在下雨吗？”

总结。我们从用户研究中得出以下观察：

- 反馈使用户能够完善行动计划中那些本质上具有主观性的方面，但仅在少数情况下需要。(研究问题3)
- 宽松的指令结构使系统能够完成我们初步评估中忽略的、出人意料复杂的多部分目标。(研究问题四)
- 系统在某些情况下的有效性受到对用户偏好和上下文不敏感的限制。(研究问题四)
- 系统的创造性选择可以帮助用户以更少的步骤和更高的灵活性实现其目标，而无需硬编码的例程。(研究问题四)

8 讨论

我们的研究结果为未来的探索提出了有趣的问题。我们将在下文中对此进行讨论。

为未来智能家居中的自然语言界面定义范围。自然语言界面的一个设计挑战是定义其范围 [35]，并向用户明确其限制，以便用户能对其能力形成心智模型 [34]。尽管我们引入的系统显著扩展了这一范围，但同样的设计挑战依然存在。事实上，当前实用的系统往往倾向于通过拒绝

不遵循命令结构的指令来避免漏报，而基于大语言模型的系统则引入了误报的新风险，即对超出范围的指令形成无意义计划。在涉及安防的场景中，例如在配备智能门锁的家庭中，误报会带来风险。我们在评估中观察到，减少误报的策略往往会增加漏报。倾向于前者的系统具有更强的创造性能力，但风险也随之增加；而倾向于后者的系统则更接近当前实践中的状态。当指令目标明确时，误报风险较低；但当用户通过不同指令探索系统能力时，风险会增加。这在用户初次获得助手时，或儿童与智能助手互动时很常见 [23]。问题依然存在：我们应如何界定和设计一个基于大语言模型的系统，使其在风险最小化的前提下提供足够的创造性能力？

对用户偏好和上下文的长期适应。Sasha 整合用户反馈以改进行动计划，但并未提供对用户偏好或上下文的长期适应。这是智能助手一个理想的功能 [47]，而我们的用户研究也重申了对此功能的需求。其最简单的形式是，系统通过学习了解到用户偏好，例如，当用户发出“帮我放松一下”这样的指令时，他们更喜欢某一类音乐而非另一类。然而，在最微妙的情况下，一个自适应系统会更好理解单个设备的能力和上下文——例如，清洁机器人可以清洁，但不同的机器人有不同的能力，而这种上下文必然会影​​响系统如何根据用户目标对它们进行推理。此外，满足用户目标的正确动作可能因情境上下文而异：中午12点“为我的朋友准备好房子”需要一套动作，而晚上9点同样的指令则需要另一套不同的动作。我们的相关性分数提供了一个粗略的概念，说明 Sasha 的设计在定位相关设备方面做得如何，但缺乏解决这个特定问题所需的细致程度。用户提供的反馈包含了有助于这种长期适应的宝贵信息。总的来说，确定如何使大语言模型适应个体智能家居偏好和约束是一个开放的挑战。

对当前状态的敏感性。我们在推理用户目标与设备和可分配设置的关系时，并未考虑对它们当前状态的敏感性。然而，许多目标本质上依赖于这种状态。像“让这里不那么冷”这样的目标，表达了从当前状态转变到新状态的愿望；同样，像“帮我降低电费账单”这样的持续性目标，则意味着需要从当前状态（或一系列状态）出发，进行更复杂的行为改变。我们在评估中表明，该系统能够生成出人意料地有用且复杂的行动计划，但我们怀疑，在纵向设置中，这种对状态的敏感性将变得必要。例如，如果用户要求系统“把灯光调亮一点”，而底层模型的温度参数设置为0.0（即行动计划的输出标记将始终遵循最可能的序列），那么系统将总是为灯光分配相同的设置。识别相关状态的这一挑战超出了我们工作的范围。

9 结论

我们介绍了利用大语言模型（LLMs）在智能家居中灵活使用设备和传感器来实现用户目标的方法。我们将问题定义为创建高质量、可执行的JSON格式“行动计划”，这些计划要么为可用设备分配设置，要么为自动化例程提出触发器和动作。通过一个新颖的原型系统和实证研究，我们对4种不同大语言模型针对3个家庭环境中的40条未充分明确的用户指令所创建的智能家居行动计划进行了定性与定量分析。基于对 $N = 20$ 名调查参与者的600份响应的分析，我们识别出7种降低用户满意度的故障模式，以及一组相应的指标。行动计划的质量受到大语言模型以下倾向的阻碍：针对不相关设备、分配不当设置、针对额外设备，以及为自动化例程选择次优的传感器触发器和值。为了解决针对设备时的误报问题，以及需要通过纳入用户反馈来减少主观性的需求，我们提出了Sasha，一个更智能的智能家居助手。Sasha的创新之处在于一个迭代推理过程，该过程将大语言模型关于行动计划的推理分解为4个组成部分：澄清目标、过滤设备、规划动作，以及迭代地

利用用户反馈改进计划。我们通过消融研究论证了该过程每个组成部分的必要性，表明Sasha的行动计划具有比朴素方法显著更低的误报率。最后，我们对Sasha进行了用户研究，共有 $N = 7$ 名参与者在无约束场景中系统与系统交互，贡献了一系列关于这种新型智能家居如何支持用户目标的观察结果。

致谢

我们感谢匿名审稿人对本文提出的建设性反馈。此项工作部分由美国国家科学基金会资助，资助号为CNS-1909221。文中表达的任何观点、发现、结论或建议均为作者个人观点，不一定代表美国国家科学基金会的立场。

参考文献

- [1] 2022. Google Nest API 文档。https://developers.google.com/nest/device-access[2] 2022. Insteon REST API 文档。https://www.insteon.com/developer[3] 2022. Philips Hue API 文档。https://developers.meethue.com/[4] 2023. IFTTT。检索于2023年5月1日，自 https://ifttt.com/[5] 2023. TP-Link Kasa 智能插座。https://www.kasasmart.com/us/products/smart-plugs[6] Giovanni Acampora, Diane J Cook, Parisa Rashidi 和 Athanasios V Vasilakos. 2013. 医疗保健领域的环境智能调查。Proc. IEEE 101, 12 (2013), 2470–2494. [7] Mussab Alaa, Aws Alaa Zaidan, Bilal Bahaa Zaidan, Mohammed Talal 和 Miss Laiha Mat Kiah. 2017. 基于物联网的智能家居应用综述。Journal of Network and Computer Applications 97 (2017), 48–65. [8] Frank Bentley, Chris Luvogt, Max Silverman, Rushani Wirasinghe, Brooke White 和 Danielle Lottridge. 2018. 理解智能音箱助手的长期使用。Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies 2, 3 (2018), 1–24. [9] Robert Botsch. 2011. 第12章：显著性与关联性度量。Scopes and Methods of Political Science (2011). [10] Artur Branny, Maja Steen Møller, Silviya Korpilo, Timon McPhearson, Natalie Gulsrud, Anton Stahl Olafsson, Christopher M Raymond 和 Erik Andersson. 2022. 通过社会-生态-技术系统方法实现更智能、更绿色的城市。Current Opinion in Environmental Sustainability 55 (2022), 101168. [11] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell 等。2020. 语言模型是少样本学习者。Advances in neural information processing systems 33 (2020), 1877–1901. [12] 诺姆·乔姆斯基。2002. 句法结构。De Gruyter Mouton, 柏林, 纽约。https://doi.org/doi:10.1515/9783110218329[13] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, Parker Schuh, Kensen Shi, Sasha Tsvyashchenko, Joshua Maynez, Abhishek Rao, Parker Barnes, Yi Tay, Noam Shazeer, Vinodkumar Prabhakaran, Emily Reif, Nan Du, Ben Hutchinson, Reiner Pope, James Bradbury, Jacob Austin, Michael Isard, Guy Gur-Ari, Pengcheng Yin, Toju Duke, Anselm Levskaya, Sanjay Ghemawat, Sunipa Dev, Henryk Michalewski, Xavier Garcia, Vedant Misra, Kevin Robinson, Liam Fedus, Denny Zhou, Daphne Ippolito, David Luan, Hyeontaek Lim, Barret Zoph, Alexander Spiridonov, Ryan Sepassi, David Dohan, Shivani Agrawal, Mark Omernick, Andrew M. Dai, Thanumalayan Sankaranarayanan Pillai, Marie Pellat, Aitor Lewkowycz, Erica Moreira, Rewon Child, Oleksandr Polozov, Katherine Lee, Zongwei Zhou, Xuezhi Wang, Brennan Saeta, Mark Diaz, Orhan Firat, Michele Catasta, Jason Wei, Kathy Meier-Hellstern, Douglas Eck, Jeff Dean, Slav Petrov 和 Noah Fiedel. 2022. 2024 02311 []。PaLM: 使用Pathways扩展语言建模。arXiv: 。cs.CL [14] Meghan Clark, Mark W Newman 和 Prabal Dutta. 2017. 设备、数据和智能体，哦天哪：智能家居抽象如何塑造终端用户心智模型。Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies 1, 3 (2017), 1–26. [15] Diane J Cook. 2012. 学习适用于智能空间的通用设置活动模型。IEEE intelligent systems 27, 1 (2012), 32. [16] William S Cooper. 1971. 信息检索相关性的定义。Information storage and retrieval 7, 1 (1971), 19–37. [17] Benjamin R Cowan, Nadia Pantidi, David Coyle, Kellie Morrissey, Peter Clarke, Sara Al-Shehri, David Earley 和 Natasha Bandeira. 2017. “我能帮您做什么？”不常用用户对智能个人助手的体验。In Proceedings of the 19th International Conference on Human-Computer Interaction with Mobile Devices and Services. 1–12. [18] Jacob Devlin, Ming-Wei Chang, Kenton Lee 和 Kristina Toutanova. 2018. Bert: 用于语言理解的深度双向Transformer预训练。arXiv preprint arXiv:1810.04805 (2018). [19] Anind K Dey. 2001. 理解与使用上下文。Personal and ubiquitous computing 5 (2001), 4–7. [20] Rob Dunne, Tim Morris 和 Simon Harper. 2021. 环境智能调查。ACM计算概览 (CSUR) 54, 4 (2021), 1–27.

- [21] Ethan Fast, William McGrath, Pranav Rajpurkar 和 Michael S Bernstein. 2016. Augur: 从小说中挖掘人类行为以驱动交互系统。In *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems*. 237–247. [22] Leo Gao, Stella Biderman, Sid Black, Laurence Golding, Travis Hoppe, Charles Foster, Jason Phang, Horace He, Anish Thite, Noa Nabeshima 等. 2020. The Pile数据集: 一个用于语言建模的800GB多样化文本数据集。arXiv preprint arXiv:2101.00027 (2020). [23] Radhika Garg 和 Subhasree Sengupta. 2020. 他就像我一样: 一项关于父母与儿童长期使用智能音箱的研究。Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies 4, 1 (2020), 1–24. [24] Ilche Georgievski 和 Marco Aiello. 2016. 普适计算的自动化规划。ACM计算概览 (CSUR) 49, 4 (2016), 1–46. [25] Kyeong-Ah Jeong, Gavriel Salvendy 和 Robert W Proctor. 2010. 美国人和韩国人的智能家居设计与操作偏好。人机工程学 53, 5 (2010), 636–660. [26] Dongsu Kim, Yeobeom Yoon, Jongman Lee, Pedro J Mago, Kwangho Lee 和 Heejin Cho. 2022. 智能建筑的设计与实现: 当前研究趋势综述。能源 15, 12 (2022), 4278. [27] Sunyoung Kim 和 Abhishek Choudhury. 2021. 探索老年人对基于智能音箱的语音助手的感知与使用: 一项纵向研究。计算机与人类行为 124 (2021), 106914. [28] Evan King, Haoxiang Yu, Sangsu Lee 和 Christine Julien. 2023. “准备开派对吧”: 借助大语言模型探索更智能的智能空间。arXiv preprint arXiv:2303.14143 (2023). [29] Taku Kudo 和 John Richardson. 2018. SentencePiece: 一种用于神经文本处理的简单且语言无关的子词分词器与去分词器。arXiv preprint arXiv:1808.06226 (2018). [30] Jacky Liang, Wenlong Huang, Fei Xia, Peng Xu, Karol Hausman, Brian Ichter, Pete Florence 和 Andy Zeng. 2022. 代码即策略: 用于具身控制的语言模型程序。arXiv preprint arXiv:2209.07753 (2022). [31] Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi 和 Graham Neubig. 2023. 预训练、提示与预测: 自然语言处理中提示方法的系统综述。计算概览 55, 9 (2023), 1–35. [32] Ewa Luger 和 Abigail Sellen. 2016. “就像有个很糟糕的私人助理”: 对话式智能体的用户期望与体验之间的鸿沟。In *Proceedings of the 2016 CHI conference on human factors in computing systems*. 5286–5297. [33] R. Lutolf. 1992. 智能家居概念及将电能表集成到家庭系统中的方法。In *Seventh International Conference on Metering Apparatus and Tariffs for Electricity Supply* 1992. 277–278. [34] Isabela Motta 和 Manuela Quaresma. 2022. 探索对话设计专家的意见: 一项关于用户对语音助手心智模型的研究。In *International Conference on Human-Computer Interaction*. Springer, 494–514. [35] Jesse Mu 和 Advait Sarkar. 2019. 我们需要自然语言吗? 探索复杂领域的受限语言界面。In *Extended Abstracts of the 2019 CHI Conference on Human Factors in Computing Systems*. 1–6. [36] Mahda Noura, Sebastian Heil 和 Martin Gaedke. 2020. 智能家居环境中的自然语言目标理解。In *Proceedings of the 10th International Conference on the Internet of Things*. 1–8. [37] Mahda Noura, Sebastian Heil 和 Martin Gaedke. 2020. VISH: 你的智能家居对话系统也需要训练数据吗? 。In *Web Engineering: 20th International Conference, ICWE 2020, Helsinki, Finland, June 9–12, 2020, Proceedings* 20. Springer, 171–187. [38] 2023 4 2303 08774 [] OpenAI. . GPT- 技术报告。arXiv: . cs.CL OpenAI. . tiktoken: 一个用于OpenAI模型的快速BPE分词器。https://github.com/openai/tiktoken. [40] Javier Palanca, Elena del Val, Ana Garcia-Fornes, Holger Billhardt, Juan Manuel Corchado 和 Vicente Julián. 2018. 设计一个面向目标的智能家居环境。信息系统前沿 20 (2018), 125–142. [41] Joon Sung Park, Joseph C O’ Brien, Carrie J Cai, Meredith Ringel Morris, Percy Liang 和 Michael S Bernstein. 2023. 生成式智能体: 人类行为的交互式模拟。arXiv preprint arXiv:2304.03442 (2023). [42] Alisha Pradhan, Amanda Lazar 和 Leah Findlater. 2020. 技术使用率低的老年人对智能语音助手的使用。ACM人机交互汇刊 (TOCHI) 27, 4 (2020), 1–27. [43] Shuofei Qiao, Yixin Ou, Ningyu Zhang, Xiang Chen, Yunzhi Yao, Shumin Deng, Chuanqi Tan, Fei Huang 和 Huajun Chen. 2022. 语言模型提示推理: 一项综述。arXiv preprint arXiv:2212.09597 (2022). [44] Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever 等. 2018. 通过生成式预训练改进语言理解。(2018). [45] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever 等. 2019. 语言模型是无监督的多任务学习者。OpenAI博客 1, 8 (2019), 9. [46] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li 和 Peter J Liu. 2020. 探索迁移学习的极限: 一个统一的文本到文本 Transformer。机器学习研究杂志 21, 1 (2020), 5485–5551. [47] Michaela R Reisinger, Sebastian Prost, Johann Schrammel 和 Peter Fröhlich. 2022. 智能家居设计的用户需求: 维度与目标。环境智能与人机计算杂志 (2022), 1–20. [48] Freda Shi, Xinyun Chen, Kanishka Misra, Nathan Scales, David Dohan, Ed Chi, Nathanael Schärli 和 Denny Zhou. 2023. 大语言模型容易被无关上下文分散注意力。arXiv preprint arXiv:2302.00093 (2023).

[49] Jungwoo Shin, Yuri Park, 和 Daeho Lee。2018. 谁将成为智能家居用户？智能家居采用与扩散分析。技术预测与社会变革 134 (2018), 246–253. [50] Marta Skreta, Naruki Yoshikawa, Sebastian Arellano-Rubach, Zhi Ji, Lasse Bjørn Kristensen, Kourosh Darvish, Alán Aspuru-Guzik, Florian Shkurti, 和 Animesh Garg。2023. 错误是有用的提示：基于验证器辅助迭代提示的指令引导任务编程。arXiv 预印本 arXiv:2303.14100 (2023). [51] Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, 等人。2022. Lamda：用于对话应用的语言模型。arXiv 预印本 arXiv:2201.08239 (2022). [52] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, 等人。2023. Llama：开放高效的基础语言模型。arXiv 预印本 arXiv:2302.13971 (2023). [53] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, 等人。2023. Llama 2：开放基础与微调聊天模型。arXiv 预印本 arXiv:2307.09288 (2023). [54] Pooja Upadhyay, Sharon Heung, Shiri Azenkot, 和 Robin N Brewer。2023. 研究老年人对语音助手的探索与长期使用。载于2023年CHI人机交互计算系统会议论文集。1–11. [55] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, 和 Illia Polosukhin。2017. 注意力机制就是一切。神经信息处理系统进展 30 (2017). [56] Jonathan J Webster 和 Chunyu Kit。1992. 分词作为自然语言处理的初始阶段。载于COLING 1992 第4卷：第14届国际计算语言学会议。[57] Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, 和 Quoc V Le。2021. 微调语言模型是零样本学习器。arXiv 预印本 arXiv:2109.01652 (2021). [58] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Ed Chi, Quoc Le, 和 Denny Zhou。2022. 思维链提示激发大语言模型中的推理能力。arXiv 预印本 arXiv:2201.11903 (2022). [59] Mark Weiser。1999. 21世纪的计算机。ACM SIGMOBILE移动计算与通信评论 3, 3 (1999), 3–11. [60] Charlie Wilson, Tom Hargreaves, 和 Richard Hauxwell-Baldwin。2015. 智能家居及其用户：系统分析与关键挑战。个人与普适计算 19 (2015), 463–476. [61] Jimmy Wu, Rika Antonova, Adam Kan, Marion Lepert, Andy Zeng, Shuran Song, Jeannette Bohg, Szymon Rusinkiewicz, 和 Thomas Funkhouser。2023. TidyBot：基于大语言模型的个性化机器人辅助。arXiv: . cs.RO Tongshuang Wu, Michael Terry, 和 Carrie Jun Cai。2022. AI链：通过链接大语言模型提示词实现透明可控的人机交互。载于2022年CHI人机交互计算系统会议论文集。1–22. [63] Haoxiang Yu, Jie Hua, 和 Christine Julien。2021. 数据集：分析IFTTT配方以研究人类如何使用物联网设备。载于第19届ACM嵌入式网络传感器系统会议论文集。537–541. [64] Daniel M Ziegler, Nisan Stiennon, Jeffrey Wu, Tom B Brown, Alec Radford, Dario Amodei, Paul Christiano, 和 Geoffrey Irving。2019. 基于人类偏好微调语言模型。arXiv 预印本 arXiv:1909.08593 (2019)。

附录A 用户指令

指令	示例IFTTT例程 [63]	Goal
环境温度		
让这里不那么冷 帮我凉快一下 让这里不那么闷热 当室外寒冷时关闭空调 当室外炎热时关闭暖气 让夜晚变得舒适	“关闭空调” “打开空调” “当CO ² 升高时循环空气” “如果室外凉爽，自动关闭空调” “天气暖和了……该关掉暖气了” “在我上床时……调整一下温度”	即时 即时 即时 持久性 持久性 持久性
环境亮度		
调暗一些 准备就寝 帮助我看得更清楚 日落后保持照明 日出后使用自然光 我不在时保持灯光关闭	“改变灯光亮度” “使用Alexa和Hue关灯就寝” “天黑时开灯” “日落后开灯” “日出时关灯” “离开地理围栏时关灯”	即时 即时 即时 持久性 持久性 持久性
安防		
检查前门 锁好 让客人进来 锁门当我离开时 有访客时通知我 在白天保持居家安全	“关闭车库门” “告诉Alexa锁好你的门” “当客人到达时，让Alexa解锁门” “当我离开我的房屋时，关闭车库门” “门口有动静时打开灯光” “我离家时唤醒摄像头”	即时 即时 即时 持久性 持久性 持久性
节能		
在我不需要时关闭恒温器 在我离开时节能 帮我节能 帮我降低电费账单	“如果你离开某个区域，请关闭暖气” “当你离开区域时关闭TP-Link智能插座” “当你离家时关闭灯光” “离开区域时关闭TP-Link智能插座”	持久性 持久性 持久性 持久性
环境氛围		
为派对进行设置 让这里变得舒适 帮助我放松 下雨时营造舒适氛围 天气不好时通知我 帮助我改善睡眠	“开始派对吧！将你的灯光设为迪斯科模式” “如果天气冷，就在室内营造温暖氛围” “调整你的Hue灯光...以助睡眠” “开始下雨时将灯光调至温馨...” “如果风力变得危险，通过Hue提醒我” “晚上10点将卧室灯光调为橙色”	即时 即时 即时 持久性 持久性 持久性
机器人控制		
打扫卧室 停止清洁 整理房屋 日落后停止清洁 有人时不清洁 我不在时进行清洁	“告诉Alexa启动你的Roomba” “告诉Google关掉你的机器人” “告诉Alexa启动你的Roomba” “每天定时清洁” “当我到家时，让Roomba回充” “当我离家时，开始清洁任务”	即时 即时 即时 持久性 持久性 持久性
其他电器		
给我一些隐私 让一些阳光照进来 喝完咖啡 在夜间保持湿度 我早上需要喝咖啡 如果天气好，就让一些阳光照进来	“通过Alexa开启PowerView日程” “通过Alexa开启PowerView日程” “说 ‘Alexa trigger coffee’ 来启动咖啡机” “在夜间将您的空气净化器设置为睡眠模式” “说 ‘Alexa trigger coffee’ 来启动咖啡机” “通过Alexa开启PowerView日程”	即时 即时 即时 持久性 持久性 持久性

附录B 用户调查设计

B.1 人口统计问题

您的年龄是？

- ☐ 18-24岁
- ☐ 25-34岁
- ☐ 35-44岁
- ☐ 45-54岁
- ☐ 55-64岁65+ 岁
- ☐

您如何描述自己的性别？

- ☐ 男 女 非二元性别 倾向于自我描述：
- ☐ _____不愿透露
- ☐
- ☐
- ☐

您完成的最高教育程度是？

- ☐ 高中或以下 高中文凭或同等学历 大学肄业 副学士或技术学位 学士学位 研
- ☐ 究生或专业学位（硕士、MBA、博士、法学博士、医学博士等） 不愿透露
- ☐
- ☐
- ☐
- ☐
- ☐

您对智能家居助手（例如：Alexa）和智能设备（例如：智能灯泡）的熟悉程度如何？

- ☐ 完全不熟悉 轻微熟
- ☐ 悉 中等程度熟悉 非
- ☐ 常熟悉 极其熟悉
- ☐
- ☐

您的英语熟练程度如何？

- ☐ 基础熟练 中等熟练 母语/
- ☐ 双语熟练
- ☐

B.2 说明

说明

本次调查共有32个问题，预计将占用您约30分钟时间。以下说明如何完成调查。

介绍


想象一个人住在一个可以通过对话控制的智能家居里，就像与Alexa或Siri对话一样。这里有灯泡和其他可以通过语音指令控制的电子设备。如果你已经了解像Google Home、Siri或Alexa这样的智能助手，请想象这个智能家居更加智能。这个人可以向家庭环境提出诸如“让这里更舒适一些”的要求，而家庭环境会尝试利用可用的智能设备找出最佳的实现方式。

如何回答调查问题

每个问题将展示：(1) 智能家居中设备的布局，(2) 一个人向家庭环境发出的语音指令，以及 (3) 智能家居如何响应的描述。

智能家居布局

首先观察房屋的图片，注意其中有哪些智能设备。以下是一个示例：



请注意，每个房间都有顶灯（以灯泡图标表示）。客厅还有一个恒温器、一个智能音箱、一台电视以及角落里的一个台灯。记下房屋内的设备后，请继续下一步。

用户指令



“turn on the light at 10PM”

我们将向您展示一条用户对家庭环境发出的指令，并询问您该指令的不同部分是否具体。所谓具体，我们指的是精确或确切：如果有人给您同样的说明，您能确切知道他们希望您做什么。

用户期望智能家居做出的**动作**是否具体？例如：“打开灯”，其动作具体是“打开”某物

用户期望智能家居控制的**目标**设备是否具体？例如：“打开灯”，其目标具体是“灯”

在某些情况下，用户可能希望家庭环境在未来基于某个**触发器**执行动作。该触发器是否具体？例如：“晚上10点打开灯”，其触发器具体是“晚上10点”



“turn on the light at 10PM”

action

target

trigger

智能家居响应



“When the local time is 10PM,
I will turn on the light”

我们将向您展示一段文字描述，说明智能家居如何响应该指令，并询问您对该响应的满意程度。请想象您就是发出指令的人。智能家居是否很好地响应了指令？

回答提示

请尽量关注你对智能家居执行的动作的满意程度，并尝试忽略其他因素，例如响应措辞的“友好”程度。

智能家居的响应可能会提及使用家庭环境中的某些传感器。例如，它可能提到使用传感器来检测人的运动，或天气的变化。您可以假设这些传感器存在于房屋中，即使它们没有在房屋的图片中显示。

您的原理


然后，我们将要求您描述家庭环境的响应中哪些方面令人满意和/或不满意。如果家庭环境的响应方式奇怪或有趣，请在此指出。

请前往下一页开始调查。



B.3 示例问题

这是家庭环境及其内部智能设备的布局图。



用户向智能家居发出如下指令：

 “有人在时不要打扫”

请选择所有适用的选项：

- ☐ 用户希望家庭环境执行的**动作**是具体的。
- ☐ 指令的**目标**智能设备是具体的。
- ☐ 应**触发**该动作的事件是具体的。
- ☐ 以上都不是。

智能家居通过以下方式响应：

 “当入口检测到运动时，客厅的*Roomba*将被关闭以停止清洁。”

对于智能家居的这一响应，您会有多满意？请重点关注智能家居声称它做了什么，而非回应的语气或友好程度。

非常满意

满意

中立

不满意

非常不满意

简要描述家庭环境响应的满意和/或不满意之处：



ers do not clean

ing on the diffuser
helped too.

uld like the lights to

is no robot

I instead of lowering
ume, set it to specific
preventing it from
uper quiet if initially
ere already very low.

the problem is that
ctions on the motion

ould need to be de-

附录D 用户研究材料

D.1 会话脚本

介绍。今天我们要测试一个名为Sasha的系统。Sasha代表“更智能的智能家居助手”。Sasha会尝试找出如何利用家庭环境中的不同设备来帮助您实现目标。它通过响应开放式或对话式口头指令来完成这一过程。如果我告诉Sasha“让这里变得舒适”，或者告诉Sasha“嘿，我想在客厅里读一本书”，它会尝试找出可以利用房间里的设备为您做些什么，而无需您具体告知它您希望它做什么。Sasha有一些局限性：

- Sasha无法访问互联网上的信息。
- Sasha不知道您在房间中的具体位置。
- Sasha没有记忆。除非你对Sasha刚做的事情提供反馈，否则它会从头开始。
- Sasha响应较慢。今天我们与Sasha互动时，请对延迟保持宽容，并重点关注Sasha响应你的指令所执行的操作。

参与者的角色。我们关注你对Sasha行为的反应，也关注你向Sasha下达指令的措辞方式。我们将模拟几个不同的场景，你可以向Sasha下达各种指令来准备房屋，并分享你的看法。如果它做了奇怪的事，请告诉我们，比如“我不太明白它为什么打开了那边的灯”。如果它做了很棒或令人惊喜的事，也请告诉我们。你分享的任何看法，无论是正面的、负面的还是具体的，都对我们很有帮助。

导览。我来向你展示Sasha可以控制的每个设备。

- **入口通道。**Sasha可以控制顶灯。
- **餐厅。**Sasha可以控制顶灯，还能打开窗帘。
- **厨房。**Sasha可以控制顶灯，并打开或关闭咖啡壶和茶壶。当Sasha打开其中任何一个时，它们上方的灯会亮起 [演示]。Sasha可以控制这个风扇。这里还有一个“清洁机器人”。它实际上并不能清洁；但Sasha认为它可以。当Sasha打开机器人时，一盏灯会亮起并照亮机器人。
- **客厅。**Sasha可以打开或关闭电视，控制顶灯、两盏台灯，并可以从几种不同的音乐流派中选择在音响上播放。

示例。以下是一些示例指令 [输入这些指令]。

- “我打算在客厅读本书”
- “我想看个电影”（反馈）“看电影的话灯光太亮了。”
- “能让点阳光进来吗？”

场景。我们将处理三个场景，每个场景都包含几个目标。一个场景示例类似于“下班回家”，而一个目标则是“吃晚餐”。在每个场景开始时，我们会关闭房间内的所有设备。你的任务是和Sasha一起，将家庭环境设置成能支持你个人对该场景中目标定义的方式。当你觉得家庭环境已准备就绪时，请告诉我，我们将继续下一个场景。完成预定义的场景后，我们将尝试一些属于你个人日常例程的场景。

结束问题。

- 有没有什么事情让你惊讶于Sasha能够做到的？最令人惊讶的是什么？
- 有没有什么事情你觉得Sasha本应能够做到却未能做到的？你是否注意到Sasha有任何一贯出错的地方？
- 你还能想象Sasha连接到其他哪些设备吗？如果我们拥有那些设备，你会如何或可能如何使用它？
- 你会在家庭环境还是工作中使用Sasha？你会用它来做什么？你为什么不会使用它？

Fdbk	FN	Err
0.12	0.00	0.12
0.14	0.43	0.00
0.25	0.00	0.00
0.25	0.00	0.12
0.50	0.00	0.00
0.17	0.00	0.00
0.00	0.00	0.00
0.00	0.33	0.00
0.25	0.00	0.00
0.50	0.00	0.00
0.33	0.00	0.00
0.50	0.00	0.00
0.29	0.00	0.00
0.20	0.00	0.00
0.60	0.00	0.00
0.12	0.25	0.00
0.12	0.00	0.00
0.43	0.00	0.00
0.00	0.00	0.00
0.00	0.17	0.00
0.36	0.00	0.00
0.17	0.17	0.00
0.25	0.08	0.00
0.73	0.00	0.00
0.20	0.00	0.00
0.18	0.09	0.09
0.17	0.00	0.00
0.30	0.10	0.00
0.27	0.06	0.02

preset scenarios with
goals in the scenario,
Err: JSON error rate.