

主动拒绝与环境锚定执行：面向安全高效的AIoT智能家居的双阶段意图分析范式

Xinxin Jin、Zhengwei Ni (*IEEE*会员)、Zhengguo Sheng (*IEEE*高级会员) 以及Victor C. M. Leung (*IEEE*终身会士)

摘要——随着大语言模型 (LLM) 从信息提供者转变为物联网 (IoT) 中的具身智能体，它们在可靠性与交互效率方面面临重大挑战。直接执行大语言模型生成的指令往往会导致实体幻觉（例如试图控制不存在的设备）。与此同时，现有的迭代框架（如SAGE）陷入交互频率困境，在鲁莽执行与过度询问用户之间摇摆不定。为应对这些问题，我们提出了双阶段意图感知（DS-IA）框架。该框架将高层用户意图理解与底层物理执行相分离。具体而言，阶段1充当语义防火墙，通过检查家庭当前状态来过滤无效指令并消解模糊指令。随后，阶段2采用确定性级联验证器——一种严格的逐步规则检查器，按顺序验证房间、设备与能力——以确保操作在执行前确实在物理上可行。在HomeBench和SAGE基准上的大量实验表明，DS-IA的精确匹配（EM）率达到58.56%（相比基线提升超过28%），并将无效指令的拒绝率提高至87.04%。在SAGE基准上的评估进一步显示，DS-IA通过平衡主动提问与基于状态的推理解决了交互频率困境。具体而言，它将自主成功率（即在没有不必要用户干预的情况下解决任务）从42.86%提升至71.43%，同时在识别确实需要人工澄清的不可消解歧义方面保持较高的精确率。这些结果凸显了该框架通过准确的环境锚定来最大限度减少用户打扰的能力。

关键词——大语言模型、智能家居、具身人工智能、幻觉、意图分析

Zhengwei Ni 的这项工作部分得到了浙江省自然科学基金（批准号：LMS26F010017）的资助，部分得到了桐乡通用人工智能研究院项目TAGI2-B-2024-0017的资助。

Xinxin Jin 和 Zhengwei Ni 任职于浙江工商大学信息与电子工程学院（萨塞克斯人工智能研究院），中国杭州 310018。（电子邮件：24020090056@pop.zjgsu.edu.cn, zhengwei.ni@zjgsu.edu.cn）

Zhengguo Sheng 任职于浙江工商大学萨塞克斯人工智能研究院（中国杭州 310018），同时任职于英国布莱顿 BN1 9RH 的萨塞克斯大学工程与设计系。（电子邮件：z.sheng@sussex.ac.uk）

Victor C. M. Leung 任职于深圳北理莫斯科大学人工智能研究院（中国深圳 518172），同时任职于深圳大学计算机科学与软件工程学院（中国深圳 518060），并任职于不列颠哥伦比亚大学电气与计算机工程系（加拿大温哥华 BC V6T 1Z4）（电子邮箱：vleung@ieee.org）。

Zhengwei Ni 是通讯作者。

I. 引言

随着物联网 (IoT) 生态系统的指数级扩张以及人工智能 (AI) 的深度融合，智能家居智能体正从基于规则的传统模式演进为人工智能驱动的自主模式。在这一演进过程中，大语言模型 (LLM) 凭借其卓越的自然语言理解、常识推理 [1]，和泛化知识，已成为下一代智能物联网 [2] 的核心驱动力。这一技术进步推动了物联网应用的范式转变：从传统的“提问-回答”流程，转向“提问-执行”流程。在“提问-执行”阶段，大语言模型不再仅仅是信息提供者，而是需要扮演具身智能体，根据用户指令和环境状态生成具体行动计划，以驱动物理设备 [3]。然而，这种转变在赋予智能家居巨大灵活性的同时，也带来了根本性挑战：由于大语言模型生成内容具有固有的随机性，直接通过API将其连接到确定性的物理世界，会形成天然的“可靠性差距”，导致执行错误，甚至引发人身安全风险。

为了弥合这一差距并实现可靠的落地控制，现有研究主要探索了两种交互推理模式，这两种模式在处理复杂的现实家庭指令时均表现出理论上的局限性。第一种是单轮交互模式。尽管Ren等人提出了“不确定性对齐”，以便在置信度较低时寻求人类帮助 [4]，但我们的研究发现，仅依靠模型自一致性来判断物理歧义是不可行的。缺乏环境状态约束时，单轮生成往往表现出过度自信，从而导致严重的实体幻觉。第二种是以SAGE（迭代式ReAct）

[3]，为代表的迭代模式，该模式试图通过“指令-计划-工具使用”的循环来解决执行问题。然而，SAGE在部署中面临着严重的“交互频率困境”：系统难以在“静默执行”与“主动询问”之间取得平衡。保守型策略倾向于频繁询问用户，从而破坏智能家居的便利性；而激进型策略则可能为尽量减少交互而鲁莽执行。

这一困境的根本原因在于，现有迭代框架既缺乏对指令歧义的深入认知，也缺乏全局规划。Ivanova等人在AmbiK数据集中将家居指令歧义分为“基于偏好的”、

“常识性的”和“安全性关键的”类型 [5]。像SAGE这样采用“边想边做”反应式策略的框架，缺少在执行前识别这些歧义类型的机制。这会导致“短视”行为，即模型陷入工具调用细节之中。这种盲目探索导致模型在面对混合指令时无法区分偏好歧义（需要确认）和无效实体错误（需要拒绝），从而产生两类典型失败，如图1所示：任务遗漏（忘记后续指令）和强制幻觉（强行映射到错误的设备）。

为了解决“无约束单轮生成”与“短视迭代交互”之间的矛盾，我们从Zhang等人将意图分析用于越狱防御的做法中汲取灵感，[6] 并提出建立“全局决策上下文”。我们构建了双阶段意图感知（DS-IA）框架，旨在将全局视角与严谨执行相结合。与SAGE被动的“先错后修”机制不同，我们的框架采用“主动分析”范式。具体而言，阶段1是全局意图分析，充当“语义路由器”，评估指令有效性并剥离核心意图；阶段2是实体锚定验证，引入“房间-设备-能力”级联检查以及针对混合意图的“生成并筛选”策略，确保每个输出动作都锚定到真实物理实体。

我们的主要贡献概括如下：

• **提出“先分析后行动”的主动范式：**我们揭示了现有迭代框架中“交互频率困境”背后的机制，并提出一种将宏观意图分析与微观动作执行解耦的机制。

• **设计一种具有级联验证的双阶段框架：**我们构建了一个包含“预执行意图路由”和“分层实体验证”的系统架构。具体针对混合意图，我们提出了一种“生成并筛选”策略，以消除任务遗漏和强制幻觉。

• **在HomeBench [7] 和SAGE基准上的验证：**在具有挑战性的HomeBench数据集上的实验表明，我们的方法显著降低了幻觉率。此外，在SAGE基准上的评估证明，我们的方法在保持高任务成功率的同时，最大程度地减少了不必要的人机交互。

为促进未来研究并推动开放协作，本研究所用的完整代码库、环境快照和评估脚本均已公开发布在 <https://github.com/xxscy/DS-IA-smart.git>。

II. 相关工作

本研究涉及三个关键领域：基于大语言模型的物联网规划、人机交互中的歧义消解，以及高效智能体部署。

A. 基于大语言模型智能家居规划

智能家居控制的范式正从槽位填充转向生成式规划。早期工作如 [8]探索了

利用大语言模型将高层用户意图（例如“为聚会进行布置”）推断为设备状态。为了弥合生成与执行之间的差距，ProgPrompt [9]引入了一种程序化提示结构，把计划落实到 Pythonic 代码中，显著提高了可执行性。类似地，物联网-大语言模型 [10] 证明了，用物联网传感器数据增强大语言模型能够提升其物理推理能力。

然而，这些方法通常以开环方式运行，或严重依赖提示工程。SAGE [3]通过引入迭代式ReAct循环推进了这一方向。然而，正如近期关于IoT-LM [11]，的研究所指出的，纯反应式智能体难以实现多感官对齐，且常常产生高延迟。我们的DS-IA框架建立在上述基础之上，但引入了一种双阶段验证机制，以显式地执行物理接地约束。

B. 歧义消解与人机交互

歧义是家庭环境中普遍存在的挑战。AmbiK数据集 [5] 将歧义划分为偏好型、常识型与安全型三类。现有的解决这些歧义的方法主要依赖人工干预或多模态线索。例如，Abugurain等人 [12]提出了一个使用GPT-4生成澄清问题的框架，而Calò等人 [13] 则利用视觉线索对命令进行消歧。

尽管这些“先问再做”策略有效，但它们也助长了“交互频率困境”。频繁提问会损害用户体验。我们的工作提出了一种状态感知的消歧策略，该策略与通过从当前环境快照中推断意图、仅在必要时请求帮助来降低人的认知负荷的目标一致。

C. 安全、隐私与效率

在私人住宅中部署大语言模型引发了关于幻觉和数据隐私的担忧。ChatIoT [14] 指出了物联网管理中的安全风险，并提出了检索增强生成（RAG）以缓解威胁。此外，为了解决大模型的计算开销，Huang等人 [15] 探索了定制化小语言模型（SLM），用于隐私保护的设备端处理。这些工作启发了我们未来的研究方向：将意图分析模块蒸馏为边缘友好型小语言模型，以平衡性能与隐私。

III. 方法

A. 问题定义

我们将智能家居指令执行任务建模为受物理约束的序列生成问题。

定义 1 (环境状态 S_t)：我们将时刻 t 的家庭环境状态形式化为一个层次化知识图谱 $S_t = \{R, D, C\}$ 。

- $R = \{r_1, \dots, r_n\}$ 表示物理房间的集合。
- $D_t = \{(d_i, r_{d_i}) \mid d_i \in \mathcal{D}_{global}, r_{d_i} \in R\}$ 表示在时刻绑定到特定房间的可用设备的集合




图1. 现有反应式框架中的失败机制。(a) 任务遗漏: 智能体在陷入多轮交互时会丢失全局上下文。(b) 被迫幻觉: 由于缺乏主动拒绝机制, 智能体只能将不可执行命令强行映射到错误实体。

t , 其中 $\mathcal{D}_{global}$ 表示系统中所有受支持的设备类型的全域词汇表。

- $C_t(d_i) = \{f_{i,1}, \dots, f_{i,k}\}$ 表示设备 d_i 在时刻 t 当前可用的可调用能力 (方法) 的集合。

定义2 (指令与动作): 给定用户指令 U , 系统生成动作序列 $A = \{a_1, a_2, \dots, a_m\}$ 。每个原子动作 a_k 表示为结构化元组:

$$a_k = \langle r_k, d_k, f_k, p_k \rangle \quad (1)$$

其中 r_k 、 d_k 、 f_k 和 p_k 分别表示目标房间、目标设备标识符、目标能力 (函数) 和函数参数。

传统的端到端模型试图最大化条件概率 $P(A|U; \theta)$, 其中 θ 表示预训练大语言模型的冻结参数。然而, 在开放词汇设置下, 这种无约束的概率生成常常导致 a_k 指向不存在的实体。因此, 我们

引入一个物理接地约束函数 $\Phi(A, S_t)$, 并将推理时的解码目标修改为:

$$A^* = \underset{A}{\operatorname{argmax}} (P(A|U, S_t; \theta) \cdot \mathbb{I}[\Phi(A, S_t) = 1]) \quad (2)$$

其中, $\mathbb{I}[\cdot]$ 为指示函数: 若生成的序列在当前环境中完全可行, 则输出 1; 否则输出 0。

B. 阶段1: 全局意图分析与路由

意图分析 (IA) 模块充当语义防火墙。它利用大语言模型的语义理解, 严格基于当前环境快照 S_t 解析指令。该模块的输出被形式化为一个分析对象 $\mathcal{O}_{IA} = \langle \text{类型}, \text{推理} \rangle$, 其中类型将指令归为三类之一, 推理包含诊断上下文。这三个类别是:

- C_{valid} (有效指令): 所有提及的实体都可以在 S_t 中以高置信度找到。

表 I 智能家居控制框架对比。DS-IA 在物理安全与交互效率之间实现了最佳平衡。

框架类型	代表性方法	推理范式	歧义处理策略	物理安全	主要限制
槽位填充	基于BERT的	有监督 / 模板	None	高 (受模板约束)	对未见命令的泛化能力较差
直接生成	GPT-3.5/4	端到端	模型概率	低 (容易产生幻觉)	严重的实体幻觉; 无反馈
反应式智能体	SAGE [3], ReAct [16]	迭代式 (思考-行动循环)	被动式 (出错时)	中等	交互频率困境; 干扰性
不确定性规划	Ren等人 [4]	概率对齐	置信度阈值	中等	语言置信度 $\neq$ 物理事实
DS-IA (本文方法)	本文工作	先分析后行动 (双阶段)	主动状态感知	非常高 (级联检查)	取决于实时快照新鲜度




图2. 双阶段意图感知 (DS-IA) 框架的工作流程。该图展示了模块化架构：阶段1主动分析意图，阶段2利用级联验证器防护机制来确保物理可行性。

- $C_{invalid}$ (无效指令)：该指令明确指向不存在的设备。系统触发提前拒绝。
- C_{mixed} (混合指令)：该指令包含多个子任务，其中既有有效实体，也有无效实体。

C. 阶段2：分层接地验证

对于通过IA的指令 (C_{valid} 和 C_{mixed})，我们使用上下文学习生成一个原始候选动作序列 A_{raw} 。为消除幻觉，我们设计了一个三级级联验证器来检查每个原子动作 $a_k = \langle r_k, d_k, f_k, p_k \rangle \in A_{raw}$ ：

第1级：空间拓扑验证 (V_R) 检查目标房间是否存在于房屋中：

$$V_R(a_k) = 1 \iff r_k \in R \quad (3)$$

第2级：实体对齐验证 (V_D) 检查目标设备在时间 t 是否实际存在于指定房间中：

$$V_D(a_k) = 1 \iff (d_k, r_k) \in D_t \quad (4)$$

第3级：可供性验证 (V_C) 检查该设备在时间 t 是否支持请求的功能：

$$V_C(a_k) = 1 \iff f_k \in C_t(d_k) \quad (5)$$

单个动作的原子约束为 $\Phi(a_k, S_t) = V_R(a_k) \wedge V_D(a_k) \wedge V_C(a_k)$ 。为了与标准具身评估协议（如HomeBench数据集）严格对齐，如果某个动作未通过任何一项检查 ($\Phi(a_k, S_t) = 0$)，验证器会显式输出一个标准化错误标记 (ϵ_{err}) 来标记物理违规。因此，通过对所有生成的步骤应用这种原子级过滤，式 (2) 中的序列级约束得到强制执行。

D. 混合意图解析策略

对于 C_{mixed} 指令，当有效与无效子任务并存时（例如“打开电视和不存在的加热器”），传统的反应式模型通常会遭遇“全有或全无”式的执行失败或强制幻觉。为了克服这一问题，我们采用“生成并筛选”策略（算法1），该策略旨在最大化任务召回率，同时严格防止不可执行动作。

操作过程主要包含两个阶段：

1) **推理引导生成**：阶段2的大语言模型生成器不会盲目生成动作，而是基于阶段1明确传递的诊断上下文（ $\mathcal{O}_{IA}$ 推理），草拟出原始候选动作序列 A_{raw} 。这一先验知识充当宏观层面的路线图，预先向生成器提示缺失的实体，并缩小搜索空间。

2) **原子过滤与序列对齐**：一旦 A_{raw} 生成，三级级联验证器会独立评估每个原子动作 a_k 。按照标准基准协议的要求，不可执行动作必须用错误标记（ ϵ_{err} ）标注。面对复杂混合意图时，我们的框架完美满足了这一要求：它不是承受级联执行失败或盲目丢弃失败任务，而是用 ϵ_{err} 精确替换局部失败。这种精确替换在结构上至关重要，因为它保持了原始多步指令的顺序对齐，从而完全防止后续有效动作被时序错位或完全遗漏（任务遗漏）。

最后，系统汇总执行结果，形成精确的文本反馈（ Msg ）。智能体不会返回一个通用错误，而是准确告知用户哪些子任务成功、哪些子任务因物理约束被安全绕过，从而确保人与智能体之间的透明交互。

E. DS-IA框架的运行示例

为具体说明DS-IA框架如何弥合可靠性差距，请考虑一条复杂的 C_{mixed} 指令和一个特定的环境快照 S_t ：

- **用户指令 (U)**：“打开卧室的阅读灯，将厨房的除湿机设置为50%，并锁上前门。”
- **环境快照 (S_t)**：- 客厅：阅读灯（开启）- 卧室：阅读灯（关闭）- 厨房：烤箱、冰箱（无除湿机）- 入口：智能门锁（未锁定）

第1步：阶段1的意图分析与路由。大语言模型路由器将 U 与 S_t 进行比对。对于“卧室阅读灯”，它确认该实体存在，且对应指令为有效指令（ C_{valid} ）。对于“厨房除湿机”，由于环境快照中缺少该设备，该路由器检测到 $C_{invalid}$ 意图。对于“锁上前门”，该指令为 C_{valid} 。整体指令被路由为 C_{mixed} ，并连同其诊断推理 $\mathcal{O}_{IA}$ 一并传递至阶段2。

步骤2：阶段2生成与级联验证。生成器拟定原始动作序列 A_{raw} 。级联验证器随后严格检查每个动作：

- 1) 打开_（卧室_灯）：通过 $V_R \wedge V_D \wedge V_C$ 。（已接受）
- 2) 设置_湿度（厨房_除湿机，50）：未通过二级验证（ $V_D = 0$ ）。已替换为错误标记 ϵ_{err}

- 3) 锁定（入口_锁）：通过所有检查。（已接受）

最终输出：与那些可能幻觉出除湿机、或因中途工具故障而漏掉锁定命令的反应式框架不同，DS-IA 安全地输出过滤后的动作序列 $A_{final} = \{\text{turn_on}(\text{bedroom_lamp}), \text{lock}(\text{entrance_lock})\}$ ，并提醒用户：“已执行灯具和门锁。失败：未找到厨房除湿机。”这体现了零任务遗漏与零强制幻觉。

F. 提示工程策略

DS-IA框架的性能高度依赖于结构化的提示设计。我们不再采用标准少样本提示，而是采用“约束感知指令提示”策略。我们在提示中引入了两个关键机制：

- 1) **状态注入**：我们将层次化知识图谱 S_t 扁平化为紧凑的文本表示。
- 2) **负向约束**：我们明确指示模型不要做什么（例如，“在操作不存在的属性和设备时，输出错误_输入”）。

由于篇幅限制，用于阶段1（全局意图分析）和阶段2（代码生成）的确切且完整的提示词模板详见附件。

算法 1：基于生成与过滤的混合意图解析 输入：用户指令 U ，环境状态 S_t 输出：可执行序列 A_{final} ，反馈 Msg

```

1: // 阶段1：意图路由 2:  $\mathcal{O}_{IA} \leftarrow \text{意图分析}(U, S_t)$  3: 如果  $\mathcal{O}_{IA}$  的类型为  $== C_{invalid}$  那么 4: 返回  $\emptyset$ , "操作被拒绝：没有有效设备。" 5: 结束如果 6: // 阶段2：生成与过滤 7:  $A_{raw} \leftarrow \text{大语言模型\_生成}(U, S_t, \mathcal{O}_{IA}.\text{推理})$  8:  $A_{final} \leftarrow \text{列表}()$ ,  $ErrorSet \leftarrow \text{集合}()$  9: 对于  $A_{raw}$  中的每个原子动作  $a_k = \langle r_k, d_k, f_k, p_k \rangle$ , 执行 10:  $v_1 \leftarrow V_R(a_k)$  11:  $v_2 \leftarrow V_D(a_k)$  12:  $v_3 \leftarrow V_C(a_k)$  13: 如果  $v_1 \wedge v_2 \wedge v_3$  为真 那么 14:  $A_{final}.\text{追加}(a_k)$  15: 否则 16:  $A_{final}.\text{追加}(\epsilon_{err})$  17:  $ErrorSet.\text{添加}(d_k)$  18: 结束如果 19: 结束循环 20: // 构建反馈 21: 如果  $ErrorSet$  不为空 那么 22:  $Msg \leftarrow \text{"已执行有效操作。失败：" + } ErrorSet$  23: 否则 24:  $Msg \leftarrow \text{"成功。"} 25: 结束如果 26: 返回  $A_{final}, Msg$$ 
```

IV. 实验设置

我们在两个互补的基准上评估 DS-IA 框架：HomeBench 用于鲁棒性，而 SAGE 基准用于交互效率。

A. 数据集

1) *HomeBench*（鲁棒性）：*HomeBench* 包含 100 个模拟家庭环境和 2,500 条指令，用于评估智能体在物理约束下落实指令的能力。指令分为三类：有效指令（标准可执行命令）、无效指令（针对不存在的实体，占数据集的 38.6%）和混合指令（同时包含有效与无效子任务）。

输入/输出实例（混合指令任务）：

- 输入上下文 (S_t)：厨房：[灯（关闭）]
- 输入指令 (U)：“打开厨房的灯和烤箱。”
- 预期输出 $\{\text{kitchen.light.turn_on()}, \epsilon_{err}\}(A)$ ：
(解释：模型必须执行有效的灯光指令，同时用错误标记替换不存在的烤箱指令。)

2) *SAGE* 基准（交互效率）：该基准包含 50 个复杂任务，聚焦于人机交互（HRI），涵盖设备解析、个性化和意图消歧等场景。它评估智能体能否在自主执行与主动询问之间取得恰当平衡。

输入/输出实例（设备解析）：

- 输入上下文 (S_t)：卧室：[灯_A（开），灯_B（关）]
- 输入指令 (U)：“打开灯。”
- 预期输出（自主执行）： $\{\text{bedroom.lamp_B.turn_on}()\}$ （解释：智能体应基于设备状态静默解决歧义，不打扰用户。如果两盏灯都处于关闭状态，预期输出将转为类似 *ask_user*（“哪盏灯？”）的交互式工具调用。）

B. 基线与模型

我们与以下方法进行对比：

1) **标准少样本**：使用 4 样本提示和完整环境上下文，代表大语言模型的原生能力。2) **SAGE（迭代式 ReAct）**：最先进的工业级框架，使用工具调用（查询_设备、人类_交互）[3]。为确保公平比较并验证泛化能力：

- 对于 HomeBench：所有方法均在 NVIDIA RTX 5090（BFloat16，启用缩放点积注意力）上使用 Qwen-2.5-7B-Instruct。DS-IA 使用贪心解码（ $T=0$ ）。
- 对于 SAGE 基准：我们将基线和我们的框架统一使用 GPT-4o-mini。这一选择是为了与原始 SAGE 论文的实验设置保持严格一致 [3]，以便公平复现和评估。

C. 评估指标

为了全面评估智能家居智能体的物理安全性和交互效率，我们采用了针对我们的两个基准定制的不同度量套件：

1. HomeBench 的评估指标（物理接地与安全性）：

• **精确匹配（EM）**：这是衡量执行准确性和安全性的主要指标。对于有效指令（有效单指令/有效多指令/混合多任务），它评估生成的动作序列是否与基准真值完美匹配，且不包含任何幻觉。对于明确无效的指令（IS/IM），完美匹配意味着系统成功生成了指定的错误_输入标记，该标记代表了系统的拒绝率。

• **F1 分数**：通过衡量生成代码中预测的房间、设备以及动作/属性的精确率和召回率，提供对部分正确性的细粒度评估。

2. SAGE 基准的评估指标（交互效率）：

• **任务成功率**：这是对多轮任务最终是否得到解决的全局评估。与标准精确匹配不同，任务成功率是在两个不同的、依赖上下文的交互维度下实现的：

- **自主成功率**：该指标评估在清晰任务上的表现。它衡量智能体在成功推断并执行所需动作时，能否避免向用户进行不必要的询问（对过度谨慎和冗余的 API 调用进行惩罚）。
- **澄清成功率**：评估在模糊任务上的性能。它衡量智能体能否正确停止物理执行，并主动调用以人为中心的工具（例如，询问_用户）来获取缺失信息（对强制幻觉进行惩罚）。

V. 结果与分析

A. HomeBench 上的鲁棒性

为了系统评估框架对实体幻觉的鲁棒性，我们根据 HomeBench 指令的有效性和复杂性将其分为五种不同类型。表 II 通过具体示例展示了这些类别，并将它们映射到相应的评估指标。

表 II HomeBench 任务分类与指标映射。（假设 S_t 不包含烤箱）

任务类别	指令示例	目标指标与能力
VS（有效单指令）	“打开灯。”	EM 与 F1：评估常规指令遵循召回率。
VM（有效多指令）	“打开灯，锁门。”	
IS（无效单一任务）	“打开烤箱。”	拒绝率：评估安全性以及幻觉抑制。
IM（无效多任务）	“打开烤箱和取暖器。”	
MM（混合多任务）	“打开灯和烤箱。”	EM 与 F1：评估过滤能力。

理解这种映射关系至关重要，因为在有效任务上的成功所衡量的是执行能力，而成功在

表 III: 在 HomeBench 上的性能比较 (EM: 精确匹配, F1: F1分数)。粗体表示最佳性能。

方法	VS (有效单指令)		IS (无效单一任务)		VM (有效多指令)		IM (无效多任务)		MM (混合多任务)		总体	
	EM	F1	EM	F1	EM	F1	EM	F1	EM	F1	EM	F1
基线	66.96%	66.89%	14.07%	14.08%	37.55%	69.18%	0.00%	5.82%	0.49%	33.23%	29.98%	35.72%
SAGE	48.63%	49.18%	29.84%	29.84%	9.09%	47.42%	0.00%	0.00%	1.77%	29.80%	1.77%	30.84%
DS-IA (本文方法)	50.40%	50.37%	87.04%	87.16%	50.00%	76.98%	38.46%	73.08%	24.49%	77.42%	58.56%	74.90%

无效任务上严格衡量的则是物理安全（即触发提前拒绝的能力）。表III给出了这些维度的综合定量结果。DS-IA的总体成功率（精确匹配）达到58.56%，F1分数为74.90%，显著优于基线（29.98%精确匹配）和SAGE（1.77%精确匹配）。

1) 基线性能异常分析：值得注意的是，与原始论文相比，SAGE框架在HomeBench上的精确匹配率（1.77%）异常之低。我们将这种性能下降归因于反应式架构与无效指令之间的不匹配。SAGE依赖一个迭代的“观察-推理-行动”循环。当面对无效指令（占HomeBench的38.6%）时，SAGE缺乏提前停止的机制；相反，它会穷尽地调用搜索工具（例如，scan_devices），直到它要么幻觉出一个语义匹配（强制接地），要么耗尽上下文窗口。这凸显了我们阶段1“语义防火墙”的必要性——它能在这些不可执行查询触发代价高昂的反应式循环之前将其过滤掉。

2) 幻觉抑制分析：在直接测试拒绝幻觉能力的IS（无效单一任务）任务中，基线仅达到14.07%，显示出强烈的“强制接地”倾向。相比之下，DS-IA达到了87.04%。这一跨越式提升证明，阶段1的意图路由机制有效地起到了语义防火墙的作用。

3) 混合意图分析：对于MM（混合多任务）任务，DS-IA的F1分数为77.42%（成功率为24.49%），而基线的F1分数为33.23%。这验证了“生成并筛选”策略：该策略允许智能体执行有效子任务，同时安全地舍弃幻觉，从而避免了单阶段模型中常见的“全有或全无”失败模式。

4) 对有效指令的改进：值得注意的是，与之前的迭代相比，我们的框架在VS（有效单指令）任务上保持了有竞争力的性能（50.40%），在提供显著更高的安全保障的同时缩小了与基线的差距。对于复杂的VM（有效多指令）任务，DS-IA以50.00%的成功率优于基线，展示了其在长时程规划处理方面的卓越能力。

B. 案例研究：对强制幻觉的抑制

为了直观展示DS-IA在HomeBench数据集上相较于SAGE的安全性优势，我们分析了一个涉及无效实体的代表性失败案例（案例ID: home45_one_1306）。

场景描述：

• **用户指令**：“将储藏室中除湿机的强度设为0。”

• **环境背景**：模拟住宅中没有“储藏室”，或者该位置没有除湿机。用户请求针对的是一个不存在的实体。

• **真值**：系统应报告错误且不执行任何操作（错误_输入）。

框架行为对比：

1) **SAGE（基线）失败**：如SAGE的执行日志所示，基线模型输出：

study_room.dehumidifiers.set_intensity(0)**分析**：

由于缺乏显式的拒绝机制，SAGE表现出“强制接地”。它将不存在的“储藏室”在语义上映射到最近的有效实体“书房”，并执行了该命令。这体现了“可靠性差距”，即模型优先考虑执行而非忠实性，导致非预期的物理操作。

2) **DS-IA（本文方法）成功**：我们的框架输出：

{error_input}

分析：

• **阶段1（意图分析）**：意图路由器扫描了环境快照

S_{t_0} 。它检测到目标实体（store_room、除湿机）在图中缺失。

• **决策**：该指令被分类为 $C_{invalid}$

• **操作**：系统触发早期拒绝协议，完全绕过了生成阶段。

该案例有力地验证了，引入执行前验证阶段对于在安全关键型物联网环境中防止大语言模型幻觉至关重要。

C. 消融实验：计算效率与安全性

为深入分析意图分析（IA）模块的贡献，我们在包含1,000个任务的子集上进行了消融实验，将完整框架（DS-IA）与不含阶段1（无IA）的基线进行了对比。在基线中，指令未经事先语义路由便被直接送入代码生成器。

本次消融实验并非只是评估常规执行，而是明确聚焦于框架的物理安全能力与计算经济性。表IV详细列出了两种配置的安全性指标（无效指令拒绝率）以及API调用频率和Token消耗量。




图 3: 在 HomeBench 上处理不存在设备的指令时的视觉对比。SAGE 会幻觉出一个目标（强制接地），而 DS-IA 则正确拒绝该命令（提前拒绝）。

表 IV: 安全性和效率的消融实验（1,000 个任务）。DS-IA 以廉价输入词元换取昂贵的自回归代码生成循环的大幅减少，同时提高物理安全（拒绝率）。

方法	安全性 IS 精确匹配（拒绝）	阶段1（意图分析） 调用次数	Token 数	阶段2（代码生成） 调用次数	Token 数
无IA基线	83.29%	0	0	1,000	2,982,070
DS-IA（本文方法）	88.69%	1,000	3,262,848	819	2,554,231

1) 通过提前拒绝强化安全性：如表IV所示，IA模块起到了关键的语义防火墙作用。如果没有阶段1，基线会盲目尝试执行每一条用户指令，导致在无效命令上出现更高的强制幻觉风险。通过将存在性验证单独放在阶段1中，DS-IA能够在明确无效的意图到达生成器之前将其准确拦截。这种严格的提前拒绝机制提升了系统的绝对物理安全性，将无效单指令（IS）的精确匹配率从83.29%提高到88.69%，从而为智能家居控制牢固确立了“不伤害”协议。

2) 大幅降低生成开销：在安全性之外，提前拒绝机制从根本上优化了智能体的计算动态。通过为明确无效的意图跳过生成阶段，DS-IA 将高开销的代码生成调用次数削减了 18.1%（从 1,000 次降至 819 次）。因此，该框架在阶段2中成功节省了超过 427,000 个生成词元。

3) 预填充与解码的经济性：尽管 DS-IA 在阶段1中引入了 3.26M 个词元，但这种看似额外的开销在实践中高度不对称。在现代大语言模型架构中，阶段1（IA）主要涉及预填充（提示词）处理，以读取环境快照 S_t 。预填充高度可并行化，计算成本很低。相反，阶段2（代码生成）高度依赖自回归解码，后者受内存带宽限制，速度慢，且计算成本高昂。

通过以廉价的输入（IA）token 换取昂贵的生成（CodeGen）token 的大幅减少，DS-IA 实现了一种高效的自适应计算策略。它确保代码生成的重活得以保留

严格限于物理上有效的任务，从而彻底消除浪费在幻觉指令上的算力。

D. SAGE基准上的交互效率

为了严格评估复杂人机交互（HRI）场景中的交互效率，我们采用了SAGE基准（50个任务）。与只对物理执行给予奖励的传统指标不同，我们在全局层面定义任务成功率：当信息充分时，智能体正确执行自主行动，或在面对不可消除的歧义时准确调用以人为中心的工具（例如 ask_user）主动获取缺失信息，则该任务被视为成功。表V展示了不同维度上的综合性能。

表V SAGE基准上的任务成功率细分。成功可通过安全自主执行或正确主动澄清实现。

任务类别	SAGE（基线）	DS-IA（本文方法）
全局判定指标		
澄清成功率（有歧义）	75.00%	75.00%
自主成功率（无歧义）	42.86%	71.43%
详细任务成功率细分		
意图解析	33.33%	70.83%
设备解析	46.15%	69.44%
个性化	27.27%	54.55%
持久化	25.00%	100.00%
命令链接	62.50%	62.50%
简单命令	57.14%	85.71%

1) 交互数据的综合分析：

• **自主性与主动提问的平衡：**从宏观层面看，SAGE 存在严重的“过度谨慎”和频繁提问问题。当人机交互模块启用时，基线常常陷入重复提问循环，自主成功率仅为 42.86%。这意味着，在超过一半本可独立完成的任务中，它用冗余问题过度打扰用户。通过将意图路由与物理生成解耦，DS-IA 将这一自主性提升至 71.43%。同时，在严格需要人工干预的歧义任务上，DS-IA 依然将澄清成功率完美保持在 75.00%。这证明我们的框架能有效抑制大语言模型频繁提出不必要问题的倾向，同时保留其识别真正信息不足并仅在确有必要时寻求帮助的关键能力。

• **卓越的消歧（意图与设备解析）：**在意图解析（33.33% → 70.83%）和设备解析（46.15% → 69.44%）中，用户指令通常含有模糊名词，需要基于状态进行推导。SAGE 的反应式“边想边做”循环往往陷入无限 API 调用，或凭空捏造目标参数。相比之下，DS-IA 的阶段1模块充当语义防火墙，在生成之前先将模糊指令与环境快照 S_t 对齐，

从而带来了 +37.5% 和 +23.29% 的巨大绝对提升。

respectively.

• **处理复杂上下文（个性化与持久化）**：个性化任务涉及用户的主观偏好，DS-IA 通过更严格的语义路由将基线成功率精确翻倍（27.27% → 54.55%）。更令人印象深刻的是，在需要长期状态监测的持久性任务上，SAGE 因多轮交互中的上下文遗忘而基本失效（25.00%）。DS-IA 在此类任务上实现了完美的 100.00% 成功率，因为其级联验证器将每个生成的动作机械地锚定在物理事实上，从而消除了上下文幻觉。

• **基础能力（简单命令与链式命令）**：即使在简单命令上，SAGE 也常常使执行轨迹过度复杂，导致格式崩溃（57.14%）。DS-IA 则直接将它们映射为有效动作，将鲁棒性提升到 85.71%。最后，在命令链接（纯顺序逻辑、无深度歧义）上，两个框架表现同样出色（62.50%），这证实 DS-IA 在引入精细消歧能力的同时，并未削弱基线的基础多步指令跟随能力。

六、结论

本文探讨了在智能家居中部署基于大语言模型的智能体所面临的两个根本瓶颈：“可靠性差距”（即实体幻觉）和“交互频率困境”（即过度的用户打扰）。我们提出了双阶段意图感知（DS-IA）框架，通过解耦宏观意图路由与微观实体锚定验证，开创了“先分析后行动”范式。

A. 贡献总结

我们在 HomeBench 和 SAGE 基准上的广泛评估得出了三个关键洞见：

- **安全性优先**：DS-IA 可充当有效的语义防火墙。通过在无效指令（HomeBench IS）上取得 87.04% 的精确匹配（EM）（基线为 14.07%），我们的框架展现出强大的提前拒绝能力。这有效消除了“强制接地”的风险，确保物理安全，即便以在简单任务上轻微降低召回率为代价。
- **兼具精确率的自主性**：我们成功缓解了反应式框架中固有的交互困境。所提出的 DS-IA 框架将自主成功率（即在没有冗余用户查询的情况下独立解决任务的能力）从 42.86%（SAGE）提升至 71.43%。这一显著提升表明，状态感知歧义消解能够通过将意图落脚于物理环境，有效化解大多数功能歧义，从而在保持执行精度的同时，最小化不必要的用户打扰。
- **长期鲁棒性**：在持久性任务上 100% 的成功率表明，我们结构化的基础机制在长时间维持上下文方面优于反应式方法。

B. 局限性与未来工作

尽管取得了这些进展，我们仍指出了未来优化的三个方向：

- 1) **多模态感知**：目前，DS-IA 依赖文本元数据。受 [13] 和 [11] 的启发，未来工作将集成视觉语言模型（VLM），以解析视觉指代（例如，“打开那盏红灯”）并处理多感官数据。
- 2) **隐私保护的小语言模型蒸馏**：为解决 [15] 中提出的推理延迟和隐私问题，我们计划将意图分析模块蒸馏为专门的小语言模型（SLM）。这将实现设备端执行，无需将家庭私有状态发送云端。
- 3) **个性化记忆**：根据 [8] 中的发现，我们旨在引入向量数据库（RAG）来记忆用户习惯，使智能体能够隐式解决基于偏好的歧义。

总之，DS-IA 为下一代具身物联网智能体提供了一个稳健、安全且高效的蓝图，弥合了语言推理与物理执行之间的鸿沟。

附录

为了确保完全可复现，并展示物理接地约束是如何被显式注入到大语言模型中的，图 4 提供了我们 DS-IA 框架两个阶段所使用的确切系统提示词和上下文结构。

参考文献

- [1] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed H. Chi, Quoc V. Le 和 Denny Zhou. 2022. 思维链提示能够在在大语言模型中激发推理能力。载于第 36 届国际神经信息处理系统会议论文集（NIPS ’ 22），美国纽约州红钩：Curran Associates Inc., 文章编号 1800, 第 24824–24837 页。[2] Wang, L., Ma, C., Feng, X. 等. 基于大语言模型的自主智能体综述. *Front. Comput. Sci.* 18, 186345 (2024). <https://doi.org/10.1007/s11704-024-40231-1>[3] Dmitriy Rivkin, Francois Hogan, Amal Feriani, Abhisek Konar, Adam Sigal, Xue Liu 和 Gregory Dudek, “通过自主大语言模型智能体实现的 AIoT 智能家居”, *IEEE 物联网期刊*, 第 12 卷, 第 3 期, 第 2458–2472 页, 2025 年. DOI: 10.1109/JIOT.2024.3471904. [4] Allen Z. Ren, Anushri Dixit, Alexandra Bodrova, Sumeet Singh, Stephen Tu, Noah Brown, Peng Xu, Leila Takayama, Fei Xia, Jake Varley, Zhenjia Xu, Dorsa Sadigh, Andy Zeng 和 Anirudha Majumdar, “会主动求助的机器人：面向大语言模型规划器的不确定性对齐”, 载于第 7 届机器人学习会议论文集, 第 229 卷, PMLR, 2023 年 11 月, 第 661–682 页。[5] Anastasia Ivanova, Bakaeva Eva, Zoya Volovikova, Alexey Kovalev 和 Aleksandr Panov. 2025. AmbiK: 厨房环境中的歧义任务数据集。载于第 63 届计算语言学协会年会论文集（第一卷：长文），第 33216–33241 页, 奥地利维也纳：计算语言学协会。[6] Yuqi Zhang, Liang Ding, Lefei Zhang 和 Dacheng Tao. 2025. 意图分析使大语言模型成为良好的越狱防御者。载于第 31 届国际计算语言学会议论文集, 第 2947–2968 页, 阿联酋阿布扎比：计算语言学协会。

(a) 阶段1：全局意图分析的提示词模板

系统角色：

你是一个智能家居意图分析器。你的任务是严格评估用户命令是否能够基于所提供的环境状态来执行。

环境上下文：

<家庭状态>_{设备_状态_快照}</

家庭_状态>

评估规则：

对每个操作，检查以下三项：

- 1) **房间存在性**：提到的房间是否存在？ 2) **设备存在性**：该设备是否存在于该房间中？ 3) **动作支持**：该设备是否支持所请求的动作/属性？

输出格式：

输出一个 JSON 对象，包含一个操作数组（含 valid 和 reason 字段）以及一个全局 all_valid 布尔标志。

(b) 用于阶段2（代码生成）的提示词模板

系统角色与负向约束：

你是“AI”，一位乐于助人的 AI 助手，负责控制房屋中的设备。请按指令完成以下任务，或仅根据所提供的信息回答以下问题。下面提供设备的当前状态及其具备的方法，请仅使用所提供的方法。**当操作不存在的属性和设备时，输出“错误_输入”。仅输出机器指令，并用 {} 括起来。**

环境上下文与能力：

<家庭状态>_

以下内容提供当前家庭中每个房间内所有设备的状态及可调节属性……{设备_状态_快照}</家庭_状态>

<设备方法>_

以下内容提供控制当前家庭中每个设备的方法：{设备_方法_快照}</设备_方法

>

少样本示例（可选）：

{在_上下文中的_示例}

用户交互：

以下是你需要回复的用户指令。<用户指令：>{User_Command}<机

器指令：>

图4. DS-IA框架中使用的完整约束感知提示词模板。(a) 阶段1提示词充当语义防火墙，以提取诊断推理。(b) 阶段2提示词生成最终执行序列，并通过整合严格负向约束（例如，针对不可执行动作使用错误_输入）来实施物理接地。

- [7] Silin Li, Yuhang Guo, Jiashu Yao, Zeming Liu 和 Haifeng Wang. 2025. HomeBench: 在智能家居中使用有效指令和无效指令, 跨单设备与多设备评估大语言模型。载于《第63届计算语言学协会年会论文集》(第1卷: 长论文), 第12230–12250页, 奥地利维也纳: 计算语言学协会。
- [8] King, E., Yu, H., Lee, S. 和 Julien, C., “‘准备一场派对’: 借助大语言模型探索更智能的智能空间”, *arXiv 电子预印本*, 文章编号 arXiv:2303.14143, 2023. DOI: 10.48550/arXiv.2303.14143.[9] Singh, I., Blukis, V., Mousavian, A. 等. ProgPrompt: 利用大语言模型为情境化机器人任务规划生成程序. *Auton Robot* 47, 999–1012 (2023). <https://doi.org/10.1007/s10514-023-10135-3>[10] Tuo An, Yunjiao Zhou, Han Zou, Jianfei Yang. IoT-LLM: 一种增强大语言模型基于真实世界传感器数据进行推理的框架. *Patterns*, 第7卷, 第1期, 2026, 101429, ISSN 2666-3899, <https://doi.org/10.1016/j.patter.2025.101429>.[11] S. Mo, R. Salakhutdinov, L.-P. Morency 和 P. P. Liang. “IoT-LM: 面向物联网的大型多感官语言模型”, *arXiv 预印本 arXiv:2407.09801*, 2024.
- [12] M. Abugurain 和 S. Park. “将消歧与用户偏好融入用于机器人运动规划的大语言模型中”, *arXiv 预印本 arXiv:2404.14547*, 2024.[13] Calò, T., De Russis, L. 通过多模态指令消歧增强智能家居交互. *Pers Ubiquit Comput* 28, 985–1000 (2024). <https://doi.org/10.1007/s00779-024-01827-3>[14] Ye Dong, Yan Lin Aung, Sudipta Chattopadhyay 和 Jianying Zhou. “ChatIoT: 面向物联网的基于大语言模型并结合检索增强生成的安全助手”, *arXiv 电子预印本*, arXiv:2502.09896, 2025年2月. DOI: 10.48550/arXiv.2502.09896.[15] Xinyu Huang, Leming Shen, Zijing Ma 和 Yuanqing Zheng. “通过定制化小语言模型迈向隐私保护与个性化智能家居”, *IEEE Transactions on Mobile Computing*, pp. 1–16, 2026, DOI: 10.1109/TMC.2026.3654976.[16] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan 和 Yuan Cao. “ReAct: 协同语言模型中的推理与行动”, *arXiv 预印本 arXiv:2210.03629*, 2022.