

PEC-Home: 智能家居中渐进省略指令的解读

单映宇¹, 刘泽明², 李思霖¹, 钱博傲¹, 姚家树¹, 郭宇航^{1†}, 王海峰³北京理工大学²北京航空航天大学³百度公司

†通讯作者邮箱: shanyingyu@bit.edu.cn, guoyuhang@bit.edu.cn

摘要

大语言模型 (LLMs) 的最新进展赋予了家庭助手自然语言交互能力。然而, 当前的助手忽视了在人类对话中, 随着共享上下文的积累而发生的渐进省略现象, 这种省略是为了实现高效沟通。因此, 当前的助手仍然难以准确解读此类省略性表达, 这限制了其在现实应用中的有效性。在实际智能家居场景中, 助手面临由省略性指令引发的两大挑战: (1) 由多用户间不同环境预期导致的指代歧义; 以及 (2) 由用户偏好随时间演变或随环境变化而产生的意图歧义。为应对这些挑战, 我们提出了 PEC-Home, 这是首个专门为解读智能家居中渐进省略指令而设计的模拟家庭数据集。在包括GPT-4o在内的多种大语言模型上进行的大量实验表明, 现有的家庭助手难以仅凭省略性指令执行用户期望的操作。即使配备了存储和检索用户对话历史的工具, 其执行准确率仍低于使用完整指令所能达到的水平。我们的代码和数据集可在 <https://github.com/BITHLP/PEC-Home> 获取。

1 引言

家庭助手通过直观、上下文感知的支持, 自动化日常家务任务并增强用户交互, 无缝融入日常生活 (Weiser, 1999)。具体而言, 其自动化带来了更高的便利性 (Ur 等人, 2014)、优化的能源使用 (Sepasgozar 等人, 2020; Gupta 等人, 2020) 等等。

在前大语言模型时代, 家庭助手主要专注于执行预定义的规则和模式




图 1: PEC-Home 的一个示例。多用户偏好展示了家庭成员之间对“舒适温度”定义冲突导致的指代歧义, 而动态用户偏好则表明了由环境变化引起的意图歧义。

识别任务, 例如家庭日常自动化 (Dey 等人, 2006; Ur 等人, 2014) 和活动预测 (Tax, 2018; Kim 等人, 2017; Khraief 等人, 2019)。尽管这些助手实现了家庭自动化, 但它们从根本上缺乏通过自然语言与用户交互的能力。

大语言模型 (Vaswani et al., 2017) 的出现, 通过实现跨领域的自然语言理解, 彻底革新了家庭助手 (Achiam et al., 2023; Touvron et al., 2023; DeepSeek-AI et al., 2024)。近期基于大语言模型的家庭助手, 如 Sasha (King et al., 2024) 和 SAGE (Rivkin et al., 2024), 在面对诸如“让屋里别那么冷”这类指令时, 展现了改进的设备控制能力。然而, 这些基于大语言模型的助手在静态、单用户假设下运行, 或将动态的用户指令转变过度简化为仅仅是明确或模糊的状态, 忽视了从明确到省略的渐进性转变。

认知科学研究表明，人类在与熟悉的伙伴进行重复交互时，会自然而然地形成独特的、日益省略的惯例（Krauss and Weinheimer, 1964; Zwaan and Radvansky, 1998; Hawkins et al., 2020）。由于忽视了这一现象，当前的家庭助手在处理自然省略的指令方面存在不足，阻碍了用户像与人类伙伴交互那样高效、直观地与它们互动。这一局限从根本上削弱了家庭助手提供直观、上下文感知支持的最终目标。

为应对这一局限，我们提出了 PEC-Home，这是首个专门为模拟智能家居中的渐进省略指令而设计的模拟家庭数据集。在实际场景中，渐进省略指令的解读面临两大核心挑战（如图1所示）：由多用户偏好冲突引发的指代歧义（例如，家庭成员之间对“舒适温度”定义存在冲突），以及动态用户偏好中的意图歧义，即先前明确的指令（例如，“将加湿器设为自动模式”）会随着环境变化逐渐失去具体性。PEC-Home 包含来自 1,424 个角色的 1,780 段对话（Zhang et al., 2018），为增强和评估基于 LLM 的家庭助手的性能提供了一个新颖且更实用的视角。

为了评估当前基于 LLM 的家庭助手在解读渐进省略指令方面的有效性，我们在 PEC-Home 上进行了广泛的实验。我们研究了一系列大语言模型，使用零样本提示和上下文学习来评估它们仅凭省略性指令执行用户预期操作的能力。结果表明，所有被评估的大语言模型都无法可靠地解读这些省略性指令。此外，我们通过外部工具、用于访问对话历史的检索增强生成（RAG）或旨在提升指令解读能力的微调来增强大语言模型。然而，我们的实验表明，即使是像 GPT-4o 这样的最先进模型，在处理省略性指令时也无法保持其在完整指令上取得的性能，这突显出现有方法的局限性。

- 据我们所知，我们是首个在人与家庭助手交互中识别出渐进省略式

指令解释任务的研究。

- 为便于研究此任务，我们引入了 PEC-Home，这是首个模拟家庭数据集，用于建模从显式指令到省略性指令的渐进转变。
- 我们在 10 个不同大语言模型上的实验结果表明，所有模型在解释渐进省略指令时都经历了显著的性能下降。即使通过工具集成、检索增强生成和微调等增强手段，包括 GPT-4o 在内的这些模型仍无法在高度省略命令上实现可靠的执行准确率。

2 相关工作

2.1 前大语言模型时代家庭自动化系统

前大语言模型时代的家庭助手本质上是基于规则或机器学习算法的家庭自动化系统。在最早的方法中，Dey 等人 (2006) 提出了 iCAP，这是一个基于规则的系统，允许用户创建规则来自动化家庭设备。类似地，Ur 等人 (2014) 探索了触发-动作编程，使用户能够创建自定义自动化规则（例如，“如果是下午 6 点，则开灯”）。

机器学习的发展使得家庭自动化系统能够整合多种算法，包括用于基于情感的自动化的支持向量机（Jaihar 等人, 2020），用于老年人跌倒检测的卷积神经网络（Khraief 等人, 2019），以及用于多用户环境中下一活动预测的长短期记忆网络（Kim 等人, 2017）。Suman 等人 (2022) 研究了基于强化学习的智能家居如何影响人类行为。类似地，Gupta 等人 (2020) 提出了一个旨在优化智能家居功耗的多目标强化学习框架。

PEC-Home 与前大语言模型时代的自动化系统有着根本区别，它从基于规则的自动化和单任务模式识别，转向了由自然语言驱动的渐进式椭圆指令解析。

2.2 基于大语言模型的家庭助手

人类常常通过直觉的语义关联，将抽象概念（例如‘舒适’）与设备特定动作（例如‘打开空调’）联系起来（King 等人, 2024）。大语言模型展现出理解人类意图背后具体动作的能力（He 等人, 2024）。这种

Ellipsis Level	Example	Components
Level 1	"Hey, could you turn on the bedroom air conditioner and set the temperature to 26 degrees at 10:00 PM tonight? I'm heading to bed soon and want it comfortable."	<i>All components clear</i>
Level 2	"Hey, can you set the air conditioner to 26 degrees at 10:00 PM ? Getting ready for bed and want it nice and cool."	<i>Room omitted</i>
Level 3	"Can you do something with the air conditioner before I sleep ? Make it comfortable for tonight."	<i>Operation & Parameters omitted</i>
Level 4	"Hey, you know the air conditioner , right? Could you take care of it for me tonight?"	<i>Only device specified</i>

Components:  room  device  operation  operation parameters

图2：跨越四个等级（等级1–等级4）的渐进省略式用户指令示例，阐明了既定标准以及对四个核心组件（房间、设备、操作和操作参数）的系统性省略。我们为**房间**、**设备**、**操作**和**操作参数**着色。需要强调的是，图中的示例经过简化以便于理解。

能力启发了近期研究，将大语言模型集成到解决模糊指令的任务中。

Sasha (King等人, 2024)，一个基于大语言模型的智能家居助手，通过迭代推理为信息不足的用户命令生成行动计划。Rivkin等人 (2024) 提出了一个基于大语言模型的智能体 SAGE，它能动态生成提示树和工具链以灵活处理用户请求。Yin等人 (2024) 介绍了 Harmony，一个利用本地可部署大语言模型来满足用户需求的框架。AwareAuto (Shi等人, 2024)，首个利用大语言模型将用户表达与智能家居自动化连接起来的终端用户编程系统。

与先前研究聚焦于模糊指令不同，我们的工作明确了渐进省略性指令解释这一任务，该任务在长期交互中直观地浮现出来。

3 问题定义

家庭助手的最终任务是在智能家居环境 H 中，于轮次 t 解读用户的指令 u_t 。每条指令（可能是明确的或省略的）都必须被准确地映射到一个具体的、可执行的助手响应 a_t 。该响应通常采用 $r_i.d_j.m_k(\theta)$ 的形式，指明一个目标房间 r_i 、一个设备-方法 $d_j.m_k$ 以及参数 θ 。

虽然基线方法（例如，基于提示的方法）仅使用

当前指令和家居状态来执行此映射， $f_{\text{baseline}} : (u_t, H) \rightarrow a_t$ ，但解释省略指令的挑战需要利用上下文信息。这主要涉及对话历史， $C = \{(u_1, a_1) \dots, (u_{t-1}, a_{t-1})\}$ ，从而催生了诸如 $f_{\text{advanced}} : (u_t, C, H) \rightarrow a_t$ 等高级解释方法。

在实际智能家居场景中，助手面临由省略指令引起的两大挑战：(1) 多用户偏好，其主要涉及利用选定的用户特定对话历史 C_l 来映射 $f_{\text{multi}}(u_t, C_l, H) \rightarrow a_t$ ；以及(2) 动态用户偏好，其通过函数 $f_{\text{dyn}}(u_t, C_l^t, H, S_t) \rightarrow a_t$ 来适应环境状态 C_l^t 和传感器数据 S_t 。我们在附录C.1中提供了更详细的问题定义。

4 PEC-Home

PEC-Home(ProgressivelyElliptical Commands Dataset for Smart Homes) 包含 1,780 段对话，涉及来自 PersonaChat 的 1,424 个独特角色 (Zhang et al., 2018)。每段对话包含 4 轮逐渐变得更加省略的聊天。PEC-Home 旨在捕捉和模拟协作式沟通中用户命令的渐进省略，这是认知科学中一个被深入研究过的现象 (Krauss and Weinheimer, 1964; Clark and Wilkes-Gibbs, 1986; Hawkinset al., 2020)。为了捕捉这种从明确到省略的渐进转变的不同方面，PEC-Home 被划分为

两个部分：1) **多用户偏好** 和 2) **动态用户偏好**。在本节中，我们将全面描述 PEC-Home 的收集过程，与现有数据集进行详细比较，并完整呈现其统计数据。

4.1 数据集收集

虚拟环境构建我们构建了一个包含12种类型设备的虚拟家庭环境，涵盖了照明、加湿器等常见设备类别。每个设备都配备了多种个性化的可执行方法，总计超过50种不同的方法。所有设备及其可执行方法的完整列表见附录B.1。为了模拟真实场景，这些设备分布在虚拟环境的多个房间中。每个房间内设备的详细列表可在附录B.1中找到。总计有超过350个个性化方法被分配到不同的房间，确保了我们的数据集的多样性和场景覆盖的全面性。

用户指令生成基于此虚拟环境，我们首先生成了函数调用式设备操作。在此基础上，我们为每个用户设定了独特的角色，并生成了符合其偏好的个性化参数。对于多用户偏好，我们随机选择了三个不同的用户组成一个家庭。对于动态用户偏好，我们在每个设备方法内为每个用户生成了两个偏好参数，分别对应不同的环境状态。我们确保所有操作都包含可记忆的个性化参数。

PEC-Home 中用户指令省略程度的递增旨在反映真实人类交流中观察到的模式。先前的研究（Krauss and Weinheimer, 1964）表明，当对话者反复提及同一对象时，在协作过程中，他们的指代会变得更加省略。最初的详细描述会通过省略在共享上下文中已相互确立的元素而逐渐缩短，最终收敛为简短的标签。为了捕捉用户与助手交互中从明确指令到省略性指令的这种渐进转变，PEC-Home 的省略级别是通过逐步减少指令中的明确信息量来构建的。受 King 等人（2024）的启发，该研究识别了智能家居指令的四个核心组件：**房间、设备、操作和操作参数**（例如，‘亮度

设置为 3’），我们通过省略这些组件来定义四个省略级别。为确保数据质量并最大限度地减少人工工作量，我们利用 GPT-4o 基于函数调用式操作和用户角色生成自然语言指令，确保其清晰、语法准确，并与日常对话风格保持一致。定义四个级别如下：

- **第一级：**用户指令包含全部四个核心组件。
- **第二级：**由于时间和空间等基本上下文要素通常在人类交流中引入事件前就已确立（Zwaan and Radvansky, 1998），我们假设用户在交互中首先确立空间位置。根据先前关于概念约定和共同基础的研究（Brennan and Clark, 1996; Clark and Wilkes-Gibbs, 1986），一旦这种空间指称通过先前的指令被共同确立，在同一空间内为后续指令重复它就显得冗余。因此，我们在这一级省略**房间**信息。
- **第三级：**先前研究（Carroll, 1980）发现，用户语言中的描述性修饰语会随时间推移逐渐被省略。在移除位置信息后，剩余的修饰语主要包括明确的**操作和操作参数**。因此，我们在这一级省略这些描述性成分。
- **第四级：**根据交互常趋于形成独特的共享指称这一发现（Krauss and Weinheimer, 1964），此级别的指令仅明确指定设备，模拟指称协作者最终达成的状态。

用于引导大语言模型生成各层级指令的提示经过了人工审查和调整，以确保生成的指令符合既定标准。渐进省略性指令的详细示例见图2，用于引导GPT-4o生成指令的具体提示详见附录B.2。

质量评估受Zeng等人（2024）启发，我们采用人工抽样与验证流程来验证我们操作生成过程的可靠性。三位研究生研究员对随机抽取的500个函数调用式设备操作进行了人工评估。结果表明，100%的操作是正确的，且96%的操作能恰当

数据集	程序省略	多偏好	动态偏好	长交互	人设	人设规模	总计
IFTTT(Yu 等人,2021)	✗	✗	✗	✗	✗	0	50,000+*
Sasha (King 等人, 2024)	✗	✗	✗	✗	✗	0	60
SAGE(Rivkin 等人, 2024)	✗	✗	✗	✗	✓	3	50
PEC-Home (本工作)	✓	✓	✓	✓	✓	1,424	7,120

表1: 现有模拟家庭数据集的比较。关键特性包括渐进省略指令 (Prog. Ellipsis)、多用户偏好 (Multi Pref.)、动态用户偏好 (Dynamic Pref.)、长期交互支持 (Long-Inter.) 和角色规模 (Pers. Size)。* IFTTT数据集使用硬编码的 ‘If This Then That’ 格式, 这与其他数据集 (Sasha、SAGE、PEC-Home) 中使用的自然语言指令不同。

统计	多用户偏好				动态用户偏好			
	Lv1	Lv2	Lv3	Lv4	Lv1	Lv2	Lv3	Lv4
平均词元数	42.08	34.54	33.88	28.43	42.10	34.70	33.87	28.11
指令数量	1,068	1,068	1,068	1,068	712	712	712	712
房间 (%)	99.34	1.59	1.03	12.36	99.02	1.26	0.98	11.10
设备 (%)	98.97	95.69	82.30	91.29	98.60	96.63	79.92	91.57
操作 (%)	91.48	79.49	26.40	4.49	90.73	77.25	26.54	6.04

表2: PEC-Home在两种任务 (多用户偏好与动态用户偏好) 下, 不同省略级别 (等级1-等级4) 的统计数据。核心组件百分比反映了用户命令中房间、设备和操作规范的呈现情况。

与环境状态保持一致, 这凸显了我们操作生成方法的高准确性与可靠性。为确认我们用户指令生成框架的可信度, 同样的三位研究员手动评估了200段涉及多个渐进省略指令的对话。结果显示, 94.5%的这些指令符合既定标准, 证明了整个流程的可靠性。

4.2 对比

表1将PEC-Home与现有的模拟家居数据集进行了比较, 突显了其独特贡献。与现有数据集不同, PEC-Home专门设计用于模拟从显式到省略性的自然转变, 这种转变源于长期的人机交互。在实际智能家居场景中, 解读此类渐进性省略指令存在两大核心挑战 (如图1所示)。为解决这些问题, PEC-Home不仅捕捉了这些模糊性, 还提供了个性化的长期交互数据, 以促进对渐进性省略指令解读的研究。

4.3 统计数据

表2 汇总了PEC-Home数据集在两项任务上的统计数据: 多用户偏好-

与动态用户偏好。两项任务均显示出从等级1到等级4平均令牌数量减少的明显趋势, 这表明用户指令逐渐变得更短且更具省略性。此外, 随着指令变得更加省略, 房间、设备和操作组件的百分比也随之下降, 进一步支持了指令正变得更加省略且更不具体的观点。

缺少操作参数组件的统计数据, 是因为存在一些高度常见的参数, 如 “up”、 “sleep” 等。这些词语频繁出现在用户命令中, 难以准确追踪。此外, 与时间相关的参数通常以12小时制 (例如 “11:30 PM”) 而非24小时制出现, 这进一步增加了精确识别时间相关参数的难度。因此, 我们没有提供操作参数组件的统计数据。

5 实验

5.1 实验设置

模型我们选取了多个开源和闭源大语言模型进行综合评估 (Zhuang等人, 2023; Wang等人, 2024a)。具体而言, 开源模型包括: Llama-3.1-8B-Instruct (AI@Meta, 2024)、Mistral-7B-

方法	多用户偏好								动态用户偏好							
	Lv1		Lv2		Lv3		Lv4		Lv1		Lv2		Lv3		Lv4	
	EA	F1	EA	F1	EA	F1	EA	F1	EA	F1	EA	F1	EA	F1	EA	F1
LLaMA3-8B																
零样本	45.04	7.87	6.80	1.12	1.94	0.56	2.21	36.66	6.32	5.83	0.56	0.95	0.28	0.96		
ICL	79.21	75.57	10.49	10.71	2.81	4.29	1.40	5.49	74.58	72.18	7.87	9.23	1.40	2.94	0.84	3.93
RAG	73.97															
Mistral-7B																
零样本	58.43	6.84	5.98	1.22	1.06	1.31	1.56	57.16	6.60	5.03	1.26	0.49	0.56	0.62		
ICL	90.36	77.77	16.11	15.63	2.81	3.79	0.66	4.57	88.76	79.32	19.52	17.83	2.25	4.59	1.12	4.89
RAG	88.76															
Gemma2-9B																
零样本	48.41	8.33	9.30	0.84	3.36	0.28	3.43	44.94	8.15	9.02	0.56	1.82	0.28	3.26		
ICL	93.26	75.33	16.20	13.18	2.53	3.63	0.66	4.25	91.85	77.55	15.87	12.57	1.97	3.73	0.56	4.57
RAG	92.60															
Gemma2-27B																
零样本	48.60	6.93	7.93	1.03	2.77	0.94	2.70	45.51	7.44	8.22	0.56	1.47	0.28	2.40		
ICL	93.63	77.80	15.36	14.02	2.81	4.82	0.84	5.25	91.01	78.25	13.90	11.01	1.97	3.21	0.84	4.32
RAG	91.95															
Qwen2.5-7B																
零样本	54.59	9.46	9.65	0.94	2.43	0.66	3.16	54.21	9.76	0.70	1.03	0.28	1.51			
ICL	88.58	83.95	15.45	12.42	2.62	3.61	1.22	4.85	86.94	80.10	17.42	13.69	2.25	3.85	1.40	4.89
RAG	91.76	87.25	89.79	85.18	64.04	65.05	48.50	53.94	93.68	86.88	91.57	85.97	52.67	57.17	43.40	50.56
Qwen2.5-14B																
零样本	50.94	8.71	9.50	2.06	3.38	1.31	3.60	38.48	8.00	9.71	0.98	2.97	0.84	3.36		
ICL	85.86	74.83	10.67	10.87	2.62	3.98	1.69	4.79	81.88	71.18	12.08	12.68	2.67	4.14	1.97	3.98
RAG	88.11															
Qwen2.5-32B																
零样本	55.06			2.15	5.24	1.12	4.75	50.14	9.27	11.19	1.40	3.73	1.12	4.33		
ICL	92.13	89.89	14.23	14.14	2.15	4.52	1.69	4.22	88.20	85.35	6.46	5.93	1.55	2.20	1.26	2.91
RAG	89.14															
Qwen2.5-72B																
零样本	39.32	7.68	9.87	2.62	4.67	1.97	3.83	34.27	7.16	9.61	2.39	4.44	1.69	3.74		
ICL	89.42	88.11	15.72	13.17	4.03	4.41	2.25	4.46	88.90	75.76	16.29	15.90	2.81	4.58	2.11	3.91
RAG	95.51															
GPT-4o																
零样本	55.99	5.06	6.20	1.03	3.07	1.31	2.68	52.81	5.62	7.21	1.12	4.03	0.70	4.63		
ICL	92.98	90.25	14.75	14.94	3.37	5.74	1.40	5.25	93.26	92.02	17.98	17.86	3.46	5.85	1.69	6.18
RAG	93.07	90.98	92.70	90.72	76.05	77.69	55.71	64.21	91.57	82.23	88.34	78.97	61.24	65.53	50.70	58.47
DeepSeek-V3																
零样本	55.15			2.81	4.72	2.06	5.18	52.81	6.74	8.69	1.40	2.59	1.69	3.37		
ICL	92.79	89.42	13.02	11.84	3.18	4.41	1.78	5.13	92.84	88.43	4.78	4.85	1.69	2.01	0.98	4.55
RAG	94.10															

表3：多用户偏好与动态用户偏好在不同省略级别下的性能比较。结果使用执行准确率（EA）和F1分数（F1）进行评估，其中橙色表示最佳性能，紫色表示次佳性能。0-Shot、ICL和 别指代零样本提示、上下文学习 增强生成。

Instruct-v0.3 (Jiang等人, 2023)、谷歌的Gemma系列 (gemma-2-9b/27b-it) (Team等人, 2024)、Qwen2.5系列 (Qwen2.5-7B/14B/32B/72B-Instruct) (Yang等人, 2024)，以及DeepSeek-V3

(深度求索等人, 2024)。对于闭源模型，我们选择GPT-4o (Achiam等人, 2023)。我们排除了推理模型，因为基于LLM的助手需要快速响应，而此类模型通常

会因首先生成推理轨迹而引入延迟。

方法我们对上述提到的大语言模型进行了零样本提示、上下文学习和检索增强生成的实验。具体实现细节请参阅附录C。

5.2 指标

遵循先前基于LLM的家庭助手（Shi等人，2024；Rivkin等人，2024）和代码生成任务（Chen等人，2021；Yu等人，2018）的做法，我们使用**执行准确率（EA）**作为主要指标，以评估家庭助手在执行用户指令方面的性能。具体而言，家庭助手的正确执行被定义为：在我们的虚拟环境中，生成精确的设备控制操作以准确满足用户的命令。

为了评估家庭助手在执行操作时的操作准确率，我们采用**F1分数**（Devlin等人，2019；Wang等人，2024b）。计算F1的具体公式在附录C.2中提供。

5.3 结果

表3展示了在PEC-Home上的实验结果。从结果中可以得出几个结论。

结果表明，没有模型能够仅基于省略性指令就准确执行用户意图的操作。即使通过RAG增强以访问对话历史，这些模型在省略性指令上的性能也无法与使用完整指令时达到的水平相匹配。具体对于RAG方法，虽然对话历史提供了一些帮助，但随着指令变得更为省略，正确执行用户操作的性能仍然会下降。

虽然增加模型参数可以增强模型利用对话历史进行指令解释的能力，但在处理高度省略命令时，这一优势会急剧下降。实验结果表明，尽管更大的模型（例如Qwen2.5和Gemma2系列）在省略程度较低的指令（等级2）上表现出性能提升，但这些增益在面对高度省略命令时迅速减弱。即使是像GPT-4o这样的SOTA模型，在上下文学习模式下，处理等级4指令时的表现也不及一些配备了RAG的较小模型。这强调了**仅仅增加参数规模并非一种充**

分的策略，无法在面对省略性指令时准确执行用户意图操作。

执行准确率和F1分数揭示了不同省略级别下的不同失败模式。在省略程度较低的指令上，执行准确率通常高于F1分数。这种差异主要归因于两个因素：首先，如附录C.2所述，执行准确率不要求输出格式严格正确，这与F1分数不同，后者突显了当前大语言模型在遵循精确要求格式方面的局限性。其次，模型可能出现“过度执行”现象，即它们正确完成了核心指令，但也生成了额外的操作，从而降低了F1分数但不影响执行准确率。相反，在高度省略命令上，执行准确率往往低于F1分数。这种现象通常发生是因为模型走了“捷径”。例如，对于“打开灯并将亮度设置为4”这样的指令，模型可能只生成更简单的“打开_”操作。这种部分匹配的简单操作可以提高F1分数，但执行准确率得分仍然很低，导致观察到这两个指标之间的差异。

6 分析

在本节中，我们通过开展三项额外的研究问题（RQs）来扩展分析，以进一步探究省略指令的解释。这些研究问题旨在系统性地探索影响助手解析省略指令能力的关键因素，重点关注**记忆管理（研究问题1）、模型优化（研究问题2）以及外部工具集成（研究问题3）**。实验详情请参阅附录C，全面的错误分析见附录D。




图3: Sasha在Qwen2.5-7B-Instruct模型上，于多用户偏好和动态用户偏好场景中，在不同数量的预加载无关内存下的执行准确率。‘内存数量’表示预加载无关内存的数量。

6.1 研究问题1：预加载无关内存如何影响解释准确率？

在实际应用中，家庭助手通常需要处理大量指令，外部记忆工具被认为可以提升模型性能（Lewis 等人，2020；Gui 等人，2022）。然而，利用记忆的有效性受到预加载无关记忆数量的影响。图3 展示了 Sasha 的执行准确率，附录中的图5、6和7 则展示了 SAGE、RAG（Qwen2.5-7B）和 RAG（Gemma2-9B）在不同预加载记忆量下的执行准确率。

本节研究预加载无关记忆的数量如何影响解释性能。对于Sasha，当其数据库中不存在无关记忆时，Sasha能有效利用对话历史来提升其对高度省略命令的处理性能。然而，当无关信息被预加载到数据库中时，在所有评估方法中观察到一个普遍趋势：随着指令变得更具省略性，其执行准确率会下降。这一现象突显了当前方法在解释日益省略的指令时，从嘈杂记忆环境中过滤和利用相关历史对话所面临的挑战。




图4：Qwen2.5-7B-Instruct模型在测试数据集中，不同训练步数下的执行准确率。

6.2 研究问题2：微调是否能增强省略命令解析？

微调是将大语言模型适配到特定领域的常用方法。我们将数据集按5:1:4的比例划分为训练集、验证集和测试集，然后使用训练数据集对Qwen2.5-7B和Gemma2-9B模型进行微调。选择这些模型是因为我们的主要实验涉及对Qwen和Gemma模型系列的评估。图4 展示了Qwen2.5-7B上的结果，而附录中的图8 展示了Gemma2-9B上的结果。

我们使用与上下文学习方法相同的提示来指导微调模型的推理。结果表明，虽然微调在低省略度任务上显著提升了性能，但其在高度省略命令上的性能却崩溃了。这种在高度省略任务上的表现与表3中上下文学习方法的结果相似，表明尽管微调有助于解释完整指令，却未能解决解释渐进省略指令这一核心挑战。

方法	多用户偏好			
	Lv1	Lv2	Lv3	Lv4
SAGE	51.40	30.25	15.73	4.49
Sasha	55.34	23.25	37.36	43.26

方法	动态用户偏好			
	Lv1	Lv2	Lv3	Lv4
SAGE	52.00	34.55	18.67	5.33
Sasha	54.33	19.93	38.33	41.33

表4：SAGE和Sasha在Qwen2.5-7B-Instruct上，于多用户偏好和动态用户偏好场景下，针对不同省略程度的执行准确率。

6.3 RQ3：外部工具如何改进省略命令处理？

外部工具的集成已成为当前家庭助手和自主代理的主流（Qiao et al., 2024；Chen et al., 2024；Zhanget al., 2024）。例如，Sasha和SAGE 代表了当前基于LLM的助手两种主流方法。具体实现细节请参阅附录C.1。因此，本节探讨了当前基于工具的家庭助手在PEC-Home中的表现。表4 展示了结果。

与面对完整指令的上下文学习（ICL）方法相比，Sasha和SAGE都存在不足。这表明基于工具的方法在处理基本用户命令时存在困难。在等级2（Lv2）指令中，指令具有中等程度的省略性，Sasha无法决定是否调用外部记忆，导致其执行准确率（EA）分数低于处理更省略的指令时。相比之下，SAGE在所有指令级别上都表现出一贯的较差性能。这些结果表明，虽然基于工具的方法可以处理一些省略性指令，但它们无法始终如一地解析省略性指令。

7 结论

我们明确了在智能家居中解释渐进省略指令这一任务，该任务自然源于人类交流，并且是认知科学中一个被深入研究过的现象。为了促进对这一关键任务的研究，我们引入了 PEC-Home，这是首个专门为解释此类渐进省略指令而设计的模拟家居数据集。我们的实验结果表明，这对当前基于大语言模型（LLM）的助手构成了重大挑战。所有被评估的模型都难以仅凭省略性指令就准确执行用户意图的操作。此外，即使配备了检索增强生成（RAG）、外部工具和微调等先进技术，这些大语言模型（包括像GPT-4o这样的最先进模型），在指令变得更为省略时，与面对完整指令时的性能相比，仍然表现出显著的性能下降。

局限性

我们的虚拟环境涵盖了多种多样的设备，且每个设备都关联着众多方法。这些方法通常附有详细的描述。当将这些描述作为输入提供给模型时，上下文会变得非常长，从而导致更高的计算成本。

此外，由于智能家居环境固有的严格隐私限制，我们无法收集大规模的真实世界用户交互数据。虽然真实的生产数据是理想标准，但目前大规模获取并不可行。为缓解这一局限，我们利用大语言模型进行数据生成，但采取了大量措施以确保模拟对话能忠实反映真实的人类沟通习惯。在数据集构建之前，我们对真实的人-家居交互进行了试点研究，观察到随着共享上下文的增加，用户自然会倾向于省略房间和操作信息。这些基于认知科学和语言学理论的实证发现，直接指导了我们的模拟设计。最后，我们实施了严格的人工介入验证流程，由专家手动评估了随机抽取的50段对话。结果显示，96.5%的生成指令在上下文上是自然的，并符合人类语言模式。通过这些努力，我们确保PEC-Home能够作为一个可靠、高度

真实且保护隐私的代理，用于模拟真实的人-系统交互。

伦理声明

在构建PEC-Home的过程中，我们遵循了严格的伦理标准，并确保所有流程都符合伦理规范。其中的虚拟环境和设备均为人工构建，经过仔细审查和严谨验证，以确保其准确性和可靠性。在生成用户命令后，我们对数据集进行了严格的质量评估，以验证其完整性并确保其符合高标准。因此，我们确信PEC-Home不包含任何冒犯性或带有偏见的内容。此外，所有研究均以坚定的伦理原则承诺进行，确保了透明度和公平性。

致谢

本研究得到中国国家自然科学基金（项目编号U21B2009）的支持。

参考文献

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, 等人. 2023. GPT-4技术报告.*arXiv预印本 arXiv:2303.08774*.
- AI@Meta.2024. [Llama 3模型卡](#).
- Susan E Brennan 和 Herbert H Clark. 1996. 对话中的概念约定与词汇选择. *实验心理学杂志: 学习、记忆与认知*, 22(6):1482.
- John M Carroll. 1980. 社会交流中的命名与描述. *语言与言语*, 23(4):309–322.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, HenriquePonde DeOliveiraPinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman 等人. 2021. 评估在代码上训练的大语言模型. *arXiv预印本 arXiv:2107.03374*.
- Zehui Chen, Weihua Du, WenweiZhang, KuikunLiu, Jiangning Liu, Miao Zheng, Jingming Zhuo, Songyang Zhang, Dahua Lin, Kai Chen, and FengZhao.2024. [T-eval: 逐步评估大语言模型的工具利用能力](#). 载于《第62届计算语言学协会年会论文集（第一卷：长论文）》，第9510–9529页，泰国曼谷。计算语言学协会。

Herbert H Clark 和 Deanna Wilkes-Gibbs. 1986. 指称作为一种协作过程。《认知》，22(1):1-39。

深度求索, 刘爱新, 冯蓓, 薛冰, 王炳轩, 吴伯超, 卢成达, 赵成刚, 邓成奇, 张宸宇, 阮冲, 戴达迈, 郭大雅, 杨德建, 陈德立, 纪东杰, 李二航, 林方云, 戴富聪, 罗富立, 郝广博, 陈冠廷, 李国伟, 张H., 包涵, 徐汉威, 王浩成, 张浩伟, 丁鸿辉, 等。2024。DeepSeek-V3技术报告。预印本, arXiv:2412.19437。

雅各布·德夫林, 张明伟, 肯顿·李, 克里斯蒂娜·图塔诺娃。2019。BERT: 用于语言理解的深度双向Transformer预训练。载于《2019年北美计算语言学协会会议论文集: 人类语言技术, 第1卷(长文与短文)》, 第4171-4186页, 明尼苏达州明尼阿波利斯市。计算语言学协会。

阿尼德·K·戴伊、蒂莫西·索恩、萨拉·斯特伦和贾斯汀·科达玛。2006年。iCAP: 上下文感知应用的交互式原型设计。载于普适计算: 第四届国际会议, PERSVasive 2006, 爱尔兰都柏林, 2006年5月7-10日。会议录 4, 第254-271页。施普林格。

桂良科、王博睿、黄秋源、亚历山大·豪普特曼、约纳坦·比斯克和高剑峰。2022年。KAT: 一种用于视觉与语言的知识增强型Transformer。载于2022年北美计算语言学协会会议录: 人类语言技术, 第956-968页, 美国西雅图。计算语言学协会。

索拉布·古普塔、西丹特·巴姆布里、卡兰·丁格拉、阿伦·巴拉吉·布杜鲁和蓬努朗加姆·库马拉古鲁。2020年。基于多目标强化学习的智能家居环境中以用户为中心的电力优化方法。载于2020年IEEE智能数据服务国际会议 (SMDS), 第89-96页, 美国加利福尼亚州洛杉矶阿拉米托斯。IEEE计算机学会。

Robert D Hawkins, Michael C Frank, and Noah D Goodman. 2020. 重复指称游戏中学习动态的特征刻画。认知科学, 44(6):e12845。

何倩玉, 曾杰, 黄文浩, 陈丽娜, 肖瑾, 何倩曦, 周寻哲, 梁嘉庆, 肖仰华。2024。大语言模型能理解现实世界的复杂指令吗? 载于AAAI人工智能会议论文集, 第38卷, 第18188-18196页。

胡爱德华, 沈业龙, 菲利普·沃利斯, 朱泽远, 李远志, 王亮,

陈伟柱, 等人。2022年。LoRA: 大语言模型的低秩自适应。国际学习表征会议, 1(2):3。约翰·贾哈尔, 尼哈尔·林加亚特, 帕特尔·萨潘·维贾伊拜, 高塔姆·文卡特什, 和基肖尔·P·乌普拉。2020年。使用机器学习算法的智能家居自动化。载于2020年新兴技术国际会议 (INCET), 第1-4页。电气电子工程师学会。阿尔伯特·Q·蒋, 亚历山大·萨布莱罗勒, 亚瑟·门施, 克里斯·班福德, 德文德拉·辛格·查普洛特, 迭戈·德拉斯卡萨斯, 弗洛里安·布雷桑, 吉安娜·伦吉尔, 纪尧姆·朗普尔, 露西尔·索尔尼尔, 莱利奥·勒纳尔·拉沃, 玛丽-安娜·拉肖, 皮埃尔·斯托克, 泰文·勒斯卡奥, 蒂博·拉夫里尔, 托马斯·王, 蒂莫泰·拉克鲁瓦, 和威廉·埃尔萨耶德。2023年。Mistral 7B。预印本, arXiv:2310.06825。

查迪亚·赫拉伊夫, 法乌齐·本扎尔蒂, 哈米德·阿米里。2019。基于动态运动和形状变化的卷积神经网络用于老年人跌倒检测。International Journal of Machine Learning and Computing, 9(6):814-820。

金英基, 安智勋, 李敏硕, 李英熙。2017。一种用于多用户智能空间中下一活动预测的活动嵌入方法。载于2017 IEEE 智能计算国际会议 (SMARTCOMP), 第1-6页。IEEE。

埃文·金、于浩翔、李尚洙和克里斯汀·朱利安。2024年。Sasha: 利用大语言模型在智能家居中进行创造性目标导向推理。《美国计算机学会人机交互、移动、可穿戴与普适技术汇刊》, 8(1)。

罗伯特·M·克劳斯和西德尼·魏因海默。1964年。社会互动中参照短语随使用频率的变化: 一项初步研究。《心理科学》, 1: 113-114。

帕特里克·刘易斯、伊桑·佩雷斯、亚历山德拉·皮克图斯、法比奥·佩特罗尼、弗拉基米尔·卡尔普欣、纳曼·戈亚尔、海因里希·库特勒、迈克·刘易斯、易文韬、蒂姆·罗克塔舍尔、塞巴斯蒂安·里德尔和杜威·基拉。2020年。面向知识密集型自然语言处理任务的检索增强生成。载于《神经信息处理系统进展》, 第33卷, 第9459-9474页。柯伦联合公司。

乔硕飞、张宁豫、方润南、罗宇杰、周王春澍、蒋雨辰、吕成飞和陈华钧。2024年。AutoAct: 通过自我规划从零开始自动学习智能体进行问答。载于《第62届计算语言学协会年会论文集(第一卷: 长论文)》, 第3003-3021页, 泰国曼谷。计算语言学协会。

德米特里·里夫金、弗朗索瓦·霍根、阿迈勒·费里亚尼、阿比谢克·科纳尔、亚当·西格尔、刘学和格雷戈里·杜德克。2024年。通过自主大语言模型智能体实现的AIoT智能家居。IEEE物联网期刊。

萨马德·塞帕斯戈扎尔、雷哈内·卡里米、莱拉·法拉扎迪、法里玛·莫埃齐、萨拉·希罗赞、

- Sanee M. Ebrahimzadeh, Felix Hui 和 Lu Aye. 2020. 智能家居中人工智能与物联网应用的系统性内容综述. 应用科学, 10(9):3074.
- YingtianShi, Xiaoyi Liu, Chun Yu, TianaoYang, ChengGao, Chen Liang, and YuanchunShi. 2024. 弥合智能家居中自然用户表达与复杂自动化编程之间的鸿沟. 预印本,arXiv:2408.12687.
- Shashi Suman, Ali Etemad, andFrancois Rivest. 2022. 智能家居对人类行为的潜在影响: 一种强化学习方法. *IEEE Transactions on Artificial Intelligence*,3(4):567–580.
- Niek Tax. 2018. 在智能家居环境中使用LSTM神经网络进行人类活动预测. 在*2018 14th international conference on intelligent environments (IE)*中, 第40–47页. 电气电子工程师学会.
- Gemma团队, Morgane Riviere, Shreya Pathak, Pier Giuseppe Sessa, Cassidy Hardin, Surya Bhupati- raju, Léonard Hussenot, Thomas Mesnard, Bobak S hahriari, Alexandre Ramé, Johan Ferret, Peter Liu, Pouya Tafti, Abe Friesen, Michelle Casbon, Sabela Ramos, Ravin Kumar, Charline Le Lan, Sammy J erome, Anton Tsitsulin, Nino Vieillard, Pi- otr Stanczyk, Sertan Girgin, and et al. 2024. *Gemma 2: 在实用规模上改进开放语言模型*. 预印本,arXiv:2408.00118.
- Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajwal Bhargava, Shruti Bhosale 等人. 2023. Llama 2: 开放基础与微调聊天模型. *arXiv*预印本 *arXiv:2307.09288*.
- Blase Ur, Elyse McManus, Melwyn Pak Yong Ho 和 Michael L Littman. 2014. 智能家居中的实用触发-动作编程. 载于*SIGCHI*人机交互计算系统会议论文集, 第803–812页.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser 和 Illia Polosukhin. 2017. *注意力机制是你所需要的一切*. 载于神经信息处理系统进展, 第30卷. 柯伦联合公司.
- Hongru Wang, Rui Wang, Boyang Xue, HenlingXia, Jingtao Cao, Zeming Liu, Jeff Z.Pan, and Kam-Fai Wong. 2024a. *AppBench: 针对复杂用户指令规划来自不同应用程序的多个应用程序接口*. 收录于2024年自然语言处理经验方法会议论文集, 第15322–15336页, 美国佛罗里达州迈阿密. 计算语言学协会.
- 王慧明、程丽颖、张文轩、苏德文和李立东. 2024b. *用于少样本命名实体识别的顺序无关数据增强*. 载于《第62届计算语言学协会年会论文集 (第一卷: 长论文) 》, 第7792–7807页, 泰国曼谷. 计算语言学协会. 马克·维瑟. 1999. *面向21世纪的计算机*. *SIGMOBILE*移动计算与通信评论, 3(3):3–11.
- 杨安, 杨宝松, 张北辰, 惠彬源, 郑博, 于博文, 李成远, 刘大衡, 黄斐, 魏浩然, 林欢, 杨健, 涂建宏, 张建伟, 杨建新, 杨佳熙, 周靖人, 林俊旸, 党凯, 卢克明, 鲍克勤, 杨可欣, 余乐, 李梅, 薛明峰, 张沛, 朱琴, 门睿, 林润基, 李天昊, 夏庭宇, 任星璋, 任宣成, 范阳, 苏阳, 张一畅, 万宇, 刘玉琼, 崔泽宇, 张振儒, 邱子涵. 2024. Qwen2.5技术报告. *arXiv*预印本 *arXiv:2412.15115*.
- 姚舜宇、赵杰弗里、余典、杜楠、伊扎克·沙弗兰、卡尔提克·纳拉辛汉和曹原. 2023年. React: 在语言模型中协同推理与行动. 发表于国际学习表征会议 (*ICLR*) 。
- 尹子祺、张明鑫和川原大辅. 2024年. *Harmony: 一个基于本地部署大语言模型、用于响应式管理和行动优化的家庭智能体*. 预印本, arXiv:2410.14252.
- 于浩翔、华杰和克里斯汀·朱利安. 2021年. *通过分析IFTTT配方研究人类如何使用物联网 (IoT) 设备*. 收录于第19届ACM嵌入式网络传感器系统会议论文集, SenSys '21, 第537–541页. ACM.
- 余涛、张瑞、杨凯、安永道弘、王东旭、李子凡、马詹姆斯、李艾琳、姚庆宁、莎内尔·罗曼、张子林和德拉戈米尔·拉杰夫. 2018年. *Spider: 一个用于复杂跨领域语义解析和文本到SQL任务的大规模人工标注数据集*. 收录于2018年自然语言处理经验方法会议论文集, 第3911–3921页, 比利时布鲁塞尔. 计算语言学协会.
- 李增、单映宇、刘泽明、姚家树、郭宇航. 2024. *FAME: 面向事实的多任务模型编辑*. 载于2024年自然语言处理经验方法会议论文集, 第15992–16011页, 美国佛罗里达州迈阿密. 计算语言学协会.
- 张可驰、李佳、李戈、石贤杰、金芝. 2024. *CodeAgent: 通过工具集成智能体系统增强代码生成, 应对真实世界仓库级编码挑战*. 载于计算语言学协会第62届年会论文集 (第一卷: 长论文) , 第13643–13658页, 泰国曼谷. 计算语言学协会.
- 张赛征、艾米丽·迪南、杰克·乌尔班内克、亚瑟·斯拉姆、杜威·基拉和杰森·韦斯顿. 2018年. *个性化对话代理: 我有一只狗, 你呢?*

也养宠物吗? 载于第56届计算语言学协会年会论文集（第一卷：长论文），第2204-2213页，澳大利亚墨尔本。计算语言学协会。

庄宇辰、余越、王宽、孙昊天和张超。2023。
Toolqa: 一个用于大语言模型外部工具问答的数据集。神经信息处理系统进展, 36:50117-50143。

罗尔夫·A·兹万和加布里埃尔·A·拉德万斯基。1998。语言理解和记忆中的情境模型。心理学公报, 123(2):162。

详细问题定义

设一个虚拟智能家居环境表示为：

$$H = \{r_1, r_2, \dots, r_n\} \quad (1)$$

其中每个房间 $r_i \in H$ 包含可操作的设备：

$$D_i = \{d_1, d_2, \dots, d_m\} \quad (2)$$

每个设备 $d_j \in D_i$ 由以下要素定义：

$$d_j = \langle s_j, M_j \rangle \quad (3)$$

其中 $s_j = [s_j^1, \dots, s_j^p]$ 是设备状态向量，
 $M_j = \{m_j^1(\theta_1) \dots, m_j^k(\theta_k)\}$ 是可执行方法集。

给定当前轮次 t 的用户指令 u_t ，对话历史为：

$$\mathcal{C} = \{(u_1, a_1), \dots, (u_{t-1}, a_{t-1})\} \quad (4)$$

其中每对 (u_k, a_k) （对于 $k < t$ ）代表用户指令 u_k 和系统相应的响应 a_k 。

将用户指令 u_t 映射到系统响应 a_t 的方式各不相同：

- 基线系统（例如，基于提示的方法）仅使用家居状态 H 将 u_t 映射到 a_t ：

$$f_{\text{baseline}} : (u_t, H) \rightarrow a_t \quad (5)$$

- 高级系统（例如，RAG）也使用对话历史 $\mathcal{C}$ （公式 4）来对 u_t 进行上下文解释：

$$f_{\text{advanced}} : (u_t, \mathcal{C}, H) \rightarrow a_t \quad (6)$$

模型的输出 $a_t = r_i.d_j.m_k(\theta)$ （目标房间 r_i ，设备-方法 $d_j.m_k$ ，参数 θ ）即为系统的响应。新配对 (u_t, a_t) 将更新对话历史。

A.1 多用户偏好管理

令 $\mathcal{P} = \{p_1, \dots, p_k\}$ 表示用户角色集，其中每个用户 p_l 维护着独立的对话历史：

$$\mathcal{C}_l = \{(u_1^l, a_1^l), \dots, (u_{t-1}^l, a_{t-1}^l)\} \quad (7)$$

高级系统通过以下方式动态选择相关历史记录：

$$\mathcal{C}_l = \text{LLM_Select}(u_t, \mathcal{P}) \in \{\mathcal{C}_1, \dots, \mathcal{C}_k\} \quad (8)$$

操作映射随后变为：

$$f_{\text{multi}} : (u_t, \mathcal{C}_l, H) \rightarrow r_i.d_j.m_k(\theta) \quad (9)$$

A.2 动态用户偏好适应

对于每个用户 p_l ，其对话历史包含两个特定于环境的偏好上下文：

$$\mathcal{C}_l = \{\mathcal{C}_l^{e_1}, \mathcal{C}_l^{e_2}\} \quad (10)$$

其中 e_1 和 e_2 代表不同的环境状态。给定实时传感器数据 S_t ，高级系统会动态选择相关上下文：

$$\mathcal{C}_l^t = \text{LLM_Select}(S_t, \mathcal{C}_l) \in \{\mathcal{C}_l^{e_1}, \mathcal{C}_l^{e_2}\} \quad (11)$$

操作映射关系如下：

$$f_{\text{dyn}} : (u_t, \mathcal{C}_l^t, H, S_t) \rightarrow r_i.d_j.m_k(\theta) \quad (12)$$

B 数据集详情

B.1 虚拟环境详情

本节提供了我们虚拟环境的全面统计数据。表 5 详细概述了虚拟环境中的所有房间，以及每个房间内对应的设备。表 6 列出了完整的设备及其关联的可执行方法，详细说明了每个设备可用的可执行方法。这些表格提供了对虚拟环境布局和设备操作接口的全面理解。

B.2 命令生成详情

在本节中，我们详细说明了用于引导大语言模型生成用户命令的具体提示。表 8 展示了为生成完整且最清晰（Le 1）的用户命令而设计的提示。此外，用于生成更高省略性指令的系统提示在表 9 中提供。我们还在表 11 中提供了提示中设备方法描述的示例。

C 实验

C.1 基线方法实现细节

对于 SAGE 和 Sasha，我们使用由 Rivkin 等人（2024）提供的框架。由于 SAGE 和

房间名称	设备
主卧室	灯、空调、暖气、风扇、空气净化器、香薰机、垃圾桶、加湿器、除湿器、电视
客卧	灯、空调、暖气、风扇、空气净化器、垃圾桶、加湿器、除湿器、电视
客厅	灯、空调、暖气、风扇、空气净化器、香薰机、垃圾桶、加湿器、除湿器、媒体播放器
餐厅	灯、风扇、空气净化器、加湿器、除湿器、垃圾桶
书房	灯、空调、暖气、风扇、空气净化器、加湿器、除湿器、垃圾桶、香薰机
厨房	灯、风扇、垃圾桶、热水器
浴室	灯、暖气、垃圾桶、热水器
阳台	灯、香薰机、垃圾桶、媒体播放器
储藏室	灯、空气净化器、加湿器、除湿器

表5：虚拟环境中所有房间的设备分布。

设备名称	方法
灯	打开_；关闭_；设置_亮度；设置_模式
空调_	打开_；关闭_；设置_温度；设置_模式；设置_风扇_风速；设置_摆风；
暖气	打开_；关闭_；设置_温度；设置_模式；设置_风扇_风速
fan	打开_；关闭_；设置_风速；设置_摆风
空气_净化器	打开_；关闭_；设置_模式；设置_风扇_风速
热水器_	打开_；关闭_；设置_温度；设置_模式
媒体_播放器	打开_；关闭_；播放；暂停；停止；设置_音量；设置_歌曲；设置_艺术家；设置_风格
垃圾桶	pack
香薰机	打开_；关闭_；设置_强度；设置_间隔
加湿器	打开_；关闭_；设置_强度；设置_模式
除湿器	打开_；关闭_；设置_强度；设置_模式
tv	打开_；关闭_；设置_音量；切换_频道；

表6：虚拟环境中设备及其关联可执行方法列表。

Sasha要求大语言模型具备工具调用能力，而在开源大语言模型中，仅Qwen2.5支持原生函数调用能力，因此我们在Qwen2.5系列上进行了评估。

SAGE 作为中央枢纽，SAGE与多个专用工具交互：用于设备控制的智能_设备_工具、用于指令历史记录的记忆_工具，以及用于环境数据收集的天气_工具。智能_设备_工具作为一个独立的智能体，提供包括get_methods()、list_devices()、list_rooms()和execute_command()在内的基本设备管理功能。基于这些多种工具，SAGE动态生成提示树和工具链来处理用户命令。为了优化系统性能，我们精简了工具集，移除了非必要组件，如代码工具和外部交互能力，从而减少了可能对模型决策过程造成的干扰。

Sasha 一个专为智能家居控制设计的智能体。它使用JSON格式与设备通信，并整合记忆与环境数据以增强设备控制能力。

Sasha 利用其计划生成工具，为未充分明确的用户指令生成高质量的行动计划。一旦智能体完成其操作，我们会通过检查设备的最终状态来验证执行是否成功。与SAGE相比，Sasha仅拥有ReAct风格(Yao等人, 2023)的计划工具，而SAGE则拥有多种工具，例如智能_设备_工具、记忆_工具等。

零样本提示 我们使用与上下文学习提示相同的提示，但移除了示例并加入了特定的格式要求。在此方法中，模型无法访问用户的对话历史。

上下文学习我们在表10中提供了上下文学习所使用的提示。针对每个层级的省略性指令，我们都包含了一个示例。在此方法中，模型同样无法访问用户的对话历史。

检索增强生成我们使用向量数据库实现检索增强生成。所有用户命令及相应的生成设备操作都存储在一个数据库中。用户的当前指令被用作查询，以在

错误类型	用户指令	生成指令（红色） / 标准指令（绿色）
房间缺失	“开灯，冷白光，拜托！...”	light.turn_on(), light.set_mode(“冷白光”) 浴室.灯.打开_(), 浴室.灯.设置_模式(“冷白光”)
房间错误	“嘿，你能处理一下香薰机的设置吗？.....”	客厅_香薰机.打开_(), 客厅_香薰机.设置_强度(80) 阳台.香薰机.打开_(), 阳台.香薰机.设置_强度(0)
参数缺失-ing	“嘿，你能处理一下我们讨论过的那个垃圾桶吗？”	dining_room.垃圾桶.打包() dining_room.垃圾桶.打包(18:46)
参数错误	“你能确保在晚上11:30之前关掉加湿器吗？...”	guest_bedroom.加湿器 .在_点关闭(“23:30”) guest_bedroom.加湿器 .在_点关闭(23:30)
忽略历史	“嘿，你能处理一下那个空调吗？...” 历史：“你能让空调启动.....” 历史回复：客人_卧室 .空调_开启_(07:13)	guest_卧室.空调_ .在_点(07:00)开启 guest_卧室.空调_ .turn_on(07:13)

表7: PEC-Home中的五种代表性错误类型：房间缺失、房间错误、参数缺失、参数错误和忽略历史。用户命令中提到的核心组件以橙色显示，大语言模型生成的错误响应以红色显示，标准答案以绿色显示。

对话历史中进行搜索，所有实验均采用固定的 $\text{top}k = 3$ 设置。为了评估预加载无关记忆的影响，我们还额外收集了五十条来自用户的自然语言指令，并随机引入其中的 5、10 和 20 条作为无关内存。

C.2 指标

F1分数的计算方式如下：

$$Precision = \frac{\text{operation_correct_num}}{\text{operation_pred_num}} \quad (13)$$

$$Recall = \frac{\text{operation_correct_num}}{\text{operation_gold_num}} \quad (14)$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (15)$$

其中，精确率衡量的是在所有预测操作中正确预测操作所占的比例，而召回率衡量的是在所有真实操作中正确预测操作所占的比例。

与F1分数不同，**执行准确率 (EA)** 的衡量方式是提取模型生成的操作，而不要求模型的输出格式严格正确。（在本文中，模型需要将其生成的指令用{}括起来；然而，对于EA计算，我们只考虑生成的操作在功能上是否正确，假设格式问题可以

在后续作为工程问题解决。）对于F1分数，我们则采用更严格的要求，即生成指令的格式也必须正确。

执行准确率（EA）评估模型生成操作的功能正确性，而不强制执行严格的输出格式。在本工作中，尽管模型被指示将生成指令包含在花括号（{}）内，但EA仅考虑预测的操作是否能在环境中实现用户预期的操作执行，将语法不一致性视为可以在事后解决的工程问题。相比之下，F1分数采用更严格的标准，要求输出不仅功能正确，还必须严格遵守规定的格式。

这种双层评估策略通过将语义理解与表层格式合规性解耦，实现了细致入微的分析。执行准确率反映了模型解释自然语言指令并识别适当设备操作的核心能力，不受格式错误影响。同时，F1分数通过衡量对下游执行所需的接口标准的符合程度，捕捉了实际部署的可行性。这些指标的结合提供了对模型核心解释能力和实际效用的更全面评估，既能评价其语义理解，也能评价其生成适合现实世界部署的输出能力。

ment.

C.3 实现细节

开源模型的实验在NVIDIA A100 GPU和NVIDIA A800 GPU上进行。对于GPT-4o，我们使用了OpenAI提供的应用程序接口。在微调Qwen2.5-7B-Instruct时，我们在NVIDIA A800 GPU上使用低秩自适应技术（Hu等人,2022）进行了微调实验。低秩自适应的超参数配置如下： $r=16$, $\text{lo}ra_alpha=32$, $\text{learning_rate}=1e-5$ 。

D 错误分析

我们进行了全面的错误分析，以识别解释渐进式省略指令所面临的挑战。受Yin等人(2024)；Yu等人(2018)的启发，我们归纳了五种代表性的错误类型，如表7所示。为确保超越自动化指标的准确性并提供定量理解，我们对Qwen2.5-7B (RAG)结果中随机抽样的100个错误案例进行了人工根因分析。主要失败模式的分布详情如下：

忽略历史 (38%)：这是最常见的错误。当模型未能利用从数据库中检索到的对话历史时发生。模型孤立地处理省略指令，未能检索到先前轮次中已确立的实体（例如，空调）或状态。

房间缺失 (22%)：当用户指令指定了设备的操作但省略了其位置时发生。操作本身是正确的，但模型未能推断出空间上下文（例如，输出turn_on时未指定卧室）。

房间错误 (17%)：当模型因上下文切换模糊而推断出错误房间时发生。

参数错误 (13%)：涉及参数格式或赋值不正确。虽然某些类型转换（例如，字符串转整数）看似简单，但模型常常会幻觉出错误的格式（例如，生成“11:30 PM”而非所需的“23:30”）或误解模糊的值（例如，“稍微暖和一点”）。在基于API的严格家庭自动化中，遵循精确的模式至关重要；“差不多”的参数通常会导致执行失败（API错误）。因此，严格地将这些情况视为错误，对于评估智能体的

鲁棒性至关重要。

参数缺失 (10%)：源于设备操作参数提取不完整。

需要指出的是，在此次分析中，结构格式错误并未单独归类。这是因为，在执行准确率计算过程中，那些操作正确但存在语法层面格式错误的模型响应仍被视为正确。此类常见的结构错误包括：函数调用式操作缺少必需的花括号 {}，或错误地使用了其他分隔符，如单引号 ‘ ’ 或尖括号 <>。这种宽松处理严格适用于外部语法，而API参数值则必须如上文所述保持精确。




图5: SAGE 在 Qwen2.5-7B-Instruct 模型上的执行准确率，展示了在多用户偏好和动态用户偏好场景下，随预加载内存数量变化的情况。‘内存数量’表示预加载无关内存的数量。




图6: RAG 在 Qwen2.5-7B-Instruct 模型上的执行准确率，展示了在多用户偏好和动态用户偏好场景下，随预加载内存数量变化的情况。‘内存数量’表示预加载无关内存的数量。

提示

请扮演一位房主，正在与智能家居助手进行随意互动。你的任务是生成你会用来指示你的虚拟助手的自然语言指令。一条清晰的指令应包含设备、操作、房间以及触发时间或设置，并且你应确保你生成的指令包含这四个部分。你应融入环境参数，且生成的指令应与环境相关联。请记住，你是发出指令的用户，而非进行响应的助手。确保你的指令多样化，并反映真实用户与虚拟助手自然交流的方式。你只需生成一条指令。

<示例>

以下是一些示例：

设备：除湿器

必需指令：<在_开启(06:53)>

给定人设：<我妈妈是我最好的朋友。我有四个姐妹。我相信美人鱼是真实存在的。我喜欢冰茶。>

美人鱼是真实存在的。我喜欢冰茶。>

环境参数：<“湿度”：70>

回复内容：<“嘿，你能在客厅打开除湿器吗，时间是6:53，可以吗？这里有点太潮湿了。谢谢！”>

...

</示例>

必需指令：给定人设：

环境参数：回复内容：

表8：用于引导大语言模型生成最清晰（等级1）用户指令的提示。手动定义的省略级别说明以橙色显示，少量示例以蓝色显示。




图7：Gemma2-9b-it模型在检索增强生成中，于多用户偏好和动态用户偏好场景下，针对不同预加载内存数量的执行准确率。‘内存数量’表示预加载无关记忆的数量。




图8：Gemma2-9b-it模型在测试数据集中，于不同训练步骤下的执行准确率。

提示

用于生成Lv2用户指令的系统提示：

假设你是一位房主，正在与智能家居助手进行随意互动。你已经给出了一条完整的指令，指定了操作、设备和房间。然后，请使用自然语言和多样化的句子结构，基于上下文假设，给出更简短的后续指令。在你的指令中应排除房间信息，但仍需指定操作、设备以及触发时间/设置。下方提供了聊天历史。请记住，你是发出指令的用户，而不是进行回应的助手。确保你的指令多样化，并反映真实用户与其虚拟助手自然交流的方式。你只需生成一条指令。

用于生成Lv3用户指令的系统提示：

... 第三条指令应是相较于第二条指令更为模糊的版本，使用自然语言和多样化的句子结构。在该指令中，不应包含房间信息，并确保触发时间或设置保持模糊。此外，基于第二条指令，使操作本身也带有一定的模糊性。假设助手已与用户多次互动，并已了解其偏好和习惯。下方提供了聊天历史。...

用于生成Lv4用户指令的系统提示：

... 第四条指令应是最模糊的版本，使用自然语言和多样的句子结构。这次，你应该避免在指令中包含操作、房间或触发时间/设置，仅提及设备。假设助手已与用户多次互动，并已了解其偏好和习惯。聊天历史如下。...

表9：用于引导大语言模型生成其他省略级别的用户指令的提示。手动定义的省略级别的说明以橙色显示。

提示
你是一个控制房屋内设备的AI助手。请根据指示完成以下任务，或仅依据所提供的信息回答以下问题。设备和设备所拥有的方法如下所示，请仅使用提供的方法。仅输出助手指令，并将其用 {} 括起来。请确保任何涉及时间的将它们放在 {} 中。请确保任何涉及时间的参数都以24小时制。例如：使用14:00表示下午2点，而非2:00 PM。使用08:30表示上午8:30，而非8:30 AM。 <设备_方法> 以下提供了控制当前房屋内各设备的方法。 ...（设备方法，表11展示了一个示例。） </设备_方法> <示例> 以下是几个示例，您的输出格式应与示例中的结果保持一致： 提供的示例： 用户_指令：“嘿，你能打开书房里的空调并把温度调到23度？我正在准备完成一些来自我最近展会的文书工作，需要一个舒适的地方来集中注意力。” 助手_指令：study_room.air_conditioner.turn_on(), study_房间.air_conditioner.set_温度(23) ... </示例> <环境> 以下提供当前房间的环境信息。 </environment> 以下是您需要回复的用户指令。 用户指令： 助手_指令：

表10：用于引导大语言模型通过上下文学习生成设备操作的提示。少样本示例以蓝色显示。

示例
灯 灯.打开_开(时间: 可选[字符串] =无, 格式: ‘%H:%M’); 灯.关闭_(时间: 可选[字符串] =无, 格式: ‘%H:%M’); 灯.设置_亮度(亮度: int) (范围: 0 – 4); light.set_mode(mode: str) (选项: [“柔和暖光” 、 “中性光” 、 “冷白光” 、 “日光” 、 “冷光”]);

表11：家庭设备方法示例。