

PromptShield Home: 面向智能家居代理的环境多模态提示注入防御

He Zhang

hpz5211@psu.edu 信息科学与技术学院 宾夕法尼亚州立大学 大学公园, 宾夕法尼亚州, 美国

Feilong Li

lifeilong@chd.edu.cn 运输工程学院 长安大学 西安, 陕西省, 中国

Dingning Long

d
ingningll
@outlook.com 心理学部
北京师范大学 北京, 中国

Yilin Cui

yilincu2
@andrew.cmu.edu 海因茨信息系统与公共政策学院 卡内基梅隆大学 匹兹堡, 宾夕法尼亚州, 美国

Peijun Zhang

ah230zang@163.com 设计信息学研究所 爱丁堡大学 爱丁堡, 英国

张悦文

y
w-
zhang24@mails.tsinghua.edu.cn 未来实验室 清华大学 北京, 中国

徐千曜

x
uqy@mail.tsinghua.edu.cn
清华大学 北京, 中国

Xinyi Fu*

f
uxy@tsinghua.edu.cn
未来实验室 清华大学 北京, 中国

摘要

智能家居助手越来越多地使用能直接感知视频和音频的多模态大语言模型。这引发了一个家庭场景特有的安全性问题: 代理能否区分真实的用户指令与环境或外部来源的内容、电视语音、屏幕文本或仅仅是看起来像指令的旁听对话? 我们推出了 PromptShield-Home, 这是一个涵盖收件人歧义、屏幕/音频注入、健康监测器误触发、混合占用以及合法指令基线的现实智能家居场景试点基准测试, 并利用它来比较三个抽象层: 传统检测器 (L0层)、单多模态大语言模型代理 (L1层; 视觉、视觉+自动语音识别和视听) 以及多代理协调 (L2层; 投票、角色专家、跨模型仲裁)。由于标签分布偏向于不行动, 聚合准确率具有误导性, 一个恒定的始终阻止预测器得分高达82%, 因此我们分别报告了不安全执行率和安全完成率。这两种范式以相反的方式失败: 检测器对所有内容都采取行动, 而每种多模态大语言模型配置都过度拒绝, 几乎不完成任何真实指令, 并且在每种情况下都漏掉了真实跌倒。关键的是, 它们的正确集合是互斥的: 一个总是选择正确层的预言机能达到94.1%, 而最佳单层仅为76.5%。我们将此报告为一个上限, 而非一个系统——尚未实现路由器——并论证家庭代理安全性是

最佳方案是通过学习型路由和传感器融合来实现, 而非用多模态大语言模型替换检测器。

CCS 概念

- 安全与隐私 → 入侵/异常检测与恶意软件缓解; 访问控制;
- 以人为中心的计算 → 交互式系统与工具; 普适与移动计算;
- 计算方法学 → 人工智能。

关键词

环境智能, 提示注入, 多模态大语言模型, 智能家居, 人工智能物联网

ACM 参考文献格式:

He Zhang, Feilong Li, Dingning Long, Yilin Cui, Peijun Zhang, Yuewen Zhang, Qian Yao Xu, and Xinyi Fu. 2026. PromptShield Home: 面向智能家居代理的环境多模态提示注入防御. In *Companion of the 2026 ACM 普适与泛在计算国际联合会会议 (UbiComp Companion '26)*, 2026年10月11日至15日, 中国上海. ACM, 美国纽约州纽约市, 5 pages. <https://doi.org/10.1145/3798063.3837198>

1 引言

智能家居正日益通过联网设备、传感器和自动控制来支持安全性、舒适性、自主性和日常便利性 [2, 4, 6, 22]。然而, 许多已部署的系统仍然依赖于基于规则的自动化和触发-动作编程 (TAP), 当家庭场景涉及多个设备、变化的上下文和复杂的依赖关系时, 这些系统变得难以配置和维护 [7, 14, 17, 20]。

近期的大语言模型和多模态大语言模型提供了更灵活的接口: 它们能够理解自然语言、处理视觉和音频证据、进行上下文推理, 并将高层目标映射到设备操作 [10,

*通讯作者。

请使用 nonacm 选项或 ACM Engage 类以启用 CC 许可。本作
享署名4.0国际许可协议进行许可。UbiComp Companion '26, 2026年10月
11日至15日, 中国上海© 2026 版权所有/作者所有。ACM ISBN
979-8-4007-2533-3/2026/10 <https://doi.org/10.1145/3798063.3837198>



18, 21, 25]。然而, 这种灵活性带来了家庭环境中特有的安全性问题。家庭环境包含许多并非作为指令的环境信号, 包括电视语音、对话、屏幕文字、便签以及其他可见或可听的内容 [11]。多模态大语言模型可能正确地感知到这些信号, 却错误地将其视为用户意图, 从而导致非预期的操作或隐私泄露 [1, 3, 5, 8, 9]。

我们将这种威胁称为环境多模态提示注入: 物理环境中的视觉、音频、文本或跨模态信息被误认为是可执行的用户指令。与直接提示注入不同, 该信号不一定是由攻击者输入模型的; 它可能自然地出现在周围环境中 [12, 19, 26, 27]。因此, 挑战不仅在于感知, 还在于来源归属和操作授权: 代理必须判断观察到的内容是否反映了真实的用户意图, 同时避免因过度谨慎而忽略有效指令或紧急情况 [13]。

为了研究这个问题, 我们提出了 *PromptShield-Home*, 一个面向智能家庭代理的早期安全协调框架和试点基准测试。每个案例都被建模为一个三元、风险感知的决策: 执行、阻断或询问用户。我们比较了三个抽象层: 传统检测器 (唤醒词、姿态和光学字符识别)、在视觉、视觉+自动语音识别和原生视听设置下的单多模态大语言模型代理, 以及通过投票、角色专家和跨模型仲裁进行的多代理协调。我们的试点场景涵盖了受话人歧义、屏幕/音频注入、健康误触发、混合占用、合法指令和占用状态查询。

由于大多数智能家居情境不应触发动作, 聚合准确率具有误导性: 一个恒定的“永不行动”预测器已经能达到82%的准确率。因此, 我们分别评估安全性与实用性。我们的结果表明, 传统检测器过度执行, 而多模态大语言模型则系统性地过度拒绝, 仅完成少量真实指令, 并在每个测试配置中都遗漏了真实跌倒。然而, 它们的正确决策是互补的: 一个基于L0层和视觉多模态大语言模型的预言机达到了94.1%, 而最佳单层仅为76.5%——这是一个上限, 因为尚未实现任何路由器。这表明更安全的智能家居代理应结合路由和传感器融合, 而非用多模态大语言模型替换检测器。

2 方法

问题。智能家居代理必须根据多模态场景证据和一个候选设备动作, 决定是否执行动作, 同时不能将环境或外部来源的内容 (电视语音、屏幕文本、人际对话) 误认为是真实的用户指令。每个实例为 $s_i = (E_i, A_i, z_i)$, 证据为 $E_i = (V_i, U_i, T_i)$ (视频、音频、可选的一行描述), 候选动作为 $A_i = (d_i, a_i)$, 以及隐藏的二进制黄金标签 $z_i \in \{0, 1\}$ 。每一层都会输出

$$\hat{y}_i \in \mathcal{Y} = \{\text{execute, block, ask_user}\}, \quad e_i = \mathbb{I}[\hat{y}_i = \text{execute}],$$

即, 阻断并询问_用户均视为非执行; 无效输出将回退至询问_用户 (永不执行)。

三层比较框架。所有层共享相同的输入、决策空间和指标, 因此安全性与实用性可直接比较。这些层是按委托的语义权威排序的工程分解, 而非现有的分类法; 诸如学习到的收件人或活动识别模型等中间设计缺乏动作级语义, 因此我们预计其




图1: 安全-效用平面。所有单智能体与多智能体配置均位于鲁莽↔过度拒绝对角线上: 传统检测器 (L0层) 作用于所有内容 (右上角), 而所有MLLM配置均存在过度拒绝 (左下角, SCR = 0; VL+ASR安全性最低)。可部署的左上角区域为空; 仅通过互补的L0层和视觉-MLLM层上的预言机 (94.1%) 可达此区域, 这为学习型路由 (而非MLLM替换) 提供了理论上限。

误差位于L0层一侧, 并将其视为第5.2节中路由器的特征, 而非作为第四层。

表1: PromptShield-Home中对比的三个抽象层。

层	机制	变体
L0	传统检测器 (确定性触发)	唤醒词 / 姿态 / 光学字符识别 (单一基线)
L1	单模态多语言模型 (零样本, JSON)	视觉 (Qwen3-VL-30B) / 视觉+自动语音识别 (Whisper) / 视听 (Omni-7B)
L2	多智能体 (组合调用)	投票 (3× 采样) / 角色专家 / 跨模型仲裁

提示词通过一个固定模板 $P_i = \tau(T_i, W_i, A_i)$ 构建, 该模板基于三个条件, 这些条件仅在哪些可选字段被填充上有所不同 (最小化 / +场景 / +转录文本, 其中 $W_i =$ 自动语音识别(U_i))。L2 专家模型查询不同的角色 (收件人、安全性、授权); 仲裁使用一个文本判断器来处理视觉和视听决策。

指标。标签偏向于无动作, 因此一个恒定的总是阻断预测器能达到很高的准确率 (并且与我们最强的配置相匹配)。因此, 我们报告可部署智能体必须共同最小化的两种错误模式:

$$\text{UER} = \frac{|\{i : z_i=0 \wedge e_i=1\}|}{|\{i : z_i=0\}|}, \quad \text{SCR} = \frac{|\{i : z_i=1 \wedge e_i=1\}|}{|\{i : z_i=1\}|},$$

即不安全执行率 (↓; 被执行的“无动作”案例占比) 和安全完成率 (↑; 被执行的“需行动案例”占比)。我们还报告了误阻率 $\text{FBR} = |\{i : z_i=1 \wedge \hat{y}_i=\text{阻断}\}|/|\{i : z_i=1\}|$ 以及人工确认率 $\text{HCR} = |\{i : \hat{y}_i=\text{询问_用户}\}|/N$; HCR基于所有 N 个案例计算, FBR仅基于需行动案例计算。




图2: 互补性。L0层和视觉多模态大语言模型拥有互不相交的正确集合, 因此一个基于这两者的预言机上限可达94.1%, 而最佳单层仅为76.5%。




图3: PromptShield-Home 基准测试中的示例智能家居场景。这些场景涵盖了可能被误解为可执行用户意图的常见环境多模态内容来源, 包括电视/媒体语音、旁观者对话、屏幕文本以及真实的用户指令。为保护隐私, 人脸已做模糊处理。

3 数据集

我们设计了一项试点基准测试, 以检验智能家居代理能否将真实的用户意图与不应执行的环境信息区分开来。基于已知的智能家居故障和用户风险案例, 三位研究者在录制前通过两次会议为每个场景编写脚本, 确定了家庭设置、候选设备-动作对、预期的黄金决策以及录制标准。随后, 两位研究者在配备智能音箱、智能灯、家用摄像头和电视的住宅环境中表演并录制了这些场景, 捕捉了视觉、音频、文本及跨模态线索。每个片段都对照脚本进行了检查, 并在需要时重新录制, 且每个片段及其黄金决策都经过至少五位作者的审核, 仅在全票同意后才纳入基准测试; 因此, 黄金标签是通过构建过程固定的, 而非事后判断, 我们将其报告为一种结构化共识协议, 而非标注者间一致性统计。多个场景是良性/有害对, 仅在关键的安全区分上有所不同, 例如真实跌倒与瑜伽姿势、空房间与有人房间、自言自语与真实指令, 这隔离了代理必须做出的决策。

该基准测试包含**19个场景**: 17个视频片段, 以.MOV或.mp4格式录制, 以及2个用于占用查询的静态图像。这些场景涵盖六个类别, 如表2所示。每个场景都标注了三种类型的信息: (i) 多模态证据, 包括视频、音频和一行场景描述; (ii) 一个候选设备-动作对, 例如灯/关闭、紧急_警报/触发_警报, 或电话/呼叫_联系人; 以及(iii) 一个黄金决策, 该决策在评估期间对模型隐藏。大多数

表2: PromptShield-Home 试点基准测试 (19个场景) 的构成。“Gold”给出了预期的判定结果。

类别	压力/风险	#	Gold
受话人歧义	非面向智能体的语音	7	阻断
屏幕/音频注入	电视/屏幕内容作为指令	3	阻断
健康误触发	跌倒、姿态、心率、手势	4	1执行/3阻止
混合占用	冲突占用者	1	询问_用户 / 阻断
指令层	真实、明确指向的指令	2	执行
占用状态	静态空置/占用图像	2	空置/占用
总计		19	

表3: 每种配置下的安全性与效用 (Acc = 准确率; 其他指标定义见第2节)。n=17: UER基于14个无需行动案例计算, SCR和FBR基于3个需行动案例计算, HCR和Acc基于全部17个案例计算, 因此这些列以7.1、33.3和5.9个百分点的步长移动, 应视为计数解读。始终阻止预测器已达到82.4%, 这促使了UER/SCR的划分; L0层在所有17个案例上均触发, 因此与始终执行一致, 因为每个场景都包含一个规则可以锁定的表面线索。

配置	UER	SCR	FBR	HCR	Acc
始终执行	100.0	100.0	0.0	0.0	17.6
始终阻止	0.0	0.0	100.0	0.0	82.4
L0 传统	100.0	100.0	0.0	0.0	17.6
L1a 视觉语言, 最小化	0.0	0.0	100.0	5.9	76.5
L1a 视觉语言, +场景	7.1	0.0	100.0	5.9	70.6
L1b 视觉层+自动语音识别	28.6	0.0	100.0	0.0	58.8
L1c 全模态, 最小化	7.1	0.0	0.0	94.1	5.9
L1c 全模态, +场景	7.1	0.0	0.0	82.4	17.6
L1c Omni, +转录文本	0.0	0.0	0.0	100.0	5.9
L2 投票	7.1	0.0	100.0	5.9	70.6
L2 专家模型	0.0	0.0	100.0	0.0	82.4
L2 仲裁	7.1	33.3	66.7	17.6	64.7

黄金决策为无行动案例: 13个为阻断, 1个是询问_用户_或_阻断。仅有3个场景需要执行, 其中2个是占用状态应答。这反映了一种常见的智能家居场景, 并促使我们对安全性与实用性进行单独评估。这17个片段是下文评分的三元行动决策 (N=17: 14个无行动, 3个需要行动); 那2个占用图像则是没有候选行动的感知查询。

传统检测器标注。对于每个场景, 我们也记录了一个传统检测器会如何行动。示例包括: 当人与人对话中出现唤醒词时通过_关键词_执行; 当瑜伽姿势被误判为跌倒时通过_姿态_阈值_执行; 当屏幕上的短语被当作命令时通过_光学字符识别_关键词_执行。此标注有两个目的。首先, 它展示了当前基于规则的系统在这些情况下可能如何失败。其次, 它提供了L0传统检测器基线, 用于与基于MLLM的层级进行比较, 而无需我们运行一个单独的检测器堆栈。这个代理在两个方向上都理想化了, 一个已部署的检测器本身也存在漏报和误报, 因此上述的互补性也是L0层贡献的上限。

4 结果

发现1——相反的失效模式。 L0层对所有内容都采取行动 (UER = 14/14, SCR = 3/3); 每个多模态大语言模型都坍塌到相反的极端 (UER ≤ 1/14, SCR = 0/3): 安全但系统性地过度拒绝。没有任何配置能在两个轴上都处于低位。

表4: L0层与视觉多模态大语言模型的互补性。它们的正确集合互不相交, 因此基于{L0,VL}的预言机准确率上限为94.1%, 而最佳单层仅为76.5%; 未实现路由器。

	正确集	计数
仅L0层	V11, V16, V17	3
仅视觉层	V01-V10\ V06, V12-V15	13
both	—	0
预言机 (L0-视觉层)		94.1%
最佳单层 (视觉层)		76.5%

表5: 基于5个采样种子的鲁棒性 (均值 ± 标准差)。视觉配置稳定; Omni变化巨大 (16/17个场景的决策随种子翻转), 表明其高询问_用户率源于决策不稳定性, 而非原则性谨慎。

配置 (5个种子)	UER	SCR	FBR
视觉层 最小化	0.0 ± 0.0	0.0 ± 0.0	86.7 ± 16.3
视觉层 +场景	7.1 ± 0.0	0.0 ± 0.0	100.0 ± 0.0
Omni +场景	12.9 ± 5.3	0.0 ± 0.0	40.0 ± 24.9

发现 2 —— 准确率是退化的。准确率最高的方法 (L2专家模型, 82.4%) 与始终阻止完全一致: 它对所有17个输入 (51/51的智能体投票) 都输出阻断, 包括真实跌倒。高准确率并不能证明其效用。

发现 3 —— 模态效应。ASR转录文本是有害的 (L1b是最不安全的 MLLM, UER = 4/14, 由嘈杂的转录文本驱动); 原生音频 (Omni) 仅仅将处理重心转移到询问_用户 (HCR高达100%), 而并未改善决策。

互补性: 路由, 而非替换。L0层和视觉多模态大语言模型拥有互不相交的正确集合: L0层恰好覆盖了多模态大语言模型过度拒绝的三个需要行动的案例, 而多模态大语言模型覆盖了检测器无法推理的语义 (收件人/注入) 案例, 且没有一个案例能被两者同时解决。因此, 基于{L0, VL}的预言机理论上限为**94.1%**, 而最佳单层仅为76.5%; 目前未实现路由器 (第5.2节)。最关键的安全性错误——漏检真实跌倒 (V11), 被所有多模态大语言模型 (9/9) 犯下, 且仅被物理传感器基线捕获, 这论证了传感器+多模态大语言模型融合 (高灵敏度触发器 + 多模态大语言模型误报过滤器) 的必要性, 而非采用纯摄像头代理。

帧预算无法解决此问题 (且会增加延迟)。单纯增加帧数 × 每帧分辨率: 更多帧数并不能恢复错过的动作 (V11、V16在所有预算下均保持阻断状态), 并且会恶化一个空间注入案例 (V09在 ≥64 帧时因每帧细节减少而翻转为不安全执行), 而总延迟增加 4.9 → 8.6秒 (16 → 128 帧)。令牌数在此具有误导性 (409 → 867, 受上限预算限制); 延迟才是公平的成本。因此, 最优帧预算取决于具体场景, 更密集的采样并非解决过度拒绝 [24]的良方。

鲁棒性 (5次随机种子)。过度拒绝是一种稳定的偏差, 而非噪声: 视觉配置几乎不变, 而Omni在多次种子运行中翻转了16/17次决策, 因此其表面上的“谨慎”实为不稳定性, 而非有原则的延迟执行。

5 讨论

5.1 单层方法难以平衡安全性与效用。

单一范式无法平衡这两个维度。检测器能处理所有需行动案例, 但几乎对所有情况都采取行动 (UER 14/14),

而多模态大语言模型配置仅通过拒绝几乎所有真实指令 (SCR 0/3) 将不安全执行降至接近零。系统从过度执行转向系统性过度拒绝, 而在家庭环境中, 无论是意外的门锁开启还是被遗漏的跌倒都是不可接受的。

5.2 路由而非替换。

传统检测器和多模态大语言模型是互补而非竞争关系: 它们的正确决策互不相交, 一个基于这两层的预言机达到了94.1%的准确率, 而最佳单层仅为76.5% (唯一高于此的配置是82.4%, 这是发现2的退化等价形式——始终阻止)。因此, 智能家居代理应将每个决策路由到最适合处理它的层, 而非相互替代, 例如, 使用高灵敏度的物理传感器 (惯性测量单元、加速度计或雷达) 进行跌倒起始检测, 并使用多模态大语言模型作为高特异性的误报过滤器 [15, 23]。基于规则和角色的策略作为部分保障措施仍然有用, 但无法预见所有家庭情境, 因此大语言模型应在明确的路由、风险和来源归属策略下充当受约束的语义中介器 [16]。

5.3 更多模态并不总是有益。

添加自动语音识别通过引入嘈杂的转录文本, 反而降低了视觉模型的安全性 (UER 4/14), 而原生音频则将决策转向询问_用户却未解决问题, 这体现的是不稳定性而非谨慎性, 因为17个场景中有16个在不同随机种子下发生了变化, 而纯视觉的过度拒绝则是稳定的。瓶颈在于校准和来源归属, 而非模态的数量。

5.4 保守行为不等于智能行为。

多模态大语言模型代理可以通过拒绝执行来减少不安全执行, 但这并不会让它们更有用或更智能, 因为它们会拒绝有效指令, 甚至错过紧急情况。总体准确率掩盖了这一点: 我们准确率最高的配置表现得像一个总是阻断的预测器。因此, 安全关键评估应分别报告安全性与实用性, 而可部署代理必须知道何时执行、拒绝或询问用户, 正如PromptShield-Home的分层设计所示。

6 局限性与未来工作

这项试点研究受限于其小型基准测试 ($N = 19$)、不均衡的类别覆盖、由作者共识而非独立标注验证的黄金决策, 以及主要是单次运行评估。互补性增益依赖于一个预言机而非训练过的路由器, 而传感器融合的论证基于L0代理而非实测的惯性测量单元或雷达数据流。推理使用了一块A100-80GB; 300亿参数视觉模型需要 ~60GB显存, 无法在家庭环境中持续运行, 这本身也是支持路由的一个论据。未来工作将扩展基准测试规模, 增加独立标注, 训练经过校准的路由器, 并评估设备端传感器融合。

7 结论

PromptShield-Home为智能家居代理中的环境多模态提示注入提供了一个早期基准测试。传统检测器倾向于过度执行, 而多模态大语言模型则倾向于过度拒绝, 导致聚合准确率不足。这些互补性故障模式促使我们采用源感知路由和传感器融合设计, 而非简单地用多模态大语言模型替换检测器。

生成式人工智能使用声明

我们使用了生成式人工智能工具进行语言润色和语法修正。生成式人工智能模型也被用作实验流程的一部分, 因为本研究评估的是基于多模态大语言模型智能家居代理及其行动决策。所有由生成式人工智能辅助生成的内容、提示词、模型输出及报告结果均由作者手动审核和验证, 作者对最终论文内容负责。

致谢

本研究使用了在实验室环境中记录的数据, 未涉及任何第三方参与者。数据收集方案已由通讯作者所在机构的机构审查委员会 (IRB) 审核 (项目编号 20230024)。为保护可识别的实验室内部环境和研究团队的声音, 我们不公开原始音频或视频; 相反, 我们发布场景清单和模型输出以支持复现。原始媒体资料可根据合理请求与研究人员共享。

参考文献

[1] Eugene Bagdasaryan, Tsung-Yin Hsieh, Ben Nassi, 以及 Vitaly Shmatikov. 2023. 滥用图像和声音进行多模态大语言模型的间接指令注入. arXiv: 2307.10490 [] 2307.10490. cs.CR

[2] https://arxiv.org/abs/. Marie Chan, Daniel Estève, Christophe Escriba, 以及 Eric Campo. 2008. 智能家居综述——现状与未来挑战. *Computer methods and programs in biomedicine* 91, 1 (2008), 55–81. https://doi.org/10.1016/j.cmpb.2008.02.001[3] Jan Clusmann, Dyke Ferber, Isabella C. Wiest, Carolin V. Schneider, Titus J. Brinker, Sebastian Foersch, Daniel Truhn, 以及 Jakob Nikolas Kather. 2025. 肿瘤学中视觉语言模型的提示注入攻击. *Nature Communica- tions* 16 (2025), 1239. https://doi.org/10.1038/s41467-024-55631-x[4] Xinyi Fu, He Zhang, Cheng Xue, 以及 Tongxin Sun. 2023. 未来智能家居前沿研究综述. 科技导报 41, 8 (2023), 36–52. [5] Kai Greshake, Sahar Abdelnabi, Shailesh Mishra, Christoph Endres, Thorsten Holz, 以及 Mario Fritz. 2023. 非你所愿: 通过间接提示注入攻击现实世界的大语言模型集成应用. 载于第16届ACM人工智能与安全研讨会论文集 (*AISeC '23*). 美国计算机协会, 美国纽约州纽约市, 79–90. https://doi.org/10.1145/3605764.3623985[6] David Hanes, Gonzalo Salgueiro, Patrick Grossetete, Robert Barton, 以及 Jerome Henry. 2017. 物联网基础: 物联网的网络技术、协议与用例. Cisco Press. [7] Wenda Li, Tan Yigitcanlar, Isil Erol, 以及 Aaron Liu. 2021. 智能家居采用的动机、障碍与风险: 从系统文献综述到概念框架. 能源研究与社会科学 80 (2021), 102211. https://doi.org/10.1016/j.erss.2021.102211[8] Yi Liu, Gelei Deng, Yuekang Li, Kailong Wang, Zihao Wang, Xiaofeng Wang, Tianwei Zhang, Yepang Liu, Haoyu Wang, Yan Zheng, Leo Yu Zhang, 以及 Yang Liu. 2023. 针对大语言模型集成应用的提示注入攻击. https://doi.org/10.48550 2306.05499 2306.05499 []. / [9] arXiv. . arXiv. . cs.CR Yupei Liu, Yuqi Jia, Runpeng Geng, Jinyuan Jia, 以及 Neil Zhenqiang Gong. 2024. 形式化与基准测试提示注入攻击与防御. 载于第33届USENIX安全研讨会 (美国宾夕法尼亚州费城). USENIX协会, 1831–1847. https://doi.org/10.48550/arXiv.2310.12815[10] Dmitriy Rivkin, Francois Hogan, Amal Feriani, Abhisek Konar, Adam Sigal, Xue Liu, 以及 Gregory Dudek. 2025. 通过自主大语言模型代理实现的AIoT智能家居. *IEEE物联网期刊* 12, 3 (2025), 2458–2472. https://doi.org/10.1109/JIOT.2024.3471904[11] Lea Schönherr, Maximilian Golla, Thorsten Eisenhofer, Jan Wiele, Dorothea Kolossa, 以及 Thorsten Holz. 2022. 探索智能音箱的意外触发. 计算机语音与语言 73 (2022), 101328. https://doi.org/10.1016/j.csl. 2021.101328[12] Chongyang Shi, Sharon Lin, Shuang Song, Jamie Hayes, Iliia Shumailov, Itay Yona, Juliette Pluto, Aneesh Pappu, Christopher A. Choquette-Choo, Milad

Nasr, Chawin Sitawarin, Gena Gibson, Andreas Terzis, 以及 John "Four" Flynn. 2025. 防御双子座模型免受间接提示注入攻击的经验教训. arXiv: 2505.14534 [] 2505.14534. cs.CR

[13] https://arxiv.org/abs/. Jiawen Shi, Zenghui Yuan, Yinuo Liu, Yue Huang, Pan Zhou, Lichao Sun, 以及 Neil Zhenqiang Gong. 2024. 针对LLM-as-a-Judge的基于优化的提示注入攻击. 载于2024年ACM SIGSAC计算机与通信安全会议论文集 (CCS '24). 美国计算机协会, 美国纽约州纽约市, 660 674 10.1145.3658644.3690291–. https://doi.org/. Marx Boyuan Wang, Daniel Manesh, Ruipu Hu, 以及 Sang Won Lee. . iThem: 超越触发-动作模式的物联网编程. 载于第35届ACM用户界面软件与技术研讨会补充论文集 (美国俄勒冈州本德市) (UIST '22 补充会议). 美国计算机协会, 美国纽约州纽约市, 文章53, 5页. https://doi.org/10.1145/3526114.3558776[15] Xueyi Wang, Joshua Ellul, 以及 George Azzopardi. 2020. 老年人跌倒检测系统: 文献综述. 机器人学与人工智能前沿 7 (2020), 71. https://doi.org/10.3389 2020.00071. /frobt. . Shihao Weng, Yang Feng, Jinrui Zhang, Xiaofei Xie, Jiongchi Yu, 以及 Jia Liu. 2026. ARGUS: 防御LLM智能体免受上下文感知提示注入攻击. arXiv: 2605.03378 [] 2605.03378. cs.CR https://arxiv.org/abs/. Charlie Wilson, Tom Hargreaves, 以及 Richard Hauxwell-Baldwin. 2015. 智能家居及其用户: 系统分析与关键挑战. 个人与普适计算 19 (2015), 463–476. https://doi.org/10.1007/s00779-014-0813-0[18] Jiayang Wu, Wensheng Gan, Zefeng Chen, Shicheng Wan, 以及 Philip S. Yu. 2023. 多模态大语言模型综述. 载于2023年IEEE大数据国际会议 (BigData). 2247–2256. https://doi.org/10.1109/BigData59044. 2023.10386743[19] Chong Xiang, Drew Zagieboylo, Shaona Ghosh, Sanjay Kariyappa, Kai Greshake, Hanshen Xiao, Chaowei Xiao, 以及 G. Edward Suh. 2026. 构建安全的AI智能体: 针对间接提示注入攻击的系统级防御视角. arXiv: 2603.30016 [] 2603.30016. cs.CR

[20] https://arxiv.org/abs/. Xiao Xue, Xinyang Li, Boyang Jia, Jiachen Du, 以及 Xinyi Fu. . 谁应掌握控制权? 通过协同设计视角重新思考合居者在家居自动化中的赋权. 载于2024年CHI计算系统中的人为因素会议论文集 (美国夏威夷州檀香山) (CHI '24). 美国计算机协会, 美国纽约州纽约市, 文章854, 19页. https://doi.org/10.1145.3613904.3642866. /. Haruki Yonekura, Fukuharu Tanaka, Teruhiro Mizumoto, 以及 Hirozumi Yam-aguchi. 2024. 利用LLM为智能家居模拟器智能体生成人类日常活动. 载于2024年智能环境国际会议 (IE). 93 96 10.1109 61493.2024.10599909–. https://doi.org/. /IE. .

[22] Sayyed Javad Asad Poor Zavei 以及 Mahmud Mohd Jusan. 2012. 基于马斯洛需求层次理论探索住房属性选择. *Procedia-社会与行为科学* 42 (2012), 311–319. https://doi.org/10.1016/j.sbspro.2012.04.195[23] He Zhang, Robin Ananda, Xinyi Fu, Zhe Sun, Xiaoyu Wang, Keqi Chen, 以及 John Carroll. 2024. 面向智能家居的多通道传感器网络构建、数据融合与挑战. 载于第十一届华人CHI国际研讨会论文集 (印度尼西亚巴厘岛登巴萨) (CHCHI '23). 美国计算机协会, 美国纽约州纽约市, 344–351. https://doi.org/10.1145/3629606.3629638[24] He Zhang 以及 Xinyi Fu. 2025. 使用大型多模态模型进行面部图像的零样本情感标注: 多类别、多帧方法的基准测试与展望. 载于第三届多模态与负责任情感计算国际研讨会论文集 (爱尔兰) (MRAC '25). 美国计算机协会, 美国纽约州纽约市, 109–118. https://doi.org/10.1145/3746270.3760233[25] He Zhang, Yuewen Zhang, Bochen Li, Wen Chen, Yueyan Liu, Qianao Xu, 以及 Xinyi Fu. 2026. AIoT智能家居自动化架构: 由多模态大语言模型驱动的自主决策. 载于第31届智能用户界面国际会议配套论文集 (IUI '26 配套会议). 美国计算机协会, 美国纽约州纽约市, 10–13. https://doi.org/10.1145/3742414.3794710[26] Wei Zou, Mingwen Dong, Miguel Romero Calvo, Shuaichen Chang, Jiang Guo, Dongkyu Lee, Xing Niu, Xiaofei Ma, Yanjun Qi, 以及 Jiarong Jiang. 2026. 一次投毒, 永久利用: 针对Web智能体的环境注入式记忆投毒攻击. arXiv: 2604.02623 [] 2604.02623. [27] cs.CR https://arxiv.org/abs/. Wei Zou, Runpeng Geng, Binghui Wang, 以及 Jinyuan Jia. . PoisonedRAG: 针对大语言模型检索增强生成的知识污染攻击. 载于第34届USENIX安全研讨会 (USENIX安全25). USENIX协会, 华盛顿州西雅图市, 3827–3844. https://www.usenix.org/conference/usenixsecurity25/presentation/zou-poisonedrag