

HomeFlow: 一个用于智能家居智能体训练、基于可验证仿真的数据飞轮

Yi Gu^{1, *} Huacan Wang^{1, *, †, ‡} Shuo Zhang^{1, 2, *, ◇} Yuqing
 Hou¹ Lei Xue¹ Weipeng Ming¹ Chen Liu¹ Fangzhou Yu^{1, 3, ◇}
 KuanLi¹ Ronghao Chen⁴ Sen Hu⁴ Xiaofeng Mou¹ Yi Xu^{1, †}
¹美的集团 ²北京邮电大学 ³东华大学 ⁴北京大学

*同等贡献, †通讯作者, ‡项目负责人。

◇工作完成于在美的AI研究中心实习期间。

摘要

大语言模型智能体正从纯文本交互迈向物理世界控制, 其中智能家居是一个代表性领域。真实的家庭交互需要理解模糊意图、在动态环境中操作以及执行多轮推理。然而, 现有方法难以生成高质量的智能家居智能体训练数据。我们提出**HomeFlow**, 一个针对该领域的可验证数据飞轮。HomeFlow使用HomeEnv作为统一仿真环境, 并使用HomeMaker程序化生成多样化家居场景。随后, Blueprint将开放式用户意图编译为基于状态的可执行成功条件, 而MCTS-Flow则通过环境引导的树搜索合成多样化、可验证的多轮轨迹。接着, 我们通过监督微调 and 逐步RLVE来优化智能体, 这通过真实物理反馈促进了迭代改进。我们进一步构建了SmartHome-Bench, 以评估智能体在各种智能家居任务上的表现。在此基准测试中, HomeFlow-RL-4B和HomeFlow-RL-8B的任务成功率分别达到84.60%和87.03%。值得注意的是, HomeFlow-RL-8B甚至超越了领先的GPT-5.5达1.23个百分点。

关键词: 智能家居, 大语言模型智能体, MCTS, RLVE

通讯作者: [HuacanWang](#), [YiXu](#)

代码: 即将发布。

1 引言

基于大语言模型 (LLM) 的智能体 (Li et al., 2025a) 正日益超越纯文本交互 (Singh et al., 2025; Comanici et al., 2025), 转向物理世界的控制 (Xietal., 2025)。智能家居 (Hammi et al., 2022年; Huda et al., 2024年) 为这一转变提供了一个天然的试验场: 它们拥有丰富的联网设备, 受物理状态支配, 并与日常用户需求紧密契合。一个能干的智能家居智能体必须能够推断隐含用户意图, 基于家居状态采取行动, 并在需要时寻求澄清。例如, “感觉有点闷”可能需要根据当前环境调整空调或通风。然而, 直接将前沿大语言模型部署为智能家居智能体是不切实际的, 因为它们缺乏情境感知。这常常导致看似合理但不可执行的指令, 需要通过领域特定训练来使模型与智能家居动态对齐。

此类训练依赖于大规模多轮交互数据, 但由于成本、部署复杂性和隐私限制, 很难从真实家庭中收集。一种常见的替代方案是通过基于大语言模型的角色扮演离线合成对话 (Shao et al., 2023年; Wang et al., 2025年)。然而, 纯文本合成存在三个根本性局限。首先, 它缺乏一个底层的物理环境来验证动作。例如, 像“调低空调”这样的生成命令是否对应一个有效设备, 以及是否能在当前房间实际执行, 仅凭文本无法确定, 这迫使评估依赖于主观的大语言模型作为裁判 (Li et al., 2024年; Gu et al., 2024年) 信号。这会引入噪声并阻碍强化学习

接收基于物理现实的奖励。其次，线性的角色扮演通常为每个场景只产生一条轨迹，对多样化的环境演变和用户响应的覆盖有限。第三，在静态离线对话上进行训练主要支持固定上下文下的单步对齐（Guo et al., 2025年；Yu et al., 2025年；Zhang et al., 2025年）。如果没有显式的多轮训练，智能体难以在整个回合中追踪意图并修正其策略。

为应对这些局限，我们提出 **HomeFlow**，一个用于训练智能家居智能体的可验证数据飞轮。其核心理念是构建一个交互式模拟环境 HomeEnv，作为统一的接地信号源，连接数据生成、轨迹扩展和多轮策略优化。基于 HomeEnv，我们设计了 HomeMaker，用于程序化生成多样的家居布局、设备和环境状态，以填充模拟环境。为实现可验证的数据生成，我们引入了一个包含 Blueprint 和 MCTS-Flow 的流水线。具体而言，Blueprint 构建包含多样化用户画像和上下文的综合交互场景，并将隐含意图编译为可执行的逻辑约束。在这些蓝图的指导下，MCTS-Flow 将数据合成从单次线性采样推进到树状结构搜索，探索并验证多样的多轮轨迹。

最后，我们采用两阶段训练范式。在初始的监督微调阶段之后，智能体通过可验证执行的分步强化学习（RLVE）（Zhang et al., 2025）进行进一步优化。与传统方法仅奖励最终结果不同，此策略在智能体与动态大语言模型用户和 HomeEnv 进行在线交互时持续优化，在生成过程的每一步都施加基于物理现实的奖励。

为评估智能体在真实智能家居场景中与用户交互及操作设备的能力，我们在 HomeEnv 之上构建了 SmartHome-Bench。在此基准测试中，基于 Qwen3-4B 和 Qwen3-8B（Yang 等人, 2025 年）通过 HomeFlow 训练得到的 HomeFlow-RL-4B 和 HomeFlow-RL-8B，分别实现了 84.60% 和 87.03% 的整体任务成功率。值得注意的是，HomeFlow-RL-8B 以 1.23% 的优势超越了 GPT-5.5，而 HomeFlow-SFT-4B 和 HomeFlow-SFT-8B 则分别比对应的纯文本角色扮演微调基线模型提升了 5.88% 和 4.67%。

2 相关工作

智能家居智能体。大语言模型已成为智能家居的核心编排器，能将自然语言意图转化为可执行的 API 调用（Rivkin 等人, 2023 年；Yu 等人, 2026 年；Birkmose 等人, 2025 年）。除了早期专注于基础指令分解的系统（King 等人, 2024 年；Yin 等人, 2025 年）外，近期研究（Yu 等人, 2026 年；Huang 等人, 2025 年；Zhan 等人, 2026 年）探索了个性化、持久记忆以及基于边缘的多智能体编排。与此同时，诸如 HomeBench（Li 等人, 2025b）和 SimuHome（Seo 等人, 2026 年）等基准测试通过评估大语言模型在指令到调用生成、时序推理和环境感知执行方面的能力，极大地推动了该领域的发展。

对话数据合成。合成数据生成为模型后训练提供了一种可扩展的方法。诸如 Self-Instruct（Wang 等人, 2022 年）和 Evol-Instruct（Xu 等人, 2023 年）等方法引导并迭代重写指令，而 AgentInstruct（Mitra 等人, 2024 年）将此扩展到复杂的智能体 workflow。对于对话智能体，多轮轨迹通常使用用户模拟器和角色扮演来构建，并常通过 LLM 即法官进行过滤（Li 等人, 2024 年；Gu 等人, 2024 年；Ni 等人, 2026 年）。近期的基于搜索的方法（Gao 等人, 2025 年；Koh 等人, 2024 年）进一步整合了树状结构探索，以增强下游训练的轨迹多样性和质量。

可验证环境强化学习。虽然 RLHF（Ouyang 等人, 2022 年）和 RLAIIF（Bai 等人, 2022 年；Lee 等人, 2024 年）依赖于基于偏好的奖励，但近期趋势更倾向于可验证奖励（RLVR），其正确性可自动检查，在数学（例如 GRPO（Shao 等人, 2024 年））和交互式智能体环境（Jimenez 等人, 2023 年；Wei 等人, 2025 年）中显示出巨大潜力。基于这些基础，HomeFlow 将智能家居任务构建为一个有状态的学习问题。它利用可验证数据合成来提供稳健的冷启动，随后通过基于结构化、环境驱动奖励进行优化的逐步 RLVE。

3 方法

3.1 任务定义

智能 A 任务可被视为在部分可观测的物理环境中进行的目标导向序列决策。我们将任务形式化为离散时间下的目标条件部分可观测马尔可夫决策过程（POMDP），由元组 $\langle \mathcal{S}, \mathcal{A}, \mathcal{E}, \mathcal{O}, \mathcal{R} \rangle$ 表示。

状态空间 $\mathcal{S}$ 捕捉了 Home 底层的物理状态。在时间步 t ，状态 $s_t \in \mathcal{S}$ 编码了连续的环境和设备属性（例如，温度），以及离散的设备状态（例如，开/关、模式）。为了实现与环境用户的双向交互，智能体在一个异构的动作空间 $\mathcal{A} = \mathcal{A}_{\text{NL}} \cup \mathcal{A}_{\text{Exec}}$ 中行动，其中 $\mathcal{A}_{\text{NL}}$ 表示用于响应和澄清的自然语言动作，




图1: HomeFlow概览。基于HomeEnv, HomeMaker生成多样化的家庭环境。Blueprint随后创建可执行的场景条件, 接着由MCTS-Flow合成多样化、可验证的轨迹。基于此架构, 我们衍生出三种数据合成策略: (M1) 纯文本角色扮演(无Blueprint); (M2) 蓝图锚定线性生成(无MCTS-Flow); 以及 (M3) 完整的HomeFlow流程。

而 $\mathcal{A}_{\text{Exec}}$ 表示可执行控制动作, 例如生成Python脚本片段或进行API调用来查询或修改物理状态。

环境动态由转移函数 $\mathcal{E} : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$ 决定。一个可执行动作 $a_t \in \mathcal{A}_{\text{Exec}}$ 会根据 $s_{t+1} = \mathcal{E}(s_t, a_t)$ 引发确定性的物理状态转移, 而一个自然语言动作 $a_t \in \mathcal{A}_{\text{NL}}$ 仅推进对话上下文, 物理状态保持不变 (即 $s_{t+1} = s_t$)。由于智能体无法直接访问完整状态 s_t , 它基于部分观察 $o_t \in \mathcal{O}$ 做出决策。观察结果 o_t 可能包括用户话语、设备查询结果以及已执行动作的反馈。

为避免依赖主观的基于LLM的评估, 我们将用户的任务目标表示为一组可验证条件

$\Phi = \{\phi_1, \phi_2, \dots, \phi_K\}$, 其中每个 $\phi_k : \mathcal{S} \rightarrow \{0, 1\}$ 是环境状态上的一个布尔谓词。基于此, 给定一个初始状态 $s_0 \sim p(s_0)$ 和一个目标规范 $\Phi \sim p(\Phi)$, 智能体策略 $\pi_\theta(a_t | h_t)$ 根据交互历史 $h_t = (o_1, a_1, \dots, o_t)$ 采取行动, 生成一条完整轨迹 τ 。在回合结束时达到最终状态 s_T 后, 终端验证奖励 $\mathcal{R}$ 由所有目标条件的累积满足度定义为 $\mathcal{R}(s_T, \Phi) = \sum_{k=1}^K \phi_k(s_T)$ 。这个累加公式通过为未完成任务授予部分奖励, 提供了更密集的信号。因此, 总体目标是找到最优策略 π_θ^* , 以最大化期望验证成功率:

$$J(\theta) = \mathbb{E}_{s_0 \sim p(s_0), \Phi \sim p(\Phi)} [\mathcal{R}(s_T, \Phi)] \quad (1)$$

这一表述凸显了训练智能家居智能体面临的两个核心挑战: (1) 构建一个交互式执行引擎来模拟环境并计算可验证奖励 (第3.2节); 以及 (2) 将开放式场景编译为精确目标, 以驱动高效探索和后续的策略优化 (第3.3节和第3.4节)。

3.2 交互式家庭环境

我们开发了HomeEnv, 这是一个为可扩展的智能体训练而设计的交互式环境。为了多样化初始状态分布 $p(s_0)$, 我们进一步引入了HomeMaker, 一个程序化环境生成器。HomeEnv和HomeMaker共同为HomeFlow提供了核心环境基础。

3.2.1 HomeEnv: 智能家居模拟引擎

HomeEnv 在整个数据生成和策略优化过程中充当可验证执行平台。它提供统一的执行反馈、部分观察和基于规则的验证。其设计包含三个主要组件。更多细节见附录A。

结构化状态表示。我们将家庭状态实例化为 $s_t \in \mathcal{S}$

$$s_t = \langle \mathcal{L}, \mathcal{D}, \psi, \mathcal{X}_t, \mathcal{F} \rangle, \quad (2)$$

其中 $\mathcal{L}$ 表示房间及其空间组织的集合, $\mathcal{D}$ 是智能设备的集合, 而 $\psi: \mathcal{D} \rightarrow \mathcal{L}$ 将每个设备映射到其位置。对于每个设备 $d \in \mathcal{D}$, $\mathcal{X}_t(d)$ 捕获其动态状态, 而 $\mathcal{F}(d)$ 则指定其暴露的可执行功能。这种声明式设备模式将状态表示与模拟实现解耦, 使环境能够扩展到异构和长尾的物联网设备。

执行沙箱。HomeEnv 为执行操作 $a_t \in \mathcal{A}_{\text{Exec}}$ 提供了一个隔离的沙盒。当智能体生成代码或 API 调用时, 沙盒会返回仅限于直接执行结果的观测结果 o_t ——例如序列化设备状态、执行反馈和运行时错误。这种设计强制了部分可观测性, 要求智能体主动查询环境并解释反馈。至关重要的是, 它能产生基于实际执行的高保真交互轨迹, 为策略优化提供可靠的数据源。

验证与审计模块。该模块持续跟踪状态, 并在每一步后评估目标条件 Φ 。当所有条件都满足时, 环境将终止该回合并返回一个已验证的成功信号。此外, 一个运行时动作审计器会阻止不安全或任务无关的操作 (例如, 访问不存在的功能或设置超出物理限制的属性), 将其转换为确定性的负反馈。这种双重机制为离线数据过滤和在线策略优化建立了一个可靠的反馈边界。

3.2.2 HomeMaker: 多样化环境实例化

智能家居环境在布局、设备配置和环境条件方面因家庭而异。在单一、固定的环境中进行训练不可避免地会导致严重的过拟合。为了缓解这一问题, HomeMaker 通过程序化方式生成多样化且物理一致的初始状态 s_0 。

对于每个家庭实例 i , HomeMaker 首先采样真实世界天气数据以建立外部上下文。然后, 它构建一个具有嵌套结构 (例如, 带有套内浴室的卧室) 的空间布局 $\mathcal{L}_i$ 。基于房间语义, 引擎从先验分布中采样设备, 以确定设备集合 $\mathcal{D}_i$ 及其位置 ψ_{i0} 。最后, 它整合外部天气、布局结构和设备配置, 以初始化动态状态变量 $\mathcal{X}_0^{(i)}$ 。这种分层过程确保每个回合都从一个真实且逻辑合理的状态 $s_0^{(i)}$ 开始。通过多样化的布局和设备组合来扩展上下文空间, HomeMaker 有效地增强了智能体在长尾居住场景中的鲁棒性。

3.3 可验证数据合成

如图1所示, 我们利用HomeEnv进行可验证执行, 通过一个两阶段流程生成大规模、高质量的训练数据: 一个静态的蓝图构建阶段, 用于构建目标分布 $p(\Phi)$, 以及一个动态的MCTS-Flow搜索阶段, 在环境验证信号的指导下高效探索交互轨迹 τ 。

3.3.1 蓝图构建

为了大规模合成多样化的训练数据, 我们提出了蓝图构建机制来编排全面的交互场景 (即“脚本”)。形式上, 我们将一个完整的交互蓝图定义为一个元组 $\mathcal{B} = \langle \mathcal{U}, s_0^{(i)}, \mathcal{I}, \Phi_{\mathcal{B}} \rangle$ 。其中, $\mathcal{U}$ 代表一个多维度的用户画像 (涵盖生理特征、生活习惯和环境偏好, 例如“深夜在复式别墅中视力不佳的老年人”); $s_0^{(i)}$ 是由第3.2.2节中HomeMaker实例化的初始物理状态; $\mathcal{I}$ 表示基于物理生活场景生成的用户生活片段; 而 $\Phi_{\mathcal{B}}$ 是对应的客观评估标准集合。

具体而言, GPT-5 (Singh等人,2025) 扮演场景脚本生成器的角色, 在给定初始化的物理环境 $s_0^{(i)}$ 和用户画像 $\mathcal{U}$ 后, 生成关于 $\mathcal{I}$ 在此生活空间内的连续“生活片段” $s_0^{(i)}$ 。随后, $\mathcal{I}$ 内的连续“生活片段”被分割为多步原子意图, 每个意图都被表述为一个候选的布尔评估函数 ϕ_k 。为保证绝对的客观性和有效性, 这些生成的条件需经过严格的三重过滤机制。首先, 通过HomeEnv沙箱执行可执行性检查, 以拦截包含解析错误或未定义的设备实体的非法条件。其次, 对照底层的设备模式验证边界有效性, 以确保参数保持在允许的硬件范围内。最后, 使用GPT-5交叉验证所表述的条件、指令意图和用户画像之间的逻辑一致性。任何检查失败的条件都会被直接丢弃。通过此机制, 模糊的指令被严格地转化为一个精确的、机器可验证的目标分布 $p(\Phi)$ 。

3.3.2 MCTS-Flow: 可验证轨迹探索

随着Blueprint $\mathcal{B}$ 的建立, 目标在于合成高质量的交互轨迹 τ , 引导智能体从 $s_0^{(i)}$ 出发, 最终到达满足既定标准 $\Phi_{\mathcal{B}}$ 的最终状态。传统的线性对话生成

方法存在严重的计算浪费：多轮交互中最后一轮的失败，会导致丢弃之前所有的探索。为了克服这个问题，MCTS-Flow将轨迹合成视为一个树搜索问题，深度融合蒙特卡洛树搜索（MCTS）与HomeEnv环境验证，以高效生成多样化、高质量的轨迹。

MCTS-Flow 在 Blueprint $\mathcal{B}$ 的约束内构建一个异构对话搜索树 $\mathcal{T} = (\mathcal{V}, \mathcal{E})$ 。每个节点 $v \in \mathcal{V}$ 代表一个可复用的交互前缀 $s_v = \langle h_v, r_v \rangle$ ，其中 h_v 是包含对话历史和环境反馈的多轮历史上下文，而 $r_v \in \{\text{用户}, \text{智能体}\}$ 表示当前活跃角色。为适应智能家居场景的特定复杂性，我们对标准 MCTS 引入了三项核心修改：

角色感知自适应分支。 我们观察到，用户话语严格受 Blueprint 意图约束，而智能体决策则涉及复杂的意图澄清和多步推理。因此，MCTS-Flow 引入了非对称分支因子 $k(v)$ 来管理这些不同的角色。具体来说，我们为智能体节点分配了更大的采样宽度，使得 $k_{\text{agent}} > k_{\text{user}}$ 。此策略将搜索预算集中在智能体关键决策的分叉点上，避免对确定性用户输入进行冗余采样。

UCB 选择与前缀复用。 在选择阶段，利用上置信界（UCB）算法在可用子节点间平衡探索与利用：

$$v^* = \arg \max_{u \in Ch(v), \rho(u)=1} \left[\frac{Q(u)}{N(u)} + c_{\text{ucb}} \sqrt{\frac{2 \ln N(v)}{N(u)}} \right] \quad (3)$$

其中 $Ch(v)$ 是子节点集合， $N(u)$ 是访问计数， $Q(u)$ 是累积的验证奖励，而 $\rho(u) \in \{0, 1\}$ 是一个可通过性指示器。当一次模拟结束时，MCTS-Flow 会保留所有模拟节点，并在反向传播过程中，如果某个节点的所有子节点都不可通过，则标记该路径上所有节点的 $\rho(u) = 0$ 。这一机制将已验证前缀转化为可复用的资产。

环境验证奖励反向传播。 与大多数依赖基于模型评分的树搜索不同，MCTS-Flow 利用了由 HomeEnv 环境提供的真实反馈。当一次模拟到达终端节点 v_L 时，会计算最终状态 s_T 的满足程度：

$$R(v_L) = \mathbf{1} \left[\text{valid}(h_{v_L}) \wedge \prod_{k=1}^K \phi_k(s_T) = 1 \right] \quad (4)$$

其中 $\text{valid}(h_{v_L})$ 是一个二元指示器，确保交互没有执行错误或指令违规。然后，这个真实的物理奖励会被反向传播，以更新所有祖先节点的 $Q(v)$ 和 $N(v)$ 。值得注意的是，该机制不仅为监督微调选择已验证轨迹，还通过已验证的成功率量化 Blueprint 的复杂度，从而有效地为日益复杂的任务促进课程驱动的强化学习。

3.4 两阶段智能体训练

3.4.1 监督微调

我们从 MCTS-Flow 搜索树中提取成功的路径。对于每个已验证回报为 $R(v_L) = 1$ 的终端节点，其对应的路径被转换为一个顺序交互轨迹 $\tau^* = (o_1, a_1, o_2, a_2, \dots, o_T, a_T)$ 。所有成功的轨迹构成了监督数据集 $\mathcal{D}_{\text{SFT}}$ 。策略 π_θ 通过标准的因果语言建模目标进行优化：

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{\tau^* \sim \mathcal{D}_{\text{SFT}}} \left[\sum_{t=1}^{|\tau^*|} \log \pi_\theta(a_t \mid h_t, \Phi_{\mathcal{B}}) \right]. \quad (5)$$

监督微调为智能体注入了关键的行为先验，包括意图澄清、设备控制语义以及环境观察推理。然而，单纯的模仿使其在长时程家庭交互中容易受到复合误差的影响。

3.4.2 逐步RLVE：使策略与物理现实对齐

在现实智能家居中，用户意图和家庭状态共同演化，这使得基于静态对话前缀的离线强化学习显得不足。为了克服被动模仿的局限性，我们引入了逐步RLVE，它通过在线、多轮交互直接优化智能体。

动态轨迹生成。 在每个从蓝图 $\mathcal{B}$ 初始化的训练回合 e 中，一个强大语言模型充当动态用户模拟器 π_{user_0} 。智能体策略 π_θ 与模拟器及 HomeEnv 环境进行实时交互循环，生成完整的在线轨迹 $\tau^{(e)} = (u_1^{(e)}, a_1^{(e)}, r_1^{(e)}, \dots, u_T^{(e)}, a_T^{(e)}, r_T^{(e)})$ ，

其中用户话语 $u_t^{(e)} \sim \pi_{\text{user}}(\cdot | \mathcal{B}, h_{<t}^{(e)})$ 是基于蓝图约束和实时交互历史动态合成的。相应地，智能体动作 $a_t^{(e)} \sim \pi_{\theta}(\cdot | h_{<t}^{(e)}, \Phi_{\mathcal{B}})$ 会触发环境更新，从而产生来自HomeEnv的逐步验证奖励 $r_t^{(e)}$ 。关键在于，这种设计确保了同一蓝图 $\mathcal{B}$ 在不同回合中能产生高度多样化的用户查询序列。因此，智能体被迫在非平稳输入分布上进行优化，学习在对话上下文和家庭状态共同演变时进行适应。

复合可验证奖励。由于环境在每一步后都会动态更新，HomeEnv会逐轮评估执行有效性。为此，令 $m_t = \frac{1}{K} \sum_{k=1}^K \phi_k(s_t)$ 表示步骤 t 时蓝图条件的完成率。我们构建了一个步进式奖励函数，以平衡增量任务推进、整体成功和执行安全：

$$r_t^{(e)}(s_t, a_t) = \lambda_{\text{prog}}(m_t - m_{t-1}) + \lambda_{\text{succ}} \mathbf{1}[t = T \wedge m_T = 1] - c_{\text{audit}} \mathbf{1}[\text{blocked}(a_t)] \quad (6)$$

其中，进度项在智能体的操作使家庭状态更接近总体目标时提供密集的正向引导。成功项严格奖励在回合结束时蓝图完全满足的情况。同时，最终指示器会为被HomeEnv防火墙拦截的非法操作触发负惩罚 c_{audit} 。这种复合结构有效缓解了长程交互中的稀疏奖励问题，同时将智能体的试错行为严格限制在安全操作限制内。

4 实验

4.1 实验设置

数据集。为评估我们的方法，我们基于HomeEnv构建了SmartHome-Bench。该数据集共包含1,678个实例，全面涵盖了多样化的房间布局和丰富的设备组成。具体而言，该基准测试评估五个核心任务：原子控制（QT1）涉及执行明确且直接的用户指令；组合控制（QT2）需要协调多个设备，并根据环境进行条件依赖推理；模糊意图（QT3）侧重于从模糊的用户描述中推断或澄清具体的操作目标；上下文感知多轮交互（QT4）处理连续对话轮次中的指代消解、话题切换和回溯；个性化记忆（QT5）评估模型遵循用户习惯和偏好的能力。关于数据集的更多细节见附录E。

基线模型。我们将我们的方法与两类基线模型进行比较。第一类包含最先进的大语言模型，例如 GPT-5.5 (OpenAI, 2026年)、Claude-4.6 Sonnet (Anthropic, 2026年)、Qwen3.5 Plus (Qwen团队, 2026年)、GLM-5 (Zeng等人, 2026年)、DeepSeek-V4-Flash (深度求索, 2026年) 以及 MiniMax M2.7 (MiniMax, 2026年)。对于经过训练的基线模型，所有模型均基于 Qwen3-4B 和 Qwen3-8B。主要的对比基线采用传统的角色扮演数据合成方法 (Chen等人, 2024年; Abdullin等人, 2024年)，该方法仅使用大语言模型模拟轨迹对基础模型进行微调。为确保公平比较，角色扮演基线模型使用与我们方法相同数量的样本进行训练。

评估指标。我们通过HomeEnv内的客观状态验证来评估每个类别的成功率以及整体成功率。此外，我们通过追踪每项任务的平均工具调用次数和输出令牌数来评估操作效率。

4.2 主要结果

表1 比较了HomeFlow与各种基线模型在SmartHome-Bench上的性能。我们观察到，HomeFlow-RL，即我们的完整训练流程，在Qwen3-4B和Qwen3-8B骨干网络上均取得了最高的成功率。具体而言，对于 Qwen3-8B，HomeFlow-SFT实现了82.45%的整体成功率，在使用相同数量训练样本的情况下，比角色扮演方法高出4.67个百分点。通过逐步RLVE的进一步优化，性能提升至87.03%。在4B规模上也观察到一致的趋势，HomeFlow-RL的成功率达到84.60%，显著超越了其基础版本和角色扮演版本。

结果凸显了我们方法的三个关键优势。首先，我们的可验证数据合成为冷启动提供了更优方案，通过直接将用户指令映射到可验证的物理状态转换，使模型能比纯文本模拟更可靠地掌握复杂的设备控制逻辑。其次，逐步RLVE确保了智能体策略在动态多轮交互中保持稳健，使其能够从实时反馈中学习，并从通常导致任务失败的复合误差中恢复。最后，我们的8B HomeFlow-RL超越了领先的专有大语言模型的性能，证明在交互式执行环境中进行训练能够克服模型规模限制，从而处理复杂的多设备家庭编排。

表1: 在统一智能体框架下, 各大大语言模型在SmartHome-Bench上的性能 (%) k.

模型	QT1	QT2	QT3	QT4	QT5	总体	Avg. 工具调用	Avg. 令牌 (千)
GPT-5.5	72.82	90.19	94.27	88.05	78.95	85.80	2.13	61.16
Claude-4.6-Sonnet	88.65	79.26	88.53	83.90	81.05	84.09	2.16	98.09
Qwen-3.5 Plus	89.45	73.89	88.53	89.87	85.26	84.15	2.17	84.03
GLM-5	91.03	74.07	90.68	87.27	87.37	84.40	2.32	86.06
DeepSeek-V4-Flash	93.14	78.15	84.59	87.79	84.21	85.16	2.50	26.98
MiniMax M2.7	73.88	55.56	61.65	81.30	81.05	68.06	2.10	77.90
Qwen3-4B	38.00	9.44	13.62	65.45	53.68	30.85	1.51	68.43
Role-play-4B	89.71	55.56	82.08	85.45	74.74	75.62	1.96	119.01
HomeFlow-SFT-4B	94.99	64.70	89.50	86.75	76.80	81.50	2.06	90.48
HomeFlow-RL-4B	96.22	72.22	88.17	92.83	76.84	84.60	2.06	89.07
Qwen3-8B	27.70	10.19	13.26	68.83	60.00	31.87	1.43	64.32
Role-play-8B	91.56	60.19	84.95	85.45	70.53	77.78	1.97	119.65
HomeFlow-SFT-8B	94.99	73.89	90.68	85.71	81.05	82.45	2.01	113.88
HomeFlow-RL-8B	94.72	79.63	90.68	88.31	82.11	87.03	2.07	89.11

表2: 非对称节点扩展预算分析。基础轨迹指初始线性轨迹, 探索轨迹代表MCTS-Flow中节点扩展产生的额外轨迹, 总轨迹是两者的合计数量。

k_{user}	k_{agent}	基础轨迹	探索轨迹	总轨迹	成功率 (%)
1	1	22,000	0	22,000	80.4
3	1	15,000	5,662	20,662	82.6
1	3	15,000	6,708	21,708	84.7
3	3	15,000	6,871	21,871	85.3

4.3 数据合成分析

4.3.1 合成范式比较

我们通过逐步消融数据合成流程中的组件来追踪SFT阶段的性能提升, 如图2所示。我们的完整方法采用了蓝图基础与MCTS-Flow探索相结合的方式。移除MCTS-Flow组件 (w/o MCTS-Flow) 会使流程降级为蓝图锚定线性生成。进一步移除蓝图约束 (w/o Blueprint) 则会将方法简化为传统的纯文本角色扮演。这一比较使我们能够评估数据生成过程的效率及其对下游模型性能的影响。

更高的数据合成效率。我们首先将这些范式的生成效率作为一个经验现象进行评估。纯文本角色扮演受大语言模型幻觉影响, 对话生成成功率仅为86.33%。引入物理基础的Blueprint强制生成过程遵循初始状态和工具逻辑, 将成功率提升至92.43%。然而, 这种线性生成方式在单一步骤失败时仍会丢弃整个对话。通过结合基于树的探索和回滚保存机制, 完整的MCTS-Flow流水线避免了这种浪费, 成功完成了复杂轨迹, 并实现了最高的生成成功率, 达到96.48%。

可验证轨迹提供更好的冷启动。这些合成数据的质量直接关系到下游模型的性能。从纯文本角色扮演升级到基于Blueprint的线性生成, 将Qwen3上的任务成功率提升至

分别提升了4.58和2.26个百分点。这表明, 通过纯文本角色扮演生成的轨迹, 虽然在文本上看似合理, 却常常违反隐藏的设备前置条件。相比之下, Blueprint-




图2: 不同监督微调数据合成策略的性能比较。我们将我们的方法与线性生成 (无MCTS-Flow) 和纯文本角色扮演 (无Blueprint) 进行对比, 以证明每个组件的必要性。

基于蓝图的轨迹在HomeEnv沙箱中执行和验证，使模型能够学习可执行的状态转换，而非仅仅模仿表面的对话模式。

MCTS提升轨迹多样性。在基于蓝图的生成基础上，引入MCTS-Flow探索进一步提升了监督微调性能，在Qwen3-8B上任务成功率达到82.45%，在Qwen3-4B上达到81.50%。通过搜索替代性的用户意图和工具调用序列，MCTS-Flow显著增加了成功轨迹的多样性和覆盖范围。这一机制对于复杂的多步骤场景尤为有效，能在多轮强化学习优化之前建立一个稳健的行为先验。

4.3.2 MCTS-Flow中非对称分支因子的影响

智能家居交互展现出固有的基于角色的非对称性：用户话语在很大程度上是确定性的，并受蓝图约束，而智能体决策则涉及复杂的多步推理。为了分析这对搜索效率的影响，我们评估了不同分支因子组合 k_{user} 和 k_{agent} 的效果，同时保持可比的总轨迹规模，如表2所示。我们观察到，将更大预算分配给智能体节点（其中 k_{agent} 等于3）能获得84.7%的显著更高成功率，相比之下，用户侧扩展的成功率为82.6%。这证实了智能体的动作空间是任务复杂度的主要来源。虽然联合扩展（其中 k_{user} 和 k_{agent} 均等于3）实现了85.3%的最高成功率，但相较于仅智能体扩展的边际提升很小。这些结果从经验上证明了我们的非对称分支策略（其中 $k_{\text{agent}} > k_{\text{user}}$ ）是合理的，该策略有效地将搜索预算集中在关键的智能体决策分叉上，同时避免了对确定性用户输入的冗余采样。

4.4 逐步RLVE分析

逐步RLVE作为一个关键阶段，旨在将智能体策略与物理家庭环境的非稳态动态对齐。虽然MCTS增强的SFT提供了高质量的行为先验，但逐步RLVE使智能体能够从被动模仿转向环境驱动的探索。通过与动态用户模拟器和HomeEnv沙箱交互，智能体学习通过试错来优化其决策，并以复合可验证奖励为基础。如表3所示，HomeFlow-RL流程实现了87.03%的任务成功率，相比HomeFlow-SFT基线有4.58个百分点的显著提升。这一增益表明，回合优化使智能体能够管理长时域依赖并从中间执行失败中恢复，有效克服了通常困扰静态模仿学习的复合误差。

为了进一步研究奖励粒度，我们将HomeFlow-RL与HomeFlow-RL (ST) 进行比较。在后者中，智能体感知整个上下文，但更新仅限于基于最终结果的最终动作。虽然这使成功率提升至86.46%，但反馈的稀缺性使得策略容易早期崩溃。如图3所示，HomeFlow-RL (ST) 的策略熵急剧下降，而HomeFlow-RL则通过密集实时指导保持探索。值得注意的是，与此变体相比，HomeFlow-RL将平均工具调用减少了8%，这表明逐步信用分配有助于形成更简洁、更有目的性的规划。

。这些结果证明了在可验证环境中密集奖励的必要性。训练后模型执行的定性示例见附录F。

5 结论

HomeFlow 建立了一个可验证训练流程，其中模拟负责指定任务、验证轨迹并提供基于规则的强化学习奖励。通过结合基于蓝图综合、MCTS扩展和逐步RLVE，

表3：不同训练范式下的性能（%）对比。**ST**表示仅在最后一步进行更新的单轮强化学习，而**Full**指我们完整的、具有多轮回合奖励的逐步RLVE。

模型	成功率 Rate	Avg. 工具	Avg. Toks
HomeFlow-SFT	82.45	2.01	113.8
HomeFlow-RL (ST)	86.46	2.25	79.0
HomeFlow-RL (Full)	87.03	2.07	89.1




图3：HomeFlow-RL变体的训练动态。稀疏反馈导致ST变体早期策略崩溃，而完整模型中的密集逐步奖励则能维持探索。

HomeFlow 将 Qwen-4B 和 Qwen-8B 模型在 SmartHome-Bench 上的任务成功率分别提升至 84.20% 和 87.03%。我们的结果得出三个关键洞见：(1) 可验证环境为监督微调数据合成和在线策略优化提供了统一基础；(2) 逐步交互维持了探索并显著改善了长时程控制；(3) MCTS 驱动搜索增强了轨迹多样性，同时将已验证前缀转化为可复用资产。最终，这些发现为具有可检查目标的人工智能物联网智能体提供了一条实用路径。

局限性与未来工作。目前，HomeFlow 依赖于确定性仿真，需要从模拟到现实的适应以应对现实世界不确定性，如延迟和传感器漂移。更广泛的部署还需要适应多样化的厂商特定协议以扩展设备覆盖范围，同时减轻由 MCTS 和在线强化学习引入的固有计算开销。有前景的未来方向包括引入持续学习以实现个性化家庭日常流程，并将可验证框架扩展到更广泛的人工智能物联网生态系统。

参考文献

Yelaman Abdullin, Diego Molla-Aliod, Bahadorreza Ofoghi, John Yearwood 和 Qingyang Li. 2024年。使用大语言模型智能体生成合成对话数据集。arXiv预印本arXiv:2401.17461。

Anthropic. 2026年。Claude sonnet 4.6 系统卡片。https://www.anthropic.com/claude-sonnet-4-6-system-card。访问日期：2026-05-07。

Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon 等 1 位作者。2022年。宪法人工智能：基于人工智能反馈的无害性。arXiv预印本arXiv:2212.08073。

Rune Birkmose, Nathan Mørkeberg Reece, Esben Hofstedt Norvin, Johannes Bjerva 和 Mike Zhang. 2025年。用于家庭助手的设备端大语言模型：在意图检测和响应生成中的双重角色。arXiv预印本arXiv:2502.12923。

Nuo Chen, Yan Wang, Yang Deng 和 Jia Li. 2024年。人工智能剧场的奥斯卡：语言模型角色扮演综述。arXiv预印本arXiv:2407.11484。

Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen 等 1 位作者。2025年。Gemini 2.5：以高级推理、多模态、长上下文和下一代智能体能力推动前沿。arXiv预印本arXiv:2507.06261。

DeepSeek-AI. 2026年。Deepseek v4 技术文档。https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf。访问日期：2026-05-07。

Yifei Gao, Junhong Ye, Jiaqi Wang 和 Jitao Sang. 2025年。Websynthesis：用于高效WebUI轨迹合成的世界模型引导的蒙特卡洛树搜索。arXiv预印本arXiv:2507.04370。

Jiawei Gu, Xuhui Jiang, Zhichao Shi, Hexiang Tan, Xuehao Zhai, Chengjin Xu, Wei Li, Yinghan Shen, Shengjie Ma, Honghao Liu 等 1 位作者。2024年。LLM即法官综述。arXiv预印本arXiv:2411.15594。

Daya Guo 等 1 位作者。2025年。Deepseek-r1 通过强化学习激励大语言模型中的推理。Nature, 645: 633–638。

Badis Hammi, Sherali Zeadally, Rida Khatoun 和 Jamel Nebhen. 2022年。智能家居调查：漏洞、风险和对策。Computers & Security, 117: 102677。

Xinyu Huang, Leming Shen, Zijing Ma 和 Yuanqing Zheng. 2025年。通过定制化小语言模型实现隐私保护和个性化智能家居。arXiv预印本arXiv:2507.08878。

Noor Ul Huda, Ijaz Ahmed, Muhammad Adnan, Mansoor Ali 和 Faisal Naeem. 2024年。专家和智能系统助力智能家居向可持续智慧城市转型：全面综述。Expert Systems with Applications, 238: 122380。

Carlos E. Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press 和 Karthik Narasimhan. 2023年。Swe-bench：语言模型能否解决现实世界GitHub问题？arXiv预印本arXiv:2310.06770。

Evan King, Haoxiang Yu, Sangsu Lee 和 Christine Julien. 2024年。Sasha：智能家居中大语言模型的创造性目标导向推理。Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 8(1): 1–38。

Jing Yu Koh, Robert Lo, Lawrence Jang, Vinay Duvvur, Ming Chong Lim, Po-Yao Huang, Graham Neubig, Daniel Fried 和 Ruslan Salakhutdinov. 2024年。语言模型智能体的树搜索。arXiv预印本arXiv:2407.01476。

Harrison Lee、Samrat Phatale、Hassan Mansoor、Thomas Mesnard、Johan Ferret、Kellie Lu、Colton Bishop、Ethan Hall、Victor Carbune、Abhinav Rastogi 等 1 位作者。2024年。RLAIF 与 RLHF：利用人工智能反馈扩展基于人类反馈的强化学习。载于第41届国际机器学习会议论文集。Haitao Li、Qian Dong、Junjie Chen、Huixue Su、Yujia Zhou、Qingyao Ai、Ziyi Ye 和 Yiqun Liu。2024年。LLMs即法官：基于大语言模型的评估方法全面综述。arXiv预印本 arXiv:2412.05579。Jiaze Li、Jingyang Chen、Yuxun Qu、Shijie Xu、Zhenru Lin、Junyou Zhu、Boshen Xu、Wenhui Tan、Pei Fu、Jianzhong Ju 等 1 位作者。2025a。小米 MIMO-VL-MILOCO 技术报告。arXiv预印本 arXiv:2512.17436。Silin Li、Yuhang Guo、Jiashu Yao、Zeming Liu 和 Haifeng Wang。2025b。Homebench：在智能家居中通过有效和无效指令跨单设备和多设备评估大语言模型。arXiv预印本 arXiv:2505.19628。MiniMax。2026年。MiniMax M2.7：自我进化的早期回响。<https://www.minimax.io/news/minimax-m27-en>。访问日期：2026-05-07。Arindam Mitra、Luciano Del Corro、Guoqing Zheng、Shweti Mahajan、Dany Rouhana、Andres Cudas、Yadong Lu、Wei-ge Chen、Olga Vrousos、Corby Rosset 等 1 位作者。2024年。AgentInstruct：迈向具有智能体流程的生成式教学。arXiv预印本 arXiv:2407.03502。Bo Ni、Leyao Wang、Yu Wang、Branislav Kveton、Franck Dernoncourt、Yu Xia、Hongjie Chen、Reuben Leura、Samyadeep Basu、Subhojyoti Mukherjee 等 1 位作者。2026年。基于大语言模型的对话用户模拟综述。arXiv预印本 arXiv:2604.24977。OpenAI。2026年。GPT-5.5 系统卡片。<https://deploymentsafety.openai.com/gpt-5-5>。访问日期：2026-05-07。Long Ouyang、Jeff Wu、Xu Jiang、Diogo Almeida、Carroll L. Wainwright、Pamela Mishkin、Chong Zhang、Sandhini Agarwal、Katarina Slama、Alex Ray 等 1 位作者。2022年。训练语言模型遵循人类反馈的指令。载于神经信息处理系统进展。Qwen团队。2026年。Qwen3.5：迈向原生多模态智能体。<https://qwen.ai/blog?id=qwen3.5>。访问日期：2026-05-07。Dmitriy Rivkin、Francois Hogan、Amal Feriani、Abhisek Konar、Adam Sigal、Steve Liu 和 Greg Dudek。2023年。SAGE：具有接地执行的智能家居智能体。arXiv预印本 arXiv:2311.00772。Gyuhyeon Seo、Jungwoo Yang、Junseong Pyo、Nalim Kim、Jonggeun Lee 和 Yohan Jo。2026年。SimuHome：一个面向智能家居大语言模型智能体的时序和环境感知基准测试。载于国际学习表征会议。Yunfan Shao、Linyang Li、Junqi Dai 和 Xipeng Qiu。2023年。角色大语言模型：一个可训练的角色扮演智能体。载于2023年自然语言处理经验方法会议论文集，第13153–13187页。Zhihong Shao、Peiyi Wang、Qihao Zhu、Runxin Xu、Junxiao Song、Xiao Bi、Haowei Zhang、Mingchuan Zhang、Y. K. Li、Y. Wu 和 Daya Guo。2024年。DeepseekMath：在开源语言模型中突破数学推理的极限。arXiv预印本 arXiv:2402.03300。Aaditya Singh、Adam Fry、Adam Perelman、Adam Tart、Adi Ganesh、Ahmed El-Kishky、Aidan McLaughlin、Aiden Low、AJ Ostrow、Akhila Ananthram 等 1 位作者。2025年。OpenAI GPT-5 系统卡片。arXiv预印本 arXiv:2601.03267。Xintao Wang、Heng Wang、Yifei Zhang、Xinfeng Yuan、Rui Xu、Jen-tse Huang、Siyu Yuan、Haoran Guo、Jiangjie Chen、Shuchang Zhou 等 1 位作者。2025年。Coser：协调基于大语言模型的既定角色角色模拟。载于第42届国际机器学习会议论文集。Yizhong Wang、Yeganeh Kordi、Swaroop Mishra、Alisa Liu、Noah A. Smith、Daniel Khashabi 和 Hannaneh Hajishirzi。2022年。Self-Instruct：用自生成指令对齐语言模型。arXiv预印本 arXiv:2212.10560。Zhepei Wei、Wenlin Yao、Yao Liu、Weizhi Zhang、Qin Lu、Liang Qiu、Changlong Yu、Puyang Xu、Chao Zhang、Bing Yin、Hyokun Yun 和 Lihong Li。2025年。WebAgent-R1：通过端到端多轮强化学习训练网络智能体。arXiv预印本 arXiv:2505.16421。Zhiheng Xi、Wenxiang Chen、Xin Guo、Wei He、Yiwen Ding、Boyang Hong、Ming Zhang、Junzhe Wang、Senjie Jin、Enyu Zhou 等 1 位作者。2025年。基于大语言模型的智能体的兴起与潜力：综述。中国科学：信息科学，68(2)：121101。

Can Xu, Qingfeng Sun, Kai Zheng, Xiubo Geng, Pu Zhao, Jiazhan Feng, Chongyang Tao, Qingwei Lin, and Daxin Jiang. 2023年. [WizardLM: 赋能大规模预训练语言模型遵循复杂指令](#). *arXiv预印本 arXiv:2304.12244*. An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, 及另外1人. 2025年. [Qwen3技术报告](#). *arXiv预印本 arXiv:2505.09388*. Ziqi Yin, Mingxin Zhang, and Daisuke Kawahara. 2025年. [Harmony: 一个基于本地部署大语言模型的人类感知、响应式、模块化助手](#). 收录于 2025年ACM普适与泛在计算国际联合会议配套论文集, 第126–130页. 美国计算机协会. Chaerin Yu, Chihun Choi, Sunjae Lee, Hyosu Kim, Steven Y. Ko, Young-Bae Ko, and Sangeun Oh. 2026年. [利用大语言模型实现高效且个性化的智能家居自动化](#). *arXiv预印本 arXiv:2601.04680*. Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, 及另外1人. 2025年. [Dapo: 一个大规模的开源大语言模型强化学习系统](#). *arXiv预印本 arXiv:2503.14476*. Aohan Zeng 及另外1人. 2026年. [GLM-5: 从氛围编码到智能体工程](#). *arXiv预印本 arXiv:2602.15763*. Zhonghao Zhan, Krinos Li, Yefan Zhang, and Hamed Haddadi. 2026年. [HearthNet: 面向智能家居的边缘多智能体编排](#). *arXiv预印本 arXiv:2604.09618*. Kaiyan Zhang, Yuxin Zuo, Bingxiang He, Youbang Sun, Runze Liu, Che Jiang, Yuchen Fan, Kai Tian, Guoli Jia, Pengfei Li, 及另外1人. 2025年. [大型推理模型强化学习综述](#). *arXiv预印本 arXiv:2509.08827*.

一个 HomeEnv 模拟引擎

我们介绍HOMEENV，这是一个支持可配置设备规格、程序化控制API以及在Gym风格环境中进行可验证任务执行的智能家居模拟引擎。

A.1 基于YAML的智能设备规格

设备使用基于YAML的配置格式进行定义。以下示例定义了一个智能灯设备：

智能灯设备的 YAML 规格

```
- name: light
  userdata:
    类别: light
    品牌: example-brand
    设备标识符: "100001"
  属性:
    - 名称: 状态
      类型: str
      选项: ["开", "关"]
    - 名称: 亮度
      类型: int
      范围: [1, 100]
      单位: 百分比
    - 名称: 色调饱和度
      类型: 元组
      项目:
        - 类型: 浮点数
          范围: [0.0, 360]
        - 类型: 浮点数
          范围: [0, 100]
  服务:
    - 名称: 开启 _on
      代码: self.state = "on"
    - 名称: 开关 _off
      代码: self.state = "关闭"
    - 名称: 设置_亮度
      参数:
        - 名称: 亮度
          类型: 整数
          范围: [1, 100]
      代码: self.亮度 = 亮度
    - 名称: 设置_hs_颜色
      参数:
        - 名称: 色调饱和度
          类型: 元组
          项目:
            - 类型: 浮点数
              范围: [0.0, 360]
            - 类型: 浮点数
              范围: [0, 100]
      代码: self.hs _颜色 = hs _颜色
```

A.2 程序化设备交互API

已配置设备可以通过统一高层API进行实例化和控制：

已配置设备的程序化控制

```
# 加载已配置的灯光设备with open("light.yaml", "r") as f: entities = Entity.load(f)light_spec = entities[0]# 使用随机化属性初始化设备light = light_spec.rand()# 检查并控制设备print(light.state, light.brightness)light.turn_on()light.set_brightness(80)print(light.state, light.brightness)
```

A.3 Gym风格的HomeSimulation环境

我们进一步构建了一个Gym风格的智能家居环境，它能自动生成房屋布局和嵌入式设备，包括房间、楼层和设备实例。

与HomeEnv模拟器的交互

```
env = gym.make("HomeEnv-v0", home=HomeSampler.sample_test()) 观察, -, 终止, 截断, 信息 = env.step({"名称": "pyexec", "code": "" device("1001").set_亮度(80) print(f'亮度 of light is {device(' 1001' ).亮度}') "" })
```

A.4 可验证任务评估

为支持自动 在自动评估中，我们将可验证任务定义为从环境状态推导出的逻辑条件。

ate.

环境任务验证

```
# 真实条件
真实_条件_列表 = [
    "设备(' 1001' ).状态 == 'on'",
    "设备(' 1001' ).亮度 > 60",
]

环境 = gym.make("HomeEnv-v0", home=HomeSampler.sample_test())

# 注册任务
对于 ground_truth_list 中的每个 gt:
    环境.引擎.任务.add_task(gt)

# 与环境交互
环境.step({"名称": "pyexec", "code": "..."})

# 验证任务完成
```

```
for task in 环境引擎任务列表: print(f"任务ID={task.id} 状态={task.finished} 条件={task.condition}")
```

B 蓝图实现细节

我们提出了一个两阶段数据合成框架，用于生成大规模、可控且多样化的面向任务的对话数据。整体流程包括：

- 蓝图生成。**根据用户画像、家庭环境以及约束验证机制，构建结构化任务蓝图。
- 对话生成。**基于生成的蓝图、用户画像和模拟智能体，合成基于情境的多轮交互。

B.1 蓝图生成

B.1.1 元信息构建

蓝图生成基于三类元信息：家庭环境、用户画像和工具/动作空间，详细信息见表4。

Ta表 4：Blueprint构建中使用的元信息。

类别	属性	描述
家庭环境	环境- 温度、湿度、亮度	智能家居环境中的物理状态变量
	设备 APIs （例如， light.turn_on, ac.set_temp）	可控智能家居设备接口。
	工具API（例如，计算器、天气） 环境实体	外部函数调用接口。 空间上下文，例如房间和室内/室外区域。
用户画像	年龄、性别	基础人口统计属性。
	生理属性	身高、体重和身体状况。
	健康状况	慢性疾病和睡眠相关状况。
	行为习惯 偏好	日常作息和生活方式模式。 环境偏好（温度、照明等）。

为确保真实性和多样性，我们从预定义分布中采样属性，并强制执行结构化一致性约束（例如，年龄-健康相关性、生活方式-偏好一致性）。
我们采用三阶段生成范式：

- (1) **基础蓝图生成器。**给定用户画像和环境状态，该生成器会生成一个代表可能用户目标的任务蓝图候选集。整体Blueprint如章节B.1.2所示。
- (2) **蓝图过滤器。**蓝图过滤器会在任务执行前移除无效或低质量的候选蓝图，其总结见表5。

表 5：蓝图过滤器使用的过滤标准。

标准	描述
逻辑一致性	移除矛盾或不连贯的候选方案。
可执行性	确保与环境及工具API的兼容性。
多样性	减少冗余候选方案并提升任务覆盖率。

- (3) **查询类型。**我们引入一种结构化查询扰动机制来控制难度与多样性，如表6所示。

形式上，查询是从这些因素的联合空间中采样，以实现可控的复杂性和多样性。

表6：查询扰动控制空间。

维度	选项	描述
意图清晰度	清晰 / 模糊 / 缺失-slot	控制用户意图的显式程度。
噪声水平	干净 / 有噪声	控制语言扰动和歧义。
设备范围	单设备 / 多设备 / 批处理设备	控制动作的粒度。
执行依赖	独立 / 依赖	控制跨步骤的时间依赖关系。

B.1.2 完整示例

Blueprint

任务：书房阅读与运动前环境调节**描述：**

场景一：下午，李梅准备在书房练习书法。室内传感器显示温度约为13°C；她感觉有点冷。吊扇灯开着，但亮度仅为11%，色温偏暖，这使得笔画难以看清。智能音箱已暂停但未静音，她担心通知音会打断练习。她希望快速让房间暖和起来，然后将照明调得更亮、色温更偏冷白色，最后保持环境安静以便专注书写。

场景二：在备用卧室进行太极热身时，湿度计显示房间很热（约31.8°C），湿度相对较高（约62%）。他希望降低湿度，并将体感温度降至20°C左右，以适合轻度运动。

任务：

- 意图：**房间感觉冷——她希望暖和些；书写前，灯光太暗且色调偏暖——她希望更亮。

查询类型：缺失_槽位+安静+依赖+多个_设备

查询：如果空调关闭，则开启制热并将温度设置为约24°C；同时书房灯太暗——请提高亮度和色温。

条件：

(设备("FQVZSo_p").状态 == "开启" 且 设备("FQVZSo_p").空调_模式 == "制热" 且 23.5 <= 设备("FQVZSo_p").目标_温度 <= 24.5) 且 (85 <= 设备("sTPi5CsC").灯光_亮度 <= 100) 且 (5000 <= 设备("sTPi5CsC").灯光_色温 <= 6500)

设备：FQVZSo_p, sTPi5CsC
- 意图：**担心被通知音打扰——希望环境更安静。

查询类型：清晰+安静+依赖+单一_设备

查询：如果智能音箱未被静音，请将其静音。

条件：

(设备("lTirJUuR").播放器.音量_静音_启用 == True)

设备：lTirJUuR
- 意图：**备用卧室湿度高——希望降低；备用卧室温度高——希望调低。

查询类型：清晰+安静+独立+单一_设备

查询：如果备用卧室空调仍在运行，请将其切换到除湿模式，并将设定温度降低至21°C左右。

条件：
(device("e7J6mKqC").ac_模式 == "dry") 和 (20 <= device("e7J6mKqC").target_温度 <= 21)

设备：e7J6mKqC

B.2 对话生成

B.2.1 仿真框架

我们构建了一个由以下部分组成的闭环交互系统，这为对话提供了基于现实、可执行且具备状态追踪的轨迹。如表7所示。

表 7：交互式评估环境中的组件。

组件	Role
蓝图用户 (GPT-5)	生成基于任务的用户查询。
助手 (GPT-5)	生成响应并执行工具操作。
沙盒环境状态	执行操作并返回环境反馈。 在每次交互步骤后动态更新。

B.2.2 输出数据结构

每个样本均以统一的结构化格式表示，同时支持监督学习和强化学习。如表8所示。

表8：统一数据样本结构。

组件	字段	描述
元信息	用户画像、环境状态、 查询类型	上下文条件信号。
对话消息	用户输入、助手响应、 环境观察	多轮交互轨迹。
任务状态	完成标志	执行级监督信号。

B.3 核心提示设计

Blueprint Generation Prompt

Task 定义。你是一个专家系统，用于生成基于真实家庭环境 和用户画像的智能家居交互场景。

目标。为智能家居系统合成现实生活场景及相应的原子可执行任务，确保物理可行性、行为真实性以及严格的设备级接地性。

生成提示流程。

1. 生活场景构建

- 生成固定数量的日常生活场景。
- 每个场景必须描述在单一物理位置发生的连续人类行为。
- 场景必须反映用户画像特征和环境状态。
- 设备状态必须基于观测到的环境信息进行设定。
- 请勿生成命令式或任务列表式描述。

2. 原子任务分解

- 将每个场景分解为原子任务。
- 每个任务必须严格源自一个场景。
- 每个任务必须仅代表一个单一用户意图。

- 不得引入新的设备或属性。

硬约束。

1. 设备约束

- 只允许使用在环境中显式定义的设备。
- 设备标识符必须完全匹配。

2. 属性约束

- 只能使用设备服务定义中列出的属性。
- 不允许出现推断或臆想的属性。

3. 原子性约束

- 每个任务必须恰好包含一个用户意图。
- 不允许出现多意图或复合任务。

4. 物理一致性约束

- 所有动作都必须在给定环境中具备物理可执行性。
- 设备状态转换必须真实且有效。

5. 设备状态依赖约束

- 功能属性（例如温度、亮度）仅在设备处于活动状态时有效。
- 如果设备处于非活动状态，则必须在修改依赖属性之前包含激活操作。

输出格式。 仅限严格的JSON格式，无需解释或额外文本。

用户档案生成提示

任务定义。 您是一个用于生成智能家居用户画像的专家系统。**目标。** 为智能家居自动化系统合成真实、多样且内部一致的用户画像。**设计原则。**

1. 智能家居基础所有属性必须映射到可控系统行为：

- 生理特征 → 环境适应
- 健康 → 暖通空调 / 空气质量控制
- 习惯 → 自动化调度
- 偏好 → 场景控制策略

2. 完整性约束

- 所有模块必须齐全：基础、生理特征、健康、习惯、偏好
- 无缺失或空字段
- 要求完全的内部一致性

3. 真实性约束

- 覆盖完整的人口统计谱系
- 包含真实的健康状况
- 确保物理上合理的数值

输出格式。 仅限严格JSON，无需解释。

用户查询生成提示

任务定义。您是一个用于在智能家居环境中生成自然用户请求的专家系统。**目标。**将结构化任务状态转换为现实、简洁且可执行的用户查询，这些查询可直接通过工具调用用于设备控制。

设计原则。

1. 以任务为中心的锚定 所有输出必须严格与当前任务列表保持一致：

- 仅关注**未完成**任务
- 忽略历史对话，除非与任务相关
- 确保每个查询都直接有助于任务完成

2. 设备状态 感知生成必须考虑实时家居

状态：

- 房间级别和设备级别状态约束
- 避免冗余或已满足的操作
- 根据当前设备条件调整操作

3. 自然用户表达约束 确保输出反映真实的用户行为：

- 避免以僵化的格式枚举多个参数或房间
- 避免使用过于结构化或机器化的命令模式
- 使用简短、对话式且隐含的指令

4. 极简主义原则

- 每个生成步骤使用一个统一的查询
- 无任务ID，无解释，无推理痕迹
- 仅在自然表达时合并动作

5. 工具执行要求

- 输出必须通过后_处理工具传递
- 必须包含：- 查询：一个单一的可执行指令字符串-
理由：生成逻辑的结构化论证

- 查询绝不能为空或为null

Out遵循格式。 仅限严格的工具调用格式。不允许自由文本回 响应。

智能家居智能体提示

Task 定义。 你是一个具备强大推理和设备控制能力的智能智能家居智能体。你 opera 在用户家庭环境内部。
目标。 准确理解用户意图（查询/控制），通过工具与智能家居设备交互，并返回正确、可执行的结果。

系统上下文。

- **家庭设备：**结构化的多房间设备列表，包含元数据（id、did、类别、品牌、标签）。
- **用户内存：**历史偏好、行为及上下文片段（如可用）。
- **用户场景上下文：**用于个性化的环境与情境信号。

核心工作流（严格）。

1. **意图识别：**识别查询类型（状态 / 控制 / 模糊 / 闲聊）。
2. **信息检索：**在执行操作前查询设备手册和状态。
3. **消歧：**当意图或目标不确定时，应用澄清规则。
4. **工具执行：**仅在验证能力和参数后执行设备操作。
5. **结果验证：**检查工具输出；若未满足则迭代。
6. **用户响应：**仅返回简洁（ ≤ 50 个中文字符）、口语化的答案。

澄清原则。

- 若设备 + 功能可唯一识别，则不进行澄清。
- 仅当存在多种有效解释时，才询问用户。
- 除非明确说明（例如“所有灯”），否则避免解释“所有设备”。

执行约束。

- 在控制前，务必先获取设备能力。
- 在执行前，务必确保参数有效性。
- 切勿向用户输出工具推理或内部步骤。

C MCTS-Flow用于对话生成

在本节中，我们展示一个使用 MCTS-Flow 来生成和选择对话数据的示例。

如图4所示，蓝图规定了用户目标、任务目标和成功指标，这些统称为用户目标与蓝图验证器。只有当对话会话终止时满足蓝图验证器的所有条件，该会话才被视为成功。

在此示例中，MCTS-Flow 从一个固定的蓝图执行了 5 次对话推演。初始用户查询由根节点生成，随后是智能体的回复。对于每个用户查询，智能体最多生成 3 个不同的候选回复。

一些对话在终止时未能满足蓝图验证器的条件，因此被视为不成功，如红色所示。其中有两个满足了条件，如绿色所示。这些成功的实例可以被收集起来用于训练智能家居智能体。值得注意的是，成功的对话轨迹与部分失败的对话轨迹有重叠部分。

就此示例而言，MCTS-Flow 将收集 2 条成功的对话轨迹，如下面 2 张图所示。请注意，这 2 段对话以不同的方式满足了用户需求，从而增强了数据多样性。




图4：MCTS-Flow用于对话生成的演示。

成功对话 1

用户查询：“光线太刺眼，风扇摆头让我分心。而且气流太强了。”

智能家居智能体：

- [查询] → Q查询房间的设备状态。
- [设备控制] → 将窗帘倾斜至40度。

用户查询：“风扇还是让我分心。而且气流太强了。”

智能家居智能体：

- [查询] → 查询该房间的设备规格。
- [设备控制] → 将风扇的摆动设置为‘关闭’。将风扇的模式设置为‘睡眠’

成功对话 2

用户查询：“光线太刺眼了。风扇摆动让我分心。而且气流太强了。”

智能家居智能体：

- [查询] → 查询房间的设备状态。
- [设备控制] → 设置风扇的模式为睡眠 p’.

用户查询：“风扇还是让我分心。而且眩光依然很强。”

智能家居智能体：

- [查询] → 查询该房间的设备规格。
- [设备控制] → 将风扇的摆动设置为‘关闭’。将窗帘倾斜至40度。

D 两阶段训练の詳細信息

D.1 训练数据量与构成

监督微调（SFT）数据集由三个不同的子集构成，它们均源自一个共享的、包含20,000个用户画像的基础池。具体而言，我们首先生成了这20,000个画像，每个画像都封装了诸如年龄、职业和行为习惯等属性。随后，我们使用HomeMaker为每位用户程序化地生成了相应的家庭配置。在此基础上，我们合成了对话轨迹，这些轨迹对应于我们在消融研究中评估的三种数据生成方案：

纯文本角色扮演（无Blueprint）：基于这20,000个包含基础家庭信息的用户画像，我们采用了一种传统的纯文本角色扮演方案，没有严格的物理蓝图约束。这个初始过程生成了20,000个对话。在应用基于大语言模型的过滤器以确保质量后，保留了16,700个对话，并从中随机选取了15,000个样本构成了第一个子集。

蓝图锚定线性生成（无MCTS-Flow）：为融入物理基础，我们利用HomeMaker为相同的20,000名用户生成了显式的家庭Blueprint。遵循线性生成方案（不进行基于搜索的探索），我们获得了17,500条物理基础对话轨迹，并从中随机选取15,000个样本构成此子集。

蓝图锚定MCTS-Flow（完整流程）：应用我们完整的数据合成流程，我们将Blueprint配置与MCTS-Flow搜索相结合。在验证信号的引导下，这一动态探索阶段产生了高度多样化的30,000条可验证对话。从中随机选取15,000个样本，构成最终、最高质量的SFT子集。

对于后续的强化学习阶段，训练环境由一组独立的10,000个基础配置初始化，每个配置包含用户画像、家庭信息以及一份物理Blueprint。我们构建了两个对应的设置以支持在线策略优化：

HomeFlow-RL（完整逐步RLVE）：这10,000个基础配置被直接用于初始化HomeEnv模拟器，使智能体能够在逐步密集奖励的引导下，进行完整的多轮次情景交互。

HomeFlow-RL (ST)：为构建单回合消融基线，我们首先从相同的10,000个基础配置中生成了完整的多回合轨迹。随后，我们移除了所有中间的工具使用和设备控制回合，仅保留最终的单回合交互。这限制了智能体只能感知完整上下文，但仅能基于最终结果接收稀疏反馈。

D.2 训练设置

奖励塑形：我们设计了三个基于规则的奖励组件来约束模型行为。

代码检查对使用受限的Python操作进行惩罚，包括内省和动态执行相关的关键字，如`getattr`、`setattr`、`eval`、`exec`以及`compile`等。

代码长度强制执行1000个令牌的最大代码长度限制，若超出则分配 -1 的奖励，否则为0。

回合检查将交互范围限制在3个回合内，同样，若违反则分配 -1 的惩罚，否则为0。

两种 HomeFlow-RL 设置的详细超参数总结于表9中。

E SmartHome-Bench

我们构建了SmartHome-Bench，这是一个包含1,678个测试样本的综合性基准测试，系统性地分为5个主要组别和18个子类别（见表10）。为了严格测试智能体的可扩展性和

表9: RLVE训练超参数。粗体值标明了关键差异: HomeFlow-RL (ST) 采用熵正则化 ($\beta_{\text{entropy}} = 10^{-4}$) 来对抗崩溃, 而 HomeFlow-RL (Full) 则移除了熵损失, 转而强制执行针对 SFT 参考模型的 KL 约束 ($\beta_{\text{KL}} = 3 \times 10^{-3}$), 并依赖动态用户模拟器进行自然探索。

参数	HomeFlow-RL (ST)	HomeFlow-RL (Full)
GPU类型	Nvidia H20 96GB	
内存	1TB	
基础模型	Qwen3-8B-SFT	
TP	4	
PP	1	
CP	1	
SP	on	
展开组大小	8	
展开温度	1.0	
LR	1e-6	
学习率预热比例	0.01	
最小学习率	5e-7	
任务完成权重	1.0	
代码检查权重	0.2	
代码长度权重	0.2	
回合检查权重	0.2	
GPU数量	32	96
训练时间成本	38h+	95h+
KL损失系数	0.0	3e-3
熵损失系数	1e-4	0.0
用户大语言模型	—	DeepSeek-V3.2

空间推理能力, 环境难度高度多样化, 涵盖了从设备少于10个的简单设置到设备超过100个的高度复杂家庭等广泛的家庭布局分布。

表10: 模板族与生成规则。

族	模板	基础规则	表面指令规则
TC1: 原子性控制	清晰指令; 口语化请求; 嘈杂话语	选择一个可控设备, 并指定一项支持的服务或属性变更。目标必须唯一且可直接执行。	清晰即显式; 口语化使用日常用语; 有噪声可能包含填充词、重复、类似ASR的产物, 或即时自我修正。
TC2: 组合控制	显式多设备; 批处理操作; 状态依赖; 房间依赖; Top-N选择	选择多个操作、一个设备集合、一个状态过滤子集、一个房间条件子集, 或一个排序后的前 k 目标。所有被选中的设备必须支持所请求的操作。	在一个家庭请求中表达依赖关系, 例如, “所有灯”、“上方的“所有灯”、“上方灯”80%”、“空调开启的房间”, 或“这两个最快的风扇”。
TC3: 模糊意图	状态级歧义; 场景级歧义; 槽位缺失	选择一个合理的目标, 但使初始话语表述不足、主观或场景化。缺失的槽位可能包括房间、设备、模式、数值、持续时间或时间。	初始查询应需要澄清或基于上下文的推断。隐藏的目标在整个过程中被保留。预期查询或参考澄清轨迹。

未完待续

表10：模板族和生成规则（续）。

族	模板	基础规则	表面指令规则
TC4：上下文感知 多轮交互 交互	上下文延续； 话题转换； 指代消解； 用户纠正	当前目标取决于 先前轮次。生成器可能 继承一个设备、覆盖先前的 操作、解析一个代词，或 切换话题同时保留 上下文。	使用自然对话形式 例如“也做那个”、“不， 调到26度”、“把那个 关掉”，或一个话题转移的 后续对话。
TC5：个性化 内存	短期记忆；	使用近期交互事实或存储的 用户偏好来填充省略的动作 细节。该任务不应 在缺少这些信息的情况下以预期方式解决。 所提供的内存。	允许紧凑的 偏好触发 指令，例如“睡眠 时间”、“照常”或“按我 喜欢的方式设置”。

F 强化学习训练对模型能力影响的案例研究

在本节中，我们展示几个关于强化学习训练的案例研究。案例一说明了强化学习后模型理解能力的提升。案例2说明了强化学习后模型优先级排序技能和推理能力的提升。

案例一(强化学习前)：理解能力

用户查询："将客厅空调调整到20度并开启垂直摆风。"

智能家居智能体："客厅空调已设置为20度，并已开启垂直摆风。"

用户查询："对主卧室和客房也做同样的设置，并且打开所有的窗帘。"

智能家居智能体（失败）：

- [查询] → Q_{查询窗 he d 帘}的设备规格。
- [设备控制] → 打开窗帘。
- [响应] → 主卧室窗帘和客房窗帘均已打开。
- 结果：助手没有为主卧室和客房都设置空调。

案例一（强化学习后）：理解能力

User 查询：“将客厅空调调整至20度并开启垂直摆风。” **智能家居智能体**

t:

“客厅空调已设置为20度，并已开启垂直摆风。”

用户查询：“为主卧室和客房也做同样设置，并且打开所有窗帘。”

智能家居智能体（成功）：

- [查询] → Q_{查询 he d 空调}的设备规格。
- [设备控制] → 设置空调。
- [查询] → 查询窗帘的设备规格。
- [设备控制] → 打开窗帘。
- [响应] → 主卧室和客房的空调均已开启，温度设定为20度，并已启用垂直摆风。主卧室窗帘和客房窗帘均已打开。
- 结果：助手完成了空调和窗帘两项操作，正确理解了“执行相同操作”。

案例2（强化学习前）：优先级技能能力与推理能力

用户查询：“感觉有点凉。把空调调到自然风。”

智能家居智能体：“多个房间的空调正在运行。您想调整哪个房间？”

用户查询：“主卧室。”

智能家居智能体（失败）：

- [Devi 尝试将空调的 1] → T模式设置为‘自然’模式。
- 结果：该空调没有“自然”模式，因此此指令执行失败。

案例2（强化学习后）：优先级排序技能能力与推理能力

用户查询：“感觉有点凉。把空调调到自然风。”

智能家居智能体：“多个房间的空调正在运行。您想调整哪个房间？”

用户查询：“主卧室。”

智能家居智能体（成功）：

- [查询] → 查询主卧室空调的设备规格。
- [推理] → 发现没有‘自然’模式，并推测用户想要‘仅风扇’模式。
- [设备控制] → 将空调的模式设置为‘仅风扇’。
- 结果：正确读取了设备状态，并将‘自然风’合理地映射到了‘仅风扇’模式。